دانشگاه صنعتی شریف
دانشکده مهندسی کامپیوتر

پایان‌نامه کارشناسی ارشد
مهندسی کامپیوتر

بخش‌بندی خودکار چنداندامی شکم در تصاویر سی‌تی‌اسکن با تمرکز بر بهبود کیفیت بر روی تصاویر بدون تزریق ماده‌حاجب

نگارش

سعیده دانائی

استاد راهنما

حمیدرضا ربیعی

شهریور ۱۴۰۵

سپاس

از استاد بزرگوارم که با کمک‌ها و راهنمایی‌های بی‌دریغشان، مرا در به سرانجام رساندن این پایان‌نامه یاری داده‌اند، تشکر و قدردانی می‌کنم. همچنین از همکاران عزیزی که با راهنمایی‌های خود در بهبود نگارش این نوشتار سهیم بوده‌اند، صمیمانه سپاسگزارم.

فهرست مطالب

۱ مقدمه ۱

۱-۱ اهمیت مسئله ۱

۱-۲ تعریف مسئله ۲

۱-۳ چالش‌ها ۳

۱-۴ اهداف پژوهش ۴

۱-۵ ساختار پایان‌نامه ۴

۱-۶ جمع‌بندی ۵

۲ کارهای پیشین ۶

۲-۱ پیش‌زمینه‌ی بالینی: سی‌تی چندفازی و فازهای کنتراست ۷

۲-۲ بخش‌بندی چندعضوی سی‌تی شکمی و شکاف کیفیت در فاز بدون‌کنتراست ۸

۲-۳ مجموعه‌داده‌های سی‌تی شکمی: کاوش وضعیت موجود ۱۱

۲-۴ تشخیص فاز کنتراست در تصاویر سی‌تی خام ۱۴

۲-۵ ثبت تصویر بین‌فازی سی‌تی ۱۸

۲-۶ تولید تصاویر سی‌تی کنتراست‌دار از تصاویر سی‌تی بدون تزریق ماده‌ی حاجب ۲۴

۲-۷ جمع‌بندی و جای خالی پژوهش ۳۰

۳ روش پیشنهادی ۳۲

۴ آزمایش‌ها ۳۳

۵ نتیجه‌گیری ۳۴

مراجع ۳۵

واژه‌نامه ۴۶

آ مطالب تکمیلی ۴۹

فهرست جداول

۲-۱ مدل‌های بخش‌بندی و مطالعات شکاف بین‌فازی: سال انتشار، داده و تسک، مقادیر گزارش‌شده و وضعیت کد. ۱۱

۲-۲ هفت مقوله‌ی چارچوب ارزیابی ریسک سوگیری [۱]. ۱۲

۲-۳ مدل‌های تشخیص فاز کنتراست: داده‌ی آموزش/ارزیابی، مقادیر AUC، دقت و F1 (ارزیابی خارجی در صورت وجود)، و وضعیت کد. ۱۸

۲-۴ روش‌های منتخب ثبت تصویر: محک اندازه‌گیری، Dice و سایر معیارهای گزارش‌شده، و وضعیت کد. ۲۳

۲-۵ طبقه‌بندی ادبیات سنتز CE-به-NC بر اساس خانواده‌ی روش. ۲۹

۲-۶ مدل‌های سنتز CE-به-NC: سال انتشار، داده و تسک، مقادیر گزارش‌شده و وضعیت کد. ۳۰

فهرست تصاویر

فصل ۱

مقدمه

۱-۱ اهمیت مسئله

سی‌تی شکمی[۱] یکی از پرکاربردترین وجهیت‌های تصویربرداری در تشخیص، مرحله‌بندی و پیگیری بیماری‌های کبد، کلیه، پانکراس و سایر اندام‌های شکمی است. در عمل بالینی، این تصویربرداری معمولاً در چند فاز کنتراست[۲] انجام می‌شود: نخست یک اسکن بدون‌کنتراست[۳]، پیش از تزریق ماده‌ی حاجب[۴]، و سپس یک یا چند اسکن کنتراست‌دار[۵] در فازهای شریانی، وریدی یا تأخیری. تشخیص بسیاری از ضایعات کانونی کبد، به‌ویژه کارسینوم سلول کبدی[۶]، مستقیماً به الگوی افزایش کنتراست و شست‌وشوی[۷] آن میان فازهای مختلف وابسته است [۲، ۳]؛ الگویی که تنها با ترکیب دقیق اطلاعات چند فاز قابل‌مشاهده است.

با این حال، فاز بدون‌کنتراست هیچ‌گاه کاربردی صرفاً تکمیلی ندارد. در بسیاری از پروتکل‌های بالینی، از جمله تروما، غربالگری فرصت‌طلبانه[۸]، و بیمارانی که به دلیل نارسایی کلیوی یا سابقه‌ی حساسیت، امکان تزریق ماده‌ی حاجب را ندارند، فاز بدون‌کنتراست تنها تصویر در دسترس است. بخش‌بندی خودکار اندام‌های شکمی روی همین فاز، زیرساخت اندازه‌گیری حجمی، برنامه‌ریزی درمان و ردیابی روند بیماری در چنین بیمارانی است. اما همان‌طور که در فصل ۲ به‌تفصیل مرور می‌شود، دقت مدل‌های بخش‌بندی روی فاز بدون‌کنتراست، به دلیل کاهش نسبت کنتراست‌به‌نویز[۹] میان بافت‌های نرم مجاور، به‌طور نظام‌مند

[۱] Abdominal CT
[۲] Contrast phase
[۳] Non-contrast (NC) phase
[۴] Contrast media
[۵] Contrast-enhanced (CE) phase
[۶] Hepatocellular carcinoma, HCC
[۷] Washout
[۸] Opportunistic screening
[۹] Contrast-to-noise ratio, CNR

و وابسته به اندام، پایین‌تر از فاز کنتراست‌دار است [۴، ۵، ۶]. این افت، به‌جای آن‌که محدودیتی ذاتی و اجتناب‌ناپذیر تلقی شود، نقطه‌ی شروع این پایان‌نامه است.

۱-۲ تعریف مسئله

هدف کلی این پایان‌نامه، کاهش شکاف دقت بخش‌بندی چندعضوی میان فاز بدون‌کنتراست و فاز کنتراست‌دار در سی‌تی شکمی است، از طریق دو راهبرد مکمل: هم‌ترازسازی هندسی فازهای موجود از طریق ثبت تصویر، و بازسازی مستقیم اطلاعات فاز کنتراست‌دار از روی فاز بدون‌کنتراست از طریق سنتز. هر دو راهبرد بر زیرساختی مشترک تکیه دارند که پیش از ورود به آن‌ها باید مستحکم شود: شناخت دقیق محدودیت‌های مجموعه‌داده‌های موجود، و شناسایی صحیح فاز کنتراست هر بررسی. این پایان‌نامه چهار سهم مشخص را دنبال می‌کند که در فصل‌های بعدی به‌ترتیب ارائه می‌شوند.

مرور انتقادی مجموعه‌داده‌های سی‌تی شکمی

پیش از طراحی هر راه‌حل، این پروژه با یک مرور نظام‌مند بر 45 مجموعه‌داده‌ی عمومی سی‌تی شکمی آغاز شد که وضعیت اکوسیستم داده‌ی موجود را از منظر بازاستفاده، سوگیری جمعیت‌شناختی و جغرافیایی، و به‌طور مشخص کمیابی داده‌ی جفت‌شده[۱۰] میان فاز بدون‌کنتراست و کنتراست‌دار مستند می‌کند [۱]. یافته‌های این مرور در بخش ۲-۳ به‌تفصیل ارائه می‌شود و مستقیماً انگیزه‌ی دو سهم بعدی این پایان‌نامه را شکل می‌دهد: وقتی داده‌ی جفت‌شده‌ی طبیعی در دسترس نیست، یا باید فازهای موجود را پس‌پردازشی هم‌تراز کرد، یا فاز غایب را از روی فاز موجود بازسازی کرد.

تشخیص فاز کنتراست

بهره‌برداری از هر داده‌ی چندفازی، اعم از عمومی یا خام گردآوری‌شده در این پروژه، به شناسایی صحیح فاز هر سری تصویر وابسته است. از آن‌جا که برچسب‌های سرآیند DICOM در عمل ناقص یا ناسازگارند (بخش ۲-۴)، در این پروژه یک مدل تشخیص فاز کنتراست بر روی داده‌ی خام گردآوری‌شده توسعه و ارزیابی می‌شود. این مدل، که جزئیات آن در فصل ۳ و نتایج آن در فصل ۴ ارائه می‌شود، زیرساخت عملیاتی هر دو سهم بعدی است.

[۱۰] Paired

ثبت تصویر بین‌فازی

این پروژه یک پایپ‌لاین ثبت تصویر چندگذره[11] برای هم‌ترازسازی هندسی فاز بدون‌کنتراست با فاز کنتراست‌دار طراحی و ارزیابی می‌کند. برخلاف معیارهای کلاسیک اطلاعات متقابل که در سطح کل تصویر تعریف می‌شوند و در برابر تغییر ناهمگن کنتراست شکننده‌اند (بخش ۲-۵)، این پایپ‌لاین از مقداردهی اولیه‌ی صلب مبتنی‌بر نشانه‌های استخوانی، گذرهای ساختاری و اطلاعات متقابل محدودشده به نقاب اندام، و پالایش نهایی غیرصلب بهره می‌گیرد تا معیار تراز را به نواحی پایدار در برابر فاز کنتراست محدود کند. این پایپ‌لاین روی مجموعه‌داده‌ی عمومی VinDr-Multiphase [۷] ارزیابی شده است.

سنتز فاز کنتراست‌دار از فاز بدون‌کنتراست

جفت‌های هم‌ترازشده‌ی حاصل از این ثبت تصویر سپس برای آموزش و ارزیابی مدل‌های سنتز فاز کنتراست‌دار از روی فاز بدون‌کنتراست به کار می‌روند (بخش ۲-۶). در نهایت، در این پروژه بررسی می‌شود که آیا ترکیب هم‌ترازسازی و سنتز بهبودیافته، شکاف دقت بخش‌بندی چندعضوی میان دو فاز را که در فصل ۲ مستند می‌شود، کاهش می‌دهد.

۱-۳ چالش‌ها

پیگیری این چهار سهم در طول این پروژه با چند چالش فنی مشترک همراه بود. نخست، برچسب‌های فاز کنتراست در سرآیند DICOM داده‌ی خام این پروژه، مشابه بسیاری از مجموعه‌داده‌های عمومی، ناقص یا ناسازگارند و امکان تکیه‌ی مستقیم بر آن‌ها برای آموزش یا ارزیابی وجود ندارد. دوم، تزریق ماده‌ی حاجب رابطه‌ی آماری میان شدت روشنایی دو فاز را به‌شکل ناهمگن در فضا تغییر می‌دهد؛ همین ناهمگنی، فرض بنیادین معیارهای کلاسیک ثبت تصویر مبتنی‌بر اطلاعات متقابل را نقض می‌کند و طراحی معیار تراز مقاوم را ضروری می‌سازد. سوم، داده‌ی جفت‌شده‌ی طبیعی میان دو فاز برای یک بیمار در یک لحظه به‌ندرت در دسترس است، که هم ارزیابی دقیق ثبت تصویر و هم آموزش نظارت‌شده‌ی مدل‌های سنتز را دشوار می‌کند. چهارم، ادبیات پژوهشی مرتبط، به‌ویژه در حوزه‌ی سنتز CE-به-NC، از ناهمگنی معیار ارزیابی و مجموعه‌داده رنج می‌برد که مقایسه‌ی مستقیم نتایج را دشوار می‌کند (بخش ۲-۶).

[11] Multi-pass

۱-۴ اهداف پژوهش

با توجه به مسئله و چالش‌های فوق، این پایان‌نامه پنج هدف مشخص را دنبال می‌کند:

- مستندسازی نظام‌مند وضعیت سوگیری و کفایت مجموعه‌داده‌های عمومی سی‌تی شکمی، با تمرکز ویژه بر کمیابی داده‌ی جفت‌شده‌ی چندفازی.
- توسعه و ارزیابی مدلی برای تشخیص قابل‌اعتماد فاز کنتراست از روی محتوای خام تصویر، مستقل از برچسب‌های ناقص سرآیند DICOM.
- طراحی یک پایپ‌لاین ثبت تصویر چندگذره که معیار تراز را به نواحی پایدار در برابر تغییر فاز کنتراست محدود می‌کند، و ارزیابی مقایسه‌ای آن در برابر رویکردهای کلاسیک مبتنی‌بر اطلاعات متقابل.
- بهره‌گیری از جفت‌های هم‌ترازشده‌ی حاصل برای آموزش و ارزیابی مدل‌های سنتز فاز کنتراست‌دار از روی فاز بدون‌کنتراست.
- سنجش این‌که آیا ترکیب این مداخلات، شکاف دقت بخش‌بندی چندعضوی میان فاز بدون‌کنتراست و کنتراست‌دار را کاهش می‌دهد.

۱-۵ ساختار پایان‌نامه

باقی این پایان‌نامه به شرح زیر سازمان‌دهی شده است. فصل ۲ پیشینه‌ی پژوهشی پنج حوزه‌ی مرتبط، شامل بخش‌بندی چندعضوی و شکاف کیفیت فاز بدون‌کنتراست، وضعیت مجموعه‌داده‌های عمومی، تشخیص فاز کنتراست، ثبت تصویر بین‌فازی، و سنتز CE-به-NC را مرور می‌کند و با جمع‌بندی جای خالی مشترک میان آن‌ها به پایان می‌رسد. فصل ۳ روش پیشنهادی این پایان‌نامه، شامل جزئیات مدل تشخیص فاز، پایپ‌لاین ثبت تصویر چندگذره، و مدل‌های سنتز CE-به-NC را ارائه می‌دهد. فصل ۴ نتایج تجربی هر یک از این سه مؤلفه، و نیز ارزیابی نهایی اثر آن‌ها بر شکاف دقت بخش‌بندی چندعضوی را گزارش می‌کند. سرانجام، فصل ۵ یافته‌های پایان‌نامه را جمع‌بندی کرده و محدودیت‌ها و مسیرهای پژوهشی آتی را مطرح می‌کند.

۱-۶ جمع‌بندی

فاز بدون‌کنتراست سی‌تی شکمی، با وجود کاربرد بالینی گسترده، همچنان از افت نظام‌مند دقت بخش‌بندی چندعضوی رنج می‌برد؛ افتی که ریشه در کاهش کنتراست بافتی و کمیابی داده‌ی جفت‌شده‌ی چندفازی دارد. این پایان‌نامه با مرور انتقادی مجموعه‌داده‌های موجود آغاز می‌شود، زیرساخت تشخیص فاز کنتراست را فراهم می‌کند، و سپس از طریق دو راهبرد مکمل—ثبت تصویر چندگذره و سنتز تلاش—NC-به-CE می‌کند این شکاف را کاهش دهد. فصل بعدی، پیشینه‌ی پژوهشی این چهار حوزه را به‌تفصیل مرور می‌کند.

فصل ۲

کارهای پیشین

این فصل به مرور پیشینه‌ی پژوهشی پنج حوزه می‌پردازد: نخست، بخش‌بندی چندعضوی[۱] تصاویر سی‌تی شکمی و شکاف کیفیتی که در فاز بدون‌کنتراست[۲] این تصاویر مشاهده می‌شود؛ دوم، وضعیت مجموعه‌داده‌های عمومی سی‌تی شکمی از منظر کفایت و سوگیری[۳]؛ سوم، تشخیص فاز کنتراست از روی محتوای خام تصویر، به‌عنوان پیش‌نیاز عملیاتی بهره‌برداری از داده‌ی چندفازی؛ چهارم، ثبت تصویر[۴] میان فازهای مختلف تصویربرداری؛ و پنجم، سنتز فاز کنتراست‌دار[۵] از روی تصویر بدون‌کنتراست. هر بخش ابتدا مسئله‌ی موضوعی خود را تعریف می‌کند، سپس معیارهای ارزیابی مرتبط را به‌تفصیل شرح می‌دهد، آن‌گاه هر یک از کارهای پیشین مرتبط را در پاراگرافی جداگانه با نام مدل یا مرجع آغاز می‌کند و معماری آن را توضیح می‌دهد، و در پایان با جدولی خلاصه از نام مدل، سال انتشار، مقادیر گزارش‌شده و وضعیت انتشار کد جمع‌بندی می‌شود. فصل با جمع‌بندی جای خالی مشترک میان این پنج حوزه به پایان می‌رسد؛ روش‌های پیشنهادی این پایان‌نامه برای هر یک از این جاهای خالی، در فصل روش پیشنهادی (فصل بعد) ارائه می‌شوند.

---

۱ Multi-organ segmentation
۲ Non-contrast (NC) phase
۳ Bias
۴ Image registration
۵ Contrast-enhanced (CE) phase

۲-۱ پیش‌زمینه‌ی بالینی: سی‌تی چندفازی و فازهای کنتراست

سی‌تی شکمی چندفازی[۶] یک بررسی تصویربرداری است که در آن، به‌جای یک اسکن واحد، چند اسکن متوالی از یک ناحیه‌ی تشریحی، در بازه‌های زمانی مشخص نسبت به تزریق وریدی ماده‌ی حاجب یددار[۷]، گرفته می‌شود. اسکن نخست، پیش از هرگونه تزریق، فاز بدون‌کنتراست نامیده می‌شود و توزیع طبیعی تضعیف اشعه‌ی ایکس[۸] بافت‌ها، بدون اثر ماده‌ی حاجب، را ثبت می‌کند. پس از تزریق، ماده‌ی حاجب به‌ترتیب از قلب به آئورت، سپس به شریان‌های احشایی، و در نهایت از طریق مویرگ‌ها به وریدها و کبد می‌رسد؛ همین توالی زمانی، پایه‌ی نام‌گذاری فازهای کنتراست‌دار است.

فاز شریانی[۹]، معمولاً 25 تا 40 ثانیه پس از تزریق، زمانی ثبت می‌شود که ماده‌ی حاجب عمدتاً در شریان‌ها و بافت‌های پرخون[۱۰] متمرکز است؛ این فاز برای آشکارسازی ضایعاتی مانند کارسینوم سلول کبدی که خون‌رسانی شریانی غالب دارند، حیاتی است. **فاز وریدی باب**[۱۱]، حدود 60 تا 90 ثانیه پس از تزریق، زمانی است که ماده‌ی حاجب پارانشیم کبد را از طریق ورید باب پر کرده و بیشترین کنتراست میان بافت‌های نرم را فراهم می‌کند؛ این فاز معمول‌ترین فاز تشخیصی برای بخش‌بندی و ارزیابی عمومی اندام‌های شکمی است. **فاز تأخیری**[۱۲]، معمولاً 3 تا 5 دقیقه پس از تزریق، شست‌وشوی[۱۳] ماده‌ی حاجب از ضایعات پرخون را نشان می‌دهد؛ الگوی افزایش کنتراست در فاز شریانی و شست‌وشوی آن در فاز تأخیری یا وریدی، معیار تشخیصی اصلی کارسینوم سلول کبدی در دستورعمل‌های بالینی مانند EASL [۲] است.

هر یک از این فازها اطلاعات تشخیصی متفاوت و مکملی را در اختیار رادیولوژیست قرار می‌دهند؛ به همین دلیل، بسیاری از پروتکل‌های بالینی به‌طور هم‌زمان چند فاز را ثبت می‌کنند و تفسیر دقیق تنها با ترکیب اطلاعات چند فاز ممکن است. با این حال، همین چندفازی‌بودن، چالش‌های محاسباتی مضاعفی به همراه دارد که موضوع اصلی این فصل‌اند: تفاوت شدت روشنایی میان فازها می‌تواند دقت مدل‌های بخش‌بندی را کاهش دهد (بخش ۲-۲)، برچسب فاز هر بررسی همیشه به‌طور قابل‌اعتماد در سرآیند تصویر ثبت نمی‌شود (بخش ۲-۴)، و جابه‌جایی بیمار میان اسکن‌های متوالی، ثبت تصویر دقیق میان فازها را ضروری می‌سازد (بخش ۲-۵).

---

[۶] Multi-phase abdominal CT
[۷] Iodinated contrast medium
[۸] X-ray attenuation
[۹] Arterial phase
[۱۰] Hypervascular
[۱۱] Portal venous phase
[۱۲] Delayed phase
[۱۳] Washout

۲-۲ بخش‌بندی چندعضوی سی‌تی شکمی و شکاف کیفیت در فاز بدون‌کنتراست

تعریف مسئله

بخش‌بندی چندعضوی تصاویر سی‌تی شکمی، یعنی تعیین دقیق مرزهای تشریحی اندام‌هایی مانند کبد، کلیه، طحال و پانکراس در حجم‌های سه‌بعدی، زیرساخت بسیاری از کاربردهای بالینی مبتنی‌بر هوش مصنوعی از جمله برنامه‌ریزی درمان، اندازه‌گیری حجمی و ردیابی روند بیماری است. این مسئله معمولاً به‌صورت یک وظیفه‌ی طبقه‌بندی پیکسل‌به‌پیکسل (یا وُکسل‌به‌وُکسل) فرمول‌بندی می‌شود که در آن هر وُکسل حجم سی‌تی باید به یکی از برچسب‌های تشریحی از پیش‌تعریف‌شده نسبت داده شود. چالش مرکزی این پایان‌نامه آن است که دقت این بخش‌بندی لزوماً در طول فازهای مختلف تصویربرداری یکنواخت باقی نمی‌ماند: فاز بدون‌کنتراست، به دلیل کاهش نسبت کنتراست‌به‌نویز[۱۴] میان بافت‌های نرم مجاور، اغلب دقت پایین‌تری نسبت به فاز کنتراست‌دار نشان می‌دهد؛ بدون تزریق ماده‌ی حاجب، تفاوت میان بافت نرم اندام‌های مجاور مانند کبد و طحال، یا میان پارانشیم اندام و عروق داخل آن، به‌مراتب کمتر از فاز کنتراست‌دار است و مرزهای تشریحی‌ای که مدل‌های بخش‌بندی برای آن‌ها آموزش دیده‌اند، در تصاویر بدون‌کنتراست کم‌رنگ‌تر یا مبهم‌تر ظاهر می‌شوند.

معیار ارزیابی

ضریب هم‌پوشانی سورنسن–دایس[۱۵]، یا به‌اختصار Dice، معیار غالب در ادبیات بخش‌بندی تصویر پزشکی است. برای دو نقاب دودویی A (پیش‌بینی مدل) و B (برچسب مرجع)، این ضریب به‌صورت $\mathrm{Dice}(A,B) = ۲|A \cap B|/(|A| + |B|)$ تعریف می‌شود و مقداری میان صفر (بدون هم‌پوشانی) و یک (هم‌پوشانی کامل) می‌گیرد. مزیت اصلی Dice نسبت به دقت پیکسلی خام، مقاومت نسبی آن در برابر عدم‌توازن حجمی میان پیش‌زمینه (اندام هدف) و پس‌زمینه است، ویژگی‌ای که در بخش‌بندی اندام‌های کوچک مانند پانکراس یا غده‌ی فوق‌کلیوی اهمیت زیادی دارد.

صدک نودوپنجم فاصله‌ی هاسدورف[۱۶] معیاری مکمل است که به خطای موضعی مرزی، برخلاف Dice، حساس است. Dice تنها میزان هم‌پوشانی حجمی را می‌سنجد و ممکن است خطای برجسته‌ی مرزی در یک ناحیه‌ی کوچک را پنهان کند؛ HD95 این کاستی را جبران می‌کند: بزرگ‌ترین فاصله‌ی

[۱۴] Contrast-to-noise ratio, CNR
[۱۵] Sørensen–Dice coefficient
[۱۶] 95th percentile Hausdorff Distance, HD95

باقی‌مانده میان مرز دو نقاب را، پس از حذف 5% دورافتاده‌ترین نقاط (برای کاهش حساسیت به نویز برچسب‌گذاری)، اندازه می‌گیرد. در برخی مطالعات، از انحراف حجمی[۱۷] نسبت به یک اسکن مرجع نیز به‌عنوان معیار مکمل برای سنجش تکرارپذیری[۱۸] استفاده می‌شود.

کارهای پیشین

چارچوب **nnU-Net** [۸] یک شبکه‌ی رمزگذار—رمزگشای پیچشی بر پایه‌ی معماری U-Net است که با **خودپیکربندی**[۱۹] خودکار معماری، پیش‌پردازش و آموزش بر اساس ویژگی‌های هر مجموعه‌داده، نیاز به تنظیم دستی فراپارامترها را حذف می‌کند و به یکی از پرکاربردترین مبناهای این حوزه بدل شده است.

TotalSegmentator [۹] یک مدل nnU-Net سه‌بعدی است که بر پایه‌ی چارچوب فوق و با آموزش روی بیش از هزار بررسی سی‌تی بالینی متنوع ساخته شده و 104 ساختار تشریحی از جمله اندام‌ها، استخوان‌ها، عضلات و عروق را بخش‌بندی می‌کند؛ در عمل به ابزاری مرجع برای تولید نقاب[۲۰] اندام در پژوهش‌های بعدی تبدیل شده است.

در کنار این چارچوب‌های عمومی، محک‌های بزرگ‌مقیاس اختصاصی شکم مانند AbdomenCT-1K [۱۰]، FLARE [۱۱] و AbdomenAtlas [۱۲]، که هر یک با گردآوری و بازبرچسب‌گذاری چند مجموعه‌داده‌ی پایه شکل گرفته‌اند، و Medical Segmentation Decathlon [۱۳] به‌عنوان محکی چندوظیفه‌ای، مسیر پیشرفت این حوزه را در سال‌های اخیر ترسیم کرده‌اند. این محک‌ها عمدتاً بر پایه‌ی همان معماری nnU-Net یا مشتقات آن ارزیابی می‌شوند.

رویکردهای مبتنی‌بر یادگیری چندوظیفه‌ای و پرسش‌محور[۲۱] مانند مدل جهانی هدایت‌شده با CLIP [۱۴]، که یک رمزگذار متن از پیش‌آموزش‌دیده را برای تولید بردار پرسش هر اندام با یک شبکه‌ی بخش‌بندی سه‌بعدی ترکیب می‌کند، نشان داده‌اند یک شبکه‌ی واحد می‌تواند هم‌زمان بخش‌بندی اندام و تشخیص تومور را در طیف وسیعی از اندام‌ها انجام دهد.

یو و همکاران [۱۵] با یک شبکه‌ی بخش‌بندی سه‌بعدی، عملکرد را میان تصاویر بدون‌کنتراست[۲۲] و کنتراست‌دار[۲۳] مقایسه کردند و افت نسبتاً محدودی در دقت فاز نخست گزارش کردند.

---

[۱۷] Volumetric deviation
[۱۸] Reproducibility
[۱۹] Self-configuring
[۲۰] Mask
[۲۱] Prompt-driven
[۲۲] Non-contrast CT, NCCT
[۲۳] Contrast-enhanced CT, CECT

جئون و همکاران [۴] با استفاده از سی‌تی دوانرژی[۲۴] برای تولید جفت‌های هم‌ترازشده‌ی بدون‌کنتراست و پس‌ازکنتراست، ابتدا عملکرد پایین‌تر مدل‌های پیشین را روی فاز بدون‌کنتراست بازتاب دادند (میانگین ضریب Dice حدود 0.86 تا 0.95 برای کبد و 0.62 برای طحال)، اما با آموزش یک مدل nnU-Net سه‌بعدی اختصاصی روی داده‌ی خودشان، این شکاف را عملاً پوشاندند و به Dice بالای 0.94 برای کبد، طحال و کلیه‌ها در هر دو فاز رسیدند.

آبل و همکاران [۵] با ارزیابی تکرارپذیری[۲۵] درون‌فردی خروجی TotalSegmentator روی اسکن‌های تکراری، نشان دادند اکثریت قاطع ساختارها (29 از 34) درون بازه‌ی قابل‌قبول انحراف حجمی باقی می‌مانند و تنها اندام‌های معدودی مانند غده‌ی فوق‌کلیوی، کیسه‌ی صفرا، طحال و دئودنوم به **جابه‌جایی حوزه‌ای**[۲۶] وابسته به فاز و پروتکل حساس‌تر بودند.

ژو و همکاران [۶] چارچوب **CKAP-Net** را پیشنهاد دادند که یک ماژول تزریق دانش کنتراست و یک شاخه‌ی ادراک تشریحی چندمقیاسی را برای سنتز اطلاعات کنتراست از روی تصویر بدون‌کنتراست، پیش از بخش‌بندی، ترکیب می‌کند؛ این مدل به ضریب Dice حدود 81.21% در بخش‌بندی چندعضوی روی مجموعه‌داده‌های چندمرکزی رسید، رقمی که فاصله‌ی چندانی با دقت متداول بخش‌بندی روی فاز کنتراست‌دار ندارد.

مجموع این شواهد نشان می‌دهد شکاف بین‌فازی بیش از آن‌که یک افت یکنواخت و بزرگ در سراسر اندام‌ها باشد، پدیده‌ای موضعی و وابسته به اندام است که با فاین‌تیون مناسب یا کمک سنتز تصویر تا حد زیادی قابل جبران است؛ ادبیات پژوهشی دو راهبرد مکمل برای جبران این افت پیشنهاد داده است که در بخش‌های ۲–۵ و ۲–۶ همین فصل مرور می‌شوند: هم‌ترازسازی هندسی فاز بدون‌کنتراست با فاز کنتراست‌دار از طریق ثبت تصویر، و سنتز مستقیم اطلاعات کنتراست از روی تصویر بدون‌کنتراست.

---

[۲۴] Dual-energy CT
[۲۵] Reproducibility
[۲۶] Domain shift

جدول ۲-۱: مدل‌های بخش‌بندی و مطالعات شکاف بین‌فازی: سال انتشار، داده و تسک، مقادیر گزارش‌شده و وضعیت کد.

مرجع	سال	داده و تسک	مقادیر گزارش‌شده	کد باز؟
nnU-Net [۸]	2021	چند محک عمومی بخش‌بندی پزشکی	مبنای خودپیکربند؛ برنده‌ی چند محک	بله
TotalSegmentator [۲۳]	2023	بیش از هزار بررسی بالینی؛ 104 ساختار	Dice حدود 94%	بله
CLIP-driven) [۱۴]	2023	چند محک بخش‌بندی/تشخیص تومور	بخش‌بندی و تشخیص تومور هم‌زمان	بله
[۱۵]	2022	مقایسه‌ی CECT/NCCT	افت محدود دقت NCCT نسبت به CECT	گزارش‌نشده
[۴]	2024	سی‌تی دوانرژی، جفت‌های CE/NC هم‌تراز	Dice 0.86–0.95 (پایه)؛ 0.94< پس از آموزش اختصاصی	گزارش‌نشده
[۵]	2025	اسکن‌های تکراری؛ تکرارپذیری TotalSegmentator	34/29 ساختار درون بازه‌ی قابل‌قبول انحراف حجمی	گزارش‌نشده
CKAP-) [۶] (Net	2024	داده‌ی چندمرکزی؛ سنتز پیش از بخش‌بندی	Dice 81.21% در بخش‌بندی چندعضوی پایین‌دستی	گزارش‌نشده

۲-۳ مجموعه‌داده‌های سی‌تی شکمی: کاوش وضعیت موجود

در کنار محدودیت‌های مدل و روش مرورشده در بخش ۲-۲، کیفیت و نمایندگی[۲۷] مجموعه‌داده‌های آموزشی، سقف واقعی کارایی هر مدل بخش‌بندی یا سنتزی را تعیین می‌کند؛ با این حال، ارزیابی نظام‌مند همین کیفیت برای مجموعه‌داده‌های عمومی سی‌تی شکمی تاکنون کمتر مورد توجه بوده است. به‌عنوان بخشی از این پروژه، یک مرور نظام‌مند بر 45 مجموعه‌داده‌ی عمومی سی‌تی شکمی، شامل مجموعاً 47,049 بررسی، بر اساس شش محور ترکیب، بافت بالینی، خاستگاه داده، ویژگی‌های تصویربرداری، شیوه‌ی برچسب‌گذاری و ترکیب جمعیت‌شناختی انجام شد [۱][۲۸]؛ یافته‌های این مرور مبنای بخش حاضر است.

[۲۷] Representativeness

[۲۸] این مرور با عنوان «وضعیت مجموعه‌داده‌های سی‌تی شکمی: مروری انتقادی بر سوگیری، ارتباط بالینی و کاربردپذیری واقعی» در نشریه‌ی PLOS Digital Health پذیرفته شده است.

از آن‌جا که هیچ چک‌لیست پذیرفته‌شده‌ای برای ارزیابی مجموعه‌داده‌های تصویربرداری پزشکی به‌عنوان منبع آموزش هوش مصنوعی وجود ندارد، این مرور با تطبیق ابزار PROBAST+AI [۱۶]، معیارهای کیفیت پیشنهادی کوچاک و همکاران [۱۷] و راهنمای گزارش‌دهی TRIPOD+AI [۱۸]، یک چارچوب هفت‌مقوله‌ای برای ارزیابی ریسک سوگیری تدوین کرد. جدول ۲-۲ این هفت مقوله را به همراه تعریف عملیاتی هر یک خلاصه می‌کند. این ارزیابی تنها روی 22 مجموعه‌داده با بیش از صد نمونه‌ی عمومی انجام شد، زیرا مجموعه‌داده‌های کوچک‌تر به‌طور پیش‌فرض در اغلب مقوله‌ها ریسک بالا دریافت می‌کنند و این امر ارزش تمایزی طبقه‌بندی را کاهش می‌دهد.

جدول ۲-۲: هفت مقوله‌ی چارچوب ارزیابی ریسک سوگیری [۱].

مقوله	محور ارزیابی
سوگیری طیف[۲۹]	پوشش دامنه‌ی شدت و تنوع بالینی درون گروه مثبت
سوگیری انتخاب[۳۰]	پوشش تشخیص‌های افتراقی در گروه غیرمثبت
سوگیری نژادی[۳۱]	نمایندگی گروه‌های نژادی/قومی نسبت به جامعه‌ی هدف
سوگیری جمعیت‌شناختی[۳۲]	توازن جنسیت و توزیع سنی
سوگیری فنی[۳۳]	تنوع سخت‌افزار تصویربرداری، پروتکل و تزریق ماده‌ی حاجب
سوگیری برچسب‌گذاری[۳۴]	دقت و سازگاری فرایند حاشیه‌نویسی
سوگیری زمانی[۳۵]	بازه‌ی زمانی گردآوری داده

یافته‌های این مرور سه الگوی هم‌گرا را در سطح اکوسیستم داده آشکار کرد. نخست، از میان 47,049 بررسی فهرست‌شده، تنها 23,746 مورد اصیل بودند و باقی، معادل حدود 51%، از مجموعه‌داده‌های پیشین بازاستفاده شده بودند؛ این بازاستفاده حول شبکه‌ای از مجموعه‌داده‌های مادر مانند LiTS، KiTS، Pancreas-CT و BTCV شکل گرفته که نمونه‌های آن‌ها به مجموعه‌های ترکیبی متأخرتری مانند AbdomenCT-1K [۱۰]، FLARE [۱۱] و AbdomenAtlas [۱۲] راه یافته‌اند و خطر نشت داده[۳۶] میان مجموعه‌های آموزش و ارزیابی را در پژوهش‌های بعدی افزایش می‌دهد. دوم، حدود 75.3% از مجموعه‌داده‌ها از آمریکای شمالی و اروپا منشأ گرفته‌اند و مناطق وسیعی از جمله آفریقای زیرصحرا، جنوب آسیا و بخش عمده‌ی خاورمیانه، هیچ نمایندگی‌ای در چشم‌انداز داده‌ی عمومی موجود ندارند.

سوم، در میان 22 مجموعه‌داده‌ی ارزیابی‌شده، سوگیری نژادی در 17 مورد در سطح ریسک بالا قرار داشت و سوگیری انتخاب، یعنی ناتوانی در پوشش طیف تشخیص‌های افتراقی بالینی، در هیچ‌یک از 22 مجموعه‌داده به سطح ریسک پایین نرسید. بخشی از سوگیری فنی که در این چارچوب تعریف شده، به‌طور مستقیم به تنوع پروتکل‌های تزریق ماده‌ی حاجب و فاز کنتراست در مجموعه‌داده‌ها مربوط است. وضعیت

[۳۶] Data leakage

فاز کنتراست[۳۷] به‌عنوان یکی از محورهای استخراج‌شده در این مرور ثبت شده است. بر مبنای همین استخراج، از میان 45 مجموعه‌داده‌ی بررسی‌شده، تنها 11 مورد (حدود 24%) هم‌زمان فاز بدون‌کنتراست و دست‌کم یک فاز کنتراست‌دار را در ترکیب داده‌های خود گزارش کرده‌اند [۱]؛ رقمی که نشان می‌دهد مجموعه‌داده‌های دارای هر دو فاز، استثنا هستند و نه قاعده. این رقم صرفاً پوشش هم‌زمان دو نوع فاز را در سطح ترکیب مجموعه‌داده نشان می‌دهد و لزوماً به معنای وجود جفت هم‌بیمار در تمام این 11 مورد نیست؛ برای نمونه، در برخی از این مجموعه‌داده‌ها ممکن است زیرمجموعه‌ای از بیماران فقط فاز بدون‌کنتراست و زیرمجموعه‌ای دیگر فقط فاز کنتراست‌دار داشته باشند. همین کمیابی داده‌ی جفت‌شده[۳۸]، ادبیات پژوهشی ثبت تصویر و سنتز مرورشده در بخش‌های ۲-۵ و ۲-۶ را برانگیخته است: وقتی داده‌ی جفت‌شده‌ی طبیعی در دسترس نیست، یا باید فازهای موجود را به‌صورت پس‌پردازشی هم‌تراز کرد (ثبت تصویر) یا فاز غایب را از روی فاز موجود بازسازی کرد (سنتز).

این مرور، سوگیری مجموعه‌داده را نه نقصی موضعی در تک‌تک منابع، بلکه ویژگی ساختاری یک اکوسیستم می‌داند که در طول چرخه‌ی حیات داده انباشته می‌شود [۱۹]، همسو با یافته‌های پیشین درباره‌ی سوگیری نژادی [۲۰]، جنسیتی [۲۱] و جغرافیایی [۲۲] در الگوریتم‌های بالینی، و مستندسازی‌های مشابه در رادیوگرافی قفسه‌ی سینه [۲۳] و پوست‌شناسی [۲۴]. برای نمونه، در مورد کارسینوم سلول کبدی[۳۹] [۲۵]، که تشخیص آن به‌شدت به الگوی افزایش کنتراست در فاز شریانی و شست‌وشوی[۴۰] آن در فاز وریدی وابسته است، موارد مستندشده در مجموعه‌داده‌های موجود عمدتاً از جمعیت‌های غربی می‌آیند، حال آن‌که در آفریقای زیرصحرا این بیماری اغلب در کبد غیرسیروتیک و در سنین پایین‌تر با الگوی تصویری متفاوتی بروز می‌کند [۲۶]. این نوع عدم‌تطابق را تمرکز صرف بر مجموعه‌داده‌های پرکاربرد و پرارجاع، که خود بازتاب پدیده‌ی بازاستفاده و تمرکز محک[۴۱] در یادگیری ماشین است [۲۷، ۲۸]، تشدید می‌کند. راهکارهایی مانند یادگیری فدرال[۴۲] [۲۹] و تسهیم گسترده‌تر داده در سطح جهانی [۳۰] در ادبیات به‌عنوان مسیرهای رفع این تمرکز مطرح شده‌اند، هرچند رفع کامل آن‌ها از حوزه‌ی این پایان‌نامه خارج است.

[۳۷] Contrast enhancement status
[۳۸] Paired
[۳۹] Hepatocellular carcinoma, HCC
[۴۰] Washout
[۴۱] Benchmark concentration
[۴۲] Federated learning

۲-۴ تشخیص فاز کنتراست در تصاویر سی‌تی خام

تعریف مسئله

همان مرور مجموعه‌داده‌ای بخش پیشین، وضعیت فاز کنتراست را یکی از محورهای استخراج‌شده و در عین حال یکی از ناهمگن‌ترین ویژگی‌های ثبت‌شده در سرآیندهای عمومی معرفی کرد. پیش از امکان بهره‌برداری از داده‌ی چندفازی، شناسایی صحیح فاز کنتراست هر سری تصویر، گامی پیش‌نیاز است: برچسب‌های موجود در سرآیند DICOM (مانند SeriesDescription) اغلب ناقص، ناسازگار میان مراکز، یا کاملاً غایب‌اند [۳۱]، که استخراج خودکار و قابل‌اعتماد فاز را از روی محتوای تصویر ضروری می‌سازد. ادبیات این حوزه را می‌توان در دو رویکرد اصلی دسته‌بندی کرد: استخراج ویژگی از نواحی آناتومیک و طبقه‌بندی با یادگیری ماشین کلاسیک، و طبقه‌بندی مستقیم تصویر با شبکه‌های پیچشی.

معیار ارزیابی

دقت[۴۳] ساده‌ترین و پرکاربردترین معیار در ادبیات تشخیص فاز کنتراست است: نسبت پیش‌بینی‌های درست به کل نمونه‌ها. این معیار زمانی گویاست که کلاس‌های فاز (بدون‌کنتراست، شریانی، وریدی، تأخیری) تقریباً متوازن باشند؛ در غیر این صورت، یک طبقه‌بند ساده که همیشه پرتکرارترین کلاس را پیش‌بینی می‌کند نیز می‌تواند دقت ظاهراً بالایی کسب کند.

F1 میانگین هارمونیک دقت‌مثبت[۴۴] و بازخوانی[۴۵] است و تصویر متعادل‌تری از عملکرد طبقه‌بند در هر کلاس، به‌ویژه در حضور عدم‌توازن کلاسی، ارائه می‌دهد؛ به همین دلیل، در بیشتر مطالعات این حوزه به‌جای دقت خام، F1 به‌ازای هر کلاس فاز گزارش می‌شود.

AUC (مساحت زیر منحنی مشخصه‌ی عملکرد سیستم[۴۶]) حساسیت طبقه‌بند را در تمام آستانه‌های ممکن تصمیم‌گیری خلاصه می‌کند و بنابراین، برخلاف دقت و F1، مستقل از انتخاب یک آستانه‌ی خاص است؛ این معیار به‌ویژه برای مقایسه‌ی طبقه‌بندهایی که آستانه‌ی تصمیم متفاوتی دارند، یا در ارزیابی‌های چندکلاسه به‌صورت یک‌درمقابل‌بقیه[۴۷]، پرکاربرد است.

---

[۴۳] Accuracy
[۴۴] Precision
[۴۵] Recall
[۴۶] Receiver Operating Characteristic curve, ROC
[۴۷] One-vs-rest

کارهای پیشین

هو و همکاران [۳۲]، در چارچوبی موسوم به **Segment-and-Classify**، ابتدا اندام‌های مرتبط با کنتراست (آئورت، ورید باب، ورید اجوف تحتانی، کلیه‌ها و غیره؛ در مجموع شانزده ساختار) را با TotalSegmentator [۹] مشخص کردند، سپس میانگین HU هر اندام را به‌عنوان بردار ویژگی به یک طبقه‌بند **XGBoost** (جنگل درختان تقویت‌شده‌ی گرادیانی[۴۸]) دادند؛ این طبقه‌بند به‌طور ذاتی می‌تواند اندام‌های غایب (مثلاً خارج از میدان دید) را از طریق مکانیزم بومی XGBoost برای داده‌ی گمشده مدیریت کند. مدل روی WAW-TACE (سه مجموعه‌داده‌ی عمومی از سه سازمان مجزا؛ آموزش روی WAW-TACE) آموزش داده و روی VinDr-Multiphase و C4KC-KiTS ارزیابی شد؛ برای مقایسه، سه شبکه‌ی پیچشی سه‌بعدی (ResNet3D-18، MC3-18، R(2+1)D-18) نیز روی همین وظیفه آموزش داده شدند و XGBoost در عین دقت بالا، به‌مراتب کاراتر از این شبکه‌های سه‌بعدی بود.

ریس و همکاران [۳۳] رویکرد مشابهی، اما با تأکید بر تفسیرپذیری، ارائه کردند: پس از بخش‌بندی با TotalSegmentator، 48 ویژگی رادیومیک (آمار شدت روشنایی) از پنج ساختار تشریحی استخراج و به یک طبقه‌بند **XGBoost** داده شد که تفاوت‌های الگوی افزایش کنتراست کلیوی و عروقی را به‌طور مستقیم قابل‌تفسیر می‌کند. مدل روی 739 بررسی چندفازی شکمی از 200 بیمار (استنفورد، 2016—2021) آموزش دید و روی داده‌ی خارجی VinDr-Multiphase با دقت 90.1% ارزیابی شد.

بالدینی و همکاران [۳۴] این رویکرد مبتنی‌بر ویژگی ناحیه‌ای و طبقه‌بند درختی را به پنج فاز (شامل فاز شریان ریوی و فاز اورگرافیک) گسترش دادند و با افزودن تشخیص ماده‌ی حاجب خوراکی در دستگاه گوارش، میانگین AUC درون‌سازمانی 99.1 تا 99.8% و برونی 97.3% را روی داده‌ی خارجی TCIA گزارش کردند.

یی و همکاران [۳۵] فاز را مستقیماً و بدون میانجی بخش‌بندی آناتومیک، با طبقه‌بندی برش‌های محوری دوبعدی و تجمیع پیش‌بینی‌ها به سطح کل بررسی، تشخیص دادند. از میان پنج معماری پیچشی آزموده‌شده (از جمله InceptionV3 و ResNet101-v2)، بهترین عملکرد از آن **EfficientNet-B4** (شبکه‌ی پیچشی با مقیاس‌پذیری ترکیبی عمق/عرض/تفکیک‌پذیری[۴۹]) بود که روی 1,979 بررسی سی‌تی سر و گردن (133,480 برش محوری) بیماران سرطانی آموزش داده شد. این مدل AUC برابر 0.996 (درون‌سازمانی) و 1.00 (خارجی، n=595) به دست آورد؛ پس از تنظیم‌دقیق روی مجموعه‌ای کوچک‌تر از سی‌تی قفسه‌سینه، به AUC 1.00 (درون‌سازمانی) و 0.980 (خارجی، n=402) رسید.

دائو و همکاران [۳۶] با یک **شبکه‌ی پیچشی برش‌محور** و نمونه‌برداری تصادفی از 20 تا 30% برش‌های

[۴۸] Gradient-boosted decision trees
[۴۹] Compound scaling

هر اسکن به همراه رأی‌گیری اکثریت میان آن‌ها، هزینه‌ی محاسباتی استنتاج را کاهش دادند. مدل روی 830 بررسی چندفازی شکمی (271,426 برش) آموزش و روی 358 بررسی داخلی ارزیابی شد و F1 برابر 92.1% به دست آورد؛ در ارزیابی برونی روی CPTAC-CCRCC (242 بررسی عمومی سرطان کلیه) و LiTS (131 بررسی تومور کبدی) این رقم به ترتیب به 76.8% و 86.9% کاهش یافت، هرچند همچنان از یک مبنای ResNet18 سه‌بعدی هم در سرعت و هم در دقت پیشی گرفت.

روچا و همکاران [۳۷] با یک شبکه‌ی پیچشی سفارشی، پیش‌بینی سطح برش را به سطح حجم و سپس سطح کل بررسی تجمیع کردند و به دقت 94.6% (برش)، 98% (حجم) و 100% (کل بررسی) دست یافتند.

محمدرحیموف و همکاران [۳۱] مسئله را به‌جای طبقه‌بندی مستقیم، به‌صورت رگرسیون زمان پس از تزریق فرمول‌بندی کردند که امکان تفکیک فازهای شریانی زودرس و دیررس، و شناسایی یک فاز میانی بین وریدی و تأخیری را فراهم می‌کند؛ دقت 93.3% روی سی‌تی شکمی و پس از انتقال یادگیری با تنها 100 نمونه‌ی برچسب‌خورده، AUC روی سی‌تی قفسه‌سینه از 0.776 به 0.999 رسید.

لیو و همکاران [۳۸] یک استراتژی **دومرحله‌ای** با ستون فقرات **ResNet-18** اشتراکی[۵۰] پیشنهاد دادند: تصاویر سه فاز یک بیمار به‌طور موازی به جریان‌های ResNet با پارامتر مشترک داده می‌شوند و یک ماژول توجه بین‌فازی[۵۱] میان آن‌ها تبادل ویژگی برقرار می‌کند. راهبرد نخست، طبقه‌بندی تک‌مرحله‌ای چهارکلاسه (شریانی زودرس/دیررس، وریدی باب، تأخیری) بود؛ راهبرد دوم، طبقه‌بندی را به دو مرحله شکست: ابتدا شریانی در برابر وریدی در برابر تأخیری، سپس در صورت شریانی‌بودن، یک زیرشبکه فاز را به زودرس یا دیررس تفکیک می‌کرد. مدل با زیان کانونی[۵۲] برای مقابله با عدم‌توازن کلاسی، روی 1,175 بررسی کنتراست‌دار شکمی (یک بیمارستان) آموزش و روی 215 بررسی خارجی از پنج بیمارستان دیگر ارزیابی شد؛ داده فاقد فاز بدون‌کنتراست بود. دقت درون‌سازمانی با مدل دومرحله‌ای به 98.3% رسید (در برابر 91.7% برای مدل تک‌مرحله‌ای چهارکلاسه)؛ دقت خارجی 95.1% تا 99.5% برای فازهای مختلف بود.

آناند و همکاران [۳۹] برچسب‌های ضعیف[۵۳] را مستقیماً از سرآیند DICOM و نام فایل استخراج کردند تا نیاز به حاشیه‌نویسی دستی را دور بزنند، هرچند این روش برچسب‌هایی نویزی و گاه نادرست تولید می‌کند. با انتخاب هر برش دهم (به دلیل افزونگی اطلاعات میان برش‌های مجاور)، 395 بررسی برای توازن پنج فاز انتخاب و 689/2,719 برش برای آموزش/اعتبارسنجی به دست آمد؛ آموزش نهایی روی

[۵۰] Shared-weight
[۵۱] Inter-phase attention
[۵۲] Focal loss
[۵۳] Weak labels

زیرمجموعه‌ای کوچک از 316 بررسی با برچسب ضعیف انجام شد. سه معماری **ResNet34**، VGG19 و DenseNet121 مقایسه شدند و شبکه‌ی باقیمانده (ResNet34) با دقت 99% روی همین مجموعه‌داده‌ی کوچک و ضعیف‌برچسب، بهترین عملکرد را نشان داد.

نقطه‌ی مشترک روش‌های رویکرد نخست ([۳۲، ۳۳، ۳۴])، وابستگی به بخش‌بندی اندام از پیش‌آموزش‌دیده (معمولاً TotalSegmentator) است. از میان تمام نه مطالعه‌ی این پیمایش، تنها چهار مورد کد منبع خود را منتشر کرده‌اند (جدول ۲–۳)؛ دو مورد از این چهار ([۳۲، ۳۳]) به رویکرد نخست و دو مورد دیگر ([۳۵، ۳۶]) به رویکرد دوم (طبقه‌بندی مستقیم تصویر، بدون وابستگی به بخش‌بندی) تعلق دارند. سه مجموعه‌داده در این پیمایش پرکاربردترین‌اند: WAW-TACE [۴۰] (233 بیمار، 854 بررسی چندفازی کبدی)، VinDr-Multiphase [۷] (265 بیمار، 1,188 بررسی)، و C4KC-KiTS [۴۱] (210 بیمار، 408 بررسی، بدون فاز وریدی). این سه مجموعه در پوشش تشریحی (شکم، شکم‌ـ‌لگن، قفسه‌سینه‌ـ‌شکم‌ـ‌لگن) و در نام‌گذاری فاز تأخیری (که در VinDr-Multiphase با برچسب "Other" و در C4KC-KiTS با برچسب "Late" ثبت شده) ناهمگن‌اند؛ ناهمگنی‌ای که ارزیابی جامعیت مدل‌های تشخیص فاز را ضروری می‌سازد.

جدول ۲–۳ برای هر مطالعه، مجموعه‌داده‌ی آموزش و ارزیابی (با نام صریح در صورت عمومی‌بودن، یا برچسب «دیتای شخصی» در صورت خصوصی‌بودن)، و مقادیر AUC، دقت و F1 را در سه ستون جداگانه فهرست می‌کند. برای مطالعاتی که هم روی داده‌ی درون‌سازمانی و هم روی داده‌ی خارجی ارزیابی شده‌اند، تنها مقدار ارزیابی **خارجی** (برون‌سازمانی)، به‌عنوان سنجه‌ی تعمیم‌پذیری، گزارش شده است.

جدول ۲-۳: مدل‌های تشخیص فاز کنتراست: داده‌ی آموزش/ارزیابی، مقادیر AUC، دقت و F1 (ارزیابی خارجی در صورت وجود)، و وضعیت کد.

مرجع	سال	داده‌ی آموزش/ارزیابی	AUC	دقت	F1	کد باز؟
Segment-and-Classify [۳۲]	2025	آموزش: WAW-TACE؛ ارزیابی: VinDr، C4KC-KiTS	>0.937	—	0.994/0.937/0.718	بله
Interpretable XGBoost [۳۳]	2024	آموزش: شخصی (استنفورد)؛ ارزیابی: VinDr	—	90.1%	82.6%	بله
5-Phase Tree Classifier [۳۴]	2024	آموزش: شخصی (Essen)؛ ارزیابی: TCIA	97.3%	—	—	گزارش‌نشده
EfficientNet-B4 [۳۵]	2022	آموزش/ارزیابی: شخصی (سر/گردن، قفسه‌سینه)	1.00؛ 0.980	—	—	بله
Random-Sampling CNN [۳۶]	2022	آموزش: شخصی؛ ارزیابی: CPTAC-CCRCC، LiTS	—	—	76.8%؛ 86.9%	بله
Hierarchical CNN [۳۷]	2022	شخصی (HCFMUSP)	—	100%	—	گزارش‌نشده
Injection-Time Regression [۳۱]	2022	شخصی (17 مرکز)	0.999	93.3%	—	گزارش‌نشده
Two-Step ResNet [۳۸]	2025	آموزش: شخصی (1 بیمارستان)؛ ارزیابی: شخصی (5 بیمارستان)	—	95.1– 99.5%	—	خیر
Weak-Label ResNet [۳۹]	2023	شخصی، برچسب ضعیف DICOM (395 بررسی)	—	99%	—	خیر

۲-۵ ثبت تصویر بین‌فازی سی‌تی

تعریف مسئله

تراز فضایی میان فازهای مختلف یک بررسی سی‌تی چندفازی[۵۴]، پیش‌نیاز بسیاری از کاربردهای بالینی است. در تشخیص و مرحله‌بندی کارسینوم سلول کبدی، دستورعمل‌های بالینی مانند EASL [۲] و مرورهای جامع این بیماری [۳] صراحتاً بر ترکیب اطلاعات فاز شریانی و وریدی برای تشخیص افزایش کنتراست و شست‌وشوی ضایعه تکیه می‌کنند؛ این ترکیب تنها زمانی معتبر است که دو فاز به‌طور دقیق بر هم منطبق باشند. هر جابه‌جایی باقی‌مانده، ناشی از تنفس، حرکت روده یا تغییر وضعیت بیمار میان دو اسکن، می‌تواند یک ضایعه را در یک فاز از دید مدل یا رادیولوژیست پنهان کند. ثبت تصویر[۵۵] به‌طور صوری،

[۵۴] Multi-phase CT
[۵۵] Image registration

مسئله‌ی یافتن یک تبدیل هندسی T است که یک تصویر متحرک[۵۶] را به بهترین شکل بر یک تصویر ثابت[۵۷] منطبق کند؛ چالش مضاعف در ثبت بین‌فازی سی‌تی شکمی آن است که تزریق ماده‌ی حاجب، رابطه‌ی آماری میان شدت روشنایی دو تصویر را به‌شکل ناهمگن در فضا تغییر می‌دهد: عروق و پارانشیم پرخون[۵۸] کبد در فاز شریانی روشن‌تر می‌شوند، در حالی که استخوان، چربی و بسیاری از بافت‌های نرم دیگر تقریباً بدون تغییر باقی می‌مانند.

معیارهای ارزیابی

اطلاعات متقابل[۵۹] و نسخه‌ی بهنجارشده‌ی آن[۶۰] معیارهای آماری‌اند که وابستگی مشترک توزیع شدت روشنایی دو تصویر را می‌سنجند، بدون فرض رابطه‌ی خطی میان آن‌ها. این معیارها هم به‌عنوان تابع هزینه‌ی بهینه‌سازی در حین ثبت و هم به‌عنوان شاخص کیفیت پس از ثبت به کار می‌روند، و پایه‌ی معیار تراز در بسیاری از روش‌های کلاسیک ([۴۲، ۴۳، ۴۴]) و ابزارهایی مانند elastix و SimpleITKاند.

همبستگی متقابل نرمال‌شده[۶۱] شباهت خطی شدت روشنایی یا گرادیان دو تصویر را می‌سنجد. این معیار پایه‌ی SyN [۴۵] و توصیف‌گرهای ساختاری مانند MIND [۴۶] و DEEDS [۴۷] است.

خطای ثبت هدف[۶۲] میانگین فاصله‌ی باقی‌مانده میان نشانه‌های آناتومیک متناظر[۶۳] پس از ثبت را اندازه می‌گیرد؛ این معیار مستقیم‌ترین سنجه‌ی دقت هندسی است و در محک‌هایی مانند Learn2Reg [۴۸] برای گزارش دقت روش‌هایی مانند DEEDS و TransMorph به کار می‌رود.

با این حال، هر دو خانواده‌ی معیار محدودیت مهمی دارند. برچسب‌گذاری دستی نشانه‌های آناتومیک برای محاسبه‌ی TRE پرهزینه و زمان‌بر است و تنها برای زیرمجموعه‌ی کوچکی از داده‌ها (عمدتاً محک‌های عمومی مغزی یا ریوی) در دسترس است؛ به همین دلیل، بسیاری از مطالعات ثبت تصویر، از جمله VoxelMorph [۴۹]، TransMorph [۵۰] و DEEDS [۴۷]، به‌جای TRE، از هم‌پوشانی ضریب Dice (تعریف‌شده در بخش ۲-۲) میان نقاب‌های تشریحی پس از ثبت، به‌عنوان معیاری جایگزین و در دسترس‌تر استفاده می‌کنند. این جایگزینی خود دو محدودیت دارد: Dice صرفاً هم‌پوشانی ناحیه‌ای را می‌سنجد، نه تناظر نقطه‌به‌نقطه‌ی واقعی، و بنابراین می‌تواند حتی در غیاب تراز دقیق هندسی مقدار نسبتاً بالایی نشان دهد؛ و کیفیت آن کاملاً به دقت نقاب‌های ورودی (معمولاً حاصل یک مدل بخش‌بندی خودکار) وابسته

[۵۶] Moving image
[۵۷] Fixed image
[۵۸] Hypervascular
[۵۹] Mutual Information, MI
[۶۰] Normalised Mutual Information, NMI
[۶۱] Normalised Cross-Correlation, NCC
[۶۲] Target Registration Error, TRE
[۶۳] Anatomical landmarks

است.

معیارهای شباهت تصویر (MI، NCC) نیز محدودیت مشابهی دارند: از آن‌جا که تنها یک پروکسی غیرمستقیم برای تراز هندسی‌اند، ممکن است در نواحی با تغییر ناهمگن کنتراست (موضوع اصلی این بخش) مقدار گمراه‌کننده‌ای گزارش کنند، حتی وقتی تراز واقعی برقرار نشده باشد.

کارهای پیشین

ولز و همکاران [۴۲] نخستین‌بار از بیشینه‌سازی اطلاعات متقابل برای ثبت تصویر صلب[۶۴] چندوجهی استفاده کردند، بدون نیاز به مدل از پیش تعریف‌شده برای رابطه‌ی شدت روشنایی میان دو تصویر.

استادهولم و همکاران [۴۳] با معرفی اطلاعات متقابل بهنجارشده، وابستگی این معیار به اندازه‌ی ناحیه‌ی هم‌پوشانی را کاهش دادند.

مَتیس و همکاران [۴۴] با برآورد اطلاعات متقابل از طریق هیستوگرام مبتنی‌بر پنجره‌ی پارزن[۶۵]، صورتی مشتق‌پذیر و کارا از این معیار ارائه کردند که هنوز پایه‌ی بسیاری از پیاده‌سازی‌های امروزی از جمله elastix [۵۱] و SimpleITK [۵۲] است.

رواکرت و همکاران [۵۳] چارچوب **تغییر شکل آزاد**[۶۶] مبتنی‌بر بی‌اسپلاین[۶۷] را به‌عنوان یکی از نخستین روش‌های عملی ثبت غیرصلب معرفی کردند، که در آن میدان جابه‌جایی با شبکه‌ای تُنُک از نقاط کنترل پارامتری می‌شود.

تیریون [۵۴] الگوریتم **دیمانز**[۶۸] را بر پایه‌ی قیاس با نفوذ حرارتی پیشنهاد داد، رویکردی تکراری که میدان جابه‌جایی را از طریق «نیروهای» مبتنی‌بر گرادیان شدت روشنایی به‌روزرسانی می‌کند.

اوانتز و همکاران [۴۵] با **SyN**[۶۹]، ثبت دیفئومورفیک متقارن مبتنی‌بر همبستگی متقابل را ارائه کردند که هنوز به‌عنوان مبنای عملکردی قوی در بسیاری از مقایسه‌ها به کار می‌رود؛ این روش هسته‌ی جعبه‌ابزار ANTs است.

پلوییم و همکاران [۵۵] در مروری جامع، شرایط اعتبار اطلاعات متقابل را مستند کردند، و متز و همکاران [۵۶] این خانواده از معیارها را برای ثبت گروهی[۷۰] دنباله‌های پویا از جمله سی‌تی شکمی پویا

[۶۴] Rigid
[۶۵] Parzen window
[۶۶] Free-Form Deformation, FFD
[۶۷] B-spline
[۶۸] Demons
[۶۹] Symmetric Normalisation
[۷۰] Groupwise

تعمیم دادند. مورفی و همکاران [۴۸] نیز چارچوبی نیمه‌خودکار برای ساخت استاندارد مرجع مبتنی‌بر نشانه‌های آناتومیک پیشنهاد کردند که ارزیابی دقیق روش‌های ثبت تصویر را ممکن می‌سازد.

مشکل بنیادین خانواده‌ی اطلاعات متقابل هنگام اعمال میان فازهای متضاد سی‌تی شکمی آشکار می‌شود: این معیارها فرض می‌کنند رابطه‌ی آماری میان شدت روشنایی دو تصویر در سراسر میدان دید پایدار است، در حالی که تزریق ماده‌ی حاجب دقیقاً همین رابطه را به‌شکل ناهمگن در فضا تغییر می‌دهد. نتیجه، معیار تراز کلی‌نگری است که بخش زیادی از واریانس آن ناشی از تغییر کنتراست است، نه جابه‌جایی هندسی واقعی.

چند خط پژوهشی تلاش کرده‌اند با محدودکردن یا وزن‌دهی معیار تراز بر اساس آناتومی، به این مسئله نزدیک شوند. پاپیه‌ژ و همکاران [۵۷] با یک منظم‌ساز[۷۱] دوسویه‌ی آگاه از آناتومی، امکان حرکت لغزشی[۷۲] در مرز اندام‌هایی مانند ریه و کبد را فراهم کردند، هرچند معیار تراز همچنان در سطح کل تصویر باقی می‌ماند.

دِفوس و همکاران [۵۸] وزن‌دهی آگاه از آناتومی را مستقیماً وارد تابع هزینه‌ی یک شبکه‌ی پیچشی سرتاسر کردند.

هو و همکاران [۵۹] با نظارت ضعیف[۷۳] مبتنی‌بر هم‌پوشانی برچسب[۷۴] به‌جای اطلاعات شدت روشنایی، مسئله‌ی ناهمگنی شدت را به‌کلی دور زدند، هرچند به قیمت وابستگی کامل کیفیت ثبت به کیفیت بخش‌بندی ورودی.

اوکتای و همکاران [۶۰] پیشین‌های شکل تشریحی[۷۵] را به‌عنوان قید در آموزش شبکه گنجاندند. نقطه‌ی مشترک این خط پژوهشی آن است که از آناتومی برای *تطبیق* یا *قید کردن* معیار تراز استفاده می‌کند، نه برای *محدودکردن دامنه‌ی محاسبه‌ی* خود معیار.

موازی با این خط، روش‌های یادگیری‌محور ثبت تصویر با سرعت محاسباتی به‌مراتب بالاتر از روش‌های تکراری[۷۶] کلاسیک توسعه یافته‌اند. **VoxelMorph** [۴۹] با یک رمزگذار–رمزگشای پیچشی و یک لایه‌ی تبدیل‌گر فضایی[۷۷]، میدان جابه‌جایی را به‌صورت بدون‌نظارت یا نیمه‌نظارت‌شده برآورد می‌کند و در سرعت، عملکردی قابل‌مقایسه با ANTs ارائه می‌دهد.

TransMorph [۵۰] با ترکیب یک رمزگذار Swin Transformer و رمزگشای پیچشی، میدان

[۷۱] Regulariser
[۷۲] Sliding motion
[۷۳] Weak supervision
[۷۴] Label overlap, Dice
[۷۵] Anatomical shape priors
[۷۶] Iterative
[۷۷] Spatial transformer

دریافت بزرگ‌تری برای یافتن تناظر دوربرد فراهم می‌کند.

LapIRN [۶۱] با هرم لاپلاسی چندمقیاسی، تغییر شکل‌های بزرگ را به‌صورت خشن‌به‌ریز[۷۸] برآورد می‌کند.

HyperMorph [۶۲] یادگیری فراپارامتر منظم‌سازی را به شبکه می‌افزاید تا از تنظیم دستی ضریب موازنه‌ی هزینه بی‌نیاز شود.

شبکه‌های آبشاری بازگشتی[۷۹] [۶۳] با پالایش تدریجی میدان جابه‌جایی در چند مرحله، تغییر شکل‌های بزرگ را بهتر مدیریت می‌کنند.

DeepAtlas [۶۴] ثبت تصویر و بخش‌بندی را در یک شبکه‌ی دوشاخه به‌صورت مشترک می‌آموزد، به‌طوری‌که هر وظیفه از سیگنال آموزشی دیگری بهره می‌برد.

UniGradICON [۶۵]، به‌عنوان یک مدل بنیادین[۸۰] اخیر مبتنی‌بر چارچوب GradICON با ستون فقرات پیش‌بین جابه‌جایی چندمرحله‌ای و آموزش مبتنی‌بر پایداری معکوس گرادیان[۸۱]، تعمیم‌پذیری صفر/چندنمونه[۸۲] در طیف وسیعی از آناتومی و وجهیت را نشان داده، اما رفتار آن در برابر جابه‌جایی حوزه‌ای ناشی از فاز کنتراست هنوز مشخصه‌یابی نشده است.

در کنار خانواده‌ی مبتنی‌بر اطلاعات متقابل، توصیف‌گرهای ساختاری مستقل از وجهیت[۸۳] مسیر دیگری برای دور زدن مسئله‌ی ناپایداری شدت روشنایی ارائه می‌دهند. **MIND** (توصیف‌گر همسایگی مستقل از وجهیت[۸۴]) [۴۶] با کدگذاری الگوی خودشباهت[۸۵] محلی، شباهتی مستقل از تبدیل خطی شدت روشنایی فراهم می‌کند.

بر همین پایه، **DEEDS** [۴۷] با بهینه‌سازی گسسته‌ی میدان تصادفی مارکوف[۸۶] بر پایه‌ی MIND، به یکی از دقیق‌ترین روش‌های ثبت تصویر شکمی و چندوجهی در محک Learn2Reg بدل شده است. این توصیف‌گرها نشان می‌دهند گرادیان‌های ساختاری در مرز اندام‌ها، برخلاف مقدار خام شدت روشنایی، نسبتاً پایدارتر در برابر تغییر فاز کنتراست باقی می‌مانند.

از نظر زیرساخت نرم‌افزاری، SimpleITK [۵۲] و elastix [۵۱]، با معماری پیمانه‌ای[۸۷] خود در

[۷۸] Coarse-to-fine
[۷۹] Recursive Cascaded Networks
[۸۰] Foundation model
[۸۱] Gradient inverse consistency
[۸۲] Zero/few-shot
[۸۳] Modality-independent
[۸۴] Modality Independent Neighbourhood Descriptor, MIND
[۸۵] Self-similarity
[۸۶] Markov Random Field, MRF
[۸۷] Modular

تعریف تبدیل، معیار و بهینه‌ساز، و پشتیبانی از نقاب تصویر ثابت[۸۸] در تعریف معیار، از پرکاربردترین زیرساخت‌های نرم‌افزاری منبع‌باز این حوزه‌اند.

جمع‌بندی این پیشینه، دو محدودیت مکمل را آشکار می‌کند: معیارهای کلاسیک خانواده‌ی اطلاعات متقابل در سطح کل تصویر تعریف می‌شوند و بنابراین در برابر تغییر ناهمگن کنتراست شکننده‌اند؛ و روش‌های آگاه از آناتومی موجود، آناتومی را برای *وزن‌دهی* یا *قید کردن* معیار به کار می‌گیرند، نه برای تعیین *دامنه‌ی محاسبه‌ی* آن؛ جای خالی‌ای که تاکنون در ادبیات پژوهشی پوشش داده نشده است. جدول ۲-۴ مقادیر عددی Dice (معیار مشترک میان اغلب این روش‌ها) و سایر معیارهای گزارش‌شده را برای هر روش، به همراه محک اندازه‌گیری، فهرست می‌کند؛ توجه شود که این معیارها تقریباً همگی روی محک‌های مغزی، ریوی یا شکمیِ *تک‌فاز* گزارش شده‌اند، نه سی‌تی شکمی چندفازی، که خود گویای همان جای خالی است.

جدول ۲-۴: روش‌های منتخب ثبت تصویر: محک اندازه‌گیری، Dice و سایر معیارهای گزارش‌شده، و وضعیت کد.

مرجع	سال	محک	Dice	سایر معیارها	کد باز؟
(SyN) [۴۵]	2008	چهار محک مغزی[۸۹]	0.60–0.77	—	بله
[۴۹] (VoxelMorph)	2019	8 محک مغزی (250 حجم)	0.753 (بدون‌نظارت)؛ 0.78 (با کمک بخش‌بندی)	—	بله
[۵۰] (TransMorph)	2022	Learn2Reg (OASIS، وظیفه‌ی T03)	0.862	mm1.431 HD95	بله
(LapIRN) [۶۱]	2020	OASIS (745 جفت آزمون)	0.808 (جابه‌جایی)؛ 0.765 (دیفئومورفیک)	—	بله
[۶۲] (HyperMorph)	2021	مغزی چندمجموعه‌داده (Buckner40)	0.70–0.74	بسته به معیار شباهت (MSE/NCC در برابر MI)	بله
(MIND) [۴۶]	2012	سی‌تی قفسه‌سینه دم/بازدم؛ چندوجهی	گزارش‌نشده[۹۰]	—	بله
(DEEDS) [۴۷]	2013	Learn2Reg شکمی (BCV/CHAOS)	77.5% (درون‌وجهی MR)؛ 63.6% (بین‌وجهی MR-CT)	—	بله
[۶۵] (UniGradICON)	2024	مغزی (HCP)؛ شکمی (L2R-Abdomen)؛ ریوی (COPDGene)	76.2 (مغزی)؛ 48.3 (شکمی)	mm2.26 TRE (ریوی)	بله

[۸۸] Fixed-image mask

۲-۶ تولید تصاویر سی‌تی کنتراست‌دار از تصاویر سی‌تی بدون تزریق ماده‌ی حاجب

تعریف مسئله

در کنار ثبت تصویر، که فازهای موجود را هم‌تراز می‌کند، مسیر مکمل دیگر در ادبیات پژوهشی، تولید مستقیم اطلاعات فاز کنتراست‌دار از روی تصویر بدون‌کنتراست است؛ وظیفه‌ای که با عناوینی مانند **سنتز کنتراست مجازی**[۹۱] یا ترجمه‌ی تصویر[۹۲] از NC به CE شناخته می‌شود و به‌طور صوری یک مسئله‌ی نگاشت شرطی $G : x_{\mathrm{NC}} \mapsto \hat{x}_{\mathrm{CE}}$ است. این حوزه در سال‌های اخیر به‌سرعت رشد کرده و اکنون شامل ده‌ها روش با معماری‌ها، مجموعه‌داده‌ها و راهبردهای نظارتی متفاوت است (جدول ۲-۵).

معیارهای ارزیابی

ارزیابی کیفیت سنتز معمولاً هم به وفاداری پیکسلی و هم به واقع‌نمایی ادراکی تصویر تولیدشده توجه می‌کند.

نسبت سیگنال به نویز اوج[۹۳] بر پایه‌ی میانگین مربعات خطا در فضای لگاریتمی تعریف می‌شود و تصویر سنتزشده را مستقیماً با تصویر واقعی مقایسه می‌کند؛ این معیار بیشتر به خطای پیکسلی خام حساس است تا ساختار ادراکی تصویر.

شاخص شباهت ساختاری[۹۴] نیز تصویر سنتزشده را مستقیماً با تصویر واقعی مقایسه می‌کند، اما با سنجش هم‌زمان روشنایی، کنتراست و ساختار محلی، به تغییرات ادراکی نزدیک‌تر از PSNR است.

میانگین قدرمطلق خطا[۹۵] و **میانگین مربعات خطا**[۹۶] معیارهای ساده‌تری برای تفاوت شدت روشنایی پیکسل‌به‌پیکسل‌اند و در بسیاری از مطالعات به‌عنوان بخشی از تابع هزینه‌ی آموزش نیز به کار می‌روند.

ضریب همبستگی پیرسون[۹۷] همبستگی خطی میان شدت روشنایی دو تصویر را می‌سنجد.

فاصله‌ی آغازشی فرشه[۹۸] برخلاف معیارهای فوق، تصویر به تصویر مقایسه نمی‌کند، بلکه فاصله‌ی

---

[۹۱] Virtual contrast enhancement
[۹۲] Image-to-image translation
[۹۳] Peak Signal-to-Noise Ratio, PSNR
[۹۴] Structural Similarity Index, SSIM
[۹۵] Mean Absolute Error, MAE
[۹۶] Mean Squared Error, MSE
[۹۷] Pearson Correlation Coefficient, PCC
[۹۸] Fréchet Inception Distance, FID

میان توزیع ویژگی‌های استخراج‌شده (با یک شبکه‌ی از پیش‌آموزش‌دیده) از کل مجموعه‌ی تصاویر واقعی و تولیدشده را اندازه می‌گیرد؛ بنابراین معیاری در سطح توزیع، نه تک‌تصویر، است.

شباهت پرسپچوال یادگرفته‌شده[۹۹] تفاوت دو تصویر را در فضای ویژگی یک شبکه‌ی از پیش‌آموزش‌دیده، به‌جای فضای پیکسل خام، می‌سنجد و بنابراین با قضاوت ادراکی انسان هم‌بستگی بهتری نسبت به SSIM/PSNR دارد.

سرانجام، در مطالعاتی که کاربردپذیری پایین‌دستی سنتز را می‌سنجند، ضریب **Dice** بخش‌بندی روی تصویر سنتزشده (تعریف‌شده در بخش ۲-۲) به‌عنوان معیار غیرمستقیم کیفیت به کار می‌رود.

کارهای پیشین

لیو و همکاران [۶۶] با یک GAN دوگذر (سراسری/موضعی) مبتنی‌بر ستون فقرات HRNet، کنتراست فازهای شریانی، وریدی و تأخیری را به‌طور هم‌زمان از سی‌تی شکم و لگن سنتز کردند.

خانواده‌ای از کارهای یان و همکاران [۶۷، ۶۸، ۶۹] به‌تدریج از یک cGAN بهبودیافته با ماژول تجمیع هرمی، به مدل توجه فضایی[۱۰۰] و سپس شبکه‌ی رمزگشای دوگانه‌ی متقاطع با هدایت بخش‌بندی تکامل یافتند، همگی روی یک مجموعه‌داده‌ی درون‌سازمانی مشترک از ضایعات کبدی ارزیابی شدند.

OA-GAN [۷۰] و **MAN-GAN** [۷۱] با بهره‌گیری از نقاب اندام کبد در بهنجارسازی سازگار با نقاب[۱۰۱]، آگاهی از آناتومی را به‌طور صریح در تولیدکننده وارد کردند؛ رویکردی که پژواک همان محدودسازی آگاه از آناتومی است که در بخش ثبت تصویر نیز دیده شد.

MAFormer [۷۲] با نرمال‌سازی آگاه از ماسک مبتنی‌بر ترانسفورمر و زیان تغییرناپذیری ساختار[۱۰۲]، ساختار تشریحی را در برابر تغییر رنگ‌آمیزی کنتراست حفظ می‌کند.

AMNet [۷۳] با ترکیب توکن‌سازی چندمقیاسی و یادگیری متضاد چندگرانی[۱۰۳]، نمونه‌ای اخیرتر از همین خانواده است.

از آن‌جا که در عمل به‌ندرت می‌توان جفت‌های کاملاً هم‌ترازِ بدون‌کنتراست و کنتراست‌دار را از یک بیمار در یک لحظه به دست آورد، خانواده‌ی دوم از رویکردهای مبتنی‌بر سازگاری چرخه‌ای[۱۰۴] برای

[۹۹] Learned Perceptual Image Patch Similarity, LPIPS
[۱۰۰] Spatial attention
[۱۰۱] Mask-adaptive normalisation
[۱۰۲] Structure invariant loss
[۱۰۳] Multi-granularity contrastive learning
[۱۰۴] Cycle-consistency

آموزش بدون‌جفت[۱۰۵] استفاده می‌کنند. **Res-CycleGAN** [۷۴] با رمزگذار—رمزگشای باقیمانده[۱۰۶] در چارچوب CycleGAN، از این راهبرد برای ترجمه‌ی NC به CE در سی‌تی ریه استفاده کرده است.

CyTran [۷۵] با ترکیب لایه‌های پیچشی و توجه چندسر[۱۰۷] در یک ترانسفورمر سازگار چرخه‌ای، همین وظیفه را دنبال می‌کند.

شی و همکاران [۷۶] نشان دادند CycleGAN و UNIT می‌توانند بدون نیاز به ثبت تصویر، انتقال حوزه[۱۰۸] میان فاز وریدی و بدون‌کنتراست را برای بهبود بخش‌بندی چندعضوی ممکن سازند.

موج اخیرتری از این ادبیات از مدل‌های انتشار[۱۰۹] بهره می‌گیرد. **CFPS-Diff** [۷۷] با یادگیری الگوی جریان کنتراست و شبکه‌ی تمایز فاز، **AdverDM** [۷۸]، مدل کنترل تبدیل فضایی مبتنی‌بر انتشار [۷۹]، مولد فضازمانی علّی[۱۱۰] [۸۰]، و مدل انتشار پل براونی[۱۱۱] با شرط‌دهی متنی[۱۱۲] [۸۱]، همگی نشان‌دهنده‌ی گذار این حوزه از GAN به مدل‌های انتشار در سال‌های 2025 و 2026 هستند، هرچند بسیاری از این کارهای اخیر هنوز جزئیات کامل مجموعه‌داده و معیار ارزیابی را گزارش نکرده‌اند.

زیرمجموعه‌ای از این ادبیات، سنتز و ثبت تصویر را در یک چارچوب واحد ترکیب می‌کنند. ژو و همکاران [۸۲] یادگیری میدان تغییر شکل و یک مولد سه‌بعدی را در یک چارچوب یادگیری چندوظیفه‌ای متحد آموزش دادند تا ثبت تصویر تغییرشکل‌پذیر و سنتز به‌طور سرتاسر و هم‌زمان انجام شود.

لی و همکاران [۸۳] با ماژول تفکیک سازگاری آناتومیک و یک زیرماژول ثبت تصویر مبتنی‌بر VoxelMorph، سازگاری میان محتوای تشریحی و سبک کنتراست را جدا از هم مدل کردند.

اوهم و همکاران [۸۴] با ثبت DEEDS [۴۷] روی تمام فازها پیش از سنتز، وابستگی مستقیم کیفیت سنتز به دقت ثبت تصویر پیشین را نشان دادند. این خط پژوهشی به‌روشنی تأیید می‌کند ثبت تصویر و سنتز، دو رویکرد رقیب نیستند بلکه دو مرحله‌ی مکمل یک زنجیره‌ی پردازشی‌اند.

در نهایت، شماری از مطالعات، کاربردپذیری بالینی این سنتز را مستقیماً ارزیابی کرده‌اند. کیم و همکاران [۸۵] با یک cGAN دومرحله‌ای، دقت تشخیصی سی‌تی مجازی کنتراست‌دار را در بیماران بخش اورژانس با درد حاد شکمی سنجیدند.

هان و همکاران [۸۶] با یک شبکه‌ی U-Net دوونیم‌بعدی و تقطیر دانش[۱۱۳] دومرحله‌ای، کاربردپذیری

[۱۰۵] Unpaired
[۱۰۶] Residual
[۱۰۷] Multi-head attention
[۱۰۸] Domain adaptation
[۱۰۹] Diffusion models
[۱۱۰] Causality-driven spatio-temporal
[۱۱۱] Brownian bridge diffusion
[۱۱۲] Text-guided
[۱۱۳] Knowledge distillation

بالینی سنتز را در بیش از دو هزار جفت آموزشی از یک اسکنر دوانرژی و چند صد بیمار برای اعتبارسنجی بالینی نشان دادند.

هاو و همکاران [۸۷، ۸۸] در مطالعات انسانی و حیوانی، امکان کاهش دوز ماده‌ی حاجب تا حدود 70% را با حفظ کنتراست تشخیصی معادل، با استفاده از cGAN، گزارش کردند. این نتایج بالینی نشان می‌دهند سنتز NC‌ـ به‌ـCE، فراتر از یک مسئله‌ی صرفاً تصویری، پتانسیل کاهش قرارگیری بیمار در معرض ماده‌ی حاجب و دوز تابش را نیز دارد.

آزادبرزین و همکاران [۸۹] و جو و همکاران [۹۰] در دو مرور نظام‌مند مجزا (به ترتیب با 18 و 56 مطالعه)، این حوزه را در سطح گسترده‌تری—از کاهش دوز ماده‌ی حاجب گرفته تا سنتز کامل کنتراست—دسته‌بندی کرده‌اند و بر عدم‌بلوغ گزارش‌دهی کمّی معیارها در بخش قابل‌توجهی از این ادبیات تأکید کرده‌اند.

هرچند شش نمونه‌ی بررسی‌شده در جدول ۲-۶ کد منبع خود را منتشر نکرده‌اند، این وضعیت در سراسر حوزه‌ی گسترده‌تر سنتز کنتراست مجازی—شامل وجهیت‌ها و اندام‌های مجاور غیر از سی‌تی شکمی—یکسان نیست؛ چند مطالعه‌ی مرتبط، کد خود را منتشر کرده‌اند. چوی و همکاران [۹۱]، نزدیک‌ترین نمونه به سنتز NC‌ـ به‌ـCE شکمی از میان این گروه، با یک **GAN** سه‌بعدی سبک pix2pix (نظارت‌شده و جفت‌شده)، کنتراست را مستقیماً از سی‌تی قفسه‌سینه‌ی بدون‌کنتراست سنتز کردند و کد را در دسترس عمومی قرار دادند؛ ارزیابی‌شان روی 25 بیمار توسعه، 25 بیمار آزمون فنی و 12 بیمار آزمون کاربردپذیری بالینی (تشخیص گره‌های لنفاوی میانی‌سینه‌ای) نشان داد تصویر سنتزشده در مقایسه با تصویر بدون‌کنتراست خام، MAE، PSNR، MS-SSIM و LPIPS به‌طور معنادار بهتری دارد.

ژو و همکاران [۹۲] با **GLFC**، یک UNet تقویت‌شده با بلوک‌های Mamba در مسیرهای پرش (برای یادگیری هم‌زمان ویژگی سراسری و موضعی) به همراه زیان تباین چندگانه[۱۱۴]، سی‌تی مصنوعی را از CBCT سنتز کردند؛ کد و ارزیابی روی محک عمومی SynthRAD2023 در دسترس است و SSIM را نسبت به CBCT خام از 77.91% به 91.50% بهبود داد.

فوکودا و همکاران [۹۳] با یک CycleGAN استاندارد، ترجمه‌ی دوسویه‌ی کنتراست را در ناحیه‌ی غدد لنفاوی ژوگولار داخلی، روی داده‌ی خصوصی 25 بیمار، انجام دادند.

رافنا و همکاران [۹۴] سه معماری (خودرمزگذار، Pix2Pix و CycleGAN) را برای سنتز تصویر «بازترکیب‌شده»[۱۱۵] در ماموگرافی طیفی کنتراست‌دار[۱۱۶] از روی تصویر کم‌انرژی مقایسه کردند؛ CycleGAN بهترین عملکرد را داشت و کد به همراه مجموعه‌داده‌ی 1,138 تصویری منتشر شد.

[۱۱۴] Multiple Contrast Loss
[۱۱۵] Recombined image
[۱۱۶] Contrast Enhanced Spectral Mammography, CESM

پینوک و همکاران [۹۵] یک چارچوب مولد شرطی‌شده بر فاز را برای سی‌تی مداخله‌ای در هدایت کرایوتراپی کلیوی توسعه دادند که با یک شبکه‌ی واحد میان فازهای مختلف کنتراست جابه‌جا می‌شود؛ بهترین پیکربندی (UNet) به SSIM حدود 0.9949 و Dice بخش‌بندی تومور حدود 0.65 رسید.

شبکه‌ی **MMgSN-Net** [۹۶] با ترکیب همزمان تصاویر T1w و T2w بدون‌کنتراست MRI، تصویر T1w کنتراست‌دار مجازی را برای بیماران کارسینوم نازوفارنکس سنتز کرد؛ کد این مدل نیز منتشر شده است.

TCGAN [۹۷] با دو مولد متوالی (نخست مبتنی‌بر ترانسفورمر برای زمینه‌ی سراسری، سپس مبتنی‌بر شبکه‌ی پیچشی برای جزئیات موضعی)، سی‌تی مصنوعی را از PET سنتز کرد و روی محک‌های BraTS2020 و IXI نیز ارزیابی شد.

کیدا و همکاران [۹۸] با CycleGAN روی داده‌ی بدون‌جفت، سی‌تی برنامه‌ریزی مصنوعی را از CBCT پرتودرمانی سنتز کردند و نرخ قبولی شاخص گاما را از 86.92% به 96.26% افزایش دادند؛ کد استفاده‌شده، ابزار عمومی ترجمه‌ی تصویر بدون‌جفت یکی از نویسندگان است.

این هشت مطالعه نشان می‌دهند کد باز در ادبیات سنتز کنتراست مجازی وجود دارد، اما با دو محدودیت مهم همراه است. نخست، دقت گزارش‌شده هنوز جای بهبود دارد و اغلب این مطالعات، حتی آن‌ها که کد منتشر کرده‌اند، روی مجموعه‌داده‌های عمومی موجود (مانند نمونه‌های مرورشده در بخش ۲-۳) آزموده نشده‌اند؛ ارزیابی هرکدام معمولاً محدود به یک یا دو مجموعه‌داده‌ی خاص (اغلب خصوصی) است. دوم، جزئیات پیش‌پردازش—به‌ویژه کیفیت هم‌ترازی هندسی جفت‌های آموزشی—در بسیاری از این مقالات به‌طور کامل گزارش نشده، در حالی که این جزئیات می‌تواند تأثیر بزرگی بر نتیجه‌ی نهایی داشته باشد. هیچ‌یک از این مطالعات معیاری برای سنجش کمّی کیفیت هم‌ترازی داده‌ی آموزشی گزارش نکرده‌اند؛ بدون چنین معیاری، تفکیک سهم کیفیت داده از سهم خود مدل در نتیجه‌ی نهایی—یعنی این‌که آیا مدل توانسته کمبود کیفیت هم‌ترازی داده را جبران کند یا نتیجه صرفاً بازتاب داده‌ی از پیش خوب هم‌تراز شده است—ممکن نیست.

جدول ۲–۵: طبقه‌بندی ادبیات سنتز CE-به-NC بر اساس خانواده‌ی روش.

خانواده‌ی روش	نمونه‌های نماینده	معیارهای رایج
GAN جفت‌شده[۱۱۷]	[۶۶، ۶۷، ۶۸، ۷۰، ۶۹، ۷۱، ۷۲، ۷۳، ۹۹، ۹۵، ۱۰۰، ۱۰۱، ۱۰۲، ۹۱]	PSNR, SSIM, MAE/MSE, PCC
سازگاری چرخه‌ای / بدون‌جفت	[۷۴، ۷۵، ۷۶، ۱۰۳]	PSNR, SSIM؛ Dice پایین‌دستی
مدل انتشار	[۷۷، ۷۹، ۷۸، ۸۰، ۸۱، ۱۰۴]	PSNR, SSIM, FID, LPIPS
سنتز هدایت‌شده با ثبت تصویر	[۸۲، ۸۳، ۸۴، ۶]	MAE, SSIM, PSNR؛ Dice
کاربردپذیری بالینی / کاهش دوز	[۸۵، ۸۶، ۸۷، ۸۸، ۱۰۵، ۱۰۶، ۱۰۷، ۱۰۸]	دقت تشخیصی، امتیاز رادیولوژیست، CNR
مرورهای نظام‌مند/گستره‌ای	[۸۹، ۹۰]	—

جدول ۲–۶ نام مدل، سال انتشار، مقادیر عددی گزارش‌شده، و وضعیت انتشار کد را برای چند نمونه‌ی نماینده از این ادبیات کنار هم می‌گذارد؛ ناهمگنی معیارها و مجموعه‌داده‌ها میان مطالعات، مقایسه‌ی مستقیم را دشوار می‌کند. نکته‌ی قابل‌توجه آن است که در هیچ‌یک از این شش نمونه، کد منبع به‌طور تأییدشده در دسترس عمومی قرار ندارد و هیچ‌کدام روی یک محک عمومی نام‌گذاری‌شده آموزش ندیده‌اند؛ همگی روی داده‌ی خصوصی یا درون‌سازمانی آموزش و ارزیابی شده‌اند، یافته‌ای که با کمیابی داده و کد بازتولیدپذیر مستندشده در بخش ۲–۳ هم‌راستاست.

جدول ۲-۶: مدل‌های سنتز CE-به-NC: سال انتشار، داده و تسک، مقادیر گزارش‌شده و وضعیت کد.

مرجع	سال	داده و تسک	مقادیر گزارش‌شده	کد باز؟
[۶۶]	2022	خصوصی، تک‌مرکزی (65 بیمار)	PSNR 19.09/19.79/17.23 و SSIM 0.63/0.65/0.65 برای فاز شریانی/وریدی/تأخیری	خیر
[۶۹] (SGCDD-GAN)	2024	خصوصی، درون‌سازمانی (ضایعات کبدی)	دقت طبقه‌بندی ضایعه 94.11% (فاز وریدی)؛ ارزیابی رادیولوژیست با توافق 94.11%	نامشخص[۱۱۸]
[۷۳] (AMNet)	2025	به‌احتمال خصوصی (گزارش‌نشده)	PSNR 24.88 و SSIM 0.85 (کل‌نگر)؛ MAE 6.28	گزارش‌نشده
[۶] (CKAP-Net)	2024	خصوصی، چندمرکزی	MAE 25.96، SSIM 0.855، PSNR 32.60؛ DSC پایین‌دستی 81.21%	گزارش‌نشده
[۸۶]	2024	خصوصی (2,202 جفت)؛ خارجی 398 بیمار	PSNR 43.25 و SSIM 0.92 در بیش از دو هزار جفت آموزشی	خیر[۱۱۹]
[۸۷، ۸۸]	2022/2021	82 بیمار (انسانی)؛ 20 مینی‌پیگ (حیوانی)	کاهش دوز تا 70% با حفظ نسبت کنتراست‌به‌نویز معادل در مطالعات انسانی و حیوانی	خیر

۲-۷ جمع‌بندی و جای خالی پژوهش

با کنار هم قرار دادن یافته‌های پنج بخش پیشین، تصویری منسجم از جای خالی پژوهشی این حوزه شکل می‌گیرد. بخش‌بندی چندعضوی شکم، با وجود پیشرفت چشمگیر معماری‌های مبتنی‌بر nnU-Net، هنوز در فاز بدون‌کنتراست به‌طور نظام‌مند کم‌دقت‌تر از فاز کنتراست‌دار عمل می‌کند؛ پدیده‌ای که ریشه در کاهش نسبت کنتراست‌به‌نویز و جابه‌جایی حوزه‌ای وابسته به فاز دارد. مرور مجموعه‌داده‌های عمومی سی‌تی شکمی نشان داد این محدودیت تنها یک مسئله‌ی الگوریتمی نیست، بلکه با کمیابی داده‌ی جفت‌شده‌ی چندفازی (تنها حدود 24% مجموعه‌داده‌ها) و سوگیری‌های ساختاری موجود در اکوسیستم داده تشدید می‌شود.

پیش از هر بهره‌برداری از همین داده‌ی چندفازیِ کمیاب، ادبیات تشخیص فاز کنتراست نشان داد شناسایی صحیح فاز هر بررسی، به دلیل ناقص و ناسازگاربودن برچسب‌های سرآیند DICOM، خود گامی

پیش‌نیاز و غیربدیهی است و اغلب روش‌های موجود به بخش‌بندی اندام از پیش‌آموزش‌دیده یا حجم آموزشی بزرگ متکی‌اند.

در پاسخ به کمیابی داده‌ی جفت‌شده، ادبیات ثبت تصویر نشان داد معیارهای کلاسیک اطلاعات متقابل، به دلیل فرض پایداری رابطه‌ی شدت روشنایی در سطح کل تصویر، در برابر تغییر ناهمگن کنتراست شکننده‌اند و روش‌های آگاه از آناتومی موجود، آناتومی را برای *وزن‌دهی* نه *محدودسازی دامنه‌ی* معیار به کار می‌گیرند؛ جای خالی‌ای که تاکنون در ادبیات پژوهشی پوشش داده نشده است.

موازی با آن، ادبیات سنتز NC–به–CE، از GANهای جفت‌شده تا مدل‌های انتشار اخیر، نشان داد بازسازی مستقیم اطلاعات کنتراست از روی تصویر بدون‌کنتراست ممکن است، اما کیفیت آن هم‌چنان به دقت هم‌ترازی هندسی پیشین (از طریق ثبت تصویر) وابسته است. برخلاف تصور رایج، کد باز در این حوزه به‌کلی غایب نیست—چند مطالعه‌ی مرتبط، به‌ویژه در وجهیت‌ها و اندام‌های مجاور سی‌تی شکمی، کد خود را منتشر کرده‌اند—اما دقت گزارش‌شده هنوز جای بهبود دارد، اغلب این مطالعات روی طیف مجموعه‌داده‌های عمومی موجود آزموده نشده‌اند، و هیچ‌کدام معیاری برای سنجش کیفیت هم‌ترازی داده‌ی آموزشی گزارش نکرده‌اند که سهم داده را از سهم مدل در نتیجه‌ی نهایی تفکیک کند.

به‌طور خلاصه، چهار جای خالی مکمل از این مرور استخراج می‌شود: نیاز به تشخیص قابل‌اعتماد فاز کنتراست مستقل از برچسب‌های ناقص سرآیند؛ نبود پایپ‌لاین ثبت تصویری که دامنه‌ی محاسبه‌ی معیار تراز را، نه صرفاً وزن آن را، به نواحی پایدار در برابر فاز کنتراست محدود کند؛ کمیابی جفت‌های هم‌ترازِ بدون‌کنتراست/کنتراست‌دار برای آموزش و ارزیابی مدل‌های سنتز؛ و فقدان شواهد کمّی درباره‌ی اثر این مداخلات بر شکاف دقت بخش‌بندی چندعضوی میان دو فاز. فصل روش پیشنهادی (فصل بعد) به این جاهای خالی می‌پردازد.

فصل ۳

روش پیشنهادی

فصل ۴

آزمایش‌ها

فصل ۵

نتیجه‌گیری

Bibliography

[1] S. Danaei, Z. Dehghanian, E. Meftah, N. Naderi, S. Safavi-Naini, F. Khorasanizade, and H. Rabiee. State of abdominal ct datasets: A critical review of bias, clinical relevance, and real-world applicability. *PLOS Digital Health*, 2026. In press.

[2] L. European Association for the Study of the. Easl clinical practice guidelines: Management of hepatocellular carcinoma. J. Hepatol., 69(1):182–236, 2018. 10.1016/j.jhep.2018.03.019.

[3] A. Forner, M. Reig, and J. Bruix. Hepatocellular carcinoma. Lancet, 391(10127):1301–1314, 2018. 10.1016/S0140-6736(18)30010-2.

[4] S. Jeon, I. Joo, J. Park, J.-M. Kim, S. Park, and S. Yoon. Fully-automated multi-organ segmentation tool applicable to both non-contrast and post-contrast abdominal CT: deep learning algorithm developed using dual-energy CT images. *Scientific Reports*, 14:4378, 2024.

[5] L. Abel, J. Wasserthal, M. Meyer, J. Vosshenrich, S. Yang, R. Donners, et al. Intra-individual reproducibility of automated abdominal organ segmentation—performance of TotalSegmentator compared to human readers and an independent nnU-Net model. *Journal of Imaging Informatics in Medicine*, 2025.

[6] Z. et al. Ncct-to-cect synthesis with contrast-enhanced knowledge and anatomical perception for multi-organ segmentation in non-contrast ct images, 2024. https://doi.org/10.1016/j.media.2024.103397.

[7] B. Dao, T. Nguyen, H. Pham, and H. Nguyen. Phase recognition in contrast-enhanced ct scans based on deep learning and random sampling (vindr-multiphase dataset). Medical Physics, 49(5):3102–3116, 2022. 10.1002/mp.15551.

[8] F. Isensee, P. Jaeger, S. Kohl, J. Petersen, and K. Maier-Hein. nnu-net: a self-configuring method for deep learning-based biomedical image segmentation. *Nature Methods*, 18(2):203–211, 2021.

[9] J. Wasserthal, H.-C. Breit, and M. Meyer. Totalsegmentator: Robust segmentation of 104 anatomic structures in ct images. Radiology: Artif. Intell., 5(5):e230024, 2023. 10.1148/ryai.230024.

[10] J. Ma, Y. Zhang, S. Gu, C. Zhu, C. Ge, Y. Zhang, et al. Abdomenct-1k: Is abdominal organ segmentation a solved problem? *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 44(10):6695–6714, 2021.

[11] J. Ma, Y. Zhang, S. Gu, C. Ge, E. Wang, Q. Zhou, et al. Automatic organ, pancancer segmentation in abdomen CT: the FLARE 2023 challenge, 2024. arXiv preprint arXiv:2408.12534.

[12] W. Li, C. Qu, X. Chen, P. Bassi, Y. Shi, Y. Lai, et al. Abdomenatlas: A large-scale, detailed-annotated, & multi-center dataset for efficient transfer learning, open algorithmic benchmarking. *Medical Image Analysis*, 97:103285, 2024.

[13] M. Antonelli, A. Reinke, S. Bakas, et al. The medical segmentation decathlon. *Nature Communications*, 13, 2022.

[14] J. Liu, Y. Zhang, J. Chen, J. Xiao, Y. Lu, B. Landman, et al. CLIP-driven universal model for organ segmentation and tumor detection. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2023.

[15] C. Yu, C. Anakwenze, Y. Zhao, R. Martin, E. Ludmir, J. Niedzielski, et al. Multi-organ segmentation of abdominal structures from non-contrast and contrast enhanced CT images. *Scientific Reports*, 12, 2022.

[16] K. Moons, J. Damen, T. Kaul, L. Hooft, C. Andaur Navarro, P. Dhiman, et al. PROBAST+AI: an updated quality, risk of bias, and applicability assessment tool for prediction models using regression or artificial intelligence methods. *BMJ*, 388, 2025.

[17] B. Koçak, A. Ponsiglione, A. Stanzione, C. Bluethgen, J. Santinha, L. Ugga, et al. Bias in artificial intelligence for medical imaging: Fundamentals, detection, avoidance, mitigation, challenges, ethics, prospects. *Diagnostic and Interventional Radiology*, 2024.

[18] G. Collins, K. Moons, P. Dhiman, R. Riley, A. Beam, B. Van Calster, et al. TRIPOD+AI statement: updated guidance for reporting clinical prediction models that use regression or machine learning methods. *BMJ*, 385:e078378, 2024.

[19] C. Jones, D. Castro, F. De Sousa Ribeiro, O. Oktay, M. McCradden, and B. Glocker. A causal perspective on dataset bias in machine learning for medical imaging. *Nature Machine Intelligence*, 6(2):138–146, 2024.

[20] Z. Obermeyer, B. Powers, C. Vogeli, and S. Mullainathan. Dissecting racial bias in an algorithm used to manage the health of populations. *Science*, 366(6464):447–453, 2019.

[21] A. Larrazabal, N. Nieto, V. Peterson, D. Milone, and E. Ferrante. Gender imbalance in medical imaging datasets produces biased classifiers for computer-aided diagnosis. *Proceedings of the National Academy of Sciences*, 117(23):12592–12594, 2020.

[22] A. Kaushal, R. Altman, and C. Langlotz. Geographic distribution of US cohorts used to train deep learning algorithms. *JAMA*, 324(12):1212–1213, 2020.

[23] L. Seyyed-Kalantari, H. Zhang, M. McDermott, I. Chen, and M. Ghassemi. Underdiagnosis bias of artificial intelligence algorithms applied to chest radiographs in under-served patient populations. *Nature Medicine*, 27(12):2176–2182, 2021.

[24] R. Daneshjou, K. Vodrahalli, R. Novoa, M. Jenkins, W. Liang, V. Rotemberg, et al. Disparities in dermatology AI performance on a diverse, curated clinical image set. *Science Advances*, 8(32):eabq6147, 2022.

[25] J. Llovet, R. Kelley, A. Villanueva, A. Singal, E. Pikarsky, S. Roayaie, et al. Hepatocellular carcinoma. *Nature Reviews Disease Primers*, 7(1):6, 2021.

[26] V. Kedar Mukthinuthalapati, V. Sewram, N. Ndlovu, S. Kimani, A. Abdelaziz, E. Chiao, et al. Hepatocellular carcinoma in sub-saharan africa. *JCO Global Oncology*, 7:756–766, 2021.

[27] B. Koch, E. Denton, A. Hanna, and J. Foster. Reduced, reused and recycled: The life of a dataset in machine learning research, 2021. arXiv preprint arXiv:2112.01716.

[28] G. Varoquaux and V. Cheplygina. Machine learning for medical imaging: methodological failures and recommendations for the future. *NPJ Digital Medicine*, 5(1):48, 2022.

[29] N. Rieke, J. Hancox, W. Li, F. Milletari, H. Roth, S. Albarqouni, et al. The future of digital health with federated learning. *NPJ Digital Medicine*, 3(1):119, 2020.

[30] K. Seastedt, P. Schwab, Z. O'Brien, E. Wakida, K. Herrera, P. Marcelo, et al. Global healthcare fairness: We should be sharing more, not less, data. *PLOS Digital Health*, 1(10):e0000102, 2022.

[31] R. Muhamedrahimov, A. Bar, J. Laserson, A. Akselrod-Ballin, and E. Elnekave. Using machine learning to identify intravenous contrast phases on computed tomography. *Computer Methods and Programs in Biomedicine*, 215:106603, 2022.

[32] B. Hou, T. S. Mathai, P. Mukherjee, X. Wang, R. M. Summers, and Z. Lu. Segment-and-classify: ROI-guided generalizable contrast phase classification in CT using XGBoost. *arXiv preprint arXiv:2501.14066*, 2025.

[33] E. P. Reis, L. Blankemeier, J. M. Zambrano Chaves, et al. Automated abdominal CT contrast phase detection using an interpretable and open-source artificial intelligence algorithm. *European Radiology*, 34(10):6680–6687, 2024.

[34] G. Baldini, R. Hosch, C. S. Schmidt, K. Borys, L. Kroll, S. Koitka, P. Haubold, O. Pelka, F. Nensa, and J. Haubold. Addressing the contrast media recognition challenge: A fully automated machine learning approach for predicting contrast phases in CT imaging. *Investigative Radiology*, 59(9):635–645, 2024.

[35] Z. Ye, J. M. Qian, A. Hosny, et al. Deep learning-based detection of intravenous contrast enhancement on CT scans. *Radiology: Artificial Intelligence*, 4:e210285, 2022.

[36] B. T. Dao, T. V. Nguyen, H. H. Pham, and H. Q. Nguyen. Phase recognition in contrast-enhanced CT scans based on deep learning and random sampling. *Medical Physics*, 49(5):3102–3116, 2022. VinDr-Multiphase dataset paper; random-slice-sampling majority-vote phase classifier.

[37] B. A. Rocha, L. C. Ferreira, L. G. R. Vianna, et al. Contrast phase recognition in liver computer tomography using deep learning. *Scientific Reports*, 12:20315, 2022.

[38] Q. Liu, J. Jiang, K. Wu, Y. Zhang, N. Sun, J. Luo, T. Ba, A. Lv, C. Liu, Y. Yin, Z. Yang, and H. Xu. A two-step automatic identification of contrast phases for abdominal CT images based on residual networks. *Insights into Imaging*, 2025.

[39] A. Anand, J. Liu, T. C. Shen, W. M. Linehan, P. A. Pinto, and R. M. Summers. Automated classification of intravenous contrast enhancement phase of CT scans using residual networks. In *Proc. SPIE 12465, Medical Imaging 2023: Computer-Aided Diagnosis*, page 124650O, 2023.

[40] WAW-TACE: A hepatocellular carcinoma multiphase CT dataset with segmentations, radiomics features, and clinical data. *Radiology: Artificial Intelligence*, 2024. Zenodo DOI: 10.5281/zenodo.11063784.

[41] N. Heller, N. Sathianathen, A. Kalapara, et al. Data from C4KC-KiTS. The Cancer Imaging Archive, 2019.

[42] I. Wells WM, P. Viola, H. Atsumi, S. Nakajima, and R. Kikinis. Multi-modal volume registration by maximization of mutual information. Med. Image Anal., 1(1):35–51, 1996. 10.1016/S1361-8415(01)80004-9.

[43] C. Studholme, D. Hill, and D. Hawkes. An overlap invariant entropy measure of 3d medical image alignment. Pattern Recognition, 32(1):71–86, 1999. 10.1016/S0031-3203(98)00091-0.

[44] D. Mattes, D. Haynor, H. Vesselle, T. Lewellen, and W. Eubank. Nonrigid multimodality image registration. Proc. SPIE Med. Imaging, 4322:1609–1620, 2001. 10.1117/12.431046.

[45] B. Avants, C. Epstein, M. Grossman, and J. Gee. Symmetric diffeomorphic image registration with cross-correlation: Evaluating automated labeling of elderly and neurodegenerative brain. Med. Image Anal., 12(1):26–41, 2008. 10.1016/j.media.2007.06.004.

[46] M. Heinrich, M. Jenkinson, M. Bhushan, T. Matin, F. Gleeson, S. Brady, and J. Schnabel. Mind: Modality independent neighbourhood descriptor for multimodal deformable registration. Med. Image Anal., 16(7):1423–1435, 2012. 10.1016/j.media.2012.05.008.

[47] M. Heinrich, M. Jenkinson, M. Brady, and J. Schnabel. Deeds: Mrf-based nonlinear image registration using efficient discrete optimization. Int. J. Comput. Vis., 103(3):384–400, 2013. 10.1007/s11263-013-0606-z.

[48] K. Murphy, B. van Ginneken, and S. Klein. Semi-automatic construction of reference standards for evaluation of image registration. Med. Image Anal., 15(1):71–84, 2011. 10.1016/j.media.2010.07.005.

[49] G. Balakrishnan, A. Zhao, M. Sabuncu, J. Guttag, and A. Dalca. Voxelmorph: A learning framework for deformable medical image registration. IEEE Trans. Med. Imaging, 38(8):1788–1800, 2019. http://doi..org/10.1109/TMI.2019.2897538.

[50] J. Chen, E. Frey, Y. He, W. Segars, Y. Li, and Y. Du. Transmorph: Transformer for unsupervised medical image registration. Med. Image Anal., 82:102615, 2022. 10.1016/j.media.2022.102615.

[51] S. Klein, M. Staring, K. Murphy, M. Viergever, and J. Pluim. Elastix: A toolbox for intensity-based medical image registration. IEEE Trans. Med. Imaging, 29(1):196–205, 2010. 10.1109/TMI.2009.2035616.

[52] B. Lowekamp, D. Chen, L. Ibanez, and D. Blezek. The design of simpleitk. Front. Neuroinform., 7:45, 2013. 10.3389/fninf.2013.00045.

[53] D. Rueckert, L. Sonoda, C. Hayes, D. Hill, M. Leach, and D. Hawkes. Nonrigid registration using free-form deformations: Application to breast mr images. IEEE Trans. Med. Imaging, 18(8):712–721, 1999. 10.1109/42.796284.

[54] J.-P. Thirion. Image matching as a diffusion process: An analogy with maxwell's demons. Med. Image Anal., 2(3):243–260, 1998. 10.1006/mian.1998.0107.

[55] J. Pluim, J. Maintz, and M. Viergever. Mutual-information based registration of medical images: A survey. IEEE Trans. Med. Imaging, 22(8):986–1004, 2003. 10.1109/TMI.2003.815867.

[56] C. Metz, S. Klein, M. Schaap, T. van Walsum, and W. Niessen. Nonrigid registration of dynamic medical imaging data using nd+t b-splines and a groupwise optimization approach. Med. Image Anal., 15(2):238–249, 2011. 10.1016/j.media.2010.10.003.

[57] B. Papiez, M. Heinrich, L. Risser, and J. Schnabel. An implicit sliding-motion preserving regularisation via bilateral filtering for deformable image registration. Med. Image Anal., 18(8):1323–1335, 2014. 10.1016/j.media.2014.06.006.

[58] B. De Vos, F. Berendsen, M. Viergever, H. Sokooti, M. Staring, and I. Isgum. A deep learning framework for unsupervised affine and deformable image registration. Med. Image Anal., 52:128–143, 2019. 10.1016/j.media.2019.02.003.

[59] Y. Hu, M. Modat, and E. Gibson. Weakly-supervised convolutional neural networks for multimodal image registration. Med. Image Anal., 49:1–13, 2018. 10.1016/j.media.2018.07.002.

[60] O. Oktay, E. Ferrante, and K. Kamnitsas. Anatomically constrained neural networks (acnn): Application to cardiac image enhancement and segmentation. IEEE Trans. Med. Imaging, 37(2):384–395, 2018. 10.1109/TMI.2017.2743464.

[61] T. Mok and A. Chung. Large deformation diffeomorphic image registration with laplacian pyramid networks. Proc. MICCAI 2020, pp. 211–221, 2020. 10.1007/978-3-030-59716-0_21.

[62] A. Hoopes, M. Hoffmann, B. Fischl, J. Guttag, and A. Dalca. Hypermorph: Amortised hyperparameter learning for image registration. Proc. IPMI 2021, pp. 3–17, 2021. 10.1007/978-3-030-78191-0_1.

[63] Z. Zhao, V. Lau, and Z. Li. Recursive cascaded networks for unsupervised medical image registration. Proc. ICCV 2019, pp. 10600–10610, 2019. 10.1109/ICCV.2019.01069.

[64] Z. Xu and M. Niethammer. Deepatlas: Joint semi-supervised learning of image registration and segmentation. Proc. MICCAI 2019, pp. 420–429, 2019. 10.1007/978-3-030-32245-8_47.

[65] H. Tian. Unigradicon: A foundation model for medical image registration. arXiv:2403.05780, 2024. https://arxiv.org/abs/2403.05780.

[66] L. et al. Virtual contrast enhancement for ct scans of abdomen and pelvis, 2022. https://doi.org/10.1016/j.compmedimag.2022.102094.

[67] Y. et al. Synthesizing contrast-enhanced computed tomography images with an improved conditional generative adversarial network, 2022. https://doi.org/10.1109/EMBC48229.2022.9871672.

[68] Y. et al. Spatial attention-guided generative adversarial network for synthesizing contrast-enhanced computed tomography images, 2023. https://doi.org/10.1109/EMBC40787.2023.10340586.

[69] Y. et al. Segmentation guided crossing dual decoding generative adversarial network for synthesizing contrast-enhanced computed tomography images, 2024. https://doi.org/10.1109/JBHI.2024.3403199.

[70] Y. et al. Oa-gan: organ-aware generative adversarial network for synthesizing contrast-enhanced medical images, 2024. https://doi.org/10.1088/2057-1976/ad31fa.

[71] Z. et al. Man-gan: a mask-adaptive normalization based generative adversarial networks for liver multi-phase ct image generation, 2025. https://doi.org/10.1038/s41598-025-10754-z.

[72] C. et al. Mask-aware transformer with structure invariant loss for ct translation, 2024. https://doi.org/10.1016/j.media.2024.103205.

[73] Z. et al. Contrast-aware network with aggregated-interacted transformer and multi-granularity aligned contrastive learning for synthesizing contrast-enhanced abdomen ct imaging, 2025. https://doi.org/10.1109/TCI.2025.3540711.

[74] X. et al. Generation of contrast-enhanced ct with residual cycle-consistent generative adversarial network (res-cyclegan), 2021. https://doi.org/10.1117/12.2581056.

[75] R. et al. Cytran: A cycle-consistent transformer with multi-level consistency for non-contrast to contrast ct translation, 2021. https://arxiv.org/abs/2110.06400.

[76] S. et al. Unpaired medical image translation between portal-venous phase and non-contrast ct volumes for multi-organ segmentation, 2021. https://doi.org/10.1117/12.2590639.

[77] Z. et al. Contrast flow pattern and cross-phase specificity-aware diffusion model for ncct-to-multiphase cect synthesis, 2025. https://doi.org/10.1007/978-3-032-04965-0_9.

[78] Z. et al. Cross-domain distribution adversarial diffusion model for synthesizing contrast-enhanced abdomen ct imaging, 2025. https://www.sciencedirect.com/science/article/abs/pii/S0031320325003553.

[79] W. et al. Synthesis of abdominal contrast-enhanced ct using diffusion-based spatial transform control, 2025. https://doi.org/10.1007/978-3-032-09513-8_14.

[80] Z. et al. Causality-driven spatio-temporal generator for multi-phase contrast-enhanced ct synthesis, 2025. https://doi.org/10.1007/978-3-032-04947-6_11.

[81] L. et al. A text-guided brownian bridge diffusion model for unified multiphase contrast-enhanced ct synthesis, 2026.

[82] Z. et al. United multi-task learning for abdominal contrast-enhanced ct synthesis through joint deformable registration, 2023. https://doi.org/10.1016/j.cmpb.2023.107391.

[83] L. et al. Boosting medical image synthesis via registration-guided consistency and disentanglement learning, 2024. https://arxiv.org/abs/2407.07660.

[84] U. et al. A unified multi-phase ct synthesis and classification framework for kidney cancer diagnosis with incomplete data, 2022. https://doi.org/10.1109/JBHI.2022.3219123.

[85] K. et al. The feasibility of deep learning-based synthetic contrast-enhanced ct from nonenhanced ct in emergency department patients with acute abdominal pain, 2021. https://doi.org/10.1038/s41598-021-99896-4.

[86] H. et al. Clinical feasibility of deep learning based synthetic contrast enhanced abdominal ct in patients undergoing non enhanced ct scans, 2024. https://doi.org/10.1038/s41598-024-68705-z.

[87] H. et al. Contrast agent dose reduction in computed tomography with deep learning using a conditional generative adversarial network, 2021. https://doi.org/10.1007/s00330-021-07714-2.

[88] H. et al. Contrast media reduction in computed tomography with deep learning using a generative adversarial network in an experimental animal study, 2022. https://pubmed.ncbi.nlm.nih.gov/35438659/.

[89] A. et al. Applications of deep learning to reduce the need for iodinated contrast media for ct imaging: a systematic review, 2023. https://doi.org/10.1007/s11548-023-02862-w.

[90] J. et al. Deep learning for synthetic contrast-enhanced ct and mri: a scoping review, 2026. https://doi.org/10.1007/s00330-026-12548-x.

[91] C. et al. Generating synthetic contrast enhancement from non-contrast chest computed tomography using a generative adversarial network, 2021. https://doi.org/10.1038/s41598-021-00058-3.

[92] X. Zhou, J. Wu, H. Zhao, L. Chen, S. Zhang, and G. Wang. GLFC: Unified global-local feature and contrast learning with mamba-enhanced UNet for synthetic CT generation from CBCT, 2025. arXiv:2501.02992; https://github.com/HiLab-git/GLFC.

[93] M. Fukuda, S. Kotaki, M. Nozawa, C. Kuwada, Y. Kise, E. Ariji, and Y. Ariji. A cycle generative adversarial network for generating synthetic contrast-enhanced computed tomographic images from non-contrast images in the internal jugular lymph node-bearing area, 2024.

[94] A. Rofena, V. Guarrasi, M. Sarli, C. L. Piccolo, M. Sammarra, B. B. Zobel, and P. Soda. A deep learning approach for virtual contrast enhancement in contrast enhanced spectral mammography. *Computerized Medical Imaging and Graphics*, 116:102398, 2024. https://github.com/cosbidev/VCE_CESM.

[95] P. et al. Multi-phase synthetic contrast enhancement in interventional computed tomography for guiding renal cryotherapy, 2023. https://doi.org/10.1007/s11548-023-02843-z.

[96] W. Li et al. Virtual contrast-enhanced magnetic resonance images synthesis for patients with nasopharyngeal carcinoma using multimodality-guided synergistic neural network. *International Journal of Radiation Oncology*Biology*Physics*, 112(4):1033–1044, 2022. https://github.com/WenLi-PolyU/MMgSN-Net-for-vce-MRI-synthesis.

[97] J. Li, Z. Qu, Y. Yang, F. Zhang, M. Li, and S. Hu. TCGAN: a transformer-enhanced GAN for PET synthetic CT. *Biomedical Optics Express*, 13(11):6003–6018, 2022. https://github.com/jinxiqinghuan/TCGAN.

[98] S. Kida, S. Kaji, et al. Visual enhancement of cone-beam CT by use of CycleGAN. *Medical Physics*, 47(3):998–1010, 2020. arXiv:1901.05773; https://github.com/shizuo-kaji/UnpairedImageTranslation.

[99] S. et al. Neural contrast enhancement of ct image, 2021. https://openaccess.thecvf.com/content/WACV2021/html/Seo_Neural_Contrast_Enhancement_of_CT_Image_WACV_2021_paper.html.

[100] P. et al. Time conditioning for arbitrary contrast phase generation in interventional computed tomography, 2024. https://doi.org/10.1088/1361-6560/ad46dd.

[101] S. et al. Synthetic contrast enhancement in cardiac ct with deep learning, 2018. https://arxiv.org/abs/1807.01779.

[102] D. et al. Development and evaluation of a novel organ-specific biomechanics-guided contrast-enhanced ct volume synthesis model, 2025.

[103] L. et al. Dyefreenet: Deep virtual contrast ct synthesis, 2020. https://doi.org/10.1007/978-3-030-59520-3_9.

[104] S. et al. Generating synthetic contrast-enhanced chest ct images from non-contrast scans using slice-consistent brownian bridge diffusion network, 2025. https://arxiv.org/abs/2508.16897.

[105] P. et al. Ncct-cect image synthesizers and their application to pulmonary vessel segmentation, 2023. https://doi.org/10.1016/j.cmpb.2023.107389.

[106] L. et al. Generative adversarial network-based noncontrast ct angiography for aorta and carotid arteries, 2023. https://doi.org/10.1148/radiol.230681.

[107] H. et al. Aorta-aware gan for non-contrast to artery contrasted ct translation and its application to abdominal aortic aneurysm detection, 2021. https://doi.org/10.1007/s11548-021-02492-0.

[108] L. et al. Translate contrast-enhanced ct from non-contrast ct via subtraction image prediction, 2025. https://www.sciencedirect.com/science/article/pii/S0360301625037952.

واژه‌نامه

الف

انحراف حجمی ..... Volumetric deviation

انتقال حوزه ..... Domain adaptation

ب

بخش‌بندی چندعضوی . Multi-organ segmentation

بازخوانی ..... Recall

بی‌اسپلاین ..... B-spline

بهنجارسازی سازگار با نقاب ..... Mask-adaptive normalisation

بدون‌جفت ..... Unpaired

باقیمانده ..... Residual

پ

پرسش‌محور ..... Prompt-driven

پرخون ..... Hypervascular

پنجره‌ی پارزن ..... Parzen window

پیشین‌های شکل تشریحی Anatomical shape priors

پایداری معکوس گرادیان ..... Gradient inverse consistency

پیمانه‌ای ..... Modular

پل براونی ..... Brownian bridge diffusion

ت

تکرارپذیری ..... Reproducibility

تمرکز محک ..... Benchmark concentration

تصویر متحرک ..... Moving image

تصویر ثابت ..... Fixed image

تغییر شکل آزاد .. Free-Form Deformation (FFD)

تکراری ..... Iterative

تبدیل‌گر فضایی ..... Spatial transformer

توصیف‌گر همسایگی مستقل از وجهیت Modality In-dependent Neighbourhood Descriptor (MIND)

ترجمه‌ی تصویر ..... Image-to-image translation

توجه چندسر ..... Multi-head attention

تقطیر دانش ..... Knowledge distillation

ث

ثبت تصویر ..... Image registration

ثبت گروهی ..... Groupwise

ج

جابه‌جایی حوزه‌ای ..... Domain shift

جنگل درختان تقویت‌شده‌ی گرادیانی .... Gradient-boosted decision trees

جفت‌شده ..... Paired

چ

چندگذره ..... Multi-pass

ح

حرکت لغزشی ..... Sliding motion

خ

خودپیکربندی ..... Self-configuring

خطای ثبت هدف ..... Target Registration Error (TRE)

خشن‌به‌ریز ..... Coarse-to-fine

خودشباهت ..... Self-similarity

د

دقت ..... Accuracy

دقت‌مثبت ..... Precision

دیمانز ..... Demons

دایکام ..... DICOM

Dice فرسایش‌یافته ..... Eroded Dice

ز

زیان تغییرناپذیری ساختار .Structure invariant loss

س

سوگیری ..... Bias

سوگیری طیف ..... Spectrum bias

سوگیری انتخاب ..... Selection bias

سوگیری نژادی ..... Racial bias

سوگیری جمعیت‌شناختی ..... Demographic bias

سوگیری فنی ..... Technical bias

سوگیری برچسب‌گذاری ..... Labelling bias

سوگیری زمانی ..... Temporal bias

سی‌تی بدون‌کنتراست .. Non-contrast CT (NCCT)

سی‌تی کنتراست‌دار ..... Contrast-enhanced CT (CECT)

سی‌تی دوانرژی ..... Dual-energy CT

سی‌تی چندفازی ..... Multi-phase CT

سی‌تی شکمی ..... Abdominal CT

سنتز کنتراست مجازی ..... Virtual contrast enhancement

سازگاری چرخه‌ای ..... Cycle-consistency

ش

شبکه‌های آبشاری بازگشتی ... Recursive Cascaded Networks

شاخص شباهت ساختاری ... Structural Similarity Index (SSIM)

شباهت پرسپچوال یادگرفته‌شده Learned Perceptual Image Patch Similarity (LPIPS)

شرط‌دهی متنی ..... Text-guided

شست‌وشو ..... Washout

ص

صدک نودوپنجم فاصله‌ی هاسدورف 95th percentile Hausdorff Distance (HD95)

صلب ..... Rigid

صفر/چندنمونه ..... Zero/few-shot

ض

ضریب هم‌پوشانی سورنسن–دایس .. Sørensen–Dice coefficient

ضریب همبستگی پیرسون .... Pearson Correlation

Coefficient (PCC)

غ

غربالگری فرصت‌طلبانه . . Opportunistic screening

ف

فاز بدون‌کنتراست . . . . . Non-contrast (NC) phase

فاز کنتراست . . . . . Contrast phase

فاز کنتراست‌دار . Contrast-enhanced (CE) phase

فاصله‌ی مرکز جرم . . . . . Centroid distance

فاصله‌ی آغازشی فرشه Fréchet Inception Distance (FID)

فضازمانی علّی Causality-driven spatio-temporal

ک

کارسینوم سلول کبدی . Hepatocellular carcinoma (HCC)

م

منحنی مشخصه‌ی عملکرد سیستم . . . . . Receiver Operating Characteristic curve (ROC)

مقیاس‌پذیری ترکیبی . . . . . Compound scaling

منظم‌ساز . . . . . Regulariser

مدل بنیادین . . . . . Foundation model

مستقل از وجهیت . . . . . Modality-independent

میدان تصادفی مارکوف . . . Markov Random Field (MRF)

میانگین قدرمطلق خطا . . . . . Mean Absolute Error (MAE)

میانگین مربعات خطا Mean Squared Error (MSE)

مدل‌های انتشار . . . . . Diffusion models

ماده‌ی حاجب . . . . . Contrast media

ن

نسبت کنتراست‌به‌نویز . . . . Contrast-to-noise ratio (CNR)

نقاب . . . . . Mask

نشت داده . . . . . Data leakage

نشانه‌های آناتومیک . . . . . Anatomical landmarks

نظارت ضعیف . . . . . Weak supervision

نقاب تصویر ثابت . . . . . Fixed-image mask

نسبت سیگنال به نویز اوج . . . Peak Signal-to-Noise Ratio (PSNR)

و

وضعیت فاز کنتراست . . . . Contrast enhancement status

هـ

هم‌پوشانی برچسب . . . . . Label overlap

ی

یادگیری فدرال . . . . . Federated learning

یادگیری متضاد چندگرانی . . . . . Multi-granularity contrastive learning

پیوست آ

مطالب تکمیلی

Abstract

We present a standard template for typesetting theses in Persian. The template is based on the XePersian package for the LaTeX typesetting system. This write-up shows a sample usage of this template.

Keywords: Thesis, Typesetting, Template, XePersian



Sharif University of Technology

Department of Computer Engineering

M.Sc. Thesis

Bioinformatics Thesis

Automatic multi-organ Segmentation in Abdominal CT with enhancing performance in non-contrast CT studies

By:

Saeide Danaei

Supervisor:

Hamid R. Rabiee

September 2026