دانشگاه صنعتی شریف
دانشکده مهندسی کامپیوتر

پایان‌نامه کارشناسی ارشد
مهندسی کامپیوتر

بخش‌بندی خودکار چنداندامی شکم در تصاویر سی‌تی‌اسکن با تمرکز بر بهبود کیفیت بر روی تصاویر بدون تزریق ماده‌حاجب

نگارش

سعیده دانائی

استاد راهنما

حمیدرضا ربیعی

شهریور ۱۴۰۵

سپاس

از استاد بزرگوارم که با کمک‌ها و راهنمایی‌های بی‌دریغشان، مرا در به سرانجام رساندن این پایان‌نامه یاری داده‌اند، تشکر و قدردانی می‌کنم. همچنین از همکاران عزیزی که با راهنمایی‌های خود در بهبود نگارش این نوشتار سهیم بوده‌اند، صمیمانه سپاسگزارم.

فهرست مطالب

۱ مقدمه ۱

۱-۱ اهمیت مسئله ۱

۱-۲ تعریف مسئله ۲

۱-۲-۱ مرور انتقادی مجموعه‌داده‌های سی‌تی شکمی ۳

۱-۲-۲ تشخیص فاز کنتراست ۳

۱-۲-۳ هم‌ترازسازی تصویر بین‌فازی ۳

۱-۲-۴ سنتز فاز کنتراست‌دار از فاز بدون‌کنتراست ۴

۱-۳ چالش‌ها ۴

۱-۴ اهداف پژوهش ۵

۱-۵ ساختار پایان‌نامه ۵

۱-۶ جمع‌بندی ۶

۲ کارهای پیشین ۷

۲-۱ پیش‌زمینه‌ی بالینی: سی‌تی چندفازی و فازهای کنتراست ۸

۲-۲ بخش‌بندی چندعضوی سی‌تی شکمی و شکاف کیفیت در فاز بدون‌کنتراست ۹

۲-۳ مجموعه‌داده‌های عمومی سی‌تی شکمی و مسئله‌ی سوگیری داده ۱۵

۲-۴ تشخیص فاز کنتراست در تصاویر سی‌تی خام ۱۹

۲-۵ هم‌ترازسازی تصویر بین‌فازی سی‌تی ۲۶

۲-۶ تولید تصاویر سی‌تی کنتراست‌دار از تصاویر سی‌تی بدون تزریق ماده‌ی حاجب ۳۹
۲-۷ جمع‌بندی و جای خالی پژوهش ۵۵

۳ روش پیشنهادی ۵۷
۳-۱ نمای کلی ۵۷
۳-۲ مرور نظام‌مند مجموعه‌داده‌های سی‌تی شکمی: پروتکل ۵۸
۳-۳ داده و پیش‌پردازش ۶۱
۳-۴ تشخیص فاز کنتراست ۶۳
۳-۵ هم‌ترازسازی تصویر بین‌فازی چندگذره ۶۷
۳-۶ سنتز فاز کنتراست‌دار: شبکه‌ی PLC-Net ۷۸
۳-۷ پروتکل ارزیابی ۸۶
۳-۸ جمع‌بندی ۸۹

۴ آزمایش‌ها ۹۱
۴-۱ یافته‌های مرور نظام‌مند مجموعه‌داده‌ها ۹۱
۴-۲ نتایج هم‌ترازسازی تصویر بین‌فازی ۹۸
۴-۳ نتایج تشخیص فاز کنتراست ۱۱۵
۴-۴ نتایج سنتز فاز کنتراست‌دار ۱۲۲

۵ نتیجه‌گیری ۱۴۱

مراجع ۱۴۲

واژه‌نامه ۱۵۵

آ مطالب تکمیلی ۱۵۹
آ-۱ تحلیل حساسیت: دایس فرسوده در ارزیابی پایین‌دستی سنتز ۱۵۹

فهرست جداول

۲-۱ مدل‌های بخش‌بندی چندعضوی و مطالعات شکاف بین‌فازی. **کد فاز:** ۰ بدون‌کنتراست، ۱ شریانی، ۲ وریدی باب، ۳ تأخیری؛ ستون «فازهای داده‌ی آموزش» فهرست فازهایی است که مدل در آموزش دیده است. همه‌ی مقادیر Dice در بازه‌ی صفر تا یک‌اند. **ستون کد:** ✓یعنی کد منبع به‌طور تأییدشده در دسترس عمومی است و ×یعنی کد منتشر نشده یا وضعیت آن در مقاله ذکر نشده است. ارقام nnU-Net مربوط به وظیفه‌های شکمی محک MSD [۱] است (طحال ۰/۹۶، کبد ۰/۹۳، پانکراس ۰/۷۹؛ تومور کبد ۰/۷۴، عروق کبدی ۰/۶۳، توده‌ی پانکراس ۰/۵۲، سرطان روده‌ی بزرگ ۰/۵۶)؛ مقاله‌ی اصلی عدد واحدی گزارش نمی‌کند. رقم TotalSegmentator میانگینی روی مجموعه‌ی آزمونی است که از نظر فاز ترکیبی و تفکیک‌نشده است و تنها به‌عنوان نقطه‌ی مرجع سمت کنتراست‌دار آورده شده. در مطالعه‌ی یو و همکاران، مقایسه‌ی دو فاز فقط کیفی و با امتیاز لیکرت گزارش شده است (۸۹/۳ درصد در برابر ۸۵/۳ درصد خطوط دئودنوم با امتیاز سه یا بالاتر) و هیچ Dice بدون‌کنتراستی ندارد. در مطالعه‌ی پارک و همکاران، مجموعه‌ی آزمون دوم از *همان* مرکز و تنها با اسکنر متفاوت است و بیماران دارای ضایعه‌ی تغییردهنده‌ی کانتور از مطالعه کنار گذاشته شده‌اند. مطالعه‌ی آبل و همکاران [۲] در این جدول نیامده است، چون معیارش انحراف حجمی میان سه فاز است و نه Dice. ۱۴

۲-۲ مدل‌های تشخیص فاز کنتراست. **کد فاز:** ۰ بدون‌کنتراست، ۱ شریانی (۱الف زودرس، ۱ب دیررس)، ۲ وریدی باب، ۳ تأخیری، ۴ فازهای اختصاصی دیگر (شریان ریوی، اورگرافیک). ستون «فازهای داده‌ی آموزش» مجموعه‌ی کلاس‌هایی است که مدل تشخیص می‌دهد؛ چون این مجموعه میان مطالعات یکسان نیست، ارقام ستون‌های عددی تنها درون هر سطر معنا دارند و مقایسه‌ی مستقیم میان سطرها معتبر نیست. همه‌ی مقادیر F1، دقت، حساسیت و AUC در بازه‌ی صفر تا یک گزارش شده‌اند؛ ✓یعنی کد منبع در دسترس عمومی است. Segment-and-Classify هیچ ارزیابی درون‌سازمانی گزارش نمی‌کند (آموزش تنها روی WAW-TACE و هر دو مجموعه‌ی ارزیابی بیرونی‌اند)؛ بازه‌ها کمینه و بیشینه‌ی F1 به‌تفکیک فازند و کمینه در هر دو مورد متعلق به فاز تأخیری است. در Hierarchical CNN سه سطح تجمیع پیاپی گزارش شده و رقم ۱/۰۰ تنها در سطح کل بررسی و پس از رأی‌گیری میان حجم‌ها به دست آمده است. در Two-Step ResNet داده اصلاً کلاس بدون‌کنتراست ندارد؛ بنابراین دقت برون‌سازمانی بالاتر از درون‌سازمانی آن را باید با همین قید خواند و نه به‌عنوان شاهدی بر تعمیم‌پذیری بهتر. در Injection-Time Regression، AUC برون‌سازمانی پیش و پس از تنظیم‌دقیق با تنها ۱۰۰ نمونه‌ی برچسب‌خورده روی حوزه‌ی جدید (سی‌تی قفسه‌سینه) گزارش شده است. ۲۴

۲-۳ روش‌های منتخب هم‌ترازسازی تصویر: وظیفه‌ای که روش برای آن معرفی شده، داده و فاز کنتراستِ آن داده، معیاری که روش *بهینه* می‌کند، و مقداری که *گزارش* می‌کند. **کد فاز:** ۱ شریانی، ۲ وریدی باب؛ «تک‌فاز» یعنی داده‌ی توسعه تنها یک فاز دارد و مسئله‌ی بین‌فازی در آن مطرح نیست؛ «بدون فاز» یعنی وجهیت داده اصلاً کنتراست تزریقی ندارد (مانند MRI مغزی). همه‌ی مقادیر Dice در بازه‌ی صفر تا یک گزارش شده‌اند؛ HD95 و TRE برحسب میلی‌متر؛ ✓یعنی کد در دسترس عمومی است. روش‌های بنیادین پیش از ۲۰۰۵ (اطلاعات متقابل و نسخه‌ی بهنجارشده‌ی آن، دیمانز، تغییر شکل آزاد) در جدول نیامده‌اند، چون پیش از تثبیت محک‌های مشترک منتشر شده‌اند و عدد قابل‌مقایسه‌ای ندارند؛ جایگاهشان در متن تشریح شد. عدد SyN از ارزیابی مستقل کلاین و همکاران (۲۰۰۹) گرفته شده، چون مقاله‌ی اصلی مقدار دقیق گزارش نمی‌کند. مقاله‌ی MIND هیچ مقدار مطلقی گزارش نمی‌کند و تنها تفاوت معنادار آماری در TRE را ذکر می‌کند؛ ارقام آن روی داده‌ی شکمی چندفازی از [۳] گرفته شده است. در سطر پارک و همکاران، فاصله‌ی سطحی متناظر ۰٫۸۵ و ۰٫۷۸ میلی‌متر است و در همان ارزیابی SyN به ۰٫۸۷۳ و ۰٫۹۵۳ و دیمانز دیفئومورفیک به ۰٫۸۷۲ و ۰٫۹۳۵ رسیده‌اند. در سطر UniGradICON سه مقدار به‌ترتیب Dice مغزی، Dice شکمی و TRE ریوی‌اند و IO یعنی بهینه‌سازی نمونه‌ای در زمان استنتاج. در سطر Recursive Cascades پیکربندی 10-cascade VTN گزارش شده و زمان اجرای آن ۰٫۲۵ ثانیه روی GPU در برابر ۷۴۸ ثانیه برای SyN ANTs روی CPU است. در سطر DeepAtlas ارقام مربوط به Dice هم‌*ترازسازی* روی MRI زانو با ده تصویر برچسب‌خورده است. ۳۸

۴-۲ ادبیات سنتز NC ـ به ـ CE، دسته‌بندی‌شده بر اساس خانواده‌ی روش. ستون «فاز داده‌ی آموزش» نشان می‌دهد آیا داده‌ی آموزش هر دو فاز را به‌صورت جفت‌شده در بر داشته است یا نه. PSNR برحسب دسی‌بل، همه‌ی مقادیر SSIM، Dice، دقت، حساسیت و AUC در بازه‌ی صفر تا یک، و MAE و HD برحسب واحد HU و میلی‌متر؛ ✓یعنی کد تأییدشده در دسترس است. خط تیره در ستون‌های PSNR و SSIM یعنی مطالعه معیار وفاداری تصویری را به‌عنوان نتیجه‌ی اصلی گزارش نمی‌کند و ارزیابی‌اش کاملاً پایین‌دستی است. مقدار SSIM سطر pix2pix سه‌بعدی در واقع MS-SSIM است؛ CyTran به‌جای PSNR، MAE و RMSE گزارش می‌کند و مبنای بدون‌ترجمه در همان جدول SSIM برابر ۰/۶۵۶ دارد. در جدول MAN-GAN، خودِ تصویر بدون‌کنتراست خام PSNR برابر ۲۶/۰۲ و SSIM برابر ۰/۷۴ می‌گیرد؛ یعنی کل بهبود مدل حدود ۱/۷ دسی‌بل روی یک مبنای بسیار بالاست. در سطر یادگیری چندوظیفه‌ای متحد، ستون‌های PSNR و SSIM ارقام وضوح بالا را نشان می‌دهند و ارقام وضوح پایین در ستون سایر معیارها آمده است. برای TCGAN ارقام پیکربندی نهایی (تمایزگر وصله‌ای) و در ستون سایر معیارها به ترتیب برای Madic، BraTS2020 و IXI آمده است. ۵۱

۳-۱ هفت مقوله‌ی چارچوب ارزیابی ریسک سوگیری، به همراه تعریف عملیاتی و تهدید مرتبه‌بالاتری که هر مقوله به آن مربوط است. ۶۰

۴-۱ طبقه‌بندی کلی سوگیری ۲۲ مجموعه‌داده‌ی ارزیابی‌شده، بر پایه‌ی رابطه‌ی ۳-۱. . . . ۹۶

۴-۲ برآورد سهم بررسی‌های بدون‌کنتراست در داده‌ی برچسب‌خورده‌ی عمومی سی‌تی شکمی، محاسبه‌شده از جدول استخراج مرور [۴]. ۹۷

۴-۳ سهم هر گام پیش‌پردازش در دقت هم‌ترازی، روی ۵۷۷ مورد مقایسه از ۲۶ بررسی. همه‌ی ستون‌ها مقدار معمول‌اند و ستون سوم بازه‌ای است که نیمی از موارد در آن قرار دارند. برای دایس مقدار بیشتر و برای دو فاصله مقدار کمتر بهتر است. †خروجی «فقط برش مشترک» تنها برای ۲۳ بررسی (۴۹۸ مورد مقایسه) موجود است. ۱۰۰

۴-۴ مقایسه‌ی چهار تابع هدف برای پالایش صلب روی ۵۷۷ مورد مقایسه. ستون «محاسبه روی» نشان می‌دهد معیار روی کل تصویر یا فقط روی نقاب اندام‌ها محاسبه می‌شود. دایس و خطای مرکز اندام مقدار معمول‌اند؛ ستون آخر درصد موارد شکست (دایس کمتر از ۰/۵) است. ۱۰۱

۴-۵ مقایسه با روش‌های موجود روی مجموعه‌ی مشترک (۲۶ بررسی، ۵۷۴ مورد مقایسه) با خطکش ارزیابی یکسان. همه‌ی ستون‌ها مقدار معمول‌اند؛ برای دایس مقدار بیشتر و برای بقیه‌ی ستون‌ها مقدار کمتر بهتر است. تاخوردگی برای روش صلب بنا به تعریف صفر است. زمان به‌ازای هر جفت فاز است؛ زمان مسیر صلب از اجرای همان تابع هدف در جدول ۴-۴ و زمان ردیف B ـ اسپلاین مجموع زمان مسیر صلب و این گذر است. زمان DEEDS (قرمز) شامل بازسازی میدان جابه‌جایی برای سنجش تاخوردگی است و با اندازه‌گیری رویه‌ی «سنجش هزینه‌ی محاسباتی» بخش ۳-۵ جایگزین می‌شود. خروجی مسیر صلب از اجرایی گرفته شده که گام هم‌ترازی درشت مرکز جرم هنوز در آن فعال بود؛ حذف این گام تفاوت معناداری در دقت ایجاد نمی‌کند (جدول ۴-۳). . . ۱۰۳

۴-۶ دایس به تفکیک گروه اندام (مقدار معمول) روی مجموعه‌ی مشترک: اندام‌های نرم ۳۱۷، رگ‌های بزرگ ۱۱۰ و مهره‌ها ۱۴۷ مورد مقایسه. روش‌های موجود روی خروجی پیش‌پردازش این پایان‌نامه اجرا شده‌اند. نشانه‌ی † یعنی آن روش در مقایسه‌ی مورد به مورد به‌طور معنادار از مسیر صلب پیشنهادی *بهتر* است و ‡ یعنی *بدتر*؛ آستانه‌ی معناداری پس از تصحیح برای سه گروه ۰/۰۱۷ است. نبودن نشانه یعنی تفاوت معنادار نیست. . ۱۰۴

۴-۷ دایس به تفکیک اندام (مقدار معمول) روی مجموعه‌ی مشترک؛ روش‌های موجود روی خروجی پیش‌پردازش این پایان‌نامه اجرا شده‌اند. سه ستون آخر مسیر صلب را مورد به مورد با uniGradICON مقایسه می‌کنند: شمار مواردی که مسیر صلب بهتر و بدتر است و مقدار p. چون این مقایسه برای یازده اندام تکرار شده، آستانه‌ی معناداری پس از تصحیح ۰/۰۰۴۵ است و مقادیری که از آن عبور می‌کنند با $*$ مشخص شده‌اند. . . ۱۰۵

۴-۸ اثر پیش‌پردازش این پایان‌نامه بر چهار روش هم‌ترازسازی موجود، روی حدود ۵۸۰ مورد مقایسه از ۲۶ بررسی. «شکست» یعنی دایس کمتر از ۰/۵ و «خطای بزرگ» یعنی خطای مرکز اندام بیش از ۱۰ میلی‌متر. ستون «تغییر مورد به مورد» برای دایس شمار مواردی را می‌دهد که با پیش‌پردازش بهتر و بدتر شده‌اند، و برای دو شاخص دیگر شمار شکست‌ها یا خطاهای بزرگی که رفع شده و شمار آن‌هایی که تازه پدید آمده‌اند. مقدار p از آزمون علامت روی همین دو شمار به دست آمده است. ۱۰۶

۴-۹ اثر پیش‌پردازش به تفکیک دشواری مورد روی حجم خام، برای موارد مقایسه‌ی هر چهار روش جدول ۴-۸ به‌صورت یک‌جا. ستون آخر شمار مواردی است که با پیش‌پردازش نیز دایس کمتر از ۰/۵ دارند. ۱۰۷

۴-۱۰ دایس روی حجم خام و با پیش‌پردازش (مقدار معمول) به تفکیک گروه اندام و اندام. نشانه‌ی * یعنی پیش‌پردازش آن روش را در آن گروه یا اندام به‌طور معنادار *بهتر* کرده و † یعنی به‌طور معنادار *بدتر*؛ آستانه‌ی معناداری پس از تصحیح برای سه گروه ۰/۰۱۷ و برای یازده اندام ۰/۰۰۴۵ است. نبودن نشانه یعنی تفاوت معنادار نیست. ۱۰۸

۴-۱۱ گذر اختیاری B ـ اسپلاین در برابر مسیر صلب پیشنهادی روی مجموعه‌ی مشترک. دایس به‌صورت مقدار معمول است. دو ستون «بهتر» و «بدتر» شمار مواردی را می‌دهند که گذر غیرصلب در آن‌ها دایس بالاتر یا پایین‌تری از خروجی صلب دارد (موارد برابر کنار گذاشته شده‌اند) و ستون آخر مقدار p است. آستانه‌ی معناداری پس از تصحیح برای سه گروه ۰/۰۱۷ و برای یازده اندام ۰/۰۰۴۵ است و مقادیری که از آن عبور می‌کنند با * مشخص شده‌اند. ۱۱۰

۴-۱۲ هزینه‌ی روش‌ها به‌ازای هر جفت فاز روی همان ۲۶ بررسی. ستون دوم مقدار معمول زمان بر حسب ثانیه است و ستون سوم بازه‌ای که نیمی از اجراها در آن قرار دارند؛ ستون «نسبت» زمان معمول هر روش را بر زمان معمول مسیر صلب تقسیم می‌کند و ستون آخر نشان می‌دهد روش به آموزش پیشین روی داده نیاز دارد یا نه. روش‌های موجود روی خروجی پیش‌پردازش این پایان‌نامه اجرا شده‌اند. زمان ردیف B ـ اسپلاین مجموع زمان مسیر صلب و این گذر برای همان جفت فاز است. خانه‌های قرمز ردیف DEEDS زمان ثبت‌شده‌ی قبلی‌اند که بازسازی میدان جابه‌جایی برای سنجش تاخوردگی را نیز در بر می‌گیرد، و خانه‌های [عدد؟] مقادیری‌اند که با رویه‌ی اندازه‌گیری کل درخت فرایندها تکمیل می‌شوند. ۱۱۲

۴-۱۳ مقایسه‌ی طبقه‌بند اندامی با روش‌های منتشرشده روی ۶۳ حجم آزمون. فاصله‌ی اطمینان ۹۵ درصد با قلم کوچک‌تر زیر هر مقدار آمده است. کد فاز همان کد جدول ۲-۲ است: ۰ بدون‌کنتراست، ۱ شریانی و ۲ وریدی. خروجی چهارکلاسه‌ی مدل‌هایی که روی داده‌ی دیگر آموزش دیده‌اند، به سه فاز موجود در مجموعه‌ی آزمون محدود شده است. ۱۱۷

۴-۱۴ ارقام گزارش‌شده در مقاله‌ها در برابر ارقام همان مدل‌ها روی ۶۳ حجم آزمون این پایان‌نامه. ارقام مقاله‌ها از جدول ۲-۲ آمده‌اند و کد فاز همان کد آن جدول است. مجموعه‌ی آزمون این پایان‌نامه فاز تأخیری ندارد و مدل‌هایی که بدون بازآموزی اجرا شده‌اند با خروجی چهارکلاسه‌ی خود سنجیده شده‌اند، یعنی پیش‌بینی فاز تأخیری خطا شمرده شده است؛ پس دو ستون عددی تنها درون هر سطر و با قید شرایط متفاوت مقایسه‌پذیرند. ۱۱۸

۴-۱۵ کاوش خطی بازنمایی‌های عمومی تصویر برای تشخیص فاز. دقت اعتبارسنجی متقاطع روی مجموعه‌ی آموزش و اعتبارسنجی به‌صورت میانگین و انحراف معیار پنج تا آمده است، و ارقام آزمون روی همان ۶۳ حجم جدول ۴-۱۳ و با همان کد فاز محاسبه شده‌اند. برای سر لایه‌ی خطی، پیش‌بینی‌های حجم‌به‌حجم ذخیره نشده و فاصله‌ی اطمینان در دسترس نیست. ۱۱۹

۴-۱۶ مدل‌های گزارش‌شده در این بخش. ستون «پایین‌دستی» نشان می‌دهد که آیا مدل در ارزیابی بخش‌بندی نیز اجرا شده است. ۱۲۳

۴-۱۷ معیارهای تصویری ارزیابی سنتز. معیارهای شدت روی دامنه‌ی مشترک $[-۲۰۰, ۴۰۰]$ واحد هانسفیلد نگاشته‌شده به $[۰, ۱]$ محاسبه می‌شوند. ۱۲۵

۴-۱۸ کیفیت تصویری در فاز وریدی. بهترین مقدار هر ستون پررنگ است (برای RAPS، نزدیک‌ترین به یک). oMAE در دامنه‌ی بهنجارشده‌ی $[۰, ۱]$ است. ۱۲۶

۴-۱۹ اثر سنتز بر بخش‌بندی پایین‌دستی: میانگین تفاوت زوجی دایس نسبت به بازوی NCCT روی ۲۰ مورد. سطر نخست دایس مطلق خودِ بازوی NCCT است. اثر خالص برابر است با تفاوت گروه عروقی منهای تفاوت گروه اسکلتی. ستون آخر شمار مواردی است که دایس ورید باب در آن‌ها از بازوی NCCT بالاتر است. ۱۲۷

۴-۲۰ مقایسه‌ی زوجی PLC-Net دوبعدی با سایر مدل‌ها روی داده و تقسیم یکسان؛ مقادیر مثبت یعنی دایس PLC-Net بالاتر است. مقادیر p با روش هولم روی ۳۰ آزمون تصحیح شده‌اند (پنج مقایسه در شش نقطه‌ی پایانی: گروه عروقی، ورید باب، ترکیب وابسته به کنتراست، و گروه‌های پارانشیمی، اسکلتی و عضلانی). ۱۳۱

۴-۲۱ شیب کالیبراسیون بهنجارشده نسبت به سقف درون‌فازی (میانه روی هشت اندام بردار سطح). مقدار بیش از یک یعنی پاسخ مدل از دامنه‌ی طبیعی فاز درخواست‌شده فراتر رفته است. جاروب پیکربندی E روی وزن‌های دوره‌ی ۱۵ همان اجرای PLC-Net دوبعدی انجام شده است. ۱۳۴

۴-۲۲ هم‌بستگی اسپیرمن معیارهای تصویری با اثر خالص پایین‌دستی. ستون دوم پس از کنار گذاشتن سه بازوی ناموفق است. ۱۳۶

۴-۲۳ پیکربندی‌های A تا F در فاز وریدی. اثر خالص با فاصله‌ی اطمینان ۹۵ درصد گزارش شده است. ۱۳۷

آ ـ ۱ میانگین تفاوت زوجی دایس نسبت به بازوی NCCT با دایس ساده و با دایس فرسوده‌ی ۶ میلی‌متری. مقادیر p از آزمون t زوجی و توصیفی‌اند؛ n شمار موارد با ماسک فرسوده‌ی ناتهی است. ۱۵۹

فهرست تصاویر

۲-۱ سه سرگروه روش‌شناختی هم‌ترازسازی تصویر. تفاوت بنیادی سه خانواده در این است که معیار تراز از چه چیزی ساخته می‌شود: (الف) از *مقدار* شدت روشنایی روی کل میدان دید؛ (ب) از *الگوی محلی* شدت روشنایی، که در برابر نگاشت یکنوای شدت پایدار است؛ (پ) از یک نگاشت *آموخته‌شده* که میدان جابه‌جایی را در یک گذر پیش‌رو پیش‌بینی می‌کند. نکته‌ی مشترک هر سه آن است که معیار تراز، در هر سه حالت، روی *کل* میدان دید تعریف می‌شود. ۳۴

۲-۲ سه راهبرد نظارتی در ادبیات سنتز NC ـ به ـ CE. محور تمایز میان (الف) و (ب) وجود یا نبود جفت هم‌بیمارِ هم‌تراز است: (الف) نظارت پیکسل‌به‌پیکسل دارد و به همین دلیل به هم‌ترازی هندسی دقیق وابسته است، و (ب) این نیاز را با قید بازگشت‌پذیری چرخه حذف می‌کند اما تضمینی برای حفظ آناتومی نمی‌دهد. (پ) نظارت را از آموزش تخاصمی به پیش‌بینی نویز منتقل می‌کند و آموزش پایدارتری دارد، اما همچنان به جفت هم‌تراز نیاز دارد. هیچ‌یک از این سه الگو سازوکاری برای *شرطی‌سازی بر سطح تقویت* ندارد. ۴۹

۲-۳ ستون فقرات ترکیبی پیچشی—ترانسفورمری. این الگو یک *راهبرد نظارتی* مستقل نیست بلکه ساختار درونی مولد است و می‌تواند جایگزین مولد در هر یک از سه راهبرد شکل ۲-۲ شود. مسیر پیچشی بافت محلی را و مسیر ترانسفورمری وابستگی‌های دوربرد را مدل می‌کند، و مسیر پرش جزئیات مکانی از دست‌رفته در رمزگذاری را بازمی‌گرداند. . . . ۵۰

۳-۱ معماری پایپ‌لاین پیشنهادی ۷۴

۲-۳ ساختار PLC-Net. رمزگذار عامدانه از شرط بی‌خبر است و جفت‌های هر دو فاز را می‌بیند؛ تنها رمزگشا از فاز و سطح هدف باخبر می‌شود، از طریق FiLM در گلوگاه و هر چهار مرحله‌ی رمزگشایی. در نسخه‌ی ۲/۵ بعدی (پیکربندی F)، ۱۱ برش مجاور به‌صورت کانال ورودی داده می‌شود. ۸۱

۱-۴ شبکه‌ی بازاستفاده‌ی موارد میان مجموعه‌داده‌های عمومی سی‌تی شکمی. هر گره یک مجموعه‌داده است و اندازه‌ی آن با شمار سری‌های سی‌تی متناسب است؛ آبی یعنی تماماً اصیل، نارنجی یعنی ترکیبی از موارد اصیل و بازاستفاده، و قرمز یعنی تماماً بازاستفاده. هر پیکان از مجموعه‌داده‌ی منبع به مجموعه‌ی مشتقی می‌رود که موارد آن را به کار گرفته است. برگرفته از [۴]. ۹۲

۲-۴ توزیع جغرافیایی کشورهای مشارکت‌کننده در مجموعه‌داده‌های عمومی سی‌تی شکمی. رنگ هر کشور شمار مجموعه‌داده‌هایی را نشان می‌دهد که در آن‌ها سهم دارد و کشورهای خاکستری هیچ سهمی ندارند. مرزهای نقشه از پایگاه GSHHG گرفته شده است. برگرفته از [۴]. ۹۳

۳-۴ توزیع سطح ریسک در هفت مقوله‌ی سوگیری برای ۲۲ مجموعه‌داده‌ی دارای صد نمونه‌ی عمومی یا بیشتر. قرمز ریسک بالا، زرد ریسک متوسط، سبز ریسک پایین و خاکستری «در دسترس نیست» است و عدد روی هر نوار، شمار مجموعه‌داده‌هاست. برگرفته از [۴]. ۹۵

۴-۴ تغییر دایس هر اندام نسبت به بازوی NCCT، به‌صورت زوجی روی مواردی که اندام در هر دو بازو وجود دارد. عدد داخل پرانتز دایس میانگین NCCT است؛ لوزی‌ها دو نسخه‌ی PLC-Netاند، نشانگر توخالی یعنی $p \geqslant ۰/۰۵$، و نوار خاکستری اندام‌های اسکلتی و عضلانی را مشخص می‌کند. ۱۲۸

۵-۴ دایس ورید باب و طحالی برای هر بیمار، روی تصویر بدون‌کنتراست (چپ هر نمودار) و روی خروجی مدل (راست)؛ خط سیاه میانگین است. PLC-Net دوبعدی در ۲۰ مورد، L1ـ اندام در ۱۹ مورد و DDPM تنها در ۳ مورد از ۲۰ مورد دایس بالاتری از NCCT دارند. ۱۲۹

۴-۶ تغییر دایس گروه اسکلتی (افقی) در برابر تغییر دایس گروه عروقی (عمودی) نسبت به NCCT، با فاصله‌ی اطمینان ۹۵ درصد، برای بازوهای جدول ۴-۱۹. روی خط‌چین $y = x$ سود عروقی با افت اسکلتی برابر است و فاصله‌ی عمودی هر نقطه از آن، اثر خالص است. هم‌بستگی اسپیرمن روی هر ۱۶ بازوی وریدی محاسبه شده است. . . . ۱۳۰

۴-۷ دایس عروقی هر مدل شرطی، یک‌بار با شرط شریانی و یک‌بار با شرط وریدی، هر دو در برابر همان مرجع وریدی. خط‌های خاکستری تفاوت معناداری ندارند: مدل بدون شرط (پیکربندی A، نوفه‌ی زنجیره‌ی ارزیابی) و پیکربندی F در دوره‌ی ۵۳. . . . . ۱۳۳

۴-۸ featHU (چپ) و FID (راست) در برابر اثر خالص پایین‌دستی برای ۱۶ بازوی وریدی. محورهای افقی مقادیر خام‌اند (کمتر بهتر)، اما ρ روی معیار جهت‌دهی‌شده (بیشتر بهتر) محاسبه شده است؛ از این رو ρ مثبت در نمودار چپ به‌صورت روند نزولی دیده می‌شود. ۱۳۶

۴-۹ اثر خالص پایین‌دستی (میانگین و فاصله‌ی اطمینان ۹۵ درصد) برای پیکربندی‌های A تا F. پیکربندی‌های E و F هر یک در دو دوره‌ی آموزشی از یک اجرا گزارش شده‌اند. . ۱۳۸

۴-۱۰ کیسه‌ی صفرا. چپ: خطای علامت‌دار حجم برای هر مورد (میله‌ی سیاه: میانه؛ مقدار منفی یعنی حجم کمتر از مرجع؛ پیکان: موردی خارج از مقیاس بالای $+150\%$). راست: دایس میانگین و تعداد مواردی که اندام یافت شده است. ۱۳۹

۴-۱۱ مقایسه‌ی بصری در یک برش محوری از یک مورد آزمون. ردیف تصویر با پنجره‌ی $W = 400$، $L = 40$؛ ردیف تفاوت پس از محدودسازی هر دو تصویر به بازه‌ی $[-۲۰۰, ۴۰۰]$ واحد هانسفیلد، با مقیاس ± ۱۰۰ واحد: در ستون NCCT تفاوت تصویر کنتراست‌دار واقعی منهای تصویر بدون‌کنتراست، و در ستون هر مدل خروجی مدل منهای تصویر کنتراست‌دار واقعی؛ قرمز یعنی روشن‌تر و آبی یعنی تیره‌تر. ۱۴۰

فصل ۱

مقدمه

این فصل مسئله‌ی مرکزی پایان‌نامه را معرفی می‌کند و چارچوبی را می‌سازد که فصل‌های بعدی بر آن استوارند. نخست توضیح داده می‌شود چرا افت دقت بخش‌بندی خودکار در فاز بدون‌کنتراست سی‌تی شکمی مسئله‌ای بالینی و نه صرفاً فنی است؛ سپس این مسئله به چهار زیرمسئله‌ی مشخص تجزیه می‌شود که ستون‌بندی مشترک فصل‌های کارهای پیشین، روش پیشنهادی و آزمایش‌ها را تعیین می‌کنند. در ادامه، چالش‌های فنی و داده‌ای که حل این زیرمسئله‌ها را دشوار می‌کنند، اهداف پژوهش، و ساختار کلی پایان‌نامه ارائه می‌شود.

راهنمای نشانه‌گذاری این نسخه. این نسخه هنوز پیش‌نویس است و سه نشانه‌ی رنگی در آن به کار رفته که همگی پیش از تحویل نهایی باید حذف شوند:

[عدد؟] ـ مقداری که باید از متن مقاله‌ی اصلی استخراج و جایگزین شود.

متن قرمز ـ عدد یا ادعایی که هنوز تأیید نشده و نیازمند بازبینی نویسنده است.

متن نارنجی ـ بخشی که نتیجه‌ی آن هنوز به دست نیامده یا آزمایشش اجرا نشده است.

برای یافتن همه‌ی آن‌ها، سه فرمان «نیازمندمقدار»، «نامطمئن» و «بایدتکمیل» را در پوشه‌ی chapters جست‌وجو کنید.

۱-۱ اهمیت مسئله

سی‌تی شکمی[1] یکی از پرکاربردترین وجهیت‌های تصویربرداری در تشخیص، مرحله‌بندی و پیگیری بیماری‌های کبد، کلیه، پانکراس و سایر اندام‌های شکمی است. در عمل بالینی، این تصویربرداری معمولاً

[1] Abdominal CT

در چند فاز کنتراست[۲] انجام می‌شود: نخست یک اسکن بدون‌کنتراست[۳]، پیش از تزریق ماده‌ی حاجب[۴]، و سپس یک یا چند اسکن کنتراست‌دار[۵] در فازهای شریانی، وریدی یا تأخیری. تشخیص بسیاری از ضایعات کانونی کبد، به‌ویژه کارسینوم سلول کبدی[۶]، مستقیماً به الگوی افزایش کنتراست و شست‌وشوی[۷] آن میان فازهای مختلف وابسته است [۵، ۶]؛ الگویی که تنها با ترکیب دقیق اطلاعات چند فاز قابل‌مشاهده است.

با این حال، فاز بدون‌کنتراست کاربردی صرفاً تکمیلی ندارد. در بسیاری از پروتکل‌های بالینی، از جمله تروما، غربالگری فرصت‌طلبانه[۸]، و بیمارانی که به دلیل نارسایی کلیوی یا سابقه‌ی حساسیت، امکان تزریق ماده‌ی حاجب را ندارند، فاز بدون‌کنتراست تنها تصویر در دسترس است. بخش‌بندی خودکار اندام‌های شکمی روی همین فاز، زیرساخت اندازه‌گیری حجمی، برنامه‌ریزی درمان و ردیابی روند بیماری در چنین بیمارانی است.

اما همان‌طور که در فصل ۲ به‌تفصیل مرور می‌شود، دقت مدل‌های بخش‌بندی روی فاز بدون‌کنتراست، به دلیل کاهش نسبت کنتراست‌به‌نویز[۹] میان بافت‌های نرم مجاور، به‌طور نظام‌مند و وابسته به اندام، پایین‌تر از فاز کنتراست‌دار است [۷، ۲، ۸]. نتیجه آن است که دقیقاً همان گروه از بیماران که کمترین دسترسی را به تصویربرداری کنتراست‌دار دارند، از ضعیف‌ترین خروجی بخش‌بندی خودکار بهره می‌برند. این افت، به‌جای آن‌که محدودیتی ذاتی و اجتناب‌ناپذیر تلقی شود، نقطه‌ی شروع این پایان‌نامه است.

۱-۲ تعریف مسئله

هدف کلی این پایان‌نامه، کاهش شکاف دقت بخش‌بندی چندعضوی میان فاز بدون‌کنتراست و فاز کنتراست‌دار در سی‌تی شکمی است، از طریق دو راهبرد مکمل: هم‌ترازسازی هندسی فازهای موجود از طریق هم‌ترازسازی تصویر، و بازسازی مستقیم اطلاعات فاز کنتراست‌دار از روی فاز بدون‌کنتراست از طریق سنتز. هر دو راهبرد بر زیرساختی مشترک تکیه دارند که پیش از ورود به آن‌ها باید مستحکم شود: شناخت دقیق محدودیت‌های مجموعه‌داده‌های موجود، و شناسایی صحیح فاز کنتراست هر بررسی.

بر این اساس، مسئله‌ی کلی به چهار زیرمسئله تجزیه می‌شود که در ادامه‌ی این بخش معرفی می‌شوند. همین چهار زیرمسئله، با همین ترتیب، ستون‌بندی فصل‌های ۲ تا ۴ را نیز تعیین می‌کنند، به‌گونه‌ای که

[۲] Contrast phase
[۳] Non-contrast (NC) phase
[۴] Contrast media
[۵] Contrast-enhanced (CE) phase
[۶] Hepatocellular carcinoma (HCC)
[۷] Washout
[۸] Opportunistic screening
[۹] Contrast-to-noise ratio (CNR)

خواننده بتواند مسیر «مسئله، پیشینه، روش، آزمایش» را برای هر زیرمسئله به‌صورت مستقل دنبال کند.

۱-۲-۱ مرور انتقادی مجموعه‌داده‌های سی‌تی شکمی

پیش از طراحی هر راه‌حل، این پروژه با یک مرور نظام‌مند بر ۴۵ مجموعه‌داده‌ی عمومی سی‌تی شکمی آغاز شد که وضعیت اکوسیستم داده‌ی موجود را از منظر بازاستفاده و سوگیری جمعیت‌شناختی و جغرافیایی مستند می‌کند [۴]؛ داده‌های جدول استخراج همین مرور نیز نشان می‌دهد که *داده‌ی برچسب‌خورده‌ی فاز بدون‌کنتراست کمیاب است*. یافته‌های این مرور در بخش ۲-۳ به‌تفصیل ارائه می‌شود و مستقیماً انگیزه‌ی دو زیرمسئله‌ی پایانی را شکل می‌دهد: وقتی نمی‌توان مدل را روی داده‌ی برچسب‌خورده‌ی بدون‌کنتراست آموزش داد، یا باید فازهای موجود یک بیمار را پس‌پردازشی هم‌تراز کرد، یا فاز غایب را از روی فاز موجود بازسازی کرد.

۱-۲-۲ تشخیص فاز کنتراست

بهره‌برداری از هر داده‌ی چندفازی، اعم از عمومی یا خام گردآوری‌شده در این پروژه، به شناسایی صحیح فاز هر سری تصویر وابسته است. از آن‌جا که برچسب‌های سرآیند DICOM در عمل ناقص یا ناسازگارند (بخش ۲-۴)، در این پروژه، به‌جای طراحی مدلی تازه، از میان مدل‌های منتشرشده‌ی تشخیص فاز مدلی برگزیده می‌شود که با نیازهای مراحل بعد سازگار باشد، و عملکرد نامزدها، به‌جای تکیه بر ارقام گزارش‌شده در مقاله‌ها، روی داده‌ی همین پایان‌نامه سنجیده می‌شود. در کنار آن، میزان سازگاری مدل‌های بنیادین تصویری با این وظیفه نیز آزموده می‌شود. مدل برگزیده، که جزئیات انتخاب آن در فصل ۳ و نتایج آن در فصل ۴ ارائه می‌شود، زیرساخت عملیاتی دو زیرمسئله‌ی بعدی است.

۱-۲-۳ هم‌ترازسازی تصویر بین‌فازی

این پروژه یک پایپ‌لاین هم‌ترازسازی تصویر چندگذره[۱۰] برای هم‌ترازسازی هندسی فاز بدون‌کنتراست با فاز کنتراست‌دار طراحی و ارزیابی می‌کند. معیارهای کلاسیک اطلاعات متقابل در سطح کل تصویر تعریف می‌شوند و از همین رو در برابر تغییر ناهمگن کنتراست شکننده‌اند (بخش ۲-۵). در مقابل، پایپ‌لاین پیشنهادی نخست با یک برش آناتومی‌محور، میدان دید مشترک دو فاز را می‌سازد و سپس با دو گذر صلب، یعنی یک هم‌ترازی اولیه بر پایه‌ی مرکز اندام‌ها و یک پالایش بر پایه‌ی هم‌پوشانی آن‌ها، دو فاز را هم‌تراز

[۱۰] Multi-pass

می‌کند؛ معیار تراز در این گذرها تنها روی اندام‌های پایدار در برابر کنتراست محاسبه می‌شود. یک گذر پالایش غیرصلب اختیاری نیز برای سنجش ناهم‌ترازی باقی‌مانده تعریف شده است. همین پیش‌پردازش پیش از روش‌های هم‌ترازسازی موجود نیز به کار گرفته و اثر آن بر دقت آن روش‌ها سنجیده می‌شود. این پایپ‌لاین روی مجموعه‌داده‌ی عمومی VinDr-Multiphase [۹] ارزیابی شده است.

۱-۲-۴ سنتز فاز کنتراست‌دار از فاز بدون‌کنتراست

جفت‌های هم‌ترازشده‌ی حاصل از این هم‌ترازسازی تصویر سپس برای آموزش و ارزیابی مدل‌های سنتز فاز کنتراست‌دار از روی فاز بدون‌کنتراست به کار می‌روند (بخش ۲-۶). در نهایت، در این پروژه بررسی می‌شود که آیا ترکیب هم‌ترازسازی و سنتز بهبودیافته، شکاف دقت بخش‌بندی چندعضوی میان دو فاز را که در فصل ۲ مستند می‌شود، کاهش می‌دهد.

۱-۳ چالش‌ها

پیگیری این چهار زیرمسئله در طول پروژه با چند چالش فنی مشترک همراه بود که هر یک، انتخاب‌های روشی فصل ۳ را شکل داده‌اند.

نخستین چالش، ناسازگاری فراداده است. برچسب‌های فاز کنتراست در سرآیند DICOM داده‌ی خام این پروژه، مشابه بسیاری از مجموعه‌داده‌های عمومی، ناقص یا ناسازگارند و امکان تکیه‌ی مستقیم بر آن‌ها برای آموزش یا ارزیابی وجود ندارد. همین محدودیت است که تشخیص فاز از روی محتوای تصویر را از یک گام جانبی به یک پیش‌نیاز تبدیل می‌کند.

چالش دوم به ماهیت خود تزریق ماده‌ی حاجب بازمی‌گردد: تزریق، رابطه‌ی آماری میان شدت روشنایی دو فاز را به‌شکل ناهمگن در فضا تغییر می‌دهد. عروق و پارانشیم پرخون روشن‌تر می‌شوند، در حالی که استخوان و چربی تقریباً بدون تغییر می‌مانند. این ناهمگنی، فرض بنیادین معیارهای کلاسیک هم‌ترازسازی تصویر مبتنی‌بر اطلاعات متقابل را نقض می‌کند و طراحی معیار تراز مقاوم را ضروری می‌سازد.

چالش سوم، کمیابی داده است. جفت طبیعی و هم‌زمان دو فاز برای یک بیمار به‌ندرت در دسترس است، و همین کمبود، هم ارزیابی دقیق هم‌ترازسازی تصویر و هم آموزش نظارت‌شده‌ی مدل‌های سنتز را دشوار می‌کند. سرانجام، ادبیات پژوهشی مرتبط، به‌ویژه در حوزه‌ی سنتز NC–به–CE، از ناهمگنی معیار ارزیابی و مجموعه‌داده رنج می‌برد؛ ناهمگنی‌ای که مقایسه‌ی مستقیم نتایج و انتخاب یک مبنای معتبر را دشوار می‌کند (بخش ۲-۶).

۱-۴ اهداف پژوهش

هدف کلی این پژوهش آن است که نشان دهد شکاف دقت بخش‌بندی چندعضوی میان فاز بدون‌کنتراست و کنتراست‌دار، با مداخله در سطح داده و پیش‌پردازش، و بدون بازطراحی خود مدل بخش‌بندی، تا چه اندازه قابل کاهش است. برای رسیدن به این هدف کلی، چهار زیرمسئله‌ی بخش ۱-۲ به چهار هدف عملیاتی ترجمه می‌شوند و یک هدف پنجم، اثر تجمیعی آن‌ها را می‌سنجد:

- مستندسازی نظام‌مند وضعیت سوگیری و کفایت مجموعه‌داده‌های عمومی سی‌تی شکمی، با تمرکز ویژه بر کمیابی داده‌ی جفت‌شده‌ی چندفازی، تا دامنه‌ی واقعی داده‌ی در دسترس برای دو هدف بعدی روشن شود.
- انتخاب و ارزیابی مدلی برای تشخیص قابل‌اعتماد فاز کنتراست از روی محتوای تصویر، مستقل از برچسب‌های ناقص سرآیند DICOM، از میان روش‌های منتشرشده و متناسب با نیازهای مراحل بعد، به‌عنوان زیرساخت عملیاتی بهره‌برداری از داده‌ی چندفازی.
- طراحی یک پایپ‌لاین هم‌ترازسازی تصویر چندگذره که دامنه‌ی محاسبه‌ی معیار تراز را به نواحی پایدار در برابر تغییر فاز کنتراست محدود می‌کند، و ارزیابی مقایسه‌ای آن در برابر رویکردهای کلاسیک مبتنی‌بر اطلاعات متقابل.
- بهره‌گیری از جفت‌های هم‌ترازشده‌ی حاصل برای آموزش و ارزیابی مدل‌های سنتز فاز کنتراست‌دار از روی فاز بدون‌کنتراست.
- سنجش این‌که آیا ترکیب این مداخلات، شکاف دقت بخش‌بندی چندعضوی میان فاز بدون‌کنتراست و کنتراست‌دار را کاهش می‌دهد.

۱-۵ ساختار پایان‌نامه

باقی این پایان‌نامه به شرح زیر سازمان‌دهی شده است. فصل ۲ پس از یک پیش‌زمینه‌ی کوتاه بالینی درباره‌ی سی‌تی چندفازی، پیشینه‌ی پژوهشی پنج حوزه‌ی مرتبط را مرور می‌کند: بخش‌بندی چندعضوی و شکاف کیفیت فاز بدون‌کنتراست، که مسئله‌ی چتر این پایان‌نامه را تعریف می‌کند، و پس از آن چهار حوزه‌ی متناظر با چهار زیرمسئله‌ی بخش ۱-۲؛ فصل با جمع‌بندی جای خالی مشترک میان آن‌ها به پایان می‌رسد. فصل ۳ روش پیشنهادی این پایان‌نامه، شامل جزئیات مدل تشخیص فاز، پایپ‌لاین هم‌ترازسازی تصویر

چندگذره، و مدل‌های سنتز NC_به_CE را ارائه می‌دهد. فصل ۴ نتایج تجربی هر یک از این سه مؤلفه، و نیز ارزیابی نهایی اثر آن‌ها بر شکاف دقت بخش‌بندی چندعضوی را گزارش می‌کند. سرانجام، فصل ۵ یافته‌های پایان‌نامه را جمع‌بندی کرده و کاستی‌ها و مسیرهای پژوهشی آتی را مطرح می‌کند.

۱-۶ جمع‌بندی

فاز بدون‌کنتراست سی‌تی شکمی، با وجود کاربرد بالینی گسترده و نقش آن به‌عنوان تنها تصویر در دسترس برای گروهی از بیماران، همچنان از افت نظام‌مند دقت بخش‌بندی چندعضوی رنج می‌برد. استدلال این فصل آن بود که ریشه‌ی این افت را نباید تنها در معماری مدل‌ها جست‌وجو کرد: کاهش کنتراست بافتی، ناسازگاری فراداده‌ی فاز، و کمیابی داده‌ی جفت‌شده‌ی چندفازی، سه عامل مستقلی‌اند که همگی پیش از مرحله‌ی مدل‌سازی عمل می‌کنند. بر همین مبنا، مسئله به چهار زیرمسئله تجزیه شد که پاسخ به آن‌ها، به‌ترتیب، در فصل‌های بعدی دنبال می‌شود.

فصل ۲

کارهای پیشین

این فصل، پیشینه‌ی پژوهشی مسئله‌ی فصل ۱ را مرور می‌کند. ساختار فصل مستقیماً از تجزیه‌ی مسئله در بخش ۱-۲ پیروی می‌کند: پس از یک پیش‌زمینه‌ی کوتاه بالینی درباره‌ی سی‌تی چندفازی (بخش ۲-۱)، که اصطلاح‌های فاز کنتراست را برای کل پایان‌نامه تثبیت می‌کند، پنج حوزه‌ی پژوهشی به‌ترتیب مرور می‌شوند.

نخستین حوزه، بخش‌بندی چندعضوی[۱] تصاویر سی‌تی شکمی و شکاف کیفیتی است که در فاز بدون‌کنتراست مشاهده می‌شود (بخش ۲-۲)؛ این حوزه به هیچ‌یک از چهار زیرمسئله به‌تنهایی متعلق نیست، بلکه مسئله‌ی چتری را تعریف می‌کند که چهار زیرمسئله در خدمت آن‌اند. چهار حوزه‌ی بعدی، دقیقاً متناظر با همان چهار زیرمسئله و با همان ترتیب‌اند: چشم‌انداز مجموعه‌داده‌های عمومی سی‌تی شکمی و ادبیات سوگیری[۲] داده (بخش ۲-۳)، تشخیص فاز کنتراست از روی محتوای خام تصویر (بخش ۲-۴)، هم‌ترازسازی تصویر[۳] میان فازهای مختلف (بخش ۲-۵)، و سنتز فاز کنتراست‌دار از روی تصویر بدون‌کنتراست (بخش ۲-۶).

هر بخش الگوی یکسانی دارد: ابتدا مسئله‌ی موضوعی خود را تعریف می‌کند، سپس معیارهای ارزیابی مرتبط را شرح می‌دهد، آن‌گاه کارهای پیشین را با نام مدل یا مرجع مرور و نقد می‌کند، و در پایان با جدولی خلاصه از نام مدل، سال انتشار، مقادیر گزارش‌شده و وضعیت انتشار کد جمع‌بندی می‌شود. فصل با جمع‌بندی جای خالی مشترک میان این حوزه‌ها (بخش ۲-۷) به پایان می‌رسد.

---

[۱] Multi-organ segmentation

[۲] Bias

[۳] Image registration

۲-۱ پیش‌زمینه‌ی بالینی: سی‌تی چندفازی و فازهای کنتراست

سی‌تی شکمی چندفازی[۴] یک بررسی تصویربرداری است که در آن، به‌جای یک اسکن واحد، چند اسکن متوالی از یک ناحیه‌ی تشریحی، در بازه‌های زمانی مشخص نسبت به تزریق وریدی ماده‌ی حاجب یددار[۵]، گرفته می‌شود. اسکن نخست، پیش از هرگونه تزریق، فاز بدون‌کنتراست نامیده می‌شود و توزیع طبیعی تضعیف اشعه‌ی ایکس[۶] بافت‌ها، بدون اثر ماده‌ی حاجب، را ثبت می‌کند. پس از تزریق، ماده‌ی حاجب به‌ترتیب از قلب به آئورت، سپس به شریان‌های احشایی، و در نهایت از طریق مویرگ‌ها به وریدها و کبد می‌رسد؛ همین توالی زمانی، پایه‌ی نام‌گذاری فازهای کنتراست‌دار است.

فاز شریانی[۷]، معمولاً ۲۵ تا ۴۰ ثانیه پس از تزریق، زمانی ثبت می‌شود که ماده‌ی حاجب عمدتاً در شریان‌ها و بافت‌های پرخون[۸] متمرکز است؛ این فاز برای آشکارسازی ضایعاتی مانند کارسینوم سلول کبدی که خون‌رسانی شریانی غالب دارند، حیاتی است. **فاز وریدی باب**[۹]، حدود ۶۰ تا ۹۰ ثانیه پس از تزریق، زمانی است که ماده‌ی حاجب پارانشیم کبد را از طریق ورید باب پر کرده و بیشترین کنتراست میان بافت‌های نرم را فراهم می‌کند؛ این فاز معمول‌ترین فاز تشخیصی برای بخش‌بندی و ارزیابی عمومی اندام‌های شکمی است. **فاز تأخیری**[۱۰]، معمولاً ۳ تا ۵ دقیقه پس از تزریق، شست‌وشوی ماده‌ی حاجب از ضایعات پرخون را نشان می‌دهد؛ الگوی افزایش کنتراست در فاز شریانی و شست‌وشوی آن در فاز تأخیری یا وریدی، معیار تشخیصی اصلی کارسینوم سلول کبدی در دستورعمل‌های بالینی مانند EASL [۵] است.

هر یک از این فازها اطلاعات تشخیصی متفاوت و مکملی را در اختیار رادیولوژیست قرار می‌دهند؛ به همین دلیل، بسیاری از پروتکل‌های بالینی به‌طور هم‌زمان چند فاز را ثبت می‌کنند و تفسیر دقیق تنها با ترکیب اطلاعات چند فاز ممکن است. با این حال، همین چندفازی‌بودن، چالش‌های محاسباتی مضاعفی به همراه دارد که موضوع اصلی این فصل‌اند: تفاوت شدت روشنایی میان فازها می‌تواند دقت مدل‌های بخش‌بندی را کاهش دهد (بخش ۲-۲)، برچسب فاز هر بررسی همیشه به‌طور قابل‌اعتماد در سرآیند تصویر ثبت نمی‌شود (بخش ۲-۴)، و جابه‌جایی بیمار میان اسکن‌های متوالی، هم‌ترازسازی تصویر دقیق میان فازها را ضروری می‌سازد (بخش ۲-۵).

---

[۴] Multi-phase abdominal CT
[۵] Iodinated contrast medium
[۶] X-ray attenuation
[۷] Arterial phase
[۸] Hypervascular
[۹] Portal venous phase
[۱۰] Delayed phase

۲-۲ بخش‌بندی چندعضوی سی‌تی شکمی و شکاف کیفیت در فاز بدون‌کنتراست

تعریف مسئله

بخش‌بندی چندعضوی تصاویر سی‌تی شکمی، یعنی تعیین دقیق مرزهای تشریحی اندام‌هایی مانند کبد، کلیه، طحال و پانکراس در حجم‌های سه‌بعدی، زیرساخت بسیاری از کاربردهای بالینی مبتنی‌بر هوش مصنوعی از جمله برنامه‌ریزی درمان، اندازه‌گیری حجمی و ردیابی روند بیماری است. این مسئله معمولاً به‌صورت یک وظیفه‌ی طبقه‌بندی پیکسل‌به‌پیکسل (یا وُکسل‌به‌وُکسل) فرمول‌بندی می‌شود که در آن هر وُکسل حجم سی‌تی باید به یکی از برچسب‌های تشریحی از پیش‌تعریف‌شده نسبت داده شود. مشاهده‌ای که این بخش بر آن متمرکز است آن است که دقت این بخش‌بندی لزوماً در طول فازهای مختلف تصویربرداری یکنواخت باقی نمی‌ماند: فاز بدون‌کنتراست، به دلیل کاهش نسبت کنتراست‌به‌نویز میان بافت‌های نرم مجاور، اغلب دقت پایین‌تری نسبت به فاز کنتراست‌دار نشان می‌دهد؛ بدون تزریق ماده‌ی حاجب، تفاوت میان بافت نرم اندام‌های مجاور مانند کبد و طحال، یا میان پارانشیم اندام و عروق داخل آن، به‌مراتب کمتر از فاز کنتراست‌دار است و مرزهای تشریحی‌ای که مدل‌های بخش‌بندی برای آن‌ها آموزش دیده‌اند، در تصاویر بدون‌کنتراست کم‌رنگ‌تر یا مبهم‌تر ظاهر می‌شوند.

معیار ارزیابی

ضریب هم‌پوشانی سورنسن–دایس[۱۱]، یا به‌اختصار Dice، معیار غالب در ادبیات بخش‌بندی تصویر پزشکی است. برای دو نقاب دودویی A (پیش‌بینی مدل) و B (برچسب مرجع)، این ضریب به‌صورت $\mathrm{Dice}(A,B) = ۲|A \cap B|/(|A| + |B|)$ تعریف می‌شود و مقداری میان صفر (بدون هم‌پوشانی) و یک (هم‌پوشانی کامل) می‌گیرد. مزیت اصلی Dice نسبت به دقت پیکسلی خام، مقاومت نسبی آن در برابر عدم‌توازن حجمی میان پیش‌زمینه (اندام هدف) و پس‌زمینه است، ویژگی‌ای که در بخش‌بندی اندام‌های کوچک مانند پانکراس یا غده‌ی فوق‌کلیوی اهمیت زیادی دارد. برای پرهیز از ناهمگنی مقیاس میان مقالات، در سراسر این فصل همه‌ی معیارهای عملکرد کران‌دار—Dice، F1، دقت، حساسیت، AUC، SSIM و ضریب همبستگی—در بازه‌ی صفر تا یک گزارش می‌شوند، حتی اگر مقاله‌ی اصلی آن‌ها را درصدی آورده باشد، و اختلاف دو مقدار نیز در همان واحد بیان می‌شود؛ درصد تنها برای سهم‌ها (سهم مجموعه‌داده‌ها، موارد یا نقاطی که شرطی را برآورده می‌کنند) و تغییرات نسبی (مانند اختلاف حجم یا میزان کاهش دوز)

[۱۱] Sørensen–Dice coefficient

به کار می‌رود.

صدک نودوپنجم فاصله‌ی هاسدورف[۱۲] معیاری مکمل است که به خطای موضعی مرزی، برخلاف Dice، حساس است. Dice تنها میزان هم‌پوشانی حجمی را می‌سنجد و ممکن است خطای برجسته‌ی مرزی در یک ناحیه‌ی کوچک را پنهان کند؛ HD95 این کاستی را جبران می‌کند: بزرگ‌ترین فاصله‌ی باقی‌مانده میان مرز دو نقاب را، پس از حذف ۵ درصد دورافتاده‌ترین نقاط (برای کاهش حساسیت به نویز برچسب‌گذاری)، اندازه می‌گیرد. در برخی مطالعات، از انحراف حجمی[۱۳] نسبت به یک اسکن مرجع نیز به‌عنوان معیار مکمل برای سنجش تکرارپذیری[۱۴] استفاده می‌شود.

کارهای پیشین

چارچوب **nnU-Net** [۱۰] یک شبکه‌ی رمزگذار—رمزگشای پیچشی بر پایه‌ی معماری U-Net است که با **خودپیکربندی**[۱۵] خودکار معماری، پیش‌پردازش و آموزش بر اساس ویژگی‌های هر مجموعه‌داده، نیاز به تنظیم دستی فراپارامترها را حذف می‌کند و به یکی از پرکاربردترین مبناهای این حوزه بدل شده است. این چارچوب روی ۲۳ مجموعه‌داده‌ی عمومی از چالش‌های بین‌المللی ارزیابی شده است؛ در وظیفه‌های شکمی محک MSD [۱]، Dice آن برای طحال ۰٫۹۶، کبد ۰٫۹۳ و پانکراس ۰٫۷۹ گزارش شده است، و برای ساختارهای دشوارتر همان محک به‌مراتب پایین‌تر می‌آید: عروق کبدی ۰٫۶۳، تومور کبد ۰٫۷۴، توده‌ی پانکراس ۰٫۵۲ و سرطان روده‌ی بزرگ ۰٫۵۶. همه‌ی این ارقام روی داده‌ی فاز کنتراست‌دار به دست آمده‌اند؛ محک MSD هیچ وظیفه‌ی بدون‌کنتراستی ندارد.

TotalSegmentator [۱۱] یک مدل nnU-Net سه‌بعدی است که بر پایه‌ی چارچوب فوق و با آموزش روی ۱٬۲۰۴ بررسی سی‌تی بالینی متنوع ساخته شده و ۱۰۴ ساختار تشریحی از جمله اندام‌ها، استخوان‌ها، عضلات و عروق را بخش‌بندی می‌کند؛ این مدل Dice برابر ۰٫۹۴۳ روی مجموعه‌ی آزمون خود گزارش کرده و در عمل به ابزاری مرجع برای تولید نقاب[۱۶] اندام در پژوهش‌های بعدی تبدیل شده است. نکته‌ای که در ادامه اهمیت می‌یابد آن است که این رقم روی مجموعه‌ی آزمونی گزارش شده که از نظر فاز کنتراست ترکیبی است و مقاله هیچ تفکیک فازی از عملکرد ارائه نمی‌کند.

در کنار این چارچوب‌های عمومی، محک‌های بزرگ‌مقیاس اختصاصی شکم مانند AbdomenCT-1K [۱۲]، FLARE [۱۳] و AbdomenAtlas [۱۴]، که هر یک با گردآوری و بازبرچسب‌گذاری

[۱۲] 95th percentile Hausdorff Distance (HD95)
[۱۳] Volumetric deviation
[۱۴] Reproducibility
[۱۵] Self-configuring
[۱۶] Mask

چند مجموعه‌داده‌ی پایه شکل گرفته‌اند، و Medical Segmentation Decathlon [۱] به‌عنوان محکی چندوظیفه‌ای، مسیر پیشرفت این حوزه را در سال‌های اخیر ترسیم کرده‌اند. این محک‌ها عمدتاً بر پایه‌ی همان معماری nnU-Net یا مشتقات آن ارزیابی می‌شوند.

رویکردهای مبتنی‌بر یادگیری چندوظیفه‌ای و پرسش‌محور[۱۷] مانند مدل جهانی هدایت‌شده با CLIP [۱۵]، که یک رمزگذار متن از پیش‌آموزش‌دیده را برای تولید بردار پرسش هر اندام با یک شبکه‌ی بخش‌بندی سه‌بعدی ترکیب می‌کند، نشان داده‌اند یک شبکه‌ی واحد می‌تواند هم‌زمان بخش‌بندی اندام و تشخیص تومور را در طیف وسیعی از اندام‌ها انجام دهد؛ این مدل با آموزش روی ۳,۴۱۰ بررسی سی‌تی از ۱۴ مجموعه‌داده و پوشش ۲۵ اندام و شش نوع تومور، به میانگین Dice برابر ۰/۸۶۱ روی محک BTCV رسید.

یو و همکاران [۱۶] با یک nnU-Net سه‌بعدی، هشت ساختار شکمی را روی تصاویر بدون‌کنتراست[۱۸] و کنتراست‌دار[۱۹] بخش‌بندی کردند. نکته‌ی روش‌شناختی مهم در این مطالعه آن است که ضریب Dice *تنها* برای فاز کنتراست‌دار گزارش شده است (از ۰/۸۰ برای دئودنوم تا ۰/۹۷ برای طحال، روی ۳۰ بیمار آزمون)، و مقایسه‌ی میان دو فاز صرفاً به‌صورت *کیفی* و با امتیازدهی لیکرت رادیولوژیست انجام شده است: ۸۹/۳ درصد خطوط دئودنوم در فاز کنتراست‌دار در برابر ۸۵/۳ درصد در فاز بدون‌کنتراست، امتیاز سه یا بالاتر (نیازمند ویرایش جزئی) گرفتند. بنابراین این مطالعه، برخلاف آن‌چه از عنوانش برمی‌آید، شواهد کمّی مستقیمی درباره‌ی اندازه‌ی شکاف بین‌فازی به دست نمی‌دهد؛ خودِ همین نبودِ گزارش کمّی، نمونه‌ای از الگویی است که در ادامه‌ی این بخش تکرار می‌شود.

جئون و همکاران [۷] تنها مطالعه‌ی این مجموعه‌اند که شکاف بین‌فازی را به‌صورت کمّی و روی داده‌ی کنترل‌شده اندازه گرفته‌اند. آن‌ها با سی‌تی دوانرژی[۲۰] جفت‌های ذاتاً هم‌ترازِ فاز وریدی و تصویر بدون‌کنتراست مجازی[۲۱] ساختند، یک nnU-Net سه‌بعدی را روی ۷۵ بررسی آموزش دادند و آن را روی ۳۰ بررسی سی‌تی تک‌انرژی خارجی آزمودند. روی این مجموعه‌ی آزمون خارجی، Dice در فاز وریدی برای کبد، طحال، کلیه‌ی راست، کلیه‌ی چپ و پانکراس به‌ترتیب ۰/۹۸۱، ۰/۹۷۲، ۰/۹۷۱، ۰/۹۷۰ و ۰/۸۴۶ بود، و در فاز بدون‌کنتراست واقعی به ۰/۹۶۵، ۰/۹۶۱، ۰/۹۴۴، ۰/۹۵۴ و ۰/۸۱۰ کاهش یافت. الگوی این ارقام گویاست: افت بین‌فازی برای اندام‌های بزرگ و پرکنتراست میان ۰/۰۱۱ و ۰/۰۲۷ است، اما برای پانکراس (اندامی کوچک با مرز مبهم در برابر بافت چرب اطراف) به ۰/۰۳۶ می‌رسد. یعنی شکاف یکنواخت نیست و بیشترین افت روی دشوارترین اندام رخ می‌دهد.

[۱۷] Prompt-driven
[۱۸] Non-contrast CT (NCCT)
[۱۹] Contrast-enhanced CT (CECT)
[۲۰] Dual-energy CT
[۲۱] Virtual non-contrast (VNC)

پارک و همکاران [۱۷]، از همان گروه پژوهشی جئون، مسیر دیگری را آزمودند: به‌جای ساختن جفت هم‌تراز، مدل را *مستقیماً و تنها* روی داده‌ی بدون‌کنتراست آموزش دادند. چون رقم حاصل از این مطالعه در نگاه نخست غیرمنتظره است، جزئیات داده‌ی آن باید صریح بماند. داده‌ی توسعه ۱۰۵ بررسی سی‌تی شکمی *بدون‌کنتراست* از بخش اورژانس یک بیمارستان دانشگاهی (سئول) در بازه‌ی ژوئن تا نوامبر ۲۰۲۰ و با یک اسکنر واحد بود، به‌همراه ۶۰ سی‌تی کم‌دوز قفسه‌سینه از برنامه‌ی غربالگری همان مرکز؛ این ۱۰۵ بررسی به ۸۵ آموزش، ۱۰ تنظیم و ۱۰ آزمون داخلی تقسیم شد. معیارهای ورود عامدانه سخت‌گیرانه بودند: بیماران با سابقه‌ی برداشت یا مداخله روی اندام هدف، با ضایعه‌ی توده‌مانندی که کانتور طبیعی اندام را تغییر دهد، و با کیست‌های بزرگ یا بیماری کلیه‌ی پلی‌کیستیک کنار گذاشته شدند؛ یعنی جمعیت مطالعه عملاً آناتومی نزدیک‌به‌طبیعی دارد. برچسب مرجع نیز با یک نرم‌افزار تجاری به‌صورت اولیه تولید و سپس برش‌به‌برش به‌دست یک رادیولوژیست بوردشده اصلاح شد، با قواعدی که شکاف‌های کبدی، بخش داخل‌کبدی ورید اجوف تحتانی و شاخه‌های اصلی ورید باب را از نقاب کبد و سینوس کلیه را از نقاب کلیه بیرون می‌گذارند.

نتیجه چشمگیر است: Dice روی مجموعه‌ی آزمون داخلی برای کبد ۰٫۹۸۲، طحال ۰٫۹۷۳، کلیه‌ی راست ۰٫۹۶۶ و کلیه‌ی چپ ۰٫۹۶۷، و روی مجموعه‌ی آزمون دوم به‌ترتیب ۰٫۹۶۸، ۰٫۹۶۰، ۰٫۹۵۲ و ۰٫۹۵۸ بود؛ یعنی هم‌سطح با ارقامی که مدل‌های دیگر روی فاز *کنتراست‌دار* گزارش می‌کنند. اختلاف حجم برآوردشده با حجم مرجع نیز میان ۰٫۷− تا ۲٫۲+ درصد ماند.

سه قید، دامنه‌ی تعمیم این ارقام را تعیین می‌کنند و هر سه از خودِ مقاله برمی‌آیند. نخست، آن‌چه مقاله «مجموعه‌ی آزمون خارجی» می‌نامد، ۵۵ بررسی شکمی و ۱۰ بررسی قفسه‌سینه از *همان بیمارستان* است که تنها با *اسکنرهای متفاوت* گرفته شده‌اند؛ پس این ارزیابی، جابه‌جایی حوزه‌ی ناشی از تغییر دستگاه را می‌سنجد و نه جابه‌جایی ناشی از تغییر مرکز، جمعیت یا پروتکل. دوم، فهرست اندام‌ها به چهار اندام توپر و بزرگ محدود است و پانکراس در آن نیست؛ یعنی دقیقاً همان اندامی که در مطالعه‌ی جئون بیشترین افت بین‌فازی (۰٫۰۳۶) را نشان داد از ارزیابی بیرون مانده است. سوم، قرارداد برچسب‌گذاری، مرزهایی را که بدون ماده‌ی حاجب مبهم‌اند (عروق درون کبد، سینوس کلیه) از پیش از نقاب بیرون گذاشته و مدل و برچسب مرجع هر دو از یک زنجیره‌ی حاشیه‌نویسی واحد بیرون آمده‌اند؛ پس عدد گزارش‌شده، سازگاری با یک قرارداد خودسازگار را روی یک گروه نزدیک‌به‌طبیعی می‌سنجد. خود نویسندگان نیز در محدودیت‌ها به کوچک‌بودن مجموعه‌ی آزمون و طبیعی‌بودن اندام‌ها تصریح کرده‌اند.

با این سه قید، تحلیل درست از این مطالعه چنین است: این کار نشان می‌دهد پایین‌بودن دقت در فاز بدون‌کنتراست یک محدودیت *فیزیکی و اجتناب‌ناپذیر* نیست؛ دست‌کم برای اندام‌های بزرگ توپر و در جمعیتی همگن، مدلی که مستقیماً روی داده‌ی بدون‌کنتراست آموزش ببیند به همان سطحی می‌رسد که مدل‌های کنتراست‌دار روی داده‌ی خودشان گزارش می‌کنند. اما این کار نشان *نمی‌دهد* که شکاف

در حالت کلی بسته می‌شود: نه برای اندام‌های کوچک و کم‌مرز، نه برای بیماران دارای ضایعه، و نه در عبور از مرز مرکز. مهم‌تر آن‌که راه‌حل پیشنهادی‌اش مقیاس‌پذیر نیست؛ این راه‌حل به داده‌ی بدون‌کنتراستِ برچسب‌خورده و بومیِ هر مرکز و هر مجموعه‌ی اندام نیاز دارد، و بخش ۲-۳ مستند می‌کند که چنین داده‌ای به‌اندازه‌ی کافی وجود ندارد و برچسب‌گذاری دستی آن به‌مراتب دشوارتر از فاز کنتراست‌دار است. همین محدودیت است که در ادبیات، دو مسیر جایگزین را پیش کشیده است: هم‌ترازسازی فازهای موجود (بخش ۲-۵) و سنتز فاز غایب (بخش ۲-۶).

آبل و همکاران [۲] به‌جای دقت مطلق، *ثبات* خروجی را سنجیدند: آن‌ها ۳٫۷۵۶ سری سی‌تی را که هر بیمار در سه فاز شریانی، وریدی و بدون‌کنتراست داشت به TotalSegmentator دادند و انحراف حجمی هر ساختار را میان فازها اندازه گرفتند. ۲۹ ساختار از ۳۴ ساختار، انحراف حجمی کمتر از ۵ درصد نشان دادند و پس تکرارپذیر تلقی شدند؛ تنها اندام‌های معدودی مانند غده‌ی فوق‌کلیوی، کیسه‌ی صفرا، طحال و دئودنوم به **جابه‌جایی حوزه‌ای**[۲۲] وابسته به فاز و پروتکل حساس‌تر بودند. این مطالعه دو نکته را برجسته می‌کند: نخست آن‌که تغییر فاز، خروجی یک ابزار ثابت را به‌طور نظام‌مند جابه‌جا می‌کند؛ و دوم آن‌که این جابه‌جایی، مانند یافته‌ی جئون، روی زیرمجموعه‌ی کوچکی از ساختارها متمرکز است.

ژو و همکاران [۸] چارچوب **CKAP-Net** را پیشنهاد دادند که یک ماژول تزریق دانش کنتراست و یک شاخه‌ی ادراک تشریحی چندمقیاسی را برای سنتز اطلاعات کنتراست از روی تصویر بدون‌کنتراست، پیش از بخش‌بندی، ترکیب می‌کند؛ این مدل به ضریب Dice حدود ۰٫۸۱۲ در بخش‌بندی چندعضوی روی مجموعه‌داده‌های چندمرکزی رسید، رقمی که فاصله‌ی چندانی با دقت متداول بخش‌بندی روی فاز کنتراست‌دار ندارد.

جدول ۲-۱ این مطالعات را کنار هم می‌گذارد. مطالعه‌ی آبل و همکاران عمداً در جدول نیامده است، چون معیار آن Dice نیست و ستون‌های عددی جدول را نمی‌پذیرد؛ جایگاه آن در متن بالا تشریح شد. ساختار جدول عمداً دو ستون عددی مجزا برای Dice در فاز کنتراست‌دار و Dice در فاز بدون‌کنتراست دارد، و خالی‌بودن گسترده‌ی ستون دوم، خود مهم‌ترین یافته‌ی این بخش است: از میان مدل‌های مرجع این حوزه، هیچ‌یک عملکرد خود را به‌تفکیک فاز کنتراست گزارش نکرده‌اند. تنها سه مطالعه عددی برای فاز بدون‌کنتراست دارند؛ جئون و همکاران [۷] که جفت‌های هم‌تراز از سی‌تی دوانرژی ساختند، پارک و همکاران [۱۷] که به‌کلی از فاز کنتراست‌دار صرف‌نظر کردند، و CKAP-Net [۸] که کنتراست را پیش از بخش‌بندی سنتز می‌کند؛ و هر سه، برای به‌دست‌آوردن این عدد، ناچار شده‌اند داده‌ی اختصاصی خود را بسازند. ستون «داده‌ی آموزش» نیز به همین دلیل افزوده شده است: بدون دانستن این‌که هر مدل با چه نوع داده‌ای و از کجا آموزش دیده، مقایسه‌ی دو ستون Dice میان سطرها بی‌معناست.

[۲۲] Domain shift

مجموع این شواهد سه نکته را تثبیت می‌کند. شکاف بین‌فازی *وجود دارد* اما یکنواخت نیست: در تنها اندازه‌گیری کمّی و کنترل‌شده‌ی موجود [۷]، افت روی اندام‌های بزرگ و پرکنتراست میان ۰٫۰۱۱ و ۰٫۰۲۷ و روی اندام کوچک و کم‌مرزی مانند پانکراس ۰٫۰۳۶ است. شکاف *تماماً ذاتی نیست*: نتیجه‌ی پارک و همکاران [۱۷] نشان می‌دهد که برای اندام‌های بزرگ توپر و در یک جمعیت همگن و نزدیک‌به‌طبیعی، آموزش مستقیم روی داده‌ی بدون‌کنتراست بخش عمده‌ی آن را می‌بندد؛ اما چنان‌که در بالا آمد، این شاهد نه اندام‌های دشوار را پوشش می‌دهد و نه عبور از مرز مرکز را، و بنابراین آن را باید *کران بالای* آن‌چه با داده‌ی متناسب به دست می‌آید خواند، نه توصیفی از حالت کلی. و سرانجام، همین راه‌حل به محدودیت داده برمی‌خورد؛ ادبیات پژوهشی دو راهبرد مکمل برای جبران این افت پیشنهاد داده است که در بخش‌های ۲-۵ و ۲-۶ همین فصل مرور می‌شوند: هم‌ترازسازی هندسی فاز بدون‌کنتراست با فاز کنتراست‌دار، و سنتز مستقیم اطلاعات کنتراست از روی تصویر بدون‌کنتراست.

جدول ۲-۱: مدل‌های بخش‌بندی چندعضوی و مطالعات شکاف بین‌فازی. کد فاز: ۰ بدون‌کنتراست، ۱ شریانی، ۲ وریدی باب، ۳ تأخیری؛ ستون «فازهای داده‌ی آموزش» فهرست فازهایی است که مدل در آموزش دیده است. همه‌ی مقادیر Dice در بازه‌ی صفر تا یک‌اند. ستون کد: ✓یعنی کد منبع به‌طور تأییدشده در دسترس عمومی است و ×یعنی کد منتشر نشده یا وضعیت آن در مقاله ذکر نشده است. ارقام nnU-Net مربوط به وظیفه‌های شکمی محک MSD [۱] است (طحال ۰٫۹۶، کبد ۰٫۹۳، پانکراس ۰٫۷۹؛ تومور کبد ۰٫۷۴، عروق کبدی ۰٫۶۳، توده‌ی پانکراس ۰٫۵۲، سرطان روده‌ی بزرگ ۰٫۵۶)؛ مقاله‌ی اصلی عدد واحدی گزارش نمی‌کند. رقم TotalSegmentator میانگینی روی مجموعه‌ی آزمونی است که از نظر فاز ترکیبی و تفکیک‌نشده است و تنها به‌عنوان نقطه‌ی مرجع سمت کنتراست‌دار آورده شده. در مطالعه‌ی یو و همکاران، مقایسه‌ی دو فاز فقط کیفی و با امتیاز لیکرت گزارش شده است (۸۹٫۳ درصد در برابر ۸۵٫۳ درصد خطوط دئودنوم با امتیاز سه یا بالاتر) و هیچ Dice بدون‌کنتراستی ندارد. در مطالعه‌ی پارک و همکاران، مجموعه‌ی آزمون دوم از *همان* مرکز و تنها با اسکنر متفاوت است و بیماران دارای ضایعه‌ی تغییردهنده‌ی کانتور از مطالعه کنار گذاشته شده‌اند. مطالعه‌ی آبل و همکاران [۲] در این جدول نیامده است، چون معیارش انحراف حجمی میان سه فاز است و نه Dice.

روش (مرجع)	سال	اندام‌های هدف	نوع و منشأ داده‌ی آموزش	فازهای آموزش	Dice فاز کنتراست‌دار	Dice فاز بدون‌کنتراست	کد
nnU-Net [۱۰]	۲۰۲۱	اندام و تومور شکمی (وظیفه‌های شکمی MSD)	۲۳ مجموعه‌داده‌ی عمومی چالش‌ها؛ سی‌تی کنتراست‌دار چندمرکزی	۲	اندام: ۰٫۷۹—۰٫۹۶ تومور: ۰٫۵۲—۰٫۷۴	—	✓
TotalSegmentator [۱۱]	۲۰۲۳	۱۰۴ ساختار تشریحی کل‌بدن	۱٬۲۰۴ بررسی بالینی روتین یک مرکز؛ اسکنر و پروتکل متنوع	۱، ۰، ۲، ۳ (تفکیک‌نشده)	۰٫۹۴۳ (ترکیبی)	—	✓

ادامه در صفحه‌ی بعد

ادامه‌ی جدول ۲-۱ از صفحه‌ی پیش

روش (مرجع)	سال	اندام‌های هدف	نوع و منشأ داده‌ی آموزش	فازهای آموزش	Dice فاز کنتراست‌دار	Dice فاز بدون‌کنتراست	کد
CLIP-driven Universal Model [۱۵]	۲۰۲۳	۲۵ اندام + شش نوع تومور	۳,۴۱۰ بررسی از ۱۴ مجموعه‌داده‌ی عمومی؛ کنتراست‌دار	۲	۰/۸۶۱ (BTCV)	—	✓
یو و همکاران [۱۶]	۲۰۲۲	هشت ساختار شکمی، شامل دئودنوم	درون‌سازمانی؛ هر بیمار در دو فاز، ۳۰ بیمار آزمون	۰ و ۲	۰/۸۰–۰/۹۷	گزارش‌نشده	×
جئون و همکاران [۷]	۲۰۲۴	کبد، طحال، دو کلیه، پانکراس	۷۵ بررسی سی‌تی دوانرژی؛ جفت ذاتاً هم‌ترازِ وریدی و بدون‌کنتراست مجازی. آزمون: ۳۰ بررسی تک‌انرژی خارجی	۰ (مجازی) و ۲	تک‌انرژی: ۰/۸۴۶–۰/۹۸۱	مجازی: ۰/۸۵۴–۰/۹۷۷ واقعی: ۰/۸۱۰–۰/۹۶۵	×
پارک و همکاران [۱۷]	۲۰۲۵	کبد، طحال، دو کلیه (بدون پانکراس)	۱۰۵ سی‌تی شکمی بدون‌کنتراست اورژانس + ۶۰ سی‌تی کم‌دوز قفسه‌سینه؛ یک مرکز، آناتومی نزدیک‌به‌طبیعی	**۰ تنها**	—	شکمی: ۰/۹۵۲–۰/۹۶۸ قفسه‌سینه: ۰/۹۶۰–۰/۹۶۹	×
CKAP-Net [۸]	۲۰۲۴	۱۳ اندام شکمی (سنتز + بخش‌بندی)	۴۰۳ و ۳۸ بیمار از دو مرکز؛ جفت‌های بدون‌کنتراست و شریانی دیررس	۰ و ۱ (جفت‌شده)	—	۰/۸۱۲	×

۲-۳ مجموعه‌داده‌های عمومی سی‌تی شکمی و مسئله‌ی سوگیری داده

بخش پیشین نشان داد سقف عملکرد مدل‌های بخش‌بندی در فاز بدون‌کنتراست، بیش از آنکه به معماری وابسته باشد، به ترکیب فازیِ داده‌ی آموزش وابسته است. این مشاهده، پرسش را یک سطح عقب‌تر می‌برد: داده‌ی عمومی موجود در این حوزه چیست، چگونه ساخته شده، و چه محدودیت‌هایی را به هر مدلی که روی آن آموزش ببیند تحمیل می‌کند؟ این بخش، پیشینه‌ی پژوهشی همین پرسش را مرور می‌کند.

چشم‌انداز مجموعه‌داده‌های عمومی

ادبیات بخش‌بندی سی‌تی شکمی حول شمار محدودی از مجموعه‌داده‌های پایه شکل گرفته است. LiTS [۱۸] (تومور کبدی)، KiTS [۱۹] (تومور کلیه)، Pancreas-CT و BTCV (بخش‌بندی چندعضوی) در عمل نقش مجموعه‌داده‌های *مادر* این حوزه را ایفا می‌کنند. نسل بعدی منابع،

عمدتاً از گردآوری، ادغام و بازبرچسب‌گذاری همین مجموعه‌ها ساخته شده‌اند: AbdomenCT-1K [۱۲]، FLARE [۱۳] و AbdomenAtlas 1.1 [۱۴] هر سه ترکیبی‌اند، و Medical Segmentation Decathlon [۱] چند وظیفه‌ی شکمی خود را از همین منابع برداشته است. در کنار این‌ها، مجموعه‌داده‌های اصیل متأخرتری مانند AMOS22 [۲۰]، WORD [۲۱] و مجموعه‌ی منتشرشده همراه با TotalSegmentator [۱۱] به این چشم‌انداز افزوده شده‌اند.

این ساختار درختی (تعداد کمی ریشه و شمار زیادی شاخه) دو پیامد دارد که در ادبیات به آن‌ها اشاره شده است. نخست، **نشت داده**[۲۳]: وقتی یک بیمار هم‌زمان در مجموعه‌ی آموزش یک پژوهش و مجموعه‌ی ارزیابی پژوهش دیگری حاضر است، ارقام گزارش‌شده خوش‌بینانه‌اند. دوم، **تمرکز محک**[۲۴]: کخ و همکاران [۲۲] نشان دادند در یادگیری ماشین، استفاده از مجموعه‌داده‌ها به‌مرور روی شمار اندکی از منابع پرارجاع متمرکز می‌شود، و واروکو و شولام [۲۳] همین الگو را به‌طور خاص در تصویربرداری پزشکی مستند کرده‌اند.

سوگیری داده در هوش مصنوعی پزشکی

مسئله‌ی سوگیری مجموعه‌داده در تصویربرداری پزشکی، پیشینه‌ی مستقلی دارد. اوبرمایر و همکاران [۲۴] سوگیری نژادی را در یک الگوریتم پرکاربرد تخصیص مراقبت سلامت نشان دادند؛ لاراسابال و همکاران [۲۵] نشان دادند عدم‌توازن جنسیتی در داده‌ی آموزش، مستقیماً به افت عملکرد در جنسیت کم‌نماینده ترجمه می‌شود؛ و کوشال و همکاران [۲۶] تمرکز جغرافیایی داده‌های آموزشی الگوریتم‌های بالینی در آمریکا را کمّی کردند. در سطح وجهیت‌های خاص، سیدکلانتری و همکاران [۲۷] *کم‌تشخیصی* نظام‌مند در جمعیت‌های محروم را در رادیوگرافی قفسه‌ی سینه و دانشجو و همکاران [۲۸] همان الگو را در پوست‌شناسی مستند کردند. جونز و همکاران [۲۹] این یافته‌های پراکنده را در یک چارچوب علّی جمع کردند و نشان دادند سوگیری، نقصی موضعی در یک منبع نیست بلکه در طول چرخه‌ی *حیات داده* انباشته می‌شود.

نکته‌ی مشترک و تعیین‌کننده‌ی این ادبیات آن است که تقریباً همه‌ی این مطالعات، سوگیری را در *خروجی مدل* می‌سنجند؛ یعنی پس از آن‌که آموزش، هر تحریفی را که داده در خود داشته جذب کرده است [۳۰، ۳۱]. خودِ مجموعه‌داده‌ها، به‌عنوان منابع بالادستی‌ای که تعیین می‌کنند مدل چه سوگیری‌هایی را می‌تواند به ارث ببرد، به‌مراتب کمتر بررسی شده‌اند.

---

[۲۳] Data leakage

[۲۴] Benchmark concentration

ابزارهای ارزیابی کیفیت و شکاف موجود

برای ارزیابی کیفیت منابع پژوهشی، ابزارهای متعددی توسعه یافته‌اند، اما هیچ‌یک مستقیماً برای مجموعه‌داده‌های تصویربرداری پزشکی در نقش *منبع آموزش هوش مصنوعی* طراحی نشده است. PROBAST+AI [۳۲] ریسک سوگیری *مدل‌های پیش‌بین* را ارزیابی می‌کند نه داده را؛ TRIPOD+AI [۳۳] یک راهنمای *گزارش‌دهی* برای مطالعات تشخیصی و پیش‌آگهی مبتنی‌بر هوش مصنوعی است؛ و معیارهای کیفیت پیشنهادی کوچاک و همکاران [۳۰] به مجموعه‌داده‌های تصویربرداری می‌پردازند اما به‌صورت چک‌لیستی عملیاتی با درجه‌بندی ریسک تدوین نشده‌اند.

نتیجه آن است که تا همین اواخر **هیچ مرور نظام‌مندی در دسترس نبود** که به‌طور هم‌زمان ترکیب جمعیت‌شناختی، شیوه‌ی برچسب‌گذاری، پوشش اندام و آسیب‌شناسی، و الگوی بازاستفاده‌ی مجموعه‌داده‌های عمومی سی‌تی شکمی را ارزیابی کرده باشد. به‌طور مشخص‌تر، هیچ منبع منتشرشده‌ای گزارش نکرده بود که چه *سهمی از داده‌ی برچسب‌خورده‌ی عمومی این حوزه اساساً از فاز بدون‌کنتراست می‌آید*؛ رقمی که تعیین می‌کند مدل‌های بخش‌بندی این حوزه اساساً چه امکانی برای آموزش روی این فاز داشته‌اند.

مرور نظام‌مند اخیر [۴] همین شکاف را هدف گرفته است. آن مرور، که چارچوبی هفت‌مقوله‌ای برای ارزیابی ریسک سوگیری مجموعه‌داده‌ها معرفی می‌کند، ۴۵ مجموعه‌داده‌ی عمومی سی‌تی شکمی را در بر می‌گیرد که روی‌هم‌رفته ۴۷,۰۴۹ بررسی سی‌تی را پوشش می‌دهند. دو یافته‌ی آن مستقیماً به بخش‌های بعدی همین فصل گره می‌خورد: از میان این ۴۷,۰۴۹ بررسی تنها ۲۳,۷۴۶ مورد اصیل‌اند و بقیه از مجموعه‌های پیشین بازاستفاده شده‌اند (بازاستفاده‌ی ۴۹/۵ درصدی)؛ و ۷۵/۳ درصد مجموعه‌داده‌ها از آمریکای شمالی و اروپا می‌آیند و آفریقای جنوب صحرا، جنوب آسیا و بیشتر خاورمیانه هیچ سهمی ندارند. موضوع آن مرور، وضعیت کلی مجموعه‌داده‌ها و سوگیری آن‌هاست و نه فاز کنتراست؛ اما جدول استخراج منتشرشده‌ی آن مشخصات تصویربرداری هر مجموعه‌داده را نیز ثبت کرده است، و از همین داده می‌توان وضعیت حضور فازهای کنتراست را در داده‌ی عمومی این حوزه نتیجه گرفت: داده‌ی برچسب‌خورده‌ی فاز بدون‌کنتراست کمیاب است.

سهم فاز بدون‌کنتراست در داده‌ی برچسب‌خورده

این نتیجه نیازمند دقت روش‌شناختی است. جزئیات هر مجموعه‌داده در **جدول استخراج** منتشرشده به‌همراه آن مرور ثبت شده است؛ سندی که برای هر مجموعه‌داده شش محور——از ترکیب و منشأ داده تا مشخصات تصویربرداری و جزئیات حاشیه‌نویسی——را از توصیف‌نامه‌ی رسمی همان مجموعه‌داده استخراج کرده و

در ادامه مرجع همه‌ی ارقام این بخش است.

معنای دقیق ستون فاز در این جدول باید پیش از هر عددی روشن شود. معیار ورود به آن مرور، وجود *نقاب بخش‌بندی* در سطح اندام بوده است؛ بنابراین آن‌چه در ستون فاز ثبت شده، فازهایی است که *نقاب‌های* هر مجموعه‌داده از آن‌ها می‌آیند، نه لزوماً همه‌ی فازهایی که در آن اسکن شده‌اند. برای نمونه WAW-TACE [۳۴] در عمل بررسی‌های چندفازی و از جمله فاز بدون‌کنتراست دارد، اما نقاب‌های آن (کبد و ضایعه) تنها روی فازهای کنتراست‌دار ارائه شده‌اند و در جدول استخراج نیز همان فازها ثبت شده است. چون پرسش این بخش، *داده‌ی آموزشیِ در دسترس برای بخش‌بندی* است، همین تعریف تعریف درست است. قید دوم آن است که توصیف‌نامه‌ها تنها حضور هر فاز را اعلام می‌کنند و تقریباً هیچ‌کدام شمار بررسی‌های هر فاز را به‌تفکیک گزارش نمی‌کنند؛ پس هر عددی در سطح شمار بررسی، برآوردی است که باید فرض‌هایش صریح بماند.

در سطح مجموعه‌داده، شمارش دقیق ممکن است. از ۴۵ مجموعه‌داده، ۳۲ مورد (حدود ۷۱ درصد) نقاب‌های خود را *تنها* از فازهای کنتراست‌دار می‌گیرند و هیچ نقاب بدون‌کنتراستی ارائه نمی‌کنند. تنها ۱۲ مجموعه‌داده (حدود ۲۷ درصد) فاز بدون‌کنتراست را در میان فازهای حاشیه‌نویسی‌شده‌ی خود دارند، و از این ۱۲ مورد، تنها یکی (WORD [۲۱]) به‌طور اختصاصی بدون‌کنتراست است (۱۷۰ بررسی در جدول مرور، که ۱۵۰ مورد آن اصیل است)؛ بقیه مجموعه‌های ترکیبی‌اند که فاز بدون‌کنتراست تنها بخشی از آن‌هاست. یک مجموعه‌داده نیز هیچ اطلاعات فازی گزارش نمی‌کند.

در سطح شمار بررسی، سه کمیت باید از هم تفکیک شود. **کران بالا:** مجموعه‌داده‌هایی که فاز بدون‌کنتراست را پوشش می‌دهند روی‌هم‌رفته ۳۳,۱۸۳ بررسی از ۴۷,۰۴۹ بررسی را در بر می‌گیرند؛ رقمی که آشکارا بیش‌برآورد است، چون بخش عمده‌ی بررسی‌های همین مجموعه‌ها کنتراست‌دار است. **کران پایین قطعی:** تنها ۱۵۰ بررسی اصیل WORD به‌طور تضمین‌شده بدون‌کنتراست‌اند. **برآورد میانی:** اگر برای هر مجموعه‌داده فرض کنیم بررسی‌ها میان فازهای پوشش‌داده‌شده‌ی آن به‌طور یکنواخت پخش شده‌اند، سهم فاز بدون‌کنتراست حدود ۹,۸۵۰ بررسی از ۴۳,۷۳۶ بررسی دارای اطلاعات فاز، یعنی حدود ۲۲ درصد، به دست می‌آید؛ به بیان دیگر نسبت کنتراست‌دار به بدون‌کنتراست حدود ۳/۴ به ۱. محدودکردن شمارش به بخش عمومی مجموعه‌داده‌ها این نسبت را تقریباً تغییر نمی‌دهد (حدود ۲۲ درصد بدون‌کنتراست از ۲۹,۸۷۰ بررسی عمومی).

فرض توزیع یکنواخت ساده‌سازی آشکاری است و به احتمال زیاد به سود فاز بدون‌کنتراست سوگیری دارد، چون در عمل فاز وریدی باب در تقریباً همه‌ی این مجموعه‌ها غالب است؛ پس سهم واقعی به احتمال زیاد کمتر از ۲۲ درصد است. واحد شمارش نیز «بررسی» به همان معنایی است که خود مجموعه‌داده گزارش کرده (اغلب معادل بیمار) و نه سری تصویری. عدد میانی را باید مرتبه‌ی بزرگی خواند، نه یک

اندازه‌گیری.

این ارقام، بُعد داده‌ایِ شکاف بین‌فازی بخش ۲-۲ را توضیح می‌دهند. نتیجه‌ی پارک و همکاران [۱۷] نشان داد مدل بخش‌بندی می‌تواند روی فاز بدون‌کنتراست هم خوب کار کند، به شرط آن‌که روی همان فاز آموزش ببیند. اما ذخیره‌ی عمومیِ برچسب‌خورده‌ی این حوزه چنین آموزشی را پشتیبانی نمی‌کند: دست‌کم هفتاد درصد مجموعه‌داده‌ها اصلاً نقاب بدون‌کنتراست ندارند، در سطح تصویر نیز فاز بدون‌کنتراست در بهترین حالت حدود یک‌پنجم داده است، و تنها یک مجموعه‌داده به‌طور اختصاصی به این فاز پرداخته است. بنابراین پیش‌فرض عملی این حوزه آن است که هر مدل بخش‌بندیِ آماده، مدلی کنتراست‌دار است؛ و شکاف مشاهده‌شده در فاز بدون‌کنتراست، پیش از آن‌که خاصیت تصویر باشد، بازتاب همین عدم‌توازن داده است.

همین کمیابی، مسیر سه بخش بعدی را تعیین می‌کند. وقتی نمی‌توان به‌سادگی مدلی را روی داده‌ی برچسب‌خورده‌ی بدون‌کنتراست آموزش داد، راه دیگر آن است که خودِ داده ساخته یا تکمیل شود؛ و این کار سه مسئله‌ی پیاپی پدید می‌آورد: باید تشخیص داد هر سری متعلق به کدام فاز است (بخش ۲-۴)، باید فازهای موجود یک بیمار را بر هم هم‌تراز کرد (بخش ۲-۵)، و باید فاز کنتراست‌دار را از روی تصویر بدون‌کنتراست بازسازی کرد (بخش ۲-۶).

۲-۴ تشخیص فاز کنتراست در تصاویر سی‌تی خام

تعریف مسئله

بخش پیشین نشان داد داده‌ی چندفازیِ در دسترس محدود است؛ اما پیش از آن‌که بتوان از همین داده‌ی محدود بهره برد، مسئله‌ی ساده‌تری باید حل شود: باید دانست هر سری تصویر متعلق به کدام فاز است. این مسئله بدیهی به نظر می‌رسد اما نیست: برچسب‌های موجود در سرآیند DICOM (مانند SeriesDescription) اغلب ناقص، ناسازگار میان مراکز، یا کاملاً غایب‌اند [۳۵]، که استخراج خودکار و قابل‌اعتماد فاز را از روی محتوای تصویر ضروری می‌سازد. ادبیات این حوزه سه شیوه‌ی صورت‌بندی متمایز دارد که در ادامه به همین ترتیب مرور می‌شوند. **رویکرد نخست** تصویر را ابتدا با یک مدل بخش‌بندی از پیش‌آموزش‌دیده به نواحی تشریحی می‌شکند، از هر ناحیه آمار شدت روشنایی استخراج می‌کند و طبقه‌بندی را به یک مدل یادگیری ماشین کلاسیک (عملاً همیشه یک جنگل درختان تقویت‌شده) می‌سپارد. **رویکرد دوم** این میانجی را حذف می‌کند و فاز را مستقیماً از پیکسل‌های تصویر با یک شبکه‌ی پیچشی طبقه‌بندی می‌کند. **رویکرد سوم**، که تنها یک نماینده دارد، اساساً مسئله را طبقه‌بندی نمی‌داند بلکه آن را به رگرسیون

زمان سپری‌شده از تزریق تبدیل می‌کند. تفاوت این سه، صرفاً معماری نیست: هر کدام پیش‌نیاز داده‌ای و نقطه‌ی شکست متفاوتی دارند، و همین تفاوت است که در جمع‌بندی این بخش اهمیت می‌یابد.

معیار ارزیابی

دقت[۲۵] ساده‌ترین و پرکاربردترین معیار در ادبیات تشخیص فاز کنتراست است: نسبت پیش‌بینی‌های درست به کل نمونه‌ها. این معیار زمانی گویاست که کلاس‌های فاز (بدون‌کنتراست، شریانی، وریدی، تأخیری) تقریباً متوازن باشند؛ در غیر این صورت، یک طبقه‌بند ساده که همیشه پرتکرارترین کلاس را پیش‌بینی می‌کند نیز می‌تواند دقت ظاهراً بالایی کسب کند.

F1 میانگین هارمونیک دقت‌مهم‌ترازسازی[۲۶] و بازخوانی[۲۷] است و تصویر متعادل‌تری از عملکرد طبقه‌بند در هر کلاس، به‌ویژه در حضور عدم‌توازن کلاسی، ارائه می‌دهد؛ به همین دلیل، در بیشتر مطالعات این حوزه به‌جای دقت خام، F1 به‌ازای هر کلاس فاز گزارش می‌شود.

AUC (مساحت زیر منحنی مشخصه‌ی عملکرد سیستم[۲۸]) حساسیت طبقه‌بند را در تمام آستانه‌های ممکن تصمیم‌گیری خلاصه می‌کند و در نتیجه، برخلاف دقت و F1، مستقل از انتخاب یک آستانه‌ی خاص است؛ این معیار به‌ویژه برای مقایسه‌ی طبقه‌بندهایی که آستانه‌ی تصمیم متفاوتی دارند، یا در ارزیابی‌های چندکلاسه به‌صورت یک‌درمقابل‌بقیه[۲۹]، پرکاربرد است.

کارهای پیشین

رویکرد نخست را سه مطالعه نمایندگی می‌کنند که هر سه ساختار یکسانی دارند: بخش‌بندی، استخراج ویژگی ناحیه‌ای، طبقه‌بند درختی.

هو و همکاران [۳۶]، در چارچوبی موسوم به **Segment-and-Classify**، ابتدا اندام‌های مرتبط با کنتراست (آئورت، ورید باب، ورید اجوف تحتانی، کلیه‌ها و غیره؛ در مجموع شانزده ساختار) را با TotalSegmentator [۱۱] مشخص کردند، سپس میانه‌ی HU هر اندام را به‌عنوان بردار ویژگی به یک طبقه‌بند **XGBoost** (جنگل درختان تقویت‌شده‌ی گرادیانی[۳۰]) دادند؛ این طبقه‌بند به‌طور ذاتی می‌تواند اندام‌های غایب (مثلاً خارج از میدان دید) را از طریق مکانیزم بومی XGBoost برای داده‌ی گمشده مدیریت

[۲۵] Accuracy
[۲۶] Precision
[۲۷] Recall
[۲۸] Receiver Operating Characteristic curve (ROC)
[۲۹] One-vs-rest
[۳۰] Gradient-boosted decision trees

کند. مدل تنها روی WAW-TACE آموزش دید و سپس، بدون هیچ تنظیم‌دقیقی، روی دو مجموعه‌داده‌ی عمومی دیگر آزموده شد. روی VinDr-Multiphase، F1 به‌ازای فازهای بدون‌کنتراست، شریانی، وریدی و تأخیری به‌ترتیب ۰/۹۹۴، ۰/۹۳۷، ۰/۸۹۸ و ۰/۷۱۸ بود و AUC در هیچ فازی از ۰/۹۳۷ پایین‌تر نیامد؛ روی C4KC-KiTS، F1 برای بدون‌کنتراست، شریانی/وریدی و تأخیری به‌ترتیب ۰/۹۸۵، ۰/۹۶۸ و ۰/۹۳۵ و کمینه‌ی AUC برابر ۰/۹۹۱ بود. الگوی این ارقام قابل‌توجه است: افت عملکرد تقریباً به‌طور کامل روی فاز تأخیری متمرکز است، همان فازی که (چنان‌که در ادامه‌ی همین بخش می‌آید) مجموعه‌داده‌های مختلف حتی بر سر نام‌گذاری‌اش توافق ندارند. برای مقایسه، سه شبکه‌ی پیچشی سه‌بعدی (ResNet3D-18، MC3-18، R (2+1) D-18) نیز روی همین وظیفه آموزش داده شدند و XGBoost در عین دقت بالا، به‌مراتب کاراتر از این شبکه‌های سه‌بعدی بود.

ریس و همکاران [۳۷] رویکرد مشابهی، اما با تأکید بر تفسیرپذیری، ارائه کردند: پس از بخش‌بندی با TotalSegmentator، ۴۸ ویژگی رادیومیک (آمار شدت روشنایی) از پنج ساختار تشریحی استخراج و به یک طبقه‌بند **XGBoost** داده شد که تفاوت‌های الگوی افزایش کنتراست کلیوی و عروقی را به‌طور مستقیم قابل‌تفسیر می‌کند. مدل روی ۷۳۹ بررسی چندفازی شکمی از ۲۰۰ بیمار (استنفورد، ۲۰۱۶—۲۰۲۱) آموزش دید. روی مجموعه‌ی آزمون درون‌سازمانی به دقت ۰/۹۲۳ و میانگین F1 برابر ۰/۹۰۷ رسید، اما روی داده‌ی خارجی VinDr-Multiphase دقت به ۰/۹۰۱ و میانگین F1 به ۰/۸۲۶ کاهش یافت؛ افتی ۰/۰۸۱ در F1 که تنها با عبور از یک مرکز به مرکز دیگر رخ می‌دهد.

بالدینی و همکاران [۳۸] همین رویکرد را به پنج فاز (با افزودن فاز شریان ریوی و فاز اورگرافیک) گسترش دادند و تشخیص ماده‌ی حاجب خوراکی در دستگاه گوارش را نیز به آن افزودند. با آموزش روی ۱,۲۰۰ بررسی درون‌سازمانی و ارزیابی روی ۲۴۰ بررسی خارجی چندمرکزی، AUC درون‌سازمانی میان ۰/۹۹۱ (فاز شریانی) و ۰/۹۹۸ (فاز وریدی) و AUC برون‌سازمانی برابر ۰/۹۷۳ گزارش شد. ارزش این مطالعه در دو نکته است. نخست، مجموعه‌ی کلاس‌های آن از چهار فاز متعارف فراتر می‌رود و نشان می‌دهد تعریف «فاز» میان مطالعات ثابت نیست؛ در نتیجه ارقام آن با سطرهای چهارکلاسه‌ی این پیمایش هم‌سنگ نیستند. دوم، تنها افت قابل‌اندازه‌گیری آن در همان جایی رخ می‌دهد که در بقیه‌ی این ادبیات نیز رخ می‌دهد: در عبور از داده‌ی درون‌سازمانی به داده‌ی چندمرکزی بیرونی.

هر سه مطالعه‌ی بالا یک ضعف مشترک دارند که در جمع‌بندی بخش به آن بازمی‌گردیم: پیش از آنکه بتوانند فاز را تشخیص دهند، به یک مدل بخش‌بندی اندام نیاز دارند که خود آموزش‌دیده است. رویکرد دوم همین وابستگی را حذف می‌کند.

یی و همکاران [۳۹] فاز را مستقیماً و بدون میانجی بخش‌بندی آناتومیک، با طبقه‌بندی برش‌های محوری دوبعدی و تجمیع پیش‌بینی‌ها به سطح کل بررسی، تشخیص دادند. از میان پنج معماری پیچشی

آزموده‌شده (از جمله InceptionV3 و ResNet101-v2)، بهترین عملکرد از آن **EfficientNet-B4** (شبکه‌ی پیچشی با مقیاس‌پذیری ترکیبی عمق/عرض/تفکیک‌پذیری[۳۱]) بود که روی ۱,۹۷۹ بررسی سی‌تی سر و گردن (۱۳۳,۴۸۰ برش محوری) بیماران سرطانی آموزش داده شد. این مدل AUC برابر ۰/۹۹۶ (درون‌سازمانی) و ۱/۰۰ (خارجی، ۵۹۵ بررسی) به دست آورد؛ پس از تنظیم‌دقیق روی مجموعه‌ای کوچک‌تر از سی‌تی قفسه‌سینه، به AUC ۱/۰۰ (درون‌سازمانی) و ۰/۹۸۰ (خارجی، ۴۰۲ بررسی) رسید.

دائو و همکاران [۴۰] با یک **شبکه‌ی پیچشی برش‌محور** و نمونه‌برداری تصادفی از ۲۰ تا ۳۰ درصد برش‌های هر اسکن به همراه رأی‌گیری اکثریت میان آن‌ها، هزینه‌ی محاسباتی استنتاج را کاهش دادند. مدل روی ۸۳۰ بررسی چندفازی شکمی (۲۷۱,۴۲۶ برش) آموزش و روی ۳۵۸ بررسی داخلی ارزیابی شد و F1 برابر ۰/۹۲۱ به دست آورد؛ در ارزیابی برونی روی CPTAC-CCRCC (۲۴۲ بررسی عمومی سرطان کلیه) و LiTS (۱۳۱ بررسی تومور کبدی) این رقم به‌ترتیب به ۰/۷۶۸ و ۰/۸۶۹ کاهش یافت، هرچند همچنان از یک مبنای ResNet18 سه‌بعدی هم در سرعت و هم در دقت پیشی گرفت.

روچا و همکاران [۴۱] با یک شبکه‌ی پیچشی سفارشی، پیش‌بینی سطح برش را به سطح حجم و سپس سطح کل بررسی تجمیع کردند و به دقت ۰/۹۴۶ (برش)، ۰/۹۸ (حجم) و ۱/۰۰ (کل بررسی) دست یافتند.

لیو و همکاران [۴۲] یک استراتژی **دومرحله‌ای** با ستون فقرات **ResNet-18** اشتراکی[۳۲] پیشنهاد دادند: تصاویر سه فاز یک بیمار به‌طور موازی به جریان‌های ResNet با پارامتر مشترک داده می‌شوند و یک ماژول توجه بین‌فازی[۳۳] میان آن‌ها تبادل ویژگی برقرار می‌کند. راهبرد نخست، طبقه‌بندی تک‌مرحله‌ای چهارکلاسه (شریانی زودرس/دیررس، وریدی باب، تأخیری) بود؛ راهبرد دوم، طبقه‌بندی را به دو مرحله شکست: ابتدا شریانی در برابر وریدی در برابر تأخیری، سپس در صورت شریانی‌بودن، یک زیرشبکه فاز را به زودرس یا دیررس تفکیک می‌کرد. مدل با زیان کانونی[۳۴] برای مقابله با عدم‌توازن کلاسی، روی ۱,۱۷۵ بررسی کنتراست‌دار شکمی (یک بیمارستان) آموزش و روی ۲۱۵ بررسی خارجی از پنج بیمارستان دیگر ارزیابی شد؛ داده فاقد فاز بدون‌کنتراست بود. دقت درون‌سازمانی با مدل دومرحله‌ای به ۰/۹۸۳ رسید (در برابر ۰/۹۱۷ برای مدل تک‌مرحله‌ای چهارکلاسه)؛ دقت کلی روی داده‌ی خارجی ۰/۹۹۱ بود و حساسیت به‌تفکیک فاز میان ۰/۹۵۱ (شریانی زودرس) و ۰/۹۹۵ (وریدی باب و تأخیری) قرار داشت.

آناند و همکاران [۴۳] برچسب‌های ضعیف[۳۵] را مستقیماً از سرآیند DICOM و نام فایل استخراج کردند تا نیاز به حاشیه‌نویسی دستی را دور بزنند، هرچند این روش برچسب‌هایی نویزی و گاه نادرست

[۳۱] Compound scaling
[۳۲] Shared-weight
[۳۳] Inter-phase attention
[۳۴] Focal loss
[۳۵] Weak labels

تولید می‌کند. با انتخاب هر برش دهم (به دلیل افزونگی اطلاعات میان برش‌های مجاور)، ۳۹۵ بررسی برای توازن پنج فاز انتخاب و ۲,۷۱۹ برش برای آموزش و ۶۸۹ برش برای اعتبارسنجی به دست آمد؛ آموزش نهایی روی زیرمجموعه‌ای کوچک از ۳۱۶ بررسی با برچسب ضعیف انجام شد. سه معماری **ResNet34**، VGG19 و DenseNet121 مقایسه شدند و شبکه‌ی باقیمانده (ResNet34) با دقت ۰/۹۹ روی همین مجموعه‌داده‌ی کوچک و ضعیف‌برچسب، بهترین عملکرد را نشان داد.

رویکرد سوم تنها یک نماینده دارد و ارزش آن بیش از عدد گزارش‌شده‌اش، در بازتعریف مسئله است. محمدرحیموف و همکاران [۳۵]، با استفاده از ۸۲,۶۹۰ بررسی سی‌تی از ۱۷ مرکز، به‌جای طبقه‌بندی به کلاس‌های گسسته، *زمان سپری‌شده از تزریق* را به‌صورت یک کمیت پیوسته رگرسیون کردند. مزیت این صورت‌بندی آن است که مرزهای فاز دیگر تعریف‌های قراردادی نیستند بلکه آستانه‌هایی روی یک محور پیوسته‌اند؛ در نتیجه مدل می‌تواند فاز شریانی زودرس را از دیررس تفکیک کند و حتی فاز میانی‌ای را که در تقسیم‌بندی متعارف جایی ندارد شناسایی کند. دقت روی سی‌تی شکمی ۰/۹۳۳ بود، و پس از تنظیم‌دقیق با تنها ۱۰۰ نمونه‌ی برچسب‌خورده، AUC روی سی‌تی قفسه‌سینه از ۰/۷۷۶ به ۰/۹۹۹ جهش کرد؛ شاهدی بر این‌که افت برون‌حوزه‌ای در این مسئله عمدتاً یک مسئله‌ی کالیبراسیون است، نه یک مسئله‌ی بازنمایی.

سه مطالعه‌ی رویکرد نخست ([۳۶، ۳۷، ۳۸]) یک وابستگی مشترک دارند: بخش‌بندی اندام با یک مدل از پیش‌آموزش‌دیده، عملاً همیشه TotalSegmentator. از میان تمام نه مطالعه‌ی این پیمایش، تنها چهار مورد کد منبع خود را منتشر کرده‌اند (جدول ۲–۲): دو مورد از رویکرد نخست ([۳۶، ۳۷]) و دو مورد از رویکرد دوم ([۳۹، ۴۰]). سه مجموعه‌داده در این پیمایش پرکاربردترین‌اند: WAW-TACE [۳۴] (۲۳۳ بیمار، ۸۵۴ بررسی چندفازی کبدی)، VinDr-Multiphase [۹] (۲۶۵ بیمار، ۱,۱۸۸ بررسی)، و C4KC-KiTS [۴۴] (۲۱۰ بیمار، ۴۰۸ بررسی، بدون فاز وریدی). این سه مجموعه در پوشش تشریحی (شکم، شکم–لگن، قفسه‌سینه–شکم–لگن) و در نام‌گذاری فاز تأخیری (که در VinDr-Multiphase با برچسب "Other" و در C4KC-KiTS با برچسب "Late" ثبت شده) ناهمگن‌اند؛ ناهمگنی‌ای که ارزیابی جامعیت مدل‌های تشخیص فاز را ضروری می‌سازد.

جدول ۲–۲ این نه مطالعه را کنار هم می‌گذارد. ستون «رویکرد» جایگاه هر مطالعه را در سه‌بندی بالا مشخص می‌کند، و «معیار اصلی» نشان می‌دهد هر مطالعه ادعای برتری خود را روی کدام سنجه بنا کرده است؛ نکته‌ای که بدون آن، مقایسه‌ی ستون‌های عددی گمراه‌کننده می‌شود، چون مطالعه‌ای که AUC گزارش می‌کند و مطالعه‌ای که F1 گزارش می‌کند عملاً دو چیز متفاوت را بهینه کرده‌اند. مهم‌ترین ویژگی این جدول، تفکیک ستون‌های ارزیابی **درون‌سازمانی** از **برون‌سازمانی** است: تنها با کنار هم گذاشتن این دو ستون است که الگوی مرکزی این ادبیات دیده می‌شود.

جدول ۲-۲: مدل‌های تشخیص فاز کنتراست. کد فاز: ۰ بدون‌کنتراست، ۱ شریانی (۱الف زودرس، ۱ب دیررس)، ۲ وریدی باب، ۳ تأخیری، ۴ فازهای اختصاصی دیگر (شریان ریوی، اورگرافیک). ستون «فازهای داده‌ی آموزش» مجموعه‌ی کلاس‌هایی است که مدل تشخیص می‌دهد؛ چون این مجموعه میان مطالعات یکسان نیست، ارقام ستون‌های عددی تنها درون هر سطر معنا دارند و مقایسه‌ی مستقیم میان سطرها معتبر نیست. همه‌ی مقادیر F1، دقت، حساسیت و AUC در بازه‌ی صفر تا یک گزارش شده‌اند؛ ✓یعنی کد منبع در دسترس عمومی است. Segment-and-Classify هیچ ارزیابی درون‌سازمانی گزارش نمی‌کند (آموزش تنها روی WAW-TACE و هر دو مجموعه‌ی ارزیابی بیرونی‌اند)؛ بازه‌ها کمینه و بیشینه‌ی F1 به‌تفکیک فازند و کمینه در هر دو مورد متعلق به فاز تأخیری است. در Hierarchical CNN سه سطح تجمیع پیاپی گزارش شده و رقم ۱/۰۰ تنها در سطح کل بررسی و پس از رأی‌گیری میان حجم‌ها به دست آمده است. در Two-Step ResNet داده اصلاً کلاس بدون‌کنتراست ندارد؛ بنابراین دقت برون‌سازمانی بالاتر از درون‌سازمانی آن را باید با همین قید خواند و نه به‌عنوان شاهدی بر تعمیم‌پذیری بهتر. در Injection-Time Regression، AUC برون‌سازمانی پیش و پس از تنظیم‌دقیق با تنها ۱۰۰ نمونه‌ی برچسب‌خورده روی حوزه‌ی جدید (سی‌تی قفسه‌سینه) گزارش شده است.

روش (مرجع)	سال	رویکرد	وظیفه و اندام	فازهای داده‌ی آموزش	معیار اصلی	درون‌سازمانی	برون‌سازمانی	کد
Segment-and-Classify [۳۶]	۲۰۲۵	یکم	طبقه‌بندی فاز؛ شکم (WAW-TACE کبدی)	۰، ۱، ۲، ۳	F1	—	VinDr: ۰/۷۱۸–۰/۹۹۴ C4KC: ۰/۹۳۵–۰/۹۸۵	✓
Interpretable XGBoost [۳۷]	۲۰۲۴	یکم	طبقه‌بندی فاز؛ شکم (۷۳۹ بررسی استنفورد)	۰، ۱، ۲، ۳	F1	دقت: ۰/۹۲۳ F1: ۰/۹۰۷	دقت: ۰/۹۰۱ F1: ۰/۸۲۶	✓
5-Phase Tree Classifier [۳۸]	۲۰۲۴	یکم	طبقه‌بندی فاز + تشخیص حاجب خوراکی؛ شکم و قفسه‌سینه	۰، ۱، ۲، ۴ (شریان ریوی و اورگرافیک)	AUC	۰/۹۹۱–۰/۹۹۸	۰/۹۷۳	×
EfficientNet-B4 [۳۹]	۲۰۲۲	دوم	تشخیص دودویی وجود کنتراست؛ سر و گردن، سپس قفسه‌سینه	۰ در برابر «کنتراست‌دار» (بدون تفکیک)	AUC	سر و گردن: ۰/۹۹۶ قفسه‌سینه: ۱/۰۰	سر و گردن: ۱/۰۰ قفسه‌سینه: ۰/۹۸۰	✓
Random-Sampling CNN [۴۰]	۲۰۲۲	دوم	طبقه‌بندی فاز؛ شکم (۸۳۰ بررسی)	۰، ۱، ۲، ۳	F1	۰/۹۲۱	CPTAC: ۰/۷۶۸ LiTS: ۰/۸۶۹	✓
Hierarchical CNN [۴۱]	۲۰۲۲	دوم	طبقه‌بندی فاز؛ کبد (HCFMUSP)	۰، ۱، ۲، ۳	دقت	برش: ۰/۹۴۶ حجم: ۰/۹۸ بررسی: ۱/۰۰	—	×

ادامه در صفحه‌ی بعد

ادامه‌ی جدول ۲-۲ از صفحه‌ی پیش

روش (مرجع)	سال	رویکرد	وظیفه و اندام	فازهای داده‌ی آموزش	معیار اصلی	درون‌سازمانی	برون‌سازمانی	کد
Two-Step ResNet [۴۲]	۲۰۲۵	دوم	طبقه‌بندی زیرفازهای کنتراست‌دار؛ شکم	۱الف، ۱ب، ۲، ۳ **بدون ۰**	دقت	دومرحله‌ای: ۰/۹۸۳ تک‌مرحله‌ای: ۰/۹۱۷	دقت کلی: ۰/۹۹۱ حساسیت: ۰/۹۵۱–۰/۹۹۵	×
Weak-Label ResNet34 [۴۳]	۲۰۲۳	دوم	طبقه‌بندی فاز با برچسب ضعیف DICOM؛ شکم	پنج کلاس فاز، شامل ۰	دقت	ResNet34: ۰/۹۹ VGG19: ۰/۹۷	—	×
Injection-Time Regression [۳۵]	۲۰۲۲	سوم	رگرسیون زمان پس از تزریق؛ شکم و قفسه‌سینه (۱۷ مرکز)	پیوسته، بدون کلاس گسسته	دقت / AUC	۰/۹۳۳	پیش از تنظیم: ۰/۷۷۶ پس از تنظیم: ۰/۹۹۹	×

آن‌چه این ادبیات روشن می‌کند، سه نکته است. نخست، تشخیص فاز از روی محتوای تصویر مسئله‌ای حل‌شده به نظر می‌رسد: دقت‌های گزارش‌شده در ارزیابی درون‌سازمانی غالباً از ۰/۹۵ بالاترند. دوم، همین ارقام در ارزیابی برون‌سازمانی به‌طور محسوسی افت می‌کنند؛ افت F1 از ۰/۹۲۱ به ۰/۷۶۸ در [۴۰]، و افت F1 از ۰/۹۰۷ به ۰/۸۲۶ در [۳۷]، دو نمونه‌ی گویای آن‌اند. استثنای ظاهری این الگو، مطالعه‌ی [۴۲] است که دقت برون‌سازمانی بالاتری از درون‌سازمانی گزارش می‌کند؛ اما مجموعه‌ی کلاس‌های این مطالعه با بقیه یکی نیست (چهار زیرفاز کنتراست‌دار، بدون کلاس بدون‌کنتراست) و بنابراین ارقامش با سایر سطرها هم‌سنگ نیست. نمی‌توان از این تفاوت نتیجه گرفت که مسئله‌ی آن ساده‌تر بوده است: حذف کلاس بدون‌کنتراست، آسان‌ترین تمایز مسئله را برمی‌دارد اما تمایزهای باقی‌مانده (شریانی زودرس در برابر دیررس، و وریدی در برابر تأخیری) دقیقاً ظریف‌ترین بخش مسئله‌اند. آن‌چه می‌توان گفت این است که ترکیب کلاس‌ها متفاوت است و مقایسه‌ی مستقیم را بی‌اعتبار می‌کند. پس آن‌چه در عمل نامطمئن است، نه دقت مطلق مدل‌ها، بلکه تعمیم‌پذیری آن‌ها به داده‌ی مرکز جدید است؛ یعنی همان شرایطی که هر کاربرد عملی روی داده‌ی یک مرکز تازه با آن روبه‌روست. سوم، یک‌سوم روش‌های موجود پیش‌نیاز سنگینی دارند: وابستگی به یک مدل بخش‌بندی اندام از پیش‌آموزش‌دیده، که خود عمدتاً روی فاز کنتراست‌دار آموزش دیده است. برای کاربردی که هدفش پردازش فاز بدون‌کنتراست است، این وابستگی یک حلقه‌ی وارونگی روش‌شناختی ایجاد می‌کند: ابزاری که قرار است فاز بدون‌کنتراست را شناسایی کند، خود به مدلی وابسته است که عمدتاً روی فاز کنتراست‌دار آموزش دیده است.

۲-۵ هم‌ترازسازی تصویر بین‌فازی سی‌تی

تعریف مسئله

تراز فضایی میان فازهای مختلف یک بررسی سی‌تی چندفازی[۳۶]، پیش‌نیاز بسیاری از کاربردهای بالینی است. در تشخیص و مرحله‌بندی کارسینوم سلول کبدی، دستورعمل‌های بالینی مانند EASL [۵] و مرورهای جامع این بیماری [۶] صراحتاً بر ترکیب اطلاعات فاز شریانی و وریدی برای تشخیص افزایش کنتراست و شست‌وشوی ضایعه تکیه می‌کنند؛ این ترکیب تنها زمانی معتبر است که دو فاز به‌طور دقیق بر هم منطبق باشند. هر جابه‌جایی باقی‌مانده، ناشی از تنفس، حرکت روده یا تغییر وضعیت بیمار میان دو اسکن، می‌تواند یک ضایعه را در یک فاز از دید مدل یا رادیولوژیست پنهان کند. هم‌ترازسازی تصویر به‌طور صوری، مسئله‌ی یافتن یک تبدیل هندسی T است که یک تصویر متحرک[۳۷] را به بهترین شکل بر یک تصویر ثابت[۳۸] منطبق کند؛ چالش مضاعف در هم‌ترازسازی بین‌فازی سی‌تی شکمی آن است که تزریق ماده‌ی حاجب، رابطه‌ی آماری میان شدت روشنایی دو تصویر را به‌شکل ناهمگن در فضا تغییر می‌دهد: عروق و پارانشیم پرخون کبد در فاز شریانی روشن‌تر می‌شوند، در حالی که استخوان، چربی و بسیاری از بافت‌های نرم دیگر تقریباً بدون تغییر باقی می‌مانند.

معیارهای ارزیابی

اطلاعات متقابل[۳۹] و نسخه‌ی بهنجارشده‌ی آن[۴۰] معیارهای آماری‌اند که وابستگی مشترک توزیع شدت روشنایی دو تصویر را می‌سنجند، بدون فرض رابطه‌ی خطی میان آن‌ها. این معیارها هم به‌عنوان تابع هزینه‌ی بهینه‌سازی در حین هم‌ترازسازی و هم به‌عنوان شاخص کیفیت پس از هم‌ترازسازی به کار می‌روند، و پایه‌ی معیار تراز در بسیاری از روش‌های کلاسیک ([۴۵، ۴۶، ۴۷]) و ابزارهایی مانند elastix و SimpleITKاند.

همبستگی متقابل نرمال‌شده[۴۱] شباهت خطی شدت روشنایی یا گرادیان دو تصویر را می‌سنجد. این معیار پایه‌ی SyN [۴۸] و توصیف‌گرهای ساختاری مانند MIND [۴۹] و DEEDS [۵۰] است.

خطای هم‌ترازی هدف[۴۲] میانگین فاصله‌ی باقی‌مانده میان نشانه‌های آناتومیک متناظر[۴۳] پس از

[۳۶] Multi-phase CT
[۳۷] Moving image
[۳۸] Fixed image
[۳۹] Mutual Information (MI)
[۴۰] Normalised Mutual Information (NMI)
[۴۱] Normalised Cross-Correlation (NCC)
[۴۲] Target Registration Error (TRE)
[۴۳] Anatomical landmarks

هم‌ترازسازی را اندازه می‌گیرد؛ این معیار مستقیم‌ترین سنجه‌ی دقت هندسی است و در محک‌هایی مانند Learn2Reg [۵۱] برای گزارش دقت روش‌هایی مانند DEEDS و TransMorph به کار می‌رود.

با این حال، هر دو خانواده‌ی معیار محدودیت مهمی دارند. برچسب‌گذاری دستی نشانه‌های آناتومیک برای محاسبه‌ی TRE پرهزینه و زمان‌بر است و تنها برای زیرمجموعه‌ی کوچکی از داده‌ها (عمدتاً محک‌های عمومی مغزی یا ریوی) در دسترس است؛ به همین دلیل، بسیاری از مطالعات هم‌ترازسازی تصویر، از جمله VoxelMorph [۵۲]، TransMorph [۵۳] و DEEDS [۵۰]، به‌جای TRE، از هم‌پوشانی ضریب Dice (تعریف‌شده در بخش ۲-۲) میان نقاب‌های تشریحی پس از هم‌ترازسازی، به‌عنوان معیاری جایگزین و در دسترس‌تر استفاده می‌کنند. این جایگزینی خود دو محدودیت دارد: Dice صرفاً هم‌پوشانی ناحیه‌ای را می‌سنجد، نه تناظر نقطه‌به‌نقطه‌ی واقعی، و بنابراین می‌تواند حتی در غیاب تراز دقیق هندسی مقدار نسبتاً بالایی نشان دهد؛ و کیفیت آن کاملاً به دقت نقاب‌های ورودی (معمولاً حاصل یک مدل بخش‌بندی خودکار) وابسته است.

معیارهای شباهت تصویر (MI، NCC) نیز محدودیت مشابهی دارند: از آن‌جا که تنها یک پروکسی غیرمستقیم برای تراز هندسی‌اند، ممکن است در نواحی با تغییر ناهمگن کنتراست (موضوع اصلی این بخش) مقدار گمراه‌کننده‌ای گزارش کنند، حتی وقتی تراز واقعی برقرار نشده باشد.

کارهای پیشین

معیارهای شباهت مبتنی‌بر شدت روشنایی

پایه‌ی نظری هم‌ترازسازی تصویر خودکار چندوجهی را ولز و همکاران [۴۵] گذاشتند. مسئله‌ای که آن‌ها حل کردند این بود: وقتی دو تصویر از دو وجهیت متفاوت می‌آیند، رابطه‌ی میان شدت روشنایی متناظر در آن‌ها نه خطی است و نه از پیش معلوم؛ پس معیارهایی مانند مجموع مربعات تفاوت بی‌معنا می‌شوند. راه‌حل آن‌ها استفاده از **اطلاعات متقابل** بود، کمیتی از نظریه‌ی اطلاعات که میزان کاهش عدم‌قطعیت درباره‌ی یک تصویر را در صورت دانستن دیگری می‌سنجد. مزیت تعیین‌کننده‌ی این معیار آن است که هیچ مدلی برای رابطه‌ی شدت‌ها فرض نمی‌کند؛ تنها فرض می‌کند چنین رابطه‌ای، هرچه باشد، *در سراسر تصویر یکسان* است. همین فرض ظاهراً بی‌ضرر، چنان‌که در ادامه می‌آید، همان‌جایی است که در سی‌تی چندفازی می‌شکند.

استادهولم و همکاران [۴۶] یک ضعف عملی این معیار را برطرف کردند. اطلاعات متقابل خام به اندازه‌ی ناحیه‌ی هم‌پوشانی دو تصویر حساس است: بهینه‌ساز می‌تواند با کوچک‌کردن هم‌پوشانی، مقدار معیار را به‌طور مصنوعی بالا ببرد و به یک راه‌حل بی‌معنا همگرا شود. **اطلاعات متقابل بهنجارشده** با

تقسیم بر آنتروپی مشترک، این وابستگی را حذف می‌کند.

مَتیس و همکاران [۴۷] مسئله‌ی سوم را حل کردند: مشتق‌پذیری. برآورد اطلاعات متقابل از هیستوگرام مشترک، تابعی پله‌ای و غیرمشتق‌پذیر تولید می‌کند که با بهینه‌سازهای مبتنی‌بر گرادیان سازگار نیست. آن‌ها با هموارسازی هیستوگرام از طریق **پنجره‌ی پارزن** با هسته‌ی بی‌اسپلاین، صورتی پیوسته و مشتق‌پذیر از این معیار ساختند که گرادیان تحلیلی دارد. همین فرمول‌بندی است که هنوز هسته‌ی پیاده‌سازی‌های امروزی از جمله elastix [۵۴] و SimpleITK [۵۵] را تشکیل می‌دهد.

مدل‌های تغییر شکل کلاسیک

موازی با تکامل معیار شباهت، مدل‌سازی خود تبدیل هندسی مسیر جداگانه‌ای پیمود. تیریون [۵۶] با الگوریتم **دیمانز** قیاسی از ترمودینامیک ساخت: مرزهای تصویر ثابت را «دیو»هایی تصور کرد که وکسل‌های تصویر متحرک را بر اساس گرادیان محلی شدت روشنایی به سمت خود می‌رانند. میدان جابه‌جایی به‌صورت تکراری و با هموارسازی گاوسی میان تکرارها به‌روزرسانی می‌شود. جذابیت این روش، سادگی و سرعت آن است؛ ضعفش آن‌که پایه‌ی نظری‌اش مستقیماً بر شدت روشنایی خام استوار است و در نتیجه در برابر تغییر کنتراست شکننده می‌ماند.

رواکرت و همکاران [۵۷] رویکرد متفاوتی را بنیان گذاشتند که هنوز پرکاربردترین مدل تغییر شکل *پارامتری* است. در **تغییر شکل آزاد** مبتنی‌بر **بی‌اسپلاین**، به‌جای تخصیص یک بردار جابه‌جایی مستقل به هر وکسل، شبکه‌ای تُنُک از نقاط کنترل روی تصویر گسترده می‌شود و جابه‌جایی هر وکسل با درون‌یابی بی‌اسپلاین مکعبی از نقاط کنترل مجاور محاسبه می‌شود. این کار دو مزیت دارد: تعداد پارامترها به‌شدت کاهش می‌یابد، و هموار‌بودن میدان جابه‌جایی به‌طور ذاتی تضمین می‌شود. تراکم شبکه، موازنه‌ی میان انعطاف‌پذیری و هموار‌بودن را کنترل می‌کند، همان فراپارامتری که در هر کاربرد باید جداگانه تنظیم شود.

اوانتز و همکاران [۴۸] با **SyN** دو ویژگی نظری مهم را افزودند. نخست **تقارن**: به‌جای تغییر شکل دادن تصویر متحرک به سمت ثابت، هر دو تصویر هم‌زمان به سمت یک نقطه‌ی میانی تغییر شکل می‌یابند، به‌طوری‌که نتیجه به انتخاب این‌که کدام تصویر «متحرک» است وابسته نباشد. دوم **دیفئومورفیسم**: تبدیل حاصل هموار، معکوس‌پذیر و دارای معکوس هموار است، که تضمین می‌کند آناتومی در حین تغییر شکل تا نخورد یا پاره نشود؛ قیدی که برای معنادار ماندن تناظر تشریحی ضروری است. SyN از همبستگی متقابل به‌عنوان معیار شباهت استفاده می‌کند و هسته‌ی جعبه‌ابزار ANTs است. در ارزیابی مستقل کلاین و همکاران روی چهار محک مغزی، Dice آن میان ۰/۶۰ تا ۰/۷۷ گزارش شد و به‌عنوان یکی از دو روش برتر آن مقایسه شناخته شد؛ به همین دلیل هنوز مبنای مقایسه‌ی غالب در این حوزه است.

پلوییم و همکاران [۵۸] در مروری جامع، شرایط اعتبار خانواده‌ی اطلاعات متقابل را مستند کردند؛ متز و همکاران [۵۹] این معیارها را به هم‌ترازسازی **گروهی** دنباله‌های پویا از جمله سی‌تی شکمی پویا تعمیم دادند؛ و مورفی و همکاران [۵۱] چارچوبی نیمه‌خودکار برای ساخت استاندارد مرجع مبتنی‌بر نشانه‌های آناتومیک پیشنهاد کردند که ارزیابی دقیق TRE را ممکن می‌سازد.

چرا این خانواده در سی‌تی چندفازی می‌شکند

مشکل بنیادین، همان فرضی است که در آغاز این بخش برجسته شد: خانواده‌ی اطلاعات متقابل فرض می‌کند رابطه‌ی آماری میان شدت روشنایی دو تصویر در سراسر میدان دید *پایدار* است. تزریق ماده‌ی حاجب دقیقاً همین فرض را نقض می‌کند، و آن را به‌شکلی نقض می‌کند که بدترین حالت ممکن است: تغییر، *ناهمگن در فضا* است. آئورت و ورید باب در فاز شریانی صدها واحد HU روشن‌تر می‌شوند، پارانشیم کبد چند ده واحد، و استخوان و چربی تقریباً هیچ. نتیجه آن است که معیار تراز کلی‌نگر، بخش بزرگی از واریانس خود را از تغییر کنتراست می‌گیرد، نه از جابه‌جایی هندسی واقعی. بهینه‌ساز، تصویر را تغییر شکل می‌دهد تا الگوی *شدت* را تطبیق دهد، در حالی که هدف مطلوب تطبیق *آناتومی* است.

روش‌های آگاه از آناتومی

چند خط پژوهشی کوشیده‌اند با واردکردن اطلاعات تشریحی به این مسئله نزدیک شوند. پاپیه‌ژ و همکاران [۶۰] یک منظم‌ساز دوسویه‌ی آگاه از آناتومی معرفی کردند که امکان **حرکت لغزشی** را در مرز اندام‌هایی مانند ریه و کبد فراهم می‌کند؛ یعنی به میدان جابه‌جایی اجازه می‌دهد در سطح تماس دو اندام ناپیوسته باشد، چیزی که منظم‌سازهای هموار متعارف ممنوع می‌کنند. با این حال، معیار تراز در این روش همچنان در سطح کل تصویر محاسبه می‌شود.

دِفوس و همکاران [۶۱] وزن‌دهی آگاه از آناتومی را مستقیماً وارد تابع هزینه‌ی یک شبکه‌ی پیچشی سرتاسر کردند: معیار شباهت همچنان روی کل تصویر محاسبه می‌شود، اما سهم هر ناحیه در جمع نهایی بر اساس نوع بافت آن تغییر می‌کند.

هو و همکاران [۶۲] رادیکال‌تر عمل کردند و به‌دلیل جایگاه روش‌شناختی متمایزشان، جزئیات کارشان را باید صریح کرد. آن‌ها با **نظارت ضعیف**[۴۴] مبتنی‌بر هم‌پوشانی برچسب، مسئله‌ی ناهمگنی شدت روشنایی را به‌کلی دور زدند: در حین آموزش، تابع هزینه اصلاً از شدت روشنایی ساخته نمی‌شود، بلکه از میزان انطباق نقاب‌های تشریحیِ تغییرشکل‌یافته با نقاب‌های تصویر ثابت ساخته می‌شود. شبکه تصویر را به‌عنوان

[۴۴] Weak supervision

ورودی می‌بیند اما هرگز بابت تطبیق شدت‌ها پاداش نمی‌گیرد؛ تنها می‌آموزد میدان جابه‌جایی‌ای تولید کند که برچسب‌ها را بر هم منطبق کند. مزیت این طراحی آن است که در زمان استنتاج هیچ برچسبی لازم نیست. بهای آن سه‌گانه است: نخست، به یک پیکره‌ی آموزشی از جفت‌های برچسب‌خورده نیاز دارد؛ دوم، کیفیت نهایی به کیفیت و پوشش همان برچسب‌ها کران‌دار می‌ماند؛ و سوم، حاصل یک نگاشت *آموخته‌شده* است که انتقالش به مرکز، پروتکل یا آناتومی جدید بدون بازآموزی تضمینی ندارد.

اوکتای و همکاران [۶۳] مسیر سومی رفتند و **پیشین‌های شکل تشریحی**[۴۵] را، که با یک خودرمزگذار از داده‌ی برچسب‌خورده آموخته می‌شوند، به‌عنوان جمله‌ی منظم‌ساز به تابع هزینه‌ی آموزش افزودند؛ یعنی آناتومی نه دامنه‌ی محاسبه را تعیین می‌کند و نه وزن آن را، بلکه فضای راه‌حل‌های پذیرفتنی را محدود می‌کند.

نقطه‌ی مشترک این خط پژوهشی، که در جمع‌بندی این بخش اهمیت می‌یابد، آن است که همگی از آناتومی برای *وزن‌دهی* یا *قید کردن* معیار تراز استفاده می‌کنند، نه برای تعیین *دامنه‌ی فضایی محاسبه‌ی* خود معیار. تفاوت این دو در نگاه اول لفظی به نظر می‌رسد و در حالت حدی (وقتی وزن به صفر میل کند) از نظر ریاضی محو می‌شود، اما در عمل نیست: اطلاعات متقابل از یک *هیستوگرام مشترک* ساخته می‌شود که روی همه‌ی وکسل‌ها انباشته می‌شود. وزنِ کم دادن به روده، سهم آن را در جمع نهایی کاهش می‌دهد اما وکسل‌های آن همچنان در ساخت هیستوگرام شرکت می‌کنند و آن را چندمُدی نگه می‌دارند؛ حذف روده از دامنه، خودِ هیستوگرام را عوض می‌کند. به بیان دیگر، وزن‌دهی سهم یک ناحیه را در جمع کم می‌کند اما آن را از *آمار* حذف نمی‌کند.

یک وابستگی نیز در هر سه این روش‌ها مشترک است و باید صریح بماند: همگی به نقاب تشریحی نیاز دارند، و این نقاب در عمل از یک مدل بخش‌بندی از پیش‌آموزش‌دیده می‌آید. جایگاه این وابستگی اما یکسان نیست. در روش برچسب‌محور [۶۲] نقاب خودِ *تابع هدف* است و هر خطای بخش‌بندی مستقیماً به خطای هم‌ترازی ترجمه می‌شود؛ در روش‌های وزن‌دهی [۶۱، ۶۰] نقاب تنها سهم نسبی نواحی را تغییر می‌دهد و خطای آن اثری تعدیل‌شده دارد.

روش‌های یادگیری‌محور

موازی با این خط، خانواده‌ای از روش‌ها توسعه یافت که به‌جای بهینه‌سازی تکراری برای هر جفت تصویر، یک شبکه را یک‌بار آموزش می‌دهند تا میدان جابه‌جایی را در یک گذر پیش‌رو پیش‌بینی کند؛ کاهشی از چند دقیقه به چند ثانیه.

VoxelMorph [۵۲] الگوی پایه‌ی این خانواده را تثبیت کرد: یک رمزگذار—رمزگشای پیچشی سبک

[۴۵] Anatomical shape priors

U-Net که جفت تصویر را می‌گیرد و میدان جابه‌جایی تولید می‌کند، به‌همراه یک **لایه‌ی تبدیل‌گر فضایی** که تصویر متحرک را با این میدان تغییر شکل می‌دهد. چون این لایه مشتق‌پذیر است، کل شبکه را می‌توان به‌صورت *بدون‌نظارت* و تنها با کمینه‌کردن اختلاف تصویر تغییر شکل‌یافته با تصویر ثابت آموزش داد. روی هشت محک مغزی (۲۵۰ حجم)، Dice برابر ۰/۷۵۳ در حالت بدون‌نظارت و ۰/۷۸ با افزودن نظارت بخش‌بندی به دست آمد، با کارایی زمانی به‌مراتب بهتر از ANTs.

سه محدودیت VoxelMorph سه شاخه‌ی بعدی را پدید آورد. محدودیت *میدان دریافت*: **TransMorph** [۵۳] رمزگذار پیچشی را با یک Swin Transformer جایگزین کرد تا تناظرهای دوربرد را بیابد، و روی وظیفه‌ی OASIS محک Learn2Reg به Dice ۰/۸۶۲ و HD95 برابر ۱/۴۳۱ میلی‌متر رسید. محدودیت *تغییر شکل بزرگ*: **LapIRN** [۶۴] با هرم لاپلاسی، میدان را از مقیاس خشن به ریز پالایش می‌کند و روی OASIS به Dice ۰/۸۰۸ (نسخه‌ی جابه‌جایی) و ۰/۷۶۵ (نسخه‌ی دیفئومورفیک) رسید؛ **شبکه‌های آبشاری بازگشتی** [۶۵] همین ایده را با اعمال مکرر یک شبکه‌ی واحد روی خروجی خودش پیاده کردند. محدودیت *تنظیم فراپارامتر*: **HyperMorph** [۶۶] یک ابرشبکه می‌آموزد که وزن‌های شبکه‌ی هم‌ترازسازی را *به‌عنوان تابعی از* ضریب منظم‌سازی تولید کند، به‌طوری‌که کاربر بتواند این ضریب را در زمان استنتاج و بدون بازآموزی تغییر دهد؛ روی داده‌ی مغزی Buckner40، Dice میان ۰/۷۰ و ۰/۷۴ گزارش شد.

DeepAtlas [۶۷] مسیر دیگری رفت و هم‌ترازسازی و بخش‌بندی را در یک چارچوب نیمه‌نظارتی مشترک آموزش داد: شبکه‌ی بخش‌بندی برچسب تولید می‌کند تا به شبکه‌ی هم‌ترازسازی نظارت بدهد، و شبکه‌ی هم‌ترازسازی برچسب‌ها را میان بیماران منتقل می‌کند تا داده‌ی آموزشی بخش‌بندی را افزون کند.

UniGradICON [۶۸]، به‌عنوان تازه‌ترین گام این مسیر، یک **مدل بنیادین** برای هم‌ترازسازی تصویر است: یک شبکه‌ی واحد روی دوازده مجموعه‌داده‌ی عمومی از آناتومی‌ها و وجهیت‌های مختلف آموزش می‌بیند و ادعا می‌کند بدون تنظیم‌دقیق روی داده‌ی جدید کار می‌کند. تابع هزینه‌ی آن ترکیبی از همبستگی متقابل محلی و یک جمله‌ی **پایداری معکوس گرادیان** است که معکوس‌پذیری تبدیل را تشویق می‌کند. عملکرد آن به‌شدت به آناتومی وابسته است: Dice برابر ۰/۷۶۲ روی مغز (HCP) اما تنها ۰/۴۸۳ روی شکم (L2R-Abdomen)، و TRE برابر ۲/۲۶ میلی‌متر روی ریه. همین اختلاف چشمگیر میان مغز و شکم، دشواری نسبی هم‌ترازسازی شکمی را کمّی می‌کند. رفتار این مدل در برابر جابه‌جایی حوزه‌ای ناشی از *فاز کنتراست* هنوز مشخصه‌یابی نشده است.

توصیف‌گرهای ساختاری مستقل از وجهیت

مسیر مفهومی متفاوتی برای دور زدن ناپایداری شدت روشنایی وجود دارد: به‌جای مقایسه‌ی *مقدار* شدت، *الگوی محلی* آن مقایسه شود. **MIND** [۴۹] این ایده را عملیاتی کرد. برای هر وکسل، به‌جای مقدار خام، برداری محاسبه می‌شود که فاصله‌ی وصله‌ی پیرامون آن وکسل را با وصله‌های همسایه‌اش کد می‌کند؛ یعنی **خودشباهت** محلی. اگر کل تصویر با یک تبدیل یکنوای شدت روشنایی تغییر کند، این الگوی نسبی تقریباً دست‌نخورده می‌ماند. توصیف‌گر حاصل، شباهتی مستقل از وجهیت فراهم می‌کند و مسئله را از «تطبیق شدت‌ها» به «تطبیق ساختارها» منتقل می‌کند.

بر همین پایه، **DEEDS** [۵۰] توصیف‌گر MIND را با **بهینه‌سازی گسسته‌ی میدان تصادفی مارکوف** ترکیب کرد. به‌جای بهینه‌سازی پیوسته و مبتنی‌بر گرادیان (که در کمینه‌های محلی گیر می‌کند) فضای جابه‌جایی گسسته‌سازی می‌شود و بهترین ترکیب جابه‌جایی‌ها با انتقال پیام روی یک گراف یافت می‌شود. این ترکیب، DEEDS را به یکی از دقیق‌ترین روش‌های هم‌ترازسازی شکمی در محک Learn2Reg بدل کرده است: Dice برابر ۰/۷۷۵ در هم‌ترازسازی درون‌وجهی MR و ۰/۶۳۶ در هم‌ترازسازی بین‌وجهی CT—MR. افت چشمگیر میان این دو رقم نشان می‌دهد حتی توصیف‌گرهای ساختاری نیز در برابر تغییر وجهیت کاملاً مصون نیستند.

سه سرگروه و آن‌چه در آن‌ها مشترک است

سه خانواده‌ی بالا، هرچه در جزئیات پیاده‌سازی متفاوت باشند، به سه پاسخ متمایز به یک پرسش واحد فرو می‌کاهند: معیار تراز از چه چیزی ساخته شود؟ شکل ۲-۱ یک نماینده‌ی شاخص از هر خانواده را کنار هم می‌گذارد. نماینده‌ی خانواده‌ی نخست، ترکیب تغییر شکل آزاد بی‌اسپلاین [۵۷] با اطلاعات متقابل مشتق‌پذیر [۴۷] است، همان ترکیبی که هسته‌ی elastix [۵۴] و SimpleITK [۵۵] است. نماینده‌ی خانواده‌ی دوم MIND [۴۹] و بسط آن DEEDS [۵۰] است. نماینده‌ی خانواده‌ی سوم VoxelMorph [۵۲] و جانشین ترانسفورمری آن TransMorph [۵۳] است.

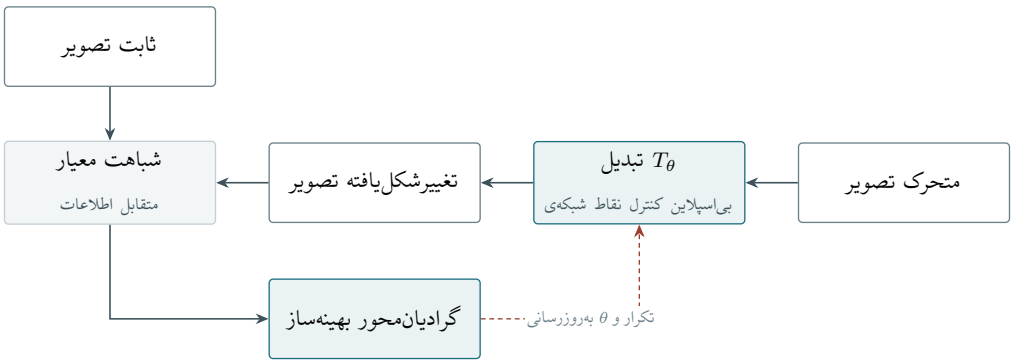
انتخاب این سه به‌عنوان سرگروه دلخواه نیست: هر سه، الگویی را تثبیت کرده‌اند که بقیه‌ی روش‌های همان خانواده صرفاً آن را پالایش می‌کنند. LapIRN، HyperMorph و شبکه‌های آبشاری همگی روی همان اسکلت پانل (پ) بنا شده‌اند و تنها یکی از سه محدودیت VoxelMorph را هدف می‌گیرند؛ و UniGradICON همان اسکلت را با داده‌ی به‌مراتب بزرگ‌تر و یک جمله‌ی منظم‌ساز اضافی آموزش می‌دهد.

آن‌چه هر سه پانل در آن مشترک‌اند، و در جمع‌بندی این بخش اهمیت می‌یابد، این است که در هر

سه، معیار تراز روی *کل* میدان دید تعریف می‌شود؛ چه به‌صورت جمع روی همه‌ی وکسل‌ها (پانل الف)، چه به‌صورت جمع روی همه‌ی بردارهای توصیف‌گر (پانل ب)، و چه به‌صورت زیانی که روی کل تصویر تغییرشکل‌یافته محاسبه می‌شود (پانل پ).

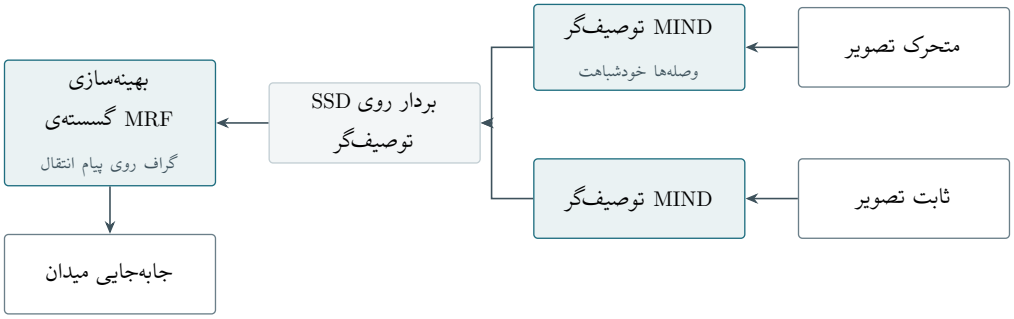
(الف) خانواده‌ی کلاسیک شدت‌محور — SimpleITK / elastix

بدون مرحله‌ی آموزش؛ برای هر جفت تصویر یک بهینه‌سازی تکراری جداگانه اجرا می‌شود



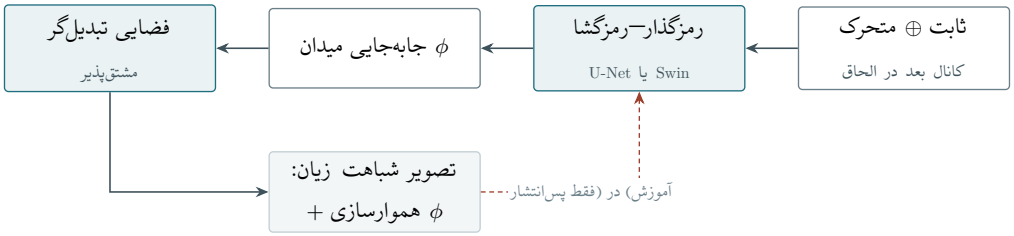
(ب) توصیف‌گرهای ساختاری — DEEDS / MIND

به‌جای *مقدار* شدت روشنایی، *الگوی محلی* آن مقایسه می‌شود



(پ) خانواده‌ی یادگیری‌محور — TransMorph / VoxelMorph

آموزش یک‌بار روی کل مجموعه؛ استنتاج در یک گذر پیش‌رو



شکل ۲-۱: سه سرگروه روش‌شناختی هم‌ترازسازی تصویر. تفاوت بنیادی سه خانواده در این است که معیار تراز از چه چیزی ساخته می‌شود: (الف) از *مقدار* شدت روشنایی روی کل میدان دید؛ (ب) از *الگوی محلی* شدت روشنایی، که در برابر نگاشت یکنوای شدت پایدار است؛ (پ) از یک نگاشت *آموخته‌شده* که میدان جابه‌جایی را در یک گذر پیش‌رو پیش‌بینی می‌کند. نکته‌ی مشترک هر سه آن است که معیار تراز، در هر سه حالت، روی *کل* میدان دید تعریف می‌شود.

هم‌ترازسازی تصویر چندفازی شکمی

برخلاف آن‌چه از حجم ادبیات بالا برمی‌آید، مسئله‌ی مشخصِ هم‌ترازسازی *بین‌فازی* سی‌تی شکمی تقریباً بدون بررسی مانده است. تنها استثنای قابل‌توجه، کار پارک، فیشمن و یول [۳] است که مستقیماً هم‌ترازسازی فاز شریانی به وریدی را هدف گرفت.

رویکرد آن‌ها ترکیبی از دو ایده‌ی بالاست: تغییر شکل **وابسته به جهت**، که به حرکت لغزشی در مرز اندام‌ها اجازه می‌دهد (در خط پاپیهژ)، به همراه خودشباهت محلی برای مقاوم‌سازی در برابر تفاوت کنتراست (در خط MIND). ارزیابی روی داده‌ی سی‌تی نازک‌برش بیماران آدنوکارسینوم پانکراس و اهداکنندگان کلیه انجام شد و کانتور دستی اندام‌ها با میدان جابه‌جایی منتقل و با کانتور دستی تصویر مقصد مقایسه شد.

نتایج، ارزشمندترین نقطه‌ی مرجع کمّی موجود برای این مسئله‌اند. روش پیشنهادی آن‌ها به Dice برابر ۰/۸۹۰ برای پانکراس و ۰/۹۸۵ برای کبد رسید، با فاصله‌ی سطحی ۰/۸۵ و ۰/۷۸ میلی‌متر، در کمتر از یک دقیقه محاسبه. در همان ارزیابی، SyN به ۰/۸۷۳ و ۰/۹۵۳، دیمانز دیفئومورفیک به ۰/۸۷۲ و ۰/۹۳۵، و MIND به ۰/۸۶۲ و ۰/۹۳۹ رسیدند.

دو نکته از این ارقام بیرون می‌آید. نخست، تفاوت میان کبد (بالای ۰/۹۳ برای همه‌ی روش‌ها) و پانکراس (زیر ۰/۹۰ برای همه) نشان می‌دهد دشواری هم‌ترازسازی بین‌فازی، مانند دشواری بخش‌بندی در بخش ۲-۲، روی اندام‌های کوچک و کم‌کنتراست متمرکز است. دوم، این‌که یک روش مبتنی‌بر خودشباهت محلی از SyN مبتنی‌بر همبستگی متقابل پیشی می‌گیرد، تأیید تجربی همان استدلالی است که در بالا مطرح شد: در حضور تغییر ناهمگن کنتراست، معیارهای ساختاری بر معیارهای شدت‌محور برتری دارند.

زیرساخت نرم‌افزاری

SimpleITK [۵۵] و elastix [۵۴] پرکاربردترین زیرساخت‌های منبع‌باز این حوزه‌اند. یک ویژگی این کتابخانه‌ها از منظر مسئله‌ی این بخش اهمیت دارد: معماری پیمانه‌ای آن‌ها اجازه می‌دهد تبدیل، معیار شباهت و بهینه‌ساز به‌طور مستقل تعریف شوند، و (تعیین‌کننده‌تر) از **نقاب تصویر ثابت** در تعریف معیار پشتیبانی می‌کنند. یعنی می‌توان به کتابخانه گفت معیار شباهت را تنها روی زیرمجموعه‌ای از وکسل‌ها محاسبه کند. یعنی محدودکردن دامنه‌ی محاسبه‌ی معیار، از نظر پیاده‌سازی مانعی ندارد.

جمع‌بندی و جای خالی

کنار هم گذاشتن این پیشینه، تصویری دقیق‌تر از آن‌چه در نگاه اول به نظر می‌رسد به دست می‌دهد.

معیارهای کلاسیک خانواده‌ی اطلاعات متقابل در سطح کل تصویر تعریف می‌شوند و بنابراین در برابر تغییر ناهمگن کنتراست شکننده‌اند. روش‌های یادگیری‌محور سریع‌ترند اما تقریباً همگی روی محک‌های مغزی توسعه یافته‌اند و (چنان‌که افت Dice از ۰/۷۶۲ به ۰/۴۸۳ در UniGradICON نشان می‌دهد) انتقالشان به شکم بدیهی نیست. توصیف‌گرهای ساختاری مانند MIND و DEEDS مقاوم‌ترین گزینه‌اند، و کار پارک و همکاران [۳] تأیید می‌کند که همین خانواده در هم‌ترازسازی بین‌فازی شکمی بهترین عملکرد را دارد.

جای خالی، از این رو، این نیست که کسی هم‌ترازسازی بین‌فازی شکمی انجام نداده باشد؛ پارک و همکاران [۳] انجام داده‌اند. جای خالی دقیق‌تر و باریک‌تر است: همه‌ی روش‌های موجود؛ چه آن‌ها که آناتومی را برای *وزن‌دهی* به کار می‌گیرند ([۶۰، ۶۱، ۶۳]) و چه آن‌ها که معیار را *مقاوم‌تر* می‌سازند ([۴۹، ۵۰، ۳])؛ معیار تراز را همچنان روی *کل* میدان دید محاسبه می‌کنند. هیچ‌یک *دامنه‌ی فضایی محاسبه‌ی* معیار را از پیش و بر مبنای دانش تشریحیِ این‌که کدام ساختارها در برابر تزریق ماده‌ی حاجب پایدارند، محدود نمی‌کند. تفاوت میان «وزن کمتر دادن به روده» و «اصلاً محاسبه‌نکردن معیار روی روده» ظریف اما پیامددار است، و همین تمایز، باریک‌ترین جای خالی این حوزه است.

افزون بر این، نکته‌ی مشترک دیگری این ادبیات را به مسئله‌ی گسترده‌تر این فصل گره می‌زند. در سراسر ادبیات سنتز و هم‌ترازسازی، کیفیت هم‌ترازی جفت‌های آموزشی هیچ‌گاه *اندازه‌گیری و گزارش* نشده است. مقالات یا می‌گویند داده را هم‌تراز کرده‌اند (اغلب با ذکر نام یک ابزار و بدون هیچ عددی) یا اصلاً به آن اشاره نمی‌کنند. پیامد این سکوت آن است که خواننده نمی‌داند هر مدل با داده‌ای به چه کیفیتی آموزش دیده است؛ و چون هیچ عدد مشترکی وجود ندارد، مقایسه‌ی ارقام سنتز میان مقالات، سهم *مدل* را از سهم *کیفیت داده* تفکیک نمی‌کند. به بیان دیگر، در این ادبیات هم‌ترازسازی همواره *هدف* است و هیچ‌گاه به‌عنوان *معیار پذیرش داده* برای یک وظیفه‌ی پایین‌دستی به کار نرفته است؛ کاربردی که به یک آستانه‌ی کمّی نیاز دارد و چنین آستانه‌ای در ادبیات موجود تعریف نشده است.

جدول ۲-۳ روش‌هایی را که مقدار عددی قابل‌مقایسه گزارش کرده‌اند کنار هم می‌گذارد. روش‌های بنیادین دهه‌ی ۱۹۹۰ و اوایل ۲۰۰۰ (اطلاعات متقابل، نسخه‌ی بهنجارشده‌ی آن، دیمانز و تغییر شکل آزاد) عمداً در جدول نیامده‌اند: آن‌ها پیش از تثبیت محک‌های مشترک منتشر شده‌اند و عددی که بتوان با سطرهای جدول سنجید ندارند؛ جایگاه روش‌شناختی‌شان در متن بالا تشریح شد.

دو ستون این جدول عمداً افزوده شده‌اند. ستون «**وظیفه‌ی معرفی**» نشان می‌دهد هر روش در اصل برای

چه آناتومی و چه نوع مسئله‌ای طراحی شده است؛ ستون «**معیار بهینه‌سازی**» تابع شباهتی را مشخص می‌کند که روش هنگام هم‌ترازسازی آن را کمینه یا بیشینه می‌کند؛ یعنی همان چیزی که روش واقعاً روی آن جلو می‌رود. کنار هم گذاشتن این دو با ستون مقادیر، سه واقعیت را آشکار می‌کند. نخست، تنها یک سطر از این جدول ([۳]) برای سی‌تی شکمی *چندفازی* معرفی شده است؛ بقیه روی محک‌های مغزی، ریوی یا شکمی تک‌فاز طراحی و سنجیده شده‌اند. دوم، معیار بهینه‌سازی تقریباً همیشه یا از خانواده‌ی اطلاعات متقابل است یا از خانواده‌ی همبستگی متقابل، و هر دو بر فرض پایداری رابطه‌ی شدت روشنایی در سطح کل تصویر بنا شده‌اند. سوم، میان معیاری که هر روش *بهینه می‌کند* و معیاری که با آن *ارزیابی می‌شود* ناهم‌خوانی نظام‌مندی وجود دارد: بهینه‌سازی تقریباً همیشه روی یک معیار شباهت شدت روشنایی انجام می‌شود، اما گزارش تقریباً همیشه با Dice نقاب‌های اندام است. این ناهم‌خوانی دو پیامد دارد که برای خواندن این جدول تعیین‌کننده‌اند. **پیامد نخست، ناعادلانه‌بودن مقایسه‌ی میان سطرهاست:** روش‌هایی که در آموزش از هم‌پوشانی برچسب نظارت می‌گیرند (مانند نسخه‌ی نیمه‌نظارتی VoxelMorph یا DeepAtlas) عملاً روی همان کمیتی آموزش دیده‌اند که با آن سنجیده می‌شوند، در حالی که روش‌های صرفاً شدت‌محور چنین مزیتی ندارند؛ پس اختلاف Dice میان این دو گروه، لزوماً اختلاف کیفیت هم‌ترازی نیست. **پیامد دوم، محدودیت خودِ Dice به‌عنوان سنجه‌ی هم‌ترازی است:** Dice تنها هم‌پوشانی *ناحیه‌ای* را می‌سنجد و نه تناظر *نقطه‌به‌نقطه* را. یک میدان جابه‌جایی می‌تواند سایه‌ی بیرونی دو اندام را تقریباً کامل بر هم بیندازد اما ساختارهای درونی همان اندام را جابه‌جا کند؛ در چنین حالتی Dice بالا می‌ماند در حالی که تناظر تشریحی برقرار نیست. پیامد عملی آن است که Dice به‌تنهایی سنجه‌ی کافی برای هم‌ترازی نیست و باید در کنار معیارهای حساس به مرز (مانند فاصله‌ی سطحی) و معیارهای سازگاری فیزیکی تغییرشکل خوانده شود.

جدول ۲-۳: روش‌های منتخب هم‌ترازسازی تصویر: وظیفه‌ای که روش برای آن معرفی شده، داده و فاز کنتراستِ آن داده، معیاری که روش *بهینه می‌کند*، و مقداری که *گزارش می‌کند*. کد فاز: ۱ شریانی، ۲ وریدی باب؛ «تک‌فاز» یعنی داده‌ی توسعه تنها یک فاز دارد و مسئله‌ی بین‌فازی در آن مطرح نیست؛ «بدون فاز» یعنی وجهیت داده اصلاً کنتراست تزریقی ندارد (مانند MRI مغزی). همه‌ی مقادیر Dice در بازه‌ی صفر تا یک گزارش شده‌اند؛ HD95 و TRE برحسب میلی‌متر؛ ✓یعنی کد در دسترس عمومی است. روش‌های بنیادین پیش از ۲۰۰۵ (اطلاعات متقابل و نسخه‌ی بهنجارشده‌ی آن، دیمانز، تغییر شکل آزاد) در جدول نیامده‌اند، چون پیش از تثبیت محک‌های مشترک منتشر شده‌اند و عدد قابل‌مقایسه‌ای ندارند؛ جایگاهشان در متن تشریح شد. عدد SyN از ارزیابی مستقل کلاین و همکاران (۲۰۰۹) گرفته شده، چون مقاله‌ی اصلی مقدار دقیق گزارش نمی‌کند. مقاله‌ی MIND هیچ مقدار مطلقی گزارش نمی‌کند و تنها تفاوت معنادار آماری در TRE را ذکر می‌کند؛ ارقام آن روی داده‌ی شکمی چندفازی از [۳] گرفته شده است. در سطر پارک و همکاران، فاصله‌ی سطحی متناظر ۰٫۸۵ و ۰٫۷۸ میلی‌متر است و در همان ارزیابی SyN به ۰٫۸۷۳ و ۰٫۹۵۳ و دیمانز دیفئومورفیک به ۰٫۸۷۲ و ۰٫۹۳۵ رسیده‌اند. در سطر UniGradICON سه مقدار به‌ترتیب Dice مغزی، Dice شکمی و TRE ریوی‌اند و IO یعنی بهینه‌سازی نمونه‌ای در زمان استنتاج. در سطر Recursive Cascades پیکربندی 10-cascade VTN گزارش شده و زمان اجرای آن ۰٫۲۵ ثانیه روی GPU در برابر ۷۴۸ ثانیه برای ANTs SyN روی CPU است. در سطر DeepAtlas ارقام مربوط به Dice هم‌*ترازسازی* روی MRI زانو با ده تصویر برچسب‌خورده است.

روش (مرجع)	سال	وظیفه‌ی معرفی	داده‌ی توسعه و فاز	معیار بهینه‌سازی	محک ارزیابی	مقدار گزارش‌شده	کد
SyN [۴۸]	۲۰۰۸	هم‌ترازسازی دیفئومورفیک MRI مغزی	بدون آموزش؛ بهینه‌سازی به‌ازای هر جفت. بدون فاز	CC	چهار محک مغزی	Dice ۰٫۶۰—۰٫۷۷	✓
MIND [۴۹]	۲۰۱۲	هم‌ترازسازی چندوجهی و سی‌تی ریه (دم/بازدم)	بدون آموزش؛ بهینه‌سازی به‌ازای هر جفت. تک‌فاز	SSD روی توصیف‌گر خودشباهت	سی‌تی ریه؛ CT—MR	گزارش‌نشده	✓
DEEDS [۵۰]	۲۰۱۳	هم‌ترازسازی تغییرشکل‌پذیر شکمی و چندوجهی	بدون آموزش؛ بهینه‌سازی به‌ازای هر جفت. تک‌فاز	MIND + بهینه‌سازی گسسته‌ی MRF	Learn2Reg شکمی (BCV/CHAOS)	درون‌وجهی MR: ۰٫۷۷۵ بین‌وجهی MR-CT: ۰٫۶۳۶	✓
VoxelMorph [۵۲]	۲۰۱۹	هم‌ترازسازی یادگیری‌محور MRI مغزی بین‌بیماری	MRI مغزی تک‌وجهی؛ بدون فاز	MSE یا CC	۸ محک مغزی (۲۵۰ حجم)	بدون‌نظارت: ۰٫۷۵۳ با نظارت: ۰٫۷۸	✓
Recursive Cascades [۶۵]	۲۰۱۹	تغییر شکل بزرگ؛ کبد (سی‌تی) و مغز (MRI)	سی‌تی کبد و MRI مغزی؛ تک‌فاز	NCC	SLIVER، LiTS، LSPIG، LPBA	SLIVER: ۰٫۹۵۳ LiTS: ۰٫۹۰۹ LPBA: ۰٫۷۱۶	✓

ادامه در صفحه‌ی بعد

ادامه‌ی جدول ۲-۳ از صفحه‌ی پیش

روش (مرجع)	سال	وظیفه‌ی معرفی	داده‌ی توسعه و فاز	معیار بهینه‌سازی	محک ارزیابی	مقدار گزارش‌شده	کد
DeepAtlas [۶۷]	۲۰۱۹	یادگیری مشترک هم‌ترازسازی و بخش‌بندی؛ مغز و زانو	MRI مغز و زانو تک‌وجهی؛ بدون فاز	شباهت شدت + هم‌پوشانی برچسب	MRI زانوی OAI؛ MindBoggle101	بدون‌نظارت: ۰/۸۰۵ با DeepAtlas: ۰/۸۵۷	✓
LapIRN [۶۴]	۲۰۲۰	تغییر شکل بزرگ MRI مغزی	MRI مغزی تک‌وجهی؛ بدون فاز	NCC چندمقیاسی	OASIS (۷۴۵ جفت آزمون)	جابه‌جایی: ۰/۸۰۸ دیفئومورفیک: ۰/۷۶۵	✓
HyperMorph [۶۶] ۲۰۲۱	۲۰۲۱	یادگیری فراپارامتر منظم‌سازی؛ MRI مغزی	MRI مغزی تک‌وجهی؛ بدون فاز	MSE/NCC یا MI	مغزی (Buckner40)	Dice ۰/۷۰— ۰/۷۴	✓
پارک و همکاران [۳]	۲۰۲۱	**هم‌ترازسازی فاز شریانی به وریدی سی‌تی شکمی**	**سی‌تی شکمی چندفازی** (PDAC و اهداکننده‌ی کلیه)؛ بدون آموزش. **فاز ۲→۱**	خودشباهت محلی + تغییر شکل وابسته به جهت	همان داده‌ی چندفازی شکمی	پانکراس: ۰/۸۹۰ کبد: ۰/۹۸۵	×
TransMorph [۵۳] ۲۰۲۲	۲۰۲۲	هم‌ترازسازی MRI مغزی با ترانسفورمر	MRI مغزی تک‌وجهی؛ بدون فاز	NCC/MSE + منظم‌ساز	Learn2Reg (OASIS، T03)	Dice ۰/۸۶۲ HD95 ۱/۴۳۱	✓
UniGrad-ICON [۶۸]	۲۰۲۴	مدل بنیادین چندآناتومی و چندوجهی	۱۲ مجموعه‌داده‌ی چندآناتومی؛ همگی تک‌فاز	LNCC + پایداری معکوس گرادیان	L2R-HCP؛ Abdomen COPDGene	بدون IO: ۰/۷۶۲ / ۰/۴۸۳ / ۲/۲۶ با IO: ۰/۷۸۹ / ۰/۵۲۲ / ۱/۴۰	✓

۲-۶ تولید تصاویر سی‌تی کنتراست‌دار از تصاویر سی‌تی بدون تزریق ماده‌ی حاجب

تعریف مسئله

در کنار هم‌ترازسازی تصویر، که فازهای موجود را هم‌تراز می‌کند، مسیر مکمل دیگر در ادبیات پژوهشی، تولید مستقیم اطلاعات فاز کنتراست‌دار از روی تصویر بدون‌کنتراست است؛ وظیفه‌ای که با عناوینی مانند **سنتز کنتراست مجازی**[۴۶] یا ترجمه‌ی تصویر[۴۷] از NC به CE شناخته می‌شود و به‌طور صوری یک مسئله‌ی

[۴۶] Virtual contrast enhancement
[۴۷] Image-to-image translation

نگاشت شرطی $G : x_{\mathrm{NC}} \mapsto \hat{x}_{\mathrm{CE}}$ است. این حوزه در سال‌های اخیر به‌سرعت رشد کرده و اکنون شامل ده‌ها روش با معماری‌ها، مجموعه‌داده‌ها و راهبردهای نظارتی متفاوت است؛ جدول ۲-۴ در انتهای این بخش، هم طبقه‌بندی روش‌شناختی و هم مقادیر عددی گزارش‌شده‌ی این ادبیات را یک‌جا جمع می‌کند.

معیارهای ارزیابی

ارزیابی کیفیت سنتز معمولاً هم به وفاداری پیکسلی و هم به واقع‌نمایی ادراکی تصویر تولیدشده توجه می‌کند.

نسبت سیگنال به نویز اوج[۴۸] بر پایه‌ی میانگین مربعات خطا در فضای لگاریتمی تعریف می‌شود و تصویر سنتزشده را مستقیماً با تصویر واقعی مقایسه می‌کند؛ این معیار بیشتر به خطای پیکسلی خام حساس است تا ساختار ادراکی تصویر.

شاخص شباهت ساختاری[۴۹] نیز تصویر سنتزشده را مستقیماً با تصویر واقعی مقایسه می‌کند، اما با سنجش هم‌زمان روشنایی، کنتراست و ساختار محلی، به تغییرات ادراکی نزدیک‌تر از PSNR است.

میانگین قدرمطلق خطا[۵۰] و **میانگین مربعات خطا**[۵۱] معیارهای ساده‌تری برای تفاوت شدت روشنایی پیکسل‌به‌پیکسل‌اند و در بسیاری از مطالعات به‌عنوان بخشی از تابع هزینه‌ی آموزش نیز به کار می‌روند.

ضریب همبستگی پیرسون[۵۲] همبستگی خطی میان شدت روشنایی دو تصویر را می‌سنجد.

فاصله‌ی آغازشی فرشه[۵۳] برخلاف معیارهای فوق، تصویر به تصویر مقایسه نمی‌کند، بلکه فاصله‌ی میان توزیع ویژگی‌های استخراج‌شده (با یک شبکه‌ی از پیش‌آموزش‌دیده) از کل مجموعه‌ی تصاویر واقعی و تولیدشده را اندازه می‌گیرد؛ پس معیاری در سطح توزیع، نه تک‌تصویر، است.

شباهت پرسپچوال یادگرفته‌شده[۵۴] تفاوت دو تصویر را در فضای ویژگی یک شبکه‌ی از پیش‌آموزش‌دیده، به‌جای فضای پیکسل خام، می‌سنجد و بنابراین با قضاوت ادراکی انسان هم‌بستگی بهتری نسبت به SSIM/PSNR دارد.

سرانجام، در مطالعاتی که کاربردپذیری پایین‌دستی سنتز را می‌سنجند، ضریب **Dice** بخش‌بندی روی تصویر سنتزشده (تعریف‌شده در بخش ۲-۲) به‌عنوان معیار غیرمستقیم کیفیت به کار می‌رود.

---

[۴۸] Peak Signal-to-Noise Ratio (PSNR)
[۴۹] Structural Similarity Index (SSIM)
[۵۰] Mean Absolute Error (MAE)
[۵۱] Mean Squared Error (MSE)
[۵۲] Pearson Correlation Coefficient (PCC)
[۵۳] Fréchet Inception Distance (FID)
[۵۴] Learned Perceptual Image Patch Similarity (LPIPS)

کارهای پیشین

خانواده‌ی نخست: GANهای جفت‌شده

نقطه‌ی عزیمت این ادبیات، معماری pix2pix است: یک GAN شرطی که تصویر ورودی را به تصویر خروجی نگاشت می‌کند و با ترکیبی از زیان تخاصمی و زیان بازسازی پیکسلی آموزش می‌بیند. آن‌چه مطالعات این خانواده را از هم متمایز می‌کند، پاسخشان به یک پرسش واحد است: چگونه می‌توان مولد را وادار کرد به *نواحی مرتبط با کنتراست* توجه کند، نه به کل تصویر به‌طور یکنواخت؟

مجموعه‌ای از سه کار پیاپی از یانگ و همکاران، این تکامل را به‌روشنی نشان می‌دهد؛ هر سه روی یک مجموعه‌داده‌ی درون‌سازمانی مشترک از ۸۶ بیمار با چهار نوع ضایعه‌ی کبدی (کارسینوم سلول کبدی، هیپرپلازی ندولار کانونی، متاستاز و کیست) ارزیابی شده‌اند که برای هر بیمار سه فاز بدون‌کنتراست، شریانی و وریدی دارد.

در گام نخست [۶۹]، یک **cGAN بهبودیافته** معرفی شد که دو ضعف مشخص معماری پایه را هدف می‌گیرد: میدان دریافت محدود رمزگذار پیچشی، و رقیق‌شدن اطلاعات معنایی در مسیر رمزگشایی. راه‌حل، افزودن یک **ماژول تجمیع هرمی**[۵۵] به انتهای رمزگذار و مجموعه‌ای از مسیرهای جریان اطلاعات است که خروجی این ماژول را مستقیماً به هر واحد رمزگشا می‌رساند. رمزگذار از ResNet از پیش‌آموزش‌دیده روی ImageNet استفاده می‌کند و شبکه با WGAN-GP به‌همراه زیان بازسازی L1 (با وزن ۲۵ در برابر وزن ۱ برای جمله‌ی تخاصمی) آموزش می‌بیند. نتیجه، PSNR برابر ۳۳/۱۸ و SSIM برابر ۰/۸۱۹ برای فاز شریانی و ۳۳/۰۲ و ۰/۸۱۹ برای فاز وریدی بود، در برابر ۳۲/۸۶ و ۰/۷۹۷ برای pix2pix پایه.

گام دوم [۷۰]، با نام **SAG-GAN**، مسئله‌ی توجه را صریح کرد. یک **ماژول توجه فضایی** سبک، نقشه‌ی امتیاز فضایی تولید می‌کند که مشخص می‌کند کدام نواحی تصویر با وظیفه مرتبط‌اند؛ تصویر نهایی، ترکیب وزن‌دار تصویر تبدیل‌شده و تصویر ورودی بر اساس همین نقشه است، به‌طوری‌که نواحی نامرتبط دست‌نخورده باقی می‌مانند. نکته‌ی هوشمندانه آن است که این نقشه بدون نیاز به نقاب دستی و به‌صورت *بدون‌نظارت* آموخته می‌شود، از طریق یک **زیان توجه** که سازگاری نقشه‌ی امتیاز میان تصویر ورودی و تصویر سنتزشده را تشویق می‌کند. تابع هدف نهایی ترکیبی سه‌جزئی است (تخاصمی با وزن ۲، بازسازی با وزن ۲۵، توجه با وزن ۱)، و SSIM فاز شریانی را به ۰/۸۳۰ و ضریب همبستگی پیرسون ناحیه‌ی تومور را به ۰/۹۶۶ رساند.

گام سوم [۷۱]، **SGCDD-GAN**، دو تحول افزود. نخست، **رمزگشایی دوگانه‌ی متقاطع**: یک شاخه تصویر تبدیل‌شده و شاخه‌ی دیگر نقشه‌ی توجه را تولید می‌کند، اما این دو شاخه به‌صورت متقاطع به

[۵۵] Pyramid pooling module

هم متصل‌اند تا اطلاعات میانشان جریان یابد. دوم، **یادگیری چندوظیفه‌ای**: یک شبکه‌ی بخش‌بندی تومور به چارچوب افزوده می‌شود تا مولد را وادار کند به ناحیه‌ی ضایعه توجه بیشتری کند. ارزیابی این کار، برخلاف دو کار پیشین، از معیارهای سطح‌پیکسل فراتر رفت: تصاویر سنتزشده به یک طبقه‌بند ResNet-50 سه‌فازی داده شد و به دقت ۰/۸۲۷ در طبقه‌بندی نوع ضایعه رسید (در برابر ۰/۶۳۵ با فاز بدون‌کنتراست تنها). در یک آزمایش خلبانی، دو رادیولوژیست با تصاویر سنتزشده به دقت تشخیصی ۰/۹۴۱ رسیدند، در برابر ۱/۰۰ با تصویر واقعی.

OA-GAN [۷۲] و **MAN-GAN** [۷۳] مسیر مکملی را دنبال کردند: به‌جای آموختن توجه، نقاب اندام کبد را مستقیماً از طریق **بهنجارسازی سازگار با نقاب**[۵۶] وارد مولد کردند؛ سازوکاری که پارامترهای بهنجارسازی لایه را بسته به این‌که وکسل درون اندام هدف است یا بیرون آن، متفاوت تنظیم می‌کند. MAN-GAN گسترده‌ترین ارزیابی این خانواده را دارد: ۳۷۴ بیمار برای آموزش، ۱۴۴ بیمار با یک بیماری کبدی مشخص به‌عنوان آزمون داخلی، و ۸۳ بیمار برای اعتبارسنجی خارجی.

MAFormer [۷۴] همین ایده را با یک ترانسفورمر بازسازی کرد و دانش بالینی متفاوتی را وارد مسئله ساخت: رادیولوژیست‌ها برای برجسته‌کردن نواحی کنتراست‌گرفته، تصویر بدون‌کنتراست را از تصویر کنتراست‌دار *تفریق* می‌کنند. MAFormer یک تخمین‌گر نقاب دارد که همین تصویر تفریق را از روی تصویر بدون‌کنتراست پیش‌بینی می‌کند، و آن را از طریق یک لایه‌ی بهنجارسازی مبتنی‌بر ترانسفورمر به شبکه تزریق می‌کند. یک **زیان تغییرناپذیری ساختار** نیز تضمین می‌کند آناتومی در برابر تغییر رنگ‌آمیزی کنتراست حفظ شود.

AMNet [۷۵] تازه‌ترین نماینده‌ی این خانواده است و بر دو چالش تمرکز دارد: کنتراست پایین و حساسیت پایین به ماده‌ی حاجب. راه‌حل آن چهار مؤلفه دارد: یک **ترانسفورمر تجمیع‌شده–تعاملی** با تجمیع توکن چندمقیاسی و تعامل میان‌توکنی؛ **یادگیری متضاد هم‌ترازشده‌ی چندگرانی** که ویژگی‌های درون‌حوزه را فشرده و میان‌حوزه را جداشدنی می‌کند؛ یک **لایه‌ی سازگار آگاه از کنتراست**؛ و یک **متمایزکننده‌ی دوجریانه**. تابع هدف ترکیبی از زیان پیکسلی L1 (وزن ۵۰)، زیان ادراکی مبتنی‌بر VGG-19 (وزن ۱۰)، زیان تخاصمی و زیان متضاد است. داده‌ی آن ۹۲ حجم سی‌تی از کلینیک کلیولند با دو فاز بدون‌کنتراست و وریدی است که *پیش از آموزش هم‌تراز شده‌اند*.

pix2pix سه‌بعدی [۷۶] اهمیت ویژه‌ای دارد، چون یکی از معدود کارهای این حوزه با کد باز است. چوی و همکاران کنتراست را از سی‌تی قفسه‌سینه‌ی بدون‌کنتراست سنتز کردند و (برخلاف اغلب مطالعات این خانواده) ارزیابی را در دو سطح جداگانه انجام دادند: ۲۵ بیمار برای سنجش فنی و ۱۲ بیمار برای سنجش کاربردپذیری بالینی. در سطح فنی، تصویر سنتزشده در مقایسه با تصویر بدون‌کنتراست خام بهبود

[۵۶] Mask-adaptive normalisation

معناداری در همه‌ی معیارها نشان داد: MAE از ۴۸/۷۴ به ۴۱/۷۲، PSNR از ۱۵/۹۷ به ۱۷/۴۴، MS-SSIM از ۰/۸۱ به ۰/۸۴ و LPIPS از ۰/۱۵ به ۰/۱۴. اما سطح بالینی، یافته‌ی به‌مراتب چشمگیرتری داد: نسبت کنتراست‌به‌نویز غدد لنفاوی میانی‌سینه‌ای از ۰/۷۴ به ۶/۱۵ جهش کرد؛ بهبودی حدوداً هشت‌برابری در سنجه‌ای که مستقیماً به قابلیت تشخیص مربوط است، در حالی که PSNR تنها حدود ۹ درصد بهتر شده بود.

این عدم‌تناسب، مهم‌ترین درس این خانواده است: *معیارهای سطح‌پیکسل، بهبود بالینی را به‌شدت کم‌برآورد می‌کنند*، چون تفاوت را روی کل تصویر میانگین می‌گیرند در حالی که کل ارزش تشخیصی در نواحی کوچکی متمرکز است.

خانواده‌ی دوم: سازگاری چرخه‌ای و آموزش بدون‌جفت

مسئله‌ی عملی خانواده‌ی نخست آن است که به جفت‌های هم‌ترازِ هم‌بیمار نیاز دارد، همان چیزی که بخش ۲-۳ کمیابی‌اش را مستند کرد. خانواده‌ی دوم این نیاز را با **سازگاری چرخه‌ای** حذف می‌کند: دو مولد در دو جهت مخالف آموزش می‌بینند و قید اصلی این است که ترجمه‌ی رفت و برگشت باید تصویر اولیه را بازتولید کند. این قید، آموزش را با داده‌ی *بدون‌جفت* ممکن می‌سازد.

Res-CycleGAN [۷۷] رمزگذار—رمزگشای باقیمانده را در چارچوب CycleGAN برای سی‌تی ریه به کار برد. **CyTran** [۷۸] لایه‌های پیچشی و توجه چندسر را در یک ترانسفورمر سازگار چرخه‌ای ترکیب کرد و همراه خود مجموعه‌داده‌ی Coltea-Lung-CT-100W را منتشر کرد. شی و همکاران [۷۹] CycleGAN و UNIT را نه برای تولید تصویر زیبا، بلکه به‌عنوان *انتقال* حوزه برای بهبود بخش‌بندی چندعضوی به کار بردند و معیارشان Dice پایین‌دستی بود، نه PSNR.

بهای این آزادی، از دست دادن نظارت پیکسل‌به‌پیکسل است: هیچ تضمینی وجود ندارد که مولد، آناتومی را حفظ کند و صرفاً بافت را «واقعی‌نما» نکند؛ خطری که در تصویربرداری پزشکی می‌تواند به **توهم**[۵۷] ساختارهای ناموجود بینجامد.

خانواده‌ی سوم: مدل‌های انتشار

موج اخیر این حوزه از GAN به **مدل‌های انتشار** گذر کرده است؛ خانواده‌ای که به‌جای آموزش تخاصمی، فرایند تدریجی حذف نویز را می‌آموزد و به همین دلیل آموزش پایدارتر و تنوع نمونه‌ی بهتری دارد، به قیمت استنتاج کندتر.

---

[۵۷] Hallucination

CFPS-Diff [۸۰] کامل‌ترین نماینده‌ی مستندشده‌ی این خانواده است. دو ایده‌ی اصلی دارد: **یادگیری الگوی جریان کنتراست**، که به‌جای نگاشت مستقل هر فاز، پویایی گذر ماده‌ی حاجب میان فازها را مدل می‌کند؛ و **یادگیری ویژگی خاص هر فاز** به‌همراه یک زیان آنتروپی متقاطع وزن‌دار با فاصله‌ی کلاس که تمایز میان فازها را تقویت می‌کند. تابع هدف ترکیبی از MAE و زیان موجک است. آموزش روی ۵۴۷ بیمار از یک بیمارستان و آزمون روی ۱۱۶ مورد از دو بیمارستان دیگر، به‌همراه یک مجموعه‌ی خارجی ۲۸ موردی با آسیب‌شناسی‌های نادر. نتایج روی مجموعه‌ی آزمون: میانگین MAE برابر ۳۱/۲۰، SSIM برابر ۰/۸۲۵ و PSNR برابر ۲۹/۳۹؛ و روی مجموعه‌ی خارجی به‌ترتیب ۳۰/۷۵، ۰/۸۲۶ و ۲۹/۴۲؛ یعنی عملاً بدون افت، که برای این حوزه غیرمعمول است.

نکته‌ی روش‌شناختی مهم این مقاله آن است که پیش‌پردازش آن صراحتاً شامل *هم‌ترازسازی تصویر* است: بهنجارسازی فضایی آفین با FSL و سپس SyN با ANTs برای هم‌ترازکردن فازهای کنتراست‌دار با فاز بدون‌کنتراست. یعنی حتی جدیدترین مدل‌های انتشار نیز نمی‌توانند از پیش‌نیاز هم‌ترازی بگریزند.

سایر کارهای این خانواده؛ AdverDM [۸۱]، مدل کنترل تبدیل فضایی [۸۲]، مولد فضازمانی علّی [۸۳] و مدل انتشار پل براونی با شرطدهی متنی [۸۴]؛ همگی در سال‌های ۲۰۲۵ و ۲۰۲۶ منتشر شده‌اند و هنوز جزئیات کامل مجموعه‌داده و معیار ارزیابی را گزارش نکرده‌اند.

خانواده‌ی چهارم: سنتز هدایت‌شده با هم‌ترازسازی تصویر

زیرمجموعه‌ای از این ادبیات، به‌جای فرض‌کردن هم‌ترازی، آن را بخشی از مسئله می‌داند.

CKAP-Net [۸] کامل‌ترین نماینده‌ی این خانواده است. ایده‌ی محوری آن **تفکیک دانش کنتراست** است: یک شبکه‌ی جداگانه می‌آموزد چه چیزی میان دو فاز مشترک است (آناتومی) و چه چیزی *متفاوت* است (اثر ماده‌ی حاجب)، تا مولد بتواند تنها مؤلفه‌ی دوم را اضافه کند. به آن یک **ترانسفورمر ادراک تشریحی چندمقیاسی** و یک **زیان ادراکی مبتنی‌بر ماده‌ی حاجب** افزوده شده که (برخلاف زیان ادراکی متعارف مبتنی‌بر VGG آموزش‌دیده روی تصاویر طبیعی دوبعدی) مخصوص همین وظیفه آموزش دیده است. داده: ۴۰۳ بیمار از مرکز اول و ۳۸ بیمار از مرکز دوم، همگی با جفت‌های بدون‌کنتراست و فاز شریانی دیررس، و ۱۳ اندام شکمی که برای زیرمجموعه‌ای از بیماران به‌دست متخصصان با بیش از ده سال تجربه برچسب خورده است.

نتایج: MAE برابر ۲۵/۹۶، SSIM برابر ۰/۸۵۵ و PSNR برابر ۳۲/۶۰ (در برابر ۳۸/۱۸، ۰/۷۸۰ و ۲۹/۲۸ برای مبنا). اما ارزشمندترین عدد این مقاله، معیار پایین‌دستی آن است: بخش‌بندی چندعضوی روی تصویر سنتزشده به Dice برابر ۰/۸۱۲ و فاصله‌ی هاسدورف ۵/۴۶ میلی‌متر رسید. این، نمونه‌ی روشنی

از زنجیره‌ی استدلالی «سنتز به‌عنوان پیش‌نیاز یک وظیفه‌ی پایین‌دستی» است.

ژو و همکاران [۸۵] هم‌ترازسازی تغییرشکل‌پذیر و سنتز را در یک چارچوب یادگیری چندوظیفه‌ای *هم‌زمان* آموزش دادند، به‌طوری‌که خطای هم‌ترازی و خطای سنتز یکدیگر را اصلاح کنند. لی و همکاران [۸۶] با ماژول تفکیک سازگاری آناتومیک و یک زیرماژول هم‌ترازسازی مبتنی‌بر VoxelMorph، محتوای تشریحی را از سبک کنتراست جدا کردند؛ روی داده‌ی درون‌سازمانی ۲۷۸ بیمار مبتلا به سرطان کبد به MAE برابر ۱۶/۳۸، PSNR برابر ۳۶/۵۲ و SSIM برابر ۰/۸۹۲ رسیدند. باید توجه داشت که جهت سنتز در این مقاله CECT ـ به ـ CT است، یعنی معکوس‌جهت NC ـ به ـ CE؛ ارزش این کار روش‌شناختی است و نه مستقیم.

اوهم و همکاران [۸۷] با اعمال DEEDS [۵۰] روی تمام فازها *پیش‌ازسنتز*، وابستگی مستقیم کیفیت سنتز به دقت هم‌ترازی پیشین را نشان دادند. این خط پژوهشی به‌روشنی تأیید می‌کند هم‌ترازسازی تصویر و سنتز، دو رویکرد رقیب نیستند بلکه دو مرحله‌ی مکمل یک زنجیره‌ی پردازشی‌اند.

خانواده‌ی پنجم: کاربردپذیری بالینی و کاهش دوز

شماری از مطالعات، به‌جای بهینه‌کردن معیارهای تصویری، مستقیماً می‌پرسند آیا این سنتز در بالین به کار می‌آید.

هان و همکاران [۸۸] بزرگ‌ترین اعتبارسنجی بالینی این حوزه را انجام دادند. آن‌ها یک U-Net دوونیم‌بعدی را با **یادگیری ضعیف‌نظارت** و با استفاده از تصاویر بدون‌کنتراست مجازی حاصل از سی‌تی دوانرژی آموزش دادند؛ راهکاری هوشمندانه برای دورزدن نیاز به جفت‌های واقعی. آموزش روی ۲,۲۰۲ جفت و اعتبارسنجی خارجی روی ۳۹۸ بیمار از سه مرکز و چند سازنده‌ی مختلف. PSNR برابر ۴۳/۲۵ و SSIM برابر ۰/۹۲ گزارش شد، اما یافته‌ی مهم‌تر بالینی است: با افزودن تصویر سنتزشده به تصویر بدون‌کنتراست، حساسیت سه رادیولوژیست در تشخیص ضایعه از ۰/۷۲۰ به ۰/۷۶۴ و سطح اطمینان تشخیصی از ۳/۰ به ۳/۶ افزایش یافت.

کیم و همکاران [۸۹] با یک cGAN دومرحله‌ای، دقت تشخیصی سی‌تی مجازی کنتراست‌دار را در بیماران اورژانس با درد حاد شکمی سنجیدند.

هاوبولد و همکاران [۹۰] پرسش را وارونه کردند: به‌جای حذف کامل ماده‌ی حاجب، چقدر می‌توان آن را کم کرد؟ آن‌ها با سی‌تی دوانرژی ۸۵ بیمار، دوز کاهش‌یافته را به‌صورت مصنوعی شبیه‌سازی کردند (با تفریق نسبی نقشه‌ی ید) و چهار cGAN را برای بازسازی تصویر با دوز کامل آموزش دادند. مدل‌های کاهش ۵۰ درصدی به SSIM بالای ۰/۹۹ و PSNR بالای ۵۱ رسیدند و مدل‌های کاهش ۸۰ درصدی به

SSIM بالای ۰/۹۸ و PSNR بالای ۴۸.

اما نتیجه‌گیری بالینی آن‌ها محتاطانه‌تر از این ارقام است و درسی مهم در بر دارد: تنها شبکه‌های کاهش ۵۰ درصدی به **سازگاری آسیب‌شناختی** ۱۰۰ درصدی رسیدند؛ در سطح کاهش ۸۰ درصدی، با وجود SSIM بالای ۰/۹۸، یافته‌های آسیب‌شناختی در برخی موارد تغییر کردند. رقم ۷۰ درصدی کاهش دوز که گاه به این خط پژوهشی نسبت داده می‌شود، متعلق به مطالعه‌ی *حیوانی* بعدی همین گروه [۹۱] روی ۲۰ مینی‌پیگ است و نه به مطالعه‌ی انسانی حاضر؛ در آن مطالعه نسبت کنتراست‌به‌نویز عروقی از ۶/۹ به ۲۸/۷ رسید (مقدار واقعی با دوز کامل ۳۴/۲) و سازگاری آسیب‌شناختی ۹۶/۵ درصد گزارش شد. تفکیک این دو رقم ضروری است: *۵۰ درصد در انسان، ۷۰ درصد در مدل حیوانی*. این یافته، شاهد دومی است بر همان نکته‌ای که در [۷۶] دیده شد: SSIM بالای ۰/۹۸ هیچ تضمینی برای حفظ اطلاعات تشخیصی نمی‌دهد.

آزادبرزین و همکاران [۹۲] و جو و همکاران [۹۳] در دو مرور نظام‌مند و گستره‌ای مجزا (به‌ترتیب با ۱۸ و ۵۶ مطالعه)، این حوزه را دسته‌بندی کرده‌اند و هر دو بر عدم‌بلوغ گزارش‌دهی کمّی در بخش قابل‌توجهی از این ادبیات تأکید کرده‌اند.

خانواده‌ی ششم: کد باز در وجهیت‌ها و اندام‌های مجاور

تصویری که تا این‌جا از بازتولیدپذیری ترسیم شد، در سراسر این حوزه یکسان نیست. اگر دامنه را از سی‌تی شکمی به وجهیت‌ها و اندام‌های مجاور گسترش دهیم، چند مطالعه کد خود را منتشر کرده‌اند و بررسی آن‌ها مرز واقعی دسترس‌پذیری را روشن‌تر می‌کند.

ژو و همکاران [۹۴] با **GLFC**، یک UNet تقویت‌شده با بلوک‌های Mamba در مسیرهای پرش به‌همراه زیان تباین چندگانه، سی‌تی مصنوعی را از CBCT سنتز کردند و SSIM را از ۰/۷۷۹ به ۰/۹۱۵ رساندند؛ ارزیابی روی محک عمومی SynthRAD2023 و کد در دسترس است.

فوکودا و همکاران [۹۵] با CycleGAN استاندارد و داده‌ی ۲۵ بیمار، کنتراست را در ناحیه‌ی غدد لنفاوی ژوگولار داخلی سنتز کردند. ارزیابی آن‌ها نمونه‌ی روشنی از نارسایی معیارهای متعارف است: PSNR تصویر سنتزشده (میانه ۱۷/۸۰) از تصویر بدون‌کنتراست خام (۱۹/۷۴) *بدتر* بود، هرچند SSIM بهتر بود (۰/۶۴ در برابر ۰/۵۷). اما در آزمون توورینگ بصری، سه ناظر تنها ۵۰/۸ درصد مواقع توانستند تصویر سنتزشده را تشخیص دهند؛ یعنی در حد حدس تصادفی. مهم‌تر آن‌که در وظیفه‌ی بالینی تمایز غدد لنفاوی از عروق، سطح زیر منحنی برای تصویر سنتزشده ۱/۰۰ بود، دقیقاً برابر تصویر کنتراست‌دار واقعی، در حالی که برای تصویر بدون‌کنتراست تنها ۰/۷۲ بود. یعنی مدلی که بر اساس PSNR «شکست خورده»

بود، از نظر بالینی کاملاً موفق بود.

رافنا و همکاران [۹۶] سه معماری (خودرمزگذار، Pix2Pix و CycleGAN) را برای سنتز تصویر بازترکیب‌شده در ماموگرافی طیفی کنتراست‌دار مقایسه کردند؛ CycleGAN بهترین عملکرد را داشت و کد به‌همراه مجموعه‌داده‌ی ۱,۱۳۸ تصویری منتشر شد. پینوک و همکاران [۹۷] یک چارچوب مولد شرطی‌شده بر فاز را برای سی‌تی مداخله‌ای در هدایت کرایوتراپی کلیوی توسعه دادند که با یک شبکه‌ی واحد میان فازهای مختلف جابه‌جا می‌شود. MMgSN-Net [۹۸] تصاویر T1w و T2w بدون‌کنتراست را برای سنتز T1w کنتراست‌دار در بیماران کارسینوم نازوفارنکس ترکیب کرد. TCGAN [۹۹] با دو مولد متوالی (نخست ترانسفورمری برای زمینه‌ی سراسری، سپس پیچشی برای جزئیات موضعی) سی‌تی مصنوعی را از PET سنتز کرد. کیدا و همکاران [۱۰۰] با CycleGAN بدون‌جفت، سی‌تی برنامه‌ریزی پرتودرمانی را از CBCT سنتز کردند و نرخ قبولی شاخص گاما را از ۸۶/۹۲ به ۹۶/۲۶ درصد افزایش دادند.

خانواده‌ی هفتم: معماری‌های عمومی ترجمه‌ی تصویر

شش خانواده‌ی بالا، ادبیاتی را پوشش می‌دهند که مسئله‌ی NC ـ به ـ CE را *به‌طور مشخص* هدف گرفته‌اند. اما بخش مهمی از آن‌چه در عمل به‌عنوان مبنای مقایسه به کار می‌رود از جای دیگری می‌آید: معماری‌های *عمومی* ترجمه‌ی تصویر که برای هیچ وظیفه‌ی پزشکی خاصی طراحی نشده‌اند اما به دلیل در دسترس بودن پیاده‌سازی و عمومیت‌شان، مبنای متعارف این حوزه شده‌اند. چون این معماری‌ها در عمل مبنای مقایسه‌ی متعارف این ادبیات‌اند، در این‌جا معرفی می‌شوند.

pix2pixHD [۱۰۱] گسترش pix2pix به تفکیک‌پذیری بالاست و سه سازوکار را به آن می‌افزاید: یک مولد *چندمقیاسی* که ابتدا تصویر کم‌تفکیک را می‌سازد و سپس آن را پالایش می‌کند، مجموعه‌ای از متمایزکننده‌های چندمقیاسی که هر یک در مقیاس متفاوتی داوری می‌کنند، و یک **زیان تطبیق ویژگی** که فعال‌سازی‌های میانی متمایزکننده را میان تصویر واقعی و تولیدشده هم‌تراز می‌کند. همین زیان تطبیق ویژگی است که بعدها در بسیاری از مولدهای پزشکی نیز تکرار شد.

ResViT [۱۰۲] برای سنتز چندوجهی تصویر پزشکی طراحی شده و مسئله‌ی موازنه‌ی میان زمینه‌ی سراسری و جزئیات موضعی را با **بلوک‌های ترانسفورمر باقیمانده‌ی تجمیع‌شده** حل می‌کند: هر بلوک یک مسیر پیچشی برای بافت محلی و یک مسیر ترانسفورمری برای وابستگی دوربرد دارد و خروجی‌شان ترکیب می‌شود. این معماری نزدیک‌ترین مبنای منتشرشده به مسئله‌ی حاضر از نظر *هدف* است، هرچند روی MRI معرفی شده است.

Ea-GAN [۱۰۳] با مشاهده‌ای ساده آغاز می‌شود: زیان‌های پیکسلی، تفاوت *بافتی* را نمی‌بینند و پس مولد می‌تواند تصویری تولید کند که از نظر شدت روشنایی نزدیک اما از نظر ساختار لبه‌ها محو است. راه‌حل، واردکردن صریح نقشه‌ی لبه به فرایند یادگیری است، در دو نسخه: **gEa-GAN** که نقشه‌ی لبه را تنها از طریق مولد وارد می‌کند، و **dEa-GAN** که آن را به متمایزکننده نیز می‌دهد تا شباهت لبه‌ها به‌صورت تخاصمی هم آموخته شود. هر دو نسخه سه‌بعدی‌اند. نکته‌ی روش‌شناختی این خانواده آن است که دغدغه‌ی حفظ بافت را از طریق *تابع زیان* دنبال می‌کند و نه از طریق *معیار ارزیابی*؛ یعنی حفظ بافت را تشویق می‌کند اما آن را نمی‌سنجد.

سرانجام، دو معماری که در اصل برای *بخش‌بندی* معرفی شده‌اند؛ **SwinUNETR** [۱۰۴] با رمزگذار Swin Transformer و **TransUNet** [۱۰۵] با ترکیب ViT و U-Net؛ در ادبیات به‌طور گسترده به‌عنوان ستون فقرات مولد نیز به کار رفته‌اند؛ یعنی به‌عنوان جایگزین ستون فقرات و نه به‌عنوان راهبرد نظارتی مستقل.

نکته‌ای که این خانواده را از شش خانواده‌ی پیشین جدا می‌کند و باید صریح بماند: هیچ‌یک از این معماری‌ها برای سی‌تی چندفازی معرفی نشده‌اند و هیچ‌کدام سازوکاری برای *شرطی‌سازی بر فاز* ندارند. در نتیجه هر یک باید به‌ازای هر فاز جداگانه آموزش ببیند، و روی محور کنترل‌پذیری اساساً قابل ارزیابی نیستند.

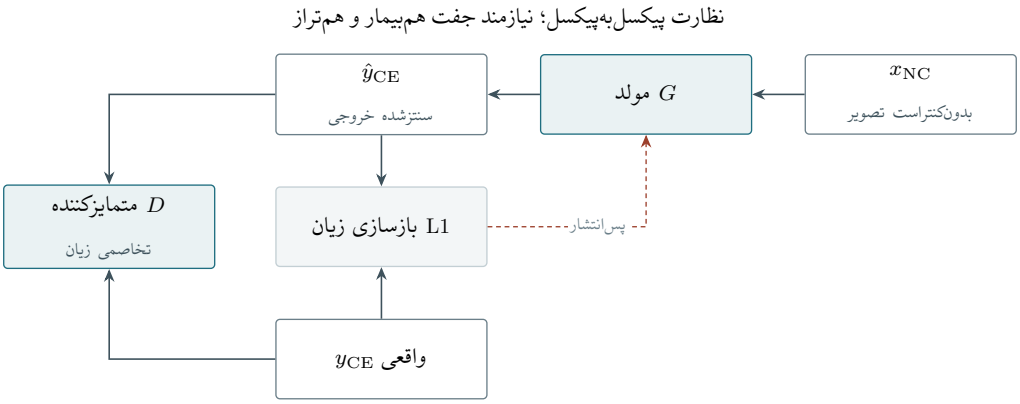
سرگروه‌های معماری

هفت خانواده‌ی بالا از نظر *انگیزه* متفاوت‌اند، اما از نظر *معماری* به شمار کمتری الگو فرو می‌کاهند. شکل ۲–۲ سه *راهبرد نظارتی* را نشان می‌دهد که تقریباً همه‌ی مطالعات این بخش نمونه‌ای از یکی از آن‌هایند: GAN شرطی جفت‌شده (pix2pix و pix2pixHD [۱۰۱]) که خانواده‌های یکم، چهارم و پنجم بر آن بنا شده‌اند؛ سازگاری چرخه‌ای (CycleGAN و CyTran [۷۸]) که خانواده‌ی دوم است؛ و مدل انتشار شرطی (CFPS-Diff [۸۰]) که خانواده‌ی سوم است. شکل ۲–۳ در کنار آن‌ها ستون فقرات ترکیبی پیچشی–ترانسفورمری (ResViT [۱۰۲]، SwinUNETR [۱۰۴]، TransUNet [۱۰۵]) را نشان می‌دهد که خود راهبرد نظارتی مستقلی نیست بلکه در جای مولدِ هر یک از آن سه می‌نشیند.

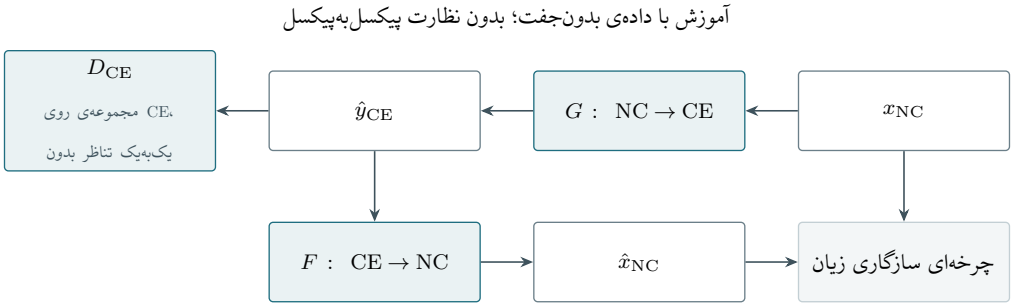
تفکیک این الگوها دو نکته را روشن می‌کند. نخست، آن‌چه مطالعات این حوزه را واقعاً از هم متمایز می‌کند اغلب معماری نیست بلکه *راهبرد نظارتی* و *کیفیت داده‌ای* است که در اختیار داشته‌اند؛ افزودن ماژول توجه یا بلوک ترانسفورمر به مولد، در چارچوب همان راهبرد نخست باقی می‌ماند. دوم، وابستگی به هم‌ترازی هندسی، خاصیت راهبرد نخست است و نه خاصیت یک مقاله‌ی خاص: هر روشی که زیان بازسازی پیکسل‌به‌پیکسل داشته باشد، ناهم‌ترازی باقی‌مانده‌ی جفت آموزشی را به‌عنوان بخشی از تفاوت

CE–NC می‌آموزد.

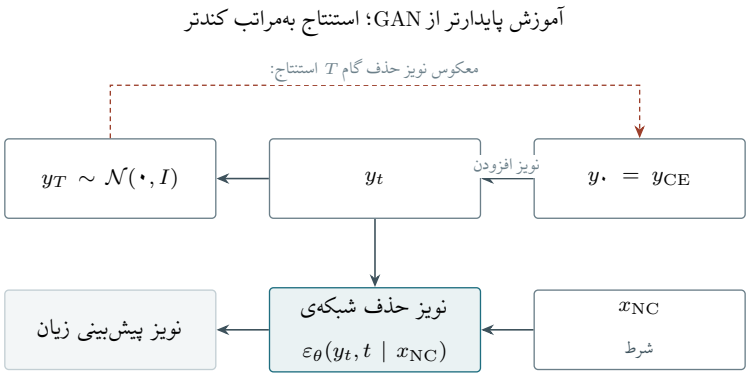
(الف) GAN شرطی جفت‌شده — pix2pixHD / pix2pix



(ب) سازگاری چرخه‌ای — CyTran / CycleGAN



(پ) مدل انتشار شرطی — CFPS-Diff



شکل ۲-۲: سه راهبرد نظارتی در ادبیات سنتز NC–به–CE. محور تمایز میان (الف) و (ب) وجود یا نبود جفت هم‌بیمارِ هم‌تراز است: (الف) نظارت پیکسل‌به‌پیکسل دارد و به همین دلیل به هم‌ترازی هندسی دقیق وابسته است، و (ب) این نیاز را با قید بازگشت‌پذیری چرخه حذف می‌کند اما تضمینی برای حفظ آناتومی نمی‌دهد. (پ) نظارت را از آموزش تخاصمی به پیش‌بینی نویز منتقل می‌کند و آموزش پایدارتری دارد، اما همچنان به جفت هم‌تراز نیاز دارد. هیچ‌یک از این سه الگو سازوکاری برای *شرطی‌سازی بر سطح تقویت* ندارد.



شکل ۲-۳: ستون فقرات ترکیبی پیچشی–ترانسفورمری. این الگو یک *راهبرد نظارتی* مستقل نیست بلکه ساختار درونی مولد است و می‌تواند جایگزین مولد در هر یک از سه راهبرد شکل ۲-۲ شود. مسیر پیچشی بافت محلی را و مسیر ترانسفورمری وابستگی‌های دوربرد را مدل می‌کند، و مسیر پرش جزئیات مکانی از دست‌رفته در رمزگذاری را بازمی‌گرداند.

جمع‌بندی

این گروه از مطالعات نشان می‌دهند کد باز در این حوزه به‌کلی غایب نیست، اما دسترس‌پذیری آن با دو محدودیت مهم همراه است. نخست، کد باز عمدتاً در *حاشیه‌ی* مسئله متمرکز است: در وجهیت‌ها و اندام‌هایی که با سنتز NC–به–CE شکمی خویشاوندند اما یکی نیستند؛ در هسته‌ی مسئله، تقریباً همه‌ی مطالعات روی داده‌ی خصوصی آموزش دیده‌اند و کد منتشر نکرده‌اند. دوم، جزئیات پیش‌پردازش (به‌ویژه کیفیت هم‌ترازی هندسی جفت‌های آموزشی) در بسیاری از این مقالات به‌طور کامل گزارش نشده است.

از همه مهم‌تر، **هیچ‌یک از این مطالعات معیاری برای سنجش کمّی کیفیت هم‌ترازی داده‌ی آموزشی گزارش نکرده‌اند.** بدون چنین معیاری، تفکیک سهم کیفیت داده از سهم خود مدل در نتیجه‌ی نهایی ممکن نیست؛ یعنی نمی‌توان تشخیص داد مدل کمبود کیفیت هم‌ترازی را جبران کرده یا نتیجه صرفاً بازتاب داده‌ای است که از پیش خوب هم‌تراز شده بود.

جدول ۲-۴ این ادبیات را در شش خانواده‌ی روش‌شناختی مرتب می‌کند و برای هر مطالعه، مجموعه‌داده، مقادیر PSNR و SSIM، سایر معیارهای گزارش‌شده و وضعیت انتشار کد را کنار هم می‌گذارد. جدول تنها مطالعاتی را در بر می‌گیرد که مقدار کمّی قابل‌مقایسه‌ای گزارش کرده‌اند؛ مطالعاتی که ارزیابی‌شان کاملاً کیفی یا پایین‌دستی است در ستون‌های وفاداری تصویری خط تیره دارند و در متن بالا معرفی شده‌اند. دو الگو در این جدول برجسته است. نخست، *ناهمگنی معیارها*: حتی مطالعاتی که هر دو معیار PSNR و SSIM را گزارش می‌کنند، ارقامشان در بازه‌های کاملاً متفاوتی قرار دارد؛ از PSNR برابر ۱۷٫۲۳ در [۱۰۶] و ۱۷٫۴۴ در [۷۶] تا ۴۳٫۲۵ در [۸۸]؛ اختلافی بیش از ۲۵ دسی‌بل، یعنی حدود سیصد برابر در نسبت توان خطا. این اختلاف عمدتاً بازتاب تفاوت در پنجره‌ی شدت روشنایی، دامنه‌ی محاسبه (کل تصویر در برابر درون نقاب بدن) و نوع داده است، نه تفاوت واقعی کیفیت. مقایسه‌ی مستقیم این

اعداد میان سطرها بی‌معناست، و این خود نشان می‌دهد که این ادبیات به یک پروتکل ارزیابی یکدست نیاز دارد. دوم، *تمرکز کد باز در حاشیه*: از میان ۱۸ مطالعه‌ی چهار خانواده‌ی نخست (یعنی همان‌ها که مستقیماً به سنتز NC‌ـ به‌ـCE می‌پردازند) تنها سه مورد کد تأییدشده دارند—[۷۶] روی قفسه‌سینه، [۷۸] روی ریه و [۹۷] روی سی‌تی مداخله‌ای کلیوی—و هیچ‌یک به سنتز چندفازی سی‌تی شکمی *تشخیصی* نمی‌پردازد. در مقابل، در خانواده‌ی ششم هر شش مطالعه کد منتشر کرده‌اند. یعنی کد باز در این حوزه هست، اما دقیقاً در هسته‌ی مسئله‌ی سنتز چندفازی شکمی نیست. این یافته با کمیابی داده و کد بازتولیدپذیر مستندشده در بخش ۲-۳ هم‌راستاست.

جدول ۲-۴: ادبیات سنتز NC‌ـ به‌ـCE، دسته‌بندی‌شده بر اساس خانواده‌ی روش. ستون «فاز داده‌ی آموزش» نشان می‌دهد آیا داده‌ی آموزش هر دو فاز را به‌صورت جفت‌شده در بر داشته است یا نه. PSNR برحسب دسی‌بل، همه‌ی مقادیر SSIM، Dice، دقت، حساسیت و AUC در بازه‌ی صفر تا یک، و MAE و HD برحسب واحد HU و میلی‌متر؛ ✓یعنی کد تأییدشده در دسترس است. خط تیره در ستون‌های PSNR و SSIM یعنی مطالعه معیار وفاداری تصویری را به‌عنوان نتیجه‌ی اصلی گزارش نمی‌کند و ارزیابی‌اش کاملاً پایین‌دستی است. مقدار SSIM سطر pix2pix سه‌بعدی در واقع MS-SSIM است؛ CyTran به‌جای PSNR، MAE و RMSE گزارش می‌کند و مبنای بدون‌ترجمه در همان جدول SSIM برابر ۰/۶۵۶ دارد. در جدول MAN-GAN، خودِ تصویر بدون‌کنتراست خام PSNR برابر ۲۶/۰۲ و SSIM برابر ۰/۷۴ می‌گیرد؛ یعنی کل بهبود مدل حدود ۱/۷ دسی‌بل روی یک مبنای بسیار بالاست. در سطر یادگیری چندوظیفه‌ای متحد، ستون‌های PSNR و SSIM ارقام وضوح بالا را نشان می‌دهند و ارقام وضوح پایین در ستون سایر معیارها آمده است. برای TCGAN ارقام پیکربندی نهایی (تمایزگر وصله‌ای) و در ستون سایر معیارها به ترتیب برای Madic، BraTS2020 و IXI آمده است.

روش (مرجع)	سال	داده و وظیفه	فاز داده‌ی آموزش	PSNR	SSIM	سایر معیارها	کد
خانواده‌ی یکم: GAN جفت‌شده (Paired GAN)							
Dual-path GAN [۱۰۶]	۲۰۲۲	خصوصی (۶۵ بیمار)؛ سنتز سه فاز شکم و لگن	هر دو فاز	شریانی: ۱۹/۰۹ وریدی: ۱۹/۷۹ تأخیری: ۱۷/۲۳	شریانی: ۰/۶۳ وریدی: ۰/۶۵ تأخیری: ۰/۶۵	—	×
cGAN بهبودیافته [۶۹]	۲۰۲۲	خصوصی (۸۶ بیمار)؛ سنتز شریانی و وریدی از ضایعات کبدی	هر دو فاز	شریانی: ۳۳/۱۸ وریدی: ۳۳/۰۲	شریانی: ۰/۸۱۹ وریدی: ۰/۸۱۹	PCC ۰/۹۵۶؛ ۰/۹۶۱	×

ادامه در صفحه‌ی بعد

ادامه‌ی جدول ۲-۴ از صفحه‌ی پیش

روش (مرجع)	سال	داده و وظیفه	فاز داده‌ی آموزش	PSNR	SSIM	سایر معیارها	کد
SAG-GAN [۷۰]	۲۰۲۳	همان داده‌ی بالا؛ افزودن توجه فضایی بدون‌نظارت	هر دو فاز	شریانی: ۳۳/۱۸ وریدی: ۳۳/۰۵	شریانی: ۰/۸۳۰ وریدی: ۰/۸۲۳	PCC ۰/۹۶۶؛ ۰/۹۶۸ SSIM کبد ۰/۹۳۲	×
SGCDD-GAN [۷۱]	۲۰۲۴	همان داده؛ رمزگشایی دوگانه + هدایت بخش‌بندی	هر دو فاز	شریانی: ۳۳/۳ وریدی: ۳۳/۱۴	شریانی: ۰/۸۳۷۱ وریدی: ۰/۸۲۴۷	دقت طبقه‌بندی ضایعه ۰/۸۲۷ دقت رادیولوژیست ۰/۹۴۱ MSE شریانی ۳۱/۰۷، وریدی ۳۲/۱۶ PCC شریانی ۰/۹۷۷۰، وریدی ۰/۹۷۸۸	×
OA-GAN [۷۲]	۲۰۲۴	خصوصی؛ سنتز آگاه از نقاب کبد	هر دو فاز	[عدد؟]	[عدد؟]	—	×
MAN-GAN [۷۳]	۲۰۲۵	۳۷۴ آموزش / ۱۴۴ آزمون داخلی / ۸۳ خارجی؛ سه فاز کبدی	هر دو فاز	شریانی: ۲۷/۷۱ وریدی: ۲۶/۷۶ تأخیری: ۲۶/۱۷	شریانی: ۰/۸۲ وریدی: ۰/۸۰ تأخیری: ۰/۷۹	مبنای NC خام: ۰/۷۴/۲۶/۰۲ ارزیابی رادیولوژیست	×
MAFormer [۷۴]	۲۰۲۴	خصوصی؛ ترجمه‌ی چندفازی کبدی با تخمین تصویر تفریق	هر دو فاز	[عدد؟]	[عدد؟]	—	×
AMNet [۷۵]	۲۰۲۵	۹۲ حجم (کلینیک کلیولند)؛ سنتز فاز وریدی	هر دو فاز (هم‌ترازشده)	کل‌نگر: ۲۴/۸۸ تومور: ۲۵/۲۰	کل‌نگر: ۰/۸۵ تومور: ۰/۸۵	MAE کل‌نگر ۶/۲۸ MAE تومور ۶/۱۷	×
pix2pix سه‌بعدی [۷۶]	۲۰۲۱	۲۵ توسعه / ۲۵ آزمون فنی / ۱۲ آزمون بالینی؛ قفسه‌سینه	هر دو فاز	سنتز: ۱۷/۴۴ مبنا NC: ۱۵/۹۷	سنتز: ۰/۸۴ مبنا NC: ۰/۸۱	MAE ۴۱/۷۲؛ LPIPS ۰/۱۴ CNR ۶/۱۵ در برابر ۰/۷۴	✓
Phase-conditioned UNet [۹۷]	۲۰۲۳	سی‌تی مداخله‌ای؛ هدایت کرایوتراپی کلیوی	هر دو فاز	[عدد؟]	۰/۹۹۵	Dice تومور ۰/۶۵	✓
خانواده‌ی دوم: سازگاری چرخه‌ای / آموزش بدون‌جفت							
Res-CycleGAN [۷۷]	۲۰۲۱	سی‌تی ریه؛ NC→CE	بدون‌جفت	[عدد؟]	[عدد؟]	—	×

ادامه در صفحه‌ی بعد

ادامه‌ی جدول ۲-۴ از صفحه‌ی پیش

روش (مرجع)	سال	داده و وظیفه	فاز داده‌ی آموزش	PSNR	SSIM	سایر معیارها	کد
CyTran [۷۸]	۲۰۲۱	Coltea-Lung-CT-100W (عمومی)؛ NC→CE ریه	بدون‌جفت	گزارش‌نشده	وریدی: ۰/۷۴۵ شریانی: ۰/۷۵۸	MAE ۰/۰۶۱؛ ۰/۰۵۹ RMSE ۰/۱۴۴؛ ۰/۱۴۷	✓
Cycle-UNIT/GAN [۷۹]	۲۰۲۱	انتقال حوزه‌ی وریدی به بدون‌کنتراست، برای بخش‌بندی چندعضوی	بدون‌جفت	—	—	Dice پایین‌دستی [عدد؟]	×
خانواده‌ی سوم: مدل‌های انتشار							
CFPS-Diff [۸۰]	۲۰۲۵	۵۴۷ آموزش (یک مرکز) / ۱۱۶ آزمون (دو مرکز) / ۲۸ خارجی؛ سنتز سه فاز	هر دو فاز (هم‌ترازشده)	آزمون: ۲۹/۳۹ خارجی: ۲۹/۴۲	آزمون: ۰/۸۲۵ خارجی: ۰/۸۲۶	MAE ۳۱/۲۰؛ ۳۰/۷۵ FID، LPIPS گزارش‌شده	×
خانواده‌ی چهارم: سنتز هدایت‌شده با هم‌ترازسازی تصویر							
CKAP-Net [۸]	۲۰۲۴	۴۰۳ + ۳۸ بیمار (دو مرکز)؛ سنتز شریانی دیررس + بخش‌بندی ۱۳ اندام	هر دو فاز (جفت‌شده)	۳۲/۶۰ (مبنا: ۲۹/۲۸)	۰/۸۵۵ (مبنا: ۰/۷۸۰)	MAE ۲۵/۹۶ Dice پایین‌دستی ۰/۸۱۲ HD ۵/۴۶	×
یادگیری چندوظیفه‌ای متحد [۸۵]	۲۰۲۳	شکمی؛ هم‌ترازسازی تغییرشکل‌پذیر و سنتز به‌صورت مشترک	هر دو فاز	شریانی: ۲۶/۲۷ وریدی: ۲۸/۲۵	شریانی: ۰/۹۲ وریدی: ۰/۹۶	MAE شریانی ۴۱/۸۹، وریدی ۳۱/۱۸ وضوح پایین: PSNR ۲۷/۶۹ و ۲۷/۴۴، SSIM ۰/۹۵ و ۰/۹۶، MAE ۲۸/۶۶ و ۳۱/۷۱	×
تفکیک سازگاری آناتومیک [۸۶]	۲۰۲۴	۲۷۸ بیمار سرطان کبد SynthRAD2023 + لگنی؛ جهت CECT-به-CT	هر دو فاز (هم‌ترازشده)	۳۶/۵۲	۰/۸۹۲	MAE ۱۶/۳۸	×
چارچوب متحد کلیوی [۸۷]	۲۰۲۲	سی‌تی چندفازی کلیه؛ هم‌ترازسازی DEEDS پیش از سنتز + طبقه‌بندی زیرگونه	هر دو فاز (هم‌ترازشده)	—	—	mAUC زیرگونه ۰/۸۳۴ (سه‌فاز ۰/۸۱۵؛ سقف چهارفاز ۰/۸۳۵)	×
خانواده‌ی پنجم: کاربردپذیری بالینی و کاهش دوز ماده‌ی حاجب							
DL-SynCCT [۸۸]	۲۰۲۴	۲,۲۰۲ جفت آموزش (DECT)؛ ۳۹۸ بیمار خارجی از سه مرکز	هر دو فاز (VNC)	۴۳/۲۵	۰/۹۲	حساسیت تشخیص ضایعه ۰/۷۲۰ به ۰/۷۶۴ اطمینان ۳/۰ به ۳/۶	×

ادامه در صفحه‌ی بعد

ادامه‌ی جدول ۲-۴ از صفحه‌ی پیش

روش (مرجع)	سال	داده و وظیفه	فاز داده‌ی آموزش	PSNR	SSIM	سایر معیارها	کد
cGAN دومرحله‌ای [۸۹]	۲۰۲۱	۳۵۳ بیمار اورژانس از سه مرکز؛ مطالعه‌ی خوانندگان با شش رادیولوژیست	هر دو فاز	—	—	دقت تشخیصی: بهبود در ۳ از ۶ خواننده اطمینان: بهبود در ۵ از ۶ ($p < ۰/۰۰۱$)	×
cGAN کاهش دوز [۹۰]	۲۰۲۱	۸۵ بیمار (DECT، فاز شریانی)؛ بازسازی دوز کامل از دوز کاهش‌یافته	هر دو فاز (VNC)	کاهش ۵۰٪: ۵۱> کاهش ۸۰٪: ۴۸>	کاهش ۵۰٪: ۰/۹۹> کاهش ۸۰٪: ۰/۹۸>	FID ۱/۷—۰/۸ سازگاری آسیب‌شناختی ۱۰۰٪ فقط در کاهش ۵۰٪	×
مطالعه‌ی حیوانی [۹۱]	۲۰۲۲	۲۰ مینی‌پیگ؛ کاهش دوز ماده‌ی حاجب	هر دو فاز	—	—	CNR عروقی ۶/۹ → ۲۸/۷ (واقعی ۳۴/۲) سازگاری آسیب‌شناختی ۹۶/۵٪ کاهش دوز ۷۰٪	×
خانواده‌ی ششم: مطالعات دارای کد باز در وجهیت‌ها و اندام‌های مجاور							
GLFC [۹۴]	۲۰۲۵	SynthRAD2023 (عمومی)؛ CBCT به CT	CT/CBCT	[عدد؟]	۰/۹۱۵ (مبنا CBCT: ۰/۷۷۹)	—	✓
CycleGAN [۹۵]	۲۰۲۴	خصوصی (۲۵ بیمار)؛ غدد لنفاوی ژوگولار داخلی	بدون‌جفت	سنتز: ۱۷/۸۰ مبنا NC: ۱۹/۷۴	سنتز: ۰/۶۴ مبنا NC: ۰/۵۷	AUC تمایز گره/عروق ۱/۰۰ در برابر ۰/۷۲ آزمون تورینگ ۵۰/۸٪	✓
CycleGAN [۱۰۰]	۲۰۲۰	CBCT به سی‌تی برنامه‌ریزی پرتودرمانی	بدون‌جفت	[عدد؟]	[عدد؟]	نرخ قبولی گاما ۸۶/۹۲٪ به ۹۶/۲۶٪	✓
CycleGAN (CESM) [۹۶]	۲۰۲۴	۱,۱۳۸ تصویر عمومی؛ ماموگرافی طیفی کنتراست‌دار	جفت‌شده	[عدد؟]	[عدد؟]	—	✓
MMgSN-Net [۹۸]	۲۰۲۲	MRI نازوفارنکس؛ T2w+T1w به T1w کنتراست‌دار	جفت‌شده	[عدد؟]	[عدد؟]	—	✓
TCGAN [۹۹]	۲۰۲۲	PET به CT روی Madic؛ ارزیابی تکمیلی روی BraTS2020 و IXI	جفت‌شده	Madic: ۴۵/۶۶ BraTS: ۳۱/۲۹ IXI: ۲۷/۳۷	Madic: ۰/۹۶۶ BraTS: ۰/۹۳۰ IXI: ۰/۸۶۷	VIF: ۰/۸۳۶، ۰/۳۲۰، ۰/۳۴۲ FID: ۶۹/۹۴، ۲۶/۱۱، ۵۵/۲۳	✓

۲-۷ جمع‌بندی و جای خالی پژوهش

با کنار هم قرار دادن یافته‌های پنج حوزه‌ی مرورشده در این فصل، تصویری منسجم از جای خالی پژوهشی شکل می‌گیرد. بخش‌بندی چندعضوی شکم، با وجود پیشرفت چشمگیر معماری‌های مبتنی‌بر nnU-Net، هنوز در فاز بدون‌کنتراست به‌طور نظام‌مند کم‌دقت‌تر از فاز کنتراست‌دار عمل می‌کند؛ پدیده‌ای که ریشه در کاهش نسبت کنتراست‌به‌نویز و جابه‌جایی حوزه‌ای وابسته به فاز دارد. مرور ادبیات مجموعه‌داده‌ها نشان داد این محدودیت تنها یک مسئله‌ی الگوریتمی نیست: هیچ ارزیابی نظام‌مندی از کفایت و سوگیری مجموعه‌داده‌های عمومی این حوزه وجود نداشت، و به‌طور مشخص هیچ منبعی گزارش نکرده بود چه سهمی از داده‌ی برچسب‌خورده‌ی این مجموعه‌ها اساساً از فاز بدون‌کنتراست می‌آید. این شکاف تنها با مرور نظام‌مند اخیر [۴] پوشش داده شده است.

پیش از هر بهره‌برداری از همین داده‌ی چندفازیِ کمیاب، ادبیات تشخیص فاز کنتراست نشان داد شناسایی صحیح فاز هر بررسی، به دلیل ناقص و ناسازگاربودن برچسب‌های سرآیند DICOM، خود گامی پیش‌نیاز و غیربدیهی است و اغلب روش‌های موجود به بخش‌بندی اندام از پیش‌آموزش‌دیده یا حجم آموزشی بزرگ متکی‌اند.

در پاسخ به کمیابی داده‌ی جفت‌شده، ادبیات هم‌ترازسازی تصویر نشان داد معیارهای کلاسیک اطلاعات متقابل، به دلیل فرض پایداری رابطه‌ی شدت روشنایی در سطح کل تصویر، در برابر تغییر ناهمگن کنتراست شکننده‌اند. مسئله‌ی هم‌ترازسازی *بین‌فازی* شکمی البته بی‌سابقه نیست (پارک و همکاران [۳] آن را مستقیماً هدف گرفته‌اند) اما نکته‌ی مشترک *همه‌ی* این روش‌ها، از آن‌ها که آناتومی را برای وزن‌دهی به کار می‌گیرند تا آن‌ها که معیار را مقاوم‌تر می‌سازند، این است که معیار تراز را همچنان روی *کل* میدان دید محاسبه می‌کنند. هیچ‌یک *دامنه‌ی فضایی محاسبه‌ی* معیار را از پیش و بر مبنای دانش تشریحیِ این‌که کدام ساختارها در برابر تزریق ماده‌ی حاجب پایدارند محدود نمی‌کند؛ همین تمایز باریک، جای خالی این حوزه است.

موازی با آن، ادبیات سنتز NC←CE، از GANهای جفت‌شده تا مدل‌های انتشار اخیر، نشان داد بازسازی مستقیم اطلاعات کنتراست از روی تصویر بدون‌کنتراست ممکن است، اما کیفیت آن هم‌چنان به دقت هم‌ترازی هندسی پیشین (از طریق هم‌ترازسازی تصویر) وابسته است. برخلاف تصور رایج، کد باز در این حوزه به‌کلی غایب نیست و چند مطالعه‌ی مرتبط، به‌ویژه در وجهیت‌ها و اندام‌های مجاور سی‌تی شکمی، کد خود را منتشر کرده‌اند؛ اما دقت گزارش‌شده هنوز جای بهبود دارد، اغلب این مطالعات روی طیف مجموعه‌داده‌های عمومی موجود آزموده نشده‌اند، و هیچ‌کدام معیاری برای سنجش کیفیت هم‌ترازی داده‌ی آموزشی گزارش نکرده‌اند که سهم داده را از سهم مدل در نتیجه‌ی نهایی تفکیک کند.

افزون بر این، هیچ‌یک از روش‌های مرورشده در این حوزه (چه GANهای شرطی و چه مدل‌های انتشار) سازوکاری برای *کنترل* سطح تقویت خروجی ندارند. همگی یک نگاشت ثابت از تصویر بدون‌کنتراست به «فاز کنتراست‌دار» می‌آموزند، در حالی که سطح تقویت واقعی به دوز، زمان‌بندی بولوس و فیزیولوژی بیمار وابسته است و یک کمیت *پیوسته* است، نه یک برچسب گسسته.

به‌طور خلاصه، پنج جای خالی مکمل از این مرور استخراج می‌شود:

۱. نبود ارزیابی نظام‌مند از کفایت و سوگیری مجموعه‌داده‌های عمومی سی‌تی شکمی، و نبود هر رقمی درباره‌ی سهم داده‌ی برچسب‌خورده‌ی فاز بدون‌کنتراست در این منابع؛

۲. نیاز به تشخیص قابل‌اعتماد فاز کنتراست مستقل از برچسب‌های ناقص سرآیند؛

۳. نبود پایپ‌لاین هم‌ترازسازی تصویری که *دامنه‌ی محاسبه‌ی* معیار تراز را (نه صرفاً وزن آن را) به نواحی پایدار در برابر فاز کنتراست محدود کند؛

۴. نبود مدل سنتزی که خروجی‌اش را بتوان بر فاز *و* بر سطح تقویت شرطی کرد، و نبود معیاری که این کنترل‌پذیری را بسنجد؛

۵. فقدان شواهد کمّی درباره‌ی اثر این مداخلات بر شکاف دقت بخش‌بندی چندعضوی میان دو فاز.

فصل بعد به این جاهای خالی می‌پردازد.

فصل ۳

روش پیشنهادی

این فصل روش پیشنهادی این پایان‌نامه را ارائه می‌کند. ساختار فصل مستقیماً از پنج جای خالی‌ای پیروی می‌کند که در پایان فصل ۲ استخراج شد: نبود ارزیابی نظام‌مند از کفایت و سوگیری مجموعه‌داده‌های عمومی (بخش ۳-۲)؛ نبود سازوکار قابل‌اعتماد برای تشخیص فاز کنتراست مستقل از سرآیند (بخش ۳-۴)؛ نبود پایپ‌لاین هم‌ترازسازی تصویری که *دامنه‌ی* محاسبه‌ی معیار تراز را به نواحی پایدار محدود کند (بخش ۳-۵)؛ نبود مدل سنتزی که بتوان خروجی‌اش را بر فاز و بر سطح تقویت شرطی کرد (بخش ۳-۶)؛ و فقدان شواهد کمّی درباره‌ی اثر این مداخلات بر شکاف دقت بخش‌بندی (بخش ۳-۷).

بخش ۳-۱ نمای کلی و منطق زنجیره‌ی مؤلفه‌ها را شرح می‌دهد. بخش ۳-۲ پروتکل مرور مجموعه‌داده‌ها و بخش ۳-۳ داده و پیش‌پردازش مشترک را معرفی می‌کند. سه بخش بعدی به‌ترتیب سه مؤلفه‌ی روش را ارائه می‌دهند: تشخیص فاز کنتراست (بخش ۳-۴)، هم‌ترازسازی تصویر بین‌فازی چندگذره (بخش ۳-۵) و سنتز فاز کنتراست‌دار با شبکه‌ی PLC-Net (بخش ۳-۶). بخش ۳-۷ پروتکل ارزیابی را تعریف می‌کند؛ این بخش صرفاً فهرستی از معیارها نیست، بلکه خود بخشی از سهم روش‌شناختی این پایان‌نامه است، چرا که——چنان‌که نشان داده خواهد شد——معیارهای متعارف سطح‌پیکسل قادر به رتبه‌بندی مدل‌های این مسئله نیستند.

۳-۱ نمای کلی

سه مؤلفه‌ی این روش یک زنجیره‌ی وابسته تشکیل می‌دهند و نه سه کار موازی.

نقطه‌ی شروع، محدودیت داده است. برای آموزش نظارت‌شده‌ی هر مدل سنتز NC‌ـبه‌ـCE، به

جفت‌هایی از یک بیمار نیاز است که هم فاز بدون‌کنتراست و هم فاز کنتراست‌دار آن موجود و از نظر هندسی هم‌تراز باشند. داده‌های جدول استخراج مرور مجموعه‌داده‌ها [۴] نشان می‌دهد چنین داده‌ای کمیاب است (بخش ۴-۱). بنابراین جفت‌ها باید از داده‌ی چندفازی موجود *ساخته* شوند، و ساختن آن‌ها دو پیش‌نیاز دارد:

- **شناسایی فاز.** برای آن‌که بدانیم کدام سری از یک بررسی، فاز بدون‌کنتراست و کدام فاز وریدی است، به برچسب فاز نیاز است. سرآیند DICOM این برچسب را به‌طور قابل‌اتکا فراهم نمی‌کند (بخش ۲-۴). مؤلفه‌ی نخست این خلأ را پر می‌کند.
- **هم‌ترازسازی هندسی.** دو سری از یک بررسی در دو زمان و با تنفس متفاوت گرفته شده‌اند و بدون هم‌ترازسازی تصویر، جفت *نیستند*. مؤلفه‌ی دوم این هم‌ترازی را انجام می‌دهد.

مؤلفه‌ی سوم، سنتز، بر خروجی این دو تکیه می‌کند. اما رابطه‌ی مؤلفه‌ی نخست با مؤلفه‌ی سوم عمیق‌تر از یک پیش‌نیاز اجرایی است: مدل تشخیص فاز، علاوه بر نقش دروازه‌بانی داده، به *ابزار اندازه‌گیری* ارزیابی سنتز نیز تبدیل می‌شود. همان‌طور که در بخش ۳-۷ تشریح می‌شود، معیار اصلی این پایان‌نامه برای سنجش وفاداری کنتراستِ تصویر تولیدشده، از ویژگی‌های سطح‌اندام همین مدل استخراج می‌شود. به این ترتیب مدلی که برای آماده‌سازی داده برگزیده شد، مسئله‌ی سنجش را نیز حل می‌کند.

سرانجام، پرسش پایانی پایان‌نامه—آیا این مداخلات شکاف دقت بخش‌بندی چندعضوی را کاهش می‌دهند—یک ارزیابی پایین‌دستی[۱] جداگانه می‌طلبد که در بخش ۳-۷ تعریف می‌شود.

۳-۲ مرور نظام‌مند مجموعه‌داده‌های سی‌تی شکمی: پروتکل

بخش ۳-۲ نشان داد هیچ ارزیابی نظام‌مندی از مجموعه‌داده‌های عمومی سی‌تی شکمی به‌عنوان منبع آموزش هوش مصنوعی وجود ندارد. این بخش، پروتکلی را که برای پرکردن این شکاف تدوین شد شرح می‌دهد؛ یافته‌های حاصل در بخش ۴-۱ گزارش می‌شوند. نتایج این مرور به‌طور مستقل نیز منتشر شده است [۴].

شناسایی و معیارهای ورود

جست‌وجو در Google Scholar، PubMed، Scopus و مخازن نهادی از جمله TCIA انجام شد. جست‌وجوی نخست میان مهر و دی ۱۴۰۳ و دو جست‌وجوی به‌روزرسانی میان آذر ۱۴۰۴ و بهمن ۱۴۰۴

[۱] Downstream

صورت گرفت. افزون بر جست‌وجوی پایگاهی، فهرست مراجع و توصیف منبع داده‌ی هر مجموعه‌داده‌ی یافت‌شده بررسی شد تا مجموعه‌داده‌های سازنده‌ای که در مجموعه‌های ترکیبی بازاستفاده شده‌اند ردیابی شوند؛ گامی که برای کمّی‌کردن بازاستفاده ضروری بود. مخازن خارج از ادبیات متعارف (Kaggle، Zenodo، Grand Challenge) نیز پیمایش شدند.

پنج معیار ورود اعمال شد: داده باید حجمی[۲] سه‌بعدی باشد (نه برش‌های دوبعدی استخراج‌شده)؛ دست‌کم یک ناحیه‌ی برچسب‌خورده به‌صورت نقاب چندضلعی یا وکسلی داشته باشد؛ برچسب‌ها از وظیفه‌ای بالینی پشتیبانی کنند؛ برچسب‌ها به ساختارهای شکمی مربوط باشند؛ و مجموعه‌داده دست‌کم در یک مقاله‌ی داوری‌شده استفاده شده باشد. معیار آخر بدین معناست که این مرور، *چشم‌انداز منتشرشده* را نمایندگی می‌کند، نه کل منابع موجود.

جست‌وجو ۴۸ نامزد شناسایی کرد که پس از اعمال معیارها سه مورد کنار گذاشته شد و **۴۵ مجموعه‌داده** باقی ماند.

استخراج داده

دو ارزیاب مستقل، داده را با فرم استاندارد استخراج کردند و در موارد اختلاف، ارزیاب سوم داوری کرد. استخراج در شش محور انجام شد: ترکیب مجموعه‌داده، بافت بالینی، خاستگاه داده، ویژگی‌های تصویربرداری (شامل **وضعیت فاز کنتراست**)، جزئیات برچسب‌گذاری، و اطلاعات جمعیت‌شناختی. محور چهارم، که وضعیت فاز کنتراست را ثبت می‌کند، همان محوری است که ارقام مورد نیاز بخش‌های ۳-۵ و ۳-۶ این فصل را فراهم می‌آورد.

چارچوب ارزیابی ریسک سوگیری

از آن‌جا که هیچ چک‌لیست پذیرفته‌شده‌ای برای این منظور وجود ندارد (بخش ۲-۳)، یک چارچوب هفت‌مقوله‌ای با تطبیق سه ابزار موجود تدوین شد: PROBAST+AI [۳۲]، معیارهای کیفیت کوچاک و همکاران [۳۰]، و راهنمای گزارش‌دهی TRIPOD+AI [۳۳]. هر مقوله در سه سطح ریسک پایین، متوسط یا بالا امتیاز می‌گیرد، و مقوله‌هایی که مستندات اولیه اطلاعات کافی برای آن‌ها فراهم نمی‌کرد با برچسب «در دسترس نیست» ثبت شدند. جدول ۳-۱ این هفت مقوله را خلاصه می‌کند.

این ارزیابی تنها روی ۲۲ مجموعه‌داده با صد نمونه‌ی عمومی یا بیشتر انجام شد؛ مجموعه‌داده‌های کوچک‌تر به‌طور پیش‌فرض در اغلب مقوله‌ها ریسک بالا می‌گیرند و این امر ارزش تمایزی طبقه‌بندی را از

[۲] Volumetric

میان می‌برد.

جدول ۳-۱: هفت مقوله‌ی چارچوب ارزیابی ریسک سوگیری، به همراه تعریف عملیاتی و تهدید مرتبه‌بالاتری که هر مقوله به آن مربوط است.

مقوله	محور ارزیابی	تهدید مرتبه‌بالاتر
سوگیری طیف (Spectrum bias)	پوشش دامنه‌ی شدت و تنوع بالینی درون گروه مثبت	نمایندگی موارد
سوگیری انتخاب (Selection bias)	پوشش تشخیص‌های افتراقی در گروه غیرمثبت	نمایندگی موارد
سوگیری برچسب‌گذاری (Labelling bias)	دقت و سازگاری فرایند حاشیه‌نویسی؛ تعداد و تخصص بازبین‌ها	نمایندگی موارد و جابه‌جایی حوزه
سوگیری نژادی (Racial bias)	نمایندگی گروه‌های نژادی و قومی نسبت به جامعه‌ی هدف	سوگیری جمعیتی
سوگیری جمعیت‌شناختی (Demographic bias)	توازن جنسیت و توزیع سنی	سوگیری جمعیتی
سوگیری فنی (Technical bias)	تنوع سخت‌افزار تصویربرداری، پروتکل و تزریق ماده‌ی حاجب	جابه‌جایی حوزه
سوگیری زمانی (Temporal bias)	بازه‌ی زمانی گردآوری داده	جابه‌جایی حوزه

فرایند ارزیابی و پایایی

سه ارزیاب (یک پژوهشگر تصویربرداری پزشکی، یک پزشک با تجربه‌ی پژوهشی در تحلیل تصویر پزشکی، و یک پزشک عمومی با تجربه‌ی پژوهشی در تصویربرداری) به‌طور مستقل همه‌ی مجموعه‌داده‌های واجد شرایط را ارزیابی کردند. پیش از ارزیابی مستقل، جلسه‌ی کالیبراسیون مشترکی برای یکسان‌سازی تفسیر تعاریف عملیاتی برگزار شد. ارزیابی تنها بر مبنای مستندات اولیه‌ی در دسترس عموم انجام شد و با سازندگان مجموعه‌داده‌ها تماس گرفته نشد؛ این تصمیم تضمین می‌کند ارزیابی، همان اطلاعاتی را بازتاب دهد که در اختیار جامعه‌ی پژوهشی است.

اختلاف میان دو یا چند ارزیاب، به‌عنوان تعارض تعریف و توسط ارزیاب چهارم در مشورت با یک رادیولوژیست بوردشده حل شد. پایایی بین‌ارزیاب با آلفای کریپندورف (با وزن‌دهی فاصله‌ی ترتیبی)

سنجیده شد: مقدار کلی ۰/۷۲۷ با فاصله‌ی اطمینان ۹۵ درصدِ ۰/۶۲ تا ۰/۸۴، که توافق قابل‌ملاحظه تلقی می‌شود. مقادیر به‌تفکیک مقوله از ۰/۱۹۹ برای سوگیری زمانی تا ۰/۸۲۰ برای سوگیری انتخاب متغیر بود؛ پایین‌بودن توافق در سوگیری زمانی، بازتاب ناقص‌بودن گزارش بازه‌ی گردآوری در مستندات اغلب مجموعه‌داده‌هاست.

طبقه‌بندی کلی سوگیری

برای تجمیع امتیازهای مقوله‌ای به یک طبقه‌بندی کلی، یک امتیاز پیوسته بر پایه‌ی سه اصل تعریف شد: ساختار چنددامنه‌ای ROBINS-I [۱۰۷]، منطق کاهش تجمعی GRADE [۱۰۸]، و این اصل از QUADAS-2 [۱۰۹] که دامنه‌ی مستندنشده را نمی‌توان کم‌ریسک فرض کرد. مقوله‌های «در دسترس نیست» برای محاسبه، ریسک متوسط در نظر گرفته شدند:

$$\text{امتیاز سوگیری} = \sum(\text{ریسک بالا}) \times ۱/۰ \; + \; \sum(\text{ریسک متوسط} + \text{در دسترس نیست}) \times \tfrac{۱}{۳} \qquad (۳\text{-}۱)$$

آستانه‌ها متناسب با چارچوب هفت‌مقوله‌ای تعیین شدند: امتیاز ۳/۰ و بالاتر «سوگیری بحرانی»، ۲/۰ تا زیر ۳/۰ «سوگیری بالا»، ۱/۰ تا زیر ۲/۰ «سوگیری متوسط»، و زیر ۱/۰ «سوگیری پایین».

۳-۳ داده و پیش‌پردازش

مجموعه‌داده

آزمایش‌های این پایان‌نامه بر مجموعه‌داده‌ی عمومی VinDr-Multiphase [۹] انجام می‌شود. این مجموعه، بررسی‌های سی‌تی شکمی چندفازی را همراه با برچسب فاز در سطح سری فراهم می‌کند و از این رو هم برای آموزش و ارزیابی مدل تشخیص فاز و هم—پس از هم‌ترازسازی تصویر—برای ساخت جفت‌های آموزشی سنتز مناسب است.

انتخاب یک مجموعه‌داده‌ی عمومی به‌جای داده‌ی خام گردآوری‌شده، تصمیمی آگاهانه است: هر ادعای این پایان‌نامه درباره‌ی سنتز باید روی داده‌ای قابل بازتولید توسط دیگران آزمون شود، و مرور مجموعه‌داده‌ها [۴] نشان داد که همین قابلیت بازاستفاده، کمبود اصلی ادبیات این حوزه است.

پس از اعمال پایپ‌لاین هم‌ترازسازی تصویر (بخش ۳-۵) و کنارگذاری جفت‌هایی که معیار کیفیت هم‌ترازی را برآورده نمی‌کنند، 137 جفت هم‌ترازشده‌ی بدون‌کنتراست/وریدی و 136 جفت

بدون‌کنتراست/شریانی باقی می‌ماند. این جفت‌ها در سطح *بیمار*—و نه در سطح برش یا سری—به سه بخش تقسیم می‌شوند: 97 مورد آموزش، 20 مورد اعتبارسنجی و 20 مورد آزمون. تقسیم با بذر تصادفی ثابت انجام و در یک فایل منجمد ذخیره می‌شود، و *همه‌ی* مدل‌های این پایان‌نامه—اعم از مدل‌های پیشنهادی و مدل‌های مبنای بازپیاده‌سازی‌شده از ادبیات—بدون استثنا روی همین تقسیم آموزش و ارزیابی می‌شوند. تقسیم در سطح بیمار، نشت اطلاعات میان برش‌های مجاور یک بیمار را که در ادبیات سنتز تصویر پزشکی خطای رایجی است حذف می‌کند.

استانداردسازی هندسی و شدت روشنایی

همه‌ی حجم‌ها به فاصله‌ی وکسل همسان‌گرد[۳] 1.5 میلی‌متر بازنمونه‌برداری می‌شوند. یکنواختی این مقدار در سراسر مجموعه به‌صورت تجربی تأیید شده است و نه فرض‌شده؛ اهمیت این تأیید در فصل ۴ روشن می‌شود، آن‌جا که ناهمگنی فاصله‌ی وکسل به‌عنوان یکی از توضیح‌های ممکن برای کف خطای سنتز کنار گذاشته می‌شود.

شدت روشنایی با یک پنجره‌ی HU ثابت در بازه‌ی $[-۲۰۰, ۴۰۰]$ به بازه‌ی $[۰, ۱]$ نگاشت می‌شود. این پنجره بافت نرم شکمی و محدوده‌ی کنتراست عروقی را پوشش می‌دهد. انتخاب یک پنجره‌ی *واحد* برای همه‌ی مدل‌ها یک الزام روش‌شناختی است، نه یک جزئیات پیاده‌سازی: تغییر پنجره، مقدار عددی هر معیار سطح‌پیکسل را تغییر می‌دهد، و مقایسه‌ی دو مدل که با دو پنجره‌ی متفاوت سنجیده شده‌اند بی‌معناست.

نقاب‌های اندام

نقاب‌های اندام با TotalSegmentator [۱۱] تولید می‌شوند. خروجی پرشمار این ابزار سپس به یک حجم برچسب فشرده با قرارداد ثابت ادغام می‌شود که در آن هر اندام یک شناسه‌ی عددی یکتا دارد. دو نقاب از این ادغام حاصل می‌شود و تمایز میان آن‌ها در ادامه‌ی فصل نقش محوری دارد:

- **نقاب کامل**: همه‌ی اندام‌های بخش‌بندی‌شده. این نقاب دامنه‌ی *ارزیابی* است.
- **نقاب هم‌ترازسازی**: تنها استخوان‌ها و اندام‌های نرمِ پایدار در برابر فاز کنتراست. روده، ساختارهای پرکنتراست عروقی و ساختارهای دارای حرکت دودی[۴] به‌صراحت از آن حذف شده‌اند. این نقاب دامنه‌ی *محاسبه‌ی معیار تراز* است.

---

[۳] Isotropic
[۴] Peristalsis

نقاب‌ها از فاز کنتراست‌دار استخراج می‌شوند، چرا که مرزهای اندام در آن فاز به‌مراتب واضح‌تر است. پیامد این انتخاب آن است که این نقاب‌ها را نمی‌توان به‌عنوان ورودی به مولد سنتز داد——چنین کاری اطلاعات هدف را به ورودی نشت می‌دهد——و کاربردشان به وزن‌دهی تابع زیان و تعریف معیارها محدود می‌ماند. این محدودیت در بخش ۳-۷ دوباره مطرح می‌شود.

۳-۴ تشخیص فاز کنتراست

نیازمندی‌های این مؤلفه

مؤلفه‌ی تشخیص فاز در زنجیره‌ی این پایان‌نامه دو کار مشخص بر عهده دارد. نخست، دروازه‌بانی داده: پیش از ساختن جفت‌های هم‌تراز باید معلوم باشد کدام سری یک بررسی بدون‌کنتراست، کدام شریانی و کدام وریدی است، و سرآیند DICOM این برچسب را به‌طور قابل‌اتکا فراهم نمی‌کند (بخش ۲-۴). دوم، سنجش: همان مدل در ارزیابی سنتز به‌عنوان خط‌کشی به کار می‌رود که می‌سنجد تصویر تولیدشده سطح تقویت هر اندام را درست بازسازی کرده و به فاز درخواست‌شده تعلق دارد (بخش ۳-۷).

این دو نقش، پیش از هر انتخابی، چهار نیازمندی را تعیین می‌کنند:

- **تفکیک سه فاز.** مدل باید فاز بدون‌کنتراست، شریانی و وریدی را در سی‌تی شکمی از هم جدا کند؛ تشخیص صرفِ وجود کنتراست کافی نیست.
- **اعتبار روی داده‌ی همین پایان‌نامه.** ارقام مقاله‌ها روی داده‌ی مراکز دیگر و با مجموعه‌ی کلاس‌های متفاوت به دست آمده‌اند، و بخش ۲-۴ نشان داد که این ارقام با عبور به مرکز تازه افت می‌کنند. معیار انتخاب باید عملکرد روی داده‌ی همین پایان‌نامه باشد.
- **خروجی سطح‌اندام.** برای نقش سنجش، مدل باید کمیتی بدهد که بتوان آن را میان تصویر واقعی و سنتزی به‌تفکیک اندام مقایسه کرد، و نه تنها یک برچسب نهایی.
- **کد و وزن‌های منتشرشده.** تا بتوان مدل را روی داده‌ی این پایان‌نامه بازآموزی کرد و نتیجه را بازتولید کرد.

انتخاب مدل از میان روش‌های موجود

با این نیازمندی‌ها، رویکرد این پایان‌نامه طراحی مدلی تازه نبود. تشخیص فاز در ادبیات راه‌حل‌های بالغی دارد، و آن‌چه برای این پایان‌نامه نامعلوم بود وجود یک مدل خوب نبود، بلکه این بود که کدام مدل *روی این داده* و *برای این دو نقش* مناسب است. از نه مطالعه‌ی مرورشده در بخش ۲-۴، تنها چهار مطالعه کد منبع منتشر کرده‌اند (جدول ۲-۲). روش یی و همکاران [۳۹] تنها وجود کنتراست را تشخیص می‌دهد و نیازمندی نخست را برآورده نمی‌کند. سه روش دیگر نامزد شدند: Segment-and-Classify [۳۶] و مدل تفسیرپذیر ریس و همکاران [۳۷] از رویکرد نخست، و شبکه‌ی برش‌محور دائو و همکاران [۴۰] از رویکرد دوم.

ارقام منتشرشده‌ی این سه روش را نمی‌توان مستقیماً مبنای انتخاب قرار داد، چون روی مجموعه‌داده‌ها، مجموعه‌ی کلاس‌ها و شرایط ارزیابی متفاوتی گزارش شده‌اند. از این رو هر سه نامزد در شرایط یکسان و روی مجموعه‌ی آزمون این پایان‌نامه دوباره ارزیابی شدند. Segment-and-Classify و شبکه‌ی برش‌محور روی داده‌ی آموزش همین پایان‌نامه بازآموزی شدند، و مدل‌های منتشرشده‌ی Segment-and-Classify و ریس و همکاران بدون بازآموزی نیز سنجیده شدند. پیکربندی هر نامزد و نتیجه‌ی این ارزیابی در بخش ۴-۳ آمده است.

معیار انتخاب دو مرحله داشت: نخست دقت روی بیمارانی که مدل در آموزش ندیده است، و میان نامزدهایی که در این معیار از هم قابل تفکیک نیستند، نیازمندی سوم. بر همین مبنا Segment-and-Classify برگزیده شد. در ارزیابی بخش ۴-۳ بالاترین دقت را داشت و تفاوتش با نزدیک‌ترین نامزد، شبکه‌ی برش‌محور، در این اندازه‌ی نمونه معنادار نبود؛ اما تنها این مدل خروجی سطح‌اندام دارد، در حالی که شبکه‌ی برش‌محور فقط برچسب فاز می‌دهد و نمی‌تواند خطکش سطح‌اندامِ ارزیابی سنتز باشد. وابستگی Segment-and-Classify به بخش‌بندی اندام نیز در این پایان‌نامه هزینه‌ی تازه‌ای ندارد، چون نقاب‌های اندام به‌هرحال برای هم‌ترازسازی تصویر (بخش ۳-۵) و وزن‌دهی زیان سنتز تولید می‌شوند. در ادامه‌ی این پایان‌نامه، این مدل *طبقه‌بند اندامی* نامیده می‌شود.

مدل برگزیده

Segment-and-Classify فاز را نه از بافت کلی تصویر، بلکه از الگوی شدت روشنایی در اندام‌های مشخص تشخیص می‌دهد؛ همان نشانه‌ای که رادیولوژیست نیز به کار می‌گیرد، یعنی روشنایی آئورت نسبت به ورید باب و پارانشیم کبد. برای هر حجم، نقاب اندام‌ها با TotalSegmentator [۱۱] محاسبه و از هر یک از ۱۶ اندام مرتبط با کنتراست، *میانه‌ی* HU درون آن اندام به‌عنوان یک ویژگی استخراج می‌شود. اندامی

که در میدان دید نیست مقدار گمشده می‌گیرد، و طبقه‌بند XGBoost [۱۱۰]، یعنی جنگلی از درختان تقویت‌شده‌ی گرادیانی[۵]، این مقدار را با سازوکار بومی خود برای داده‌ی گمشده مدیریت می‌کند [۳۶].

این صورت‌بندی سه ویژگی دارد که با نیازمندی‌های این پایان‌نامه هم‌خوان است. ابعاد ورودی از چند میلیون وکسل به ۱۶ عدد کاهش می‌یابد و مسئله با داده‌ی آموزشی اندک قابل‌حل می‌شود. ویژگی‌ها واحد فیزیکی دارند و در نتیجه احتمالاً میان دستگاه‌ها قابل‌انتقال‌ترند. و همان بردار ویژگی، مستقل از طبقه‌بند، مستقیم‌ترین کمیتی است که می‌توان میان تصویر واقعی و سنتزی مقایسه کرد؛ همان خروجی سطح‌اندامی که نیازمندی سوم می‌خواهد. استفاده از میانه به‌جای میانگین نیز ویژگی را در برابر داده‌ی پرت، مانند ضایعات کانونی، کلسیفیکاسیون و خطاهای موضعی بخش‌بندی، مقاوم می‌کند.

در اجرای این پایان‌نامه، نگاشت نام اندام به شناسه‌ی برچسب در زمان اجرا از نسخه‌ی نصب‌شده‌ی TotalSegmentator خوانده می‌شود و در کد ثابت نشده است؛ در غیر این صورت، ارتقای نسخه‌ی این ابزار می‌توانست بی‌سروصدا ویژگی‌ها را جابه‌جا کند و مدل را بی‌آن‌که خطایی رخ دهد بی‌اعتبار سازد.

داده و پروتکل ارزیابی

همه‌ی نامزدها روی حجم‌های هم‌ترازشده‌ی VinDr-Multiphase [۹] ارزیابی می‌شوند که برچسب فازشان یکی از سه کلاس بدون‌کنتراست، شریانی یا وریدی است: ۴۱۰ حجم از ۱۳۷ بررسی. هفت حجمی که برچسبشان در این سه کلاس نمی‌گنجد کنار گذاشته می‌شوند. تقسیم داده در سطح بررسی انجام می‌شود تا فازهای مختلف یک بیمار هرگز در دو بخش متفاوت قرار نگیرند: ۲۸۴ حجم (۹۵ بررسی) برای آموزش، ۶۳ حجم (۲۱ بررسی) برای اعتبارسنجی، و ۶۳ حجم (۲۱ بررسی، از هر فاز ۲۱ حجم) برای آزمون. واحد نمونه در این مؤلفه حجم تکی است و نه جفت هم‌تراز؛ از این رو این تقسیم از تقسیم جفت‌های سنتز در بخش ۳-۳ جداست، اما مانند آن با بذر ثابت ساخته و در یک فایل منجمد نگهداری می‌شود.

طبقه‌بند اندامی با دستورالعمل منتشرشده‌ی Segment-and-Classify [۳۶] روی این داده بازآموزی می‌شود: اعتبارسنجی متقاطع لایه‌ای[۶] پنج‌تایی که بررسی‌ها را میان تاها جدا نگه می‌دارد، یک مدل در هر تا (نرخ یادگیری ۰/۰۵، بیشینه‌ی عمق ۴ و ۲۰۰ درخت)، و میانگین احتمال پنج مدل به‌عنوان خروجی نهایی. این دستورالعمل دو بار اجرا می‌شود. نسخه‌ای که ابزار اندازه‌گیری ارزیابی سنتز است (بخش ۳-۷)، روی هر ۴۱۰ حجم آموزش می‌بیند تا از همه‌ی داده‌ی در دسترس بهره بگیرد. چون این نسخه همه‌ی بیماران را دیده است، عملکرد آن روی بیمار ناشناخته با نسخه‌ی دوم برآورد می‌شود: همان دستورالعمل، این بار تنها

[۵] Gradient-boosted trees
[۶] Stratified k-fold cross-validation

روی مجموعه‌ی آموزش و اعتبارسنجی، که سپس یک بار روی مجموعه‌ی آزمون سنجیده می‌شود. برای سنجش انتقال‌پذیری، نسخه‌ای از همین طبقه‌بند که روی WAW-TACE [۳۴] آموزش دیده است نیز بدون هیچ بازآموزی روی همان مجموعه‌ی آزمون اجرا می‌شود. نتایج، همراه با مقایسه با روش‌های منتشرشده، در بخش ۴-۳ گزارش می‌شود.

آزمایش: سازگاری مدل‌های بنیادین با این وظیفه

انتخاب بالا وابستگی به بخش‌بندی اندام را، که بخش ۴-۲ ضعف مشترک رویکرد نخست دانست، می‌پذیرد. در کنار آن، مدل‌های بنیادین[۷] تصویری مانند DINOv2 [۱۱۱]، که با یادگیری خودنظارتی روی حجم بزرگی از تصاویر پیش‌آموزش دیده‌اند، بازنمایی‌های عمومی‌ای می‌دهند که بدون تنظیم‌دقیق در وظایف متنوعی به کار رفته‌اند. این پرسش پیش می‌آید که آیا اطلاعات فاز را می‌توان بدون هیچ نقاب اندامی و مستقیماً از بازنمایی چنین مدلی به دست آورد. برای سنجیدن میزان سازگاری این مدل‌ها با وظیفه‌ی تشخیص فاز، آزمایشی طراحی شد. هدف آن ساختن جایگزینی برای طبقه‌بند اندامی نیست؛ هدف، سنجیدن این است که چه مقدار از اطلاعات فاز در بازنمایی‌های عمومی تصویر به‌شکل خطی قابل بازیابی است. پاسخ مثبت یعنی وابستگی به بخش‌بندی قابل حذف است، و پاسخ منفی، پذیرش آن وابستگی را توجیه تجربی می‌کند.

در این آزمایش، شدت هر حجم از بازه‌ی منفی ۱۰۰۰ تا ۱۰۰۰ هانسفیلد به بازه‌ی صفر تا یک نگاشته و حجم به ۱۲۸ وکسل در هر محور بازنمونه‌برداری می‌شود. سپس ۳۲ برش دوبعدی با فاصله‌ی یکنواخت در امتداد نخستین محور مکانی حجم برداشته می‌شود؛ هر برش به ۲۲۴ پیکسل در هر ضلع بزرگ‌نمایی و به سه کانال تکثیر می‌شود و از یک رمزگذار منجمد[۸] می‌گذرد. بردارهای خروجی برش‌ها با ادغام میانگین[۹] به یک بردار برای کل حجم تبدیل می‌شوند. در این زنجیره هیچ پارامتر آموزش‌پذیری وجود ندارد و تنها وزن‌های ازپیش‌آموزش‌دیده‌ی خود رمزگذار در استخراج ویژگی نقش دارند.

دو رمزگذار آزموده شد. نخست DINOv2 ViT-S/14 [۱۱۱]، که با یادگیری خودنظارتی[۱۰] روی تصاویر طبیعی آموزش دیده است و برای هر حجم برداری ۳۸۴ بعدی می‌دهد. پیکربندی اولیه‌ی آزمایش DINOv3 را هدف گرفته بود، اما وزن‌های آن در محیط اجرا در دسترس نبود؛ همه‌ی نتایج گزارش‌شده با DINOv2 به دست آمده‌اند و هویت وزن‌ها با استخراج دوباره‌ی ویژگی‌ها و مقایسه با ویژگی‌های ذخیره‌شده تأیید شده است. دومی MedViT-S [۱۱۲] است، یک معماری ترکیبی پیچشی–ترانسفورمری

[۷] Foundation models
[۸] Frozen encoder
[۹] Mean pooling
[۱۰] Self-supervised learning

که برای طبقه‌بندی تصاویر پزشکی طراحی شده است؛ در این آزمایش وزن‌های ازپیش‌آموزش‌دیده‌ی آن روی ImageNet-1k به کار رفت و خروجی آن برداری ۱۰۲۴ بعدی است.

روی این بردارها سه سر طبقه‌بند خطی مقایسه می‌شود: تحلیل تشخیصی خطی[۱۱] با برآوردگر انقباضی[۱۲] ماتریس کوواریانس [۱۱۳]؛ همان تحلیل پس از کاهش ابعاد به ۴۰ مؤلفه با تحلیل مؤلفه‌های اصلی[۱۳]؛ و یک لایه‌ی خطی که آموزش آن با توقف زودهنگام روی زیرمجموعه‌ای گروه‌بندی‌شده از داده‌ی آموزش کنترل می‌شود. انتخاب سرهای خطی آگاهانه است. با ۳۴۷ نمونه‌ی آموزشی و ابعاد ویژگی هم‌مرتبه‌ی آن، یک سر غیرخطی به‌آسانی بیش‌برازش می‌کند؛ مهم‌تر از آن، سر خطی دقیقاً همان چیزی را می‌سنجد که این آزمایش می‌پرسد، یعنی اطلاعاتی که در خود بازنمایی به‌شکل خطی موجود است. این شیوه‌ی ارزیابی بازنمایی، کاوش خطی[۱۴] نام دارد [۱۱۱]. مقیاس‌بندی ویژگی‌ها و کاهش ابعاد تنها روی داده‌ی آموزشِ هر تا برازش می‌شوند. ارزیابی با اعتبارسنجی متقاطع پنج‌تایی گروه‌بندی‌شده بر اساس بررسی روی مجموعه‌ی آموزش و اعتبارسنجی، و سپس با یک ارزیابی واحد روی همان مجموعه‌ی آزمون طبقه‌بند اندامی انجام می‌شود.

۳-۵ هم‌ترازسازی تصویر بین‌فازی چندگذره

هدف این بخش، ساختن جفت‌های هم‌تراز از فاز بدون‌کنتراست و فازهای کنتراست‌دار یک بیمار است تا در ادامه به‌عنوان پیکره‌ی آموزشی سنتز به کار آید. این هدف، شکل مسئله را تعیین می‌کند: هم‌ترازی در این‌جا محصول نهایی نیست، بلکه گامی میانی است که خروجی‌اش باید هم دقیق و هم *از نظر فیزیکی* معتبر باشد. شکل ۳-۱ کل زنجیره را از خواندن DICOM تا ارزیابی نشان می‌دهد و در ستون کنار خود وضعیت داده را پس از هر گام مجسم می‌کند.

ایده‌ی مرکزی: محدودسازی دامنه، نه وزن‌دهی

معیارهای کلاسیک هم‌ترازسازی چندوجهی، به‌ویژه اطلاعات متقابل[۱۵] [۴۵، ۴۷]، بر این فرض بنا شده‌اند که میان شدت روشنایی دو تصویر یک رابطه‌ی آماری *یکنواخت در سراسر تصویر* برقرار است. تزریق ماده‌ی حاجب این فرض را نقض می‌کند و نقض آن یکنواخت نیست: آئورت ممکن است بیش از صد واحد HU

[۱۱] Linear Discriminant Analysis (LDA)
[۱۲] Shrinkage
[۱۳] Principal Component Analysis (PCA)
[۱۴] Linear probing
[۱۵] Mutual information

روشن‌تر شود، کبد چند ده واحد، و استخوان اصلاً تغییر نکند. هیستوگرام مشترک میان دو فاز در نتیجه چندمُدی[۱۶] می‌شود و معیاری که روی کل تصویر تعریف شده است، روی این ناهمگنی حاشیه‌گیری[۱۷] می‌کند و اطلاعات را از دست می‌دهد.

روش‌های آگاه از آناتومی موجود در ادبیات (بخش ۲-۵) به این مشکل با *وزن‌دهی* پاسخ می‌دهند: معیار همچنان روی کل تصویر محاسبه می‌شود، اما سهم نواحی مختلف در آن متفاوت است. پیشنهاد این پایان‌نامه از این نقطه جدا می‌شود:

معیار تراز نباید در نواحی ناپایدار وزن کمتری بگیرد؛ نباید در آن نواحی *محاسبه* شود.

به بیان صوری، اگر $\mathcal{M}$ نقاب اندام‌های پایدار در برابر فاز باشد، معیار S نه به‌صورت $\sum_x w(x)\, s(x)$ با w کوچک بیرون از $\mathcal{M}$، بلکه به‌صورت $\sum_{x\in\mathcal{M}} s(x)$ تعریف می‌شود. تفاوت این دو، در حالتی که w به صفر میل کند، از نظر ریاضی از میان می‌رود؛ اما در عمل تفاوت اساسی است، زیرا در فرمول‌بندی وزنی، هیستوگرام مشترک—که اطلاعات متقابل از آن ساخته می‌شود—همچنان از وکسل‌های ناپایدار انباشته می‌شود و چندمُدی می‌ماند. محدودسازی دامنه، هیستوگرام را نیز محدود می‌کند.

این ادعا آزمون‌پذیر است و طرح آزمایش آن در همین بخش تعبیه شده: اگر تفسیر بالا درست باشد، محدودسازی دامنه باید در اندام‌هایی که شدت روشنایی‌شان با کنتراست تغییر می‌کند سود بدهد و در استخوان، که تغییر نمی‌کند، سودی نداشته باشد. نتیجه‌ی این آزمون در بخش ۲-۴ گزارش شده است.

نسبت با نزدیک‌ترین کارهای پیشین

سه خط پژوهشی مرورشده در بخش ۲-۵ در ظاهر به همین ایده نزدیک‌اند و تفکیک آن‌ها از پیشنهاد حاضر ضروری است. روش‌های وزن‌دهی [۶۱، ۶۰] معیار را همچنان روی کل تصویر محاسبه می‌کنند و تنها سهم نسبی نواحی را تغییر می‌دهند؛ روش‌های مبتنی‌بر پیشین شکل [۶۳] آناتومی را به‌عنوان قید بر فضای راه‌حل وارد می‌کنند؛ و روش برچسب‌محور هو و همکاران [۶۲] معیار شدت‌محور را به‌کلی کنار می‌گذارد. تفاوت با مورد سوم، که از همه نزدیک‌تر است، در چهار محور خلاصه می‌شود.

یکم، موضع مداخله. در [۶۲] تابع هزینه از هم‌پوشانی نقاب‌ها ساخته می‌شود و شبکه هرگز بابت تطبیق شدت روشنایی پاداش نمی‌گیرد؛ در پیشنهاد حاضر معیار همچنان شدت‌محور است و تنها *دامنه‌ی فضایی* محاسبه‌اش محدود می‌شود. یعنی اطلاعات بافتی *درون* اندام‌های پایدار همچنان به کار می‌آید، در حالی که در روش برچسب‌محور تنها مرز نقاب‌ها دیده می‌شود.

[۱۶] Multi-modal
[۱۷] Marginalise

دوم، معیار انتخاب ساختارها. در ادبیات موجود، انتخاب ساختارها بر پایه‌ی اهمیت آناتومیک یا در دسترس بودن برچسب است؛ در این‌جا معیار انتخاب صریحاً *پایداری در برابر تزریق ماده‌ی حاجب* است، و ساختارهایی مانند روده و دوازدهه که میان دو اسکن حرکت غیرقابل‌مدل‌سازی دارند به‌طور صریح حذف می‌شوند.

سوم، نبود مرحله‌ی آموزش. روش‌های یادگیری‌محور به پیکره‌ای از جفت‌های برچسب‌خورده نیاز دارند و نگاشت آموخته‌شده‌شان بدون بازآموزی به مرکز یا پروتکل جدید منتقل نمی‌شود. پایپ‌لاین حاضر بهینه‌سازی به‌ازای هر جفت است و چنین پیکره‌ای لازم ندارد؛ دقیقاً همان منبعی که بخش ۲-۳ کمیابی‌اش را مستند کرد.

چهارم، هدف. در ادبیات، هم‌ترازسازی محصول نهایی است و با TRE یا دایس سنجیده می‌شود تا نشان دهد روش چقدر خوب است. در این‌جا هم‌ترازسازی یک *گام ساخت داده* است: فاصله‌ی باقی‌مانده میان نقاب‌های اندام پس از هم‌ترازسازی، شاخص کیفیت همان جفت داده است و هم به‌عنوان *دروازه‌ی پذیرش* و هم به‌عنوان سندِ کیفیت پیکره‌ی آموزشی سنتز به کار می‌رود.

وابستگی مشترک. هر دو رویکرد به یک مدل بخش‌بندی از پیش‌آموزش‌دیده برای تولید نقاب متکی‌اند و این وابستگی باید صریح بماند. تفاوت در *نحوه‌ی انتشار خطا* است: در روش برچسب‌محور نقاب خودِ تابع هدف است و هر خطای بخش‌بندی مستقیماً به خطای هم‌ترازی ترجمه می‌شود، در حالی که این‌جا نقاب تنها تعیین می‌کند معیار *کجا* محاسبه شود و معیارِ درون آن همچنان از شدت روشنایی واقعی ساخته می‌شود. افزون بر آن، پوشش نقاب در هر مورد پایش می‌شود تا شکست بخش‌بندی پیش از تفسیر نتیجه شناسایی شود.

ساخت نقاب لایه‌بندی‌شده

نقاب $\mathcal{M}$ از حجم برچسب ادغام‌شده‌ی بخش ۳-۳ ساخته می‌شود. معیار لایه‌بندی، همان‌طور که گفته شد، پایداری ساختار در برابر کنتراست است:

- **لایه‌ی ۱ ـ استخوان.** مهره‌ها، دنده‌ها، لگن، جناغ و طناب نخاعی. این ساختارها صلب‌اند و شدت روشنایی‌شان به‌کلی مستقل از فاز کنتراست است؛ پس بالاترین اعتماد را دارند و مرجع صحت‌سنجی گذرهای صلب‌اند.
- **لایه‌ی ۲ ـ بافت نرم پایدار.** کبد، طحال، کلیه‌ها، پانکراس، کیسه‌ی صفرا و عضلات محوری. این‌ها با کنتراست تغییر می‌کنند اما شکل و موقعیتشان پایدار است.

- **لایه‌ی ۳ ـ سایر بافت نرم.** معده، مثانه، غدد فوق‌کلیه و لوب‌های ریه. تنها در نقاب *ارزیابی* حضور دارند.

- **حذف‌شده.** روده‌ی بزرگ و کوچک، دوازدهه و رکتوم. این ساختارها میان دو اسکن به‌دلیل حرکت دودی و گاز جابه‌جایی غیرقابل‌مدل‌سازی دارند و حضورشان در معیار تراز، خطا وارد می‌کند و نه اطلاعات.

نقاب هم‌ترازسازی از لایه‌های ۱ و ۲ ساخته می‌شود و نقاب ارزیابی از هر سه لایه. جدا نگه‌داشتن این دو، شرط لازم برای معنادار بودن ارزیابی است: اگر معیار ارزیابی همان نقابی باشد که بهینه شده است، عدد به‌دست‌آمده کیفیت هم‌ترازی را نمی‌سنجد بلکه موفقیت بهینه‌ساز را در بهینه‌کردن خودش می‌سنجد. پوشش نقاب (درصد وکسل‌های حجم) نیز در هر مورد ثبت می‌شود؛ پوشش بسیار کم نشانه‌ی شکست بخش‌بندی است و باید پیش از تفسیر نتیجه شناسایی شود.

استانداردسازی هندسه و شدت روشنایی

پیش از هر محاسبه‌ی هندسی، هر سری از جهت‌های راهنمای DICOM به قرارداد LPS بازآرایی و به فاصله‌ی وکسل همسان‌گرد ۱٫۵ میلی‌متر بازنمونه‌برداری می‌شود. دو جزئیات این گام، که در نگاه نخست پیاده‌سازی به نظر می‌رسند، در عمل تعیین‌کننده‌اند.

نخست، *مقدار پرکننده‌ی مرز* در بازنمونه‌برداری به‌صورت ثابت منفی ۱۰۲۴ واحد HU (هوا) تعیین می‌شود و نه کمینه‌ی خود تصویر. اسکنرهای سی‌تی وکسل‌های بیرون از میدان دید را با یک مقدار نشانه[۱۸] ذخیره می‌کنند که پس از اعمال شیب و عرض‌ازمبدأ به منفی ۴۰۴۸ واحد HU می‌رسد؛ استفاده از این مقدار به‌عنوان پرکننده، هر وکسل مرزی حاصل از بازنمونه‌برداری را با عددی پر می‌کند که هیچ بافتی تولید نمی‌کند و هیستوگرام مشترک را آلوده می‌کند.

دوم، بازه‌ی HU از منفی ۱۰۲۴ تا ۳۰۰۰ برش داده می‌شود. کران پایین همان مقدار نشانه را حذف می‌کند. کران بالا عمداً بالاتر از ۱۰۲۴ انتخاب شده است: برش در ۱۰۲۴ استخوان متراکم قشری را می‌بُرد و کیفیت بخش‌بندی ساختارهای اسکلتی را، که در گذرهای بعدی نقش لنگر هندسی دارند، به‌طور محسوس کاهش می‌داد.

[۱۸] Sentinel value

پنجره‌ی برش مشترک

دو سری از یک بررسی اغلب محدوده‌ی آناتومیک یکسانی را پوشش نمی‌دهند؛ یکی ممکن است از دیافراگم آغاز شود و دیگری از حفره‌ی لگن. هر معیار شباهتی که روی کل میدان دید تعریف شود، در این وضعیت بخشی از یک حجم را با هوا یا با بافتی مقایسه می‌کند که در حجم دیگر اصلاً تصویر نشده است. این خطا از جنس نویز نیست؛ سیستماتیک است و بهینه‌ساز را به سمت راه‌حل غلط می‌کشد.

راه‌حل این پایان‌نامه ساده و پیش از هر بهینه‌سازی است: از نقاب اندام‌ها، یک پنجره‌ی برش مشترک میان دو فاز استخراج و هر دو حجم به همان پنجره محدود می‌شوند. کران بالای پنجره از بالاترین ساختار قابل‌اتکای مشترک (قلب) و کران پایین آن از پایین‌ترین (مثانه) گرفته می‌شود. نتیجه، دو حجم با محدوده‌ی آناتومیک یکسان است که معیار شباهت روی آن‌ها معنا دارد.

اهمیت این گام از سهم عددی‌اش در دقت نهایی روش پیشنهادی فراتر می‌رود، و دلیلش این است که این گام به هیچ موتور هم‌ترازسازی خاصی وابسته نیست. هر روشی که ورودی سه‌بعدی می‌گیرد می‌تواند پس از آن قرار بگیرد. بخش ۴-۲ این ترکیب‌پذیری را به‌صورت کمّی می‌آزماید: چند روش شناخته‌شده‌ی هم‌ترازسازی [۵۰، ۴۸، ۶۸] یک‌بار روی حجم خام و یک‌بار روی خروجی همین گام، با پارامترهای یکسان، اجرا شده‌اند. به این ترتیب پیش‌پردازش این پایان‌نامه نه فقط در نقش رقیب آن روش‌ها، بلکه به‌عنوان گامی *پیش از* آن‌ها نیز سنجیده می‌شود.

هم‌ترازسازی صلب دوگذره

انتخاب تبدیل صلب در این‌جا یک محدودیت تحمیل‌شده نیست بلکه یک الزام کاربرد است. خروجی این پایپ‌لاین به شبکه‌ی سنتز خورانده می‌شود و تغییرشکل غیرصلبی که دترمینان ژاکوبین آن نامثبت شود، بافت را در آن ناحیه *جعل* می‌کند؛ یعنی پیکره‌ی آموزشی را با ساختاری آلوده می‌کند که در بدن بیمار وجود نداشته است. تبدیل صلب، به‌طور ساختاری و نه با تنظیم پارامتر، از این خطا مصون است.

گذر صفر ـ مقداردهی اولیه‌ی بسته. به‌جای آغاز بهینه‌سازی از تبدیل همانی، یک تبدیل صلب اولیه به‌صورت بسته و بدون بهینه‌سازی تکراری محاسبه می‌شود. مرکز جرم هر اندامِ نقاب هم‌ترازسازی در دو حجم به‌عنوان یک زوج نقطه‌ی متناظر در نظر گرفته می‌شود و چرخش و انتقال بهینه میان دو مجموعه نقطه با تجزیه‌ی مقادیر منفرد[۱۹] به روش کابش [۱۱۴] به دست می‌آید. یک نگهبان روی دترمینان ماتریس چرخش تضمین می‌کند که راه‌حل یک چرخش سره باشد و نه یک بازتاب؛ بدون این قید، دو حجم با

[۱۹] Singular value decomposition, SVD

جهت‌گیری آینه‌ای را می‌توان با نگاشت هر اندام به قرینه‌ی آناتومیک آن «هم‌تراز» کرد.

استفاده از هر دو لایه، و نه فقط استخوان، تصمیمی تجربی است: نسخه‌ی نخست این گذر تنها بر لنگرهای استخوانی تکیه می‌کرد و افزودن اندام‌های نرم پایدار به‌طور یکنواخت نتیجه‌ی بهتری داد، چرا که تعداد نقاط متناظر را افزایش و شرطی‌شدگی[۲۰] مسئله‌ی SVD را بهبود می‌دهد.

گذر یک ـ پالایش با زیان آناتومیک. گذر دوم، تبدیل صلب را با کمینه‌سازی یک زیان *آناتومیک* و نه یک زیان مبتنی‌بر شدت روشنایی پالایش می‌کند:

$$\mathcal{L}(T) \;=\; \lambda\, d_c(T) \;+\; \big(۱ - \mathrm{Dice}_\epsilon(T)\big), \qquad \lambda = ۱۰, \tag{۲-۳}$$

که در آن d_c میانگین وزن‌دار جابه‌جایی مرکز جرم و Dice_ϵ ضریب دایس *فرسوده* است. هر دو جمله تنها روی یک زیرمجموعه‌ی گزیده از ۱۱ اندام محاسبه می‌شوند: کبد، طحال، دو کلیه، پانکراس، کیسه‌ی صفرا، آئورت، بزرگ‌سیاهرگ زیرین و سه مهره‌ی کمری نخست. ساختارهایی که موقعیتشان میان دو فاز ناپایدار است——معده و مری به‌دلیل حرکت دودی و پرشدگی، و عروق ایلیاک به‌دلیل تغییر شدید شدت روشنایی با کنتراست——به‌صراحت از این دامنه بیرون گذاشته شده‌اند.

شعاع فرسایش به‌ازای هر اندام و متناسب با اندازه‌ی آن تعیین می‌شود، از ۶ میلی‌متر برای کبد تا ۱٫۵ میلی‌متر برای مهره‌ها، تا ساختارهای کوچکِ دارای مرز نویزی نتوانند بر زیان مسلط شوند.

بهینه‌سازی با روش سیمپلکس نلدر–مید [۱۱۵] انجام می‌گیرد. انتخاب یک بهینه‌ساز بدون مشتق در این‌جا یک راه‌حل جایگزین نیست بلکه یک ضرورت است: ضریب دایس روی نقاب‌های دودویی گسسته محاسبه می‌شود و نسبت به پارامترهای تبدیل مشتق‌پذیر نیست، در نتیجه هیچ بهینه‌ساز گرادیانی روی این زیان تعریف نمی‌شود.

چرا دو گذر و نه یکی. این دو گذر جانشین یکدیگر نیستند و هم‌نشینی‌شان یک تصمیم آگاهانه است. گذر صفر یک حل بسته روی مرکز جرم است و طبیعتاً موقعیت درشت اندام‌های نرم بزرگ را تصحیح می‌کند؛ گذر یک یک جست‌وجوی محلی روی هم‌پوشانی نقاب است و طبیعتاً انطباق دقیق ساختارهای صلب و پرجزئیات را سفت می‌کند. انتظار می‌رود اثر این دو گذر روی گروه‌های اندامی متفاوتی ظاهر شود، و بخش ۲–۴ نشان می‌دهد که همین‌طور است. این تفکیک، مهم‌ترین شاهد ساختاری به سود طرح دوگذره است.

---

[۲۰] Conditioning

دروازه‌های پذیرش. هر گذر پالایشی با یک *دروازه‌ی پذیرش* همراه است: پس از اجرای گذر، خطای مرکز جرم دوباره اندازه‌گیری می‌شود و اگر نسبت به گذر پیشین بدتر شده باشد، تبدیل گذر پیشین حفظ و نتیجه‌ی گذر جدید دور ریخته می‌شود. این ساز و کار یک جزئیات مهندسی نیست بلکه یک تصمیم روش‌شناختی است: زنجیره‌ای از گذرهای پالایشی، بدون دروازه، هر شکست یک گذر را به همه‌ی گام‌های پایین‌دستی منتقل می‌کند و آن را در انبوه داده پنهان می‌سازد. با دروازه، بدترین حالتِ یک گذرِ ناموفق «بی‌اثر» است و نه «مخرب». چنان‌که در بخش ۴-۲ دیده می‌شود، این تمایز در عمل تعیین‌کننده شد و دقیقاً یکی از گذرها را از عامل خرابی به عامل بی‌اثر تبدیل کرد.

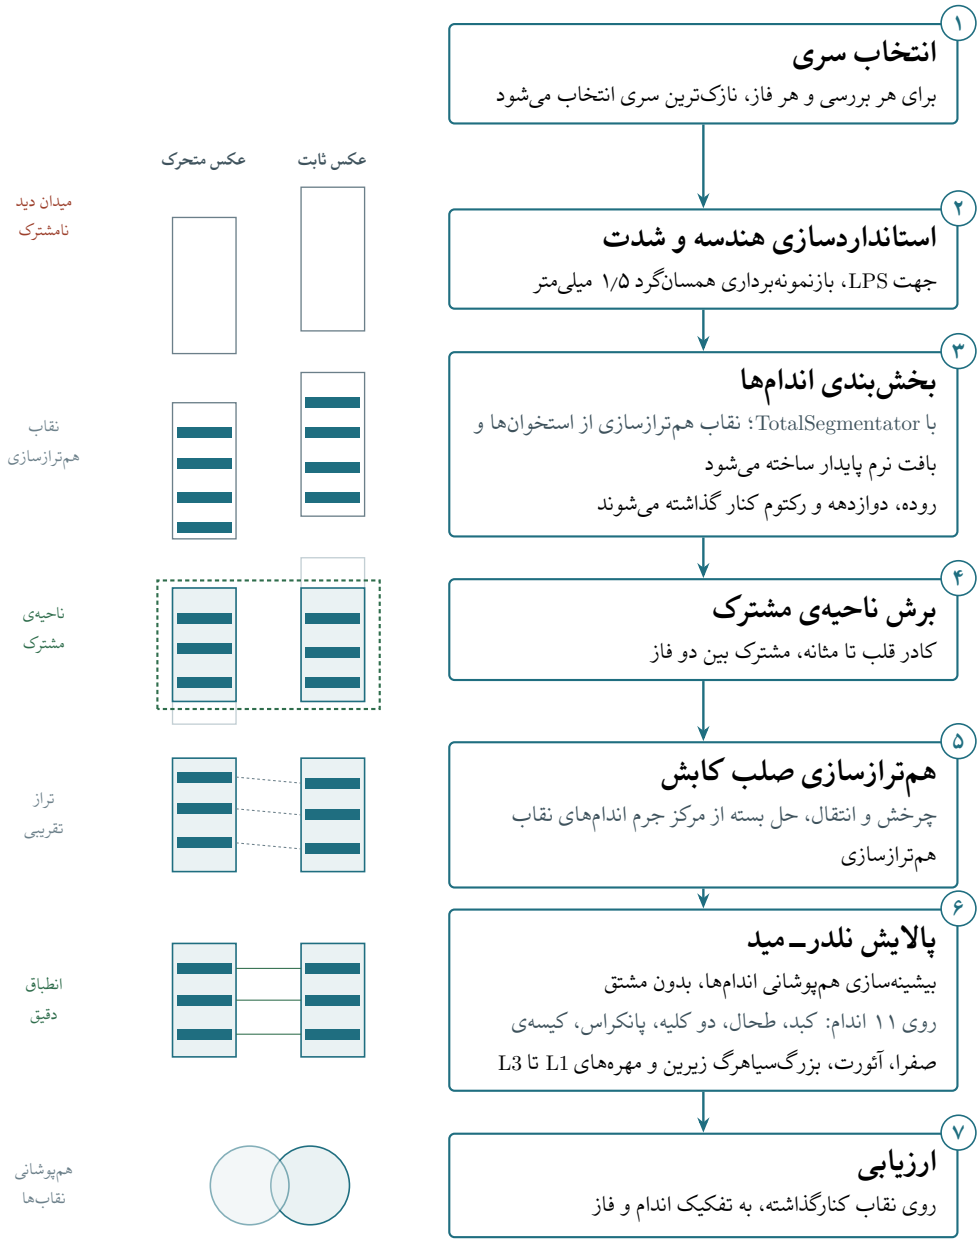
پیاده‌سازی همه‌ی گذرها بر پایه‌ی SimpleITK [۵۵] است و هیچ مرحله‌ی آموزشی و هیچ پردازنده‌ی گرافیکی لازم ندارد.

گذر اختیاری پالایش غیرصلب

مسیر پیشنهادی با دو گذر صلب پایان می‌یابد، اما پس از آن پرسشی باز می‌ماند: جفت‌های حاصل تا چه اندازه هم‌ترازند، و ناهم‌ترازی باقی‌مانده در کدام اندام‌هاست؟ تبدیل صلب بنا به تعریف نمی‌تواند تغییرشکل تنفسی یا جابه‌جایی محلی اندام‌های نرم را جبران کند، و معیارهای ارزیابی این بخش خطای کل را می‌سنجند و سهم بخش غیرصلب آن را جدا نمی‌کنند. برای پاسخ به این پرسش، یک گذر پالایش غیرصلب به‌صورت *اختیاری* پس از گذر یک تعریف شده است.

این گذر از خروجی گذر یک آغاز می‌کند و یک تبدیل B-اسپلاین آزادشکل مکعبی [۵۷] را روی شبکه‌ی کنترلی با فاصله‌ی ۲۵ میلی‌متر برآورد می‌کند. معیار آن همبستگی متقاطع نرمال‌شده‌ی محلی با شعاع همسایگی ۴ وکسل است و روی بزرگی گرادیان شدت روشنایی محاسبه می‌شود، نه روی خود مقدار HU؛ به همان دلیلی که سطح روشنایی میان دو فاز قابل‌اتکا نیست. دامنه‌ی این معیار نیز، هم‌راستا با ایده‌ی مرکزی این بخش، به نقاب اندام‌ها محدود است. نقاب تصویر ثابت با گشادسازی ۴ تا ۸ میلی‌متری، بسته به ساختار، ساخته می‌شود و نقاب تصویر متحرک با ۱۲ میلی‌متر گشادسازی بیشتر، تا خطای باقی‌مانده‌ی گذرهای صلب را در بر بگیرد. بهینه‌سازی با L-BFGS-B در سه سطح هرم تفکیک، با کوچک‌سازی ۴، ۲ و ۱ برابر و حداکثر ۳۰۰ تکرار در هر سطح، انجام می‌شود و معیار با نمونه‌گیری تصادفی از ۱۵ درصد وکسل‌های دامنه برآورد می‌شود.

برخلاف گذرهای صلب، این گذر به‌طور ساختاری از تاخوردگی مصون نیست. به همین دلیل درصد تاخوردگی برای هر جفت اندازه‌گیری و گزارش می‌شود، اما دروازه‌ی پذیرشی بر آن گذاشته نشده است: دروازه‌ای که با کمترین تاخوردگی نتیجه را به خروجی صلب برگرداند، اثر گذر را پنهان و آن را از یک سنجه



شکل ۳-۱: معماری پایپ‌لاین پیشنهادی. ستون راست گام‌ها و ستون چپ وضعیت داده پس از هر گام است. در ستون چپ، هر میله محور z یک حجم را نشان می‌دهد و نوارهای تیره اندام‌های نقاب هم‌ترازسازی‌اند. اختلاف طول و افست دو میله در گام ۲ همان میدان دید نامشترک است که در گام ۴ حذف می‌شود؛ خط‌چین‌های خاکستری در گام ۵ تراز تقریبی و خطوط سبز در گام ۶ انطباق دقیق اندام‌ها را نشان می‌دهند. سهم اندازه‌گیری‌شده‌ی هر گام در فصل نتایج گزارش شده است.

به یک صافی تبدیل می‌کند.

این گذر در این پایان‌نامه دو نقش دارد و هیچ‌یک ادعای دقت برتر نیست. نقش نخست سنجش است. چون گذر تنها تغییرشکل محلی به خروجی صلب می‌افزاید، فاصله‌ی دقت آن با خروجی صلب، اندام به اندام، اندازه‌ای از ناهم‌ترازی غیرصلب باقی‌مانده در جفت‌هاست و نشان می‌دهد جفت‌هایی که به سنتز داده می‌شوند در کدام نواحی آماده‌اند. همین سنجش، گام‌های پیش‌پردازش را نیز از زاویه‌ای دیگر می‌آزماید: اگر خروجی پیش‌پردازش و گذرهای صلب نقطه‌ی شروع مناسبی باشد، یک روش کلاسیک و بدون آموزش باید از همان‌جا به دقت روش‌های غیرصلب موجود نزدیک شود. نقش دوم *پالایش* است: در ساخت برون‌خط جفت‌ها، وقتی دقت اندام‌های نرم اولویت دارد و زمان محدودیت نیست، خروجی این گذر می‌تواند جای خروجی صلب را بگیرد. نتایج هر دو نقش و هزینه‌ی زمانی گذر در بخش ۴-۲ گزارش شده است. چون این هزینه بیش از یک مرتبه بالاتر از مسیر صلب است، گذر غیرصلب جزو مسیر پیش‌فرض نیست و در شکل ۳-۱ نیامده است.

طرح آزمایش برای سنجش ادعای دامنه

ادعای مرکزی این بخش این است که سود از *محدودسازی دامنه‌ی* معیار به اندام‌های پایدار می‌آید. برای سنجش آن، گذر پالایشی صلب با چهار تابع هدف متفاوت اجرا می‌شود، در حالی که مدل تبدیل، مقداردهی اولیه و خطکش ارزیابی ثابت می‌مانند: ترکیب خطای مرکز اندام و دایس فرسوده؛ همبستگی لبه‌های دو تصویر (بزرگی گرادیان سوبل) روی *کل* تصویر و بدون نقاب؛ توصیفگر ساختاری MIND [۴۹] محدود به نقاب؛ و ترکیب خطای مرکز اندام، دایس و همبستگی لبه‌ها محدود به نقاب.

ردیف دوم تنها تابع هدفی است که روی کل تصویر محاسبه می‌شود و سه ردیف دیگر به نقاب اندام محدودند. این طرح محدودیتی دارد که باید صریح بماند: ردیف دوم افزون بر دامنه، در *نوع* معیار نیز با ردیف‌های دیگر تفاوت دارد، زیرا نسخه‌ی محدود به نقابِ همان معیار لبه اجرا نشده است. بنابراین این مقایسه نشان می‌دهد توابع هدفی که به نقاب اندام تکیه دارند بهتر عمل می‌کنند، اما سهم خودِ دامنه را از سهم نوع معیار جدا نمی‌کند. شاهد تکمیلی، الگوی اثر در گروه‌های اندام است که همراه با نتیجه‌ی این آزمایش در بخش ۴-۲ گزارش می‌شود.

معیارهای ارزیابی

کیفیت هم‌ترازی با کمیت‌های زیر سنجیده می‌شود که همگی روی نقاب *ارزیابی* محاسبه می‌شوند:

- **ضریب دایس فرسوده**[۲۱]: ضریب دایس پس از فرسایش هر دو نقاب در فضای فیزیکی. فرسایش، حساسیت معیار به نویز مرزی بخش‌بندی را کاهش می‌دهد و آن را به تراز مرکز اندام حساس‌تر می‌کند.
- **فاصله‌ی هاسدورف صدک ۹۵**: کران بالای فاصله‌ی سطحی، مقاوم نسبت به تعداد اندکی وکسل پرت.
- **جابه‌جایی مرکز جرم**: بر حسب میلی‌متر، روی نقاب‌های فرسوده‌نشده.
- **همبستگی گرادیان درون اندام**: میزان انطباق ساختار لبه‌ای، مستقل از سطح روشنایی.
- **همبستگی توصیفگر MIND**: انطباق ساختار خودمشابه، معیاری مستقل از هر دو مورد بالا.
- **درصد تاخوردگی**: تنها برای روش‌های غیرصلب؛ سهم وکسل‌هایی با دترمینان ژاکوبین نامثبت. این کمیت *دقت* را نمی‌سنجد بلکه *اعتبار فیزیکی* تغییرشکل را می‌سنجد و بدون آن، مقایسه‌ی یک روش غیرصلب با یک روش صلب بی‌معناست.

همبستگی متقاطع روی HU خام عمداً از این فهرست کنار گذاشته شده است: این معیار وجود رابطه‌ی خطی میان شدت روشنایی متناظر دو تصویر را فرض می‌کند و تزریق ماده‌ی حاجب همین فرض را نقض می‌کند، از این رو مقدار آن میان دو فاز نویز است و نه سیگنال.

یازده اندام ارزیابی برای گزارش در سه گروه دسته‌بندی می‌شوند: *اندام‌های نرم* (کبد، طحال، دو کلیه، پانکراس و کیسه‌ی صفرا)، *رگ‌های بزرگ* (آئورت و بزرگ‌سیاهرگ زیرین) و *مهره‌ها* (سه مهره‌ی نخست کمری). گروه مهره‌ها نقش *گروه کنترل* را دارد: استخوان با کنتراست تغییر نمی‌کند، پس خطای باقی‌مانده در آن نشانه‌ی شکست هم‌ترازسازی است و نه دشواری ناشی از کنتراست. همین گروه است که ادعای بخش «ایده‌ی مرکزی» را ابطال‌پذیر می‌کند: اگر محدودسازی دامنه در مهره‌ها هم به همان اندازه سود بدهد، تفسیر ارائه‌شده نادرست است.

سنجش هزینه‌ی محاسباتی

هزینه‌ی هر روش با دو کمیت و به‌ازای هر جفت فاز سنجیده می‌شود.

- **زمان اجرا**: زمان واقعی سپری‌شده از آغاز فراخوانی روش هم‌ترازسازی تا بازگشت نتیجه. خواندن حجم‌ها از دیسک و ذخیره‌ی خروجی بیرون از این بازه‌اند. گام‌هایی که تنها برای ارزیابی اجرا

[۲۱] Eroded Dice

می‌شوند جداگانه زمان‌سنجی و از زمان روش کنار گذاشته می‌شوند؛ مهم‌ترین نمونه، بازسازی میدان جابه‌جایی چگال DEEDS است که فقط برای سنجش تاخوردگی لازم است و سه اجرای اضافه‌ی برنامه را در بر می‌گیرد.

- **بیشینه‌ی حافظه**: بیشترین حافظه‌ی فیزیکی اشغال‌شده در طول اجرا، برابر با مجموع حافظه‌ی فرایند اجراکننده و همه‌ی *فرایندهای فرزند* آن. شمردن فرایندهای فرزند برای روشی مانند DEEDS ضروری است که به‌صورت برنامه‌های اجرایی جداگانه اجرا می‌شود؛ برای روش‌هایی که درون همان فرایند اجرا می‌شوند، این مقدار با حافظه‌ی خود فرایند برابر است.

روش‌هایی که درون فرایند اجرا می‌شوند (مسیر صلب، ANTs-SyN و uniGradICON) با ابزار پروفایل مشترک اندازه‌گیری شدند که حافظه‌ی همان فرایند را هر ۰٫۲۵ ثانیه نمونه‌برداری می‌کند. این ابزار حافظه‌ی DEEDS را نمی‌بیند و زمان آن را همراه با بازسازی میدان ثبت می‌کند؛ گذر B ـ اسپلاین نیز با آن اندازه‌گیری نشده بود. برای این دو روش، رویه‌ی جداگانه‌ای اجرا شد که همان جفت‌ها را دوباره هم‌تراز می‌کند، بی‌آن‌که خروجی ارزیابی‌شده را تغییر دهد: حافظه‌ی کل درخت فرایندها هر ۰٫۱ ثانیه نمونه‌برداری می‌شود، زمان هر مرحله‌ی DEEDS (هم‌ترازی خطی اولیه، هم‌ترازی غیرصلب و بازسازی میدان) جداگانه ثبت می‌شود، و گذر B ـ اسپلاین برای هر بررسی در یک فرایند مستقل با پوشه‌ی خروجی موقت اجرا می‌شود. همه‌ی اجراها روی یک سرور با ۸۰ هسته‌ی پردازنده و بدون پردازنده‌ی گرافیکی انجام شده‌اند. برای هر روش *مقدار معمول*، یعنی مقداری که نیمی از اجراها کمتر و نیمی بیشتر از آن‌اند، و بازه‌ای که نیمی از اجراها در آن قرار می‌گیرند گزارش می‌شود.

گام‌های آزموده و کنارگذاشته

دو گام دیگر پیاده‌سازی و ارزیابی شدند اما شواهد، نگه‌داشتن آن‌ها را در مسیر اصلی توجیه نمی‌کند. گزارش آن‌ها در همین‌جا، هم برای شفافیت لازم است و هم برای آن‌که خواننده بداند فضای طراحی تا کجا جست‌وجو شده است.

هم‌ترازی درشت مرکز جرم. در نسخه‌های نخست، پیش از گذرهای صلب یک جابه‌جایی درشت از مرکز جرم چهار اندام بزرگ برآورد و اعمال می‌شد. این گام دروازه‌دار بود و تنها در بخش کوچکی از موارد فعال می‌شد. اندازه‌گیری نشان داد که سهم آن در دقت نهایی معنادار نیست و به‌تنهایی حتی نتیجه را بدتر می‌کند (بخش ۴–۲). این گام تنها در ۴ بررسی جابه‌جایی اعمال کرد و در بیشتر همان موارد، خطای مرکز اندام را به‌جای کاهش به‌طور محسوس افزایش داد؛ رفتاری که با تطبیق نادرست اندام‌ها در این گام سازگار است. گذر صفر همان تصحیح را، به‌صورت بسته و همراه با چرخش، بهتر انجام می‌دهد. این گام از مسیر

پیشنهادی کنار گذاشته شد.

گذر پالایشی روی بزرگی گرادیان. گذر سومی نیز پیاده‌سازی شد که معیار را از شدت روشنایی به بزرگی گرادیان[۲۲] تغییر می‌داد، با این استدلال که تزریق ماده‌ی حاجب *سطح* روشنایی را جابه‌جا می‌کند اما *لبه*ها را در جای خود نگه می‌دارد. استدلال از نظر نظری درست است، اما در این پیکربندی دروازه‌ی پذیرش این گذر را در تقریباً همه‌ی موارد رد کرد، چون خطای مرکز جرمی که تولید می‌کرد بزرگ‌تر از گذر پیشین بود. نتیجه‌ی عملی، یک گذر بی‌اثر است. این یک نتیجه‌ی منفی است و به همین صورت گزارش می‌شود؛ ارزش روش‌شناختی آن در این است که نشان می‌دهد دروازه‌ی پذیرش کار خودش را انجام داده است.

جمع‌بندی مرزهای ادعا. مسیر پیشنهادی، یک زنجیره‌ی صلبِ بدون آموزش است که دامنه‌ی معیارش را به اندام‌های پایدار محدود می‌کند و پیش از آن، میدان دید مشترک را می‌سازد. ادعای این بخش، برتری دقت بر همه‌ی روش‌های موجود نیست؛ چنان‌که بخش ۴-۲ نشان می‌دهد، یک روش غیرصلب مبتنی‌بر بهینه‌سازی گسسته دقت بالاتری به دست می‌آورد، هرچند به بهای تاخوردگی. ادعای این بخش دو چیز است: نخست این‌که توابع هدفی که به نقاب اندام محدودند، در همان گروه‌های اندامی که نظریه پیش‌بینی می‌کند، بهبود قابل‌سنجش می‌دهند؛ و دوم این‌که پیش‌پردازش آناتومی‌محورِ این زنجیره، مستقل از خودِ زنجیره ارزش دارد و شکست‌ها و خطاهای بزرگ روش‌های موجود را نیز کاهش می‌دهد. گذر اختیاری غیرصلب دامنه‌ی این دو ادعا را گسترش نمی‌دهد؛ ابزاری است برای سنجیدن آن‌چه مسیر صلب باقی می‌گذارد، و در صورت نیاز، پالایشی پرهزینه برای ساخت برون‌خط جفت‌ها.

۳-۶ سنتز فاز کنتراست‌دار: شبکه‌ی PLC-Net

صورت‌بندی مسئله

جفت‌های هم‌ترازشده‌ی حاصل از بخش ۳-۵ یک مسئله‌ی ترجمه‌ی تصویر ــ به ــ تصویر نظارت‌شده تعریف می‌کنند: با داشتن حجم بدون‌کنتراست x، حجم کنتراست‌دار y همان بیمار در همان هندسه بازسازی شود.

اما این صورت‌بندی، در همان نگاه نخست ناقص است. «فاز کنتراست‌دار» یک هدف واحد نیست: تصویر فاز شریانی و تصویر فاز وریدی هر دو از یک ورودی بدون‌کنتراست یکسان می‌آیند و هر دو معتبرند. یک مدل که تنها x را می‌بیند، هیچ راهی برای انتخاب میان آن‌ها ندارد و ناگزیر به میانگین‌گیری میان دو

[۲۲] Gradient magnitude

هدف می‌رسد. مسئله پس از ابتدا یک نگاشت *شرطی* است:

$$G:\ (x,\ c) \mapsto \hat{y}, \qquad c = (\text{فاز هدف},\ \text{سطح تقویت هدف}).$$

شبکه‌ی پیشنهادی این پایان‌نامه، **PLC-Net**[۲۳]، دقیقاً همین شرط c را به‌عنوان ورودی درجه‌یک می‌پذیرد. این بخش، مسیر رسیدن به آن، معماری نهایی و منطق ارزیابی‌اش را شرح می‌دهد.

مسیر طراحی: از یک مدل سبک تا شرطی‌سازی کامل

معماری نهایی حاصل یک طراحی یک‌باره نیست، بلکه نتیجه‌ی شش پیکربندی پیاپی است که هر یک در پاسخ به شکست مشخصی از پیکربندی پیش از خود ساخته شد. چون منطق این زنجیره، خودِ استدلال طراحی است، آن را به‌ترتیب می‌آوریم؛ ارقام کامل در فصل ۴ گزارش می‌شوند.

نقطه‌ی شروع: سبک، دوبعدی، تک‌فاز. تصمیم آگاهانه‌ی اولیه این بود که کار با کوچک‌ترین مدل ممکن آغاز شود، یک U-Net دوبعدی روی وصله‌های ۱۲۸ × ۱۲۸، آموزش‌دیده تنها روی جفت‌های فاز وریدی. دلیل این انتخاب، محدودیت داده است: پس از فیلتر کیفیت هم‌ترازی، تنها حدود صد جفت حجمی در دسترس است و یک شبکه‌ی سه‌بعدی با این حجم داده به‌سرعت بیش‌برازش می‌کند.

پیکربندی A ـ چندفازی بدون شرط. نخستین گسترش، افزودن جفت‌های فاز شریانی به استخر آموزش بود تا داده دو برابر شود. نتیجه، همان چیزی بود که پیش‌بینی می‌شد: مدل میان دو هدف میانگین گرفت و دقت تشخیص فاز خروجی به ۰٫۷۰ سقوط کرد. تصویر تولیدشده نه شریانی بود و نه وریدی.

پیکربندی B ـ افزودن شرط فاز. یک بردار شناسه‌ی فاز از طریق سازوکار مدولاسیون ویژگی خطی[۲۴] [۱۱۶] به رمزگشا داده شد. این کم‌هزینه‌ترین تغییر کل مطالعه بود (یک بردار ۶۴ بعدی) و بزرگ‌ترین بازده را داشت: دقت فاز از ۰٫۷۰ به ۱٫۰۰ رسید و خطای سطح اندام نیز به‌طور محسوس کاهش یافت. نکته‌ی تعیین‌کننده این است که مدل چندفازیِ *شرطی* هم‌زمان دو مزیت می‌گیرد: استخر آموزشی دو برابر می‌شود و خروجی مبهم نمی‌ماند.

پیکربندی C ـ افزودن جمله‌ی متخاصم با ضریب متعارف. افزودن یک متمایزکننده با ضریب پیش‌فرض ادبیات ($\lambda_{\text{adv}} = ۲٫۰$) مدل را ویران کرد: خطای سطح اندام بیش از دو برابر شد. لاگ آموزش علت را مستقیم نشان می‌دهد؛ زیان مولد بالا می‌رود در حالی که زیان متمایزکننده ثابت و پایین می‌ماند، یعنی متمایزکننده بر مولد چیره شده است.

---

[۲۳] Phase- and Level-Conditioned Network

[۲۴] Feature-wise Linear Modulation (FiLM)

پیکربندی D ـ افزودن زمینه‌ی محور z. برای نجات بافت بدون بازگشت به ضریب متخاصم پایین، یک پیکربندی ۲٫۵ بعدی به کار رفت: $2k+1$ برش مجاور به‌عنوان کانال ورودی داده می‌شود و تنها برش میانی پیش‌بینی می‌شود. شبکه دوبعدی می‌ماند و تعداد پارامترها تقریباً ثابت است. این تغییر، بافت و انسجام بین‌برشی را بازگرداند.

پیکربندی E ـ شرط سطح، و ضریب متخاصم کالیبره. چند تغییر هم‌زمان اعمال شد: ضریب متخاصم به $\lambda_{\text{adv}} = ۰٫۵$ کاهش یافت، تطبیق ویژگی[۲۵] فعال شد، نرمال‌سازی گروهی به کار رفت، و یک بردار *سطح* *تقویت* در سطح اندام به شرط افزوده شد. چون این تغییرها هم‌زمان‌اند، اثر این گام را نمی‌توان تنها به شرط سطح نسبت داد. در میان پیکربندی‌های این زنجیره، این پیکربندی کمترین FID و نزدیک‌ترین نسبت طیفی به یک را به دست آورد.

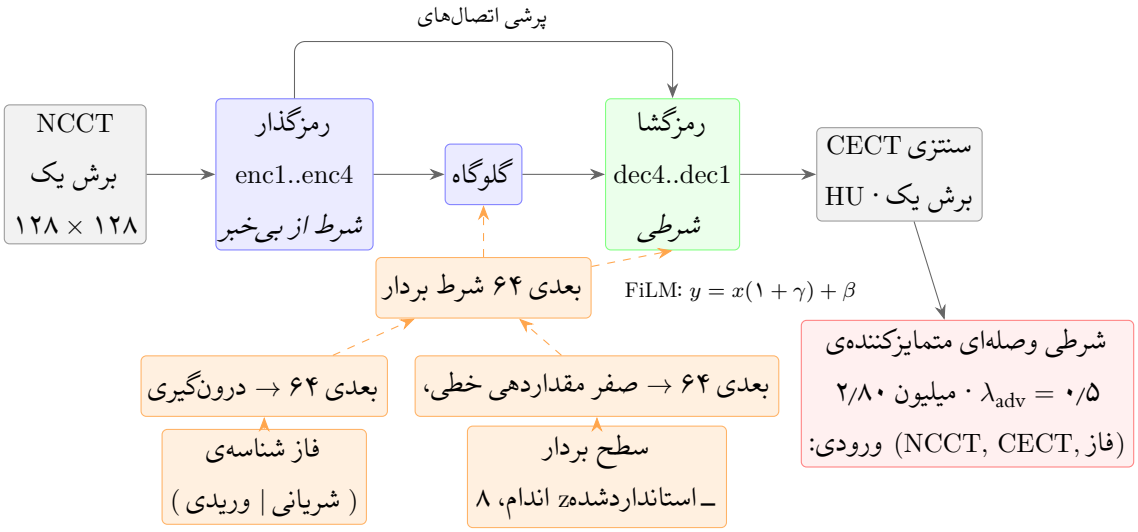
پیکربندی F ـ شرط سطح به‌علاوه‌ی زمینه‌ی z. ترکیب E با ورودی ۲٫۵ بعدی. شیب کالیبراسیون *خام* این پیکربندی بالاتر است و در نگاه اول کنترل‌پذیرتر به نظر می‌رسد، اما فصل ۴ نشان می‌دهد این خوانش نادرست است: سنجیده در برابر سقف درون‌فازی، پاسخ این پیکربندی از دامنه‌ی طبیعی فاز خود فراتر می‌رود و در استنتاج گزارش‌شده، پاسخ آن به شرط فاز ضعیف می‌شود. **مدل نهایی این پایان‌نامه، پیکربندی دوبعدی E با وزن‌های دوره‌ی ۴۵ است**، که تنها پیکربندی‌ای است که هر دو سیگنال کنترل را هم‌زمان نگه می‌دارد.

سه نکته‌ی طراحی از این مسیر بیرون می‌آید که در فصل ۴ به‌صورت کمّی دفاع می‌شوند: ضریب متخاصم در این مسئله یک فراپارامتر حساس است و نه یک جزئیات پیاده‌سازی؛ شرطی‌سازی فاز امکان آموزش یک مدل واحد روی جفت‌های هر دو فاز را فراهم می‌کند و بدین ترتیب داده‌ی آموزشی را دو برابر می‌کند؛ و دو سیگنال شرط (فاز و سطح) تا حد زیادی اطلاعات مشترک دارند، به‌طوری‌که شبکه می‌تواند یکی را به بهای دیگری نادیده بگیرد. این پدیده در بخش ۴-۴ اندازه‌گیری و تحلیل می‌شود.

معماری

PLC-Net یک مولد U-Net با ۱۳٫۵۵ میلیون پارامتر و یک متمایزکننده‌ی وصله‌ای شرطی با ۲٫۸۰ میلیون پارامتر است. شکل ۳-۲ ساختار آن را نشان می‌دهد.

[۲۵] Feature matching



شکل ۳-۲: ساختار PLC-Net. رمزگذار عامدانه از شرط بی‌خبر است و جفت‌های هر دو فاز را می‌بیند؛ تنها رمزگشا از فاز و سطح هدف باخبر می‌شود، از طریق FiLM در گلوگاه و هر چهار مرحله‌ی رمزگشایی. در نسخه‌ی ۲/۵ بعدی (پیکربندی F)، ۱۱ برش مجاور به‌صورت کانال ورودی داده می‌شود.

سه تصمیم معماری در این طرح، بار استدلالی دارند.

رمزگذارِ بی‌خبر از شرط. شرط تنها به رمزگشا داده می‌شود و رمزگذار آن را نمی‌بیند؛ رمزگذار بازنمایی آناتومیکی از ورودی بدون‌کنتراست می‌سازد که به فاز هدف وابسته نیست، و تنها رمزگشا تعیین می‌کند کدام فاز تولید شود. سود داده‌ای این طرح از شرطی‌سازی فاز می‌آید، نه از خودِ این تفکیک: چون یک مدل واحد هر دو فاز را تولید می‌کند، جفت‌های هر دو فاز در یک استخر آموزشی قرار می‌گیرند و تعداد جفت‌های قابل‌استفاده از ۹۷ به ۱۹۳ جفت حجمی دو برابر می‌شود، که با بیش‌برازش اجراهای تک‌فاز روی این داده‌ی کوچک مقابله می‌کند.

مقداردهی اولیه‌ی صفر لایه‌های شرط. لایه‌ی خروجی هر بلوک FiLM (و نیز لایه‌ی خطیِ مسیر سطح) با وزن صفر مقداردهی می‌شود، به‌طوری‌که در گام صفر آموزش، $\gamma = \beta = ۰$ و شبکه بیت‌به‌بیت با یک مدل *بدون شرط* یکسان است. این کار دو فایده دارد: آموزش از یک نقطه‌ی پایدار و شناخته‌شده آغاز می‌شود، و (مهم‌تر) بزرگی آموخته‌شده‌ی $|\gamma|$ به یک *شاهد قابل‌اندازه‌گیری* تبدیل می‌شود بر این‌که آیا رمزگشا واقعاً از شرط استفاده می‌کند یا آن را نادیده می‌گیرد.

متمایزکننده‌ی شرطی. ورودی متمایزکننده الحاق تصویر مبدأ، تصویر مقصد و شناسه‌ی فاز است. متمایزکننده‌ی غیرشرطی نمی‌تواند تشخیص دهد که تصویر تولیدشده به *این* ورودی و به *این* فاز مربوط است یا نه، و صرفاً واقع‌نمایی کلی را پاداش می‌دهد.

تابع زیان و برنامه‌ی آموزش

تابع هدف مولد ترکیبی چهارجزئی است:

$$\mathcal{L}_G \;=\; ۱۰۰ \cdot \mathcal{L}_۱ \;+\; ۲۰ \cdot \mathcal{L}_۱^{\text{اندام}} \;+\; ۰/۵ \cdot \mathcal{L}_{\text{adv}}^{\text{LSGAN}} \;+\; ۱۰ \cdot \mathcal{L}_{\text{feat}},$$

که در آن $\mathcal{L}_۱^{\text{اندام}}$ زیان $L_۱$ وزن‌دار در سطح اندام است و $\mathcal{L}_{\text{feat}}$ تطبیق ویژگی. ضریب $\mathcal{L}_۱$ در طول آموزش کاهش می‌یابد (از ۱۰۰ تا دوره‌ی ۱۰ به ۲۵ از دوره‌ی ۳۰) تا در مراحل اولیه ساختار کلی و در مراحل بعدی جزئیات بافتی شکل بگیرد، و جمله‌ی متخاصم با گرم‌شدن پنج دوره‌ای وارد می‌شود.

وزن‌های سطح‌اندام لایه‌بندی‌شده‌اند و بر اساس اهمیت هر اندام در تعیین فاز کنتراست تعیین می‌شوند. روده وزن *صفر* می‌گیرد: محتوای گاز و مدفوع آن میان دو اسکن تغییر می‌کند و از روی فاز بدون‌کنتراست قابل استنتاج نیست، پس آموزش مدل برای بازسازی آن، ظرفیت را صرف نویز می‌کند. روده همچنان *ارزیابی* می‌شود، صرفاً *آموزش* داده نمی‌شود.

انتخاب $\lambda_{\text{adv}} = ۰/۵$ به‌جای مقدار متعارف ۲/۰ یک تنظیم دلبخواه نیست بلکه مستقیماً از پیکربندی C می‌آید و در فصل ۴ با عدد پشتیبانی می‌شود.

بهینه‌ساز آدام با نرخ یادگیری ۲×۱۰^{-۴} برای مولد و ۱×۱۰^{-۴} برای متمایزکننده، اندازه‌ی دسته‌ی ۱۶، وصله‌های ۱۲۸×۱۲۸، نرمال‌سازی گروهی [۱۱۷]، و حداکثر ۷۰ دوره با توقف زودهنگام و صبر ۳۰. آموزش پیکربندی E در دوره‌ی ۴۵ و پیکربندی F در دوره‌ی ۵۳ متوقف شد. وزن‌های گزارش‌شده بر پایه‌ی معیارهای مجموعه‌ی اعتبارسنجی و بازبینی بصری خروجی‌های همان مجموعه انتخاب شدند: دوره‌ی ۴۵ برای E و دوره‌ی ۲۳ برای F.

سه حالت استنتاج

انگیزه‌ی شرط سطح یک محدودیت اندازه‌گیری‌شده است. پیش‌بینی عدد هانسفیلد آئورت در تصویر کنتراست‌دار از روی میانه‌های HU اندام‌ها در تصویر بدون‌کنتراست، با یک رگرسیون خطی ریج، روی داده‌ی کنارگذاشته به $R^۲ = -۰/۱۰۵$ می‌رسد؛ بدتر از پیش‌بینی با میانگین. سطح تقویت مخصوص هر بیمار به دوز، زمان‌بندی بولوس و برون‌ده قلبی وابسته است و با این پروب از اسکن بدون‌کنتراست *پیش‌بینی‌پذیر نیست*؛ این نتیجه پیش‌بینی‌پذیری خطی را محدود می‌کند و نه هر پیش‌بین ممکن را. این یک محدودیت **ذاتی**[۲۶] است، و تنها راه در اختیار گرفتن آن، دریافت سطح به‌عنوان *ورودی* است.

[۲۶] Aleatoric

بردار سطح، برخلاف شناسه‌ی فاز، یک کمیت پیوسته است و باید در زمان استنتاج از جایی تأمین شود. سه حالت تعریف شده است و تفکیک آن‌ها برای تفسیر نتایج ضروری است:

- **population_phase** ـ بردار سطح برابر میانگین آموزشیِ *مخصوص همان فاز* گذاشته می‌شود. هیچ اطلاعاتی از تصویر بیمار خوانده نمی‌شود، پس این حالت هیچ نشت اطلاعاتی ندارد و با تمام روش‌های رقیب (که اصلاً ورودی سطح ندارند) قابل مقایسه است. **عدد شاخص همه‌ی جدول‌های مقایسه‌ای این پایان‌نامه از همین حالت می‌آید.** [یادداشت: حالت سطح استنتاج اجراهای گزارش‌شده (دوره‌های ۴۵ و ۲۳) باید روی سرور تأیید شود؛ شواهد محلی نشان می‌دهد وزن‌های دوره‌ی ۲۳ پیکربندی F با این حالت نتایجی متفاوت از ارقام جدول‌ها می‌دهند.]
- **fixed_z** ـ کاربر سطح دلخواه را بر حسب انحراف معیار مشخص می‌کند. این حالتِ *قابل استقرار* در عمل است و همان حالتی است که ادعای کنترل‌پذیری روی آن سنجیده می‌شود.
- **oracle** ـ سطح واقعی هر مورد از تصویر مرجع خوانده می‌شود. این حالت در بالین در دسترس نیست و تنها برای سنجش ارزش اطلاعات سطح به کار می‌رود. در ارزیابی پایین‌دستی این پایان‌نامه، این حالت تنها برای یک مدل تک‌فاز سطح‌شرطیِ پیشین اجرا شده است و اثر خالص آن ($+0.030$) از PLC-Net کمتر است؛ بنابراین آن عدد سقفی برای PLC-Net نیست.

یک هشدار ارزیابی

حالت ساده‌ی «جمعیتی» (یعنی یک بردار شرط تماماً صفر) برای مدل *چندفازی* بدـ‌تعریف است و این نکته به‌سادگی از چشم پنهان می‌ماند. استانداردسازِ سطح، آمار هر دو فاز را با هم میانگین می‌گیرد؛ در نتیجه $z = 0$ سطحی را درخواست می‌کند که به هیچ‌یک از دو فاز تعلق ندارد؛ مقداری میان میانه‌ی وریدی و میانه‌ی شریانی.

پیامد این خطا وارونه‌کننده است: تحت این حالت، معیار دقت فاز مدلی را که به شرط خود *وفادار* است جریمه می‌کند و مدلی را که آن را *نادیده* می‌گیرد پاداش می‌دهد. به همین دلیل همه‌ی ارقام شاخص این پایان‌نامه در حالت population_phase گزارش می‌شوند.

اما این اصلاح را نباید بیش از آن‌چه هست جلوه داد: population_phase یک حالت *استنتاج* است و تنها پیش‌فرض *ارزیابی* را اصلاح می‌کند. درهم‌تنیدگی دو سیگنال شرط در زمان *آموزش* رخ می‌دهد، چون بردارهای سطح با همان استانداردسازی تجمیعی ساخته می‌شوند. رفع ریشه‌ای آن نیازمند استانداردسازی درون‌فازی و بازآموزی است و کار آتی محسوب می‌شود.

استنتاج در سطح حجم

استنتاج به‌صورت کاشی‌کاری با هم‌پوشانی و آمیختن[۲۷] وزنی انجام می‌شود تا مرز وصله‌ها در خروجی دیده نشود. خروجی به HU بازگردانده و روی شبکه‌ی اصلی هر مورد آزمون به‌صورت NIfTI نوشته می‌شود. این قرارداد خروجی برای همه‌ی مدل‌ها (از جمله مدل‌های بازپیاده‌سازی‌شده از ادبیات) یکسان است، و همین یکسانی است که امکان امتیازدهی همه‌ی آن‌ها با یک ابزار واحد را فراهم می‌کند.

مدل‌سازی عدم‌قطعیت: انتشار و رگرسیون ناهم‌واریانس

یک رگرسیون‌گر آموزش‌دیده با زیان L_1، در بهترین حالت *میانه‌ی شرطی* را پیش‌بینی می‌کند. اگر رابطه‌ی $x \mapsto y$ قطعی نباشد (یعنی اگر y به متغیرهایی وابسته باشد که در x مشاهده‌پذیر نیستند) آن‌گاه خطای باقی‌مانده تقلیل‌ناپذیر است و هیچ تغییری در معماری یا تابع زیان آن را کاهش نمی‌دهد.

در مسئله‌ی حاضر، نامزد چنین متغیرهای مشاهده‌نشده‌ای روشن است: دوز تزریق، زمان‌بندی بولوس و برون‌ده قلبی، که هیچ‌یک در اسکن بدون‌کنتراست قابل‌مشاهده نیستند. به بیان صوری،

$$y = f(x, Z), \qquad Z = \text{(دوز، زمان‌بندی، فیزیولوژی) مشاهده‌نشده}.$$

این صورت‌بندی، خودِ شرطی‌سازی سطح را نیز توضیح می‌دهد: بردار سطح، تخمینی از تصویر Z روی فضای قابل‌مشاهده است. وقتی این بردار از میانگین جمعیتی می‌آید، مدل بهترین حدس ممکن را می‌زند؛ وقتی کاربر آن را تعیین می‌کند، بخشی از Z به‌صورت صریح در اختیار مدل قرار می‌گیرد.

دو خانواده‌ی مدل برای آزمودن این ایده به‌عنوان مبنا آموزش داده شده‌اند:

رگرسیون ناهم‌واریانس. سر خروجی مولد به دو کانال گسترش می‌یابد که میانگین μ و لگاریتم واریانس $\log \sigma^2$ را در هر وکسل پیش‌بینی می‌کنند، و آموزش با درست‌نمایی منفی گاوسی انجام می‌شود [۱۱۸]. این مدل با هزینه‌ی محاسباتی ناچیز، یک تخمین عدم‌قطعیت کالیبره‌شدنی می‌دهد و بنابراین *مبنایی* است که مدل انتشار باید از آن بهتر عمل کند تا هزینه‌اش توجیه شود.

مدل انتشار. مدل انتشار [۱۱۹] به‌جای $\mathbb{E}[y \mid x]$، خودِ توزیع $p(y \mid x)$ را مدل می‌کند و از این نظر ابزار نظری درست برای یک باقی‌مانده‌ی تصادفی است. پیاده‌سازی این پایان‌نامه از پارامترسازی v [۱۲۰]،

[۲۷] Blending

نمونه‌بردار DDIM [۱۲۱]، هدایت بدون‌طبقه‌بند [۱۲۲]، وزن‌دهی زیان بر پایه‌ی نسبت سیگنال به نویز کمینه [۱۲۳] و میانگین متحرک نمایی وزن‌ها بهره می‌گیرد.

نکته‌ی حیاتی—که پیش از اجرای آزمایش‌ها ثبت شده است—آن است که یک نمونه‌ی صادق از توزیع شرطی، بر حسب یک معیار نقطه‌ای، *بدتر* از میانگین شرطی امتیاز می‌گیرد. برای یک توزیع گاوسی با انحراف معیار s، پیش‌بین میانگین خطای مطلق s ۰/۷۹۸ و یک نمونه‌ی منفرد خطای s ۱/۱۲۸ دارد؛ یعنی نسبتی حدود $\sqrt{۲}$. این افت، نقص مدل انتشار نیست بلکه بهای صادقانه‌ی مدل‌کردن عدم‌قطعیت است، آن‌گاه که با معیاری نقطه‌ای سنجیده شود. ثبت این انتظار *پیش از* آزمایش، شرط لازم برای آن است که نتیجه قابل ابطال باشد. گونه‌ی انتشاری که در فصل ۴ گزارش می‌شود از پارامترسازی x. استفاده می‌کند و با معیارهای نقطه‌ای و پایین‌دستی سنجیده شده است؛ ارزیابی احتمالاتی آن (نمونه‌برداری چندگانه، پوشش بازه‌ها و CRPS) و آزمون این پیش‌بینی انجام نشده و به کار آتی واگذار می‌شود.

مدل‌های مبنا از ادبیات

برای آن‌که ادعاهای این پایان‌نامه در برابر وضعیت موجود سنجیده شوند، مجموعه‌ای از مدل‌های منتشرشده روی *همان* تقسیم داده، *همان* موارد آزمون و با *همان* ابزار امتیازدهی بازآموزی و ارزیابی می‌شوند:

- pix2pixHD [۱۰۱]، گسترش pix2pix [۱۲۴] — مبنای ترجمه‌ی جفت‌شده.
- CycleGAN [۱۲۵] — شاهد *جفت‌نشده*. داده‌ی ما جفت‌شده است، اما این مدل عمداً در حالت جفت‌نشده آموزش می‌بیند تا هزینه‌ی چشم‌پوشی از جفت‌شدگی اندازه‌گیری شود.
- ResViT [۱۰۲] و CyTran [۷۸] — مبناهای مبتنی‌بر ترانسفورمر.
- SwinUNETR [۱۲۶] و TransUNet [۱۰۵] — این دو *معماری*‌اند و نه پایپ‌لاین سنتز؛ هر دو در اصل برای بخش‌بندی عرضه شده‌اند. شبکه‌ی آن‌ها بدون تغییر نگه داشته و حلقه‌ی آموزش با هدف یکسان با ResViT فراهم می‌شود تا مقایسه، *معماری* را جدا کند و نه بهینه‌سازی را. این دو مدل تنها در ارزیابی تصویری گزارش می‌شوند.
- Ea-GAN [۱۲۷] — شبکه‌ی مولد_متخاصم آگاه از لبه، در دو گونه‌ی gEa-GAN و dEa-GAN؛ تنها در ارزیابی تصویری.
- DDPM [۱۱۹] با پارامترسازی x. — مدل انتشار (بخش ۳-۶).

- SynDiff [۱۲۸] —— مدل انتشار خصمانه. این مدل به‌دلیل هزینه‌ی محاسباتی از اجرای نهایی کنار گذاشته شد.

ارزیابی پایین‌دستی بخش‌بندی برای pix2pixHD، CycleGAN، ResViT، CyTran و DDPM اجرا شده است. بازآموزی این مدل‌ها روی داده و مقیاس این پایان‌نامه، اعداد مقاله‌های اصلی آن‌ها را بازتولید *نمی‌کند*؛ آن‌چه گزارش می‌شود یک مقایسه‌ی کنترل‌شده بر داده‌ی یکسان است، نه یک بازتولید.

۳-۷ پروتکل ارزیابی

چرا معیارهای متعارف کافی نیستند

معیارهای رایج در ادبیات سنتز تصویر پزشکی—PSNR، SSIM و خطای مطلق میانگین—در این مسئله گمراه‌کننده‌اند، و این نکته یکی از یافته‌های روش‌شناختی این پایان‌نامه است.

دلیل نخست ساختاری است: پنجره‌ی HU انتخاب‌شده، هوا، ریه و چربی را به صفر و استخوان را به یک اشباع می‌کند، و این نواحی بخش بزرگی از حجم را تشکیل می‌دهند. هر معیاری که روی کل تصویر میانگین بگیرد، عمدتاً روی جرمی میانگین می‌گیرد که همه‌ی مدل‌ها در آن بی‌خطا هستند؛ حتی یک کپی همانی از تصویر بدون‌کنتراست بخش عمده‌ی امتیاز بهترین مدل را کسب می‌کند.

دلیل دوم عمیق‌تر است: این معیارها با میانگین شرطی کمینه می‌شوند. پس یک خروجی *تار* را بالاتر از یک نمونه‌ی دارای بافت صحیح امتیاز می‌دهند. مرتب‌سازی مدل‌ها بر اساس این معیارها، آن‌ها را بر اساس میزان بافتی که تلاش می‌کنند تولید کنند مرتب می‌کند—در جهت اشتباه.

در نتیجه این معیارها گزارش می‌شوند اما *ثانویه* تلقی می‌شوند، و ادعاها بر معیارهای زیر بنا می‌شود.

معیار اصلی: وفاداری HU در سطح اندام

معیار سرصفحه‌ی این پایان‌نامه، میانگین قدرمطلق خطای میانه‌ی HU در سطح اندام است که روی مجموعه‌ای از اندام‌های شکمی محاسبه می‌شود. نکته‌ی مهم آن است که این معیار با همان استخراج ویژگی سطح‌اندامِ مدل تشخیص فاز (بخش ۳-۴) محاسبه می‌شود. به این ترتیب مؤلفه‌ی نخست روش، ابزار سنجش مؤلفه‌ی سوم می‌شود، و معیار به کمیتی متصل می‌ماند که معنای بالینی دارد: میزان روشنایی هر اندام، همان چیزی که فاز کنتراست را تعریف می‌کند.

در کنار آن، خطای مطلق و PSNR و SSIM *محدودشده به ناحیه‌ی اندام* گزارش می‌شود که مشکل نخستِ بالا را برطرف می‌کند.

معیار بازیابی سطح: تشخیص مولد از میانگین‌گیر

دو کمیت برای تشخیص یک مولد واقعی از یک میانگین‌گیر تعریف می‌شود. میانه‌ی HU هر اندام در تصویر تولیدشده، بر همان کمیت در تصویر واقعی، در سراسر موارد آزمون رگرس می‌شود:

- β، شیب این رگرسیون. مقدار $\beta = ۱$ یعنی مدل سطح واقعی هر مورد را دنبال می‌کند؛ مقدار $\beta = ۰$ یعنی مدل صرف‌نظر از ورودی، میانگین جمعیت را تولید می‌کند.
- نسبت واریانس $\mathrm{var}(\text{تولیدشده})/\mathrm{var}(\text{واقعی})$، با هدف ۱. مقدار نزدیک صفر یعنی خروجی کم‌پراکنده[۲۸] است.

این دو کمیت دقیقاً همان چیزی را می‌سنجند که معیارهای نقطه‌ای پنهان می‌کنند: یک مدل می‌تواند خطای HU قابل‌قبولی داشته باشد و در عین حال نسبت واریانسش نزدیک صفر باشد، یعنی هرگز سطح کنتراست هیچ بیماری را واقعاً پیش‌بینی نکرده باشد. برای مدلی که در استنتاج، سطح مخصوص بیمار را دریافت نمی‌کند، مقدار نزدیک صفر مورد انتظار است و نقص به شمار نمی‌آید؛ در آن حالت این کمیت تنها نشان می‌دهد مدل تا چه اندازه سطح را از خودِ آناتومی برداشت می‌کند.

معیارهای بافت و پیوستگی

چهار کمیت نسبتی برای سنجش بافت و پیوستگی به کار می‌رود: نسبت انرژی طیفی بسامد بالا، فاصله‌ی واسرشتاین میان توزیع بزرگی گرادیان تولیدشده و واقعی، انرژی درز در مرز کاشی‌ها، و سوسوزنی[۲۹] میان‌برشی.

نکته‌ی تفسیری مهم آن است که این‌ها نسبت‌اند و هدفشان مقدار ۱ است، نه بیشینه. مقدار کمتر از یک به معنای تاری و مقدار بیشتر از یک به معنای نویز یا بافت توهمی[۳۰] است؛ هر دو شکست‌اند و باید بر حسب فاصله از یک رتبه‌بندی شوند.

---

[۲۸] Under-dispersed
[۲۹] Flicker
[۳۰] Hallucinated

معیارهای ادراکی LPIPS [۱۲۹] و FID [۱۳۰] نیز صرفاً برای *قابلیت مقایسه با ادبیات* گزارش می‌شوند و مبنای هیچ ادعایی نیستند: هر دو شبکه‌های از پیش آموزش‌دیده روی تصاویر طبیعی را بر تصویر سی‌تی خاکستری اجرا می‌کنند و اعتبار ترتیبشان در این دامنه تأیید نشده است.

معیارهای کالیبراسیون

برای مدل‌های احتمالاتی بخش ۳-۶، دو کمیت افزوده می‌شود: امتیاز احتمال رتبه‌ای پیوسته[۳۱] [۱۳۱] و پوشش بازه‌ی پیش‌بینی ۹۰ درصد، که مقدار هدفش ۰٫۹۰ است. انحراف از این مقدار، مستقیماً بدکالیبراسیون را اندازه می‌گیرد. این دو کمیت در ارزیابی نهایی این پایان‌نامه محاسبه نشده‌اند.

ارزیابی پایین‌دستی: شکاف بخش‌بندی

هیچ‌یک از معیارهای بالا، پرسش اصلی این پایان‌نامه را پاسخ نمی‌دهد. آن پرسش یک ارزیابی جداگانه می‌طلبد که به‌صورت زیر تعریف می‌شود.

مرجع، خروجی بخش‌بندی خودکار روی تصویر کنتراست‌دار *واقعی* است. دو نوع بازو در برابر این مرجع سنجیده می‌شوند:

- بخش‌بندی روی تصویر بدون‌کنتراست واقعی — این خودِ *شکاف* است.
- بخش‌بندی روی تصویر کنتراست‌دار *تولیدشده* توسط هر مدل.

معیار، دایس ساده است. برخلاف فصل هم‌ترازسازی (بخش ۳-۵)، دایس فرسوده‌ی ۶ میلی‌متری به کار نمی‌رود، زیرا این فرسایش عروقی را که قطرشان کمتر از حدود ۱۲ میلی‌متر است تقریباً به‌طور کامل حذف می‌کند؛ نتایج دایس فرسوده به‌عنوان تحلیل حساسیت در پیوست آ-۱ گزارش می‌شود. علاوه بر گروه‌ها، ترکیبی از اندام‌های وابسته به کنتراست (پانکراس، کیسه‌ی صفرا، آئورت، ورید اجوف تحتانی، و ورید باب و طحالی) به‌عنوان نقطه‌ی پایانی تأییدیِ از پیش تعیین‌شده تعریف می‌شود. اندام‌ها به همان چهار گروه دسته‌بندی می‌شوند و گروه *اسکلتی* بار دیگر نقش شاهد منفی را دارد: استخوان با کنتراست تغییر نمی‌کند، پس اگر بازوی بدون‌کنتراست روی استخوان نیز افت دایس نشان دهد، آن‌چه اندازه گرفته شده تفاوت کیفیت کلی تصویر است و نه اثر کنتراست، و بقیه‌ی جدول را نمی‌توان به کنتراست نسبت داد.

[۳۱] Continuous ranked probability score, CRPS

محدودیت این طرح باید صریح بماند: مرجع، حاشیه‌نویسی انسانی نیست بلکه خروجی خودکار روی تصویر واقعی است. بنابراین یک تصویر تولیدشده می‌تواند با شبیه‌شدن به یک تصویر کنتراست‌دار *از دید همان ابزار بخش‌بندی* امتیاز بگیرد. این محدودیت هرجا که این اعداد ظاهر شوند تکرار خواهد شد؛ شاهد منفی اسکلتی و کف بازوی بدون‌کنتراست، آن چیزی است که سیگنال باقی‌مانده را قابل‌تفسیر نگه می‌دارد.

انضباط آماری

سه قاعده در سراسر فصل ۴ اعمال می‌شود و ذکرشان در این‌جا ضروری است، چون بدون آن‌ها بخشی از نتایج گزارش‌شده متفاوت می‌بود.

- **کف نویز بذر.** کف نویز بذر برای پیکربندی‌های پایه‌ی تک‌فاز با سه بذر تصادفی اندازه‌گیری شد؛ مدل‌های نهایی (PLC-Net و مدل‌های مبنا) به‌دلیل هزینه‌ی محاسباتی تنها با یک بذر آموزش دیده‌اند. تفاوتی که از دروازه‌ی 2σ کوچک‌تر باشد نتیجه به شمار نمی‌آید. این قاعده در جریان همین پژوهش یک ادعای سرصفحه را باطل کرد—ادعایی که در یک بذر معنادار به نظر می‌رسید و در سه بذر نه‌تنها ناپدید شد بلکه علامتش برگشت.
- **آزمون‌های زوجی در سطح مورد.** پراکندگی میان بیماران بر تفاوت میان مدل‌ها غلبه دارد. از این رو مقایسه‌ها از طریق آزمون زوجی روی موارد مشترک انجام می‌شود و نه از طریق مقایسه‌ی میانگین‌ها و انحراف معیارها.
- **تفاضل پیکربندی.** هر اجرا با اجرای پیشین خود تنها در کلیدهایی تفاوت دارد که عمداً تغییر داده شده‌اند. این ساده‌ترین محافظ در برابر مخدوش‌کننده‌هاست؛ گام پیکربندی E در زنجیره‌ی طراحی، که چند تغییر را هم‌زمان اعمال می‌کند، از این قاعده مستثناست و در تفسیر آن لحاظ می‌شود.

۳-۸ جمع‌بندی

این فصل سه مؤلفه‌ی روش پیشنهادی را ارائه کرد. مدل تشخیص فاز، که از میان روش‌های منتشرشده و بر پایه‌ی ارزیابی روی داده‌ی همین پایان‌نامه برگزیده شد، مسئله را از حجم خام به بردار کوچکی از میانه‌های HU در سطح اندام تقلیل می‌دهد و در ادامه، علاوه بر نقش دروازه‌بانی داده، ابزار اندازه‌گیری ارزیابی سنتز نیز می‌شود. در کنار آن، سازگاری مدل‌های بنیادین تصویری با این وظیفه آزموده شد تا روشن شود بازنمایی‌های عمومی یک رمزگذار منجمد، بدون بخش‌بندی اندام، تا چه اندازه اطلاعات فاز را در خود

دارند. پایپ‌لاین هم‌ترازسازی تصویر، به‌جای وزن‌دهی به نواحی پایدار، *دامنه‌ی* محاسبه‌ی معیار تراز را به آن‌ها محدود می‌کند و با یک مقداردهی اولیه‌ی بسته بر پایه‌ی مرکز جرم اندام‌های نقاب هم‌ترازسازی، از کمینه‌های محلی پرهیز می‌کند. دو گذر صلب آن اثرهای مکمل بر گروه‌های اندامی متفاوت دارند، و گام پیش‌پردازش آناتومی‌محورِ مقدم بر آن‌ها مستقل از خود زنجیره ارزش دارد و شکست‌ها و خطاهای بزرگ روش‌های موجود را نیز کاهش می‌دهد. یک گذر اختیاری پالایش غیرصلب نیز تعریف شد که جزو مسیر پیش‌فرض نیست و نقش اصلی‌اش سنجش ناهم‌ترازی باقی‌مانده در جفت‌های صلب است. مدل‌های سنتز، از مولد قطعی تا مدل انتشار و رگرسیون ناهم‌واریانس، همگی روی جفت‌های حاصل از این هم‌ترازسازی تصویر و روی یک تقسیم منجمد آموزش می‌بینند.

پروتکل ارزیابی، خود بخشی از سهم این پایان‌نامه است: نشان داده شد که چرا معیارهای متعارف سطح‌پیکسل در این مسئله قادر به رتبه‌بندی مدل‌ها نیستند، و مجموعه‌ای از معیارهای سطح‌اندام، بازیابی سطح، بافت و کالیبراسیون به‌جای آن‌ها تعریف شد. سرانجام، ارزیابی پایین‌دستی بخش‌بندی تعریف شد که تنها سنجه‌ای است که به پرسش عنوان این پایان‌نامه پاسخ می‌دهد.

فصل بعد نتایج تجربی هر یک از این مؤلفه‌ها را گزارش می‌کند.

فصل ۴

آزمایش‌ها

۴-۱ یافته‌های مرور نظام‌مند مجموعه‌داده‌ها

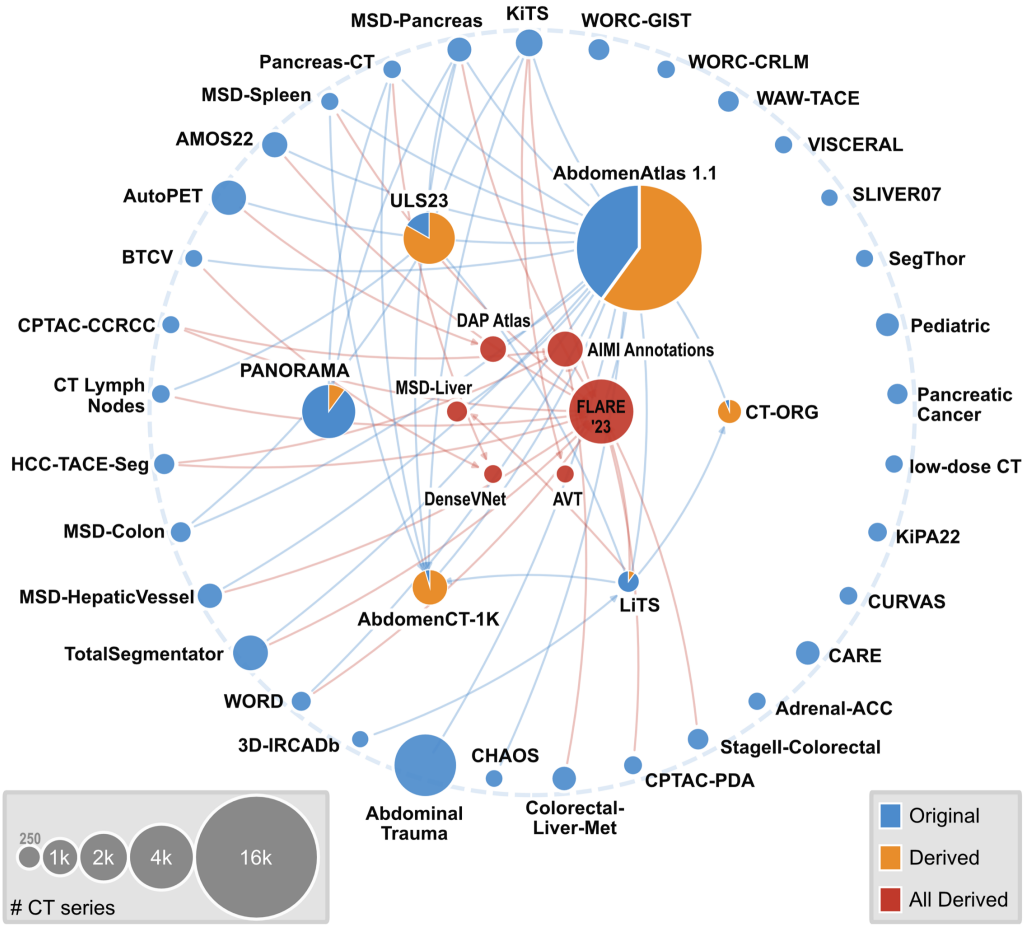
این بخش، یافته‌های حاصل از اجرای پروتکل بخش ۳-۲ را گزارش می‌کند. یافته‌ها در چهار محور ارائه می‌شوند: ترکیب و افزونگی مجموعه‌داده‌ها، توزیع جغرافیایی، پوشش اندام و شیوه‌ی برچسب‌گذاری، و ارزیابی ریسک سوگیری. پس از آن وضعیت فاز کنتراست در داده‌ی برچسب‌خورده، که مستقیماً به مسئله‌ی این پایان‌نامه مربوط است، گزارش می‌شود و بخش پایانی پیامد این یافته‌ها را برای سه مؤلفه‌ی روش استخراج می‌کند.

ترکیب و افزونگی

از میان ۴۵ مجموعه‌داده‌ی واردشده، مجموعاً ۴۷,۰۴۹ بررسی سی‌تی فهرست شده است. اما تنها ۲۳,۷۴۶ مورد از این‌ها *اصیل* بودند؛ یعنی ۲۳,۳۰۳ مورد (۴۹/۵ درصد) از حجم ظاهری این اکوسیستم، بازاستفاده‌ی موارد پیشین است و شش مجموعه‌داده اصلاً هیچ مورد اصیلی ندارند. این بازاستفاده در سال‌های اخیر شدیدتر شده است: انتشار مجموعه‌داده‌ها از سال ۲۰۲۲ جهش کرد و در سال ۲۰۲۳ با ۱۱ مجموعه‌داده به اوج رسید، اما در همان سال کمتر از نیمی از بررسی‌های منتشرشده اصیل بودند. رشد ظاهری داده در این دوره، بیش از آن‌که گردآوری تازه باشد، ترکیب دوباره‌ی داده‌ی موجود است.

ردیابی منشأ نشان داد این بازاستفاده تصادفی نیست بلکه ساختاری شبکه‌ای دارد (شکل ۴-۱): شمار اندکی از مجموعه‌داده‌های پایه، به‌ویژه LiTS [۱۸]، KiTS [۱۹]، Pancreas-CT و BTCV، نقش گره‌های مرکزی را ایفا می‌کنند و موارد آن‌ها به مجموعه‌های ترکیبی متأخرتری مانند AbdomenCT-

1K [۱۲]، FLARE [۱۳] و AbdomenAtlas 1.1 [۱۴] سرریز می‌شود. بزرگ‌ترین این مجموعه‌ها، AbdomenAtlas 1.1 با ۹,۲۶۲ بررسی عمومی، حدود ۶۰ درصد موارد خود را از مجموعه‌های دیگر گرفته است.



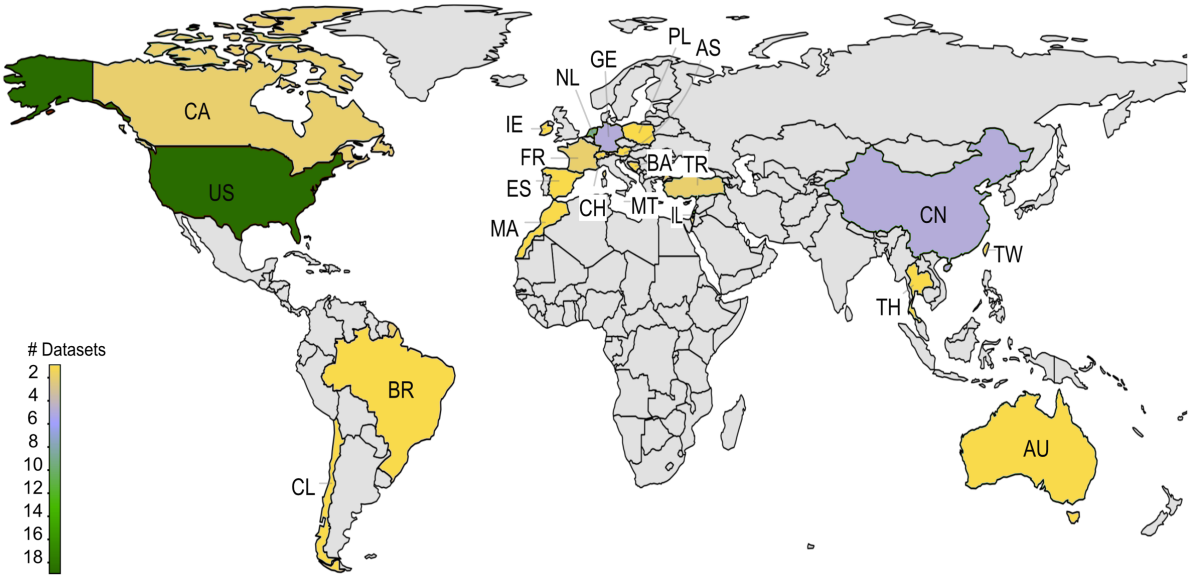
شکل ۴-۱: شبکه‌ی بازاستفاده‌ی موارد میان مجموعه‌داده‌های عمومی سی‌تی شکمی. هر گره یک مجموعه‌داده است و اندازه‌ی آن با شمار سری‌های سی‌تی متناسب است؛ آبی یعنی تماماً اصیل، نارنجی یعنی ترکیبی از موارد اصیل و بازاستفاده، و قرمز یعنی تماماً بازاستفاده. هر پیکان از مجموعه‌داده‌ی منبع به مجموعه‌ی مشتقی می‌رود که موارد آن را به کار گرفته است. برگرفته از [۴].

پیامد روش‌شناختی این ساختار برای هر پژوهشی که از این منابع استفاده می‌کند، خطر نشت داده است: پژوهشگری که مدلی را روی یک مجموعه‌ی ترکیبی آموزش می‌دهد و روی یکی از مجموعه‌داده‌های پایه ارزیابی می‌کند، ممکن است بدون آگاهی، همان بیماران را در هر دو سو داشته باشد. همین ملاحظه است که تصمیم فصل ۳ را برای تقسیم داده در سطح *بیمار* و تثبیت آن در یک فایل منجمد توجیه می‌کند.

توزیع جغرافیایی

با وجود مشارکت دست‌کم ۲۴ کشور، توزیع جغرافیایی به‌شدت نامتوازن است (شکل ۴-۲): ۷۵/۳ درصد مجموعه‌داده‌ها از ایالات متحده، کانادا و کشورهای اروپایی می‌آیند. ایالات متحده به‌تنهایی ۲۱ درصد و پس از آن چین و فرانسه هر یک ۹ درصد سهم دارند.

مهم‌تر از این تمرکز، آن چیزی است که کاملاً *غایب* است: آفریقای زیرصحرا، جنوب آسیا و بخش عمده‌ی خاورمیانه هیچ نمایندگی‌ای در چشم‌انداز داده‌ی عمومی موجود ندارند. این غیاب، پیامد بالینی مشخصی دارد. کارسینوم سلول کبدی [۱۳۲]، که تشخیصش به‌شدت به الگوی افزایش کنتراست در فاز شریانی و شست‌وشوی آن در فاز وریدی وابسته است، در آفریقای زیرصحرا اغلب در کبد غیرسیروتیک و در سنین پایین‌تر با الگوی تصویری متفاوتی بروز می‌کند [۱۳۳]. مدلی که تنها الگوی غربی این بیماری را دیده باشد، هیچ تضمینی برای عملکرد در آن بافت بالینی ندارد.



شکل ۴-۲: توزیع جغرافیایی کشورهای مشارکت‌کننده در مجموعه‌داده‌های عمومی سی‌تی شکمی. رنگ هر کشور شمار مجموعه‌داده‌هایی را نشان می‌دهد که در آن‌ها سهم دارد و کشورهای خاکستری هیچ سهمی ندارند. مرزهای نقشه از پایگاه GSHHG گرفته شده است. برگرفته از [۴].

پوشش اندام و شیوه‌ی برچسب‌گذاری

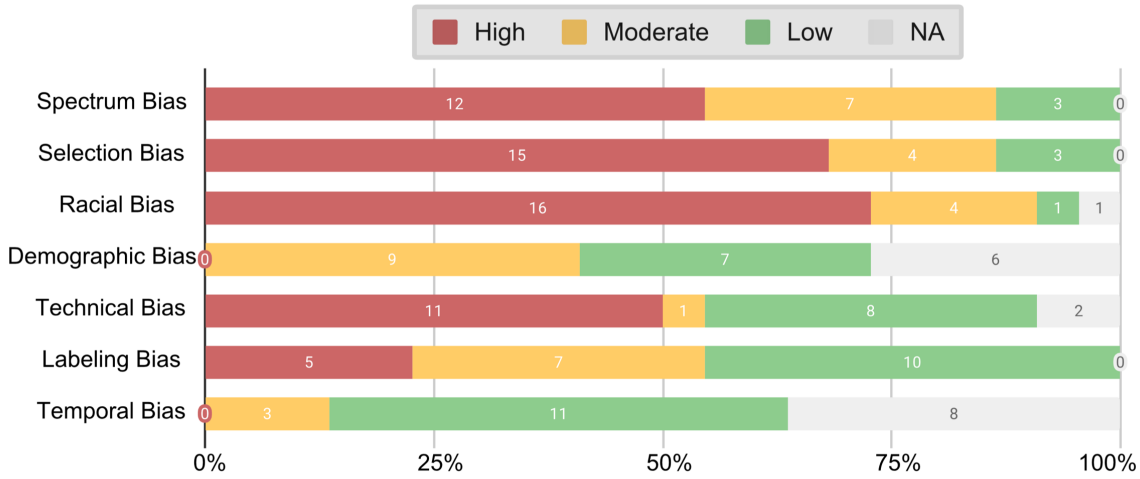
پوشش اندام‌ها نیز یکنواخت نیست. کبد در ۲۳ مجموعه‌داده، کلیه و پانکراس هر یک در ۱۹ و طحال در ۱۴ مجموعه‌داده نقاب دارند؛ در مقابل، عروق کبدی تنها در ۵ و تنه‌ی سلیاک و عروق مزانتریک هر یک تنها در ۲ مجموعه‌داده برچسب خورده‌اند. نقاب ضایعه از این هم محدودتر است و در سطح اندام تقریباً تنها

برای کبد، کلیه، پانکراس، روده‌ی بزرگ و غده‌ی فوق‌کلیوی وجود دارد. آسیب‌شناسی‌های پوشش‌داده‌شده نیز عمدتاً توموری‌اند و بیماری‌های شایع غیرتوموری، مانند بیماری‌های التهابی و عروقی، تقریباً غایب‌اند. برای این پایان‌نامه نکته‌ی مهم آن است که برخی از ساختارهای عروقی، که دیده‌شدنشان بیش از هر ساختار دیگری به ماده‌ی حاجب وابسته است، در زمره‌ی کم‌برچسب‌ترین ساختارهای این اکوسیستم‌اند.

در شیوه‌ی برچسب‌گذاری، از ۴۵ مجموعه‌داده ۲۷ مورد (۶۰ درصد) تماماً به‌دست متخصص برچسب خورده‌اند و ۱۷ مورد (۳۷/۸ درصد) از زنجیره‌ای نیمه‌خودکار استفاده کرده‌اند که خروجی یک مدل را متخصص اصلاح می‌کند؛ یک مجموعه‌داده نیز روش برچسب‌گذاری را گزارش نمی‌کند. سهم زنجیره‌ی نیمه‌خودکار در شمار مجموعه‌داده‌ها کمتر از نصف است، اما در حجم داده غالب است، چون بزرگ‌ترین مجموعه‌ها، از جمله AbdomenAtlas 1.1، FLARE، TotalSegmentator و AMOS22، همگی در این گروه‌اند. نقاب‌های اندام این پایان‌نامه نیز با TotalSegmentator تولید می‌شوند (بخش ۳-۳)؛ پس کیفیت نقاب‌های مرجع این پایان‌نامه نیز به همان نوع زنجیره‌ی نیمه‌خودکار وابسته است.

ارزیابی ریسک سوگیری

ارزیابی روی ۲۲ مجموعه‌داده‌ی دارای صد نمونه‌ی عمومی یا بیشتر انجام شد و شکل ۴-۳ توزیع کامل سطح ریسک را در هر هفت مقوله نشان می‌دهد. سوگیری نژادی (۱۶ از ۲۲) و سوگیری انتخاب (۱۵ از ۲۲) پرتکرارترین مقوله‌های پرریسک‌اند: اغلب مجموعه‌داده‌ها تک‌مرکزی‌اند یا ترکیب نژادی را اصلاً گزارش نمی‌کنند، و گروه شاهد آن‌ها اغلب تنها موارد سالم است و تشخیص‌های افتراقی را پوشش نمی‌دهد. سوگیری طیف (۱۲ مورد، به دلیل تمرکز بر یک آسیب‌شناسی و شدت خاص) و سوگیری فنی (۱۱ مورد، به دلیل اسکنر واحد یا پروتکل یکنواخت) در رده‌ی بعد قرار دارند. در سوی دیگر، سوگیری برچسب‌گذاری تنها در ۵ مورد پرریسک و در ۱۰ مورد کم‌ریسک است.



شکل ۴-۳: توزیع سطح ریسک در هفت مقوله‌ی سوگیری برای ۲۲ مجموعه‌داده‌ی دارای صد نمونه‌ی عمومی یا بیشتر. قرمز ریسک بالا، زرد ریسک متوسط، سبز ریسک پایین و خاکستری «در دسترس نیست» است و عدد روی هر نوار، شمار مجموعه‌داده‌هاست. برگرفته از [۴].

این نمایش، نکته‌ای را آشکار می‌کند که شمارش موارد پرریسک به‌تنهایی پنهان می‌کند: سوگیری جمعیت‌شناختی و زمانی هیچ مورد پرریسکی ندارند، اما این به معنای کم‌ریسک‌بودن آن‌ها نیست. سهم «در دسترس نیست» در همین دو مقوله از همه بیشتر است (۶ و ۸ مجموعه‌داده)؛ یعنی بخش قابل‌توجهی از مستندات، توزیع سن و جنس یا بازه‌ی زمانی گردآوری را اصلاً گزارش نمی‌کند. همین کمبود مستندات، پایین‌بودن توافق ارزیاب‌ها در سوگیری زمانی را نیز توضیح می‌دهد (بخش ۳-۲).

الگوی کلی گویاست. دو مقوله‌ی نژادی و انتخاب بیش از دو سوم مجموعه‌داده‌ها را در سطح ریسک بالا قرار می‌دهند، در حالی که سوگیری برچسب‌گذاری تنها در پنج مورد پرریسک است. به بیان دیگر، ضعف اصلی این اکوسیستم در کیفیت *حاشیه‌نویسی* نیست (که موضوع تمرکز بیشتر پژوهش‌های کیفیت داده است) بلکه در ترکیب آن است: چه کسانی و چه بیماری‌هایی در داده حاضرند.

جدول ۴-۱ طبقه‌بندی کلی حاصل از رابطه‌ی ۳-۱ را به‌تفکیک مجموعه‌داده نشان می‌دهد.

بیش از نیمی از منابع بزرگ این حوزه (۱۲ از ۲۲) در بالاترین رده‌ی ریسک‌اند. ۱۴ مجموعه‌داده (۶۴ درصد) سه مقوله‌ی پرریسک یا بیشتر داشتند و تنها ۷ مورد (۳۲ درصد) سه مقوله‌ی کم‌ریسک یا بیشتر. دو مورد از سه مجموعه‌داده‌ی کم‌ریسک، یعنی AbdomenAtlas 1.1 [۱۴] با ۱۱۲ مرکز و RSNA Abdominal Trauma [۱۳۴] با ۲۳ مرکز، چندمرکزی و بزرگ‌مقیاس‌اند؛ الگویی که با نقش تنوع مراکز در کاهش ریسک سازگار است. در مقابل، WORD [۲۱]، که چنان‌که در ادامه می‌آید تنها مجموعه‌داده‌ی اختصاصی بدون‌کنتراست است، تک‌مرکزی است و در رده‌ی بحرانی قرار دارد.

جدول ۴-۱: طبقه‌بندی کلی سوگیری ۲۲ مجموعه‌داده‌ی ارزیابی‌شده، بر پایه‌ی رابطه‌ی ۳-۱.

رده‌ی سوگیری	شمار	مجموعه‌داده‌ها
بحرانی	۱۲	AutoPET, CARE, Colorectal-Liver-Metastases, HCC-TACE-Seg, KiPA22, KiTS, MSD-Colon, MSD-HepaticVessel, MSD-Pancreas, Pancreatic Cancer Survival Prediction, StageII-Colorectal-CT, WORD
بالا	۲	WAW-TACE, WORC-GIST
متوسط	۵	AMOS22, LiTS, PANORAMA, TotalSegmentator, ULS23
پایین	۳	AbdomenAtlas 1.1, RSNA Abdominal Trauma, Pediatric-CT-SEG

وضعیت فاز کنتراست

موضوع مرور منتشرشده، وضعیت کلی مجموعه‌داده‌ها و سوگیری آن‌هاست و فاز کنتراست محور تحلیل آن نیست. با این حال، وضعیت تزریق ماده‌ی حاجب جزو مشخصات تصویربرداری است که در جدول استخراج همان مرور برای هر مجموعه‌داده ثبت شده است، و از همین داده می‌توان وضعیت حضور فازهای کنتراست را در داده‌ی عمومی این حوزه نتیجه گرفت. ارقام زیر مستقیماً از این جدول محاسبه شده‌اند.

یک قید تعیین‌کننده پیش از ارقام: معیار ورود به آن مرور وجود نقاب بخش‌بندی در سطح اندام بوده است، و بنابراین ستون فاز، فازهایی را ثبت می‌کند که *نقاب‌های* هر مجموعه‌داده از آن‌ها می‌آیند و نه لزوماً همه‌ی فازهایی که در آن اسکن شده‌اند. پرسش این بخش نیز دقیقاً همین است: چه اندازه داده‌ی برچسب‌خورده‌ی بدون‌کنتراست برای آموزش مدل‌های بخش‌بندی در دسترس است.

از ۴۵ مجموعه‌داده، ۳۲ مورد (۷۱/۱ درصد) نقاب‌های خود را تنها از فازهای کنتراست‌دار می‌گیرند؛ ۱۲ مورد (۲۶/۷ درصد) فاز بدون‌کنتراست را در میان فازهای حاشیه‌نویسی‌شده دارند؛ و از این ۱۲ مورد تنها یکی (WORD) به‌طور اختصاصی بدون‌کنتراست است؛ این مجموعه ۱۷۰ بررسی دارد که ۱۵۰ مورد آن اصیل است. یک مجموعه‌داده هیچ اطلاعات فازی گزارش نمی‌کند.

در سطح شمار بررسی هیچ عدد دقیقی قابل استخراج نیست، چون توصیف‌نامه‌ها تنها حضور هر فاز را اعلام می‌کنند و نه شمار بررسی‌های آن. از این رو جدول ۴-۲ به‌جای یک عدد، یک بازه گزارش می‌کند: کران پایین قطعی، یعنی تنها بررسی‌هایی که به‌طور تضمین‌شده بدون‌کنتراست‌اند؛ کران بالا، یعنی همه‌ی بررسی‌های مجموعه‌داده‌هایی که فاز بدون‌کنتراست را پوشش می‌دهند، که آشکارا بیش‌برآورد است؛ و یک برآورد میانی با فرض پخش یکنواخت بررسی‌های هر مجموعه‌داده میان فازهای پوشش‌داده‌شده‌ی همان

مجموعه.

جدول ۴-۲: برآورد سهم بررسی‌های بدون‌کنتراست در داده‌ی برچسب‌خورده‌ی عمومی سی‌تی شکمی، محاسبه‌شده از جدول استخراج مرور [۴].

برآورد	بررسی بدون‌کنتراست	از مجموع	سهم (درصد)
کران پایین قطعی (تنها WORD)	۱۵۰	۴۷,۰۴۹	۰/۳
برآورد میانی، پخش یکنواخت	۹,۸۵۰	۴۳,۷۳۶	۲۲/۵
برآورد میانی، تنها بخش عمومی	۶,۴۹۳	۲۹,۸۷۰	۲۱/۷
کران بالا	۳۳,۱۸۳	۴۷,۰۴۹	۷۰/۵

برآورد میانی معادل نسبت کنتراست‌دار به بدون‌کنتراست حدود ۳/۴ به ۱ است، و محدودکردن شمارش به بخش عمومی این نسبت را تقریباً تغییر نمی‌دهد.

فرض پخش یکنواخت ساده‌سازی آشکاری است و به احتمال زیاد به سود فاز بدون‌کنتراست سوگیری دارد، چون فاز وریدی باب در تقریباً همه‌ی این مجموعه‌ها غالب است؛ پس سهم واقعی به احتمال زیاد از ۲۲ درصد کمتر است. تحلیل کامل این ارقام و قیدهای آن در بخش ۲-۳ فصل ۲ آمده است.

پیامد برای این پایان‌نامه

سه یافته‌ی بالا، سه قید عملی بر کار این پایان‌نامه می‌گذارند.

نخست، بازاستفاده‌ی ۴۹/۵ درصدی، ارزیابی روی مجموعه‌های ترکیبی را بی‌اعتبار می‌کند مگر آن‌که منشأ هر مورد ردیابی شود. به همین دلیل، آزمایش‌های این پایان‌نامه روی یک مجموعه‌داده‌ی *اصیل* و منفرد انجام می‌شوند، نه روی یک محک ترکیبی.

دوم، کمیابی داده‌ی برچسب‌خورده‌ی فاز بدون‌کنتراست، مسیر «کافی است مدل را روی همان فاز آموزش دهیم» را در عمل می‌بندد و هم‌ترازسازی تصویر و سنتز را از دو گزینه‌ی رقیب به دو ضرورت مکمل تبدیل می‌کند: جفت‌های آموزشی باید *ساخته* شوند، و ساختنشان به هم‌ترازسازی هندسی نیاز دارد.

سوم، سوگیری جغرافیایی و جمعیت‌شناختی مستندشده، دامنه‌ی اعتبار هر نتیجه‌ای را که در ادامه‌ی این فصل به دست می‌آید محدود می‌کند. این محدودیت در تفسیر نتایج باید صریح بماند و در فصل ۵ به آن بازمی‌گردیم.

۲-۴ نتایج هم‌ترازسازی تصویر بین‌فازی

این بخش نتایج پایپ‌لاین بخش ۳-۵ را گزارش می‌کند. پیش از جدول‌ها، قراردادهای گزارش در چند بند روشن می‌شوند تا هر جدول بدون بازگشت به متن قابل‌خواندن باشد.

- **مجموعه‌ی مشترک.** همه‌ی مقایسه‌ها روی ۲۶ بررسی از تقسیم آزمون انجام شده‌اند که همه‌ی روش‌ها برای آن‌ها خروجی دارند، شامل ۵۵ جفت فاز. هر اندام در هر جفت فاز یک *مورد مقایسه* است؛ با یازده اندام، این مجموعه ۵۷۴ مورد مقایسه دارد. در مقایسه‌های دوبه‌دو، شمار موارد بسته به اندام‌های قابل‌ارزیابی در هر دو روش اندکی متفاوت است.

- **شاخص‌های دقت.** *هم‌پوشانی دایس* میان نقاب اندام‌ها پس از فرسایش مرزها (یک یعنی انطباق کامل و صفر یعنی بدون هم‌پوشانی)؛ *خطای مرکز اندام* بر حسب میلی‌متر؛ و *فاصله‌ی مرزها*، یعنی فاصله‌ای که ۹۵ درصد نقاط مرز دو نقاب از آن به یکدیگر نزدیک‌ترند. برای روش‌های غیرصلب، *تاخوردگی* نیز گزارش می‌شود: درصد وکسل‌هایی که تغییرشکل در آن‌ها بافت را روی خودش تا می‌کند و از نظر فیزیکی ناممکن است. هم‌ترازی‌ای که دایس آن کمتر از ۰٫۵ باشد شکست شمرده می‌شود.

- **خلاصه‌ی هر شاخص.** برای هر روش *مقدار معمول*[۱] گزارش می‌شود: مقداری که نیمی از موارد بالاتر و نیمی پایین‌تر از آن‌اند. میانگین به کار نمی‌رود، چون چند شکست بزرگ آن را به‌شدت جابه‌جا می‌کند و تصویر نادرستی از رفتار معمول روش می‌دهد. هر جا پراکندگی لازم است، بازه‌ای که نیمی از موارد در آن قرار دارند[۲] نیز آمده است.

- **معناداری.** برای مقایسه‌ی دو روش، در هر مورد مقایسه بررسی می‌شود کدام روش دایس بالاتری دارد و شمار موارد «بهتر» و «بدتر» گزارش می‌شود. آزمون علامت[۳] تعیین می‌کند آیا این دو شمار به‌طور معنادار متفاوت‌اند؛ مقدار p کمتر از ۰٫۰۵ به معنای تفاوت معنادار است. این مقایسه‌ی مورد به مورد ضروری است، چون تفاوت دو روش روی یک بیمار اغلب از تفاوت میان بیماران کوچک‌تر است. وقتی یک مقایسه برای چند گروه یا اندام تکرار می‌شود، آستانه‌ی معناداری به همان نسبت سخت‌تر می‌شود (تصحیح بونفرونی): ۰٫۰۱۷ برای سه گروه اندام و ۰٫۰۰۴۵ برای یازده اندام.

- **گروه‌های اندام.** اندام‌های نرم (کبد، طحال، دو کلیه، پانکراس و کیسه‌ی صفرا)، رگ‌های بزرگ (آئورت و بزرگ‌سیاهرگ زیرین) و مهره‌ها (سه مهره‌ی نخست کمری). مهره‌ها با کنتراست تغییر

[۱] Median
[۲] Interquartile range
[۳] Sign test

نمی‌کنند و نقش گروه کنترل را دارند.

داده‌ی واجد شرط

از ۲۶۵ بررسی مجموعه‌داده، تنها ۱۶۹ بررسی (۶۳٫۸ درصد) سری بدون‌کنتراست دارند. چون فاز بدون‌کنتراست در سراسر این پایپ‌لاین مرجع ثابت است، ۹۶ بررسی باقی‌مانده پیش از هر هم‌ترازسازی کنار گذاشته می‌شوند. همین عدد، و نه کیفیت هم‌ترازی، سقف تعداد جفت‌های آموزشی سنتز را تعیین می‌کند.

تبدیل DICOM به NIfTI روی هر ۷۷۲ حجم بدون خطا انجام شد و بررسی خودکار سلامت بخش‌بندی ۷۷۱ حجم را پذیرفت. تنها حجم ردشده هر سه شرط این بررسی را هم‌زمان نقض می‌کرد: هیچ اندام مرجعی در آن شناسایی نشده بود، برچسب ستون فقرات نداشت و نقاب آن خالی بود؛ یعنی دقیقاً همان خرابی که این بررسی برای شناسایی‌اش طراحی شده است.

اندازه‌ی ناهم‌ترازی پیش از هم‌ترازسازی

پیش از تفسیر نتایج، اندازه‌ی مسئله باید روشن شود. جابه‌جایی مرکز اندام‌ها میان فاز بدون‌کنتراست و فازهای دیگر، در حالت معمول ۲٫۷۹ میلی‌متر است؛ تنها در ۱۰ درصد سری‌ها از ۱۰٫۵ میلی‌متر بیشتر می‌شود و بیشینه‌ی آن ۲۹٫۸ میلی‌متر است. گام هم‌ترازی درشت مرکز جرم تنها وقتی جابه‌جایی اعمال می‌کند که جابه‌جایی برآوردشده از یک آستانه‌ی کمینه بزرگ‌تر باشد؛ این شرط در راستای سر به پا در ۱۲٫۴ درصد و در صفحه‌ی مقطع در ۸٫۸ درصد سری‌ها برقرار شد.

به بیان دیگر، فازهای این مجموعه‌داده در حدود ۸۷ درصد موارد از پیش تقریباً هم‌موقعیت‌اند. مسئله‌ی اصلی در این داده جابه‌جایی‌های بزرگ و فراگیر نیست، بلکه ناهم‌ترازی‌های چندمیلی‌متری و شکست‌های پراکنده است؛ این نکته در تفسیر جدول‌های بعد، به‌ویژه اثر پیش‌پردازش بر روش‌های موجود، تعیین‌کننده است.

سهم هر گام پیش‌پردازش

جدول ۴–۳ نتیجه‌ی افزودن تدریجی گام‌ها را نشان می‌دهد. بخش بالای جدول زنجیره‌ی کامل گام‌های آزموده است و بخش پایین همان زنجیره بدون گام هم‌ترازی درشت مرکز جرم، که مسیر پیشنهادی نهایی است.

جدول ۴-۳: سهم هر گام پیش‌پردازش در دقت هم‌ترازی، روی ۵۷۷ مورد مقایسه از ۲۶ بررسی. همه‌ی ستون‌ها مقدار معمول‌اند و ستون سوم بازه‌ای است که نیمی از موارد در آن قرار دارند. برای دایس مقدار بیشتر و برای دو فاصله مقدار کمتر بهتر است. †خروجی «فقط برش مشترک» تنها برای ۲۳ بررسی (۴۹۸ مورد مقایسه) موجود است.

گام‌ها	دایس	نیمی از موارد	خطای مرکز (میلی‌متر)	فاصله‌ی مرزها (میلی‌متر)
زنجیره‌ی کامل گام‌های آزموده				
فقط برش مشترک†	۰/۷۹۷	۰/۶۲—۰/۸۹	۲/۶۲	۳/۳۵
+ هم‌ترازی درشت مرکز جرم	۰/۷۷۳	۰/۵۷—۰/۸۸	۲/۸۹	۳/۶۷
+ هم‌ترازی صلب اولیه (کابش)	۰/۷۹۲	۰/۶۲—۰/۸۹	۲/۲۷	۳/۳۵
+ پالایش صلب (نلدر–مید)	۰/۸۱۶	۰/۶۳—۰/۹۰	۲/۰۸	۳/۳۵
+ گذر روی بزرگی گرادیان	۰/۸۱۶	۰/۶۳—۰/۹۰	۲/۰۸	۳/۳۵
مسیر پیشنهادی: همان گام‌ها بدون هم‌ترازی درشت مرکز جرم				
برش مشترک + هم‌ترازی صلب اولیه	۰/۷۹۷	۰/۶۳—۰/۸۹	۲/۲۷	۳/۳۵
برش مشترک + هم‌ترازی صلب اولیه + پالایش صلب	**۰/۸۲۱**	۰/۶۵—۰/۹۰	۲/۰۸	۳/۳۵

سه یافته از این جدول بیرون می‌آید.

یکم ـ هم‌ترازی درشت مرکز جرم کمکی نمی‌کند و در جایی که فعال می‌شود آسیب می‌زند. افزودن این گام به برش مشترک، دایس را در ۴۰ مورد بدتر و تنها در ۱۶ مورد بهتر می‌کند (p برابر ۰/۰۰۱۸). بررسی موارد نشان می‌دهد این گام تنها در ۸ جفت فاز از ۴ بررسی جابه‌جایی اعمال کرده است. در سه جفت اثر آن ناچیز بود، اما در پنج جفت دیگر خطای مرکز اندام را به‌طور محسوس افزایش داد؛ در دو مورد، مقدار معمول این خطا از حدود ۱۶ و ۲۳ میلی‌متر به حدود ۴۰ میلی‌متر رسید و دایس این دو جفت به کمتر از ۰/۰۷ افتاد. این الگو با تطبیق نادرست اندام‌ها در این گام سازگار است. پس از دو گذر صلب، تفاوت دو شاخه دیگر معنادار نیست (با این گام ۲۱۲ مورد بهتر و ۱۸۲ مورد بدتر؛ p برابر ۰/۱۴)، و مقدار معمول دایس بدون آن اندکی بالاتر است. این گام از مسیر پیشنهادی کنار گذاشته شد.

دوم ـ دو گذر صلب اثرهای مکمل دارند و هر یک روی گروه متفاوتی اثر می‌گذارد. هم‌ترازی صلب اولیه (کابش) در مجموع ۳۵۱ مورد را بهتر و ۱۷۹ مورد را بدتر می‌کند (p کمتر از ۰/۰۰۱) و تقریباً تمام این اثر در اندام‌های نرم است (دایس از ۰/۷۴۲ به ۰/۷۸۴؛ ۲۱۷ بهتر در برابر ۷۶ بدتر؛ p کمتر از ۰/۰۰۱)، در حالی که اثر آن بر مهره‌ها پس از تصحیح بونفرونی معنادار نیست. پالایش صلب (نلدر–مید) برعکس عمل می‌کند: اثر آن بر مهره‌هاست (دایس از ۰/۸۸۳ به ۰/۹۰۸؛ ۹۰ بهتر در برابر ۲۴ بدتر؛ p کمتر از ۰/۰۰۱) و بر اندام‌های نرم اثر معناداری ندارد. تفسیر این الگو ساده است: حل بسته‌ی کابش موقعیت

درشت اندام‌های نرم بزرگ را تصحیح می‌کند، و پالایش مبتنی‌بر دایس، انطباق دقیق ساختارهای صلب و کوچک را بهتر می‌کند؛ هیچ‌یک جایگزین دیگری نیست.

سوم ـ گذر روی بزرگی گرادیان هیچ اثری ندارد. خروجی این گذر در همه‌ی ۵۸۱ مورد و در همه‌ی شاخص‌ها دقیقاً با خروجی پالایش صلب یکسان است. دلیل روشن است: دروازه‌ی پذیرش، که نتیجه‌ی یک گذر را تنها در صورت کاهش خطای مرکز اندام می‌پذیرد، این گذر را در ۶۹۵ از ۶۹۹ مورد (۹۹/۴ درصد) رد کرد، چون مقدار معمول خطای مرکز اندام پس از آن ۱۳/۹۹ میلی‌متر در برابر ۲/۰۹ میلی‌متر پیش از آن بود. این یک نتیجه‌ی منفی است، اما نشان می‌دهد دروازه‌ی پذیرش کار خود را کرده است: بدون آن، این گذر خطا را در حالت معمول حدود شش برابر می‌کرد و این خرابی در انبوه داده پنهان می‌ماند.

گذر B ـ اسپلاین جزو این زنجیره نیست؛ این گذر در بخش ۳-۵ اختیاری تعریف شد و در ادامه‌ی همین بخش جداگانه ارزیابی می‌شود.

مقایسه‌ی توابع هدف

جدول ۴-۴ ادعای مرکزی بخش ۳-۵، یعنی سود محدودکردن معیار به اندام‌های پایدار، را می‌آزماید. هر چهار اجرا یک مدل تبدیل صلب، یک مقداردهی اولیه و یک خطکش ارزیابی دارند و تنها در تابع هدف پالایش متفاوت‌اند. این اجراها مستقل از زنجیره‌ی جدول ۴-۳ انجام شده‌اند و ارقامشان با آن جدول یکی نیست.

جدول ۴-۴: مقایسه‌ی چهار تابع هدف برای پالایش صلب روی ۵۷۷ مورد مقایسه. ستون «محاسبه روی» نشان می‌دهد معیار روی کل تصویر یا فقط روی نقاب اندام‌ها محاسبه می‌شود. دایس و خطای مرکز اندام مقدار معمول‌اند؛ ستون آخر درصد موارد شکست (دایس کمتر از ۰/۵) است.

تابع هدف	محاسبه روی	دایس	خطای مرکز (میلی‌متر)	شکست (درصد)
خطای مرکز اندام + دایس	نقاب اندام‌ها	۰/۷۹۳	۱/۹۵	۱۳/۷
همبستگی لبه‌های دو تصویر	کل تصویر	۰/۷۶۱	۲/۹۰	۱۸/۲
توصیفگر ساختاری MIND	نقاب اندام‌ها	۰/۷۹۸	۲/۴۰	۱۴/۹
خطای مرکز اندام + دایس + همبستگی لبه‌ها	نقاب اندام‌ها	**۰/۸۰۵**	۱/۹۷	**۱۳/۵**

تنها تابع هدفی که روی کل تصویر محاسبه می‌شود، ضعیف‌ترین نتیجه را دارد. در برابر تابع هدف ترکیبی (ردیف آخر)، این تابع در ۱۴۲ مورد بهتر و در ۳۹۸ مورد بدتر است (p کمتر از ۰/۰۰۱)؛ خطای مرکز اندام آن ۴۷ درصد بیشتر و نرخ شکست آن از ۱۳/۵ به ۱۸/۲ درصد بالاتر است.

شاهد مهم‌تر، *جای* این تفاوت است. در مقایسه‌ی تابع ترکیبی با تابع کل‌تصویر، دایس اندام‌های نرم

از ۰/۷۵۵ به ۰/۸۲۱ (۲۵۵ بهتر در برابر ۵۱ بدتر) و دایس رگ‌های بزرگ از ۰/۶۳۷ به ۰/۶۸۶ (۷۹ در برابر ۳۱) می‌رسد و هر دو معنادارند (p کمتر از ۰/۰۰۱)، اما در مهره‌ها تفاوتی دیده نمی‌شود (۰/۸۸۸ و ۰/۸۹۱؛ ۶۴ در برابر ۶۰). همین الگو در مقایسه‌ی تابع «خطای مرکز اندام + دایس» با تابع کل‌تصویر نیز تکرار می‌شود. این همان پیش‌بینی بخش ۳-۵ است: استخوان با کنتراست تغییر نمی‌کند و محدودکردن معیار در آن سودی ندارد؛ اندام‌های نرم و رگ‌ها همان‌جایی‌اند که کنتراست رابطه‌ی شدت روشنایی دو فاز را برهم می‌زند.

این آزمایش یک محدودیت دارد که باید صریح بماند. تابع کل‌تصویر افزون بر دامنه، در *نوع* معیار نیز با سه تابع دیگر متفاوت است، زیرا نسخه‌ی محدود به نقابِ همان معیار لبه اجرا نشده است. پس نتیجه نشان می‌دهد توابع هدفی که به نقاب اندام تکیه دارند بهتر عمل می‌کنند، اما سهم خودِ دامنه را از سهم نوع معیار جدا نمی‌کند.

دو نتیجه‌ی جانبی نیز انتخاب تابع هدف مسیر پیشنهادی را توضیح می‌دهد. افزودن جمله‌ی همبستگی لبه‌ها به «خطای مرکز اندام + دایس» در هیچ گروهی تفاوت معناداری ایجاد نمی‌کند (در مجموع ۲۶۱ بهتر در برابر ۲۴۹ بدتر؛ p برابر ۰/۶۳)؛ به همین دلیل مسیر پیشنهادی همان تابع ساده‌تر رابطه‌ی ۳-۲ را به کار می‌گیرد. توصیفگر MIND، با وجود محدود بودن به نقاب، از این تابع ساده ضعیف‌تر است (۲۱۷ بهتر در برابر ۳۲۴ بدتر؛ p کمتر از ۰/۰۰۱).

مقایسه با روش‌های موجود

جدول ۴-۵ مسیر پیشنهادی را کنار چهار روش هم‌ترازسازی شناخته‌شده قرار می‌دهد: ANTs-SyN [۴۸]، مدل آموخته‌شده‌ی uniGradICON [۶۸] با و بدون بهینه‌سازی تکمیلی، و DEEDS [۵۰]. «بهینه‌سازی تکمیلی» یعنی ۵۰ گام بهینه‌سازی روی هر جفت، پس از پیش‌بینی مدل آموخته‌شده. روش‌های موجود یک‌بار روی خروجی پیش‌پردازش این پایان‌نامه اجرا شده‌اند و دو روش از آن‌ها روی حجم خام نیز در جدول آمده‌اند؛ مقایسه‌ی کامل خام و پیش‌پردازش‌شده در زیربخش «اثر پیش‌پردازش بر روش‌های موجود» می‌آید.

جدول ۴-۵: مقایسه با روش‌های موجود روی مجموعه‌ی مشترک (۲۶ بررسی، ۵۷۴ مورد مقایسه) با خطکش ارزیابی یکسان. همه‌ی ستون‌ها مقدار معمول‌اند؛ برای دایس مقدار بیشتر و برای بقیه‌ی ستون‌ها مقدار کمتر بهتر است. تاخوردگی برای روش صلب بنا به تعریف صفر است. زمان به‌ازای هر جفت فاز است؛ زمان مسیر صلب از اجرای همان تابع هدف در جدول ۴-۴ و زمان ردیف B‌ـاسپلاین مجموع زمان مسیر صلب و این گذر است. زمان DEEDS (قرمز) شامل بازسازی میدان جابه‌جایی برای سنجش تاخوردگی است و با اندازه‌گیری رویه‌ی «سنجش هزینه‌ی محاسباتی» بخش ۳-۵ جایگزین می‌شود. خروجی مسیر صلب از اجرایی گرفته شده که گام هم‌ترازی درشت مرکز جرم هنوز در آن فعال بود؛ حذف این گام تفاوت معناداری در دقت ایجاد نمی‌کند (جدول ۴-۳).

روش	دایس	خطای مرکز (میلی‌متر)	فاصله‌ی مرزها (میلی‌متر)	تاخوردگی (درصد)	زمان (ثانیه)
مسیر پیشنهادی (بدون وزن آموخته‌شده)					
مسیر صلب پیشنهادی	۰/۸۱۵	۲/۰۹	۳/۳۵	۰	۲۸
مسیر صلب + پالایش B‌ـاسپلاین	۰/۸۵۹	۱/۳۰	۳/۰۰	۰/۰۰	۱۶۴۳
روش‌های موجود، روی خروجی پیش‌پردازش این پایان‌نامه					
ANTs-SyN	۰/۸۰۹	۱/۵۵	۳/۰۰	۰/۰۰	۸۸
uniGradICON	۰/۷۹۴	۱/۳۳	۳/۰۰	۰/۰۰	۱۱
uniGradICON با بهینه‌سازی تکمیلی	۰/۸۳۲	۱/۱۲	۲/۶۰	۰/۰۰	۱۶۹
DEEDS	۰/۸۸۶	**۱/۰۱**	**۲/۱۲**	۲/۶۵	۲۹۲
روش‌های موجود، روی حجم خام					
DEEDS	۰/۸۸۰	۱/۱۷	۲/۱۲	۱/۹۴	۳۳۷
uniGradICON	۰/۷۳۶	۱/۷۵	۳/۳۵	۰/۰۰	۱۰

این جدول در سه سطح خوانده می‌شود.

در دقت، DEEDS به‌وضوح جلوتر است. مسیر صلب در ۶۳ مورد از DEEDS بهتر و در ۵۰۵ مورد بدتر است (p کمتر از ۰/۰۰۱)، و هیچ خوانشی از این داده ادعای هم‌رده‌بودن دقت آن دو را پشتیبانی نمی‌کند. اما DEEDS در حالت معمول ۲/۶۵ درصد وکسل‌های درون نقاب را تا می‌کند؛ تغییرشکل در آن نواحی از نظر فیزیکی نامعتبر است و بافتی می‌سازد که در بدن بیمار وجود ندارد. برای کاربرد این پایان‌نامه، یعنی ساخت جفت‌های آموزشی سنتز، نبودِ تاخوردگی یک الزام است. با این حال بهترین دقت کل این مطالعه، دایس ۰/۸۸۶، روی خروجی پیش‌پردازش همین پایان‌نامه به دست آمده است.

در برابر مدل آموخته‌شده، نتیجه برابری است و نه برتری. مقدار معمول دایس مسیر صلب (۰/۸۱۵) از uniGradICON (۰/۷۹۴) بالاتر است، اما مقایسه‌ی مورد به مورد این تفاوت را تأیید نمی‌کند (۲۹۸ بهتر در برابر ۲۷۹ بدتر؛ p برابر ۰/۴۵). ادعای درست این است که یک مسیر صلبِ بدون آموزش با یک مدل هم‌ترازسازی آموخته‌شده روی مجموعه‌داده‌های متعدد تفاوت معناداری ندارد؛ نه این‌که از آن بهتر

است. نسخه‌ی همان مدل با بهینه‌سازی تکمیلی از مسیر صلب به‌طور معنادار دقیق‌تر است (۲۰۳ بهتر در برابر ۳۷۲ بدتر برای مسیر صلب؛ p کمتر از ۰/۰۰۱).

با گذر اختیاری B–اسپلاین، مسیر پیشنهادی به گروه روش‌های غیرصلب بدون تاخوردگی می‌رسد. این ردیف بالاترین مقدار معمول دایس را در میان روش‌های بدون تاخوردگی دارد، اما مقدار معمول به‌تنهایی مبنای رتبه‌بندی نیست؛ مقایسه‌ی مورد به مورد، الگوی اثر به تفکیک اندام و هزینه‌ی این گذر در زیربخش «گذر اختیاری پالایش غیرصلب» گزارش می‌شود.

تفکیک به‌ازای گروه اندام و اندام

برابری کلی مسیر صلب با uniGradICON عددی است که روی یازده اندام با رفتار آناتومیک متفاوت گرفته شده است. جدول ۴-۶ همان مقایسه را به سه گروه اندام تفکیک می‌کند.

جدول ۴-۶: دایس به تفکیک گروه اندام (مقدار معمول) روی مجموعه‌ی مشترک: اندام‌های نرم ۳۱۷، رگ‌های بزرگ ۱۱۰ و مهره‌ها ۱۴۷ مورد مقایسه. روش‌های موجود روی خروجی پیش‌پردازش این پایان‌نامه اجرا شده‌اند. نشانه‌ی † یعنی آن روش در مقایسه‌ی مورد به مورد به‌طور معنادار از مسیر صلب پیشنهادی *بهتر*است و ‡ یعنی *بدتر*؛ آستانه‌ی معناداری پس از تصحیح برای سه گروه ۰/۰۱۷ است. نبودن نشانه یعنی تفاوت معنادار نیست.

روش	اندام‌های نرم	رگ‌های بزرگ	مهره‌ها
مسیر صلب پیشنهادی	۰/۷۹۵	۰/۶۷۰	۰/۹۱۰
مسیر صلب + پالایش B–اسپلاین	†۰/۸۵۲	۰/۶۵۵	۰/۹۰۵
ANTs-SyN	†۰/۷۹۸	۰/۶۷۲	۰/۹۱۵
uniGradICON	†۰/۷۷۶	۰/۶۳۸	‡۰/۸۹۷
uniGradICON با بهینه‌سازی تکمیلی	†۰/۸۲۴	۰/۶۵۳	۰/۹۱۸
DEEDS	†۰/۸۸۳	†۰/۷۸۳	†۰/۹۲۴

الگوی این جدول روشن است: فاصله‌ی مسیر صلب با روش‌های غیرصلب بدون تاخوردگی تقریباً تنها در اندام‌های نرم است. در رگ‌های بزرگ، تفاوت آن با ANTs-SyN و هر دو نسخه‌ی uniGradICON معنادار نیست. در مهره‌ها نیز تفاوت با ANTs-SyN و uniGradICON با بهینه‌سازی تکمیلی معنادار نیست، و مسیر صلب از uniGradICON به‌طور معنادار بهتر است (۹۸ بهتر در برابر ۴۹ بدتر؛ p کمتر از ۰/۰۰۱). تنها DEEDS در هر سه گروه برتری معنادار دارد، که با تاخوردگی همراه است.

در اندام‌های نرم، هر سه روش غیرصلب بدون تاخوردگی از مسیر صلب بهترند، اما نه به یک اندازه: برتری uniGradICON کوچک است (۱۸۱ در برابر ۱۳۶؛ p برابر ۰/۰۱۳) و حتی با مقدار معمول پایین‌تری همراه است، در حالی که برتری نسخه‌ی دارای بهینه‌سازی تکمیلی قاطع است (p کمتر از ۰/۰۰۱).

این همان گروهی است که انتظار می‌رود فرض صلب‌بودن در آن بیش از همه نقض شود، و گذر اختیاری B‌ـاسپلاین دقیقاً همین گروه را بهبود می‌دهد.

جدول ۴-۷ همین تحلیل را به سطح اندام می‌برد و نشان می‌دهد برابری کلی با uniGradICON از جنس «نبود تفاوت» نیست، بلکه حاصل جمع دو برتری در جهت مخالف است.

جدول ۴-۷: دایس به تفکیک اندام (مقدار معمول) روی مجموعه‌ی مشترک؛ روش‌های موجود روی خروجی پیش‌پردازش این پایان‌نامه اجرا شده‌اند. سه ستون آخر مسیر صلب را مورد به مورد با uniGradICON مقایسه می‌کنند: شمار مواردی که مسیر صلب بهتر و بدتر است و مقدار p. چون این مقایسه برای یازده اندام تکرار شده، آستانه‌ی معناداری پس از تصحیح ۰/۰۰۴۵ است و مقادیری که از آن عبور می‌کنند با $*$ مشخص شده‌اند.

اندام	مسیر صلب	ANTs-SyN	uniGradICON	uniGradICON با بهینه‌سازی	DEEDS	صلب بهتر	صلب بدتر	p
اندام‌های نرم								
کبد	۰/۹۲۸	۰/۹۴۴	۰/۹۴۹	۰/۹۵۶	۰/۹۶۱	۹	۴۶	کمتر از ۰/۰۰۱*
طحال	۰/۸۷۷	۰/۹۰۷	۰/۹۲۳	۰/۹۳۱	۰/۹۳۶	۹	۴۶	کمتر از ۰/۰۰۱*
کلیه‌ی راست	۰/۷۹۰	۰/۷۸۳	۰/۷۱۶	۰/۷۴۵	۰/۸۷۵	۴۵	۱۰	کمتر از ۰/۰۰۱*
کلیه‌ی چپ	۰/۷۵۷	۰/۷۶۹	۰/۷۳۷	۰/۷۸۰	۰/۸۷۷	۳۸	۱۷	۰/۰۰۶۵
پانکراس	۰/۵۴۱	۰/۵۹۶	۰/۶۴۲	۰/۶۶۶	۰/۷۱۴	۲۱	۳۴	۰/۱۰
کیسه‌ی صفرا	۰/۵۷۸	۰/۶۵۴	۰/۷۲۶	۰/۷۳۱	۰/۷۸۷	۱۴	۲۸	۰/۰۴۴
رگ‌های بزرگ								
آئورت	۰/۷۳۴	۰/۷۰۵	۰/۶۵۱	۰/۶۹۱	۰/۸۴۲	۴۴	۱۱	کمتر از ۰/۰۰۱*
بزرگ‌سیاهرگ زیرین	۰/۵۵۹	۰/۶۵۱	۰/۶۱۸	۰/۶۵۱	۰/۶۷۴	۱۸	۳۷	۰/۰۱۴
مهره‌ها								
مهره‌ی L1	۰/۹۱۱	۰/۹۰۵	۰/۸۸۵	۰/۹۰۲	۰/۹۱۴	۳۸	۱۶	۰/۰۰۳۸*
مهره‌ی L2	۰/۹۰۳	۰/۹۱۱	۰/۸۹۷	۰/۹۱۶	۰/۹۲۳	۳۵	۱۴	۰/۰۰۳۸*
مهره‌ی L3	۰/۹۱۲	۰/۹۲۵	۰/۹۱۵	۰/۹۲۸	۰/۹۳۱	۲۵	۱۹	۰/۴۵

پس از تصحیح، مسیر صلب بر آئورت، کلیه‌ی راست و مهره‌های L1 و L2 به‌طور معنادار از uniGradICON بهتر است، و uniGradICON بر کبد و طحال؛ در پنج اندام دیگر هیچ تفاوتی از آستانه‌ی تصحیح‌شده عبور نمی‌کند.

این تقسیم تصادفی به نظر نمی‌رسد. ساختارهایی که مسیر صلب در آن‌ها برتر است میان دو اسکن کم‌وبیش مانند یک جسم صلب جابه‌جا می‌شوند: مهره‌ها ذاتاً صلب‌اند، و آئورت و کلیه‌ها پشت صفاق و در مجاورت ستون فقرات قرار دارند. در مقابل، کبد و طحال مستقیماً زیر دیافراگم‌اند و بیشترین تغییرشکل تنفسی را دارند. این الگو با این تفسیر سازگار است که خطای مسیر صلب در جایی متمرکز است که فرض صلب‌بودن نقض می‌شود، و در جایی که این فرض برقرار است، تبدیل صلب، که برخلاف یک میدان تغییرشکل آموخته‌شده شکل ساختار را تغییر نمی‌دهد، از مدل آموخته‌شده پیشی می‌گیرد. این تبیین با این

داده مستقیماً آزموده نشده است.

اثر پیش‌پردازش بر روش‌های موجود

مهم‌ترین نتیجه‌ی این بخش، مقایسه‌ی مسیر صلب با روش‌های دیگر نیست، بلکه این است که پیش‌پردازش این پایان‌نامه می‌تواند *پیش از* همان روش‌ها به کار رود و آن‌ها را بهتر کند. برای سنجش آن، هر یک از چهار روش موجود با پارامترهای یکسان دو بار اجرا شد: یک‌بار روی حجم خام و یک‌بار روی خروجی پیش‌پردازش. حجم خام نیز یکسان‌سازی هندسه و شدت روشنایی را گذرانده است؛ تفاوت دو اجرا برش مشترک آناتومی‌محور است، به‌همراه گام هم‌ترازی درشت مرکز جرم که در زمان این اجراها هنوز فعال بود. جدول ۴–۸ نتیجه را با سه شاخص گزارش می‌کند: دایس در حالت معمول، شمار شکست‌ها، و شمار خطاهای بزرگ مرکز اندام.

جدول ۴–۸: اثر پیش‌پردازش این پایان‌نامه بر چهار روش هم‌ترازسازی موجود، روی حدود ۵۸۰ مورد مقایسه از ۲۶ بررسی. «شکست» یعنی دایس کمتر از ۰٫۵ و «خطای بزرگ» یعنی خطای مرکز اندام بیش از ۱۰ میلی‌متر. ستون «تغییر مورد به مورد» برای دایس شمار مواردی را می‌دهد که با پیش‌پردازش بهتر و بدتر شده‌اند، و برای دو شاخص دیگر شمار شکست‌ها یا خطاهای بزرگی که رفع شده و شمار آن‌هایی که تازه پدید آمده‌اند. مقدار p از آزمون علامت روی همین دو شمار به دست آمده است.

روش	شاخص	روی حجم خام	با پیش‌پردازش	تغییر مورد به مورد	p
DEEDS	دایس (مقدار معمول)	۰٫۸۸۰	۰٫۸۸۶	۳۷۱ بهتر، ۱۹۶ بدتر	کمتر از ۰٫۰۰۱
	شمار شکست‌ها	۳۲	۲۲	۱۳ رفع، ۳ تازه	۰٫۰۲۱
	شمار خطاهای بزرگ	۶۳	۲۲	۴۳ رفع، ۲ تازه	کمتر از ۰٫۰۰۱
uniGradICON	دایس (مقدار معمول)	۰٫۷۳۴	۰٫۷۹۴	۳۳۰ بهتر، ۲۴۴ بدتر	کمتر از ۰٫۰۰۱
	شمار شکست‌ها	۱۵۷	۸۷	۸۳ رفع، ۱۳ تازه	کمتر از ۰٫۰۰۱
	شمار خطاهای بزرگ	۱۴۳	۵۱	۱۰۳ رفع، ۱۱ تازه	کمتر از ۰٫۰۰۱
uniGradICON با بهینه‌سازی تکمیلی	دایس (مقدار معمول)	۰٫۷۹۶	۰٫۸۳۲	۲۹۶ بهتر، ۲۸۰ بدتر	۰٫۵۳
	شمار شکست‌ها	۱۰۸	۶۴	۵۲ رفع، ۸ تازه	کمتر از ۰٫۰۰۱
	شمار خطاهای بزرگ	۱۱۵	۴۷	۷۷ رفع، ۹ تازه	کمتر از ۰٫۰۰۱
ANTs-SyN	دایس (مقدار معمول)	۰٫۸۱۶	۰٫۸۰۹	۲۶۶ بهتر، ۲۹۳ بدتر	۰٫۲۷
	شمار شکست‌ها	۶۱	۵۷	۱۱ رفع، ۷ تازه	۰٫۴۸
	شمار خطاهای بزرگ	۷۵	۴۴	۳۷ رفع، ۶ تازه	کمتر از ۰٫۰۰۱

جدول ۴–۸ یک پیام روشن دارد: پیش‌پردازش برای هر *چهار* روش شمار خطاهای بزرگ مرکز اندام را به‌طور معنادار کم می‌کند، برای سه روش شمار شکست‌ها را، و برای دو روش مقدار معمول دایس را.

در همه‌ی موارد، شمار خطاهای رفع‌شده چند برابر شمار خطاهای تازه است. برای uniGradICON، ۸۳ شکست رفع و تنها ۱۳ شکست تازه پدید آمد و شمار خطاهای بزرگ از ۱۴۳ به ۵۱ رسید؛ برای DEEDS، که روی حجم خام هم کم شکست می‌خورد، خطاهای بزرگ از ۶۳ به ۲۲ کاهش یافت. ANTs-SyN تنها روشی است که دایس معمول و شمار شکست‌هایش تغییر معناداری نمی‌کند، اما حتی در آن نیز خطاهای بزرگ از ۷۵ به ۴۴ رسید.

چرا برای دو روش شمار شکست‌ها کم می‌شود اما دایس معمول تغییر معناداری نمی‌کند؟ جدول ۴–۹ پاسخ را نشان می‌دهد. در این جدول، موارد مقایسه‌ی هر چهار روش بر اساس دایس روی حجم خام دسته‌بندی شده‌اند.

جدول ۴–۹: اثر پیش‌پردازش به تفکیک دشواری مورد روی حجم خام، برای موارد مقایسه‌ی هر چهار روش جدول ۴–۸ به‌صورت یک‌جا. ستون آخر شمار مواردی است که با پیش‌پردازش نیز دایس کمتر از ۰٫۵ دارند.

دایس روی حجم خام	موارد	میانگین تغییر دایس	بهتر	بدتر	p	همچنان شکست
کمتر از ۰٫۵ (شکست)	۳۵۸	۰٫۲۹۴	۲۶۷	۸۳	کمتر از ۰٫۰۰۱	۱۹۹
از ۰٫۵ تا ۰٫۷۵	۵۵۰	۰٫۰۱۷	۳۱۱	۲۳۹	۰٫۰۰۲۴	۲۶
۰٫۷۵ و بیشتر	۱۳۹۹	منفی ۰٫۰۰۵	۶۸۵	۶۹۱	۰٫۸۹	۵

پیش‌پردازش در مواردی که روی حجم خام شکست خورده‌اند، دایس را در میانگین ۰٫۲۹۴ بالا می‌برد و ۱۵۹ مورد از ۳۵۸ شکست را رفع می‌کند؛ در مواردی که روی حجم خام خوب هم‌تراز شده‌اند، هیچ تغییر معناداری ایجاد نمی‌کند. به بیان دیگر، پیش‌پردازش *شکست‌ها را از میان برمی‌دارد* و به موارد موفق آسیبی نمی‌زند. چون مقدار معمول دایس در موارد موفق تعیین می‌شود، این اثر در آن کمتر دیده می‌شود و شمار شکست‌ها و خطاهای بزرگ شاخص درست‌تری برای آن است. سود برای روش‌هایی بزرگ‌تر است که روی حجم خام بیشتر شکست می‌خورند: نرخ شکست روی حجم خام برای uniGradICON ۲۷٫۲ درصد و برای نسخه‌ی دارای بهینه‌سازی تکمیلی ۱۸٫۷ درصد است و میانگین بهبود موارد شکست این دو، ۰٫۳۵۷ و ۰٫۳۴۵ است؛ این اعداد برای ANTs-SyN (نرخ شکست ۱۰٫۶ درصد) و DEEDS (۵٫۵ درصد) به ۰٫۱۰۸ و ۰٫۱۶۶ می‌رسد. نیمه‌ی دیگر تصویر نیز باید گفته شود: ۱۹۹ مورد از شکست‌ها با پیش‌پردازش نیز شکست می‌مانند.

جدول ۴–۱۰ همین اثر را به تفکیک اندام نشان می‌دهد.

جدول ۴-۱۰: دایس روی حجم خام و با پیش‌پردازش (مقدار معمول) به تفکیک گروه اندام و اندام. نشانه‌ی * یعنی پیش‌پردازش آن روش را در آن گروه یا اندام به‌طور معنادار *بهتر* کرده و † یعنی به‌طور معنادار *بدتر*؛ آستانه‌ی معناداری پس از تصحیح برای سه گروه ۰/۰۱۷ و برای یازده اندام ۰/۰۰۴۵ است. نبودن نشانه یعنی تفاوت معنادار نیست.

	DEEDS		uniGradICON		uniGradICON با بهینه‌سازی		ANTs-SyN	
اندام	**خام**	**پیش‌پردازش**	**خام**	**پیش‌پردازش**	**خام**	**پیش‌پردازش**	**خام**	**پیش‌پردازش**
اندام‌های نرم								
کل گروه	۰/۸۸۰	*۰/۸۸۳	۰/۷۲۲	*۰/۷۷۴	۰/۷۸۲	۰/۸۲۳	۰/۷۹۴	۰/۷۹۸
کبد	۰/۹۵۸	*۰/۹۶۱	۰/۹۴۴	۰/۹۴۹	۰/۹۵۳	۰/۹۵۶	۰/۹۴۶	۰/۹۴۵
طحال	۰/۹۳۵	۰/۹۳۶	۰/۹۱۹	۰/۹۲۳	۰/۹۲۸	۰/۹۳۱	۰/۹۰۵	۰/۹۰۷
کلیه‌ی راست	۰/۸۶۶	*۰/۸۷۵	۰/۶۲۸	۰/۷۱۶	۰/۷۳۱	۰/۷۴۵	۰/۷۸۸	۰/۷۸۳
کلیه‌ی چپ	۰/۸۶۴	۰/۸۷۷	۰/۶۸۶	*۰/۷۳۷	۰/۷۷۹	۰/۷۸۰	۰/۷۶۶	۰/۷۶۹
پانکراس	۰/۷۰۹	۰/۷۱۴	۰/۶۱۲	۰/۶۴۲	۰/۶۵۰	۰/۶۶۶	۰/۶۰۷	۰/۵۹۶
کیسه‌ی صفرا	۰/۷۹۲	۰/۷۸۷	۰/۶۷۲	۰/۷۲۲	۰/۶۵۰	۰/۷۲۸	۰/۶۵۲	۰/۶۵۴
رگ‌های بزرگ								
کل گروه	۰/۷۵۴	*۰/۷۸۳	۰/۵۴۹	۰/۶۳۸	۰/۶۱۵	۰/۶۵۳	۰/۶۲۳	۰/۶۷۲
آئورت	۰/۸۰۰	*۰/۸۴۲	۰/۵۵۸	۰/۶۵۱	۰/۶۴۰	۰/۶۹۱	۰/۶۵۷	۰/۷۰۵
بزرگ‌سیاهرگ زیرین	۰/۶۴۸	۰/۶۷۴	۰/۵۲۷	*۰/۶۱۸	۰/۶۱۵	*۰/۶۵۱	۰/۶۱۷	۰/۶۵۱
مهره‌ها								
کل گروه	۰/۹۱۸	*۰/۹۲۳	۰/۸۹۵	۰/۸۹۷	۰/۹۱۶	۰/۹۱۶	۰/۹۲۰	†۰/۹۱۵
مهره‌ی L1	۰/۹۱۳	۰/۹۱۱	۰/۸۸۱	۰/۸۸۴	۰/۹۰۸	۰/۹۰۲	۰/۹۰۸	۰/۹۰۵
مهره‌ی L2	۰/۹۱۸	*۰/۹۲۳	۰/۸۹۱	۰/۸۹۷	۰/۹۲۱	۰/۹۱۶	۰/۹۲۲	۰/۹۱۱
مهره‌ی L3	۰/۹۲۲	*۰/۹۳۰	۰/۹۰۸	۰/۹۱۳	۰/۹۲۰	۰/۹۲۷	۰/۹۳۰	۰/۹۲۵

برای DEEDS، پیش‌پردازش در هر سه گروه به‌طور معنادار سودمند است و در سطح اندام، آئورت، کلیه‌ی راست، کبد و مهره‌های L2 و L3 را بهتر می‌کند؛ بزرگ‌ترین جهش در آئورت است (۰/۸۰۰ به ۰/۸۴۲). برای uniGradICON، سود در اندام‌های نرم معنادار است و کلیه‌ی چپ و بزرگ‌سیاهرگ زیرین را بهتر می‌کند؛ برای نسخه‌ی دارای بهینه‌سازی تکمیلی، بزرگ‌سیاهرگ زیرین. اثر پیش‌پردازش بر شکست‌ها در سطح اندام از این نیز روشن‌تر است: شکست‌های طحال برای uniGradICON از ۹ و برای نسخه‌ی دارای بهینه‌سازی از ۷ به صفر رسید، شکست‌های کبد uniGradICON از ۵ به صفر، و شکست‌های کلیه‌ی راست نسخه‌ی دارای بهینه‌سازی از ۹ به ۱؛ در کل اندام‌های نرم، شکست‌های uniGradICON از ۸۶ به ۴۰ و شکست‌های نسخه‌ی دارای بهینه‌سازی از ۶۰ به ۲۹ کاهش یافت.

یک نتیجه‌ی خلاف این جهت نیز باید گزارش شود. برای ANTs-SyN در مهره‌ها، پیش‌پردازش دایس را اندکی و به‌طور معنادار *کاهش* داد (۵۲ مورد بهتر در برابر ۸۴ بدتر؛ مقدار معمول از ۰/۹۲۰ به ۰/۹۱۵). اندازه‌ی این کاهش کوچک است و علت آن در این پایان‌نامه بررسی نشده است.

آیا این اثر به گام هم‌ترازی درشت مرکز جرم وابسته است که از مسیر پیشنهادی کنار گذاشته شد؟ برای

پاسخ، همین مقایسه با خروجی *فقط برش مشترک* روی ۲۹ بررسی نیز انجام شد. نتیجه همان است: شمار خطاهای بزرگ برای DEEDS از ۸۲ به ۲۶، برای ANTs-SyN از ۸۹ به ۵۲ و برای uniGradICON با بهینه‌سازی تکمیلی از ۱۵۷ به ۵۵ رسید، و شمار شکست‌های DEEDS از ۳۹ به ۲۷ و نسخه‌ی دارای بهینه‌سازی از ۱۴۲ به ۷۱ کاهش یافت؛ همه‌ی این تغییرها معنادارند (p کمتر از ۰/۰۱). برای ANTs-SyN، مانند پیش، شمار شکست‌ها تغییر نکرد. اجرای فقط‌برش uniGradICON تنها برای ۸ بررسی کامل است و در این مقایسه نیامده است.

ادعای قابل‌دفاع این زیربخش در نتیجه چنین است: پیش‌پردازش این پایان‌نامه، پیش از روش‌های هم‌ترازسازی موجود، شکست‌ها و خطاهای بزرگ آن‌ها را به‌طور معنادار کاهش می‌دهد، برای DEEDS و uniGradICON دقت معمول را نیز بالا می‌برد، و بهترین پیکربندی کل این مطالعه روی خروجی همین پیش‌پردازش به دست آمده است. ادعای بهبود دقت معمول برای ANTs-SyN و نسخه‌ی دارای بهینه‌سازی تکمیلی uniGradICON پشتیبانی نمی‌شود.

گذر اختیاری پالایش غیرصلب: سنجه‌ای برای کیفیت جفت‌ها

جدول‌های پیشین کیفیت خروجی صلب را در برابر روش‌های دیگر می‌سنجند، اما به یک پرسش مستقیم پاسخ نمی‌دهند: پس از هم‌ترازی صلب، چه مقدار ناهم‌ترازی *غیرصلب* در جفت‌ها باقی مانده و این باقی‌مانده در کدام اندام‌هاست؟ پاسخ این پرسش مشخص می‌کند جفت‌هایی که به سنتز داده می‌شوند در کدام نواحی قابل‌اتکا هستند. گذر اختیاری B‑اسپلاین بخش ۳-۵ برای همین پرسش به کار رفت. این گذر از خروجی مسیر صلب آغاز می‌کند و تنها تغییرشکل محلی به آن می‌افزاید؛ پس فاصله‌ی دقت آن با خروجی صلب، اندازه‌ای از همان ناهم‌ترازی باقی‌مانده است. جدول ۴-۱۱ این فاصله را به تفکیک گروه اندام و اندام گزارش می‌کند.

جدول ۴-۱۱: گذر اختیاری B ـ اسپلاین در برابر مسیر صلب پیشنهادی روی مجموعه‌ی مشترک. دایس به‌صورت مقدار معمول است. دو ستون «بهتر» و «بدتر» شمار مواردی را می‌دهند که گذر غیرصلب در آن‌ها دایس بالاتر یا پایین‌تری از خروجی صلب دارد (موارد برابر کنار گذاشته شده‌اند) و ستون آخر مقدار p است. آستانه‌ی معناداری پس از تصحیح برای سه گروه ۰/۰۱۷ و برای یازده اندام ۰/۰۰۴۵ است و مقادیری که از آن عبور می‌کنند با $*$ مشخص شده‌اند.

گروه یا اندام	مسیر صلب	با پالایش B ـ اسپلاین	بهتر	بدتر	p
اندام‌های نرم					
کل گروه	۰/۷۹۵	۰/۸۵۲	۲۳۴	۷۵	کمتر از ۰/۰۰۱*
کبد	۰/۹۲۸	۰/۹۵۱	۵۲	۲	کمتر از ۰/۰۰۱*
طحال	۰/۸۷۷	۰/۹۲۰	۴۵	۹	کمتر از ۰/۰۰۱*
کلیه‌ی راست	۰/۷۹۰	۰/۸۳۷	۳۶	۱۸	۰/۰۲۰
کلیه‌ی چپ	۰/۷۵۷	۰/۸۲۲	۴۱	۱۳	کمتر از ۰/۰۰۱*
پانکراس	۰/۵۴۱	۰/۵۶۳	۲۷	۲۷	۱/۰۰
کیسه‌ی صفرا	۰/۵۷۸	۰/۷۴۳	۳۳	۶	کمتر از ۰/۰۰۱*
رگ‌های بزرگ					
کل گروه	۰/۶۷۰	۰/۶۵۵	۴۲	۶۶	۰/۰۲۶
آئورت	۰/۷۳۴	۰/۶۹۷	۱۲	۴۲	کمتر از ۰/۰۰۱*
بزرگ‌سیاهرگ زیرین	۰/۵۵۹	۰/۵۷۹	۳۰	۲۴	۰/۵۰
مهره‌ها					
کل گروه	۰/۹۱۰	۰/۹۰۵	۵۸	۷۷	۰/۱۲
مهره‌ی L1	۰/۹۱۱	۰/۹۰۳	۱۹	۳۴	۰/۰۵۳
مهره‌ی L2	۰/۹۰۳	۰/۹۰۱	۱۸	۲۶	۰/۲۹
مهره‌ی L3	۰/۹۱۲	۰/۹۰۹	۲۱	۱۷	۰/۶۳

در مجموع، گذر غیرصلب مقدار معمول دایس را از ۰/۸۱۵ به ۰/۸۵۹ می‌رساند و در مقایسه‌ی مورد به مورد روی ۵۷۷ مورد، ۳۳۴ مورد بهتر و ۲۲۰ مورد بدتر است (p کمتر از ۰/۰۰۱). میانگین این بهبود ۰/۰۲۸ واحد دایس است و بازه‌ی اطمینان ۹۵ درصدی آن، که با ۲۰۰۰ بار نمونه‌گیری دوباره‌ی تصادفی از بررسی‌ها برآورد شد، از ۰/۰۱۵ تا ۰/۰۴۳ است. مقدار معمول خطای مرکز اندام نیز از ۲/۰۹ به ۱/۳۰ میلی‌متر می‌رسد. این بهبود با تاخوردگی ناچیزی همراه است: تاخوردگی در حالت معمول صفر است، تنها ۱۱ از ۵۵ جفت فاز مقدار غیرصفر دارند و بیشینه‌ی آن ۰/۰۵۵ درصد وکسل‌هاست.

اهمیت این گذر اما بیشتر در *الگوی* اثر آن است تا در عدد کل. همه‌ی بهبود معنادار در اندام‌های نرم رخ می‌دهد: کبد، طحال، کلیه‌ی چپ و کیسه‌ی صفرا پس از تصحیح بهبود معنادار دارند و بزرگ‌ترین جهش در کیسه‌ی صفراست (۰/۵۷۸ به ۰/۷۴۳). در مهره‌ها تفاوت معناداری دیده نمی‌شود؛ همان رفتاری که از

گروه کنترل انتظار می‌رود، چون مهره‌ها صلب‌اند و پس از گذرهای صلب احتمالاً چیزی برای اصلاح محلی در آن‌ها باقی نمانده است. خوانش این جدول به‌عنوان سنجه‌ی کیفیت جفت‌ها این است که ناهم‌ترازی باقی‌مانده‌ی جفت‌های صلب عمدتاً در اندام‌های نرم است. این نتیجه برای ارزیابی سنتز معنا دارد، چون معیار اصلی آن در سطح اندام تعریف شده است (بخش ۳–۷): بخشی از اختلاف تصویر سنتزی با مرجع در همین اندام‌ها ممکن است از ناهم‌ترازی جفت و نه از خطای مدل ناشی شود.

رگ‌های بزرگ در جهت مخالف حرکت می‌کنند. گذر غیرصلب بر آئورت به‌طور معنادار از خروجی صلب بدتر است (۱۲ مورد بهتر در برابر ۴۲ مورد بدتر؛ p کمتر از ۰/۰۰۱) و در بزرگ‌سیاهرگ زیرین اثر معناداری ندارد. یک تبیین محتمل به معیار این گذر برمی‌گردد: این معیار روی بزرگی گرادیان شدت روشنایی تعریف شده است، و لبه‌های رگ‌ها همان لبه‌هایی‌اند که با ورود ماده‌ی حاجب پدیدار یا پررنگ می‌شوند؛ پس فرضی که معیار در استخوان بر آن تکیه دارد، در رگ‌ها برقرار نیست. تفکیک فازها با این تبیین سازگار است: میانگین بهبود در فاز وریدی ۰/۰۳۷ واحد دایس است (p کمتر از ۰/۰۰۱) و در فاز شریانی، که تغییر روشنایی رگ‌ها در آن شدیدتر است، ۰/۰۲۷ (p برابر ۰/۰۴۷). این تبیین در این پایان‌نامه آزموده نشده است؛ پیامد عملی آن اما به تبیین وابسته نیست: برای رگ‌ها، خروجی صلب انتخاب مطمئن‌تری است.

سود گذر غیرصلب در موارد دشوار بزرگ‌تر است، اما این موارد را نجات نمی‌دهد. در ۷۷ مورد مقایسه‌ای که دایس خروجی صلب در آن‌ها کمتر از ۰/۵ است، میانگین بهبود ۰/۱۰۵ است؛ با این حال ۴۶ مورد از آن‌ها پس از پالایش نیز شکست می‌مانند و نرخ شکست کل تنها از ۱۳/۴ به ۹/۹ درصد می‌رسد. یک گذر محلی با شبکه‌ی کنترلی ۲۵ میلی‌متری برای جبران خطای درشت طراحی نشده است، و این نتیجه با این برداشت سازگار است که کیفیت نهایی همچنان به گذرهای صلب و پیش‌پردازش پیش از آن‌ها وابسته است.

خوانش دوم این گذر به خودِ پیش‌پردازش مربوط است. تبدیل B‌ـاسپلاین آزادشکل روشی کلاسیک و بدون آموزش است [۵۷]، و وقتی از خروجی مسیر صلب این پایان‌نامه آغاز می‌کند، به گروه روش‌های غیرصلب بدون تاخوردگی می‌رسد. تفاوت آن با ANTs-SyN معنادار نیست (۳۰۴ در برابر ۲۶۳؛ p برابر ۰/۰۹۳) و از uniGradICON بهتر است (۳۵۰ در برابر ۲۲۷؛ p کمتر از ۰/۰۰۱). در برابر uniGradICON با بهینه‌سازی تکمیلی تصویر یکدست نیست: آن مدل در موارد بیشتری جلوتر است (۳۱۵ در برابر ۲۶۰؛ p برابر ۰/۰۲۴)، اما میانگین تفاوت تنها ۰/۰۰۱ واحد دایس است و بازه‌ی اطمینان آن، از منفی ۰/۰۱۲ تا ۰/۰۱۱، صفر را در بر می‌گیرد. DEEDS همچنان به‌طور قاطع دقیق‌تر است (۵۲۴ مورد در برابر ۴۹)، با همان تاخوردگی جدول ۴–۵. این مقایسه یک قید دارد: گذر B‌ـاسپلاین تنها روی خروجی پیش‌پردازش اجرا شده است، پس نشان نمی‌دهد همین گذر بدون پیش‌پردازش به کجا می‌رسید؛

شاهد مستقیم اثر پیش‌پردازش همچنان جدول ۴-۸ است.

این دو خوانش جایگاه گذر غیرصلب را تعیین می‌کنند. دقت بیشتر آن واقعی است، اما بهایی دارد که در زیربخش بعد می‌آید: زمان معمول مسیر صلب همراه با این گذر ۱۶۴۳ ثانیه به‌ازای هر جفت فاز است. بنابراین این گذر برای ساخت یک‌باره و برون‌خط جفت‌های آموزشی، وقتی دقت اندام‌های نرم اولویت دارد، گزینه‌ای قابل‌دفاع است؛ و برای رگ‌ها یا کاربردی که زمان در آن محدودیت است، مسیر صلب کافی و مطمئن‌تر است. کاربرد دیگر آن سنجش است: هر بار که داده یا گام‌های پیش‌پردازش تغییر کند، اجرای این گذر روی جفت‌ها نشان می‌دهد ناهم‌ترازی باقی‌مانده در کدام اندام‌ها و به چه اندازه است.

هزینه‌ی محاسباتی

جدول ۴-۱۲ هزینه‌ی هر روش را به‌ازای هر جفت فاز نشان می‌دهد: زمان اجرا، بیشینه‌ی حافظه و نیاز به آموزش پیشین. رویه‌ی اندازه‌گیری در بخش ۳-۵ آمده است. همه‌ی اجراها روی یک سرور با ۸۰ هسته‌ی پردازنده و بدون پردازنده‌ی گرافیکی انجام شده‌اند؛ پس این جدول یک مقایسه‌ی پردازنده با پردازنده است، نکته‌ای که در خواندن ردیف‌های uniGradICON اهمیت دارد.

جدول ۴-۱۲: هزینه‌ی روش‌ها به‌ازای هر جفت فاز روی همان ۲۶ بررسی. ستون دوم مقدار معمول زمان بر حسب ثانیه است و ستون سوم بازه‌ای که نیمی از اجراها در آن قرار دارند؛ ستون «نسبت» زمان معمول هر روش را بر زمان معمول مسیر صلب تقسیم می‌کند و ستون آخر نشان می‌دهد روش به آموزش پیشین روی داده نیاز دارد یا نه. روش‌های موجود روی خروجی پیش‌پردازش این پایان‌نامه اجرا شده‌اند. زمان ردیف B ـ اسپلاین مجموع زمان مسیر صلب و این گذر برای همان جفت فاز است. خانه‌های قرمز ردیف DEEDS زمان ثبت‌شده‌ی قبلی‌اند که بازسازی میدان جابه‌جایی برای سنجش تاخوردگی را نیز در بر می‌گیرد، و خانه‌های [عدد؟] مقادیری‌اند که با رویه‌ی اندازه‌گیری کل درخت فرایندها تکمیل می‌شوند.

روش	زمان معمول	نیمی از اجراها	نسبت	حافظه (مگابایت)	آموزش
مسیر صلب پیشنهادی	۲۸	۲۴–۳۱	۱/۰	۱۳۳۶	ندارد
مسیر صلب + پالایش B ـ اسپلاین	۱۶۴۳	۹۰۶–۲۴۵۶	۵۸/۸	[عدد؟]	ندارد
ANTs-SyN	۸۸	۶۸–۱۰۳	۳/۱	۳۲۳۵	ندارد
uniGradICON	۱۱	۹–۱۳	۰/۴	۳۶۲۱	دارد
uniGradICON با بهینه‌سازی تکمیلی	۱۶۹	۱۲۴–۲۰۶	۶/۰	۳۸۲۶	دارد
DEEDS	۲۹۲	۲۴۲–۳۳۱	۱۰/۵	[عدد؟]	ندارد

مسیر صلب پیشنهادی از همه‌ی روش‌های مبتنی‌بر بهینه‌سازی تکراری ارزان‌تر است. زمان معمول آن

۲۸ ثانیه به‌ازای هر جفت فاز است (نیمی از اجراها میان ۲۴ و ۳۱ ثانیه)، در برابر ۸۸ ثانیه برای ANTs-SyN و ۱۶۹ ثانیه برای uniGradICON با بهینه‌سازی تکمیلی. بیشینه‌ی حافظه‌ی آن نیز ۱۳۳۶ مگابایت است، در برابر ۳۲۳۵ مگابایت ANTs-SyN و ۳۸۲۶ مگابایت نسخه‌ی دارای بهینه‌سازی تکمیلی.

اما مسیر صلب ارزان‌ترین روش نیست. uniGradICON با یک گذر پیش‌رو و زمان معمول ۱۱ ثانیه از آن سریع‌تر است؛ همان روشی که دقتش با مسیر صلب تفاوت معناداری ندارد. آن‌چه مسیر صلب در این قیاس دارد در ستون زمان دیده نمی‌شود: uniGradICON این سرعت را با تکیه بر آموزشی پیشین روی مجموعه‌داده‌های متعدد به دست می‌آورد، در حالی که مسیر صلب هیچ وزن آموخته‌شده‌ای ندارد و برای انتقال به مرکز یا پروتکل تازه به بازآموزی نیاز ندارد. در مقابل، چون هیچ اجرایی از پردازنده‌ی گرافیکی استفاده نکرده است، عدد ۱۱ ثانیه نماینده‌ی پیکربندی مورد نظر سازندگان این مدل نیست و روی سخت‌افزار گرافیکی کوتاه‌تر خواهد شد؛ این قید مقایسه را به سود مسیر صلب سوگیر نمی‌کند، بلکه برعکس. ANTs-SyN و DEEDS پیاده‌سازی‌های پردازنده‌محورند و زمان آن‌ها نماینده‌ی پیکربندی متعارفشان است.

گذر اختیاری B‌ـاسپلاین پرهزینه‌ترین ردیف جدول است. زمان معمول خود این گذر ۱۶۱۶ ثانیه به‌ازای هر جفت فاز است (نیمی از اجراها میان ۸۷۷ و ۲۴۳۴ ثانیه)، و با زمان مسیر صلب به ۱۶۴۳ ثانیه می‌رسد؛ یعنی حدود ۵۹ برابر مسیر صلب و ۱۹ برابر ANTs-SyN. پراکندگی این زمان نیز زیاد است، چون بهینه‌ساز تا رسیدن به معیار توقف پیش می‌رود و شمار تکرارها از جفتی به جفت دیگر تغییر می‌کند (در حالت معمول ۶۳٫۵ تکرار، از ۱ تا ۲۹۰). همین هزینه دلیل اصلی آن است که این گذر در مسیر پیشنهادی اختیاری مانده است.

هزینه‌ی DEEDS. زمانی که ابزار پروفایل مشترک برای DEEDS ثبت کرده، بازسازی میدان جابه‌جایی چگال را نیز شامل می‌شود که تنها برای سنجش تاخوردگی لازم است، و حافظه‌ی آن را نمی‌بیند، چون DEEDS به‌صورت برنامه‌های اجرایی جداگانه اجرا می‌شود. زمان هم‌ترازسازی و بیشینه‌ی حافظه‌ی DEEDS و حافظه‌ی گذر B‌ـاسپلاین با رویه‌ی اندازه‌گیری کل درخت فرایندها (بخش ۳-۵) تکمیل می‌شوند.

جمع‌بندی و محدودیت‌ها

آن‌چه شواهد این بخش نشان می‌دهد:

- پیش‌پردازش این پایان‌نامه، پیش از روش‌های هم‌ترازسازی موجود، شکست‌ها و خطاهای بزرگ آن‌ها را به‌طور معنادار کاهش می‌دهد؛ خطاهای بزرگ برای هر چهار روش و شکست‌ها برای سه روش.

این سود در مواردی متمرکز است که روی حجم خام شکست خورده‌اند، و به موارد موفق آسیبی نمی‌زند. بهترین دقت کل مطالعه (DEEDS، دایس ۰/۸۸۶) روی خروجی همین پیش‌پردازش به دست آمد.

- توابع هدفی که به نقاب اندام تکیه دارند از تابع هدف کل‌تصویر بهترند، و این سود در اندام‌های نرم و رگ‌ها دیده می‌شود و نه در مهره‌ها، همان‌گونه که فرضیه پیش‌بینی می‌کرد.
- دو گذر صلب اثرهای مکمل دارند: هم‌ترازی صلب اولیه بر اندام‌های نرم و پالایش صلب بر مهره‌ها.
- دروازه‌ی پذیرش، گذری را که خطا را حدود شش برابر می‌کرد به گذری بی‌اثر تبدیل کرد.
- مسیر صلب با uniGradICON در مجموع تفاوت معناداری ندارد، اما این برابری از دو برتری مخالف تشکیل شده است: مسیر صلب بر آئورت، کلیه‌ی راست و مهره‌های L1 و L2 بهتر است و uniGradICON بر کبد و طحال.
- مسیر صلب بدون پردازنده‌ی گرافیکی و بدون آموزش، در ۲۸ ثانیه برای هر جفت فاز اجرا می‌شود و از روش‌های مبتنی‌بر بهینه‌سازی تکراری ارزان‌تر است.
- گذر اختیاری B‌ـاسپلاین، با تاخوردگی ناچیز، دقت را به‌طور معنادار و عمدتاً در اندام‌های نرم بالا می‌برد و به‌عنوان سنجه نشان می‌دهد ناهم‌ترازی باقی‌مانده‌ی جفت‌های صلب در همین اندام‌هاست.

آن‌چه شواهد نشان نمی‌دهد و نباید ادعا شود:

- هم‌ترازی درشت مرکز جرم دقت را بهتر نمی‌کند و در جایی که فعال می‌شود آسیب می‌زند؛ گذر روی بزرگی گرادیان نیز اثری ندارد.
- دقت مسیر صلب هم‌رده‌ی DEEDS نیست، و برتری کلی آن بر uniGradICON معنادار نیست.
- مسیر صلب ارزان‌ترین روش این مطالعه نیست.
- آزمایش توابع هدف سهم خودِ محدودکردن دامنه را از سهم نوع معیار جدا نمی‌کند.
- پیش‌پردازش دقت معمول ANTs-SyN و uniGradICON با بهینه‌سازی تکمیلی را بالا نمی‌برد و برای ANTs-SyN در مهره‌ها اندکی آن را کاهش می‌دهد.
- گذر B‌ـاسپلاین دقت رگ‌ها را بهتر نمی‌کند (بر آئورت بدتر است) و از ANTs-SyN و uniGradICON با بهینه‌سازی تکمیلی به‌طور معنادار دقیق‌تر نیست.

محدودیت‌ها:

- *اندازه‌ی مجموعه‌ی ارزیابی.* هیچ‌یک از روش‌های این بخش روی داده‌ی این پایان‌نامه آموزش نمی‌بیند، و بنابراین همه تنها روی تقسیم آزمون ارزیابی شده‌اند؛ همان تقسیمی که مدل‌های سنتز بخش ۴-۴ روی آن گزارش می‌شوند. از ۵۳ بررسی تقسیم آزمون، ۳۰ بررسی فاز بدون‌کنتراست دارند و ۲۹ مورد ارزیابی شده‌اند؛ کوچکی این عدد به ترکیب مجموعه‌داده برمی‌گردد. با این حال شمار موارد هر اندام حداکثر ۵۵ است، و به همین دلیل آستانه‌ی معناداری در جدول‌های اندام سخت‌تر شده است.

- *طرح آزمایش توابع هدف.* تابع هدف کل‌تصویر افزون بر دامنه در نوع معیار نیز متفاوت است؛ نسخه‌ی محدود به نقابِ همان معیار اجرا نشده است.

- *گام کنارگذاشته در خروجی‌ها.* خروجی مسیر صلب و ورودی روش‌های موجود از اجرایی گرفته شده‌اند که گام هم‌ترازی درشت مرکز جرم در آن فعال بود. حذف این گام تفاوت معناداری در دقت مسیر صلب ایجاد نمی‌کند، و اثر پیش‌پردازش بر روش‌های موجود با خروجی فقط‌برش نیز تکرار شد.

- *اندازه‌گیری هزینه.* چون هیچ اجرایی روی پردازنده‌ی گرافیکی انجام نشده، زمان روش‌های یادگیری‌محور نماینده‌ی پیکربندی متعارف آن‌ها نیست. زمان و حافظه‌ی DEEDS و حافظه‌ی گذر B-اسپلاین با رویه‌ی جداگانه‌ی بخش ۳-۵ اندازه‌گیری می‌شوند.

- *گذر B-اسپلاین.* این گذر تنها روی خروجی پیش‌پردازش اجرا شده است، و تبیین پیشنهادی برای افت آن در آئورت، یعنی وابستگی لبه‌های رگ‌ها به فاز کنتراست، در این پایان‌نامه آزموده نشده است.

۴-۳ نتایج تشخیص فاز کنتراست

مؤلفه‌ی تشخیص فاز در این پایان‌نامه یک مشارکت مستقل نیست؛ یک *ابزار* است که دو نقش مشخص دارد: دروازه‌بانی داده در بخش ۳-۳، و (مهم‌تر) تأمین ابزار اندازه‌گیری برای معیارهای اصلی ارزیابی سنتز در بخش ۴-۴. این بخش به دو پرسش پاسخ می‌دهد. پرسش نخست از همین نقش برمی‌آید: این خطکش روی بیمارانی که هرگز ندیده، و در مقایسه با روش‌های منتشرشده در شرایط یکسان، تا چه اندازه قابل‌اعتماد است؟ پرسش دوم به آزمایش مدل‌های بنیادین بخش ۴-۳ مربوط است: آیا بازنمایی‌های عمومی تصویر، بدون بخش‌بندی اندام، اطلاعات فاز را به همان اندازه در خود دارند؟ ارزیابی پرسش نخست، مبنای انتخاب مدل در بخش ۴-۳ نیز بوده است.

پیکربندی ارزیابی

همه‌ی روش‌های این بخش روی مجموعه‌ی آزمون بخش ۳-۴ سنجیده می‌شوند: ۶۳ حجم از ۲۱ بررسی، از هر فاز ۲۱ حجم، که هیچ‌یک از مدل‌ها بیماران آن را در آموزش ندیده‌اند. معیارها دقت، میانگین کلان F1 و F1 به‌تفکیک فازند (بخش ۲-۴). فاصله‌ی اطمینان ۹۵ درصد با بازنمونه‌گیری بوت‌استرپ[۴] [۱۳۵] و ۲۰۰۰ تکرار برآورد می‌شود، و واحد بازنمونه‌گیری *بررسی* است و نه حجم: سه فاز یک بیمار از هم مستقل نیستند و بازنمونه‌گیری حجم‌ها، پهنای فاصله را کمتر از واقع نشان می‌دهد. مقایسه‌ی دو روش زوجی و روی همان ۶۳ حجم انجام می‌شود و معناداری آن با آزمون دقیق مک‌نمار[۵] [۱۳۶] سنجیده می‌شود، که تنها حجم‌هایی را به حساب می‌آورد که دو روش درباره‌شان اختلاف دارند.

مقایسه با روش‌های منتشرشده

از چهار روش دارای کد منبع در جدول ۲-۲، سه روش در این مقایسه حضور دارند. طبقه‌بند اندامی همان Segment-and-Classify [۳۶] است که در بخش ۳-۴ برگزیده شد، و از آن دو نسخه گزارش می‌شود: نسخه‌ی بازآموزی‌شده روی مجموعه‌ی آموزش و اعتبارسنجی، که برآوردی بدون نشت از عملکرد ابزار اندازه‌گیری بخش ۴-۴ روی بیمار ناشناخته به دست می‌دهد، و نسخه‌ی آموزش‌دیده روی WAW-TACE بدون هیچ بازآموزی. شبکه‌ی برش‌محور دائو و همکاران [۴۰] با پیکربندی EfficientNet-B0 مخزن کد نویسندگان (پنجره‌ی ۴۰۰ هانسفیلدی با مرکز ۵۰، ۱۵ دوره‌ی آموزش، و رأی‌گیری اکثریت روی ۳۰ درصد برش‌های تصادفی هر حجم) روی مجموعه‌ی آموزش بازآموزی شد و بهترین نقطه‌ی ذخیره با مجموعه‌ی اعتبارسنجی انتخاب شد. تقسیم داده برای این شبکه نیز در سطح بررسی انجام شد و نه در سطح برش، تا برش‌های یک حجم هم‌زمان در آموزش و آزمون حضور نداشته باشند.

مدل منتشرشده‌ی ریس و همکاران [۳۷] بدون بازآموزی اجرا شد. این مدل برای سری DICOM و نقاب‌های نسخه‌ی نخست TotalSegmentator طراحی شده است؛ در این‌جا نقاب‌های نسخه‌ی دوم به شناسه‌های نسخه‌ی نخست نگاشته شدند و به‌جای دهلیز چپ، که در نسخه‌ی دوم برچسب مستقلی ندارد، کل قلب به کار رفت؛ همان جایگزینی که در کد خود نویسندگان پیش‌بینی شده است. حساسیت نتیجه به ترتیب محورهای حجم نیز بررسی شد و پیش‌بینی‌ها در ۶۲ حجم از ۶۳ حجم یکسان ماند. روش یی و همکاران [۳۹] از مقایسه کنار گذاشته شد، چون تنها وجود کنتراست را تشخیص می‌دهد و میان فاز شریانی و وریدی تمایز نمی‌گذارد. جدول ۴-۱۳ نتیجه‌ی این مقایسه را گزارش می‌کند.

---

[۴] Bootstrap

[۵] McNemar's test

جدول ۴-۱۳: مقایسه‌ی طبقه‌بند اندامی با روش‌های منتشرشده روی ۶۳ حجم آزمون. فاصله‌ی اطمینان ۹۵ درصد با قلم کوچک‌تر زیر هر مقدار آمده است. کد فاز همان کد جدول ۲-۲ است: ۰ بدون‌کنتراست، ۱ شریانی و ۲ وریدی. خروجی چهارکلاسه‌ی مدل‌هایی که روی داده‌ی دیگر آموزش دیده‌اند، به سه فاز موجود در مجموعه‌ی آزمون محدود شده است.

روش	بازآموزی روی این داده	دقت	میانگین کلان F1	F1 فاز ۰	F1 فاز ۱	F1 فاز ۲
طبقه‌بند اندامی (Segment-and-Classify، بازآموزی‌شده)	بله	۰/۹۸۴ ۰/۹۵۲–۱/۰۰۰	۰/۹۸۴ ۰/۹۵۲–۱/۰۰۰	۱/۰۰	۰/۹۸	۰/۹۸
Segment-and-Classify، نسخه‌ی آموزش‌دیده روی WAW-TACE	خیر	۰/۹۸۴ ۰/۹۵۲–۱/۰۰۰	۰/۹۸۴ ۰/۹۵۲–۱/۰۰۰	۱/۰۰	۰/۹۸	۰/۹۸
شبکه‌ی برش‌محور با نمونه‌برداری تصادفی [۴۰]	بله	۰/۹۶۸ ۰/۹۲۱–۱/۰۰۰	۰/۹۶۸ ۰/۹۱۸–۱/۰۰۰	۰/۹۸	۰/۹۵	۰/۹۸
مدل تفسیرپذیر ریس و همکاران [۳۷]	خیر	۰/۸۲۵ ۰/۷۶۲–۰/۸۸۹	۰/۸۱۰ ۰/۷۱۸–۰/۸۸۶	۰/۹۸	۰/۶۵	۰/۸۱

طبقه‌بند اندامی تنها یک حجم از ۶۳ حجم را اشتباه تشخیص داد: یک حجم شریانی که وریدی طبقه‌بندی شد. هر سه روش دیگر نیز همین حجم را وریدی تشخیص دادند، و این احتمالاً نشان می‌دهد با موردی مرزی از نظر زمان‌بندی تزریق سروکار داریم. دقت اعتبارسنجی متقاطع همین مدل روی مجموعه‌ی آموزش و اعتبارسنجی ۰/۹۶۰ بود که با رقم آزمون سازگار است. نسخه‌ی آموزش‌دیده روی WAW-TACE بدون هیچ بازآموزی به همان دقت رسید و خطای یگانه‌ی آن نیز همان حجم بود، که در خروجی چهارکلاسه‌ی مدل فاز تأخیری پیش‌بینی شده بود. این یافته با گزارش نویسندگان درباره‌ی انتقال‌پذیری این ویژگی‌ها میان مراکز [۳۶] سازگار است، هرچند در این‌جا تنها یک مرکز مقصد آزموده شده است.

شبکه‌ی برش‌محور دائو و همکاران با دو خطا در رتبه‌ی بعدی قرار گرفت. تفاوت آن با طبقه‌بند اندامی تنها در یک حجم است و آزمون مک‌نمار تفاوتی نشان نمی‌دهد (مقدار p برابر ۱/۰)؛ با این اندازه‌ی مجموعه‌ی آزمون، این دو روش را نمی‌توان رتبه‌بندی کرد و هر دو نزدیک سقف‌اند. هر چهار سطر جدول همه‌ی ۲۱ حجم بدون‌کنتراست را درست تشخیص دادند؛ دشواری مسئله تقریباً به‌تمامی در تفکیک شریانی از وریدی است، که با افت عملکرد مدل‌های مرورشده در فازهای کنتراست‌دار (بخش ۲-۴) هم‌خوان است.

مدل ریس و همکاران در این شرایط به دقت ۰/۸۲۵ رسید، و اگر پیش‌بینی‌های فاز تأخیری آن خطا

شمرده شوند، دقت به ۰/۷۳۰ کاهش می‌یابد (۷ حجم). خطاهای این مدل تقریباً یک‌سویه‌اند: ۱۰ خطا از ۱۱ خطا، حجمی شریانی را وریدی تشخیص داده‌اند، و روی حجم‌های شریانی میانگین احتمال دو فاز شریانی و وریدی تقریباً برابر است (۰/۴۰ و ۰/۴۲). یعنی مدل در این داده سطح تقویت شریانی را به‌طور نظام‌مند کمتر از واقع می‌خواند. این رقم را نباید برآورد منصفانه‌ای از توان خود روش دانست: مدل روی پروتکل تصویربرداری مرکزی دیگر و روی نقاب‌های نسخه‌ی نخست TotalSegmentator آموزش دیده است و در این‌جا با نقاب‌های نگاشته‌شده، جایگزینی دهلیز چپ با کل قلب و حجم‌های برش‌خورده‌ی هم‌ترازشده سنجیده شده است. سهم هر یک از این عوامل در این طرح قابل تفکیک نیست.

ارقام این داده در برابر ارقام گزارش‌شده

عملکرد یک مدل روی داده‌ی این پایان‌نامه با رقمی که مقاله‌ی همان مدل گزارش کرده است یکسان نیست، و همین تفاوت دلیل انتخاب بر پایه‌ی ارزیابی دوباره بود. جدول ۴-۱۴ ارقام گزارش‌شده‌ی سه نامزد را کنار ارقام همان مدل‌ها روی مجموعه‌ی آزمون این پایان‌نامه قرار می‌دهد.

جدول ۴-۱۴: ارقام گزارش‌شده در مقاله‌ها در برابر ارقام همان مدل‌ها روی ۶۳ حجم آزمون این پایان‌نامه. ارقام مقاله‌ها از جدول ۲-۲ آمده‌اند و کد فاز همان کد آن جدول است. مجموعه‌ی آزمون این پایان‌نامه فاز تأخیری ندارد و مدل‌هایی که بدون بازآموزی اجرا شده‌اند با خروجی چهارکلاسه‌ی خود سنجیده شده‌اند، یعنی پیش‌بینی فاز تأخیری خطا شمرده شده است؛ پس دو ستون عددی تنها درون هر سطر و با قید شرایط متفاوت مقایسه‌پذیرند.

معیار	گزارش مقاله	روی داده‌ی این پایان‌نامه
Segment-and-Classify [۳۶] ــ مقاله: VinDr-Multiphase، بیرونی، چهار فاز؛ این پایان‌نامه: مدل WAW-TACE بدون بازآموزی		
F1 فاز ۰	۰/۹۹۴	۱/۰۰
F1 فاز ۱	۰/۹۳۷	۰/۹۸
F1 فاز ۲	۰/۸۹۸	۱/۰۰
F1 فاز ۳	۰/۷۱۸	—
ریس و همکاران [۳۷] ــ مقاله: VinDr-Multiphase، بیرونی؛ این پایان‌نامه: بدون بازآموزی		
دقت	۰/۹۰۱	۰/۷۳۰
میانگین F1	۰/۸۲۶	۰/۷۵۷
دائو و همکاران [۴۰] ــ مقاله: داده‌ی درون‌سازمانی نویسندگان با ۳۵۸ بررسی؛ این پایان‌نامه: بازآموزی‌شده روی این داده		
F1 درون‌سازمانی	۰/۹۲۱	۰/۹۶۸
F1 بیرونی (CPTAC و LiTS)	۰/۷۶۸ و ۰/۸۶۹	—

دو الگو از این جدول بیرون می‌آید. نخست، جهت تفاوت میان روش‌ها یکسان نیست. Segment-and-

Classify بدون هیچ بازآموزی، در فازهای شریانی و وریدی روی این داده F1 بالاتری از رقم گزارش‌شده‌ی خود روی همین مجموعه‌داده دارد، در حالی که مدل ریس و همکاران، که آن نیز در مقاله‌اش روی VinDr-Multiphase ارزیابی شده است، روی این داده به دقت و F1 پایین‌تری از رقم گزارش‌شده رسید. شبکه‌ی برش‌محور پس از بازآموزی روی داده‌ی همین پایان‌نامه از رقم درون‌سازمانی گزارش‌شده‌ی خود بالاتر است، هرچند این مقایسه هم‌ارز نیست، چون دو داده‌ی درون‌سازمانی متفاوت را کنار هم می‌گذارد.

دوم، دلیل این تفاوت‌ها در این طرح قابل تفکیک نیست. مجموعه‌ی آزمون تنها ۲۱ بررسی دارد؛ فاز تأخیری، که در Segment-and-Classify بیشترین افت را داشت، در آن حضور ندارد؛ حجم‌ها برش‌خورده و هم‌ترازشده‌اند؛ و برای مدل ریس و همکاران نقاب‌ها از نسخه‌ی دیگری از TotalSegmentator نگاشته شده‌اند. نتیجه‌ی عملی این جدول برای پایان‌نامه همان نیازمندی دوم بخش ۳-۴ است: رقم گزارش‌شده‌ی یک مدل برآورد قابل‌اتکایی از عملکرد آن روی داده‌ی تازه نیست، و انتخاب باید روی خود داده انجام شود.

آزمایش مدل‌های بنیادین: اطلاعات فاز در بازنمایی‌های عمومی تصویر

جدول ۴-۱۵ نتیجه‌ی شش ترکیب رمزگذار و سر طبقه‌بند را گزارش می‌کند.

جدول ۴-۱۵: کاوش خطی بازنمایی‌های عمومی تصویر برای تشخیص فاز. دقت اعتبارسنجی متقاطع روی مجموعه‌ی آموزش و اعتبارسنجی به‌صورت میانگین و انحراف معیار پنج تا آمده است، و ارقام آزمون روی همان ۶۳ حجم جدول ۴-۱۳ و با همان کد فاز محاسبه شده‌اند. برای سر لایه‌ی خطی، پیش‌بینی‌های حجم‌به‌حجم ذخیره نشده و فاصله‌ی اطمینان در دسترس نیست.

رمزگذار	سر طبقه‌بند	دقت اعتبارسنجی متقاطع	دقت آزمون	میانگین کلان F1 آزمون	F1 فاز ۰	F1 فاز ۱	F1 فاز ۲
DINOv2	LDA	۰/۸۱۵±۰/۰۴۷	۰/۸۴۱ ۰/۷۷۸–۰/۹۲۱	۰/۸۴۱ ۰/۷۶۹–۰/۹۲۰	۱/۰۰	۰/۷۵	۰/۷۷
DINOv2	PCA و LDA	۰/۷۶۱±۰/۰۴۰	۰/۷۴۶ ۰/۶۶۷–۰/۸۲۵	۰/۷۴۷ ۰/۶۵۷–۰/۸۲۷	۰/۹۸	۰/۶۷	۰/۶۰
DINOv2	لایه‌ی خطی	۰/۷۵۵±۰/۰۳۵	۰/۷۶۲	۰/۷۶۱	۱/۰۰	۰/۶۷	۰/۶۲
MedViT	LDA	۰/۷۱۵±۰/۰۵۲	۰/۷۴۶ ۰/۶۸۳–۰/۸۱۰	۰/۷۲۸ ۰/۶۴۰–۰/۸۰۲	۰/۹۸	۰/۷۱	۰/۵۰
MedViT	PCA و LDA	۰/۶۷۴±۰/۰۳۱	۰/۶۸۳ ۰/۶۱۹–۰/۷۴۶	۰/۶۷۲ ۰/۵۹۷–۰/۷۴۴	۰/۹۸	۰/۶۳	۰/۴۱
MedViT	لایه‌ی خطی	۰/۶۶۶±۰/۰۳۰	۰/۵۸۷	۰/۵۴۳	۰/۸۴	۰/۵۲	۰/۲۷

بهترین ترکیب، DINOv2 با تحلیل تشخیصی خطی، به دقت آزمون ۰٫۸۴۱ رسید، و دقت اعتبارسنجی متقاطع آن (۰٫۸۱۵) نشان می‌دهد این رقم حاصل یک تقسیم خوش‌اقبال نیست. در هر دو رمزگذار، کاهش ابعاد با تحلیل مؤلفه‌های اصلی دقت را پایین آورد و لایه‌ی خطی نیز از تحلیل تشخیصی خطی بهتر عمل نکرد؛ یعنی بخشی از اطلاعات فاز در مؤلفه‌هایی نشسته است که بیشترین واریانس را ندارند، و افزودن پارامتر آموزش‌پذیر به سر طبقه‌بند آن را بازیابی نمی‌کند.

الگوی خطا در همه‌ی ترکیب‌ها مشابه است. در پنج ترکیب از شش ترکیب، F1 فاز بدون‌کنتراست دست‌کم ۰٫۹۸ است، در حالی که F1 فاز شریانی یا وریدی در هیچ ترکیبی از ۰٫۷۷ فراتر نمی‌رود. ده خطای بهترین ترکیب در ده بررسی متفاوت پخش شده‌اند (شش حجم شریانی که وریدی و چهار حجم وریدی که شریانی تشخیص داده شدند) و هیچ‌یک از آن‌ها را طبقه‌بند اندامی یا شبکه‌ی برش‌محور اشتباه نکرده است. MedViT با تحلیل تشخیصی خطی، علاوه بر دقت پایین‌تر، سوگیری آشکاری دارد: ۱۲ خطا از ۱۶ خطای آن، حجم وریدی را شریانی تشخیص داده‌اند.

در مقایسه‌ی زوجی، دقت بهترین ترکیب ۱۴٫۳ واحد درصد کمتر از طبقه‌بند اندامی است (فاصله‌ی اطمینان ۲۲٫۲—۴٫۸)؛ از ۱۱ حجمی که دو روش درباره‌شان اختلاف دارند، طبقه‌بند اندامی ۱۰ حجم را درست تشخیص داده است (مقدار p آزمون مک‌نمار برابر ۰٫۰۱۲). فاصله با شبکه‌ی برش‌محور دائو و همکاران ۱۲٫۷ واحد درصد است (۲۰٫۶—۳٫۲؛ مقدار p برابر ۰٫۰۳۹). با تصحیح بونفرونی برای سه مقایسه با روش‌های منتشرشده، تنها تفاوت با طبقه‌بند اندامی معنادار می‌ماند. در مقابل، این ترکیب با مدل ریس و همکاران تفاوت معناداری ندارد (۱٫۶ واحد درصد به سود DINOv2؛ مقدار p برابر ۱٫۰)، و برتری DINOv2 بر MedViT با همان سر طبقه‌بند (۹٫۵ واحد درصد) نیز در این اندازه‌ی نمونه معنادار نیست (مقدار p برابر ۰٫۲۴).

یک تبیین محتمل برای این الگو آن است که ورود ماده‌ی حاجب تغییری سراسری و پرتباین در تصویر ایجاد می‌کند (روشن‌شدن عروق بزرگ، کلیه‌ها و پارانشیم) که حتی رمزگذاری آموزش‌دیده روی تصاویر طبیعی آن را در بازنمایی خود بازتاب می‌دهد. در مقابل، تفکیک شریانی از وریدی به مقایسه‌ی سطح HU میان چند ساختار کوچک مشخص وابسته است، مانند آئورت در برابر ورید باب؛ همان کمیتی که طبقه‌بند اندامی مستقیماً اندازه می‌گیرد. در پیکربندی این آزمایش چند عامل این اطلاعات ظریف را رقیق می‌کند: پنجره‌ی شدت دوهزارهانسفیلدی، بازه‌ی چندصدهانسفیلدی بافت نرم و عروق را که تفاوت فازها در آن رخ می‌دهد به بخش کوچکی از بازه‌ی شدت فشرده می‌کند؛ بازنمونه‌برداری به ۱۲۸ وکسل در هر محور ساختارهای عروقی کوچک را محو می‌کند؛ و ادغام میانگین روی برش‌ها و روی پهنه‌ی هر برش، سیگنال چند ساختار کوچک را با بقیه‌ی حجم میانگین می‌گیرد. این آزمایش سهم این عوامل را از هم جدا نمی‌کند، و از آن نمی‌توان نتیجه گرفت که بازنمایی‌های عمومی در هر *پیکربندی* برای این مسئله ناکافی‌اند.

نتیجه‌ی عملی این آزمایش برای پایان‌نامه اما روشن است. در شرایط این مطالعه، حذف وابستگی به بخش‌بندی هزینه‌ای معنادار در دقت دارد، در حالی که نقاب‌های اندام به‌هرحال برای هم‌ترازسازی تصویر و وزن‌دهی زیان سنتز تولید می‌شوند. از این رو طبقه‌بند اندامی به‌عنوان ابزار اندازه‌گیری حفظ شد و بازنمایی‌های عمومی تنها به‌عنوان یک یافته‌ی اکتشافی گزارش می‌شوند.

نقش این مدل در ارزیابی سنتز

ارزش اصلی این مؤلفه در جای دیگری است. همان بردار ۱۶ بعدی و همان طبقه‌بند، دو معیار اصلی جدول ۴-۱۷ را می‌سازند:

- **featHU** از فاصله‌ی همین بردار میان تصویر سنتزشده و تصویر واقعی به دست می‌آید و مستقیم‌ترین سنجه‌ی بازسازی سطح تقویت است.
- **phase و prob** خروجی همین طبقه‌بند روی تصویر سنتزشده‌اند و می‌پرسند آیا تصویر تولیدشده اساساً به فاز درخواست‌شده *تعلق دارد*.

به این ترتیب، مدلی که برای آماده‌سازی داده برگزیده شد، مسئله‌ی سنجش را نیز حل می‌کند. اعتبار این کاربرد به دقت مطلق طبقه‌بند وابسته نیست بلکه به *ثبات* آن وابسته است: چون یک خط‌کش واحد روی خروجی همه‌ی مدل‌های مقایسه‌شده اعمال می‌شود، هر سوگیری سیستماتیک آن میان مدل‌ها مشترک است و رتبه‌بندی را جابه‌جا نمی‌کند.

یک قید باید کنار این استدلال گذاشته شود. نسخه‌ای از طبقه‌بند که در ارزیابی سنتز به کار می‌رود، روی هر ۴۱۰ حجم آموزش دیده است؛ یعنی روی تصاویر واقعی همه‌ی ۱۳۷ بررسی، از جمله بیماران تقسیم آزمون سنتز. دقت خارج‌ازتای[۶] همین دستورالعمل روی این ۴۱۰ حجم ۰/۹۷۱ است و با دقت ۰/۹۸۴ نسخه‌ی بازآموزی‌شده روی بیماران ناشناخته هم‌خوان است؛ پس خط‌کش به داده‌ی تازه تعمیم می‌یابد. با این حال، معیارهای phase و prob روی تصویر سنتزی بیمارانی سنجیده می‌شوند که تصویر واقعی‌شان در آموزش طبقه‌بند حضور داشته است، و مقدار مطلق آن‌ها ممکن است اندکی خوش‌بینانه باشد. انتظار می‌رود این اثر عمدتاً میان همه‌ی مدل‌های سنتز مشترک باشد، هرچند نمی‌توان کاملاً رد کرد که به سود مدل‌هایی تمام شود که خروجی‌شان به تصویر واقعی همان بیمار نزدیک‌تر است. معیار featHU از این قید مصون است، چون تنها از استخراج ویژگی استفاده می‌کند و طبقه‌بند در آن نقشی ندارد. بازآموزی طبقه‌بند بدون بیماران تقسیم آزمون سنتز و امتیازدهی دوباره، این قید را برطرف می‌کند.

[۶] Out-of-fold

محدودیت‌ها

چهار محدودیت دامنه‌ی اعتبار ارقام این بخش را تعیین می‌کند.

نخست، اندازه‌ی مجموعه‌ی آزمون. ۶۳ حجم از ۲۱ بررسی، فاصله‌ی اطمینانی به پهنای تا حدود ۱۵ واحد درصد می‌دهد، و دو روش برتر جدول ۴-۱۳ در این اندازه‌ی نمونه قابل رتبه‌بندی نیستند.

دوم، ارزیابی درون‌سازمانی است و تنها سه فاز را پوشش می‌دهد. همه‌ی حجم‌ها از VinDr-Multiphase می‌آیند و فاز تأخیری در این تقسیم حضور ندارد. بخش ۴-۲ نشان داد افت برون‌سازمانی در این مسئله قاعده است و نه استثنا، و افت عملکرد مدل‌های مرورشده بیش از همه در فاز تأخیری رخ می‌دهد؛ پس ارقام بالا را نباید به داده‌ی مرکز دیگر یا به مسئله‌ی چهارکلاسه تعمیم داد.

سوم، مدل‌هایی که بدون بازآموزی اجرا شدند، روی حجم‌های برش‌خورده و هم‌ترازشده و با نقاب‌هایی سنجیده شدند که با ورودی اصلی آن‌ها متفاوت است. این شرایط برای مدل ریس و همکاران آشکارا نامساعدتر است و رقم آن باید با همین قید خوانده شود. شبکه‌ی برش‌محور نیز تنها با یک بذر تصادفی بازآموزی شده است.

چهارم، طبقه‌بند اندامی به یک بخش‌بندی اندام ازپیش‌آموزش‌دیده وابسته است، همان پیش‌نیازی که بخش ۴-۲ ضعف مشترک رویکرد نخست دانست. آزمایش مدل‌های بنیادین این بخش نشان داد حذف این وابستگی، دست‌کم در پیکربندی آزموده‌شده، با افت معنادار دقت همراه است؛ و پایان‌نامه این وابستگی را می‌پذیرد، چون نقاب‌های اندام به‌هرحال برای هم‌ترازسازی تصویر و وزن‌دهی زیان سنتز تولید می‌شوند. خود آن آزمایش نیز تنها یک پیکربندی را آزموده است: یک پنجره‌ی شدت، یک تفکیک‌پذیری و یک راهبرد ادغام برش‌ها.

۴-۴ نتایج سنتز فاز کنتراست‌دار

این بخش نتایج شبکه‌ی PLC-Net (بخش ۳-۶) را گزارش می‌کند. پرسش راهنما آن است که آیا تصویر سنتزشده برای یک وظیفه‌ی پایین‌دستی سودمند است، و نه تنها این‌که تا چه اندازه به تصویر واقعی شبیه است. پس از معرفی مدل‌ها و قراردادهای ارزیابی، ابتدا کیفیت تصویری، سپس اثر پایین‌دستی بر بخش‌بندی و مقایسه با روش‌های منتشرشده، و پس از آن کنترل فاز و سطح گزارش می‌شود. اعتبار معیارهای تصویری در پایان، در نسبت با همان اثر پایین‌دستی، سنجیده می‌شود.

مدل‌ها و نام‌گذاری

جدول ۴-۱۶ نام هر مدل در این بخش را به پیکربندی‌های بخش ۳-۶ و به شناسه‌ی اجرای آن پیوند می‌دهد. وزن‌های هر اجرا با شماره‌ی دوره‌ی آموزشی مشخص می‌شوند. PLC-Net دوبعدی وزن‌های دوره‌ی ۴۵ اجرای پیکربندی E است و PLC-Net ۲٫۵ بعدی وزن‌های دوره‌ی ۲۳ اجرای پیکربندی F؛ هر دو بر پایه‌ی معیارهای مجموعه‌ی اعتبارسنجی و بازبینی بصری خروجی‌های همان مجموعه انتخاب شده‌اند. در برخی تحلیل‌ها وزن‌های دوره‌های دیگرِ همان دو اجرا نیز گزارش می‌شوند و دوره‌ی آن‌ها در هر مورد ذکر می‌شود.

جدول ۴-۱۶: مدل‌های گزارش‌شده در این بخش. ستون «پایین‌دستی» نشان می‌دهد که آیا مدل در ارزیابی بخش‌بندی نیز اجرا شده است.

نام	توضیح	پایین‌دستی	شناسه‌ی اجرا (دوره)
PLC-Net دوبعدی	پیکربندی E؛ مدل پیشنهادی	✓	mp_lvl_adv (45)
PLC-Net ۲٫۵ بعدی	پیکربندی F؛ ورودی ۱۱ برشی	✓	mp_lvl_adv_slc11 (23)
پیکربندی‌های A تا F	زنجیره‌ی طراحی بخش ۳-۶؛ E و F هر یک در دو دوره	✓	دوره‌های ۱۵ و ۴۵ (E)؛ دوره‌های ۲۳ و ۵۳ (F)
L1ـ اندام	ابلیشن داخلی تک‌فاز: L1 وزن‌دار اندامی با نرمال‌سازی گروهی، بدون جمله‌ی تخاصمی و بدون شرط	✓	l1_organ_groupnorm
L1 ناهم‌واریانس	ابلیشن داخلی تک‌فاز با سر ناهم‌واریانس (بخش ۳-۶)	✓	diff_hetero_nll
pix2pixHD، CycleGAN، CyTran ،ResViT	روش‌های منتشرشده، بازآموزی‌شده روی همان داده و همان تقسیم	✓	—
SwinUNETR، TransUNet، dEa-GAN ،gEa-GAN	روش‌های منتشرشده؛ تنها در ارزیابی تصویری	×	—
DDPM	مدل انتشار با پارامترسازی x.	✓	diff_x0

قراردادهای ارزیابی

آزمون‌ها. همه‌ی مقایسه‌های پایین‌دستی روی ۲۰ مورد آزمون و به‌صورت زوجی انجام می‌شوند (آزمون t زوجی روی میانگین هر مورد)، زیرا پراکندگی میان بیماران از تفاوت میان مدل‌ها بزرگ‌تر است. مقادیر p جدول مقایسه با روش‌های منتشرشده با روش هولم تصحیح شده‌اند و سایر مقادیر p توصیفی‌اند. تنها

یک نقطه‌ی پایانی تأییدی از پیش تعیین شده بود: دایس ترکیب اندام‌های وابسته به کنتراست (پانکراس، کیسه‌ی صفرا، آئورت، ورید اجوف تحتانی، و ورید باب و طحالی) برای PLC-Net دوبعدی. سایر نقاط پایانی، از جمله ورید باب، اکتشافی‌اند.

معیار پایین‌دستی. معیار، دایس ساده است. فرسایش ۶ میلی‌متری فصل هم‌ترازسازی، ساختارهایی را که قطرشان کمتر از حدود ۱۲ میلی‌متر است تقریباً به‌طور کامل حذف می‌کند و برای عروق، که موضوع اصلی این ارزیابی‌اند، مناسب نیست. نتایج دایس فرسوده به‌عنوان تحلیل حساسیت در پیوست آ–۱ آمده است؛ تحت آن معیار، اثر سنتز بر گروه عروقی دیده نمی‌شود.

مرجع. مرجع، خروجی TotalSegmentator روی تصویر کنتراست‌دار واقعی است و نه حاشیه‌نویسی انسانی؛ بنابراین یک حجم سنتزی می‌تواند صرفاً با شبیه‌شدن به تصویر کنتراست‌دار از دید همین ابزار امتیاز بگیرد. گروه اسکلتی، که با کنتراست تغییر نمی‌کند، شاهد منفی است و بازوی NCCT، یعنی بخش‌بندی مستقیم تصویر بدون‌کنتراست، کف مقایسه. این محدودیت بر همه‌ی ارقام پایین‌دستی این بخش اعمال می‌شود.

گروه‌های اندامی. گروه عروقی شامل آئورت، شریان‌ها و وریدهای ایلیاک چپ و راست، ورید اجوف تحتانی، و ورید باب و طحالی است؛ گروه اسکلتی شامل استخوان‌های لگن، ساکروم و مهره‌های T10 تا L5.

بذر تصادفی. PLC-Net و مدل‌های مبنا هر یک با یک بذر تصادفی آموزش دیده‌اند. پراکندگی میان بذرها تنها برای ابلیشن L1ـاندام در دسترس است (سه بذر؛ featHU میان ۱۲/۹ و ۱۳/۹).

جدول ۴–۱۷ معیارهای تصویری را تعریف می‌کند. تمایز معیار اصلی از ثانویه در زیربخش اعتبار معیارها با داده آزموده می‌شود.

جدول ۴-۱۷: معیارهای تصویری ارزیابی سنتز. معیارهای شدت روی دامنه‌ی مشترک $[-۲۰۰, ۴۰۰]$ واحد هانسفیلد نگاشته‌شده به $[۰, ۱]$ محاسبه می‌شوند.

معیار	جهت	تعریف	آن‌چه می‌سنجد
featHU	↓ اصلی	میانگین قدرمطلق خطای میانه‌ی عدد هانسفیلد هر اندام	مقدار HU بافت، که فاز کنتراست را تعریف می‌کند؛ در معیارهای پیکسلی این خطا در حجم بزرگ هوا و چربی رقیق می‌شود.
دقت فاز	↑ اصلی	نسبت مواردی که طبقه‌بند مستقل فاز (بخش ۴-۳) خروجی را به فاز درخواست‌شده نسبت می‌دهد	این‌که خروجی به فاز درخواست‌شده تعلق دارد؛ مدلی با PSNR بالا ممکن است فاز نادرست تولید کند.
شیب کالیبراسیون	۱ ← اصلی	شیب HU تولیدشده بر حسب سطح درخواست‌شده‌ی z، بهنجارشده با سقف درون‌فازی	پاسخ مدل به درخواست سطح؛ مرجع آن خودِ درخواست است و نه تصویر بیمار.
β_{lev}، varR	۱ ←	شیب رگرسیون میانه‌ی HU تولیدشده بر میانه‌ی واقعی در میان موارد، و نسبت واریانس (بخش ۳-۷)	ردیابی سطح تقویت هر بیمار.
oMAE	↓	خطای مطلق میانگین، تنها درون نواحی اندام	همان MAE بدون میانگین‌گیری روی پس‌زمینه‌ی مشترک همه‌ی مدل‌ها.
RAPS	۱ ←	نسبت انرژی طیفی بسامد بالای تصویر تولیدشده به تصویر واقعی	تاری (کمتر از یک) یا نویز و بافت توهمی (بیشتر از یک).
SSIM / PSNR	↑ ثانویه	معیارهای متعارف سطح تصویر	پنجره‌ی HU هوا، ریه، چربی و استخوان را برای همه‌ی مدل‌ها یکسان اشباع می‌کند.
FID / LPIPS	↓ ثانویه	فاصله‌ی ادراکی و فاصله‌ی فرشه با پشتوانه‌ی ImageNet	مقایسه‌پذیری با ادبیات؛ اعتبار آن‌ها برای سی‌تی خاکستری تأیید نشده است.
FID (Rad)	↓ ثانویه	فاصله‌ی فرشه با پشتوانه‌ی RadImageNet	همان پرسش با پشتوانه‌ای درون‌دامنه.

کیفیت تصویری

جدول ۴-۱۸ معیارهای تصویری همه‌ی مدل‌ها را روی همان ۲۰ مورد آزمون و در فاز وریدی گزارش می‌کند.

جدول ۴–۱۸: کیفیت تصویری در فاز وریدی. بهترین مقدار هر ستون پررنگ است (برای RAPS، نزدیک‌ترین به یک). oMAE در دامنه‌ی بهنجارشده‌ی $[۰, ۱]$ است.

مدل	↓featHU	↓oMAE	↑PSNR	↑SSIM	↓LPIPS	↓FID	↓FID (Rad)	RAPS	دقت فاز↑
PLC-Net دوبعدی	14.55	0.0332	29.64	0.937	0.040	9.6	0.048	**0.982**	1.00
PLC-Net ۲/۵ بعدی	22.01	0.0381	28.95	0.933	0.049	16.7	0.089	0.904	0.75
L1ـاندام	**12.90**	**0.0286**	30.66	**0.949**	0.047	28.3	0.114	0.842	1.00
L1 ناهم‌واریانس	14.46	0.0298	**30.82**	**0.949**	0.048	22.4	0.146	0.800	1.00
pix2pixHD	17.07	0.0319	30.01	0.941	**0.038**	**7.6**	**0.045**	0.895	0.95
CycleGAN	18.66	0.0335	29.88	0.938	0.052	11.1	0.084	0.738	1.00
ResViT	15.17	0.0349	29.18	0.929	0.057	12.9	0.091	0.723	1.00
CyTran	38.12	0.0451	28.87	0.930	0.052	10.4	0.088	0.744	0.35
SwinUNETR	16.72	0.0348	29.34	0.930	0.055	10.8	0.097	0.712	0.95
TransUNet	17.15	0.0368	29.00	0.927	0.059	12.4	0.093	0.713	0.95
gEa-GAN	23.51	0.0372	29.14	0.928	0.059	13.3	0.139	0.690	0.95
dEa-GAN	25.18	0.0365	29.32	0.934	0.066	22.3	0.172	0.629	0.90
DDPM	24.76	0.0392	28.74	0.934	0.055	18.3	0.079	0.848	1.00

PLC-Net دوبعدی در featHU (۱۴/۵۵ واحد هانسفیلد) از همه‌ی روش‌های منتشرشده بهتر است (بهترینِ آن‌ها ResViT با ۱۵/۱۷)، اما از دو ابلیشن داخلی تک‌فاز که جمله‌ی تخاصمی ندارند (L1ـاندام با ۱۲/۹۰ و L1 ناهم‌واریانس با ۱۴/۴۶) عقب‌تر است. نسبت طیفی آن (۰/۹۸۲) نزدیک‌ترین مقدار به یک در کل جدول است و FID آن (۹/۶) پس از pix2pixHD (۷/۶) دومین مقدار است.

معیارهای پیکسلی در بازه‌ای باریک قرار دارند (PSNR میان ۲۸/۷ و ۳۰/۸ و SSIM میان ۰/۹۲۷ و ۰/۹۴۹) و بالاترین مقادیرشان به دو مدل تک‌فاز L1 تعلق دارد؛ همین دو مدل در FID در میان بدترین‌ها هستند (۲۸/۳ و ۲۲/۴). این دو خانواده از معیارها مدل‌ها را تقریباً در ترتیب مخالف رتبه‌بندی می‌کنند، و زیربخش اعتبار معیارها نشان می‌دهد کدام‌یک با سودمندی پایین‌دستی هم‌راستاست. طبقه‌بند فاز نیز شکست‌هایی را آشکار می‌کند که معیارهای ادراکی نمی‌بینند: CyTran با FID برابر ۱۰/۴ تنها در ۳۵ درصد موارد به فاز وریدی نسبت داده می‌شود.

ردیابی سطح تقویت بیمار به بیمار برای PLC-Net دوبعدی نزدیک صفر است ($\beta_{\text{lev}} =$ ۰/۰۸، varR $=$ ۰/۱۰). این با طراحی مدل سازگار است: در استنتاج گزارش‌شده، سطح مخصوص بیمار به مدل داده نمی‌شود و سطح خروجی باید از ورودی z تعیین شود. بیشتر مدل‌های تک‌فاز مقادیر بالاتری دارند (برای نمونه L1ـاندام ۰/۲۵، ResViT ۰/۳۱ و CycleGAN ۰/۳۷)، که همچنان از یک فاصله‌ی زیادی دارد.

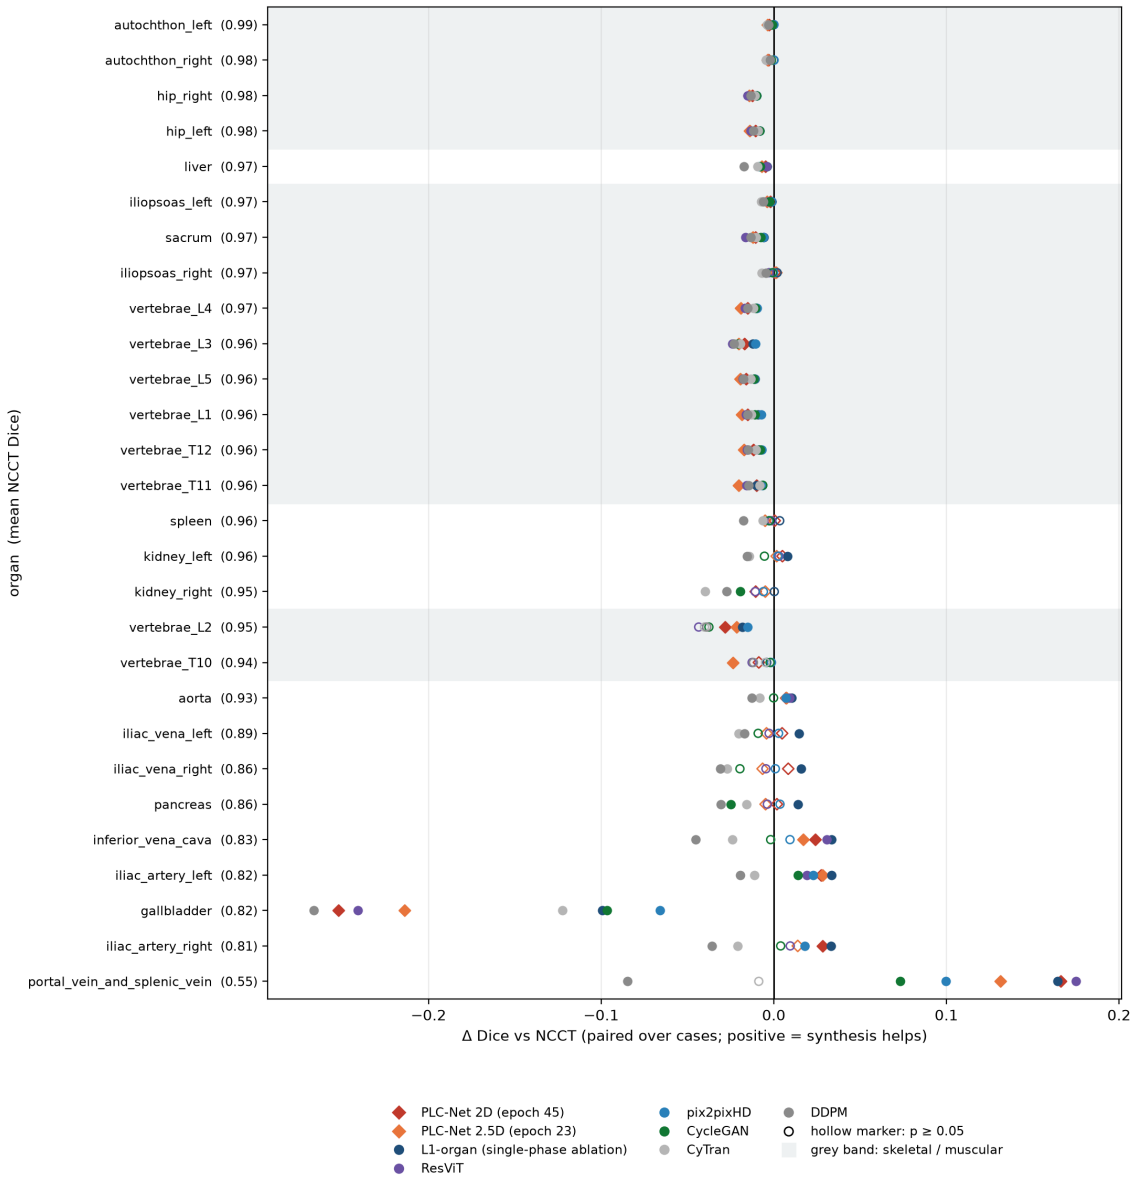
شکاف پایین‌دستی و اثر سنتز

بخش‌بندی مستقیم تصویر بدون‌کنتراست در برابر مرجع، در گروه اسکلتی دایس ۰٫۹۶۲، در گروه عروقی ۰٫۸۱۱، در ترکیب وابسته به کنتراست ۰٫۷۹۸ و در ورید باب و طحالی تنها ۰٫۵۵۴ به دست می‌دهد؛ یعنی شکاف میان دو فاز در عروق، و به‌ویژه در ورید باب، متمرکز است. جدول ۴–۱۹ اثر هر بازوی سنتزی را به‌صورت تفاوت زوجی دایس نسبت به همین کف گزارش می‌کند.

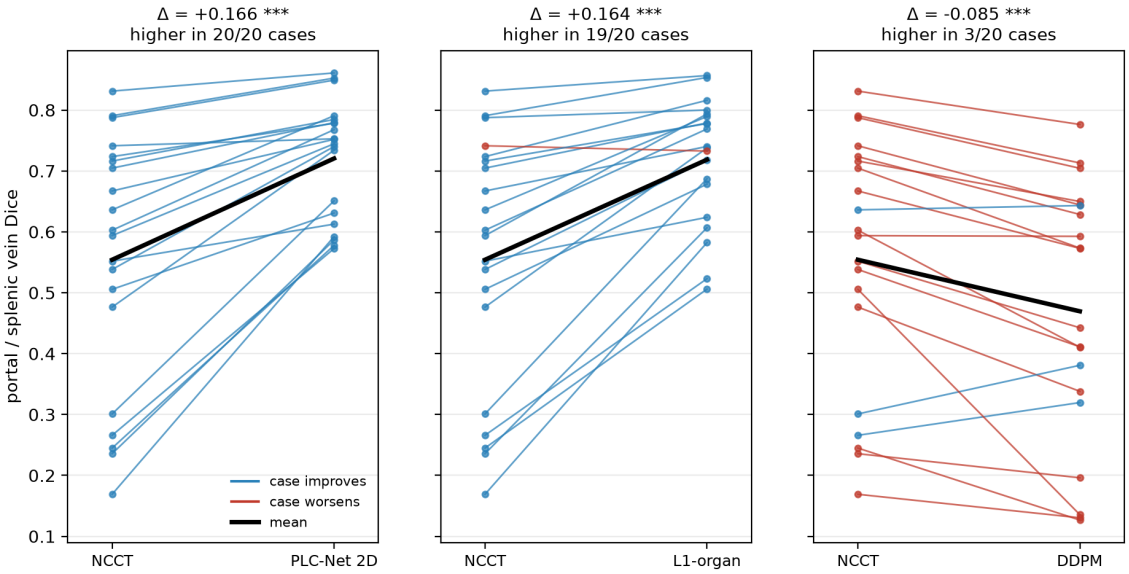
جدول ۴–۱۹: اثر سنتز بر بخش‌بندی پایین‌دستی: میانگین تفاوت زوجی دایس نسبت به بازوی NCCT روی ۲۰ مورد. سطر نخست دایس مطلق خودِ بازوی NCCT است. اثر خالص برابر است با تفاوت گروه عروقی منهای تفاوت گروه اسکلتی. ستون آخر شمار مواردی است که دایس ورید باب در آن‌ها از بازوی NCCT بالاتر است.

بازو	ورید باب	گروه عروقی	گروه اسکلتی	اثر خالص	ورید باب: بالاتر
NCCT (دایس مطلق)	0.554	0.811	0.962	—	—
PLC-Net دوبعدی	**+0.1663**	+0.0381	-0.0142	+0.0523	20/20
ResViT	+0.1749	+0.0345	-0.0188	+0.0533	20/20
L1 ـ اندام	+0.1643	+0.0438	-0.0097	+0.0535	19/20
PLC-Net ۲٫۵ بعدی	+0.1312	+0.0270	-0.0183	+0.0453	19/20
pix2pixHD	+0.0997	+0.0231	-0.0084	+0.0315	19/20
CycleGAN	+0.0733	+0.0089	-0.0121	+0.0210	15/20
CyTran	-0.0087	-0.0171	-0.0137	-0.0034	7/20
DDPM	-0.0847	-0.0358	-0.0172	-0.0185	3/20

اثر متمرکز است. بزرگ‌ترین اثر روی ورید باب و طحالی است: 0.166+ برای PLC-Net دوبعدی، با دایس بالاتر در هر ۲۰ مورد. اثر روی سایر عروق کوچک‌تر است (ورید اجوف تحتانی 0.024+، شریان‌های ایلیاک حدود 0.03+ و آئورت 0.007+)، روی کبد، طحال و کلیه‌ها قدرمطلق تفاوت از 0.011 فراتر نمی‌رود، و روی استخوان‌ها منفی است. شکل ۴–۴ این توزیع را اندام به اندام و شکل ۴–۵ اثر ورید باب را بیمار به بیمار نشان می‌دهد. این الگو با فیزیک مسئله سازگار است: کبد، طحال و کلیه‌ها در تصویر بدون‌کنتراست نیز مرز قابل‌تشخیص دارند، اما ورید باب بدون ماده‌ی حاجب از پارانشیم اطراف به‌سختی جدا می‌شود. کیسه‌ی صفرا از این الگو پیروی نمی‌کند و در زیربخشی جداگانه بررسی می‌شود.



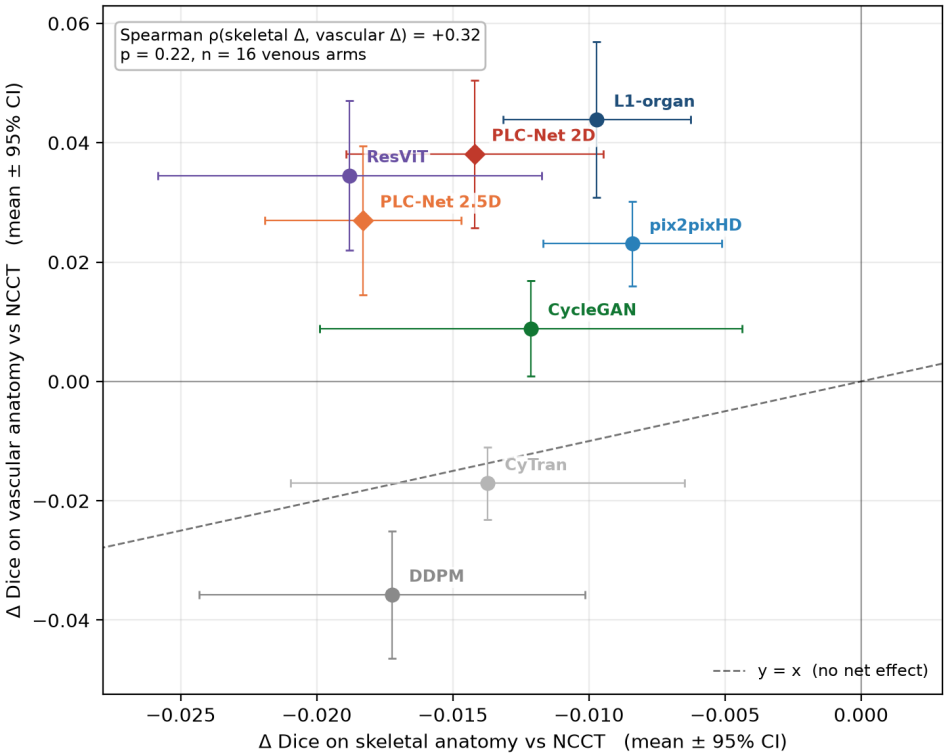
شکل ۴-۴: تغییر دایس هر اندام نسبت به بازوی NCCT، به‌صورت زوجی روی مواردی که اندام در هر دو بازو وجود دارد. عدد داخل پرانتز دایس میانگین NCCT است؛ لوزی‌ها دو نسخه‌ی PLC-Netاند، نشانگر توخالی یعنی $p \geqslant ۰/۰۵$، و نوار خاکستری اندام‌های اسکلتی و عضلانی را مشخص می‌کند.



شکل ۴–۵: دایس وریدِ باب و طحالی برای هر بیمار، روی تصویر بدون‌کنتراست (چپ هر نمودار) و روی خروجی مدل (راست)؛ خط سیاه میانگین است. PLC-Net دوبعدی در ۲۰ مورد، L1ـاندام در ۱۹ مورد و DDPM تنها در ۳ مورد از ۲۰ مورد دایس بالاتری از NCCT دارند.

هزینه‌ی تولید. همه‌ی بازوهای سنتزی روی آناتومی اسکلتی دایس از دست می‌دهند: میان 0.008- و 0.019-، در همه‌ی بازوها معنادار ($p < ۰/۰۰۵$)، و تنها در صفر یا یک مورد از ۲۰ مورد بالاتر از NCCT. چون استخوان با ماده‌ی حاجب تغییر نمی‌کند، این افت را می‌توان به خودِ فرایند تولید (تاری، تغییر بافت و آرتیفکت) نسبت داد.

اثر خالص. اثر خالص هر بازو، تفاوت دایس گروه عروقی منهای تفاوت دایس گروه اسکلتی همان بازو است. چون تفاوت اسکلتی منفی است، اثر خالص از سود خام عروقی بزرگ‌تر است؛ این کمیت سود عروقی را نسبت به افت عمومی همان بازو می‌سنجد و فرض می‌کند هزینه‌ی تولید بر عروق و استخوان به اندازه‌ی مشابه اثر می‌گذارد، فرضی که مستقیماً آزموده نشده است. در میان ۱۶ بازوی وریدی، افت اسکلتی و سود عروقی هم‌بستگی معناداری ندارند (اسپیرمن $\rho = +۰/۳۲$، $p = ۰/۲۲$) و افت اسکلتی تنها در بازه‌ای ۲/۳ برابری تغییر می‌کند؛ با این تعداد بازو، این آزمون تنها وابستگی قوی را رد می‌کند (شکل ۴–۶).



شکل ۴-۶: تغییر دایس گروه اسکلتی (افقی) در برابر تغییر دایس گروه عروقی (عمودی) نسبت به NCCT، با فاصله‌ی اطمینان ۹۵ درصد، برای بازوهای جدول ۴-۱۹. روی خط‌چین $y = x$ سود عروقی با افت اسکلتی برابر است و فاصله‌ی عمودی هر نقطه از آن، اثر خالص است. هم‌بستگی اسپیرمن روی هر ۱۶ بازوی وریدی محاسبه شده است.

دو بازوی ناموفق. CyTran و DDPM بخش‌بندی عروقی را بدتر می‌کنند. همین دو بازو در سنجه‌های دیگر نیز ضعیف‌اند: CyTran دقت فاز ۰/۳۵ و featHU برابر ۳۸/۱ دارد، و featHU مدل DDPM برابر ۲۴/۸ است.

نقطه‌ی پایانی از پیش تعیین‌شده. روی ترکیب اندام‌های وابسته به کنتراست، تفاوت PLC-Net دوبعدی با NCCT برابر $+0.0011$ است ($p = ۰/۹۴$)، بالاتر در ۹ مورد از ۲۰)؛ کمینه‌ی اثر قابل‌تشخیص برای این نقطه‌ی پایانی در توان ۸۰ درصد حدود 0.043 است. بنابراین فرضیه‌ی تأییدی از داده پشتیبانی نمی‌شود. بخش عمده‌ی این نتیجه به کیسه‌ی صفرا بازمی‌گردد که اثر مثبت ورید باب را در ترکیب خنثی می‌کند. یافته‌های ورید باب در این بخش، اکتشافی‌اند.

مقایسه با روش‌های منتشرشده

جدول ۴-۲۰ PLC-Net دوبعدی را به‌صورت زوجی با چهار روش منتشرشده و با مدل انتشار DDPM مقایسه می‌کند.

جدول ۴-۲۰: مقایسه‌ی زوجی PLC-Net دوبعدی با سایر مدل‌ها روی داده و تقسیم یکسان؛ مقادیر مثبت یعنی دایس PLC-Net بالاتر است. مقادیر p با روش هولم روی ۳۰ آزمون تصحیح شده‌اند (پنج مقایسه در شش نقطه‌ی پایانی: گروه عروقی، ورید باب، ترکیب وابسته به کنتراست، و گروه‌های پارانشیمی، اسکلتی و عضلانی).

در برابر	Δ عروقی	p هولم	Δ ورید باب	p هولم	نتیجه
ResViT	+0.0036	1.00	-0.0086	1.00	هم‌ارز در حاشیه‌ی ±۰/۰۲
pix2pixHD	+0.0150	0.013	+0.0666	0.013	PLC-Net بالاتر
CycleGAN	+0.0292	0.0004	+0.0930	0.0003	PLC-Net بالاتر
CyTran	+0.0552	0.0001<	+0.1750	0.0001<	PLC-Net بالاتر
DDPM	+0.0739	0.0001<	+0.2510	0.0001<	PLC-Net بالاتر

ResViT. تفاوت با ResViT معنادار نیست (p خام برابر 0.38). با ۲۰ مورد، کمینه‌ی تفاوت قابل‌تشخیص برای این مقایسه‌ی زوجی در گروه عروقی و در توان ۸۰ درصد حدود 0.012 دایس است. آزمون هم‌ارزی دوطرفه (TOST) هم‌ارزی را در حاشیه‌ی ±۰/۰۲ دایس تأیید می‌کند ($p = ۰/۰۰۰۳$) اما در حاشیه‌ی ±۰/۰۱ نه ($p = ۰/۰۶۰$). نتیجه‌ی دقیق این است که دو مدل در حاشیه‌ی 0.02 دایس هم‌ارزند و تفاوتی در حد 0.01 را نمی‌توان رد کرد. تمایز PLC-Net با ResViT در دقت پایین‌دستی نیست، بلکه در کنترل فاز است: ResViT، مانند سایر مدل‌های این جدول، تک‌فاز است و برای هر فاز باید جداگانه آموزش ببیند، در حالی که PLC-Net هر دو فاز را با یک مدل تولید می‌کند.

ابلیشن L1ـاندام. این ابلیشن داخلی تک‌فاز، که نه شرط دارد و نه جمله‌ی تخاصمی، روی گروه عروقی اندکی بالاتر از PLC-Net دوبعدی است (+0.0057، $p = ۰/۰۱۰$، بالاتر در ۱۶ مورد از ۲۰) و روی ترکیب وابسته به کنتراست نیز (+0.024، $p = ۰/۰۳۱$، بالاتر در ۱۸ مورد)؛ روی ورید باب تفاوتی ندارند (-0.002، $p = ۰/۷۸$). بنابراین بخش عمده‌ی سود پایین‌دستی را می‌توان به زیان L1 وزن‌دار اندامی نسبت داد و نه به اجزای شرطی. آن ابلیشن اما قادر به تولید فاز شریانی نیست؛ سهم PLC-Net کنترل فاز و سطح با سودمندی پایین‌دستی هم‌تراز با بهترین مدل‌های تک‌فاز است، و نه سودمندی بیشتر.

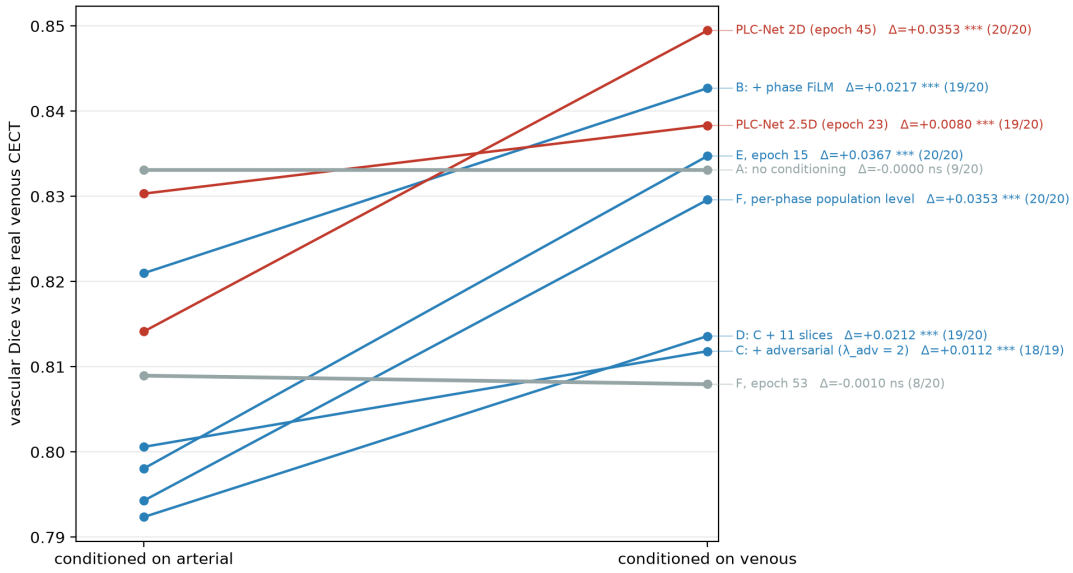
کنترل فاز

هر مدل شرطی دو بار استنتاج شد، یک‌بار با شرط وریدی و یک‌بار با شرط شریانی، و هر دو خروجی در برابر همان مرجع وریدی سنجیده شدند. اگر شرط‌گذاری کار کند، خروجی با شرط وریدی باید دایس عروقی بالاتری بگیرد.

هفت اجرا از هشت اجرای شرطی با شرط وریدی دایس عروقی به‌طور معنادار بالاتری دارند: تفاوت میان $+0.008$ و $+0.037$، همگی با $p < ۰/۰۰۰۱$، و بالاتر در ۱۸ تا ۲۰ مورد (یکی از اجراها ۱۹ مورد زوجی دارد). برای PLC-Net دوبعدی تفاوت $+0.0353$ است ($p < ۰/۰۰۰۱$، بالاتر در هر ۲۰ مورد). شکل ۴–۷ این پاسخ‌ها را نشان می‌دهد.

مدل بدون شرط (پیکربندی A) ورودی فاز ندارد؛ بنابراین تفاوت دو استنتاج آن تنها نوفه‌ی زنجیره‌ی ارزیابی را نشان می‌دهد، که عملاً صفر است (-0.0000، $p = ۰/۸۶$، بالاتر در ۹ مورد). پاسخ مدل‌های شرطی به‌روشنی بالاتر از این کف است.

تنها اجرای شرطی بدون پاسخ، پیکربندی F در دوره‌ی ۵۳ است (-0.0010، $p = ۰/۵۷$، بالاتر در ۸ مورد). طبقه‌بند مستقل فاز نیز به همین اجرا دقت ۰/۲۵ می‌دهد؛ دو سنجه‌ی مستقل برای این اجرا هم‌جهت‌اند. همان پیکربندی F، وقتی با بردار سطحِ میانگین جمعیتی مخصوص هر فاز استنتاج می‌شود، پاسخ فاز عادی دارد ($+0.0353$، بالاتر در هر ۲۰ مورد، دقت فاز ۱/۰۰)، و وزن‌های دوره‌ی ۲۳ نیز با همان نوع استنتاج به دقت فاز ۱/۰۰ و featHU برابر ۱۶/۸ می‌رسند، در برابر ۰/۷۵ و ۲۲/۰ در جدول ۴–۱۸. بنابراین از دست رفتن پاسخ فاز در پیکربندی F به بردار سطحی که هنگام استنتاج داده می‌شود وابسته است؛ زیربخش سازوکار به این نکته بازمی‌گردد. [یادداشت: حالت سطحِ استنتاج اجراهای گزارش‌شده برای PLC-Net (دوره‌های ۴۵ و ۲۳) و دوره‌ی وزن‌های اجرای «سطح جمعیتی مخصوص فاز» باید با بررسی روی سرور تأیید شود.]



شکل ۴-۷: دایس عروقی هر مدل شرطی، یک‌بار با شرط شریانی و یک‌بار با شرط وریدی، هر دو در برابر همان مرجع وریدی. خط‌های خاکستری تفاوت معناداری ندارند: مدل بدون شرط (پیکربندی A، نوفه‌ی زنجیره‌ی ارزیابی) و پیکربندی F در دوره‌ی ۵۳.

کنترل سطح

دلیل وجود شرط سطح، یعنی پیش‌بینی‌ناپذیری سطح تقویت هر بیمار از روی تصویر بدون‌کنتراست، در بخش ۳-۶ آمده است. برای سنجش کنترل سطح، مقدار z در هفت مقدار از -1.5 تا $+1.5$ انحراف معیار درخواست و میانه‌ی HU هر اندام در خروجی اندازه‌گیری شد. شیب‌های خام میانه (تغییر HU در هر واحد z تقسیم بر انحراف معیار تجمیعی) چنین‌اند: پیکربندی E در دوره‌ی ۱۵، 0.29 با شرط وریدی و 0.09 با شرط شریانی؛ پیکربندی F در دوره‌های ۲۳ و ۵۳، میان 0.67 و 0.84.

خواندن این شیب‌ها به‌صورت خام گمراه‌کننده است. استانداردسازی سطح، هر اندام را روی هر دو فاز با هم استاندارد می‌کند: برای آئورت، انحراف معیار تجمیعی ۱۰۵/۳ واحد هانسفیلد است، در حالی که انحراف معیار درون فاز وریدی در داده‌ی آموزش ۲۱/۴ و درون فاز شریانی ۱۰۴/۶ است. مدلی که با شرط وریدی درون توزیع وریدی بماند، برای آئورت حداکثر شیب معنادار ۰/۲۰ ≈ ۲۱/۴/۱۰۵/۳ دارد و شیب 1.0 به معنای پیمودن دامنه‌ی فاز شریانی است. جدول ۴-۲۱ شیب هر اندام را بر سقف درون‌فازیِ همان اندام و همان فاز تقسیم می‌کند؛ در این مقیاس، 1.0 یعنی دستگیره دقیقاً پهنای طبیعی فاز خودش را می‌پیماید.

جدول ۴-۲۱: شیب کالیبراسیون بهنجارشده نسبت به سقف درون‌فازی (میانه روی هشت اندام بردار سطح). مقدار بیش از یک یعنی پاسخ مدل از دامنه‌ی طبیعی فاز درخواست‌شده فراتر رفته است. جاروب پیکربندی E روی وزن‌های دوره‌ی ۱۵ همان اجرای PLC-Net دوبعدی انجام شده است.

پیکربندی (دوره)	وریدی، میانه	وریدی، آئورت	شریانی، میانه	تفسیر
E دوبعدی (15)	0.63	0.88	0.10	وریدی تا حدی کنترل‌پذیر؛ شریانی کنترل‌ناپذیر
F ۲٫۵ بعدی (23)؛ PLC-Net ۲٫۵ بعدی	1.04	**3.66**	0.84	آئورت فراتر از دامنه‌ی وریدی
F ۲٫۵ بعدی (53)	1.25	**4.96**	0.87	آئورت فراتر از دامنه‌ی وریدی

میانه‌ی نزدیک به یکِ پیکربندی F (1.04) پراکندگی میان اندام‌ها را پنهان می‌کند: پاسخ آئورت با شرط وریدی ۳٫۷ برابر (دوره‌ی ۲۳) و ۵٫۰ برابر (دوره‌ی ۵۳) پهنای طبیعی فاز وریدی است. در دوره‌ی ۵۳، جاروب z آئورتِ خروجی با شرط وریدی را از ۷۹ به ۳۸۰ واحد هانسفیلد می‌برد، یعنی از مقادیر وریدی به مقادیر شریانی، در حالی که شرط فاز همچنان وریدی است. در این پیکربندی، z الگوی بین‌اندامیِ تعریف‌کننده‌ی فاز را تغییر می‌دهد و نه سطح تقویت درون یک فاز.

سه اندازه‌گیری دیگر همین ترتیب را نشان می‌دهند. **امضای فاز**، یعنی اختلاف HU آئورت و ورید باب در $z = ۰$، برای پیکربندی E با شرط شریانی ۱۹۵ و با شرط وریدی ۲۶ واحد است (فاصله‌ی ۱۶۹ واحد میان دو فاز، سازگار با فیزیولوژی)؛ برای F در دوره‌ی ۲۳ این دو مقدار ۱۰۹ و ۷۹ (فاصله‌ی ۳۰) و در دوره‌ی ۵۳، ۱۱۵ و ۹۸ (فاصله‌ی ۱۷) است. **دقت طبقه‌بند فاز** برای PLC-Net دوبعدی، F در دوره‌ی ۲۳ و F در دوره‌ی ۵۳ به‌ترتیب ۱٫۰۰، ۰٫۷۵ و ۰٫۲۵ است، و **پاسخ فاز پایین‌دستی** $+0.0353$، $+0.0080$ و -0.0010. وزن‌های دوره‌ی ۱۵ پیکربندی E نیز دقت فاز ۱٫۰۰ و پاسخ $+0.0367$ دارند.

پیکربندی دوبعدی E تنها پیکربندی‌ای است که هر دو سیگنال را هم‌زمان حفظ می‌کند: پاسخ فاز کامل، و دستگیره‌ی سطحی که ۶۳ درصد دامنه‌ی درون‌فازی وریدی را می‌پیماید (۸۸ درصد برای آئورت). در میان پیکربندی‌های شرطی، بیشترین اثر خالص پایین‌دستی نیز به همین پیکربندی تعلق دارد. دستگیره‌ی سطح *شریانی* در این پیکربندی کار نمی‌کند: شیب بهنجارشده در همه‌ی اندام‌ها حدود ۰٫۱۰ است و برازش خطی در برخی اندام‌ها ضعیف است ($r^۲$ از ۰٫۰۴ تا ۰٫۹۵).

سازوکار: درهم‌تنیدگی دو سیگنال شرط

بردار شرط سطح خود تا حد زیادی فاز را مشخص می‌کند. با طبقه‌بندی فاز *تنها* از روی بردارهای استانداردشده‌ی هشت‌اندامی سطح در داده‌ی آموزش، تحلیل تفکیکی خطی با اعتبارسنجی یکی‌ـ‌بیرون به دقت ۰٫۹۴۲ می‌رسد ($n = 155$ بردار، مواردی که هر هشت اندام را دارند). این اطلاعات در الگوی میان اندام‌هاست و نه در یک جابه‌جایی سراسری: آئورت و قلب در فاز شریانی بالاترند (دقت تک‌اندام ۰٫۸۸ و ۰٫۸۷) و کبد، ورید اجوف تحتانی و ورید باب در فاز وریدی (۰٫۹۱، ۰٫۸۱ و ۰٫۷۴).

بنابراین شبکه دو ورودی دریافت می‌کند که یکی دیگری را با دقت حدود ۹۴ درصد پیش‌بینی می‌کند، و هیچ جمله‌ای در تابع هدف استفاده از هر دو را الزامی نمی‌کند. در عمل دو نسخه به دو سوی مخالف رفته‌اند: مدل دوبعدی به شناسه‌ی فاز پاسخ قوی و به سطح پاسخ محدود می‌دهد، و مدل ۲٫۵ بعدی به سطح پاسخی فراتر از دامنه‌ی طبیعی و به شناسه‌ی فاز پاسخ ضعیف. مشاهده‌ی زیربخش کنترل فاز با این تصویر سازگار است: وقتی بردار سطحِ مخصوص فاز درخواستی به مدل ۲٫۵ بعدی داده می‌شود، فاز درست تولید می‌شود، یعنی اطلاعات فاز عمدتاً از مسیر بردار سطح به این مدل می‌رسد. خودِ این جدایی رفتار اندازه‌گیری شده است؛ این‌که استانداردسازی تجمیعی بردار سطح در زمان آموزش علت آن باشد، تفسیری است که با بازآموزی آزموده نشده است.

حالت استنتاج population_phase (بخش ۳-۶) پیش‌فرض ارزیابی را اصلاح می‌کند، اما درهم‌تنیدگی ایجادشده در زمان آموزش را از میان نمی‌برد. رفع آن نیازمند استانداردسازی درون‌فازی بردار شرط و بازآموزی، یا یک طرح صریح حذف تصادفی شرط در آموزش است و به کار آتی واگذار می‌شود.

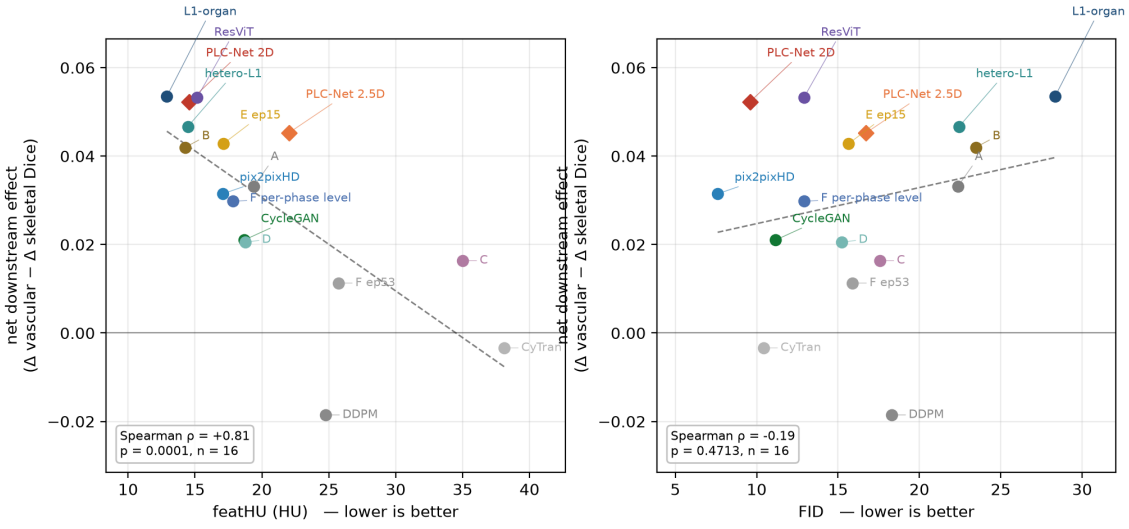
اعتبار معیارهای تصویری

در میان ۱۶ بازوی وریدی، هم‌بستگی اسپیرمن هر معیار تصویری با اثر خالص پایین‌دستی محاسبه شد. معیارها چنان جهت داده شده‌اند که مقدار بزرگ‌تر همواره تصویر بهتر را نشان دهد (برای RAPS، قدرمطلق فاصله از یک با علامت منفی). برای سنجش مقاومت، همین هم‌بستگی پس از کنار گذاشتن سه بازویی که در پایین‌دست یا در کنترل فاز شکست خورده‌اند (DDPM، CyTran و پیکربندی F در دوره‌ی ۵۳) تکرار شد.

جدول ۴-۲۲: هم‌بستگی اسپیرمن معیارهای تصویری با اثر خالص پایین‌دستی. ستون دوم پس از کنار گذاشتن سه بازوی ناموفق است.

معیار	ρ ($n = ۱۶$)	ρ ($n = ۱۳$)	نتیجه
featHU	**+0.81** ($p = ۰/۰۰۰۱$)	**+0.68** ($p = ۰/۰۱۰$)	مقاوم
oMAE	+0.64 ($p = ۰/۰۰۸$)	+0.36 ($p = ۰/۲۳$)	تنها با حضور بازوهای ناموفق
PSNR	+0.58 ($p = ۰/۰۱۹$)	+0.25 ($p = ۰/۴۰$)	تنها با حضور بازوهای ناموفق
SSIM اندامی	+0.56 ($p = ۰/۰۲۴$)	+0.18 ($p = ۰/۵۵$)	تنها با حضور بازوهای ناموفق
LPIPS	+0.44 ($p = ۰/۰۸۷$)	+0.18 ($p = ۰/۵۷$)	معنادار نیست
FID (Rad)	-0.06 ($p = ۰/۸۳$)	-0.12 ($p = ۰/۷۱$)	بدون رابطه
RAPS	+0.04 ($p = ۰/۸۹$)	-0.05 ($p = ۰/۸۷$)	بدون رابطه
FID	-0.19 ($p = ۰/۴۷$)	-0.26 ($p = ۰/۳۹$)	بدون رابطه

تنها featHU پس از کنار گذاشتن بازوهای ناموفق معنادار می‌ماند. oMAE، PSNR و SSIM تنها زمانی با سودمندی هم‌بسته به نظر می‌رسند که مدل‌های ناموفق در نمونه حاضر باشند، LPIPS حتی در آن حالت معنادار نیست، و FID، FID (Rad) و RAPS رابطه‌ای نشان نمی‌دهند (شکل ۴-۸). برای نمونه، pix2pixHD بهترین FID مطالعه (۷/۶) را دارد اما اثر خالص آن (+0.032) در میانه‌ی جدول است، و L1_اندام با بدترین FID این گروه (۲۸/۳) بیشترین اثر خالص (+0.054) را دارد. این نتایج هم‌بستگی روی ۱۶ مدلِ یک مطالعه‌اند و رابطه‌ی علّی را نشان نمی‌دهند.



شکل ۴-۸: featHU (چپ) و FID (راست) در برابر اثر خالص پایین‌دستی برای ۱۶ بازوی وریدی. محورهای افقی مقادیر خام‌اند (کمتر بهتر)، اما ρ روی معیار جهت‌دهی‌شده (بیشتر بهتر) محاسبه شده است؛ از این رو ρ مثبت در نمودار چپ به‌صورت روند نزولی دیده می‌شود.

این یافته با تمایزی که در بخش ۳-۷ مطرح شد سازگار است: معیارهای واقع‌نمایی توزیعی می‌سنجند

که آیا تصویر تولیدشده شبیه تصاویر واقعی است، در حالی که featHU می‌سنجد که آیا عدد هانسفیلد بافت درست است. برای وظیفه‌ای که به مرز میان بافت‌ها تکیه دارد، پرسش دوم مرتبط‌تر است.

مطالعه‌ی ابلیشن

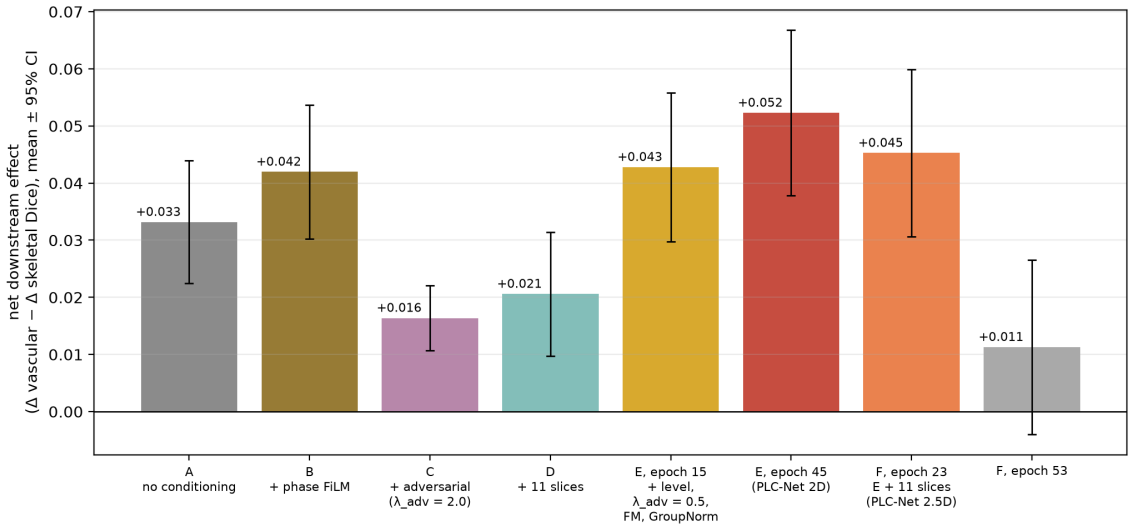
جدول ۴-۲۳ و شکل ۴-۹ پیکربندی‌های زنجیره‌ی طراحی بخش ۳-۶ را مقایسه می‌کنند.

جدول ۴-۲۳: پیکربندی‌های A تا F در فاز وریدی. اثر خالص با فاصله‌ی اطمینان ۹۵ درصد گزارش شده است.

پیکربندی	↓featHU	دقت فاز	↓FID	اثر خالص
A: چندفازی بدون شرط	19.39	0.70	22.4	$0.011 \pm +0.033$
B: A + شرط فاز (FiLM)	14.26	1.00	23.5	$0.012 \pm +0.042$
C: B + جمله‌ی تخاصمی ($\lambda_{\text{adv}} =$ ۲/۰)	35.01	0.85	17.6	$0.006 \pm +0.016$
D: C + ورودی ۱۱ برشی	18.75	1.00	15.2	$0.011 \pm +0.021$
E (دوره‌ی 15)	17.12	1.00	15.6	$0.013 \pm +0.043$
E (دوره‌ی 45)؛ PLC-Net دوبعدی	**14.55**	1.00	**9.6**	$\mathbf{0.015 \pm +0.052}$
F (دوره‌ی 23)؛ PLC-Net ۲/۵ بعدی	22.01	0.75	16.7	$0.015 \pm +0.045$
F (دوره‌ی 53)	25.72	0.25	15.9	$0.015 \pm +0.011$

افزودن شرط فاز (A به B) دقت فاز را از ۰/۷۰ به ۱/۰۰ می‌رساند، featHU را از ۱۹/۴ به ۱۴/۳ کاهش می‌دهد و اثر خالص را از $0.033+$ به $0.042+$ افزایش می‌دهد (مقایسه‌ی زوجی، $p = ۰/۰۰۹$). افزودن جمله‌ی تخاصمی با ضریب متعارف $\lambda_{\text{adv}} = ۲/۰$ (C) اثر خالص را ۶۱ درصد کاهش می‌دهد (به $0.016+$) و featHU را به ۳۵/۰ می‌رساند؛ این همان مشاهده‌ای است که انتخاب $\lambda_{\text{adv}} = ۰/۵$ در بخش ۳-۶ بر آن تکیه دارد. ورودی ۱۱ برشی (D) بخشی از این افت را جبران می‌کند.

پیکربندی E نسبت به پیکربندی‌های پیشین چند تغییر را هم‌زمان اعمال می‌کند: بردار سطح، ضریب تخاصمی 0.5، تطبیق ویژگی و نرمال‌سازی گروهی. بنابراین افزایش اثر خالص در این گام را نمی‌توان تنها به شرط سطح نسبت داد. وزن‌های دوره‌ی ۴۵ این پیکربندی (PLC-Net دوبعدی) بیشترین اثر خالص، کمترین featHU و کمترین FID را در این زنجیره دارند. پیکربندی F، که همان E با ورودی ۱۱ برشی است، در دوره‌ی ۲۳ اثر خالص $0.045+$ اما دقت فاز ۰/۷۵ دارد، و در دوره‌ی ۵۳ اثر خالص آن به $0.011+$ با فاصله‌ی اطمینانی که صفر را در بر می‌گیرد کاهش می‌یابد. همه‌ی این پیکربندی‌ها با یک بذر آموزش دیده‌اند و تفاوت‌های کوچک میان گام‌های مجاور باید با احتیاط خوانده شوند.



شکل ۴-۹: اثر خالص پایین‌دستی (میانگین و فاصله‌ی اطمینان ۹۵ درصد) برای پیکربندی‌های A تا F. پیکربندی‌های E و F هر یک در دو دوره‌ی آموزشی از یک اجرا گزارش شده‌اند.

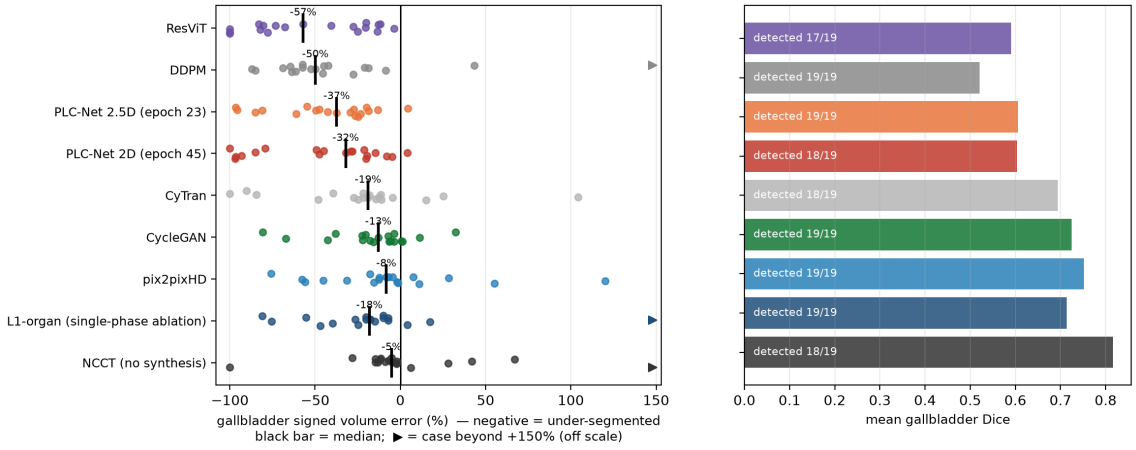
کنترل کیفیت داده

ادعاهای سطح اندام در این بخش بر این فرض تکیه دارند که خطای هانسفیلد اندازه‌گیری‌شده خطای مدل است و نه باقی‌مانده‌ی ناهم‌ترازی جفت‌های تصویر. هم‌بستگی featHU هر مورد با شاخص‌های کیفیت هم‌ترازسازی در ۲۰ مورد آزمون چنین است: هم‌بستگی متقابل استخوان $r = -۰/۰۹$، خطای مطلق استخوان $r = +۰/۲۵$ و دایس گاز روده $r = +۰/۱۱$؛ هیچ‌یک معنادار نیست. با ۲۰ مورد تنها هم‌بستگی‌هایی بزرگ‌تر از حدود 0.44 در سطح 0.05 قابل تشخیص‌اند؛ بنابراین این آزمون وابستگی قوی خطای هانسفیلد به ناهم‌ترازی را رد می‌کند، اما اثرهای کوچک‌تر را نه.

شکست شناخته‌شده: کیسه‌ی صفرا

کیسه‌ی صفرا تنها اندامی است که همه‌ی بازوهای سنتزی در آن دایس به‌روشنی کمتری از بازوی NCCT دارند (برای PLC-Net دوبعدی حدود 0.25-). این اندام در ۱۹ مورد ارزیابی می‌شود، زیرا در یک مورد آزمون در مرجع وجود ندارد. این یک شکست تشخیص نیست: اندام در ۱۷ تا ۱۹ مورد از ۱۹ مورد یافت می‌شود. شکست، کم‌برآوردی نظام‌مند حجم است؛ میانه‌ی خطای علامت‌دار حجم برای NCCT ٪-5، pix2pixHD ٪-8، CycleGAN ٪-13، L1 ـ اندام ٪-18، CyTran ٪-19، PLC-Net دوبعدی ٪-32، PLC-Net ۲/۵ بعدی ٪-37، DDPM ٪-50 و ResViT ٪-57 است (شکل ۴-۱۰).

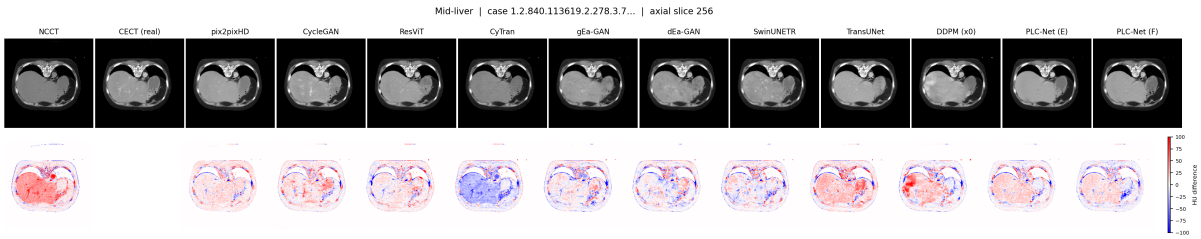
سازوکار این شکست اثبات نشده است. جمله‌ی تخاصمی به‌تنهایی آن را توضیح نمی‌دهد، زیرا pix2pixHD و CycleGAN نیز جمله‌ی تخاصمی دارند و کمترین خطای حجم را نشان می‌دهند. برای PLC-Net یک فرضیه آن است که کیسه‌ی صفرا یکی از هشت اندام بردار سطح است و مدل ممکن است حفره‌ی آن را روشن کند، در حالی که در تصویر وریدی واقعی صفرای کم‌جذب باقی می‌ماند و مرز از دست می‌رود؛ این فرضیه اما خطای بزرگ ResViT و DDPM را توضیح نمی‌دهد. آزمون مستقیم آن، مقایسه‌ی HU درون کیسه‌ی صفرا در تصویر سنتزی و واقعی، انجام نشده است. همین اندام است که ترکیب وابسته به کنتراست را برای PLC-Net دوبعدی، با وجود اثر 0.166+ روی ورید باب، به حدود صفر می‌رساند، و مشخص‌ترین جهت کار آتی است.



شکل ۴-۱۰: کیسه‌ی صفرا. چپ: خطای علامت‌دار حجم برای هر مورد (میله‌ی سیاه: میانه؛ مقدار منفی یعنی حجم کمتر از مرجع؛ پیکان: موردی خارج از مقیاس بالای 150+٪). راست: دایس میانگین و تعداد مواردی که اندام یافت شده است.

مقایسه‌ی بصری

شکل ۴-۱۱ یک برش محوری از یک مورد آزمون را برای همه‌ی مدل‌ها نشان می‌دهد. ردیف پایین نقشه‌ی تفاوت است: در ستون NCCT تفاوت تصویر کنتراست‌دار واقعی با تصویر بدون‌کنتراست، یعنی تقویتی که مدل باید تولید کند، و در ستون هر مدل تفاوت خروجی آن با تصویر کنتراست‌دار واقعی. در این نقشه‌ها رنگ آبی گسترده روی کبد و عروق نشانه‌ی کم‌تقویتی است، مانند خروجی CyTran که با دقت فاز ۰٫۳۵ آن سازگار است، و لکه‌های قرمز موضعی نشانه‌ی تقویت بیش از حد یا آرتیفکت، مانند خروجی DDPM. این شکل یک برش از یک مورد است و جنبه‌ی توضیحی دارد؛ نتایج کمّی جدول‌های پیشین مبنای مقایسه‌اند. [یادداشت: این شکل باید با اسکریپت به‌روزشده بازتولید شود (برش ورید باب و کیسه‌ی صفرا، مدل‌های جدول‌های این بخش، وزن‌های دوره‌های ۴۵ و ۲۳)؛ پس از بازتولید، توصیف این پاراگراف بازبینی شود.]



شکل ۴-۱۱: مقایسه‌ی بصری در یک برش محوری از یک مورد آزمون. ردیف تصویر با پنجره‌ی $W = 400$، $L = 40$؛ ردیف تفاوت پس از محدودسازی هر دو تصویر به بازه‌ی $[-۲۰۰, ۴۰۰]$ واحد هانسفیلد، با مقیاس ± ۱۰۰ واحد: در ستون NCCT تفاوت تصویر کنتراست‌دار واقعی منهای تصویر بدون‌کنتراست، و در ستون هر مدل خروجی مدل منهای تصویر کنتراست‌دار واقعی؛ قرمز یعنی روشن‌تر و آبی یعنی تیره‌تر.

محدودیت‌ها و آن‌چه ادعا نمی‌شود

- PLC-Net بهترین مدل به‌طور کلی نیست: با ResViT در حاشیه‌ی 0.02 دایس هم‌ارز است و روی گروه عروقی و ترکیب وابسته به کنتراست اندکی از ابلیشن تک‌فاز L1ـ اندام عقب‌تر است.
- فرضیه‌ی تأییدی از پیش تعیین‌شده (ترکیب وابسته به کنتراست) پشتیبانی نمی‌شود و یافته‌های ورید باب اکتشافی‌اند.
- اثر عروقی به انتخاب معیار حساس است و تحت دایس فرسوده دیده نمی‌شود (پیوست آ ـ ۱).
- مرجع بخش‌بندی خودکار است، نه حاشیه‌نویسی انسانی؛ همه‌ی مدل‌ها با یک بذر آموزش دیده‌اند و ارزیابی روی ۲۰ مورد آزمون انجام شده است.
- نسخه‌های دوبعدی و ۲/۵ بعدی میان وفاداری و کنترل‌پذیری معاوضه نمی‌کنند: نسخه‌ی دوبعدی در FID، featHU، کنترل فاز و اثر خالص بهتر است، و پاسخ سطح بزرگ‌تر نسخه‌ی ۲/۵ بعدی فراتر رفتن از دامنه‌ی فاز است، نه کنترل بهتر.
- ارقام خروجی‌های با شرط شریانی امتیاز کیفیت مدل نیستند، زیرا در برابر مرجع وریدی سنجیده شده‌اند؛ تنها تفاوت وریدی و شریانی درون یک مدل معنا دارد.

فصل ۵

نتیجه‌گیری

Bibliography

[1] M. Antonelli, A. Reinke, S. Bakas, et al. The medical segmentation decathlon. *Nature Communications*, 13, 2022.

[2] L. Abel, J. Wasserthal, M. Meyer, J. Vosshenrich, S. Yang, R. Donners, et al. Intra-individual reproducibility of automated abdominal organ segmentation—performance of TotalSegmentator compared to human readers and an independent nnU-Net model. *Journal of Imaging Informatics in Medicine*, 2025.

[3] S. Park, E. K. Fishman, and A. L. Yuille. Multi-phase deformable registration for time-dependent abdominal organ variations. arXiv:2103.05525, 2021. https://arxiv.org/abs/2103.05525.

[4] S. Danaei, Z. Dehghanian, E. Meftah, N. Naderi, S. Safavi-Naini, F. Khorasanizade, and H. Rabiee. State of abdominal ct datasets: A critical review of bias, clinical relevance, and real-world applicability. *PLOS Digital Health*, 5(8):e0001567, 2026.

[5] L. European Association for the Study of the. Easl clinical practice guidelines: Management of hepatocellular carcinoma. J. Hepatol., 69(1):182–236, 2018. 10.1016/j.jhep.2018.03.019.

[6] A. Forner, M. Reig, and J. Bruix. Hepatocellular carcinoma. Lancet, 391(10127):1301–1314, 2018. 10.1016/S0140-6736(18)30010-2.

[7] S. Jeon, I. Joo, J. Park, J.-M. Kim, S. Park, and S. Yoon. Fully-automated multi-organ segmentation tool applicable to both non-contrast and post-contrast abdominal CT: deep learning algorithm developed using dual-energy CT images. *Scientific Reports*, 14:4378, 2024.

[8] Z. et al. Ncct-to-cect synthesis with contrast-enhanced knowledge and anatomical perception for multi-organ segmentation in non-contrast ct images, 2024. https://doi.org/10.1016/j.media.2024.103397.

[9] B. Dao, T. Nguyen, H. Pham, and H. Nguyen. Phase recognition in contrast-enhanced ct scans based on deep learning and random sampling (vindr-multiphase dataset). Medical Physics, 49(5):3102–3116, 2022. 10.1002/mp.15551.

[10] F. Isensee, P. Jaeger, S. Kohl, J. Petersen, and K. Maier-Hein. nnu-net: a self-configuring method for deep learning-based biomedical image segmentation. *Nature Methods*, 18(2):203–211, 2021.

[11] J. Wasserthal, H.-C. Breit, and M. Meyer. Totalsegmentator: Robust segmentation of 104 anatomic structures in ct images. Radiology: Artif. Intell., 5(5):e230024, 2023. 10.1148/ryai.230024.

[12] J. Ma, Y. Zhang, S. Gu, C. Zhu, C. Ge, Y. Zhang, et al. Abdomenct-1k: Is abdominal organ segmentation a solved problem? *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 44(10):6695–6714, 2021.

[13] J. Ma, Y. Zhang, S. Gu, C. Ge, E. Wang, Q. Zhou, et al. Automatic organ, pan-cancer segmentation in abdomen CT: the FLARE 2023 challenge, 2024. arXiv preprint arXiv:2408.12534.

[14] W. Li, C. Qu, X. Chen, P. Bassi, Y. Shi, Y. Lai, et al. Abdomenatlas: A large-scale, detailed-annotated, & multi-center dataset for efficient transfer learning, open algorithmic benchmarking. *Medical Image Analysis*, 97:103285, 2024.

[15] J. Liu, Y. Zhang, J. Chen, J. Xiao, Y. Lu, B. Landman, et al. CLIP-driven universal model for organ segmentation and tumor detection. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2023.

[16] C. Yu, C. Anakwenze, Y. Zhao, R. Martin, E. Ludmir, J. Niedzielski, et al. Multi-organ segmentation of abdominal structures from non-contrast and contrast enhanced CT images. *Scientific Reports*, 12, 2022.

[17] J. Park, I. Joo, S. K. Jeon, J.-M. Kim, S. J. Park, and S. H. Yoon. Automated abdominal organ segmentation algorithms for non-enhanced CT for volumetry and 3D radiomics analysis. *Abdominal Radiology*, 50(3):1448–1456, 2025.

[18] P. Christ et al. LiTS – liver tumor segmentation challenge (LiTS17). CodaLab competition 17094, 2017. 10.48550/arXiv.1901.04056.

[19] N. Heller, N. Sathianathen, A. Kalapara, E. Walczak, K. Moore, H. Kaluzniak, et al. Data from C4KC-KiTS. In *The Cancer Imaging Archive*, 2019.

[20] Y. Ji, H. Bai, C. Ge, J. Yang, Y. Zhu, R. Zhang, et al. AMOS: A large-scale abdominal multi-organ benchmark for versatile medical image segmentation. *Advances in Neural Information Processing Systems*, 35:36722–36732, 2022.

[21] X. Luo, W. Liao, J. Xiao, J. Chen, T. Song, X. Zhang, et al. WORD: A large scale dataset, benchmark, clinical applicable study for abdominal organ segmentation from CT image. *Medical Image Analysis*, 82:102642, 2022.

[22] B. Koch, E. Denton, A. Hanna, and J. Foster. Reduced, reused and recycled: The life of a dataset in machine learning research, 2021. arXiv preprint arXiv:2112.01716.

[23] G. Varoquaux and V. Cheplygina. Machine learning for medical imaging: methodological failures and recommendations for the future. *NPJ Digital Medicine*, 5(1):48, 2022.

[24] Z. Obermeyer, B. Powers, C. Vogeli, and S. Mullainathan. Dissecting racial bias in an algorithm used to manage the health of populations. *Science*, 366(6464):447–453, 2019.

[25] A. Larrazabal, N. Nieto, V. Peterson, D. Milone, and E. Ferrante. Gender imbalance in medical imaging datasets produces biased classifiers for computer-aided diagnosis. *Proceedings of the National Academy of Sciences*, 117(23):12592–12594, 2020.

[26] A. Kaushal, R. Altman, and C. Langlotz. Geographic distribution of US cohorts used to train deep learning algorithms. *JAMA*, 324(12):1212–1213, 2020.

[27] L. Seyyed-Kalantari, H. Zhang, M. McDermott, I. Chen, and M. Ghassemi. Underdiagnosis bias of artificial intelligence algorithms applied to chest radiographs in under-served patient populations. *Nature Medicine*, 27(12):2176–2182, 2021.

[28] R. Daneshjou, K. Vodrahalli, R. Novoa, M. Jenkins, W. Liang, V. Rotemberg, et al. Disparities in dermatology AI performance on a diverse, curated clinical image set. *Science Advances*, 8(32):eabq6147, 2022.

[29] C. Jones, D. Castro, F. De Sousa Ribeiro, O. Oktay, M. McCradden, and B. Glocker. A causal perspective on dataset bias in machine learning for medical imaging. *Nature Machine Intelligence*, 6(2):138–146, 2024.

[30] B. Koçak, A. Ponsiglione, A. Stanzione, C. Bluethgen, J. Santinha, L. Ugga, et al. Bias in artificial intelligence for medical imaging: Fundamentals, detection,

avoidance, mitigation, challenges, ethics, prospects. *Diagnostic and Interventional Radiology*, 2024.

[31] Z. Xu et al. Addressing fairness issues in deep learning-based medical image analysis: A systematic review. *npj Digital Medicine*, 7:265, 2024.

[32] K. Moons, J. Damen, T. Kaul, L. Hooft, C. Andaur Navarro, P. Dhiman, et al. PROBAST+AI: an updated quality, risk of bias, and applicability assessment tool for prediction models using regression or artificial intelligence methods. *BMJ*, 388, 2025.

[33] G. Collins, K. Moons, P. Dhiman, R. Riley, A. Beam, B. Van Calster, et al. TRIPOD+AI statement: updated guidance for reporting clinical prediction models that use regression or machine learning methods. *BMJ*, 385:e078378, 2024.

[34] . WAW-TACE: A hepatocellular carcinoma multiphase CT dataset with segmentations, radiomics features, and clinical data. *Radiology: Artificial Intelligence*, 2024. Zenodo DOI: 10.5281/zenodo.11063784.

[35] R. Muhamedrahimov, A. Bar, J. Laserson, A. Akselrod-Ballin, and E. Elnekave. Using machine learning to identify intravenous contrast phases on computed tomography. *Computer Methods and Programs in Biomedicine*, 215:106603, 2022.

[36] B. Hou, T. S. Mathai, P. Mukherjee, X. Wang, R. M. Summers, and Z. Lu. Segment-and-classify: ROI-guided generalizable contrast phase classification in CT using XGBoost. *arXiv preprint arXiv:2501.14066*, 2025.

[37] E. P. Reis, L. Blankemeier, J. M. Zambrano Chaves, et al. Automated abdominal CT contrast phase detection using an interpretable and open-source artificial intelligence algorithm. *European Radiology*, 34(10):6680–6687, 2024.

[38] G. Baldini, R. Hosch, C. S. Schmidt, K. Borys, L. Kroll, S. Koitka, P. Haubold, O. Pelka, F. Nensa, and J. Haubold. Addressing the contrast media recognition challenge: A fully automated machine learning approach for predicting contrast phases in CT imaging. *Investigative Radiology*, 59(9):635–645, 2024.

[39] Z. Ye, J. M. Qian, A. Hosny, et al. Deep learning-based detection of intravenous contrast enhancement on CT scans. *Radiology: Artificial Intelligence*, 4:e210285, 2022.

[40] B. T. Dao, T. V. Nguyen, H. H. Pham, and H. Q. Nguyen. Phase recognition in contrast-enhanced CT scans based on deep learning and random sampling. *Med-*

ical Physics, 49(5):3102–3116, 2022. VinDr-Multiphase dataset paper; random-slice-sampling majority-vote phase classifier.

[41] B. A. Rocha, L. C. Ferreira, L. G. R. Vianna, et al. Contrast phase recognition in liver computer tomography using deep learning. *Scientific Reports*, 12:20315, 2022.

[42] Q. Liu, J. Jiang, K. Wu, Y. Zhang, N. Sun, J. Luo, T. Ba, A. Lv, C. Liu, Y. Yin, Z. Yang, and H. Xu. A two-step automatic identification of contrast phases for abdominal CT images based on residual networks. *Insights into Imaging*, 2025.

[43] A. Anand, J. Liu, T. C. Shen, W. M. Linehan, P. A. Pinto, and R. M. Summers. Automated classification of intravenous contrast enhancement phase of CT scans using residual networks. In *Proc. SPIE 12465, Medical Imaging 2023: Computer-Aided Diagnosis*, page 124650O, 2023.

[44] N. Heller, N. Sathianathen, A. Kalapara, et al. Data from C4KC-KiTS. The Cancer Imaging Archive, 2019.

[45] I. Wells WM, P. Viola, H. Atsumi, S. Nakajima, and R. Kikinis. Multi-modal volume registration by maximization of mutual information. Med. Image Anal., 1(1):35–51, 1996. 10.1016/S1361-8415(01)80004-9.

[46] C. Studholme, D. Hill, and D. Hawkes. An overlap invariant entropy measure of 3d medical image alignment. Pattern Recognition, 32(1):71–86, 1999. 10.1016/S0031-3203(98)00091-0.

[47] D. Mattes, D. Haynor, H. Vesselle, T. Lewellen, and W. Eubank. Nonrigid multimodality image registration. Proc. SPIE Med. Imaging, 4322:1609–1620, 2001. 10.1117/12.431046.

[48] B. Avants, C. Epstein, M. Grossman, and J. Gee. Symmetric diffeomorphic image registration with cross-correlation: Evaluating automated labeling of elderly and neurodegenerative brain. Med. Image Anal., 12(1):26–41, 2008. 10.1016/j.media.2007.06.004.

[49] M. Heinrich, M. Jenkinson, M. Bhushan, T. Matin, F. Gleeson, S. Brady, and J. Schnabel. Mind: Modality independent neighbourhood descriptor for multi-modal deformable registration. Med. Image Anal., 16(7):1423–1435, 2012. 10.1016/j.media.2012.05.008.

[50] M. Heinrich, M. Jenkinson, M. Brady, and J. Schnabel. Deeds: Mrf-based nonlinear image registration using efficient discrete optimization. Int. J. Comput. Vis., 103(3):384–400, 2013. 10.1007/s11263-013-0606-z.

[51] K. Murphy, B. van Ginneken, and S. Klein. Semi-automatic construction of reference standards for evaluation of image registration. Med. Image Anal., 15(1):71–84, 2011. 10.1016/j.media.2010.07.005.

[52] G. Balakrishnan, A. Zhao, M. Sabuncu, J. Guttag, and A. Dalca. Voxelmorph: A learning framework for deformable medical image registration. IEEE Trans. Med. Imaging, 38(8):1788–1800, 2019. http://doi..org/10.1109/TMI.2019.2897538.

[53] J. Chen, E. Frey, Y. He, W. Segars, Y. Li, and Y. Du. Transmorph: Transformer for unsupervised medical image registration. Med. Image Anal., 82:102615, 2022. 10.1016/j.media.2022.102615.

[54] S. Klein, M. Staring, K. Murphy, M. Viergever, and J. Pluim. Elastix: A toolbox for intensity-based medical image registration. IEEE Trans. Med. Imaging, 29(1):196–205, 2010. 10.1109/TMI.2009.2035616.

[55] B. Lowekamp, D. Chen, L. Ibanez, and D. Blezek. The design of simpleitk. Front. Neuroinform., 7:45, 2013. 10.3389/fninf.2013.00045.

[56] J.-P. Thirion. Image matching as a diffusion process: An analogy with maxwell's demons. Med. Image Anal., 2(3):243–260, 1998. 10.1006/mian.1998.0107.

[57] D. Rueckert, L. Sonoda, C. Hayes, D. Hill, M. Leach, and D. Hawkes. Nonrigid registration using free-form deformations: Application to breast mr images. IEEE Trans. Med. Imaging, 18(8):712–721, 1999. 10.1109/42.796284.

[58] J. Pluim, J. Maintz, and M. Viergever. Mutual-information based registration of medical images: A survey. IEEE Trans. Med. Imaging, 22(8):986–1004, 2003. 10.1109/TMI.2003.815867.

[59] C. Metz, S. Klein, M. Schaap, T. van Walsum, and W. Niessen. Nonrigid registration of dynamic medical imaging data using nd+t b-splines and a groupwise optimization approach. Med. Image Anal., 15(2):238–249, 2011. 10.1016/j.media.2010.10.003.

[60] B. Papiez, M. Heinrich, L. Risser, and J. Schnabel. An implicit sliding-motion preserving regularisation via bilateral filtering for deformable image registration. Med. Image Anal., 18(8):1323–1335, 2014. 10.1016/j.media.2014.06.006.

[61] B. De Vos, F. Berendsen, M. Viergever, H. Sokooti, M. Staring, and I. Isgum. A deep learning framework for unsupervised affine and deformable image registration. Med. Image Anal., 52:128–143, 2019. 10.1016/j.media.2019.02.003.

[62] Y. Hu, M. Modat, and E. Gibson. Weakly-supervised convolutional neural networks for multimodal image registration. Med. Image Anal., 49:1–13, 2018. 10.1016/j.media.2018.07.002.

[63] O. Oktay, E. Ferrante, and K. Kamnitsas. Anatomically constrained neural networks (acnn): Application to cardiac image enhancement and segmentation. IEEE Trans. Med. Imaging, 37(2):384–395, 2018. 10.1109/TMI.2017.2743464.

[64] T. Mok and A. Chung. Large deformation diffeomorphic image registration with laplacian pyramid networks. Proc. MICCAI 2020, pp. 211–221, 2020. 10.1007/978-3-030-59716-0_21.

[65] Z. Zhao, V. Lau, and Z. Li. Recursive cascaded networks for unsupervised medical image registration. Proc. ICCV 2019, pp. 10600–10610, 2019. 10.1109/ICCV.2019.01069.

[66] A. Hoopes, M. Hoffmann, B. Fischl, J. Guttag, and A. Dalca. Hypermorph: Amortised hyperparameter learning for image registration. Proc. IPMI 2021, pp. 3–17, 2021. 10.1007/978-3-030-78191-0_1.

[67] Z. Xu and M. Niethammer. Deepatlas: Joint semi-supervised learning of image registration and segmentation. Proc. MICCAI 2019, pp. 420–429, 2019. 10.1007/978-3-030-32245-8_47.

[68] H. Tian. Unigradicon: A foundation model for medical image registration. arXiv:2403.05780, 2024. https://arxiv.org/abs/2403.05780.

[69] Y. et al. Synthesizing contrast-enhanced computed tomography images with an improved conditional generative adversarial network, 2022. https://doi.org/10.1109/EMBC48229.2022.9871672.

[70] Y. et al. Spatial attention-guided generative adversarial network for synthesizing contrast-enhanced computed tomography images, 2023. https://doi.org/10.1109/EMBC40787.2023.10340586.

[71] Y. et al. Segmentation guided crossing dual decoding generative adversarial network for synthesizing contrast-enhanced computed tomography images, 2024. https://doi.org/10.1109/JBHI.2024.3403199.

[72] Y. et al. Oa-gan: organ-aware generative adversarial network for synthesizing contrast-enhanced medical images, 2024. https://doi.org/10.1088/2057-1976/ad31fa.

[73] Z. et al. Man-gan: a mask-adaptive normalization based generative adversarial networks for liver multi-phase ct image generation, 2025. https://doi.org/10.1038/s41598-025-10754-z.

[74] C. et al. Mask-aware transformer with structure invariant loss for ct translation, 2024. https://doi.org/10.1016/j.media.2024.103205.

[75] Z. et al. Contrast-aware network with aggregated-interacted transformer and multi-granularity aligned contrastive learning for synthesizing contrast-enhanced abdomen ct imaging, 2025. https://doi.org/10.1109/TCI.2025.3540711.

[76] C. et al. Generating synthetic contrast enhancement from non-contrast chest computed tomography using a generative adversarial network, 2021. https://doi.org/10.1038/s41598-021-00058-3.

[77] X. et al. Generation of contrast-enhanced ct with residual cycle-consistent generative adversarial network (res-cyclegan), 2021. https://doi.org/10.1117/12.2581056.

[78] R. et al. Cytran: A cycle-consistent transformer with multi-level consistency for non-contrast to contrast ct translation, 2021. https://arxiv.org/abs/2110.06400.

[79] S. et al. Unpaired medical image translation between portal-venous phase and non-contrast ct volumes for multi-organ segmentation, 2021. https://doi.org/10.1117/12.2590639.

[80] Z. et al. Contrast flow pattern and cross-phase specificity-aware diffusion model for ncct-to-multiphase cect synthesis, 2025. https://doi.org/10.1007/978-3-032-04965-0_9.

[81] Z. et al. Cross-domain distribution adversarial diffusion model for synthesizing contrast-enhanced abdomen ct imaging, 2025. https://www.sciencedirect.com/science/article/abs/pii/S0031320325003553.

[82] W. et al. Synthesis of abdominal contrast-enhanced ct using diffusion-based spatial transform control, 2025. https://doi.org/10.1007/978-3-032-09513-8_14.

[83] Z. et al. Causality-driven spatio-temporal generator for multi-phase contrast-enhanced ct synthesis, 2025. https://doi.org/10.1007/978-3-032-04947-6_11.

[84] L. et al. A text-guided brownian bridge diffusion model for unified multiphase contrast-enhanced ct synthesis, 2026.

[85] Z. et al. United multi-task learning for abdominal contrast-enhanced ct synthesis through joint deformable registration, 2023. https://doi.org/10.1016/j.cmpb.2023.107391.

[86] L. et al. Boosting medical image synthesis via registration-guided consistency and disentanglement learning, 2024. https://arxiv.org/abs/2407.07660.

[87] U. et al. A unified multi-phase ct synthesis and classification framework for kidney cancer diagnosis with incomplete data, 2022. https://doi.org/10.1109/JBHI.2022.3219123.

[88] H. et al. Clinical feasibility of deep learning based synthetic contrast enhanced abdominal ct in patients undergoing non enhanced ct scans, 2024. https://doi.org/10.1038/s41598-024-68705-z.

[89] K. et al. The feasibility of deep learning-based synthetic contrast-enhanced ct from nonenhanced ct in emergency department patients with acute abdominal pain, 2021. https://doi.org/10.1038/s41598-021-99896-4.

[90] H. et al. Contrast agent dose reduction in computed tomography with deep learning using a conditional generative adversarial network, 2021. https://doi.org/10.1007/s00330-021-07714-2.

[91] H. et al. Contrast media reduction in computed tomography with deep learning using a generative adversarial network in an experimental animal study, 2022. https://pubmed.ncbi.nlm.nih.gov/35438659/.

[92] A. et al. Applications of deep learning to reduce the need for iodinated contrast media for ct imaging: a systematic review, 2023. https://doi.org/10.1007/s11548-023-02862-w.

[93] J. et al. Deep learning for synthetic contrast-enhanced ct and mri: a scoping review, 2026. https://doi.org/10.1007/s00330-026-12548-x.

[94] X. Zhou, J. Wu, H. Zhao, L. Chen, S. Zhang, and G. Wang. GLFC: Unified global-local feature and contrast learning with mamba-enhanced UNet for synthetic CT generation from CBCT, 2025. arXiv:2501.02992; https://github.com/HiLab-git/GLFC.

[95] M. Fukuda, S. Kotaki, M. Nozawa, C. Kuwada, Y. Kise, E. Ariji, and Y. Ariji. A cycle generative adversarial network for generating synthetic contrast-enhanced computed tomographic images from non-contrast images in the internal jugular lymph node-bearing area, 2024.

[96] A. Rofena, V. Guarrasi, M. Sarli, C. L. Piccolo, M. Sammarra, B. B. Zobel, and P. Soda. A deep learning approach for virtual contrast enhancement in contrast enhanced spectral mammography. *Computerized Medical Imaging and Graphics*, 116:102398, 2024. https://github.com/cosbidev/VCE_CESM.

[97] P. et al. Multi-phase synthetic contrast enhancement in interventional computed tomography for guiding renal cryotherapy, 2023. https://doi.org/10.1007/s11548-023-02843-z.

[98] W. Li et al. Virtual contrast-enhanced magnetic resonance images synthesis for patients with nasopharyngeal carcinoma using multimodality-guided synergistic neural network. *International Journal of Radiation Oncology*Biology*Physics*, 112(4):1033–1044, 2022. https://github.com/WenLi-PolyU/MMgSN-Net-for-vce-MRI-synthesis.

[99] J. Li, Z. Qu, Y. Yang, F. Zhang, M. Li, and S. Hu. TCGAN: a transformer-enhanced GAN for PET synthetic CT. *Biomedical Optics Express*, 13(11):6003–6018, 2022. https://github.com/jinxiqinghuan/TCGAN.

[100] S. Kida, S. Kaji, et al. Visual enhancement of cone-beam CT by use of CycleGAN. *Medical Physics*, 47(3):998–1010, 2020. arXiv:1901.05773; https://github.com/shizuo-kaji/UnpairedImageTranslation.

[101] T.-C. Wang, M.-Y. Liu, J.-Y. Zhu, A. Tao, J. Kautz, and B. Catanzaro. High-resolution image synthesis and semantic manipulation with conditional gans. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 8798–8807, 2018.

[102] O. Dalmaz, M. Yurt, and T. Çukur. ResViT: Residual vision transformers for multimodal medical image synthesis. *IEEE Transactions on Medical Imaging*, 41(10):2598–2614, 2022.

[103] B. Yu, L. Zhou, L. Wang, Y. Shi, J. Fripp, and P. Bourgeat. Ea-GANs: Edge-aware generative adversarial networks for cross-modality MR image synthesis. *IEEE Transactions on Medical Imaging*, 38(7):1750–1762, 2019.

[104] A. Hatamizadeh, V. Nath, Y. Tang, D. Yang, H. R. Roth, and D. Xu. Swin UNETR: Swin transformers for semantic segmentation of brain tumors in MRI images. In *Brainlesion: Glioma, Multiple Sclerosis, Stroke and Traumatic Brain Injuries (BrainLes)*, pages 272–284, 2022.

[105] J. Chen, Y. Lu, Q. Yu, X. Luo, E. Adeli, Y. Wang, L. Lu, A. L. Yuille, and Y. Zhou. TransUNet: Transformers make strong encoders for medical image segmentation. *arXiv preprint arXiv:2102.04306*, 2021.

[106] L. et al. Virtual contrast enhancement for ct scans of abdomen and pelvis, 2022. https://doi.org/10.1016/j.compmedimag.2022.102094.

[107] J. A. C. Sterne, M. A. Hernán, B. C. Reeves, J. Savović, N. D. Berkman, M. Viswanathan, et al. ROBINS-I: a tool for assessing risk of bias in non-randomised studies of interventions. *BMJ*, 355:i4919, 2016.

[108] H. J. Schünemann, C. Cuello, E. A. Akl, R. A. Mustafa, J. J. Meerpohl, K. Thayer, et al. GRADE guidelines: 18. how ROBINS-I and other tools to assess risk of bias in nonrandomized studies should be used to rate the certainty of a body of evidence. *Journal of Clinical Epidemiology*, 111:105–114, 2019.

[109] P. F. Whiting, A. W. S. Rutjes, M. E. Westwood, S. Mallett, J. J. Deeks, J. B. Reitsma, et al. QUADAS-2: A revised tool for the quality assessment of diagnostic accuracy studies. *Annals of Internal Medicine*, 155(8):529–536, 2011.

[110] T. Chen and C. Guestrin. XGBoost: A scalable tree boosting system. In *ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794, 2016.

[111] M. Oquab, T. Darcet, T. Moutakanni, H. Vo, M. Szafraniec, V. Khalidov, P. Fernandez, D. Haziza, F. Massa, A. El-Nouby, et al. DINOv2: Learning robust visual features without supervision. *Transactions on Machine Learning Research*, 2024.

[112] O. N. Manzari, H. Ahmadabadi, H. Kashiani, S. B. Shokouhi, and A. Ayatollahi. MedViT: A robust vision transformer for generalized medical image classification. *Computers in Biology and Medicine*, 157:106791, 2023.

[113] O. Ledoit and M. Wolf. A well-conditioned estimator for large-dimensional covariance matrices. *Journal of Multivariate Analysis*, 88(2):365–411, 2004.

[114] W. Kabsch. A solution for the best rotation to relate two sets of vectors. Acta Crystallogr. A, 32(5):922–923, 1976. 10.1107/S0567739476001873.

[115] J. Nelder and R. Mead. A simplex method for function minimization. Comput. J., 7(4):308–313, 1965. 10.1093/comjnl/7.4.308.

[116] E. Perez, F. Strub, H. de Vries, V. Dumoulin, and A. Courville. FiLM: Visual reasoning with a general conditioning layer. In *AAAI Conference on Artificial Intelligence*, pages 3942–3951, 2018.

[117] Y. Wu and K. He. Group normalization. In *European Conference on Computer Vision (ECCV)*, pages 3–19, 2018.

[118] A. Kendall and Y. Gal. What uncertainties do we need in bayesian deep learning for computer vision? In *Advances in Neural Information Processing Systems (NeurIPS)*, pages 5574–5584, 2017.

[119] J. Ho, A. Jain, and P. Abbeel. Denoising diffusion probabilistic models. *Advances in Neural Information Processing Systems*, 33:6840–6851, 2020.

[120] T. Salimans and J. Ho. Progressive distillation for fast sampling of diffusion models. In *International Conference on Learning Representations (ICLR)*, 2022.

[121] J. Song, C. Meng, and S. Ermon. Denoising diffusion implicit models. In *International Conference on Learning Representations (ICLR)*, 2021.

[122] J. Ho and T. Salimans. Classifier-free diffusion guidance. *arXiv preprint arXiv:2207.12598*, 2022.

[123] T. Hang, S. Gu, C. Li, J. Bao, D. Chen, H. Hu, X. Geng, and B. Guo. Efficient diffusion training via min-SNR weighting strategy. In *IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 7441–7451, 2023.

[124] P. Isola, J.-Y. Zhu, T. Zhou, and A. A. Efros. Image-to-image translation with conditional adversarial networks. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 5967–5976, 2017.

[125] J.-Y. Zhu, T. Park, P. Isola, and A. A. Efros. Unpaired image-to-image translation using cycle-consistent adversarial networks. In *IEEE International Conference on Computer Vision (ICCV)*, pages 2242–2251, 2017.

[126] A. Hatamizadeh, V. Nath, Y. Tang, D. Yang, H. R. Roth, and D. Xu. Swin unetr: Swin transformers for semantic segmentation of brain tumors in MRI images. In *International MICCAI Brainlesion Workshop*, pages 272–284, 2021.

[127] B. Yu, L. Zhou, L. Wang, Y. Shi, J. Fripp, and P. Bourgeat. Ea-GANs: Edge-aware generative adversarial networks for cross-modality MR image synthesis. *IEEE Transactions on Medical Imaging*, 38(7):1750–1762, 2019.

[128] M. Özbey, O. Dalmaz, S. U. H. Dar, H. A. Bedel, Ş. Ünal, and T. Çukur. Unsupervised medical image translation with adversarial diffusion models. *IEEE Transactions on Medical Imaging*, 42(12):3524–3539, 2023.

[129] R. Zhang, P. Isola, A. A. Efros, E. Shechtman, and O. Wang. The unreasonable effectiveness of deep features as a perceptual metric. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 586–595, 2018.

[130] M. Heusel, H. Ramsauer, T. Unterthiner, B. Nessler, and S. Hochreiter. GANs trained by a two time-scale update rule converge to a local nash equilibrium. In *Advances in Neural Information Processing Systems (NeurIPS)*, pages 6626–6637, 2017.

[131] T. Gneiting and A. E. Raftery. Strictly proper scoring rules, prediction, and estimation. *Journal of the American Statistical Association*, 102(477):359–378, 2007.

[132] J. Llovet, R. Kelley, A. Villanueva, A. Singal, E. Pikarsky, S. Roayaie, et al. Hepatocellular carcinoma. *Nature Reviews Disease Primers*, 7(1):6, 2021.

[133] V. Kedar Mukthinuthalapati, V. Sewram, N. Ndlovu, S. Kimani, A. Abdelaziz, E. Chiao, et al. Hepatocellular carcinoma in sub-saharan africa. *JCO Global Oncology*, 7:756–766, 2021.

[134] J. D. Rudie, H.-M. Lin, R. L. Ball, S. Jalal, L. M. Prevedello, S. Nicolaou, et al. The RSNA abdominal traumatic injury CT (RATIC) dataset. *Radiology: Artificial Intelligence*, 6(6):e240101, 2024.

[135] B. Efron. Bootstrap methods: another look at the jackknife. *The Annals of Statistics*, 7(1):1–26, 1979.

[136] Q. McNemar. Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika*, 12(2):153–157, 1947.

واژه‌نامه

الف

انحراف حجمی ..... Volumetric deviation

انتقال حوزه ..... Domain adaptation

اطلاعات متقابل ..... Mutual Information (MI)

اطلاعات متقابل بهنجارشده .. Normalised Mutual Information (NMI)

اشتراکی (پارامتر مشترک) ..... Shared-weight

آزمون مک‌نمار ..... McNemar's test

ادغام میانگین ..... Mean pooling

انقباض ..... Shrinkage

ب

بخش‌بندی چندعضوی . Multi-organ segmentation

بازخوانی ..... Recall

بی‌اسپلاین ..... B-spline

بهنجارسازی سازگار با نقاب ..... Mask-adaptive normalisation

بدون‌جفت ..... Unpaired

باقیمانده ..... Residual

بهنجارسازی متقارن ... Symmetric Normalisation

برچسب‌های ضعیف ..... Weak labels

بوت‌استرپ ..... Bootstrap

پ

پرسش‌محور ..... Prompt-driven

پرخون ..... Hypervascular

پنجره‌ی پارزن ..... Parzen window

پیشین‌های شکل تشریحی Anatomical shape priors

پایداری معکوس گرادیان ..... Gradient inverse consistency

پیمانه‌ای ..... Modular

پل براونی ..... Brownian bridge diffusion

ت

تکرارپذیری ..... Reproducibility

تمرکز محک ..... Benchmark concentration

تصویر متحرک ..... Moving image

تصویر ثابت ..... Fixed image

تغییر شکل آزاد .. Free-Form Deformation (FFD)

تکراری ..... Iterative

تبدیل‌گر فضایی ..... Spatial transformer

توصیف‌گر همسایگی مستقل از وجهیت Modality Independent Neighbourhood Descriptor (MIND)

ترجمه‌ی تصویر ..... Image-to-image translation

توجه چندسر ..... Multi-head attention

تقطیر دانش ..... Knowledge distillation

توجه بین‌فازی ..... Inter-phase attention

توجه فضایی ..... Spatial attention

تصویر بازترکیب‌شده ..... Recombined image

تضعیف اشعه‌ی ایکس ..... X-ray attenuation

تحلیل تشخیصی خطی ..... Linear Discriminant Analysis (LDA)

تحلیل مؤلفه‌های اصلی .... Principal Component Analysis (PCA)

ث

ثبت تصویر ..... Image registration

ثبت گروهی ..... Groupwise

ج

جابه‌جایی حوزه‌ای ..... Domain shift

جنگل درختان تقویت‌شده‌ی گرادیانی .... Gradient-boosted decision trees

جفت‌شده ..... Paired

جفت‌شده (خانواده‌ی GAN) ..... Paired GAN

چ

چندگذره ..... Multi-pass

ح

حرکت لغزشی ..... Sliding motion

خ

خودپیکربندی ..... Self-configuring

خطای ثبت هدف ..... Target Registration Error (TRE)

خشن‌به‌ریز ..... Coarse-to-fine

خودشباهت ..... Self-similarity

خارج‌ازتا ..... Out-of-fold

د

دقت ..... Accuracy

دقت‌مثبت ..... Precision

دیمانز ..... Demons

دایکام ..... DICOM

Dice فرسایش‌یافته ..... Eroded Dice

ر

رمزگذار منجمد ..... Frozen encoder

ز

زیان تغییرناپذیری ساختار .Structure invariant loss

زیان کانونی ..... Focal loss

زیان تباین چندگانه ..... Multiple Contrast Loss

س

سوگیری ..... Bias

سوگیری طیف ..... Spectrum bias

سوگیری انتخاب ..... Selection bias

سوگیری نژادی ..... Racial bias

سوگیری جمعیت‌شناختی ..... Demographic bias

سوگیری فنی ..... Technical bias

سوگیری برچسب‌گذاری ..... Labelling bias

سوگیری زمانی ..... Temporal bias

سی‌تی بدون‌کنتراست .. Non-contrast CT (NCCT)

سی‌تی کنتراست‌دار ..... Contrast-enhanced CT (CECT)

سی‌تی دوانرژی ..... Dual-energy CT

سی‌تی چندفازی ..... Multi-phase CT

سی‌تی شکمی ..... Abdominal CT

سنتز کنتراست مجازی ..... Virtual contrast enhancement

سازگاری چرخه‌ای ..... Cycle-consistency

سی‌تی شکمی چندفازی Multi-phase abdominal CT

ش

شبکه‌های آبشاری بازگشتی ... Recursive Cascaded Networks

شاخص شباهت ساختاری ... Structural Similarity Index (SSIM)

شباهت پرسپچوال یادگرفته‌شده Learned Perceptual Image Patch Similarity (LPIPS)

شرط‌دهی متنی ..... Text-guided

شست‌وشو ..... Washout

ص

صدک نودوپنجم فاصله‌ی هاسدورف 95th percentile Hausdorff Distance (HD95)

صلب ..... Rigid

صفر/چندنمونه ..... Zero/few-shot

ض

ضریب هم‌پوشانی سورنسن–دایس .. Sørensen–Dice coefficient

ضریب همبستگی پیرسون .... Pearson Correlation Coefficient (PCC)

غ

غربالگری فرصت‌طلبانه .. Opportunistic screening

ف

فاز بدون‌کنتراست ..... Non-contrast (NC) phase

فاز کنتراست ..... Contrast phase

فاز کنتراست‌دار . Contrast-enhanced (CE) phase

فاصله‌ی مرکز جرم ..... Centroid distance

فاصله‌ی آغازشی فرشه Fréchet Inception Distance (FID)

فضازمانی علّی Causality-driven spatio-temporal

فاز شریانی ..... Arterial phase

فاز وریدی باب ..... Portal venous phase

فاز تأخیری ..... Delayed phase

ک

کارسینوم سلول کبدی . Hepatocellular carcinoma (HCC)

کاوش خطی ..... Linear probing

م

منحنی مشخصه‌ی عملکرد سیستم ..... Receiver Operating Characteristic curve (ROC)

مقیاس‌پذیری ترکیبی ..... Compound scaling

منظم‌ساز ..... Regulariser

مدل بنیادین ..... Foundation model

مستقل از وجهیت ..... Modality-independent

میدان تصادفی مارکوف ... Markov Random Field (MRF)

میانگین قدرمطلق خطا ..... Mean Absolute Error (MAE)

میانگین مربعات خطا Mean Squared Error (MSE)

مدل‌های انتشار ..... Diffusion models

ماده‌ی حاجب ..... Contrast media

ماده‌ی حاجب یددار . Iodinated contrast medium

ماموگرافی طیفی کنتراست‌دار . . Contrast Enhanced Spectral Mammography (CESM)

ن

نسبت کنتراست‌به‌نویز . . . . Contrast-to-noise ratio (CNR)

نقاب . . . . . Mask

نشت داده . . . . . Data leakage

نشانه‌های آناتومیک . . . . . Anatomical landmarks

نظارت ضعیف . . . . . Weak supervision

نقاب تصویر ثابت . . . . . Fixed-image mask

نسبت سیگنال به نویز اوج . . . Peak Signal-to-Noise Ratio (PSNR)

نمایندگی . . . . . Representativeness

نقشه‌های ویژگی . . . . . Feature maps

و

وضعیت فاز کنتراست . . . . Contrast enhancement status

هـ

هم‌پوشانی برچسب . . . . . Label overlap (Dice)

همبستگی متقابل نرمال‌شده . . . . . Normalised Cross-Correlation (NCC)

ی

یادگیری فدرال . . . . . Federated learning

یادگیری متضاد چندگرانی . . . . . Multi-granularity contrastive learning

یک‌درمقابل‌بقیه . . . . . One-vs-rest

یادگیری خودنظارتی . . . . . Self-supervised learning

پیوست آ

مطالب تکمیلی

آ‌ـ۱ تحلیل حساسیت: دایس فرسوده در ارزیابی پایین‌دستی سنتز

ارزیابی پایین‌دستی بخش ۴-۴ با دایس ساده گزارش شده است. جدول آ‌ـ۱ همان مقایسه‌ی زوجی با بازوی NCCT را با دایس فرسوده‌ی ۶ میلی‌متری، یعنی معیار فصل هم‌ترازسازی، کنار دایس ساده قرار می‌دهد. تحت فرسایش، اثر مثبت سنتز بر گروه عروقی در هیچ بازویی معنادار نیست. برای ورید باب، ماسک فرسوده تنها در حدود نیمی از موارد ناتهی می‌ماند (۸ تا ۱۰ مورد)؛ در همین زیرمجموعه، PLC-Net دوبعدی اثر مثبت معنادار حفظ می‌کند. این نتایج نشان می‌دهد اثر عروقی گزارش‌شده به انتخاب معیار حساس است و عمدتاً در لایه‌ی مرزی ساختارهای نازک رخ می‌دهد.

جدول آ‌ـ۱: میانگین تفاوت زوجی دایس نسبت به بازوی NCCT با دایس ساده و با دایس فرسوده‌ی ۶ میلی‌متری. مقادیر p از آزمون t زوجی و توصیفی‌اند؛ n شمار موارد با ماسک فرسوده‌ی ناتهی است.

بازو	عروقی، دایس ساده	عروقی، دایس فرسوده	ورید باب، دایس فرسوده
PLC-Net دوبعدی	+0.0381 ($p <$ ۰/۰۰۱)	-0.0247 ($p =$ ۰/۳۷)	+0.1387 ($n =$ ۱۰، $p =$ ۰/۰۰۳)
PLC-Net ۲/۵ بعدی	+0.0270 ($p <$ ۰/۰۰۱)	-0.0284 ($p =$ ۰/۱۴)	+0.0173 ($n =$ ۹، $p =$ ۰/۶۲)
L1ـ اندام	+0.0438 ($p <$ ۰/۰۰۱)	+0.0059 ($p =$ ۰/۷۴)	+0.0865 ($n =$ ۹، $p =$ ۰/۰۳۹)
ResViT	+0.0345 ($p <$ ۰/۰۰۱)	-0.0259 ($p =$ ۰/۱۴)	+0.0529 ($n =$ ۱۰، $p =$ ۰/۱۵)
pix2pixHD	+0.0231 ($p <$ ۰/۰۰۱)	+0.0082 ($p =$ ۰/۵۳)	+0.0578 ($n =$ ۹، $p =$ ۰/۰۷۸)
CycleGAN	+0.0089 ($p =$ ۰/۰۳۲)	-0.0396 ($p =$ ۰/۰۸۲)	-0.0354 ($n =$ ۱۰، $p =$ ۰/۲۲)
CyTran	-0.0171 ($p <$ ۰/۰۰۱)	-0.0540 ($p <$ ۰/۰۰۱)	-0.0687 ($n =$ ۸، $p =$ ۰/۰۴۲)
DDPM	-0.0358 ($p <$ ۰/۰۰۱)	-0.0530 ($p =$ ۰/۰۱۲)	-0.0706 ($n =$ ۹، $p =$ ۰/۰۱۶)

Abstract

We present a standard template for typesetting theses in Persian. The template is based on the XePersian package for the LaTeX typesetting system. This write-up shows a sample usage of this template.

Keywords: Thesis, Typesetting, Template, XePersian



Sharif University of Technology

Department of Computer Engineering

M.Sc. Thesis

Bioinformatics Thesis

Automatic multi-organ Segmentation in Abdominal CT with enhancing performance in non-contrast CT studies

By:

Saeide Danaei

Supervisor:

Hamid R. Rabiee

September 2026