دانشگاه صنعتی شریف
دانشکده مهندسی کامپیوتر

پایان‌نامه کارشناسی ارشد
مهندسی کامپیوتر

بخش‌بندی خودکار چنداندامی شکم در تصاویر سی‌تی‌اسکن با تمرکز بر بهبود کیفیت بر روی تصاویر بدون تزریق ماده‌حاجب

نگارش

سعیده دانائی

استاد راهنما

حمیدرضا ربیعی

شهریور ۱۴۰۵

سپاس

از استاد بزرگوارم که با کمک‌ها و راهنمایی‌های بی‌دریغشان، مرا در به سرانجام رساندن این پایان‌نامه یاری داده‌اند، تشکر و قدردانی می‌کنم. همچنین از همکاران عزیزی که با راهنمایی‌های خود در بهبود نگارش این نوشتار سهیم بوده‌اند، صمیمانه سپاسگزارم.

فهرست مطالب

۱ مقدمه ۱

۱-۱ اهمیت مسئله ۱

۱-۲ تعریف مسئله ۲

۱-۲-۱ مرور انتقادی مجموعه‌داده‌های سی‌تی شکمی ۲

۱-۲-۲ تشخیص فاز کنتراست ۳

۱-۲-۳ ثبت تصویر بین‌فازی ۳

۱-۲-۴ سنتز فاز کنتراست‌دار از فاز بدون‌کنتراست ۳

۱-۳ چالش‌ها ۴

۱-۴ اهداف پژوهش ۴

۱-۵ ساختار پایان‌نامه ۵

۱-۶ جمع‌بندی ۵

۲ کارهای پیشین ۶

۲-۱ پیش‌زمینه‌ی بالینی: سی‌تی چندفازی و فازهای کنتراست ۷

۲-۲ بخش‌بندی چندعضوی سی‌تی شکمی و شکاف کیفیت در فاز بدون‌کنتراست ۸

۲-۳ مجموعه‌داده‌های عمومی سی‌تی شکمی و مسئله‌ی سوگیری داده ۱۴

۲-۴ تشخیص فاز کنتراست در تصاویر سی‌تی خام ۱۶

۲-۵ ثبت تصویر بین‌فازی سی‌تی ۲۲

۲-۶ تولید تصاویر سی‌تی کنتراست‌دار از تصاویر سی‌تی بدون تزریق ماده‌ی حاجب ۳۲
۲-۷ جمع‌بندی و جای خالی پژوهش ۴۳

۳ روش پیشنهادی **۴۵**
۳-۱ نمای کلی ۴۵
۳-۲ مرور نظام‌مند مجموعه‌داده‌های سی‌تی شکمی: پروتکل ۴۶
۳-۳ داده و پیش‌پردازش ۴۹
۳-۴ تشخیص فاز کنتراست ۵۱
۳-۵ ثبت تصویر بین‌فازی چندگذره ۵۲
۳-۶ سنتز فاز کنتراست‌دار از فاز بدون‌کنتراست ۵۹
۳-۷ پروتکل ارزیابی ۶۳
۳-۸ جمع‌بندی ۶۶

۴ آزمایش‌ها **۶۸**
۴-۱ یافته‌های مرور نظام‌مند مجموعه‌داده‌ها ۶۸
۴-۲ نتایج ثبت تصویر بین‌فازی ۷۱

۵ نتیجه‌گیری **۷۶**

مراجع **۷۷**

واژه‌نامه **۹۱**

آ مطالب تکمیلی **۹۵**

فهرست جداول

۲-۱ مدل‌های بخش‌بندی و مطالعات شکاف بین‌فازی. ستون «فاز داده‌ی آموزش» نشان می‌دهد مدل با کدام فاز(ها) آموزش دیده است؛ کنار هم گذاشتن آن با دو ستون Dice، نشان می‌دهد شکاف بین‌فازی عمدتاً پیامد ترکیب داده‌ی آموزش است، نه خاصیت ذاتی فاز بدون‌کنتراست. ۱۳

۲-۲ مدل‌های تشخیص فاز کنتراست. ستون «معیار اصلی» سنجه‌ای است که مطالعه ادعای خود را بر آن بنا کرده؛ ستون‌های درون‌سازمانی و برون‌سازمانی عمداً از هم جدا شده‌اند تا افت تعمیم‌پذیری دیده شود. ۲۱

۲-۳ روش‌های منتخب ثبت تصویر: وظیفه‌ای که روش برای آن معرفی شده، معیاری که روش آن را بهینه می‌کند، و مقادیر گزارش‌شده روی محک ارزیابی. روش‌های بنیادین پیش از ۲۰۰۵، به‌دلیل نبودِ عدد قابل‌مقایسه، تنها در متن بررسی شده‌اند. ۳۱

۲-۴ ادبیات سنتز NC‌ـبه‌ـCE، دسته‌بندی‌شده بر اساس خانواده‌ی روش. ستون «فاز داده‌ی آموزش» نشان می‌دهد آیا داده‌ی آموزش هر دو فاز را به‌صورت جفت‌شده در بر داشته است یا نه. سلول‌های [ ] مقادیری‌اند که متن مقاله در دسترس نبوده یا جدول نتایج آن به‌صورت تصویر ذخیره شده و باید دستی استخراج شوند. ۴۰

۳-۱ هفت مقوله‌ی چارچوب ارزیابی ریسک سوگیری، به همراه تعریف عملیاتی و تهدید مرتبه‌بالاتری که هر مقوله به آن مربوط است. ۴۸

۴-۱ شمار مجموعه‌داده‌های دارای ریسک بالا در هر مقوله، از مجموع ۲۲ مجموعه‌داده‌ی ارزیابی‌شده. ۶۹

۴-۲ ابلیشن گام‌به‌گام پایپ‌لاین. دایس فرسوده به‌صورت میانه]چارک اول–چارک سوم[؛ فاصله‌ها بر حسب میلی‌متر و به‌صورت میانه. $n = 26$ بررسی، 55 جفت فاز. ۷۲

۴-۳ ابلیشن تابع هدف با مدل تبدیل و مقداردهی اولیه‌ی یکسان. تنها ردیف دوم دامنه‌ی معیار را به نقاب محدود *نمی‌کند*. ۷۳

۴-۴ مقایسه با روش‌های موجود روی همان ورودی و همان خطکش ارزیابی. ستون تاخوردگی تنها برای روش‌های غیرصلب معنا دارد. ۷۴

فهرست تصاویر

۳-۱ نمودار جریان پایپ‌لاین ثبت تصویر بین‌فازی ۵۸

فصل ۱

مقدمه

این فصل مسئله‌ی مرکزی پایان‌نامه را معرفی می‌کند و چارچوبی را می‌سازد که فصل‌های بعدی بر آن استوارند. نخست توضیح داده می‌شود چرا افت دقت بخش‌بندی خودکار در فاز بدون‌کنتراست سی‌تی شکمی مسئله‌ای بالینی و نه صرفاً فنی است؛ سپس این مسئله به چهار زیرمسئله‌ی مشخص تجزیه می‌شود که ستون‌بندی مشترک فصل‌های کارهای پیشین، روش پیشنهادی و آزمایش‌ها را تعیین می‌کنند. در ادامه، چالش‌های فنی و داده‌ای که حل این زیرمسئله‌ها را دشوار می‌کنند، اهداف پژوهش، و ساختار کلی پایان‌نامه ارائه می‌شود.

۱-۱ اهمیت مسئله

سی‌تی شکمی[۱] یکی از پرکاربردترین وجهیت‌های تصویربرداری در تشخیص، مرحله‌بندی و پیگیری بیماری‌های کبد، کلیه، پانکراس و سایر اندام‌های شکمی است. در عمل بالینی، این تصویربرداری معمولاً در چند فاز کنتراست[۲] انجام می‌شود: نخست یک اسکن بدون‌کنتراست[۳]، پیش از تزریق ماده‌ی حاجب[۴]، و سپس یک یا چند اسکن کنتراست‌دار[۵] در فازهای شریانی، وریدی یا تأخیری. تشخیص بسیاری از ضایعات کانونی کبد، به‌ویژه کارسینوم سلول کبدی[۶]، مستقیماً به الگوی افزایش کنتراست و شست‌وشوی[۷] آن میان فازهای مختلف وابسته است [۱، ۲]؛ الگویی که تنها با ترکیب دقیق اطلاعات چند فاز قابل‌مشاهده است.

[۱] Abdominal CT
[۲] Contrast phase
[۳] Non-contrast (NC) phase
[۴] Contrast media
[۵] Contrast-enhanced (CE) phase
[۶] Hepatocellular carcinoma (HCC)
[۷] Washout

با این حال، فاز بدون‌کنتراست کاربردی صرفاً تکمیلی ندارد. در بسیاری از پروتکل‌های بالینی، از جمله تروما، غربالگری فرصت‌طلبانه[۸]، و بیمارانی که به دلیل نارسایی کلیوی یا سابقه‌ی حساسیت، امکان تزریق ماده‌ی حاجب را ندارند، فاز بدون‌کنتراست تنها تصویر در دسترس است. بخش‌بندی خودکار اندام‌های شکمی روی همین فاز، زیرساخت اندازه‌گیری حجمی، برنامه‌ریزی درمان و ردیابی روند بیماری در چنین بیمارانی است.

اما همان‌طور که در فصل ۲ به‌تفصیل مرور می‌شود، دقت مدل‌های بخش‌بندی روی فاز بدون‌کنتراست، به دلیل کاهش نسبت کنتراست‌به‌نویز[۹] میان بافت‌های نرم مجاور، به‌طور نظام‌مند و وابسته به اندام، پایین‌تر از فاز کنتراست‌دار است [۳، ۴، ۵]. نتیجه آن است که دقیقاً همان گروه از بیماران که کمترین دسترسی را به تصویربرداری کنتراست‌دار دارند، از ضعیف‌ترین خروجی بخش‌بندی خودکار بهره می‌برند. این افت، به‌جای آن‌که محدودیتی ذاتی و اجتناب‌ناپذیر تلقی شود، نقطه‌ی شروع این پایان‌نامه است.

۱-۲ تعریف مسئله

هدف کلی این پایان‌نامه، کاهش شکاف دقت بخش‌بندی چندعضوی میان فاز بدون‌کنتراست و فاز کنتراست‌دار در سی‌تی شکمی است، از طریق دو راهبرد مکمل: هم‌ترازسازی هندسی فازهای موجود از طریق ثبت تصویر، و بازسازی مستقیم اطلاعات فاز کنتراست‌دار از روی فاز بدون‌کنتراست از طریق سنتز. هر دو راهبرد بر زیرساختی مشترک تکیه دارند که پیش از ورود به آن‌ها باید مستحکم شود: شناخت دقیق محدودیت‌های مجموعه‌داده‌های موجود، و شناسایی صحیح فاز کنتراست هر بررسی.

بر این اساس، مسئله‌ی کلی به چهار زیرمسئله تجزیه می‌شود که در ادامه‌ی این بخش معرفی می‌شوند. همین چهار زیرمسئله، با همین ترتیب، ستون‌بندی فصل‌های ۲ تا ۴ را نیز تعیین می‌کنند، به‌گونه‌ای که خواننده بتواند مسیر «مسئله، پیشینه، روش، آزمایش» را برای هر زیرمسئله به‌صورت مستقل دنبال کند.

۱-۲-۱ مرور انتقادی مجموعه‌داده‌های سی‌تی شکمی

پیش از طراحی هر راه‌حل، این پروژه با یک مرور نظام‌مند بر ۴۵ مجموعه‌داده‌ی عمومی سی‌تی شکمی آغاز شد که وضعیت اکوسیستم داده‌ی موجود را از منظر بازاستفاده، سوگیری جمعیت‌شناختی و جغرافیایی، و به‌طور مشخص کمیابی داده‌ی جفت‌شده[۱۰] میان فاز بدون‌کنتراست و کنتراست‌دار مستند می‌کند [۶].

[۸] Opportunistic screening
[۹] Contrast-to-noise ratio (CNR)
[۱۰] Paired

یافته‌های این مرور در بخش ۲-۳ به‌تفصیل ارائه می‌شود و مستقیماً انگیزه‌ی دو زیرمسئله‌ی پایانی را شکل می‌دهد: وقتی داده‌ی جفت‌شده‌ی طبیعی در دسترس نیست، یا باید فازهای موجود را پس‌پردازشی هم‌تراز کرد، یا فاز غایب را از روی فاز موجود بازسازی کرد.

۱-۲-۲ تشخیص فاز کنتراست

بهره‌برداری از هر داده‌ی چندفازی، اعم از عمومی یا خام گردآوری‌شده در این پروژه، به شناسایی صحیح فاز هر سری تصویر وابسته است. از آن‌جا که برچسب‌های سرآیند DICOM در عمل ناقص یا ناسازگارند (بخش ۲-۴)، در این پروژه یک مدل تشخیص فاز کنتراست بر روی داده‌ی خام گردآوری‌شده توسعه و ارزیابی می‌شود. این مدل، که جزئیات آن در فصل ۳ و نتایج آن در فصل ۴ ارائه می‌شود، زیرساخت عملیاتی دو زیرمسئله‌ی بعدی است.

۱-۲-۳ ثبت تصویر بین‌فازی

این پروژه یک پایپ‌لاین ثبت تصویر چندگذره[۱۱] برای هم‌ترازسازی هندسی فاز بدون‌کنتراست با فاز کنتراست‌دار طراحی و ارزیابی می‌کند. معیارهای کلاسیک اطلاعات متقابل در سطح کل تصویر تعریف می‌شوند و از همین رو در برابر تغییر ناهمگن کنتراست شکننده‌اند (بخش ۲-۵). در مقابل، پایپ‌لاین پیشنهادی از مقداردهی اولیه‌ی صلب مبتنی‌بر نشانه‌های استخوانی، گذرهای ساختاری و اطلاعات متقابل محدودشده به نقاب اندام، و پالایش نهایی غیرصلب بهره می‌گیرد تا دامنه‌ی محاسبه‌ی معیار تراز را به نواحی پایدار در برابر فاز کنتراست محدود کند. این پایپ‌لاین روی مجموعه‌داده‌ی عمومی VinDr-Multiphase [۷] ارزیابی شده است.

۱-۲-۴ سنتز فاز کنتراست‌دار از فاز بدون‌کنتراست

جفت‌های هم‌ترازشده‌ی حاصل از این ثبت تصویر سپس برای آموزش و ارزیابی مدل‌های سنتز فاز کنتراست‌دار از روی فاز بدون‌کنتراست به کار می‌روند (بخش ۲-۶). در نهایت، در این پروژه بررسی می‌شود که آیا ترکیب هم‌ترازسازی و سنتز بهبودیافته، شکاف دقت بخش‌بندی چندعضوی میان دو فاز را که در فصل ۲ مستند می‌شود، کاهش می‌دهد.

[۱۱] Multi-pass

۱-۳ چالش‌ها

پیگیری این چهار زیرمسئله در طول پروژه با چند چالش فنی مشترک همراه بود که هر یک، انتخاب‌های روشی فصل ۳ را شکل داده‌اند.

نخستین چالش، ناسازگاری فراداده است. برچسب‌های فاز کنتراست در سرآیند DICOM داده‌ی خام این پروژه، مشابه بسیاری از مجموعه‌داده‌های عمومی، ناقص یا ناسازگارند و امکان تکیه‌ی مستقیم بر آن‌ها برای آموزش یا ارزیابی وجود ندارد. همین محدودیت است که تشخیص فاز از روی محتوای تصویر را از یک گام جانبی به یک پیش‌نیاز تبدیل می‌کند.

چالش دوم به ماهیت خود تزریق ماده‌ی حاجب بازمی‌گردد: تزریق، رابطه‌ی آماری میان شدت روشنایی دو فاز را به‌شکل ناهمگن در فضا تغییر می‌دهد. عروق و پارانشیم پرخون روشن‌تر می‌شوند، در حالی که استخوان و چربی تقریباً بدون تغییر می‌مانند. این ناهمگنی، فرض بنیادین معیارهای کلاسیک ثبت تصویر مبتنی‌بر اطلاعات متقابل را نقض می‌کند و طراحی معیار تراز مقاوم را ضروری می‌سازد.

چالش سوم، کمیابی داده است. جفت طبیعی و هم‌زمان دو فاز برای یک بیمار به‌ندرت در دسترس است، و همین کمبود، هم ارزیابی دقیق ثبت تصویر و هم آموزش نظارت‌شده‌ی مدل‌های سنتز را دشوار می‌کند. سرانجام، ادبیات پژوهشی مرتبط، به‌ویژه در حوزه‌ی سنتز NC–به–CE، از ناهمگنی معیار ارزیابی و مجموعه‌داده رنج می‌برد؛ ناهمگنی‌ای که مقایسه‌ی مستقیم نتایج و انتخاب یک مبنای معتبر را دشوار می‌کند (بخش ۲-۶).

۱-۴ اهداف پژوهش

هدف کلی این پژوهش آن است که نشان دهد شکاف دقت بخش‌بندی چندعضوی میان فاز بدون‌کنتراست و کنتراست‌دار، با مداخله در سطح داده و پیش‌پردازش، و بدون بازطراحی خود مدل بخش‌بندی، تا چه اندازه قابل کاهش است. برای رسیدن به این هدف کلی، چهار زیرمسئله‌ی بخش ۱-۲ به چهار هدف عملیاتی ترجمه می‌شوند و یک هدف پنجم، اثر تجمیعی آن‌ها را می‌سنجد:

- مستندسازی نظام‌مند وضعیت سوگیری و کفایت مجموعه‌داده‌های عمومی سی‌تی شکمی، با تمرکز ویژه بر کمیابی داده‌ی جفت‌شده‌ی چندفازی، تا دامنه‌ی واقعی داده‌ی در دسترس برای دو هدف بعدی روشن شود.
- توسعه و ارزیابی مدلی برای تشخیص قابل‌اعتماد فاز کنتراست از روی محتوای خام تصویر، مستقل

از برچسب‌های ناقص سرآیند DICOM، به‌عنوان زیرساخت عملیاتی بهره‌برداری از داده‌ی چندفازی.

- طراحی یک پایپ‌لاین ثبت تصویر چندگذره که دامنه‌ی محاسبه‌ی معیار تراز را به نواحی پایدار در برابر تغییر فاز کنتراست محدود می‌کند، و ارزیابی مقایسه‌ای آن در برابر رویکردهای کلاسیک مبتنی‌بر اطلاعات متقابل.
- بهره‌گیری از جفت‌های هم‌ترازشده‌ی حاصل برای آموزش و ارزیابی مدل‌های سنتز فاز کنتراست‌دار از روی فاز بدون‌کنتراست.
- سنجش این‌که آیا ترکیب این مداخلات، شکاف دقت بخش‌بندی چندعضوی میان فاز بدون‌کنتراست و کنتراست‌دار را کاهش می‌دهد.

۱-۵ ساختار پایان‌نامه

باقی این پایان‌نامه به شرح زیر سازمان‌دهی شده است. فصل ۲ پس از یک پیش‌زمینه‌ی کوتاه بالینی درباره‌ی سی‌تی چندفازی، پیشینه‌ی پژوهشی پنج حوزه‌ی مرتبط را مرور می‌کند: بخش‌بندی چندعضوی و شکاف کیفیت فاز بدون‌کنتراست، که مسئله‌ی چتر این پایان‌نامه را تعریف می‌کند، و پس از آن چهار حوزه‌ی متناظر با چهار زیرمسئله‌ی بخش ۱-۲؛ فصل با جمع‌بندی جای خالی مشترک میان آن‌ها به پایان می‌رسد. فصل ۳ روش پیشنهادی این پایان‌نامه، شامل جزئیات مدل تشخیص فاز، پایپ‌لاین ثبت تصویر چندگذره، و مدل‌های سنتز NC→CE را ارائه می‌دهد. فصل ۴ نتایج تجربی هر یک از این سه مؤلفه، و نیز ارزیابی نهایی اثر آن‌ها بر شکاف دقت بخش‌بندی چندعضوی را گزارش می‌کند. سرانجام، فصل ۵ یافته‌های پایان‌نامه را جمع‌بندی کرده و کاستی‌ها و مسیرهای پژوهشی آتی را مطرح می‌کند.

۱-۶ جمع‌بندی

فاز بدون‌کنتراست سی‌تی شکمی، با وجود کاربرد بالینی گسترده و نقش آن به‌عنوان تنها تصویر در دسترس برای گروهی از بیماران، همچنان از افت نظام‌مند دقت بخش‌بندی چندعضوی رنج می‌برد. استدلال این فصل آن بود که ریشه‌ی این افت را نباید تنها در معماری مدل‌ها جست‌وجو کرد: کاهش کنتراست بافتی، ناسازگاری فراداده‌ی فاز، و کمیابی داده‌ی جفت‌شده‌ی چندفازی، سه عامل مستقلی‌اند که همگی پیش از مرحله‌ی مدل‌سازی عمل می‌کنند. بر همین مبنا، مسئله به چهار زیرمسئله تجزیه شد که پاسخ به آن‌ها، به‌ترتیب، در فصل‌های بعدی دنبال می‌شود.

فصل ۲

کارهای پیشین

این فصل، پیشینه‌ی پژوهشی مسئله‌ی فصل ۱ را مرور می‌کند. ساختار فصل مستقیماً از تجزیه‌ی مسئله در بخش ۱-۲ پیروی می‌کند: پس از یک پیش‌زمینه‌ی کوتاه بالینی درباره‌ی سی‌تی چندفازی (بخش ۱-۲)، که اصطلاح‌های فاز کنتراست را برای کل پایان‌نامه تثبیت می‌کند، پنج حوزه‌ی پژوهشی به‌ترتیب مرور می‌شوند.

نخستین حوزه، بخش‌بندی چندعضوی[۱] تصاویر سی‌تی شکمی و شکاف کیفیتی است که در فاز بدون‌کنتراست مشاهده می‌شود (بخش ۲-۲)؛ این حوزه به هیچ‌یک از چهار زیرمسئله به‌تنهایی متعلق نیست، بلکه مسئله‌ی چتری را تعریف می‌کند که چهار زیرمسئله در خدمت آن‌اند. چهار حوزه‌ی بعدی، دقیقاً متناظر با همان چهار زیرمسئله و با همان ترتیب‌اند: چشم‌انداز مجموعه‌داده‌های عمومی سی‌تی شکمی و ادبیات سوگیری[۲] داده (بخش ۲-۳)، تشخیص فاز کنتراست از روی محتوای خام تصویر (بخش ۲-۴)، ثبت تصویر[۳] میان فازهای مختلف (بخش ۲-۵)، و سنتز فاز کنتراست‌دار از روی تصویر بدون‌کنتراست (بخش ۲-۶).

هر بخش الگوی یکسانی دارد: ابتدا مسئله‌ی موضوعی خود را تعریف می‌کند، سپس معیارهای ارزیابی مرتبط را شرح می‌دهد، آن‌گاه کارهای پیشین را با نام مدل یا مرجع مرور و نقد می‌کند، و در پایان با جدولی خلاصه از نام مدل، سال انتشار، مقادیر گزارش‌شده و وضعیت انتشار کد جمع‌بندی می‌شود. فصل با جمع‌بندی جای خالی مشترک میان این حوزه‌ها (بخش ۲-۷) به پایان می‌رسد؛ روش‌های پیشنهادی این پایان‌نامه برای هر یک از این جاهای خالی، در فصل ۳ ارائه می‌شوند.

---

[۱] Multi-organ segmentation
[۲] Bias
[۳] Image registration

۲-۱ پیش‌زمینه‌ی بالینی: سی‌تی چندفازی و فازهای کنتراست

سی‌تی شکمی چندفازی[۴] یک بررسی تصویربرداری است که در آن، به‌جای یک اسکن واحد، چند اسکن متوالی از یک ناحیه‌ی تشریحی، در بازه‌های زمانی مشخص نسبت به تزریق وریدی ماده‌ی حاجب یددار[۵]، گرفته می‌شود. اسکن نخست، پیش از هرگونه تزریق، فاز بدون‌کنتراست نامیده می‌شود و توزیع طبیعی تضعیف اشعه‌ی ایکس[۶] بافت‌ها، بدون اثر ماده‌ی حاجب، را ثبت می‌کند. پس از تزریق، ماده‌ی حاجب به‌ترتیب از قلب به آئورت، سپس به شریان‌های احشایی، و در نهایت از طریق مویرگ‌ها به وریدها و کبد می‌رسد؛ همین توالی زمانی، پایه‌ی نام‌گذاری فازهای کنتراست‌دار است.

فاز شریانی[۷]، معمولاً ۲۵ تا ۴۰ ثانیه پس از تزریق، زمانی ثبت می‌شود که ماده‌ی حاجب عمدتاً در شریان‌ها و بافت‌های پرخون[۸] متمرکز است؛ این فاز برای آشکارسازی ضایعاتی مانند کارسینوم سلول کبدی که خون‌رسانی شریانی غالب دارند، حیاتی است. **فاز وریدی باب**[۹]، حدود ۶۰ تا ۹۰ ثانیه پس از تزریق، زمانی است که ماده‌ی حاجب پارانشیم کبد را از طریق ورید باب پر کرده و بیشترین کنتراست میان بافت‌های نرم را فراهم می‌کند؛ این فاز معمول‌ترین فاز تشخیصی برای بخش‌بندی و ارزیابی عمومی اندام‌های شکمی است. **فاز تأخیری**[۱۰]، معمولاً ۳ تا ۵ دقیقه پس از تزریق، شست‌وشوی ماده‌ی حاجب از ضایعات پرخون را نشان می‌دهد؛ الگوی افزایش کنتراست در فاز شریانی و شست‌وشوی آن در فاز تأخیری یا وریدی، معیار تشخیصی اصلی کارسینوم سلول کبدی در دستورعمل‌های بالینی مانند EASL [۱] است.

هر یک از این فازها اطلاعات تشخیصی متفاوت و مکملی را در اختیار رادیولوژیست قرار می‌دهند؛ به همین دلیل، بسیاری از پروتکل‌های بالینی به‌طور هم‌زمان چند فاز را ثبت می‌کنند و تفسیر دقیق تنها با ترکیب اطلاعات چند فاز ممکن است. با این حال، همین چندفازی‌بودن، چالش‌های محاسباتی مضاعفی به همراه دارد که موضوع اصلی این فصل‌اند: تفاوت شدت روشنایی میان فازها می‌تواند دقت مدل‌های بخش‌بندی را کاهش دهد (بخش ۲-۲)، برچسب فاز هر بررسی همیشه به‌طور قابل‌اعتماد در سرآیند تصویر ثبت نمی‌شود (بخش ۲-۴)، و جابه‌جایی بیمار میان اسکن‌های متوالی، ثبت تصویر دقیق میان فازها را ضروری می‌سازد (بخش ۲-۵).

---

[۴] Multi-phase abdominal CT
[۵] Iodinated contrast medium
[۶] X-ray attenuation
[۷] Arterial phase
[۸] Hypervascular
[۹] Portal venous phase
[۱۰] Delayed phase

۲-۲ بخش‌بندی چندعضوی سی‌تی شکمی و شکاف کیفیت در فاز بدون‌کنتراست

تعریف مسئله

بخش‌بندی چندعضوی تصاویر سی‌تی شکمی، یعنی تعیین دقیق مرزهای تشریحی اندام‌هایی مانند کبد، کلیه، طحال و پانکراس در حجم‌های سه‌بعدی، زیرساخت بسیاری از کاربردهای بالینی مبتنی‌بر هوش مصنوعی از جمله برنامه‌ریزی درمان، اندازه‌گیری حجمی و ردیابی روند بیماری است. این مسئله معمولاً به‌صورت یک وظیفه‌ی طبقه‌بندی پیکسل‌به‌پیکسل (یا وُکسل‌به‌وُکسل) فرمول‌بندی می‌شود که در آن هر وُکسل حجم سی‌تی باید به یکی از برچسب‌های تشریحی از پیش‌تعریف‌شده نسبت داده شود. چالش مرکزی این پایان‌نامه آن است که دقت این بخش‌بندی لزوماً در طول فازهای مختلف تصویربرداری یکنواخت باقی نمی‌ماند: فاز بدون‌کنتراست، به دلیل کاهش نسبت کنتراست‌به‌نویز میان بافت‌های نرم مجاور، اغلب دقت پایین‌تری نسبت به فاز کنتراست‌دار نشان می‌دهد؛ بدون تزریق ماده‌ی حاجب، تفاوت میان بافت نرم اندام‌های مجاور مانند کبد و طحال، یا میان پارانشیم اندام و عروق داخل آن، به‌مراتب کمتر از فاز کنتراست‌دار است و مرزهای تشریحی‌ای که مدل‌های بخش‌بندی برای آن‌ها آموزش دیده‌اند، در تصاویر بدون‌کنتراست کم‌رنگ‌تر یا مبهم‌تر ظاهر می‌شوند.

معیار ارزیابی

ضریب هم‌پوشانی سورنسن–دایس[۱۱]، یا به‌اختصار Dice، معیار غالب در ادبیات بخش‌بندی تصویر پزشکی است. برای دو نقاب دودویی A (پیش‌بینی مدل) و B (برچسب مرجع)، این ضریب به‌صورت $\mathrm{Dice}(A,B) = ۲|A \cap B|/(|A| + |B|)$ تعریف می‌شود و مقداری میان صفر (بدون هم‌پوشانی) و یک (هم‌پوشانی کامل) می‌گیرد. مزیت اصلی Dice نسبت به دقت پیکسلی خام، مقاومت نسبی آن در برابر عدم‌توازن حجمی میان پیش‌زمینه (اندام هدف) و پس‌زمینه است، ویژگی‌ای که در بخش‌بندی اندام‌های کوچک مانند پانکراس یا غده‌ی فوق‌کلیوی اهمیت زیادی دارد.

صدک نودوپنجم فاصله‌ی هاسدورف[۱۲] معیاری مکمل است که به خطای موضعی مرزی، برخلاف Dice، حساس است. Dice تنها میزان هم‌پوشانی حجمی را می‌سنجد و ممکن است خطای برجسته‌ی مرزی در یک ناحیه‌ی کوچک را پنهان کند؛ HD95 این کاستی را جبران می‌کند: بزرگ‌ترین فاصله‌ی

[۱۱] Sørensen–Dice coefficient
[۱۲] 95th percentile Hausdorff Distance (HD95)

باقی‌مانده میان مرز دو نقاب را، پس از حذف ۵ درصد دورافتاده‌ترین نقاط (برای کاهش حساسیت به نویز برچسب‌گذاری)، اندازه می‌گیرد. در برخی مطالعات، از انحراف حجمی[۱۳] نسبت به یک اسکن مرجع نیز به‌عنوان معیار مکمل برای سنجش تکرارپذیری[۱۴] استفاده می‌شود.

کارهای پیشین

چارچوب **nnU-Net** [۸] یک شبکه‌ی رمزگذار–رمزگشای پیچشی بر پایه‌ی معماری U-Net است که با **خودپیکربندی**[۱۵] خودکار معماری، پیش‌پردازش و آموزش بر اساس ویژگی‌های هر مجموعه‌داده، نیاز به تنظیم دستی فراپارامترها را حذف می‌کند و به یکی از پرکاربردترین مبناهای این حوزه بدل شده است. این چارچوب روی ۲۳ مجموعه‌داده‌ی عمومی از چالش‌های بین‌المللی ارزیابی شده است؛ در وظیفه‌های شکمی محک MSD [۹]، Dice آن برای طحال ۰٫۹۶، کبد ۰٫۹۳ و پانکراس ۰٫۷۹ گزارش شده است، و برای ساختارهای دشوارتر همان محک به‌مراتب پایین‌تر می‌آید: عروق کبدی ۰٫۶۳، تومور کبد ۰٫۷۴، توده‌ی پانکراس ۰٫۵۲ و سرطان روده‌ی بزرگ ۰٫۵۶. همه‌ی این ارقام روی داده‌ی فاز کنتراست‌دار به دست آمده‌اند؛ محک MSD هیچ وظیفه‌ی بدون‌کنتراستی ندارد.

TotalSegmentator [۱۰] یک مدل nnU-Net سه‌بعدی است که بر پایه‌ی چارچوب فوق و با آموزش روی ۱٬۲۰۴ بررسی سی‌تی بالینی متنوع ساخته شده و ۱۰۴ ساختار تشریحی از جمله اندام‌ها، استخوان‌ها، عضلات و عروق را بخش‌بندی می‌کند؛ این مدل Dice برابر ۰٫۹۴۳ روی مجموعه‌ی آزمون خود گزارش کرده و در عمل به ابزاری مرجع برای تولید نقاب[۱۶] اندام در پژوهش‌های بعدی تبدیل شده است. نکته‌ای که در ادامه اهمیت می‌یابد آن است که این رقم روی مجموعه‌ی آزمونی گزارش شده که از نظر فاز کنتراست ترکیبی است و مقاله هیچ تفکیک فازی از عملکرد ارائه نمی‌کند.

در کنار این چارچوب‌های عمومی، محک‌های بزرگ‌مقیاس اختصاصی شکم مانند AbdomenCT-1K [۱۱]، FLARE [۱۲] و AbdomenAtlas [۱۳]، که هر یک با گردآوری و بازبرچسب‌گذاری چند مجموعه‌داده‌ی پایه شکل گرفته‌اند، و Medical Segmentation Decathlon [۹] به‌عنوان محکی چندوظیفه‌ای، مسیر پیشرفت این حوزه را در سال‌های اخیر ترسیم کرده‌اند. این محک‌ها عمدتاً بر پایه‌ی همان معماری nnU-Net یا مشتقات آن ارزیابی می‌شوند.

رویکردهای مبتنی‌بر یادگیری چندوظیفه‌ای و پرسش‌محور[۱۷] مانند مدل جهانی هدایت‌شده با

[۱۳] Volumetric deviation
[۱۴] Reproducibility
[۱۵] Self-configuring
[۱۶] Mask
[۱۷] Prompt-driven

CLIP [۱۴]، که یک رمزگذار متن از پیش‌آموزش‌دیده را برای تولید بردار پرسش هر اندام با یک شبکه‌ی بخش‌بندی سه‌بعدی ترکیب می‌کند، نشان داده‌اند یک شبکه‌ی واحد می‌تواند هم‌زمان بخش‌بندی اندام و تشخیص تومور را در طیف وسیعی از اندام‌ها انجام دهد؛ این مدل با آموزش روی ۳,۴۱۰ بررسی سی‌تی از ۱۴ مجموعه‌داده و پوشش ۲۵ اندام و شش نوع تومور، به میانگین Dice برابر ۸۶/۱۳ درصد روی محک BTCV رسید.

یو و همکاران [۱۵] با یک nnU-Net سه‌بعدی، هشت ساختار شکمی را روی تصاویر بدون‌کنتراست[۱۸] و کنتراست‌دار[۱۹] بخش‌بندی کردند. نکته‌ی روش‌شناختی مهم در این مطالعه آن است که ضریب Dice *تنها* برای فاز کنتراست‌دار گزارش شده است (از ۰/۸۰ برای دئودنوم تا ۰/۹۷ برای طحال، روی ۳۰ بیمار آزمون)، و مقایسه‌ی میان دو فاز صرفاً به‌صورت *کیفی* و با امتیازدهی لیکرت رادیولوژیست انجام شده است: ۸۹/۳ درصد خطوط دئودنوم در فاز کنتراست‌دار در برابر ۸۵/۳ درصد در فاز بدون‌کنتراست، امتیاز سه یا بالاتر (نیازمند ویرایش جزئی) گرفتند. بنابراین این مطالعه، برخلاف آن‌چه از عنوانش برمی‌آید، شواهد کمّی مستقیمی درباره‌ی اندازه‌ی شکاف بین‌فازی به دست نمی‌دهد؛ خودِ همین نبودِ گزارش کمّی، نمونه‌ای از الگویی است که در ادامه‌ی این بخش تکرار می‌شود.

جئون و همکاران [۳] تنها مطالعه‌ی این مجموعه‌اند که شکاف بین‌فازی را به‌صورت کمّی و روی داده‌ی کنترل‌شده اندازه گرفته‌اند. آن‌ها با سی‌تی دوانرژی[۲۰] جفت‌های ذاتاً هم‌ترازِ فاز وریدی و تصویر بدون‌کنتراست مجازی[۲۱] ساختند، یک nnU-Net سه‌بعدی را روی ۷۵ بررسی آموزش دادند و آن را روی ۳۰ بررسی سی‌تی تک‌انرژی خارجی آزمودند. روی این مجموعه‌ی آزمون خارجی، Dice در فاز وریدی برای کبد، طحال، کلیه‌ی راست، کلیه‌ی چپ و پانکراس به‌ترتیب ۰/۹۸۱، ۰/۹۷۲، ۰/۹۷۱، ۰/۹۷۰ و ۰/۸۴۶ بود، و در فاز بدون‌کنتراست واقعی به ۰/۹۶۵، ۰/۹۶۱، ۰/۹۴۴، ۰/۹۵۴ و ۰/۸۱۰ کاهش یافت. الگوی این ارقام گویاست: افت بین‌فازی برای اندام‌های بزرگ و پرکنتراست تنها ۱/۶ تا ۲/۷ واحد درصد است، اما برای پانکراس——اندامی کوچک با مرز مبهم در برابر بافت چرب اطراف——به ۳/۶ واحد درصد می‌رسد. یعنی شکاف، یکنواخت نیست بلکه روی اندام‌های دشوار متمرکز است.

پارک و همکاران [۱۶]، از همان گروه پژوهشی جئون، مسیر دیگری را آزمودند: به‌جای ساختن جفت هم‌تراز، مدل را *مستقیماً و تنها* روی داده‌ی بدون‌کنتراست آموزش دادند. آن‌ها یک nnU-Net را روی ۱۰۵ بررسی سی‌تی شکمی بدون‌کنتراست و ۶۰ سی‌تی قفسه‌سینه‌ی کم‌دوز آموزش دادند و روی ۵۵ بررسی شکمی و ۱۰ بررسی قفسه‌سینه‌ی خارجی آزمودند. نتیجه چشمگیر است: Dice روی داده‌ی خارجی *بدون‌کنتراست* برای کبد ۰/۹۶۸، طحال ۰/۹۶۰، کلیه‌ی راست ۰/۹۵۲ و کلیه‌ی چپ ۰/۹۵۸ بود——

[۱۸] Non-contrast CT (NCCT)
[۱۹] Contrast-enhanced CT (CECT)
[۲۰] Dual-energy CT
[۲۱] Virtual non-contrast (VNC)

یعنی هم‌سطح با ارقامی که مدل‌های دیگر روی فاز *کنتراست‌دار* گزارش می‌کنند. اختلاف حجم برآوردشده با حجم مرجع نیز میان ۰/۷− تا ۲/۲+ درصد ماند. این یافته، مهم‌ترین قید را بر تفسیر شکاف بین‌فازی می‌گذارد: شکاف، خاصیت *ذاتی* فاز بدون‌کنتراست نیست، بلکه تا حد زیادی پیامد این است که مدل‌های مرجع روی داده‌ی کنتراست‌دار آموزش دیده‌اند و در فاز بدون‌کنتراست دچار جابه‌جایی حوزه می‌شوند. با داده‌ی آموزشی متناسب، بخش عمده‌ی شکاف بسته می‌شود. محدودیت این راه‌حل اما دقیقاً همان چیزی است که بخش ۲-۳ مستند می‌کند: داده‌ی بدون‌کنتراستِ برچسب‌خورده به‌اندازه‌ی کافی وجود ندارد، و برچسب‌گذاری دستی آن به‌مراتب دشوارتر از فاز کنتراست‌دار است.

آبل و همکاران [۴] به‌جای دقت مطلق، *ثبات* خروجی را سنجیدند: آن‌ها ۳٫۷۵۶ سری سی‌تی را که هر بیمار در سه فاز شریانی، وریدی و بدون‌کنتراست داشت به TotalSegmentator دادند و انحراف حجمی هر ساختار را میان فازها اندازه گرفتند. ۲۹ ساختار از ۳۴ ساختار، انحراف حجمی کمتر از ۵ درصد نشان دادند و بنابراین تکرارپذیر تلقی شدند؛ تنها اندام‌های معدودی مانند غده‌ی فوق‌کلیوی، کیسه‌ی صفرا، طحال و دئودنوم به **جابه‌جایی حوزه‌ای**[۲۲] وابسته به فاز و پروتکل حساس‌تر بودند. این مطالعه از منظر پایان‌نامه‌ی حاضر دو پیام دارد: نخست آن‌که تغییر فاز، خروجی یک ابزار ثابت را به‌طور نظام‌مند جابه‌جا می‌کند؛ و دوم آن‌که این جابه‌جایی، مانند یافته‌ی جئون، روی زیرمجموعه‌ی کوچکی از ساختارها متمرکز است.

ژو و همکاران [۵] چارچوب **CKAP-Net** را پیشنهاد دادند که یک ماژول تزریق دانش کنتراست و یک شاخه‌ی ادراک تشریحی چندمقیاسی را برای سنتز اطلاعات کنتراست از روی تصویر بدون‌کنتراست، پیش از بخش‌بندی، ترکیب می‌کند؛ این مدل به ضریب Dice حدود ۸۱/۲۱ درصد در بخش‌بندی چندعضوی روی مجموعه‌داده‌های چندمرکزی رسید، رقمی که فاصله‌ی چندانی با دقت متداول بخش‌بندی روی فاز کنتراست‌دار ندارد.

جدول ۲-۱ این مطالعات را کنار هم می‌گذارد. ساختار جدول عمداً دو ستون عددی مجزا برای Dice در فاز کنتراست‌دار و Dice در فاز بدون‌کنتراست دارد، و خالی‌بودن گسترده‌ی ستون دوم، خود مهم‌ترین یافته‌ی این بخش است: از میان مدل‌های مرجع این حوزه، هیچ‌یک عملکرد خود را به‌تفکیک فاز کنتراست گزارش نکرده‌اند. تنها دو مطالعه عددی برای فاز بدون‌کنتراست دارند——جئون و همکاران [۳] که جفت‌های هم‌تراز از سی‌تی دوانرژی ساختند، و CKAP-Net [۵] که کنتراست را پیش از بخش‌بندی سنتز می‌کند——و هر دو، برای به‌دست‌آوردن این عدد، ناچار شده‌اند داده‌ی جفت‌شده‌ی خود را بسازند.

مجموع این شواهد سه نکته را تثبیت می‌کند. شکاف بین‌فازی *وجود دارد* اما یکنواخت نیست: روی اندام‌های بزرگ و پرکنتراست تنها یکی دو واحد درصد و روی اندام‌های کوچک و کم‌مرز مانند پانکراس چند برابر آن است. شکاف *ذاتی نیست*: نتیجه‌ی پارک و همکاران [۱۶] نشان می‌دهد با داده‌ی آموزشی

[۲۲] Domain shift

متناسب، بخش عمده‌ی آن بسته می‌شود. و سرانجام، همین راه‌حل به محدودیت داده برمی‌خورد؛ ادبیات پژوهشی دو راهبرد مکمل برای جبران این افت پیشنهاد داده است که در بخش‌های ۲-۵ و ۲-۶ همین فصل مرور می‌شوند: هم‌ترازسازی هندسی فاز بدون‌کنتراست با فاز کنتراست‌دار از طریق ثبت تصویر، و سنتز مستقیم اطلاعات کنتراست از روی تصویر بدون‌کنتراست.

جدول ۲-۱: مدل‌های بخش‌بندی و مطالعات شکاف بین‌فازی. ستون «فاز داده‌ی آموزش» نشان می‌دهد مدل با کدام فاز(ها) آموزش دیده است؛ کنار هم گذاشتن آن با دو ستون Dice، نشان می‌دهد شکاف بین‌فازی عمدتاً پیامد ترکیب داده‌ی آموزش است، نه خاصیت ذاتی فاز بدون‌کنتراست.

روش (مرجع)	سال	وظیفه و اندام	فاز داده‌ی آموزش	Dice فاز کنتراست‌دار	Dice فاز بدون‌کنتراست	کد
nnU-Net [۸]	۲۰۲۱	بخش‌بندی چندعضوی و توموری؛ ۲۳ محک عمومی	کنتراست‌دار	اندام: ۰٫۷۹–۰٫۹۶ تومور: ۰٫۵۲–۰٫۷۴ (الف)	—	✓
TotalSegmentator [۱۰]	۲۰۲۳	بخش‌بندی ۱۰۴ ساختار تشریحی کل‌بدن	ترکیبی، تفکیک‌نشده	۰٫۹۴۳ (ب)	—	✓
CLIP-driven Universal Model [۱۴]	۲۰۲۳	بخش‌بندی ۲۵ اندام + تشخیص شش نوع تومور	کنتراست‌دار	۰٫۸۶۱ (BTCV)	—	✓
یو و همکاران [۱۵]	۲۰۲۲	بخش‌بندی هشت ساختار شکمی (شامل روده)	هر دو فاز	۰٫۸۰–۰٫۹۷	گزارش‌نشده (پ)	×
جئون و همکاران [۳]	۲۰۲۴	بخش‌بندی کبد، طحال، دو کلیه و پانکراس	هر دو فاز (DECT)	DECT: ۰٫۸۷۳–۰٫۹۸۶ SECT: ۰٫۸۴۶–۰٫۹۸۱	VNC: ۰٫۸۵۴–۰٫۹۷۷ واقعی: ۰٫۸۱۰–۰٫۹۶۵	×
پارک و همکاران [۱۶]	۲۰۲۵	بخش‌بندی کبد، طحال و دو کلیه برای حجم‌سنجی و رادیومیکس	**فقط بدون‌کنتراست**	—	شکمی: ۰٫۹۵۲–۰٫۹۶۸ قفسه‌سینه: ۰٫۹۶۰–۰٫۹۶۹	×
آبل و همکاران [۴]	۲۰۲۵	سنجش تکرارپذیری بین‌فازی TotalSegmentator	بدون آموزش (فقط استنتاج)	— (ت)	— (ت)	×
CKAP-Net [۵]	۲۰۲۴	سنتز کنتراست + بخش‌بندی چندعضوی پایین‌دستی	هر دو فاز (جفت‌شده)	—	۰٫۸۱۲	×

یادداشت‌ها: علامت ✓یعنی کد منبع به‌طور تأییدشده در دسترس عمومی است و ×یعنی کد منتشر نشده یا وضعیت آن در مقاله ذکر نشده است. **(الف)** ارقام مربوط به وظیفه‌های شکمی محک MSD [۹]: طحال ۰٫۹۶، کبد ۰٫۹۳، پانکراس ۰٫۷۹؛ و برای تومور: تومور کبد ۰٫۷۴، عروق کبدی ۰٫۶۳، توده‌ی پانکراس ۰٫۵۲، سرطان روده‌ی بزرگ ۰٫۵۶. مقاله‌ی اصلی nnU-Net خودْ عدد واحدی گزارش نمی‌کند. **(ب)** مجموعه‌ی آزمون از نظر فاز کنتراست ترکیبی است و مقاله تفکیک فازی ارائه نمی‌دهد؛ این عدد میانگینی روی هر دو فاز است و تنها به‌عنوان نقطه‌ی مرجع سمت کنتراست‌دار آورده شده. **(پ)** مقایسه‌ی دو فاز تنها به‌صورت کیفی و با امتیاز لیکرت گزارش شده است: ۸۹٫۳ درصد در برابر ۸۵٫۳ درصد خطوط دئودنوم با امتیاز سه یا بالاتر. **(ت)** معیار این مطالعه Dice نیست بلکه انحراف حجمی میان سه فاز است: ۲۹ ساختار از ۳۴ ساختار، انحراف کمتر از ۵ درصد داشتند.

۲-۳ مجموعه‌داده‌های عمومی سی‌تی شکمی و مسئله‌ی سوگیری داده

بخش پیشین نشان داد سقف عملکرد مدل‌های بخش‌بندی در فاز بدون‌کنتراست، بیش از آن‌که به معماری وابسته باشد، به ترکیب فازیِ داده‌ی آموزش وابسته است. این مشاهده، پرسش را یک سطح عقب‌تر می‌برد: داده‌ی عمومی موجود در این حوزه چیست، چگونه ساخته شده، و چه محدودیت‌هایی را به هر مدلی که روی آن آموزش ببیند تحمیل می‌کند؟ این بخش، پیشینه‌ی پژوهشی همین پرسش را مرور می‌کند.

چشم‌انداز مجموعه‌داده‌های عمومی

ادبیات بخش‌بندی سی‌تی شکمی حول شمار محدودی از مجموعه‌داده‌های پایه شکل گرفته است. LiTS [۱۷] (تومور کبدی)، KiTS [۱۸] (تومور کلیه)، Pancreas-CT و BTCV (بخش‌بندی چندعضوی) در عمل نقش مجموعه‌داده‌های *مادر* این حوزه را ایفا می‌کنند. نسل بعدی منابع، عمدتاً از گردآوری، ادغام و بازبرچسب‌گذاری همین مجموعه‌ها ساخته شده‌اند: AbdomenCT-1K [۱۱]، FLARE [۱۲] و AbdomenAtlas 1.1 [۱۳] هر سه ترکیبی‌اند، و Medical Segmentation Decathlon [۹] چند وظیفه‌ی شکمی خود را از همین منابع برداشته است. در کنار این‌ها، مجموعه‌داده‌های اصیل متأخرتری مانند AMOS22 [۱۹]، WORD [۲۰] و مجموعه‌ی منتشرشده همراه با TotalSegmentator [۱۰] به این چشم‌انداز افزوده شده‌اند.

این ساختار درختی—تعداد کمی ریشه و شمار زیادی شاخه—دو پیامد دارد که در ادبیات به آن‌ها اشاره شده است. نخست، **نشت داده**[۲۳]: وقتی یک بیمار هم‌زمان در مجموعه‌ی آموزش یک پژوهش و مجموعه‌ی ارزیابی پژوهش دیگری حاضر است، ارقام گزارش‌شده خوش‌بینانه‌اند. دوم، **تمرکز محک**[۲۴]: کخ و همکاران [۲۱] نشان دادند در یادگیری ماشین، استفاده از مجموعه‌داده‌ها به‌مرور روی شمار اندکی از منابع پرارجاع متمرکز می‌شود، و واروکو و شولام [۲۲] همین الگو را به‌طور خاص در تصویربرداری پزشکی مستند کرده‌اند.

سوگیری داده در هوش مصنوعی پزشکی

مسئله‌ی سوگیری مجموعه‌داده در تصویربرداری پزشکی، پیشینه‌ی مستقلی دارد. اوبرمایر و همکاران [۲۳] سوگیری نژادی را در یک الگوریتم پرکاربرد تخصیص مراقبت سلامت نشان دادند؛ لاراسابال و همکاران [۲۴] نشان دادند عدم‌توازن جنسیتی در داده‌ی آموزش، مستقیماً به افت عملکرد در جنسیت

[۲۳] Data leakage
[۲۴] Benchmark concentration

کم‌نماینده ترجمه می‌شود؛ و کوشال و همکاران [۲۵] تمرکز جغرافیایی داده‌های آموزشی الگوریتم‌های بالینی در آمریکا را کمّی کردند. در سطح وجهیت‌های خاص، سیدکلانتری و همکاران [۲۶] *کم‌تشخیصی* نظام‌مند در جمعیت‌های محروم را در رادیوگرافی قفسه‌ی سینه و دانشجو و همکاران [۲۷] همان الگو را در پوست‌شناسی مستند کردند. جونز و همکاران [۲۸] این یافته‌های پراکنده را در یک چارچوب علّی جمع کردند و نشان دادند سوگیری، نقصی موضعی در یک منبع نیست بلکه در طول *چرخه‌ی حیات داده* انباشته می‌شود.

نکته‌ی مشترک و تعیین‌کننده‌ی این ادبیات آن است که تقریباً همه‌ی این مطالعات، سوگیری را در *خروجی مدل* می‌سنجند—یعنی پس از آن‌که آموزش، هر تحریفی را که داده در خود داشته جذب کرده است [۲۹، ۳۰]. خودِ مجموعه‌داده‌ها، به‌عنوان منابع بالادستی‌ای که تعیین می‌کنند مدل چه سوگیری‌هایی را می‌تواند به ارث ببرد، به‌مراتب کمتر بررسی شده‌اند.

ابزارهای ارزیابی کیفیت و شکاف موجود

برای ارزیابی کیفیت منابع پژوهشی، ابزارهای متعددی توسعه یافته‌اند، اما هیچ‌یک مستقیماً برای مجموعه‌داده‌های تصویربرداری پزشکی در نقش *منبع آموزش هوش مصنوعی* طراحی نشده است. PROBAST+AI [۳۱] ریسک سوگیری *مدل‌های پیش‌بین* را ارزیابی می‌کند نه داده را؛ TRIPOD+AI [۳۲] یک راهنمای *گزارش‌دهی* برای مطالعات تشخیصی و پیش‌آگهی مبتنی‌بر هوش مصنوعی است؛ و معیارهای کیفیت پیشنهادی کوچاک و همکاران [۲۹] به مجموعه‌داده‌های تصویربرداری می‌پردازند اما به‌صورت چک‌لیستی عملیاتی با درجه‌بندی ریسک تدوین نشده‌اند.

نتیجه آن است که، تا زمان نگارش این پایان‌نامه، **هیچ مرور نظام‌مندی وجود ندارد** که به‌طور هم‌زمان ترکیب جمعیت‌شناختی، شیوه‌ی برچسب‌گذاری، پوشش اندام و آسیب‌شناسی، و الگوی بازاستفاده‌ی مجموعه‌داده‌های عمومی سی‌تی شکمی را ارزیابی کرده باشد. به‌طور مشخص‌تر و از منظر این پایان‌نامه، هیچ منبع منتشرشده‌ای گزارش نکرده است که *چند مجموعه‌داده‌ی عمومی سی‌تی شکمی، هم‌زمان فاز بدون‌کنتراست و فاز کنتراست‌دار را در بر می‌گیرند*—رقمی که سقف داده‌ی در دسترس برای هر کار ثبت تصویر یا سنتز بین‌فازی را تعیین می‌کند.

پرکردن همین شکاف، نخستین مشارکت این پایان‌نامه است. پروتکل مرور نظام‌مند و چارچوب هفت‌مقوله‌ای ارزیابی ریسک سوگیری که برای این منظور تدوین شد، در بخش ۳-۲ فصل ۳ تشریح می‌شود، و یافته‌های کمّی آن در بخش ۴-۱ فصل ۴ گزارش می‌شود [۶]. سه یافته‌ی آن مرور مستقیماً به بخش‌های بعدی همین فصل گره می‌خورند و اینجا تنها به‌عنوان پیش‌فرض کاری معرفی می‌شوند:

بازاستفاده‌ی گسترده‌ی موارد میان مجموعه‌داده‌ها، تمرکز جغرافیایی شدید در آمریکای شمالی و اروپا، و——مهم‌تر از همه برای این پایان‌نامه——کمیابی داده‌ی چندفازی جفت‌شده.

همین کمیابیِ آخر است که ساختار سه بخش بعدی را تعیین می‌کند. وقتی داده‌ی جفت‌شده‌ی طبیعی در دسترس نیست، سه مسئله‌ی پیاپی پدید می‌آید: باید تشخیص داد هر سری متعلق به کدام فاز است (بخش ۲-۴)، باید فازهای موجود را به‌صورت پس‌پردازشی هم‌تراز کرد (بخش ۲-۵)، و باید فاز غایب را از روی فاز موجود بازسازی کرد (بخش ۲-۶).

۲-۴ تشخیص فاز کنتراست در تصاویر سی‌تی خام

تعریف مسئله

بخش پیشین نشان داد داده‌ی چندفازیِ در دسترس محدود است؛ اما پیش از آن‌که بتوان از همین داده‌ی محدود بهره برد، مسئله‌ی ساده‌تری باید حل شود: باید دانست هر سری تصویر متعلق به کدام فاز است. این مسئله بدیهی به نظر می‌رسد اما نیست: برچسب‌های موجود در سرآیند DICOM (مانند SeriesDescription) اغلب ناقص، ناسازگار میان مراکز، یا کاملاً غایب‌اند [۳۳]، که استخراج خودکار و قابل‌اعتماد فاز را از روی محتوای تصویر ضروری می‌سازد. ادبیات این حوزه سه شیوه‌ی صورت‌بندی متمایز دارد که در ادامه به همین ترتیب مرور می‌شوند. **رویکرد نخست** تصویر را ابتدا با یک مدل بخش‌بندی از پیش‌آموزش‌دیده به نواحی تشریحی می‌شکند، از هر ناحیه آمار شدت روشنایی استخراج می‌کند و طبقه‌بندی را به یک مدل یادگیری ماشین کلاسیک——عملاً همیشه یک جنگل درختان تقویت‌شده——می‌سپارد. **رویکرد دوم** این میانجی را حذف می‌کند و فاز را مستقیماً از پیکسل‌های تصویر با یک شبکه‌ی پیچشی طبقه‌بندی می‌کند. **رویکرد سوم**، که تنها یک نماینده دارد، اساساً مسئله را طبقه‌بندی نمی‌داند بلکه آن را به رگرسیون زمان سپری‌شده از تزریق تبدیل می‌کند. تفاوت این سه، صرفاً معماری نیست: هر کدام پیش‌نیاز داده‌ای و نقطه‌ی شکست متفاوتی دارند، و همین تفاوت است که در انتهای بخش به انتخاب روش فصل ۳ می‌انجامد.

معیار ارزیابی

دقت[۲۵] ساده‌ترین و پرکاربردترین معیار در ادبیات تشخیص فاز کنتراست است: نسبت پیش‌بینی‌های درست به کل نمونه‌ها. این معیار زمانی گویاست که کلاس‌های فاز (بدون‌کنتراست، شریانی، وریدی، تأخیری)

[۲۵] Accuracy

تقریباً متوازن باشند؛ در غیر این صورت، یک طبقه‌بند ساده که همیشه پرتکرارترین کلاس را پیش‌بینی می‌کند نیز می‌تواند دقت ظاهراً بالایی کسب کند.

F1 میانگین هارمونیک دقت‌مثبت[۲۶] و بازخوانی[۲۷] است و تصویر متعادل‌تری از عملکرد طبقه‌بند در هر کلاس، به‌ویژه در حضور عدم‌توازن کلاسی، ارائه می‌دهد؛ به همین دلیل، در بیشتر مطالعات این حوزه به‌جای دقت خام، F1 به‌ازای هر کلاس فاز گزارش می‌شود.

AUC (مساحت زیر منحنی مشخصه‌ی عملکرد سیستم[۲۸]) حساسیت طبقه‌بند را در تمام آستانه‌های ممکن تصمیم‌گیری خلاصه می‌کند و بنابراین، برخلاف دقت و F1، مستقل از انتخاب یک آستانه‌ی خاص است؛ این معیار به‌ویژه برای مقایسه‌ی طبقه‌بندهایی که آستانه‌ی تصمیم متفاوتی دارند، یا در ارزیابی‌های چندکلاسه به‌صورت یک‌درمقابل‌بقیه[۲۹]، پرکاربرد است.

کارهای پیشین

رویکرد نخست را سه مطالعه نمایندگی می‌کنند که هر سه ساختار یکسانی دارند: بخش‌بندی، استخراج ویژگی ناحیه‌ای، طبقه‌بند درختی.

هو و همکاران [۳۴]، در چارچوبی موسوم به **Segment-and-Classify**، ابتدا اندام‌های مرتبط با کنتراست (آئورت، ورید باب، ورید اجوف تحتانی، کلیه‌ها و غیره؛ در مجموع شانزده ساختار) را با TotalSegmentator [۱۰] مشخص کردند، سپس میانگین HU هر اندام را به‌عنوان بردار ویژگی به یک طبقه‌بند **XGBoost** (جنگل درختان تقویت‌شده‌ی گرادیانی[۳۰]) دادند؛ این طبقه‌بند به‌طور ذاتی می‌تواند اندام‌های غایب (مثلاً خارج از میدان دید) را از طریق مکانیزم بومی XGBoost برای داده‌ی گمشده مدیریت کند. مدل تنها روی WAW-TACE آموزش دید و سپس، بدون هیچ تنظیم‌دقیقی، روی دو مجموعه‌داده‌ی عمومی دیگر آزموده شد. روی VinDr-Multiphase، F1 به‌ازای فازهای بدون‌کنتراست، شریانی، وریدی و تأخیری به‌ترتیب ۰/۹۹۴، ۰/۹۳۷، ۰/۸۹۸ و ۰/۷۱۸ بود و AUC در هیچ فازی از ۰/۹۳۷ پایین‌تر نیامد؛ روی C4KC-KiTS، F1 برای بدون‌کنتراست، شریانی/وریدی و تأخیری به‌ترتیب ۰/۹۸۵، ۰/۹۶۸ و ۰/۹۳۵ و کمینه‌ی AUC برابر ۰/۹۹۱ بود. الگوی این ارقام قابل‌توجه است: افت عملکرد تقریباً به‌طور کامل روی فاز تأخیری متمرکز است، همان فازی که—چنان‌که در ادامه‌ی همین بخش می‌آید—مجموعه‌داده‌های مختلف حتی بر سر نام‌گذاری‌اش توافق ندارند. برای مقایسه، سه شبکه‌ی پیچشی سه‌بعدی (ResNet3D-

[۲۶] Precision
[۲۷] Recall
[۲۸] Receiver Operating Characteristic curve (ROC)
[۲۹] One-vs-rest
[۳۰] Gradient-boosted decision trees

18، MC3-18، R(2+1)D-18) نیز روی همین وظیفه آموزش داده شدند و XGBoost در عین دقت بالا، به‌مراتب کاراتر از این شبکه‌های سه‌بعدی بود.

ریس و همکاران [۳۵] رویکرد مشابهی، اما با تأکید بر تفسیرپذیری، ارائه کردند: پس از بخش‌بندی با TotalSegmentator، ۴۸ ویژگی رادیومیک (آمار شدت روشنایی) از پنج ساختار تشریحی استخراج و به یک طبقه‌بند **XGBoost** داده شد که تفاوت‌های الگوی افزایش کنتراست کلیوی و عروقی را به‌طور مستقیم قابل‌تفسیر می‌کند. مدل روی ۷۳۹ بررسی چندفازی شکمی از ۲۰۰ بیمار (استنفورد، ۲۰۱۶—۲۰۲۱) آموزش دید. روی مجموعه‌ی آزمون درون‌سازمانی به دقت ۹۲/۳ درصد و میانگین F1 برابر ۹۰/۷ درصد رسید، اما روی داده‌ی خارجی VinDr-Multiphase دقت به ۹۰/۱ درصد و میانگین F1 به ۸۲/۶ درصد کاهش یافت—افتی هشت‌واحدی در F1 که تنها با عبور از یک مرکز به مرکز دیگر رخ می‌دهد.

بالدینی و همکاران [۳۶] همین رویکرد را به پنج فاز (با افزودن فاز شریان ریوی و فاز اورگرافیک) گسترش دادند و تشخیص ماده‌ی حاجب خوراکی در دستگاه گوارش را نیز به آن افزودند. با آموزش روی ۱,۲۰۰ بررسی درون‌سازمانی و ارزیابی روی ۲۴۰ بررسی خارجی چندمرکزی، AUC درون‌سازمانی میان ۹۹/۱۳ درصد (فاز شریانی) و ۹۹/۸ درصد (فاز وریدی) و AUC برون‌سازمانی برابر ۹۷/۳ درصد گزارش شد. این مطالعه نشان می‌دهد افزودن فازهای بیشتر لزوماً مسئله را دشوارتر نمی‌کند؛ آن‌چه دشوار است، عبور از مرز سازمان است.

هر سه مطالعه‌ی بالا یک ضعف مشترک دارند که در جمع‌بندی بخش به آن بازمی‌گردیم: پیش از آن‌که بتوانند فاز را تشخیص دهند، به یک مدل بخش‌بندی اندام نیاز دارند که خود آموزش‌دیده است. رویکرد دوم دقیقاً همین وابستگی را حذف می‌کند.

یی و همکاران [۳۷] فاز را مستقیماً و بدون میانجی بخش‌بندی آناتومیک، با طبقه‌بندی برش‌های محوری دوبعدی و تجمیع پیش‌بینی‌ها به سطح کل بررسی، تشخیص دادند. از میان پنج معماری پیچشی آزموده‌شده (از جمله InceptionV3 و ResNet101-v2)، بهترین عملکرد از آن **EfficientNet-B4** (شبکه‌ی پیچشی با مقیاس‌پذیری ترکیبی عمق/عرض/تفکیک‌پذیری[۳۱]) بود که روی ۱,۹۷۹ بررسی سی‌تی سر و گردن (۱۳۳,۴۸۰ برش محوری) بیماران سرطانی آموزش داده شد. این مدل AUC برابر ۰/۹۹۶ (درون‌سازمانی) و ۱/۰۰ (خارجی، ۵۹۵ بررسی) به دست آورد؛ پس از تنظیم‌دقیق روی مجموعه‌ای کوچک‌تر از سی‌تی قفسه‌سینه، به AUC ۱/۰۰ (درون‌سازمانی) و ۰/۹۸۰ (خارجی، ۴۰۲ بررسی) رسید.

دائو و همکاران [۳۸] با یک **شبکه‌ی پیچشی برش‌محور** و نمونه‌برداری تصادفی از ۲۰ تا ۳۰ درصد برش‌های هر اسکن به همراه رأی‌گیری اکثریت میان آن‌ها، هزینه‌ی محاسباتی استنتاج را کاهش دادند. مدل روی ۸۳۰ بررسی چندفازی شکمی (۲۷۱,۴۲۶ برش) آموزش و روی ۳۵۸ بررسی داخلی ارزیابی شد و

[۳۱] Compound scaling

F1 برابر ۹۲/۱ درصد به دست آورد؛ در ارزیابی برونی روی CPTAC-CCRCC (۲۴۲ بررسی عمومی سرطان کلیه) و LiTS (۱۳۱ بررسی تومور کبدی) این رقم به‌ترتیب به ۷۶/۸ و ۸۶/۹ درصد کاهش یافت، هرچند همچنان از یک مبنای ResNet18 سه‌بعدی هم در سرعت و هم در دقت پیشی گرفت.

روچا و همکاران [۳۹] با یک شبکه‌ی پیچشی سفارشی، پیش‌بینی سطح برش را به سطح حجم و سپس سطح کل بررسی تجمیع کردند و به دقت ۹۴/۶ درصد (برش)، ۹۸ درصد (حجم) و ۱۰۰ درصد (کل بررسی) دست یافتند.

لیو و همکاران [۴۰] یک استراتژی **دومرحله‌ای** با ستون فقرات **ResNet-18** اشتراکی[۳۲] پیشنهاد دادند: تصاویر سه فاز یک بیمار به‌طور موازی به جریان‌های ResNet با پارامتر مشترک داده می‌شوند و یک ماژول توجه بین‌فازی[۳۳] میان آن‌ها تبادل ویژگی برقرار می‌کند. راهبرد نخست، طبقه‌بندی تک‌مرحله‌ای چهارکلاسه (شریانی زودرس/دیررس، وریدی باب، تأخیری) بود؛ راهبرد دوم، طبقه‌بندی را به دو مرحله شکست: ابتدا شریانی در برابر وریدی در برابر تأخیری، سپس در صورت شریانی‌بودن، یک زیرشبکه فاز را به زودرس یا دیررس تفکیک می‌کرد. مدل با زیان کانونی[۳۴] برای مقابله با عدم‌توازن کلاسی، روی ۱٫۱۷۵ بررسی کنتراست‌دار شکمی (یک بیمارستان) آموزش و روی ۲۱۵ بررسی خارجی از پنج بیمارستان دیگر ارزیابی شد؛ داده فاقد فاز بدون‌کنتراست بود. دقت درون‌سازمانی با مدل دومرحله‌ای به ۹۸/۳ درصد رسید (در برابر ۹۱/۷ درصد برای مدل تک‌مرحله‌ای چهارکلاسه)؛ دقت کلی روی داده‌ی خارجی ۹۹/۱ درصد بود و حساسیت به‌تفکیک فاز میان ۹۵/۱ درصد (شریانی زودرس) و ۹۹/۵ درصد (وریدی باب و تأخیری) قرار داشت.

آناند و همکاران [۴۱] برچسب‌های ضعیف[۳۵] را مستقیماً از سرآیند DICOM و نام فایل استخراج کردند تا نیاز به حاشیه‌نویسی دستی را دور بزنند، هرچند این روش برچسب‌هایی نویزی و گاه نادرست تولید می‌کند. با انتخاب هر برش دهم (به دلیل افزونگی اطلاعات میان برش‌های مجاور)، ۳۹۵ بررسی برای توازن پنج فاز انتخاب و ۲٫۷۱۹ برش برای آموزش و ۶۸۹ برش برای اعتبارسنجی به دست آمد؛ آموزش نهایی روی زیرمجموعه‌ای کوچک از ۳۱۶ بررسی با برچسب ضعیف انجام شد. سه معماری **ResNet34**، VGG19 و DenseNet121 مقایسه شدند و شبکه‌ی باقیمانده (ResNet34) با دقت ۹۹ درصد روی همین مجموعه‌داده‌ی کوچک و ضعیف‌برچسب، بهترین عملکرد را نشان داد.

رویکرد سوم تنها یک نماینده دارد و ارزش آن بیش از عدد گزارش‌شده‌اش، در بازتعریف مسئله است. محمدرحیموف و همکاران [۳۳]، با استفاده از ۸۲٫۶۹۰ بررسی سی‌تی از ۱۷ مرکز، به‌جای طبقه‌بندی به

[۳۲] Shared-weight
[۳۳] Inter-phase attention
[۳۴] Focal loss
[۳۵] Weak labels

کلاس‌های گسسته، *زمان سپری‌شده از تزریق* را به‌صورت یک کمیت پیوسته رگرسیون کردند. مزیت این صورت‌بندی آن است که مرزهای فاز دیگر تعریف‌های قراردادی نیستند بلکه آستانه‌هایی روی یک محور پیوسته‌اند؛ در نتیجه مدل می‌تواند فاز شریانی زودرس را از دیررس تفکیک کند و حتی فاز میانی‌ای را که در تقسیم‌بندی متعارف جایی ندارد شناسایی کند. دقت روی سی‌تی شکمی ۹۳/۳ درصد بود، و پس از تنظیم‌دقیق با تنها ۱۰۰ نمونه‌ی برچسب‌خورده، AUC روی سی‌تی قفسه‌سینه از ۰/۷۷۶ به ۰/۹۹۹ جهش کرد——شاهدی بر این‌که افت برون‌حوزه‌ای در این مسئله عمدتاً یک مسئله‌ی کالیبراسیون است، نه یک مسئله‌ی بازنمایی.

سه مطالعه‌ی رویکرد نخست ([۳۴، ۳۵، ۳۶]) یک وابستگی مشترک دارند: بخش‌بندی اندام با یک مدل از پیش‌آموزش‌دیده، عملاً همیشه TotalSegmentator. از میان تمام نه مطالعه‌ی این پیمایش، تنها چهار مورد کد منبع خود را منتشر کرده‌اند (جدول ۲-۲): دو مورد از رویکرد نخست ([۳۴، ۳۵]) و دو مورد از رویکرد دوم ([۳۷، ۳۸]). سه مجموعه‌داده در این پیمایش پرکاربردترین‌اند: WAW-TACE [۴۲] (۲۳۳ بیمار، ۸۵۴ بررسی چندفازی کبدی)، VinDr-Multiphase [۷] (۲۶۵ بیمار، ۱٫۱۸۸ بررسی)، و C4KC-KiTS [۴۳] (۲۱۰ بیمار، ۴۰۸ بررسی، بدون فاز وریدی). این سه مجموعه در پوشش تشریحی (شکم، شکم_لگن، قفسه‌سینه_شکم_لگن) و در نام‌گذاری فاز تأخیری (که در VinDr-Multiphase با برچسب "Other" و در C4KC-KiTS با برچسب "Late" ثبت شده) ناهمگن‌اند؛ ناهمگنی‌ای که ارزیابی جامعیت مدل‌های تشخیص فاز را ضروری می‌سازد.

جدول ۲-۲ این نه مطالعه را کنار هم می‌گذارد. ستون «رویکرد» جایگاه هر مطالعه را در سه‌بندی بالا مشخص می‌کند، و «معیار اصلی» نشان می‌دهد هر مطالعه ادعای برتری خود را روی کدام سنجه بنا کرده است——نکته‌ای که بدون آن، مقایسه‌ی ستون‌های عددی گمراه‌کننده می‌شود، چون مطالعه‌ای که AUC گزارش می‌کند و مطالعه‌ای که F1 گزارش می‌کند عملاً دو چیز متفاوت را بهینه کرده‌اند. مهم‌ترین ویژگی این جدول، تفکیک ستون‌های ارزیابی **درون‌سازمانی** از **برون‌سازمانی** است: تنها با کنار هم گذاشتن این دو ستون است که الگوی مرکزی این ادبیات دیده می‌شود.

جدول ۲-۲: مدل‌های تشخیص فاز کنتراست. ستون «معیار اصلی» سنجه‌ای است که مطالعه ادعای خود را بر آن بنا کرده؛ ستون‌های درون‌سازمانی و برون‌سازمانی عمداً از هم جدا شده‌اند تا افت تعمیم‌پذیری دیده شود.

روش	مرجع	سال	رویکرد	داده‌ی آموزش / ارزیابی	معیار اصلی	درون‌سازمانی	برون‌سازمانی	کد باز؟
Segment-and-Classify	[۳۴]	۲۰۲۵	یکم	آموزش: WAW-TACE؛ ارزیابی: C4KC-KiTS ،VinDr	F1	— (الف)	۰٫۷۱۸–۰٫۹۹۴	بله
Interpretable XGBoost	[۳۵]	۲۰۲۴	یکم	آموزش: شخصی (استنفورد، ۷۳۹ بررسی)؛ ارزیابی: VinDr	F1	۹۰٫۷	۸۲٫۶	بله
5-Phase Tree Classifier	[۳۶]	۲۰۲۴	یکم	آموزش: شخصی (۱,۲۰۰ بررسی)؛ ارزیابی: ۲۴۰ بررسی چندمرکزی	AUC	۹۹٫۱۳–۹۹٫۸	۹۷٫۳	گزارش‌نشده
EfficientNet-B4	[۳۷]	۲۰۲۲	دوم	۱,۹۷۹ بررسی سر/گردن (۱۳۳,۴۸۰ برش)؛ تنظیم‌دقیق روی قفسه‌سینه	AUC	۰٫۹۹۶	۰٫۹۸۰–۱٫۰۰ (ب)	بله
Random-Sampling CNN	[۳۸]	۲۰۲۲	دوم	آموزش: ۸۳۰ بررسی؛ ارزیابی: CPTAC-CCRCC ،LiTS	F1	۹۲٫۰۹	۷۶٫۷۹–۸۶٫۹۴	بله
Hierarchical CNN	[۳۹]	۲۰۲۲	دوم	شخصی (HCFMUSP)؛ بدون ارزیابی خارجی	دقت	۹۴٫۶–۱۰۰ (پ)	—	گزارش‌نشده
Two-Step ResNet	[۴۰]	۲۰۲۵	دوم	آموزش: ۱,۱۷۵ بررسی (یک بیمارستان)؛ ارزیابی: ۲۱۵ بررسی (پنج بیمارستان)	دقت	۹۸٫۳	۹۹٫۱	خیر
Weak-Label ResNet34	[۴۱]	۲۰۲۳	دوم	شخصی، برچسب ضعیف DICOM؛ ۳۱۶ آموزش / ۷۹ آزمون	دقت	۹۹	—	خیر
Injection-Time Regression	[۳۳]	۲۰۲۲	سوم	۸۲,۶۹۰ بررسی از ۱۷ مرکز	دقت / AUC	۹۳٫۳	۰٫۷۷۶ (ت)	گزارش‌نشده

یادداشت‌ها: مقادیر F1 و دقت برحسب درصد و مقادیر AUC در بازه‌ی صفر تا یک‌اند، مگر آن‌که خود مقاله آن‌ها را درصدی گزارش کرده باشد. **(الف)** این مطالعه هیچ ارزیابی درون‌سازمانی گزارش نمی‌کند؛ هر دو مجموعه‌ی ارزیابی خارجی‌اند. بازه‌ی ذکرشده، کمینه و بیشینه‌ی F1 به‌تفکیک فاز روی VinDr-Multiphase است (کمینه متعلق به فاز تأخیری). **(ب)** کران بالا مربوط به سی‌تی سر و گردن و کران پایین مربوط به سی‌تی قفسه‌سینه پس از تنظیم‌دقیق است. **(پ)** به‌ترتیب در سطح برش، حجم و کل بررسی؛ رقم ۱۰۰ درصد تنها در سطح کل بررسی و پس از رأی‌گیری میان حجم‌ها به دست آمده و با ارقام سطح‌بررسی سایر سطرها هم‌سنگ نیست. **(ت)** AUC روی حوزه‌ی جدید (سی‌تی قفسه‌سینه) *پیش از* تنظیم‌دقیق؛ پس از تنظیم‌دقیق با ۱۰۰ نمونه به ۰٫۹۹۹ می‌رسد.

آن‌چه این ادبیات برای پایان‌نامه‌ی حاضر روشن می‌کند، سه نکته است. نخست، تشخیص فاز از روی محتوای تصویر مسئله‌ای حل‌شده به نظر می‌رسد: دقت‌های گزارش‌شده در ارزیابی درون‌سازمانی غالباً

بالای ۹۵ درصدند. دوم، همین ارقام در ارزیابی برون‌سازمانی به‌طور محسوسی افت می‌کنند؛ افت F1 از ۹۲/۰۹ به ۷۶/۷۹ درصد در [۳۸]، و افت F1 از ۹۰/۷ به ۸۲/۶ درصد در [۳۵]، دو نمونه‌ی گویای آن‌اند. استثنای ظاهری این الگو، مطالعه‌ی [۴۰] است که دقت برون‌سازمانی بالاتری از درون‌سازمانی گزارش می‌کند؛ اما داده‌ی آن فاقد فاز بدون‌کنتراست است و بنابراین مسئله‌ی ساده‌تری را حل می‌کند. بنابراین آن‌چه در عمل نامطمئن است، نه دقت مطلق مدل‌ها، بلکه تعمیم‌پذیری آن‌ها به داده‌ی مرکز جدید است؛ دقیقاً همان شرایطی که داده‌ی خام گردآوری‌شده در این پروژه ایجاد می‌کند. سوم، یک‌سوم روش‌های موجود پیش‌نیاز سنگینی دارند: وابستگی به یک مدل بخش‌بندی اندام از پیش‌آموزش‌دیده، که خود عمدتاً روی فاز کنتراست‌دار آموزش دیده است. برای کاربردی که هدفش پردازش فاز بدون‌کنتراست است، این وابستگی یک حلقه‌ی وارونگی ایجاد می‌کند که در انتخاب روش فصل ۳ در نظر گرفته شده است.

۲-۵ ثبت تصویر بین‌فازی سی‌تی

تعریف مسئله

تراز فضایی میان فازهای مختلف یک بررسی سی‌تی چندفازی[۳۶]، پیش‌نیاز بسیاری از کاربردهای بالینی است. در تشخیص و مرحله‌بندی کارسینوم سلول کبدی، دستورعمل‌های بالینی مانند EASL [۱] و مرورهای جامع این بیماری [۲] صراحتاً بر ترکیب اطلاعات فاز شریانی و وریدی برای تشخیص افزایش کنتراست و شست‌وشوی ضایعه تکیه می‌کنند؛ این ترکیب تنها زمانی معتبر است که دو فاز به‌طور دقیق بر هم منطبق باشند. هر جابه‌جایی باقی‌مانده، ناشی از تنفس، حرکت روده یا تغییر وضعیت بیمار میان دو اسکن، می‌تواند یک ضایعه را در یک فاز از دید مدل یا رادیولوژیست پنهان کند. ثبت تصویر به‌طور صوری، مسئله‌ی یافتن یک تبدیل هندسی T است که یک تصویر متحرک[۳۷] را به بهترین شکل بر یک تصویر ثابت[۳۸] منطبق کند؛ چالش مضاعف در ثبت بین‌فازی سی‌تی شکمی آن است که تزریق ماده‌ی حاجب، رابطه‌ی آماری میان شدت روشنایی دو تصویر را به‌شکل ناهمگن در فضا تغییر می‌دهد: عروق و پارانشیم پرخون کبد در فاز شریانی روشن‌تر می‌شوند، در حالی که استخوان، چربی و بسیاری از بافت‌های نرم دیگر تقریباً بدون تغییر باقی می‌مانند.

[۳۶] Multi-phase CT
[۳۷] Moving image
[۳۸] Fixed image

معیارهای ارزیابی

اطلاعات متقابل[۳۹] و نسخه‌ی بهنجارشده‌ی آن[۴۰] معیارهای آماری‌اند که وابستگی مشترک توزیع شدت روشنایی دو تصویر را می‌سنجند، بدون فرض رابطه‌ی خطی میان آن‌ها. این معیارها هم به‌عنوان تابع هزینه‌ی بهینه‌سازی در حین ثبت و هم به‌عنوان شاخص کیفیت پس از ثبت به کار می‌روند، و پایه‌ی معیار تراز در بسیاری از روش‌های کلاسیک ([۴۴، ۴۵، ۴۶]) و ابزارهایی مانند elastix و SimpleITKاند.

همبستگی متقابل نرمال‌شده[۴۱] شباهت خطی شدت روشنایی یا گرادیان دو تصویر را می‌سنجد. این معیار پایه‌ی SyN [۴۷] و توصیف‌گرهای ساختاری مانند MIND [۴۸] و DEEDS [۴۹] است.

خطای ثبت هدف[۴۲] میانگین فاصله‌ی باقی‌مانده میان نشانه‌های آناتومیک متناظر[۴۳] پس از ثبت را اندازه می‌گیرد؛ این معیار مستقیم‌ترین سنجه‌ی دقت هندسی است و در محک‌هایی مانند Learn2Reg [۵۰] برای گزارش دقت روش‌هایی مانند DEEDS و TransMorph به کار می‌رود.

با این حال، هر دو خانواده‌ی معیار محدودیت مهمی دارند. برچسب‌گذاری دستی نشانه‌های آناتومیک برای محاسبه‌ی TRE پرهزینه و زمان‌بر است و تنها برای زیرمجموعه‌ی کوچکی از داده‌ها (عمدتاً محک‌های عمومی مغزی یا ریوی) در دسترس است؛ به همین دلیل، بسیاری از مطالعات ثبت تصویر، از جمله VoxelMorph [۵۱]، TransMorph [۵۲] و DEEDS [۴۹]، به‌جای TRE، از هم‌پوشانی ضریب Dice (تعریف‌شده در بخش ۲-۲) میان نقاب‌های تشریحی پس از ثبت، به‌عنوان معیاری جایگزین و در دسترس‌تر استفاده می‌کنند. این جایگزینی خود دو محدودیت دارد: Dice صرفاً هم‌پوشانی ناحیه‌ای را می‌سنجد، نه تناظر نقطه‌به‌نقطه‌ی واقعی، و بنابراین می‌تواند حتی در غیاب تراز دقیق هندسی مقدار نسبتاً بالایی نشان دهد؛ و کیفیت آن کاملاً به دقت نقاب‌های ورودی (معمولاً حاصل یک مدل بخش‌بندی خودکار) وابسته است.

معیارهای شباهت تصویر (MI، NCC) نیز محدودیت مشابهی دارند: از آن‌جا که تنها یک پروکسی غیرمستقیم برای تراز هندسی‌اند، ممکن است در نواحی با تغییر ناهمگن کنتراست (موضوع اصلی این بخش) مقدار گمراه‌کننده‌ای گزارش کنند، حتی وقتی تراز واقعی برقرار نشده باشد.

---

[۳۹] Mutual Information (MI)
[۴۰] Normalised Mutual Information (NMI)
[۴۱] Normalised Cross-Correlation (NCC)
[۴۲] Target Registration Error (TRE)
[۴۳] Anatomical landmarks

کارهای پیشین

معیارهای شباهت مبتنی‌بر شدت روشنایی

پایه‌ی نظری ثبت تصویر خودکار چندوجهی را ولز و همکاران [۴۴] گذاشتند. مسئله‌ای که آن‌ها حل کردند این بود: وقتی دو تصویر از دو وجهیت متفاوت می‌آیند، رابطه‌ی میان شدت روشنایی متناظر در آن‌ها نه خطی است و نه از پیش معلوم؛ بنابراین معیارهایی مانند مجموع مربعات تفاوت بی‌معنا می‌شوند. راه‌حل آن‌ها استفاده از **اطلاعات متقابل** بود، کمیتی از نظریه‌ی اطلاعات که میزان کاهش عدم‌قطعیت درباره‌ی یک تصویر را در صورت دانستن دیگری می‌سنجد. مزیت تعیین‌کننده‌ی این معیار آن است که هیچ مدلی برای رابطه‌ی شدت‌ها فرض نمی‌کند؛ تنها فرض می‌کند چنین رابطه‌ای، هرچه باشد، *در سراسر تصویر یکسان* است. همین فرض ظاهراً بی‌ضرر، چنان‌که در ادامه می‌آید، دقیقاً همان‌جایی است که در سی‌تی چندفازی می‌شکند.

استادهولم و همکاران [۴۵] یک ضعف عملی این معیار را برطرف کردند. اطلاعات متقابل خام به اندازه‌ی ناحیه‌ی هم‌پوشانی دو تصویر حساس است: بهینه‌ساز می‌تواند با *کوچک‌کردن* هم‌پوشانی، مقدار معیار را به‌طور مصنوعی بالا ببرد و به یک راه‌حل بی‌معنا همگرا شود. **اطلاعات متقابل بهنجارشده** با تقسیم بر آنتروپی مشترک، این وابستگی را حذف می‌کند.

مَتیس و همکاران [۴۶] مسئله‌ی سوم را حل کردند: مشتق‌پذیری. برآورد اطلاعات متقابل از هیستوگرام مشترک، تابعی پله‌ای و غیرمشتق‌پذیر تولید می‌کند که با بهینه‌سازهای مبتنی‌بر گرادیان سازگار نیست. آن‌ها با هموارسازی هیستوگرام از طریق **پنجره‌ی پارزن** با هسته‌ی بی‌اسپلاین، صورتی پیوسته و مشتق‌پذیر از این معیار ساختند که گرادیان تحلیلی دارد. همین فرمول‌بندی است که هنوز هسته‌ی پیاده‌سازی‌های امروزی از جمله elastix [۵۳] و SimpleITK [۵۴] را تشکیل می‌دهد و در پایپ‌لاین فصل ۳ نیز به کار می‌رود.

مدل‌های تغییر شکل کلاسیک

موازی با تکامل معیار شباهت، مدل‌سازی خود تبدیل هندسی مسیر جداگانه‌ای پیمود. تیریون [۵۵] با الگوریتم **دیمانز** قیاسی از ترمودینامیک ساخت: مرزهای تصویر ثابت را «دیو»هایی تصور کرد که وکسل‌های تصویر متحرک را بر اساس گرادیان محلی شدت روشنایی به سمت خود می‌رانند. میدان جابه‌جایی به‌صورت تکراری و با هموارسازی گاوسی میان تکرارها به‌روزرسانی می‌شود. جذابیت این روش، سادگی و سرعت آن است؛ ضعفش آن‌که پایه‌ی نظری‌اش مستقیماً بر شدت روشنایی خام استوار است و بنابراین در برابر تغییر کنتراست شکننده می‌ماند.

رواکرت و همکاران [۵۶] رویکرد متفاوتی را بنیان گذاشتند که هنوز پرکاربردترین مدل تغییر شکل *پارامتری* است. در **تغییر شکل آزاد** مبتنی‌بر **بی‌اسپلاین**، به‌جای تخصیص یک بردار جابه‌جایی مستقل به هر وکسل، شبکه‌ای تُنُک از نقاط کنترل روی تصویر گسترده می‌شود و جابه‌جایی هر وکسل با درون‌یابی بی‌اسپلاین مکعبی از نقاط کنترل مجاور محاسبه می‌شود. این کار دو مزیت دارد: تعداد پارامترها به‌شدت کاهش می‌یابد، و هموار‌بودن میدان جابه‌جایی به‌طور ذاتی تضمین می‌شود. تراکم شبکه، موازنه‌ی میان انعطاف‌پذیری و هموار‌بودن را کنترل می‌کند—همان فراپارامتری که در فصل ۳ باید تنظیم شود.

اوانتز و همکاران [۴۷] با **SyN** دو ویژگی نظری مهم را افزودند. نخست **تقارن**: به‌جای تغییر شکل دادن تصویر متحرک به سمت ثابت، هر دو تصویر هم‌زمان به سمت یک نقطه‌ی میانی تغییر شکل می‌یابند، به‌طوری‌که نتیجه به انتخاب این‌که کدام تصویر «متحرک» است وابسته نباشد. دوم **دیفئومورفیسم**: تبدیل حاصل هموار، معکوس‌پذیر و دارای معکوس هموار است، که تضمین می‌کند آناتومی در حین تغییر شکل تا نخورد یا پاره نشود—قیدی که برای معنادار ماندن تناظر تشریحی ضروری است. SyN از همبستگی متقابل به‌عنوان معیار شباهت استفاده می‌کند و هسته‌ی جعبه‌ابزار ANTs است. در ارزیابی مستقل کلاین و همکاران روی چهار محک مغزی، Dice آن میان ۰٫۶۰ تا ۰٫۷۷ گزارش شد و به‌عنوان یکی از دو روش برتر آن مقایسه شناخته شد؛ به همین دلیل هنوز مبنای مقایسه‌ی غالب در این حوزه است.

پلوییم و همکاران [۵۷] در مروری جامع، شرایط اعتبار خانواده‌ی اطلاعات متقابل را مستند کردند؛ متز و همکاران [۵۸] این معیارها را به ثبت **گروهی** دنباله‌های پویا از جمله سی‌تی شکمی پویا تعمیم دادند؛ و مورفی و همکاران [۵۰] چارچوبی نیمه‌خودکار برای ساخت استاندارد مرجع مبتنی‌بر نشانه‌های آناتومیک پیشنهاد کردند که ارزیابی دقیق TRE را ممکن می‌سازد.

چرا این خانواده در سی‌تی چندفازی می‌شکند

مشکل بنیادین، همان فرضی است که در آغاز این بخش برجسته شد: خانواده‌ی اطلاعات متقابل فرض می‌کند رابطه‌ی آماری میان شدت روشنایی دو تصویر در سراسر میدان دید *پایدار* است. تزریق ماده‌ی حاجب دقیقاً همین فرض را نقض می‌کند، و آن را به‌شکلی نقض می‌کند که بدترین حالت ممکن است: تغییر، *ناهمگن در فضا* است. آئورت و ورید باب در فاز شریانی صدها واحد HU روشن‌تر می‌شوند، پارانشیم کبد چند ده واحد، و استخوان و چربی تقریباً هیچ. نتیجه آن است که معیار تراز کلی‌نگر، بخش بزرگی از واریانس خود را از تغییر کنتراست می‌گیرد، نه از جابه‌جایی هندسی واقعی. بهینه‌ساز، تصویر را تغییر شکل می‌دهد تا الگوی *شدت* را تطبیق دهد، در حالی که هدف مطلوب تطبیق *آناتومی* است.

روش‌های آگاه از آناتومی

چند خط پژوهشی کوشیده‌اند با واردکردن اطلاعات تشریحی به این مسئله نزدیک شوند. پاپیه‌ژ و همکاران [۵۹] یک منظم‌ساز دوسویه‌ی آگاه از آناتومی معرفی کردند که امکان **حرکت لغزشی** را در مرز اندام‌هایی مانند ریه و کبد فراهم می‌کند؛ یعنی به میدان جابه‌جایی اجازه می‌دهد در سطح تماس دو اندام ناپیوسته باشد، چیزی که منظم‌سازهای هموار متعارف ممنوع می‌کنند. با این حال، معیار تراز در این روش همچنان در سطح کل تصویر محاسبه می‌شود.

دِفوس و همکاران [۶۰] وزن‌دهی آگاه از آناتومی را مستقیماً وارد تابع هزینه‌ی یک شبکه‌ی پیچشی سرتاسر کردند. هو و همکاران [۶۱] رادیکال‌تر عمل کردند: با **نظارت ضعیف** مبتنی‌بر هم‌پوشانی برچسب به‌جای اطلاعات شدت روشنایی، مسئله‌ی ناهمگنی شدت را به‌کلی دور زدند——شبکه اصلاً شدت روشنایی را نمی‌بیند، بلکه فقط می‌آموزد نقاب‌ها را بر هم منطبق کند. بهای این کار، وابستگی کامل کیفیت ثبت به کیفیت بخش‌بندی ورودی است. اوکتای و همکاران [۶۲] **پیشین‌های شکل تشریحی** را به‌عنوان قید در آموزش گنجاندند.

نقطه‌ی مشترک این خط پژوهشی، که در جمع‌بندی این بخش اهمیت می‌یابد، آن است که همگی از آناتومی برای *وزن‌دهی* یا *قید کردن* معیار تراز استفاده می‌کنند، نه برای تعیین *دامنه‌ی فضایی محاسبه‌ی* خود معیار.

روش‌های یادگیری‌محور

موازی با این خط، خانواده‌ای از روش‌ها توسعه یافت که به‌جای بهینه‌سازی تکراری برای هر جفت تصویر، یک شبکه را یک‌بار آموزش می‌دهند تا میدان جابه‌جایی را در یک گذر پیش‌رو پیش‌بینی کند——کاهشی از چند دقیقه به چند ثانیه.

VoxelMorph [۵۱] الگوی پایه‌ی این خانواده را تثبیت کرد: یک رمزگذار—رمزگشای پیچشی سبک U-Net که جفت تصویر را می‌گیرد و میدان جابه‌جایی تولید می‌کند، به‌همراه یک **لایه‌ی تبدیل‌گر فضایی** که تصویر متحرک را با این میدان تغییر شکل می‌دهد. چون این لایه مشتق‌پذیر است، کل شبکه را می‌توان به‌صورت *بدون‌نظارت* و تنها با کمینه‌کردن اختلاف تصویر تغییر شکل‌یافته با تصویر ثابت آموزش داد. روی هشت محک مغزی (۲۵۰ حجم)، Dice برابر ۰/۷۵۳ در حالت بدون‌نظارت و ۰/۷۸ با افزودن نظارت بخش‌بندی به دست آمد، با کارایی زمانی به‌مراتب بهتر از ANTs.

سه محدودیت VoxelMorph سه شاخه‌ی بعدی را پدید آورد. محدودیت *میدان دریافت*: **TransMorph** [۵۲] رمزگذار پیچشی را با یک Swin Transformer جایگزین کرد تا تناظرهای دوربرد

را بیابد، و روی وظیفه‌ی OASIS محک Learn2Reg به Dice ۰/۸۶۲ و HD95 برابر ۱/۴۳۱ میلی‌متر رسید. محدودیت *تغییر شکل بزرگ*: **LapIRN** [۶۳] با هرم لاپلاسی، میدان را از مقیاس خشن به ریز پالایش می‌کند و روی OASIS به Dice ۰/۸۰۸ (نسخه‌ی جابه‌جایی) و ۰/۷۶۵ (نسخه‌ی دیفئومورفیک) رسید؛ **شبکه‌های آبشاری بازگشتی** [۶۴] همین ایده را با اعمال مکرر یک شبکه‌ی واحد روی خروجی خودش پیاده کردند. محدودیت *تنظیم فراپارامتر*: **HyperMorph** [۶۵] یک ابرشبکه می‌آموزد که وزن‌های شبکه‌ی ثبت را *به‌عنوان تابعی از* ضریب منظم‌سازی تولید کند، به‌طوری‌که کاربر بتواند این ضریب را در زمان استنتاج و بدون بازآموزی تغییر دهد؛ روی داده‌ی مغزی Buckner40، Dice میان ۰/۷۰ و ۰/۷۴ گزارش شد.

DeepAtlas [۶۶] مسیر دیگری رفت و ثبت و بخش‌بندی را در یک چارچوب نیمه‌نظارتی مشترک آموزش داد: شبکه‌ی بخش‌بندی برچسب تولید می‌کند تا به شبکه‌ی ثبت نظارت بدهد، و شبکه‌ی ثبت برچسب‌ها را میان بیماران منتقل می‌کند تا داده‌ی آموزشی بخش‌بندی را افزون کند.

UniGradICON [۶۷]، به‌عنوان تازه‌ترین گام این مسیر، یک **مدل بنیادین** برای ثبت تصویر است: یک شبکه‌ی واحد روی دوازده مجموعه‌داده‌ی عمومی از آناتومی‌ها و وجهیت‌های مختلف آموزش می‌بیند و ادعا می‌کند بدون تنظیم‌دقیق روی داده‌ی جدید کار می‌کند. تابع هزینه‌ی آن ترکیبی از همبستگی متقابل محلی و یک جمله‌ی **پایداری معکوس گرادیان** است که معکوس‌پذیری تبدیل را تشویق می‌کند. عملکرد آن به‌شدت به آناتومی وابسته است: Dice برابر ۷۶/۲ روی مغز (HCP) اما تنها ۴۸/۳ روی شکم (L2R-Abdomen)، و TRE برابر ۲/۲۶ میلی‌متر روی ریه. همین اختلاف چشمگیر میان مغز و شکم، دشواری نسبی ثبت شکمی را کمّی می‌کند. رفتار این مدل در برابر جابه‌جایی حوزه‌ای ناشی از *فاز کنتراست* هنوز مشخصه‌یابی نشده است.

توصیف‌گرهای ساختاری مستقل از وجهیت

مسیر مفهومی متفاوتی برای دور زدن ناپایداری شدت روشنایی وجود دارد: به‌جای مقایسه‌ی *مقدار* شدت، *الگوی محلی* آن مقایسه شود. **MIND** [۴۸] این ایده را عملیاتی کرد. برای هر وکسل، به‌جای مقدار خام، برداری محاسبه می‌شود که فاصله‌ی وصله‌ی پیرامون آن وکسل را با وصله‌های همسایه‌اش کد می‌کند—یعنی **خودشباهت** محلی. اگر کل تصویر با یک تبدیل یکنوای شدت روشنایی تغییر کند، این الگوی نسبی تقریباً دست‌نخورده می‌ماند. توصیف‌گر حاصل، شباهتی مستقل از وجهیت فراهم می‌کند و مسئله را از «تطبیق شدت‌ها» به «تطبیق ساختارها» منتقل می‌کند.

بر همین پایه، **DEEDS** [۴۹] توصیف‌گر MIND را با **بهینه‌سازی گسسته‌ی میدان تصادفی مارکوف** ترکیب کرد. به‌جای بهینه‌سازی پیوسته و مبتنی‌بر گرادیان—که در کمینه‌های محلی گیر می‌کند—فضای جابه‌جایی گسسته‌سازی می‌شود و بهترین ترکیب جابه‌جایی‌ها با انتقال پیام روی یک گراف یافت می‌شود.

این ترکیب، DEEDS را به یکی از دقیق‌ترین روش‌های ثبت شکمی در محک Learn2Reg بدل کرده است: Dice برابر ۷۷/۵ درصد در ثبت درون‌وجهی MR و ۶۳/۶ درصد در ثبت بین‌وجهی CT—MR. افت چشمگیر میان این دو رقم نشان می‌دهد حتی توصیف‌گرهای ساختاری نیز در برابر تغییر وجهیت کاملاً مصون نیستند.

ثبت تصویر چندفازی شکمی

برخلاف آن‌چه از حجم ادبیات بالا برمی‌آید، مسئله‌ی مشخصِ ثبت *بین‌فازی* سی‌تی شکمی تقریباً بدون بررسی مانده است. تنها استثنای قابل‌توجه، کار پارک، فیشمن و یول [۶۸] است که مستقیماً ثبت فاز شریانی به وریدی را هدف گرفت.

رویکرد آن‌ها ترکیبی از دو ایده‌ی بالاست: تغییر شکل **وابسته به جهت**، که به حرکت لغزشی در مرز اندام‌ها اجازه می‌دهد (در خط پاپیه‌ژ)، به همراه خودشباهت محلی برای مقاوم‌سازی در برابر تفاوت کنتراست (در خط MIND). ارزیابی روی داده‌ی سی‌تی نازک‌برش بیماران آدنوکارسینوم پانکراس و اهداکنندگان کلیه انجام شد و کانتور دستی اندام‌ها با میدان جابه‌جایی منتقل و با کانتور دستی تصویر مقصد مقایسه شد.

نتایج، ارزشمندترین نقطه‌ی مرجع کمّی موجود برای این مسئله‌اند. روش پیشنهادی آن‌ها به Dice برابر ۸۹/۰۴ درصد برای پانکراس و ۹۸/۵۲ درصد برای کبد رسید، با فاصله‌ی سطحی ۰/۸۵ و ۰/۷۸ میلی‌متر، در کمتر از یک دقیقه محاسبه. در همان ارزیابی، SyN به ۸۷/۳۲ و ۹۵/۳۲ درصد، دیمانز دیفئومورفیک به ۸۷/۱۶ و ۹۳/۵۲ درصد، و MIND به ۸۶/۲۴ و ۹۳/۸۵ درصد رسیدند.

دو نکته از این ارقام برای پایان‌نامه‌ی حاضر بیرون می‌آید. نخست، تفاوت میان کبد (بالای ۹۳ درصد برای همه‌ی روش‌ها) و پانکراس (زیر ۹۰ درصد برای همه) نشان می‌دهد دشواری ثبت بین‌فازی، مانند دشواری بخش‌بندی در بخش ۲-۲، روی اندام‌های کوچک و کم‌کنتراست متمرکز است. دوم، این‌که یک روش مبتنی‌بر خودشباهت محلی از SyN مبتنی‌بر همبستگی متقابل پیشی می‌گیرد، تأیید تجربی همان استدلالی است که در بالا مطرح شد: در حضور تغییر ناهمگن کنتراست، معیارهای ساختاری بر معیارهای شدت‌محور برتری دارند.

زیرساخت نرم‌افزاری

SimpleITK [۵۴] و elastix [۵۳] پرکاربردترین زیرساخت‌های منبع‌باز این حوزه‌اند. اهمیت آن‌ها برای این پایان‌نامه در یک ویژگی مشخص است: معماری پیمانه‌ای آن‌ها اجازه می‌دهد تبدیل، معیار شباهت و

بهینه‌ساز به‌طور مستقل تعریف شوند، و——تعیین‌کننده‌تر——از **نقاب تصویر ثابت** در تعریف معیار پشتیبانی می‌کنند. یعنی می‌توان به کتابخانه گفت معیار شباهت را تنها روی زیرمجموعه‌ای از وکسل‌ها محاسبه کند. همین قابلیت است که پیاده‌سازی ایده‌ی فصل ۳ را ممکن می‌سازد.

جمع‌بندی و جای خالی

کنار هم گذاشتن این پیشینه، تصویری دقیق‌تر از آن‌چه در نگاه اول به نظر می‌رسد به دست می‌دهد.

معیارهای کلاسیک خانواده‌ی اطلاعات متقابل در سطح کل تصویر تعریف می‌شوند و بنابراین در برابر تغییر ناهمگن کنتراست شکننده‌اند. روش‌های یادگیری‌محور سریع‌ترند اما تقریباً همگی روی محک‌های مغزی توسعه یافته‌اند و——چنان‌که افت Dice از ۷۶/۲ به ۴۸/۳ در UniGradICON نشان می‌دهد—— انتقالشان به شکم بدیهی نیست. توصیف‌گرهای ساختاری مانند MIND و DEEDS مقاوم‌ترین گزینه‌اند، و کار پارک و همکاران [۶۸] تأیید می‌کند که همین خانواده در ثبت بین‌فازی شکمی بهترین عملکرد را دارد.

جای خالی، بنابراین، این نیست که کسی ثبت بین‌فازی شکمی انجام نداده باشد؛ پارک و همکاران انجام داده‌اند. جای خالی دقیق‌تر و باریک‌تر است: همه‌ی روش‌های موجود——چه آن‌ها که آناتومی را برای *وزن‌دهی* به کار می‌گیرند ([۵۹، ۶۰، ۶۲]) و چه آن‌ها که معیار را *مقاوم‌تر می‌سازند* ([۴۸، ۴۹، ۶۸])—— معیار تراز را همچنان روی *کل* میدان دید محاسبه می‌کنند. هیچ‌یک *دامنه‌ی فضایی محاسبه‌ی* معیار را از پیش و بر مبنای دانش تشریحیِ این‌که کدام ساختارها در برابر تزریق ماده‌ی حاجب پایدارند، محدود نمی‌کند. تفاوت میان «وزن کمتر دادن به روده» و «اصلاً محاسبه‌نکردن معیار روی روده» ظریف اما پیامددار است، و همین تمایز، نقطه‌ی عزیمت پایپ‌لاین بخش ۳–۵ است.

افزون بر این، نکته‌ی مشترک دیگری این ادبیات را به مسئله‌ی گسترده‌تر این فصل گره می‌زند: هیچ‌یک از این مطالعات، کیفیت هم‌ترازی حاصل را به‌عنوان *معیار پذیرش داده* برای یک وظیفه‌ی پایین‌دستی به کار نبرده‌اند. ثبت تصویر در این ادبیات هدف نهایی است، در حالی که در این پایان‌نامه ابزاری برای *ساخت* داده‌ی آموزشی سنتز است——کاربردی که به یک آستانه‌ی کمّی برای «به‌اندازه‌ی کافی هم‌تراز» نیاز دارد.

جدول ۲–۳ روش‌هایی را که مقدار عددی قابل‌مقایسه گزارش کرده‌اند کنار هم می‌گذارد. روش‌های بنیادین دهه‌ی ۱۹۹۰ و اوایل ۲۰۰۰——اطلاعات متقابل، نسخه‌ی بهنجارشده‌ی آن، دیمانز و تغییر شکل آزاد——عمداً در جدول نیامده‌اند: آن‌ها پیش از تثبیت محک‌های مشترک منتشر شده‌اند و عددی که بتوان با سطرهای جدول سنجید ندارند؛ جایگاه روش‌شناختی‌شان در متن بالا تشریح شد.

دو ستون این جدول عمداً افزوده شده‌اند. ستون «**وظیفه‌ی معرفی**» نشان می‌دهد هر روش در اصل

برای چه آناتومی و چه نوع مسئله‌ای طراحی شده است؛ ستون «**معیار بهینه‌سازی**» تابع شباهتی را مشخص می‌کند که روش هنگام ثبت آن را کمینه یا بیشینه می‌کند——یعنی همان چیزی که روش واقعاً روی آن جلو می‌رود. کنار هم گذاشتن این دو با ستون مقادیر، سه واقعیت را آشکار می‌کند. نخست، تنها یک سطر از این جدول ([۶۸]) برای سی‌تی شکمی *چندفازی* معرفی شده است؛ بقیه روی محک‌های مغزی، ریوی یا شکمی تک‌فاز طراحی و سنجیده شده‌اند. دوم، معیار بهینه‌سازی تقریباً همیشه یا از خانواده‌ی اطلاعات متقابل است یا از خانواده‌ی همبستگی متقابل، و هر دو بر فرض پایداری رابطه‌ی شدت روشنایی در سطح کل تصویر بنا شده‌اند. سوم، معیار *گزارش‌شده* تقریباً همیشه Dice است، حتی وقتی معیار *بهینه‌شده* چیز دیگری بوده؛ یعنی این ادبیات با سنجه‌ای ارزیابی می‌شود که خودش برای آن آموزش ندیده است.

جدول ۲-۳: روش‌های منتخب ثبت تصویر: وظیفه‌ای که روش برای آن معرفی شده، معیاری که روش آن را بهینه می‌کند، و مقادیر گزارش‌شده روی محک ارزیابی. روش‌های بنیادین پیش از ۲۰۰۵، به‌دلیل نبودِ عدد قابل‌مقایسه، تنها در متن بررسی شده‌اند.

روش (مرجع)	سال	وظیفه‌ی معرفی	معیار بهینه‌سازی	محک ارزیابی	مقدار گزارش‌شده	کد
SyN [۴۷]	۲۰۰۸	ثبت دیفئومورفیک MRI مغزی	CC	چهار محک مغزی (الف)	Dice ۰/۶۰—۰/۷۷	✓
MIND [۴۸]	۲۰۱۲	ثبت چندوجهی و سی‌تی ریه (دم/بازدم)	SSD روی توصیف‌گر خودشباهت	سی‌تی ریه؛ MR—CT	گزارش‌نشده (ب)	✓
DEEDS [۴۹]	۲۰۱۳	ثبت تغییرشکل‌پذیر شکمی و چندوجهی	MIND + بهینه‌سازی گسسته‌ی MRF	Learn2Reg شکمی (BCV/CHAOS)	درون‌وجهی MR: ۷۷/۵ بین‌وجهی MR-CT: ۶۳/۶	✓
VoxelMorph [۵۱]	۲۰۱۹	ثبت یادگیری‌محور MRI مغزی بین‌بیماری	MSE یا CC	۸ محک مغزی (۲۵۰ حجم)	بدون‌نظارت: ۰/۷۵۳ با نظارت: ۰/۷۸	✓
Recursive Cascades [۶۴]	۲۰۱۹	تغییر شکل بزرگ؛ کبد (سی‌تی) و مغز (MRI)	NCC	[ ]	[ ]	✓
DeepAtlas [۶۶]	۲۰۱۹	یادگیری مشترک ثبت و بخش‌بندی؛ مغز و زانو	شباهت شدت + هم‌پوشانی برچسب	[ ]	[ ]	✓
LapIRN [۶۳]	۲۰۲۰	تغییر شکل بزرگ MRI مغزی	NCC چندمقیاسی	OASIS (۷۴۵ جفت آزمون)	جابه‌جایی: ۰/۸۰۸ دیفئومورفیک: ۰/۷۶۵	✓
HyperMorph [۶۵]	۲۰۲۱	یادگیری فراپارامتر منظم‌سازی؛ MRI مغزی	MSE/NCC یا MI	مغزی (Buckner40)	Dice ۰/۷۰—۰/۷۴	✓
پارک و همکاران [۶۸]	۲۰۲۱	**ثبت شریانی به وریدی سی‌تی شکمی**	خودشباهت محلی + تغییر شکل وابسته به جهت	سی‌تی چندفازی شکمی (PDAC و اهداکننده‌ی کلیه)	پانکراس: ۸۹/۰۴ کبد: ۹۸/۵۲ (پ)	×
TransMorph [۵۲]	۲۰۲۲	ثبت MRI مغزی با ترانسفورمر	NCC/MSE + منظم‌ساز	Learn2Reg (OASIS، T03)	Dice ۰/۸۶۲ HD95 ۱/۴۳۱	✓
UniGradICON [۶۷]	۲۰۲۴	مدل بنیادین چندآناتومی و چندوجهی	LNCC + پایداری معکوس گرادیان	L2R-HCP؛ Abdomen COPDGene	بدون IO: ۷۶/۲ / ۴۸/۳ / ۲/۲۶ با IO: ۷۸/۹ / ۵۲/۲ / ۱/۴۰ (ت)	✓

یادداشت‌ها: مقادیر Dice بدون واحد در بازه‌ی صفر تا یک و با علامت درصد، درصدی‌اند؛ HD95 و TRE برحسب میلی‌متر. **(الف)** LPBA40، IBSR18، CUMC12، MGH10؛ عدد Dice از ارزیابی مستقل Klein et al. 2009 است، چون مقاله‌ی اصلی مقدار دقیق گزارش نکرده و تنها عبور از آستانه‌ی ۰/۶ را ذکر کرده است. **(ب)** مقاله‌ی اصلی مقدار مطلق گزارش نمی‌کند و تنها تفاوت معنادار آماری ($p < ۰/۰۰۰۱$) در TRE نسبت به سایر روش‌ها را ذکر می‌کند؛ ارقام MIND روی داده‌ی شکمی چندفازی را می‌توان از [۶۸] گرفت: پانکراس ۸۶/۲۴ و کبد ۹۳/۸۵ درصد. **(پ)** برحسب درصد؛ فاصله‌ی سطحی متناظر ۰/۸۵ و ۰/۷۸ میلی‌متر. در همین ارزیابی SyN به ۸۷/۳۲ و ۹۵/۳۲ و دیمانز دیفئومورفیک به ۸۷/۱۶ و ۹۳/۵۲ درصد رسیدند. **(ت)** سه مقدار به‌ترتیب Dice مغزی، Dice شکمی و TRE ریوی‌اند؛ IO یعنی بهینه‌سازی نمونه‌ای(instance optimisation) در زمان استنتاج.

۲-۶ تولید تصاویر سی‌تی کنتراست‌دار از تصاویر سی‌تی بدون تزریق ماده‌ی حاجب

تعریف مسئله

در کنار ثبت تصویر، که فازهای موجود را هم‌تراز می‌کند، مسیر مکمل دیگر در ادبیات پژوهشی، تولید مستقیم اطلاعات فاز کنتراست‌دار از روی تصویر بدون‌کنتراست است؛ وظیفه‌ای که با عناوینی مانند **سنتز کنتراست مجازی**[۴۴] یا ترجمه‌ی تصویر[۴۵] از NC به CE شناخته می‌شود و به‌طور صوری یک مسئله‌ی نگاشت شرطی $G : x_{\mathrm{NC}} \mapsto \hat{x}_{\mathrm{CE}}$ است. این حوزه در سال‌های اخیر به‌سرعت رشد کرده و اکنون شامل ده‌ها روش با معماری‌ها، مجموعه‌داده‌ها و راهبردهای نظارتی متفاوت است؛ جدول ۲-۴ در انتهای این بخش، هم طبقه‌بندی روش‌شناختی و هم مقادیر عددی گزارش‌شده‌ی این ادبیات را یک‌جا جمع می‌کند.

معیارهای ارزیابی

ارزیابی کیفیت سنتز معمولاً هم به وفاداری پیکسلی و هم به واقع‌نمایی ادراکی تصویر تولیدشده توجه می‌کند.

نسبت سیگنال به نویز اوج[۴۶] بر پایه‌ی میانگین مربعات خطا در فضای لگاریتمی تعریف می‌شود و تصویر سنتزشده را مستقیماً با تصویر واقعی مقایسه می‌کند؛ این معیار بیشتر به خطای پیکسلی خام حساس است تا ساختار ادراکی تصویر.

شاخص شباهت ساختاری[۴۷] نیز تصویر سنتزشده را مستقیماً با تصویر واقعی مقایسه می‌کند، اما با سنجش هم‌زمان روشنایی، کنتراست و ساختار محلی، به تغییرات ادراکی نزدیک‌تر از PSNR است.

میانگین قدرمطلق خطا[۴۸] و **میانگین مربعات خطا**[۴۹] معیارهای ساده‌تری برای تفاوت شدت روشنایی پیکسل‌به‌پیکسل‌اند و در بسیاری از مطالعات به‌عنوان بخشی از تابع هزینه‌ی آموزش نیز به کار می‌روند.

ضریب همبستگی پیرسون[۵۰] همبستگی خطی میان شدت روشنایی دو تصویر را می‌سنجد.

---

[۴۴] Virtual contrast enhancement
[۴۵] Image-to-image translation
[۴۶] Peak Signal-to-Noise Ratio (PSNR)
[۴۷] Structural Similarity Index (SSIM)
[۴۸] Mean Absolute Error (MAE)
[۴۹] Mean Squared Error (MSE)
[۵۰] Pearson Correlation Coefficient (PCC)

فاصله‌ی آغازشی فرشه[۵۱] برخلاف معیارهای فوق، تصویر به تصویر مقایسه نمی‌کند، بلکه فاصله‌ی میان توزیع ویژگی‌های استخراج‌شده (با یک شبکه‌ی از پیش‌آموزش‌دیده) از کل مجموعه‌ی تصاویر واقعی و تولیدشده را اندازه می‌گیرد؛ بنابراین معیاری در سطح توزیع، نه تک‌تصویر، است.

شباهت پرسپچوال یادگرفته‌شده[۵۲] تفاوت دو تصویر را در فضای ویژگی یک شبکه‌ی از پیش‌آموزش‌دیده، به‌جای فضای پیکسل خام، می‌سنجد و بنابراین با قضاوت ادراکی انسان هم‌بستگی بهتری نسبت به SSIM/PSNR دارد.

سرانجام، در مطالعاتی که کاربردپذیری پایین‌دستی سنتز را می‌سنجند، ضریب **Dice** بخش‌بندی روی تصویر سنتزشده (تعریف‌شده در بخش ۲-۲) به‌عنوان معیار غیرمستقیم کیفیت به کار می‌رود.

کارهای پیشین

خانواده‌ی نخست: GANهای جفت‌شده

نقطه‌ی عزیمت این ادبیات، معماری pix2pix است: یک GAN شرطی که تصویر ورودی را به تصویر خروجی نگاشت می‌کند و با ترکیبی از زیان تخاصمی و زیان بازسازی پیکسلی آموزش می‌بیند. آن‌چه مطالعات این خانواده را از هم متمایز می‌کند، پاسخشان به یک پرسش واحد است: چگونه می‌توان مولد را وادار کرد به *نواحی مرتبط با کنتراست* توجه کند، نه به کل تصویر به‌طور یکنواخت؟

مجموعه‌ای از سه کار پیاپی از یانگ و همکاران، این تکامل را به‌روشنی نشان می‌دهد؛ هر سه روی یک مجموعه‌داده‌ی درون‌سازمانی مشترک از ۸۶ بیمار با چهار نوع ضایعه‌ی کبدی (کارسینوم سلول کبدی، هیپرپلازی ندولار کانونی، متاستاز و کیست) ارزیابی شده‌اند که برای هر بیمار سه فاز بدون‌کنتراست، شریانی و وریدی دارد.

در گام نخست [۶۹]، یک **cGAN بهبودیافته** معرفی شد که دو ضعف مشخص معماری پایه را هدف می‌گیرد: میدان دریافت محدود رمزگذار پیچشی، و رقیق‌شدن اطلاعات معنایی در مسیر رمزگشایی. راه‌حل، افزودن یک **ماژول تجمیع هرمی**[۵۳] به انتهای رمزگذار و مجموعه‌ای از مسیرهای جریان اطلاعات است که خروجی این ماژول را مستقیماً به هر واحد رمزگشا می‌رساند. رمزگذار از ResNet از پیش‌آموزش‌دیده روی ImageNet استفاده می‌کند و شبکه با WGAN-GP به‌همراه زیان بازسازی L1 (با وزن ۲۵ در برابر وزن ۱ برای جمله‌ی تخاصمی) آموزش می‌بیند. نتیجه، PSNR برابر ۳۳/۱۸ و SSIM برابر ۰/۸۱۹ برای فاز شریانی و ۳۳/۰۲ و ۰/۸۱۹ برای فاز وریدی بود، در برابر ۳۲/۸۶ و ۰/۷۹۷ برای pix2pix پایه.

[۵۱] Fréchet Inception Distance (FID)
[۵۲] Learned Perceptual Image Patch Similarity (LPIPS)
[۵۳] Pyramid pooling module

گام دوم [۷۰]، با نام **SAG-GAN**، مسئله‌ی توجه را صریح کرد. یک **ماژول توجه فضایی** سبک، نقشه‌ی امتیاز فضایی تولید می‌کند که مشخص می‌کند کدام نواحی تصویر با وظیفه مرتبط‌اند؛ تصویر نهایی، ترکیب وزن‌دار تصویر تبدیل‌شده و تصویر ورودی بر اساس همین نقشه است، به‌طوری‌که نواحی نامرتبط دست‌نخورده باقی می‌مانند. نکته‌ی هوشمندانه آن است که این نقشه بدون نیاز به نقاب دستی و به‌صورت *بدون‌نظارت* آموخته می‌شود، از طریق یک **زیان توجه** که سازگاری نقشه‌ی امتیاز میان تصویر ورودی و تصویر سنتزشده را تشویق می‌کند. تابع هدف نهایی ترکیبی سه‌جزئی است (تخاصمی با وزن ۲، بازسازی با وزن ۲۵، توجه با وزن ۱)، و SSIM فاز شریانی را به ۰/۸۳۰ و ضریب همبستگی پیرسون ناحیه‌ی تومور را به ۰/۹۶۶ رساند.

گام سوم [۷۱]، **SGCDD-GAN**، دو تحول افزود. نخست، **رمزگشایی دوگانه‌ی متقاطع**: یک شاخه تصویر تبدیل‌شده و شاخه‌ی دیگر نقشه‌ی توجه را تولید می‌کند، اما این دو شاخه به‌صورت متقاطع به هم متصل‌اند تا اطلاعات میانشان جریان یابد. دوم، **یادگیری چندوظیفه‌ای**: یک شبکه‌ی بخش‌بندی تومور به چارچوب افزوده می‌شود تا مولد را وادار کند به ناحیه‌ی ضایعه توجه بیشتری کند. ارزیابی این کار، برخلاف دو کار پیشین، از معیارهای سطح‌پیکسل فراتر رفت: تصاویر سنتزشده به یک طبقه‌بند ResNet-50 سه‌فازی داده شد و به دقت ۸۲/۶۸ درصد در طبقه‌بندی نوع ضایعه رسید (در برابر ۶۳/۴۹ درصد با فاز بدون‌کنتراست تنها). در یک آزمایش خلبانی، دو رادیولوژیست با تصاویر سنتزشده به دقت تشخیصی ۹۴/۱۱ درصد رسیدند، در برابر ۱۰۰ درصد با تصویر واقعی.

OA-GAN [۷۲] و **MAN-GAN** [۷۳] مسیر مکملی را دنبال کردند: به‌جای آموختن توجه، نقاب اندام کبد را مستقیماً از طریق **بهنجارسازی سازگار با نقاب**[۵۴] وارد مولد کردند——سازوکاری که پارامترهای بهنجارسازی لایه را بسته به این‌که وکسل درون اندام هدف است یا بیرون آن، متفاوت تنظیم می‌کند. MAN-GAN گسترده‌ترین ارزیابی این خانواده را دارد: ۳۷۴ بیمار برای آموزش، ۱۴۴ بیمار با یک بیماری کبدی مشخص به‌عنوان آزمون داخلی، و ۸۳ بیمار برای اعتبارسنجی خارجی.

MAFormer [۷۴] همین ایده را با یک ترانسفورمر بازسازی کرد و دانش بالینی متفاوتی را وارد مسئله ساخت: رادیولوژیست‌ها برای برجسته‌کردن نواحی کنتراست‌گرفته، تصویر بدون‌کنتراست را از تصویر کنتراست‌دار *تفریق* می‌کنند. MAFormer یک تخمین‌گر نقاب دارد که همین تصویر تفریق را از روی تصویر بدون‌کنتراست پیش‌بینی می‌کند، و آن را از طریق یک لایه‌ی بهنجارسازی مبتنی‌بر ترانسفورمر به شبکه تزریق می‌کند. یک **زیان تغییرناپذیری ساختار** نیز تضمین می‌کند آناتومی در برابر تغییر رنگ‌آمیزی کنتراست حفظ شود.

AMNet [۷۵] تازه‌ترین نماینده‌ی این خانواده است و بر دو چالش تمرکز دارد: کنتراست پایین

[۵۴] Mask-adaptive normalisation

و حساسیت پایین به ماده‌ی حاجب. راه‌حل آن چهار مؤلفه دارد: یک **ترانسفورمر تجمیع‌شده–تعاملی** با تجمیع توکن چندمقیاسی و تعامل میان‌توکنی؛ **یادگیری متضاد هم‌ترازشده‌ی چندگرانی** که ویژگی‌های درون‌حوزه را فشرده و میان‌حوزه را جداشدنی می‌کند؛ یک **لایه‌ی سازگار آگاه از کنتراست**؛ و یک **متمایزکننده‌ی دوجریانه**. تابع هدف ترکیبی از زیان پیکسلی L1 (وزن ۵۰)، زیان ادراکی مبتنی‌بر VGG-19 (وزن ۱۰)، زیان تخاصمی و زیان متضاد است. داده‌ی آن ۹۲ حجم سی‌تی از کلینیک کلیولند با دو فاز بدون‌کنتراست و وریدی است که *پیش از آموزش ثبت شده‌اند*.

pix2pix سه‌بعدی [۷۶] از منظر این پایان‌نامه اهمیت ویژه‌ای دارد، چون یکی از معدود کارهای این حوزه با کد باز است. چوی و همکاران کنتراست را از سی‌تی قفسه‌سینه‌ی بدون‌کنتراست سنتز کردند و—برخلاف اغلب مطالعات این خانواده—ارزیابی را در دو سطح جداگانه انجام دادند: ۲۵ بیمار برای سنجش فنی و ۱۲ بیمار برای سنجش کاربردپذیری بالینی. در سطح فنی، تصویر سنتزشده در مقایسه با تصویر بدون‌کنتراست خام بهبود معناداری در همه‌ی معیارها نشان داد: MAE از ۴۸/۷۴ به ۴۱/۷۲، PSNR از ۱۵/۹۷ به ۱۷/۴۴، MS-SSIM از ۰/۸۱ به ۰/۸۴ و LPIPS از ۰/۱۵ به ۰/۱۴. اما سطح بالینی، یافته‌ی به‌مراتب چشمگیرتری داد: نسبت کنتراست‌به‌نویز غدد لنفاوی میانی‌سینه‌ای از ۰/۷۴ به ۶/۱۵ جهش کرد—بهبودی حدوداً هشت‌برابری در سنجه‌ای که مستقیماً به قابلیت تشخیص مربوط است، در حالی که PSNR تنها حدود ۹ درصد بهتر شده بود.

این عدم‌تناسب، مهم‌ترین درس این خانواده برای پایان‌نامه‌ی حاضر است: *معیارهای سطح‌پیکسل، بهبود بالینی را به‌شدت کم‌برآورد می‌کنند*، چون تفاوت را روی کل تصویر میانگین می‌گیرند در حالی که کل ارزش تشخیصی در نواحی کوچکی متمرکز است.

خانواده‌ی دوم: سازگاری چرخه‌ای و آموزش بدون‌جفت

مسئله‌ی عملی خانواده‌ی نخست آن است که به جفت‌های هم‌ترازِ هم‌بیمار نیاز دارد—همان چیزی که بخش ۲-۳ کمیابی‌اش را مستند کرد. خانواده‌ی دوم این نیاز را با **سازگاری چرخه‌ای** حذف می‌کند: دو مولد در دو جهت مخالف آموزش می‌بینند و قید اصلی این است که ترجمه‌ی رفت و برگشت باید تصویر اولیه را بازتولید کند. این قید، آموزش را با داده‌ی *بدون‌جفت* ممکن می‌سازد.

Res-CycleGAN [۷۷] رمزگذار–رمزگشای باقیمانده را در چارچوب CycleGAN برای سی‌تی ریه به کار برد. **CyTran** [۷۸] لایه‌های پیچشی و توجه چندسر را در یک ترانسفورمر سازگار چرخه‌ای ترکیب کرد و همراه خود مجموعه‌داده‌ی Coltea-Lung-CT-100W را منتشر کرد. شی و همکاران [۷۹] CycleGAN و UNIT را نه برای تولید تصویر زیبا، بلکه به‌عنوان *انتقال* حوزه برای بهبود بخش‌بندی چندعضوی به کار بردند و معیارشان Dice پایین‌دستی بود، نه PSNR.

بهای این آزادی، از دست دادن نظارت پیکسل‌به‌پیکسل است: هیچ تضمینی وجود ندارد که مولد، آناتومی را حفظ کند و صرفاً بافت را «واقعی‌نما» نکند—خطری که در تصویربرداری پزشکی می‌تواند به **توهم**[۵۵] ساختارهای ناموجود بینجامد.

خانواده‌ی سوم: مدل‌های انتشار

موج اخیر این حوزه از GAN به **مدل‌های انتشار** گذر کرده است؛ خانواده‌ای که به‌جای آموزش تخاصمی، فرایند تدریجی حذف نویز را می‌آموزد و به همین دلیل آموزش پایدارتر و تنوع نمونه‌ی بهتری دارد، به قیمت استنتاج کندتر.

CFPS-Diff [۸۰] کامل‌ترین نماینده‌ی مستندشده‌ی این خانواده است. دو ایده‌ی اصلی دارد: **یادگیری الگوی جریان کنتراست**، که به‌جای نگاشت مستقل هر فاز، پویایی گذر ماده‌ی حاجب میان فازها را مدل می‌کند؛ و **یادگیری ویژگی خاص هر فاز** به‌همراه یک زیان آنتروپی متقاطع وزن‌دار با فاصله‌ی کلاس که تمایز میان فازها را تقویت می‌کند. تابع هدف ترکیبی از MAE و زیان موجک است. آموزش روی ۵۴۷ بیمار از یک بیمارستان و آزمون روی ۱۱۶ مورد از دو بیمارستان دیگر، به‌همراه یک مجموعه‌ی خارجی ۲۸ موردی با آسیب‌شناسی‌های نادر. نتایج روی مجموعه‌ی آزمون: میانگین MAE برابر ۳۱٫۲۰، SSIM برابر ۰٫۸۲۵ و PSNR برابر ۲۹٫۳۹؛ و روی مجموعه‌ی خارجی به‌ترتیب ۳۰٫۷۵، ۰٫۸۲۶ و ۲۹٫۴۲—یعنی عملاً بدون افت، که برای این حوزه غیرمعمول است.

نکته‌ی روش‌شناختی مهم این مقاله برای پایان‌نامه‌ی حاضر آن است که پیش‌پردازش آن صراحتاً شامل ثبت تصویر است: بهنجارسازی فضایی آفین با FSL و سپس SyN با ANTs برای هم‌ترازکردن فازهای کنتراست‌دار با فاز بدون‌کنتراست. یعنی حتی جدیدترین مدل‌های انتشار نیز نمی‌توانند از پیش‌نیاز هم‌ترازی بگریزند.

سایر کارهای این خانواده—AdverDM [۸۱]، مدل کنترل تبدیل فضایی [۸۲]، مولد فضازمانی علّی [۸۳] و مدل انتشار پل براونی با شرط‌دهی متنی [۸۴]—همگی در سال‌های ۲۰۲۵ و ۲۰۲۶ منتشر شده‌اند و هنوز جزئیات کامل مجموعه‌داده و معیار ارزیابی را گزارش نکرده‌اند.

خانواده‌ی چهارم: سنتز هدایت‌شده با ثبت تصویر

زیرمجموعه‌ای از این ادبیات، به‌جای فرض‌کردن هم‌ترازی، آن را بخشی از مسئله می‌داند.

CKAP-Net [۵] نزدیک‌ترین کار به مسئله‌ی این پایان‌نامه است. ایده‌ی محوری آن **تفکیک دانش**

[۵۵] Hallucination

کنتراست است: یک شبکه‌ی جداگانه می‌آموزد چه چیزی میان دو فاز مشترک است (آناتومی) و چه چیزی *متفاوت* است (اثر ماده‌ی حاجب)، تا مولد بتواند تنها مؤلفه‌ی دوم را اضافه کند. به آن یک **ترانسفورمر ادراک تشریحی چندمقیاسی** و یک **زیان ادراکی مبتنی‌بر ماده‌ی حاجب** افزوده شده که—برخلاف زیان ادراکی متعارف مبتنی‌بر VGG آموزش‌دیده روی تصاویر طبیعی دوبعدی—مخصوص همین وظیفه آموزش دیده است. داده: ۴۰۳ بیمار از مرکز اول و ۳۸ بیمار از مرکز دوم، همگی با جفت‌های بدون‌کنتراست و فاز شریانی دیررس، و ۱۳ اندام شکمی که برای زیرمجموعه‌ای از بیماران به‌دست متخصصان با بیش از ده سال تجربه برچسب خورده است.

نتایج: MAE برابر ۲۵/۹۶، SSIM برابر ۰/۸۵۵ و PSNR برابر ۳۲/۶۰ (در برابر ۳۸/۱۸، ۰/۷۸۰ و ۲۹/۲۸ برای مبنا). اما ارزشمندترین عدد این مقاله، معیار پایین‌دستی آن است: بخش‌بندی چندعضوی روی تصویر سنتزشده به Dice برابر ۸۱/۲۱ درصد و فاصله‌ی هاسدورف ۵/۴۶ میلی‌متر رسید. این دقیقاً همان زنجیره‌ی استدلالی است که پایان‌نامه‌ی حاضر دنبال می‌کند.

ژو و همکاران [۸۵] ثبت تغییرشکل‌پذیر و سنتز را در یک چارچوب یادگیری چندوظیفه‌ای *هم‌زمان* آموزش دادند، به‌طوری‌که خطای هم‌ترازی و خطای سنتز یکدیگر را اصلاح کنند. لی و همکاران [۸۶] با ماژول تفکیک سازگاری آناتومیک و یک زیرماژول ثبت مبتنی‌بر VoxelMorph، محتوای تشریحی را از سبک کنتراست جدا کردند؛ روی داده‌ی درون‌سازمانی ۲۷۸ بیمار مبتلا به سرطان کبد به MAE برابر ۱۶/۳۸، PSNR برابر ۳۶/۵۲ و SSIM برابر ۸۹/۲۲ درصد رسیدند. توجه: جهت سنتز در این مقاله CECT ← CT است، یعنی معکوس جهت مورد نیاز این پایان‌نامه؛ ارزش آن روش‌شناختی است، نه مستقیم.

اوهم و همکاران [۸۷] با اعمال DEEDS [۴۹] روی تمام فازها *پیش‌ازسنتز*، وابستگی مستقیم کیفیت سنتز به دقت ثبت پیشین را نشان دادند. این خط پژوهشی به‌روشنی تأیید می‌کند ثبت تصویر و سنتز، دو رویکرد رقیب نیستند بلکه دو مرحله‌ی مکمل یک زنجیره‌ی پردازشی‌اند.

خانواده‌ی پنجم: کاربردپذیری بالینی و کاهش دوز

شماری از مطالعات، به‌جای بهینه‌کردن معیارهای تصویری، مستقیماً می‌پرسند آیا این سنتز در بالین به کار می‌آید.

هان و همکاران [۸۸] بزرگ‌ترین اعتبارسنجی بالینی این حوزه را انجام دادند. آن‌ها یک U-Net دوونیم‌بعدی را با **یادگیری ضعیف‌نظارت** و با استفاده از تصاویر بدون‌کنتراست مجازی حاصل از سی‌تی دوانرژی آموزش دادند—راهکاری هوشمندانه برای دورزدن نیاز به جفت‌های واقعی. آموزش روی ۲,۲۰۲

جفت و اعتبارسنجی خارجی روی ۳۹۸ بیمار از سه مرکز و چند سازنده‌ی مختلف. PSNR برابر ۴۳/۲۵ و SSIM برابر ۰/۹۲ گزارش شد، اما یافته‌ی مهم‌تر بالینی است: با افزودن تصویر سنتزشده به تصویر بدون‌کنتراست، حساسیت سه رادیولوژیست در تشخیص ضایعه از ۷۲/۰ به ۷۶/۴ درصد و سطح اطمینان تشخیصی از ۳/۰ به ۳/۶ افزایش یافت.

کیم و همکاران [۸۹] با یک cGAN دومرحله‌ای، دقت تشخیصی سی‌تی مجازی کنتراست‌دار را در بیماران اورژانس با درد حاد شکمی سنجیدند.

هاوبولد و همکاران [۹۰] پرسش را وارونه کردند: به‌جای حذف کامل ماده‌ی حاجب، چقدر می‌توان آن را کم کرد؟ آن‌ها با سی‌تی دوانرژی ۸۵ بیمار، دوز کاهش‌یافته را به‌صورت مصنوعی شبیه‌سازی کردند (با تفریق نسبی نقشه‌ی ید) و چهار cGAN را برای بازسازی تصویر با دوز کامل آموزش دادند. مدل‌های کاهش ۵۰ درصدی به SSIM بالای ۹۹ درصد و PSNR بالای ۵۱ رسیدند و مدل‌های کاهش ۸۰ درصدی به SSIM بالای ۹۸ درصد و PSNR بالای ۴۸.

اما نتیجه‌گیری بالینی آن‌ها محتاطانه‌تر از این ارقام است و درسی مهم در بر دارد: تنها شبکه‌های کاهش ۵۰ درصدی به **سازگاری آسیب‌شناختی** ۱۰۰ درصدی رسیدند؛ در سطح کاهش ۸۰ درصدی، با وجود SSIM بالای ۹۸ درصد، یافته‌های آسیب‌شناختی در برخی موارد تغییر کردند. توجه: نسخه‌ی پیشین این پایان‌نامه «کاهش دوز تا حدود ۷۰ درصد» را به این مطالعه نسبت داده بود؛ عدد درست بر پایه‌ی متن مقاله ۵۰ درصد است. رقم مربوط به مطالعه‌ی حیوانی [۹۱] جداگانه باید بررسی شود. این یافته، شاهد دومی است بر همان نکته‌ای که در [۷۶] دیده شد: SSIM بالای ۹۸ درصد هیچ تضمینی برای حفظ اطلاعات تشخیصی نمی‌دهد.

آزادبرزین و همکاران [۹۲] و جو و همکاران [۹۳] در دو مرور نظام‌مند و گستره‌ای مجزا (به‌ترتیب با ۱۸ و ۵۶ مطالعه)، این حوزه را دسته‌بندی کرده‌اند و هر دو بر عدم‌بلوغ گزارش‌دهی کمّی در بخش قابل‌توجهی از این ادبیات تأکید کرده‌اند.

خانواده‌ی ششم: کد باز در وجهیت‌ها و اندام‌های مجاور

تصویری که تا این‌جا از بازتولیدپذیری ترسیم شد، در سراسر این حوزه یکسان نیست. اگر دامنه را از سی‌تی شکمی به وجهیت‌ها و اندام‌های مجاور گسترش دهیم، چند مطالعه کد خود را منتشر کرده‌اند و بررسی آن‌ها مرز واقعی دسترس‌پذیری را روشن‌تر می‌کند.

ژو و همکاران [۹۴] با **GLFC**، یک UNet تقویت‌شده با بلوک‌های Mamba در مسیرهای پرش به‌همراه زیان تباین چندگانه، سی‌تی مصنوعی را از CBCT سنتز کردند و SSIM را از ۷۷/۹۱ به ۹۱/۵۰

درصد رساندند؛ ارزیابی روی محک عمومی SynthRAD2023 و کد در دسترس است.

فوکودا و همکاران [۹۵] با CycleGAN استاندارد و داده‌ی ۲۵ بیمار، کنتراست را در ناحیه‌ی غدد لنفاوی ژوگولار داخلی سنتز کردند. ارزیابی آن‌ها نمونه‌ی روشنی از نارسایی معیارهای متعارف است: PSNR تصویر سنتزشده (میانه ۱۷/۸۰) از تصویر بدون‌کنتراست خام (۱۹/۷۴) *بدتر* بود، هرچند SSIM بهتر بود (۰/۶۴ در برابر ۰/۵۷). اما در آزمون تورینگ بصری، سه ناظر تنها ۵۰/۸ درصد مواقع توانستند تصویر سنتزشده را تشخیص دهند—یعنی در حد حدس تصادفی. مهم‌تر آن‌که در وظیفه‌ی بالینی تمایز غدد لنفاوی از عروق، سطح زیر منحنی برای تصویر سنتزشده ۱/۰ بود، دقیقاً برابر تصویر کنتراست‌دار واقعی، در حالی که برای تصویر بدون‌کنتراست تنها ۰/۷۲ بود. یعنی مدلی که بر اساس PSNR «شکست خورده» بود، از نظر بالینی کاملاً موفق بود.

رافنا و همکاران [۹۶] سه معماری (خودرمزگذار، Pix2Pix و CycleGAN) را برای سنتز تصویر بازترکیب‌شده در ماموگرافی طیفی کنتراست‌دار مقایسه کردند؛ CycleGAN بهترین عملکرد را داشت و کد به‌همراه مجموعه‌داده‌ی ۱,۱۳۸ تصویری منتشر شد. پینوک و همکاران [۹۷] یک چارچوب مولد شرطی‌شده بر فاز را برای سی‌تی مداخله‌ای در هدایت کرایوتراپی کلیوی توسعه دادند که با یک شبکه‌ی واحد میان فازهای مختلف جابه‌جا می‌شود. MMgSN-Net [۹۸] تصاویر T1w و T2w بدون‌کنتراست را برای سنتز T1w کنتراست‌دار در بیماران کارسینوم نازوفارنکس ترکیب کرد. TCGAN [۹۹] با دو مولد متوالی—نخست ترانسفورمری برای زمینه‌ی سراسری، سپس پیچشی برای جزئیات موضعی—سی‌تی مصنوعی را از PET سنتز کرد. کیدا و همکاران [۱۰۰] با CycleGAN بدون‌جفت، سی‌تی برنامه‌ریزی پرتودرمانی را از CBCT سنتز کردند و نرخ قبولی شاخص گاما را از ۸۶/۹۲ به ۹۶/۲۶ درصد افزایش دادند.

جمع‌بندی

این گروه از مطالعات نشان می‌دهند کد باز در این حوزه به‌کلی غایب نیست، اما دسترس‌پذیری آن با دو محدودیت مهم همراه است. نخست، کد باز عمدتاً در *حاشیه‌ی* مسئله متمرکز است: در وجهیت‌ها و اندام‌هایی که با سنتز NC‌ـبه‌ـCE شکمی خویشاوندند اما یکی نیستند؛ در هسته‌ی مسئله، تقریباً همه‌ی مطالعات روی داده‌ی خصوصی آموزش دیده‌اند و کد منتشر نکرده‌اند. دوم، جزئیات پیش‌پردازش—به‌ویژه کیفیت هم‌ترازی هندسی جفت‌های آموزشی—در بسیاری از این مقالات به‌طور کامل گزارش نشده است.

از همه مهم‌تر، **هیچ‌یک از این مطالعات معیاری برای سنجش کمّی کیفیت هم‌ترازی داده‌ی آموزشی گزارش نکرده‌اند**. بدون چنین معیاری، تفکیک سهم کیفیت داده از سهم خود مدل در نتیجه‌ی نهایی ممکن نیست؛ یعنی نمی‌توان تشخیص داد مدل کمبود کیفیت هم‌ترازی را جبران کرده یا نتیجه صرفاً بازتاب داده‌ای است که از پیش خوب هم‌تراز شده بود.

جدول ۲-۴ این ادبیات را در شش خانواده‌ی روش‌شناختی مرتب می‌کند و برای هر مطالعه، مجموعه‌داده، مقادیر PSNR و SSIM، سایر معیارهای گزارش‌شده و وضعیت انتشار کد را کنار هم می‌گذارد. سه الگو در این جدول برجسته است. نخست، *ناهمگنی معیارها*: حتی مطالعاتی که هر دو معیار PSNR و SSIM را گزارش می‌کنند، ارقامشان در بازه‌های کاملاً متفاوتی قرار دارد—از PSNR برابر ۱۷/۲۳ در [۱۰۱] و ۱۷/۴۴ در [۷۶] تا ۴۳/۲۵ در [۸۸]؛ اختلافی بیش از ۲۵ دسی‌بل، یعنی حدود سیصد برابر در نسبت توان خطا. این اختلاف عمدتاً بازتاب تفاوت در پنجره‌ی شدت روشنایی، دامنه‌ی محاسبه (کل تصویر در برابر درون نقاب بدن) و نوع داده است، نه تفاوت واقعی کیفیت. مقایسه‌ی مستقیم این اعداد میان سطرها بی‌معناست، و همین بی‌معنایی، یکی از انگیزه‌های پروتکل ارزیابی یکدست فصل ۳ است. دوم، *تعداد پرشمار سلول‌های خالی*: بخش قابل‌توجهی از مطالعات این حوزه، به‌ویژه در خانواده‌ی مدل‌های انتشار، هیچ مقدار کمّی قابل استخراجی گزارش نمی‌کنند؛ همان کاستی گزارش‌دهی که مرورهای [۹۲، ۹۳] نیز بر آن انگشت گذاشته‌اند. سوم، *تمرکز کد باز در حاشیه*: از میان ۱۲ مطالعه‌ی چهار خانواده‌ی نخست—یعنی دقیقاً همان‌ها که به مسئله‌ی این پایان‌نامه نزدیک‌ترند—تنها سه مورد کد تأییدشده دارند و هیچ‌یک از آن سه روی سی‌تی شکمی کار نمی‌کند. در مقابل، در خانواده‌ی ششم شش مطالعه از شش مطالعه کد منتشر کرده‌اند. یعنی کد باز در این حوزه هست، اما دقیقاً آن‌جا نیست که مسئله‌ی این پایان‌نامه قرار دارد. این یافته با کمیابی داده و کد بازتولیدپذیر مستندشده در بخش ۲-۳ هم‌راستاست.

جدول ۲-۴: ادبیات سنتز NC←به←CE، دسته‌بندی‌شده بر اساس خانواده‌ی روش. ستون «فاز داده‌ی آموزش» نشان می‌دهد آیا داده‌ی آموزش هر دو فاز را به‌صورت جفت‌شده در بر داشته است یا نه. سلول‌های [ ] مقادیری‌اند که متن مقاله در دسترس نبوده یا جدول نتایج آن به‌صورت تصویر ذخیره شده و باید دستی استخراج شوند.

روش (مرجع)	سال	داده و وظیفه	فاز داده‌ی آموزش	PSNR	SSIM	سایر معیارها	کد
خانواده‌ی یکم: GAN جفت‌شده (Paired GAN)							
Dual-path GAN [۱۰۱]	۲۰۲۲	خصوصی (۶۵ بیمار)؛ سنتز سه فاز شکم و لگن	هر دو فاز	شریانی: ۱۹/۰۹ وریدی: ۱۹/۷۹ تأخیری: ۱۷/۲۳	شریانی: ۰/۶۳ وریدی: ۰/۶۵ تأخیری: ۰/۶۵	—	×
cGAN بهبودیافته [۶۹]	۲۰۲۲	خصوصی (۸۶ بیمار)؛ سنتز شریانی و وریدی از ضایعات کبدی	هر دو فاز	شریانی: ۳۳/۱۸ وریدی: ۳۳/۰۲	شریانی: ۰/۸۱۹ وریدی: ۰/۸۱۹	PCC ۰/۹۵۶؛ ۰/۹۶۱	×

ادامه در صفحه‌ی بعد

ادامه‌ی جدول ۲-۴ از صفحه‌ی پیش

روش (مرجع)	سال	داده و وظیفه	فاز داده‌ی آموزش	PSNR	SSIM	سایر معیارها	کد
SAG-GAN [۷۰]	۲۰۲۳	همان داده‌ی بالا؛ افزودن توجه فضایی بدون‌نظارت	هر دو فاز	شریانی: ۳۳/۱۸ وریدی: ۳۳/۰۵	شریانی: ۰/۸۳۰ وریدی: ۰/۸۲۳	PCC ۰/۹۶۶؛ ۰/۹۶۸ SSIM کبد ۰/۹۳۲	×
SGCDD-GAN [۷۱]	۲۰۲۴	همان داده؛ رمزگشایی دوگانه + هدایت بخش‌بندی	هر دو فاز	[ ] (الف)	[ ] (الف)	دقت طبقه‌بندی ضایعه ٪۸۲/۶۸ دقت رادیولوژیست ٪۹۴/۱۱	×
OA-GAN [۷۲]	۲۰۲۴	خصوصی؛ سنتز آگاه از نقاب کبد	هر دو فاز	[ ]	[ ]	—	×
MAN-GAN [۷۳]	۲۰۲۵	۳۷۴ آموزش / ۱۴۴ آزمون داخلی / ۸۳ خارجی؛ سه فاز کبدی	هر دو فاز	[ ]	[ ]	ارزیابی رادیولوژیست	[ ]
MAFormer [۷۴]	۲۰۲۴	خصوصی؛ ترجمه‌ی چندفازی کبدی با تخمین تصویر تفریق	هر دو فاز	[ ]	[ ]	—	اعلام‌شده (ب)
AMNet [۷۵]	۲۰۲۵	۹۲ حجم (کلینیک کلیولند)؛ سنتز فاز وریدی	هر دو فاز (ثبت‌شده)	[ ] (الف)	[ ] (الف)	MAE؛ ارزیابی کل‌نگر و ناحیه‌ی تومور	×
pix2pix سه‌بعدی [۷۶]	۲۰۲۱	۲۵ توسعه / ۲۵ آزمون فنی / ۱۲ آزمون بالینی؛ قفسه‌سینه	هر دو فاز	سنتز: ۱۷/۴۴ مبنا NC: ۱۵/۹۷	سنتز: ۰/۸۴ مبنا NC: ۰/۸۱ (پ)	MAE ۴۱/۷۲؛ LPIPS ۰/۱۴ CNR ۶/۱۵ در برابر ۰/۷۴	✓
Phase-conditioned UNet [۹۷]	۲۰۲۳	سی‌تی مداخله‌ای؛ هدایت کرایوتراپی کلیوی	هر دو فاز	[ ]	۰/۹۹۴۹	Dice تومور ۰/۶۵	✓
سایر نمونه‌ها	[۱۰۲، ۱۰۳، ۱۰۴، ۱۰۵] — بدون مقادیر کمّی قابل استخراج در این پیمایش.						
خانواده‌ی دوم: سازگاری چرخه‌ای / آموزش بدون‌جفت							
Res-CycleGAN [۷۷]	۲۰۲۱	سی‌تی ریه؛ NC→CE	بدون‌جفت	[ ]	[ ]	—	×
CyTran [۷۸]	۲۰۲۱	Coltea-Lung-CT-100W (عمومی)؛ NC→CE ریه	بدون‌جفت	[ ]	[ ]	—	✓
UNIT/CycleGAN [۷۹]	۲۰۲۱	انتقال حوزه‌ی وریدی—بدون‌کنتراست برای بخش‌بندی چندعضوی	بدون‌جفت	—	—	Dice پایین‌دستی [ ]	× (ت)
سایر نمونه‌ها	[۱۰۶] — بدون مقادیر کمّی قابل استخراج در این پیمایش.						
خانواده‌ی سوم: مدل‌های انتشار							

ادامه در صفحه‌ی بعد

ادامه‌ی جدول ۲-۴ از صفحه‌ی پیش

روش (مرجع)	سال	داده و وظیفه	فاز داده‌ی آموزش	PSNR	SSIM	سایر معیارها	کد
CFPS-Diff [۸۰]	۲۰۲۵	۵۴۷ آموزش (یک مرکز) / ۱۱۶ آزمون (دو مرکز) / ۲۸ خارجی؛ سنتز سه فاز	هر دو فاز (ثبت‌شده)	آزمون: ۲۹/۳۹ خارجی: ۲۹/۴۲	آزمون: ۰/۸۲۵ خارجی: ۰/۸۲۶	MAE ۳۱/۲۰؛ FID ۳۰/۷۵، LPIPS گزارش‌شده	×
سایر نمونه‌ها	[۸۲، ۸۱، ۸۳، ۸۴، ۱۰۷] — منتشرشده در ۲۰۲۵–۲۰۲۶؛ جزئیات کامل مجموعه‌داده و معیار ارزیابی هنوز گزارش نشده است.						
خانواده‌ی چهارم: سنتز هدایت‌شده با ثبت تصویر							
CKAP-Net [۵]	۲۰۲۴	۴۰۳ + ۳۸ بیمار (دو مرکز)؛ سنتز شریانی دیررس + بخش‌بندی ۱۳ اندام	هر دو فاز (جفت‌شده)	۳۲/۶۰ (مبنا: ۲۹/۲۸)	۰/۸۵۵ (مبنا: ۰/۷۸۰)	MAE ۲۵/۹۶ Dice پایین‌دستی ۸۱/۲۱٪ HD ۵/۴۶	×
یادگیری چندوظیفه‌ای متحد [۸۵]	۲۰۲۳	شکمی؛ ثبت تغییرشکل‌پذیر و سنتز به‌صورت مشترک	هر دو فاز	[ ]	[ ]	—	×
تفکیک سازگاری آناتومیک [۸۶]	۲۰۲۴	۲۷۸ بیمار سرطان کبد + SynthRAD2023 لگنی؛ جهت CECT-به-CT	هر دو فاز (ثبت‌شده)	۳۶/۵۲	۸۹/۲۲٪	MAE ۱۶/۳۸	×
چارچوب متحد کلیوی [۸۷]	۲۰۲۲	سی‌تی چندفازی کلیه؛ ثبت DEEDS پیش از سنتز + طبقه‌بندی زیرگونه	هر دو فاز (ثبت‌شده)	[ ]	[ ]	دقت طبقه‌بندی زیرگونه [ ]	×
خانواده‌ی پنجم: کاربردپذیری بالینی و کاهش دوز ماده‌ی حاجب							
DL-SynCCT [۸۸]	۲۰۲۴	۲,۲۰۲ جفت آموزش (DECT)؛ ۳۹۸ بیمار خارجی از سه مرکز	هر دو فاز (VNC)	۴۳/۲۵	۰/۹۲	حساسیت تشخیص ضایعه ۷۲/۰٪ به ۷۶/۴٪ اطمینان ۳/۰ به ۳/۶	× (ث)
cGAN دومرحله‌ای [۸۹]	۲۰۲۱	بیماران اورژانس با درد حاد شکمی؛ سنجش دقت تشخیصی	هر دو فاز	[ ]	[ ]	دقت تشخیصی [ ]	×
cGAN کاهش دوز [۹۰]	۲۰۲۱	۸۵ بیمار (DECT، فاز شریانی)؛ بازسازی دوز کامل از دوز کاهش‌یافته	هر دو فاز (VNC)	کاهش ۵۰٪: >۵۱ کاهش ۸۰٪: >۴۸	کاهش ۵۰٪: >۹۹٪ کاهش ۸۰٪: >۹۸٪	FID ۱/۷–۰/۸ سازگاری آسیب‌شناختی ۱۰۰٪ فقط در کاهش ۵۰٪	×
مطالعه‌ی حیوانی [۹۱]	۲۰۲۲	۲۰ مینی‌پیگ؛ کاهش دوز ماده‌ی حاجب	هر دو فاز	[ ]	[ ]	[ ]	×
سایر نمونه‌ها	[۱۰۸، ۱۰۹، ۱۱۰، ۱۱۱] — بدون مقادیر کمّی قابل استخراج در این پیمایش.						
خانواده‌ی ششم: مطالعات دارای کد باز در وجهیت‌ها و اندام‌های مجاور							

ادامه در صفحه‌ی بعد

ادامه‌ی جدول ۲-۴ از صفحه‌ی پیش

روش (مرجع)	سال	داده و وظیفه	فاز داده‌ی آموزش	PSNR	SSIM	سایر معیارها	کد
GLFC [۹۴]	۲۰۲۵	SynthRAD2023 (عمومی)؛ CBCT به CT	CT/CBCT	[ ]	٪۹۱/۵۰ (مبنا :CBCT ٪۷۷/۹۱)	—	✓
CycleGAN [۹۵]	۲۰۲۴	خصوصی (۲۵ بیمار)؛ غدد لنفاوی ژوگولار داخلی	بدون‌جفت	سنتز: ۱۷/۸۰ مبنا :NC ۱۹/۷۴	سنتز: ۰/۶۴ مبنا :NC ۰/۵۷	AUC تمایز گره/عروق ۱/۰ در برابر ۰/۷۲ آزمون تورینگ ٪۵۰/۸	✓
CycleGAN [۱۰۰]	۲۰۲۰	CBCT به سی‌تی برنامه‌ریزی پرتودرمانی	بدون‌جفت	[ ]	[ ]	نرخ قبولی گاما ٪۸۶/۹۲ به ٪۹۶/۲۶	✓
CycleGAN (CESM) [۹۶]	۲۰۲۴	۱,۱۳۸ تصویر عمومی؛ ماموگرافی طیفی کنتراست‌دار	جفت‌شده	[ ]	[ ]	—	✓
MMgSN-Net [۹۸]	۲۰۲۲	MRI نازوفارنکس؛ T2w+T1w به T1w کنتراست‌دار	جفت‌شده	[ ]	[ ]	—	✓
TCGAN [۹۹]	۲۰۲۲	PET به CT؛ ارزیابی روی BraTS2020 و IXI	جفت‌شده	[ ]	[ ]	—	✓
مرورهای نظام‌مند و گستره‌ای							
مرور نظام‌مند [۹۲]	۲۰۲۳	۱۸ مطالعه؛ از کاهش دوز تا سنتز کامل	—	—	—	—	—
مرور گستره‌ای [۹۳]	۲۰۲۶	۵۶ مطالعه؛ سنتز کنتراست در CT و MRI	—	—	—	—	—

یادداشت‌ها: PSNR برحسب دسی‌بل، SSIM در بازه‌ی صفر تا یک مگر با علامت درصد، MAE و HD برحسب واحد HU و میلی‌متر. علامت ✓یعنی کد تأییدشده در دسترس است. **(الف)** جدول نتایج در متن مقاله به‌صورت تصویر ذخیره شده و لایه‌ی متنی PDF آن را در بر ندارد؛ باید دستی از مقاله خوانده شود. **(ب)** مقاله انتشار کد را اعلام کرده اما در زمان بررسی مخزن در دسترس نبود. **(پ)** این مقدار MS-SSIM است، نه SSIM متعارف. **(ت)** در شیت پیمایش، مخزن این مقاله با وضعیت «404» ثبت شده است؛ یعنی نشانی کد اعلام شده اما مخزن در دسترس نیست. **(ث)** بیانیه‌ی دسترسی به داده صراحتاً انتشار عمومی را به دلیل محدودیت هیئت اخلاق پژوهشی رد می‌کند؛ بیانیه‌ای برای کد منتشر نشده است.

۲-۷ جمع‌بندی و جای خالی پژوهش

با کنار هم قرار دادن یافته‌های پنج حوزه‌ی مرورشده در این فصل، تصویری منسجم از جای خالی پژوهشی شکل می‌گیرد. بخش‌بندی چندعضوی شکم، با وجود پیشرفت چشمگیر معماری‌های مبتنی‌بر nnU-Net، هنوز در فاز بدون‌کنتراست به‌طور نظام‌مند کم‌دقت‌تر از فاز کنتراست‌دار عمل می‌کند؛ پدیده‌ای که ریشه در کاهش نسبت کنتراست‌به‌نویز و جابه‌جایی حوزه‌ای وابسته به فاز دارد. مرور ادبیات مجموعه‌داده‌ها

نشان داد این محدودیت تنها یک مسئله‌ی الگوریتمی نیست: هیچ ارزیابی نظام‌مندی از کفایت و سوگیری مجموعه‌داده‌های عمومی این حوزه وجود نداشت، و به‌طور مشخص هیچ منبعی گزارش نکرده بود چه سهمی از این مجموعه‌داده‌ها اساساً هر دو فاز را در بر می‌گیرند. پرکردن این شکاف، نخستین مشارکت این پایان‌نامه است که پروتکل آن در بخش ۳-۲ و یافته‌هایش در بخش ۴-۱ ارائه می‌شود.

پیش از هر بهره‌برداری از همین داده‌ی چندفازیِ کمیاب، ادبیات تشخیص فاز کنتراست نشان داد شناسایی صحیح فاز هر بررسی، به دلیل ناقص و ناسازگاربودن برچسب‌های سرآیند DICOM، خود گامی پیش‌نیاز و غیربدیهی است و اغلب روش‌های موجود به بخش‌بندی اندام از پیش‌آموزش‌دیده یا حجم آموزشی بزرگ متکی‌اند.

در پاسخ به کمیابی داده‌ی جفت‌شده، ادبیات ثبت تصویر نشان داد معیارهای کلاسیک اطلاعات متقابل، به دلیل فرض پایداری رابطه‌ی شدت روشنایی در سطح کل تصویر، در برابر تغییر ناهمگن کنتراست شکننده‌اند و روش‌های آگاه از آناتومی موجود، آناتومی را برای *وزن‌دهی* نه *محدودسازی دامنه‌ی* معیار به کار می‌گیرند؛ جای خالی‌ای که تاکنون در ادبیات پژوهشی پوشش داده نشده است.

موازی با آن، ادبیات سنتز NC–به–CE، از GANهای جفت‌شده تا مدل‌های انتشار اخیر، نشان داد بازسازی مستقیم اطلاعات کنتراست از روی تصویر بدون‌کنتراست ممکن است، اما کیفیت آن هم‌چنان به دقت هم‌ترازی هندسی پیشین (از طریق ثبت تصویر) وابسته است. برخلاف تصور رایج، کد باز در این حوزه به‌کلی غایب نیست و چند مطالعه‌ی مرتبط، به‌ویژه در وجهیت‌ها و اندام‌های مجاور سی‌تی شکمی، کد خود را منتشر کرده‌اند؛ اما دقت گزارش‌شده هنوز جای بهبود دارد، اغلب این مطالعات روی طیف مجموعه‌داده‌های عمومی موجود آزموده نشده‌اند، و هیچ‌کدام معیاری برای سنجش کیفیت هم‌ترازی داده‌ی آموزشی گزارش نکرده‌اند که سهم داده را از سهم مدل در نتیجه‌ی نهایی تفکیک کند.

به‌طور خلاصه، چهار جای خالی مکمل از این مرور استخراج می‌شود: نیاز به تشخیص قابل‌اعتماد فاز کنتراست مستقل از برچسب‌های ناقص سرآیند؛ نبود پایپ‌لاین ثبت تصویری که دامنه‌ی محاسبه‌ی معیار تراز را، نه صرفاً وزن آن را، به نواحی پایدار در برابر فاز کنتراست محدود کند؛ کمیابی جفت‌های هم‌ترازِ بدون‌کنتراست/کنتراست‌دار برای آموزش و ارزیابی مدل‌های سنتز؛ و فقدان شواهد کمّی درباره‌ی اثر این مداخلات بر شکاف دقت بخش‌بندی چندعضوی میان دو فاز. فصل روش پیشنهادی (فصل بعد) به این جاهای خالی می‌پردازد.

فصل ۳

روش پیشنهادی

این فصل روش پیشنهادی این پایان‌نامه را ارائه می‌کند. ساختار فصل مستقیماً از چهار جای خالی‌ای پیروی می‌کند که در پایان فصل ۲ استخراج شد: نبود سازوکار قابل‌اعتماد برای تشخیص فاز کنتراست مستقل از سرآیند، نبود پایپ‌لاین ثبت تصویری که *دامنه‌ی* محاسبه‌ی معیار تراز را به نواحی پایدار محدود کند، کمیابی جفت‌های هم‌تراز برای آموزش مدل‌های سنتز، و فقدان شواهد کمّی درباره‌ی اثر این مداخلات بر شکاف دقت بخش‌بندی.

بخش ۳-۱ نمای کلی و منطق زنجیره‌ی مؤلفه‌ها را شرح می‌دهد. بخش ۳-۳ داده و پیش‌پردازش مشترک را معرفی می‌کند. سه بخش بعدی به‌ترتیب سه مؤلفه‌ی روش را ارائه می‌دهند: تشخیص فاز کنتراست (بخش ۳-۴)، ثبت تصویر بین‌فازی چندگذره (بخش ۳-۵) و سنتز فاز کنتراست‌دار (بخش ۳-۶). بخش ۳-۷ پروتکل ارزیابی را تعریف می‌کند؛ این بخش صرفاً فهرستی از معیارها نیست، بلکه خود بخشی از سهم روش‌شناختی این پایان‌نامه است، چرا که——چنان‌که نشان داده خواهد شد——معیارهای متعارف سطح‌پیکسل قادر به رتبه‌بندی مدل‌های این مسئله نیستند.

۳-۱ نمای کلی

سه مؤلفه‌ی این روش یک زنجیره‌ی وابسته تشکیل می‌دهند و نه سه کار موازی.

نقطه‌ی شروع، محدودیت داده است. برای آموزش نظارت‌شده‌ی هر مدل سنتز NC_به_CE، به جفت‌هایی از یک بیمار نیاز است که هم فاز بدون‌کنتراست و هم فاز کنتراست‌دار آن موجود و از نظر هندسی هم‌تراز باشند. مرور مجموعه‌داده‌ها [۶] نشان داد چنین داده‌ای کمیاب است. بنابراین جفت‌ها

باید از داده‌ی چندفازی موجود *ساخته* شوند، و ساختن آن‌ها دو پیش‌نیاز دارد:

- **شناسایی فاز.** برای آن‌که بدانیم کدام سری از یک بررسی، فاز بدون‌کنتراست و کدام فاز وریدی است، به برچسب فاز نیاز است. سرآیند DICOM این برچسب را به‌طور قابل‌اتکا فراهم نمی‌کند (بخش ۲-۴). مؤلفه‌ی نخست این خلأ را پر می‌کند.
- **هم‌ترازسازی هندسی.** دو سری از یک بررسی در دو زمان و با تنفس متفاوت گرفته شده‌اند و بدون ثبت تصویر، جفت *نیستند*. مؤلفه‌ی دوم این هم‌ترازی را انجام می‌دهد.

مؤلفه‌ی سوم، سنتز، بر خروجی این دو تکیه می‌کند. اما رابطه‌ی مؤلفه‌ی نخست با مؤلفه‌ی سوم عمیق‌تر از یک پیش‌نیاز اجرایی است: مدل تشخیص فاز، علاوه بر نقش دروازه‌بانی داده، به *ابزار اندازه‌گیری* ارزیابی سنتز نیز تبدیل می‌شود. همان‌طور که در بخش ۳-۷ تشریح می‌شود، معیار اصلی این پایان‌نامه برای سنجش وفاداری کنتراستِ تصویر تولیدشده، از ویژگی‌های سطح‌اندام همین مدل استخراج می‌شود. به این ترتیب مؤلفه‌ای که برای آماده‌سازی داده ساخته شد، مسئله‌ی سنجش را نیز حل می‌کند.

سرانجام، پرسش پایانی پایان‌نامه—آیا این مداخلات شکاف دقت بخش‌بندی چندعضوی را کاهش می‌دهند—یک ارزیابی پایین‌دستی[1] جداگانه می‌طلبد که در بخش ۳-۷ تعریف می‌شود.

۳-۲ مرور نظام‌مند مجموعه‌داده‌های سی‌تی شکمی: پروتکل

بخش ۲-۳ نشان داد هیچ ارزیابی نظام‌مندی از مجموعه‌داده‌های عمومی سی‌تی شکمی به‌عنوان منبع آموزش هوش مصنوعی وجود ندارد. این بخش، پروتکلی را که برای پرکردن این شکاف تدوین شد شرح می‌دهد؛ یافته‌های حاصل در بخش ۴-۱ گزارش می‌شوند. نتایج این مرور به‌طور مستقل نیز منتشر شده است [۶].

شناسایی و معیارهای ورود

جست‌وجو در Google Scholar، PubMed، Scopus و مخازن نهادی از جمله TCIA انجام شد. جست‌وجوی نخست میان مهر و آذر ۱۴۰۳ و دو جست‌وجوی به‌روزرسانی میان آذر ۱۴۰۴ و بهمن ۱۴۰۴ صورت گرفت. افزون بر جست‌وجوی پایگاهی، فهرست مراجع و توصیف منبع داده‌ی هر مجموعه‌داده‌ی یافت‌شده بررسی شد تا مجموعه‌داده‌های سازنده‌ای که در مجموعه‌های ترکیبی بازاستفاده شده‌اند ردیابی

[1] Downstream

شوند—گامی که برای کمّی‌کردن بازاستفاده ضروری بود. مخازن خارج از ادبیات متعارف (Kaggle، Zenodo، Grand Challenge) نیز پیمایش شدند.

پنج معیار ورود اعمال شد: داده باید حجمی[۲] سه‌بعدی باشد (نه برش‌های دوبعدی استخراج‌شده)؛ دست‌کم یک ناحیه‌ی برچسب‌خورده به‌صورت نقاب چندضلعی یا وکسلی داشته باشد؛ برچسب‌ها از وظیفه‌ای بالینی پشتیبانی کنند؛ برچسب‌ها به ساختارهای شکمی مربوط باشند؛ و مجموعه‌داده دست‌کم در یک مقاله‌ی داوری‌شده استفاده شده باشد. معیار آخر بدین معناست که این مرور، *چشم‌انداز منتشرشده* را نمایندگی می‌کند، نه کل منابع موجود.

جست‌وجو ۴۸ نامزد شناسایی کرد که پس از اعمال معیارها سه مورد کنار گذاشته شد و **۴۵ مجموعه‌داده** باقی ماند.

استخراج داده

دو ارزیاب مستقل، داده را با فرم استاندارد استخراج کردند و در موارد اختلاف، ارزیاب سوم داوری کرد. استخراج در شش محور انجام شد: ترکیب مجموعه‌داده، بافت بالینی، خاستگاه داده، ویژگی‌های تصویربرداری (شامل **وضعیت فاز کنتراست**)، جزئیات برچسب‌گذاری، و اطلاعات جمعیت‌شناختی. محور چهارم، که وضعیت فاز کنتراست را ثبت می‌کند، همان محوری است که ارقام مورد نیاز بخش‌های ۳-۵ و ۳-۶ این فصل را فراهم می‌آورد.

چارچوب ارزیابی ریسک سوگیری

از آن‌جا که هیچ چک‌لیست پذیرفته‌شده‌ای برای این منظور وجود ندارد (بخش ۲-۳)، یک چارچوب هفت‌مقوله‌ای با تطبیق سه ابزار موجود تدوین شد: PROBAST+AI [۳۱]، معیارهای کیفیت کوچاک و همکاران [۲۹]، و راهنمای گزارش‌دهی TRIPOD+AI [۳۲]. هر مقوله در سه سطح ریسک پایین، متوسط یا بالا امتیاز می‌گیرد، و مقوله‌هایی که مستندات اولیه اطلاعات کافی برای آن‌ها فراهم نمی‌کرد با برچسب «در دسترس نیست» ثبت شدند. جدول ۳-۱ این هفت مقوله را خلاصه می‌کند.

این ارزیابی تنها روی ۲۲ مجموعه‌داده با صد نمونه‌ی عمومی یا بیشتر انجام شد؛ مجموعه‌داده‌های کوچک‌تر به‌طور پیش‌فرض در اغلب مقوله‌ها ریسک بالا می‌گیرند و این امر ارزش تمایزی طبقه‌بندی را از میان می‌برد.

---

[۲] Volumetric

جدول ۳-۱: هفت مقوله‌ی چارچوب ارزیابی ریسک سوگیری، به همراه تعریف عملیاتی و تهدید مرتبه‌بالاتری که هر مقوله به آن مربوط است.

مقوله	محور ارزیابی	تهدید مرتبه‌بالاتر
سوگیری طیف[۳]	پوشش دامنه‌ی شدت و تنوع بالینی درون گروه مثبت	نمایندگی موارد
سوگیری انتخاب[۴]	پوشش تشخیص‌های افتراقی در گروه غیرمثبت	نمایندگی موارد
سوگیری برچسب‌گذاری[۵]	دقت و سازگاری فرایند حاشیه‌نویسی؛ تعداد و تخصص بازبین‌ها	نمایندگی موارد و جابه‌جایی حوزه
سوگیری نژادی[۶]	نمایندگی گروه‌های نژادی و قومی نسبت به جامعه‌ی هدف	سوگیری جمعیتی
سوگیری جمعیت‌شناختی[۷]	توازن جنسیت و توزیع سنی	سوگیری جمعیتی
سوگیری فنی[۸]	تنوع سخت‌افزار تصویربرداری، پروتکل و تزریق ماده‌ی حاجب	جابه‌جایی حوزه
سوگیری زمانی[۹]	بازه‌ی زمانی گردآوری داده	جابه‌جایی حوزه

فرایند ارزیابی و پایایی

سه ارزیاب—یک پژوهشگر تصویربرداری پزشکی، یک پزشک با تجربه‌ی پژوهشی در تحلیل تصویر پزشکی، و یک پزشک عمومی با تجربه‌ی پژوهشی در تصویربرداری—به‌طور مستقل همه‌ی مجموعه‌داده‌های واجد شرایط را ارزیابی کردند. پیش از ارزیابی مستقل، جلسه‌ی کالیبراسیون مشترکی برای یکسان‌سازی تفسیر تعاریف عملیاتی برگزار شد. ارزیابی تنها بر مبنای مستندات اولیه‌ی در دسترس عموم انجام شد و با سازندگان مجموعه‌داده‌ها تماس گرفته نشد؛ این تصمیم تضمین می‌کند ارزیابی، همان اطلاعاتی را بازتاب دهد که در اختیار جامعه‌ی پژوهشی است.

اختلاف میان دو یا چند ارزیاب، به‌عنوان تعارض تعریف و توسط ارزیاب چهارم در مشورت با یک رادیولوژیست بوردشده حل شد. پایایی بین‌ارزیاب با آلفای کریپندورف (با وزن‌دهی فاصله‌ی ترتیبی) سنجیده شد: مقدار کلی ۰/۷۲۷ با فاصله‌ی اطمینان ۹۵ درصدِ ۰/۶۲ تا ۰/۸۴، که توافق قابل‌ملاحظه تلقی می‌شود. مقادیر به‌تفکیک مقوله از ۰/۱۹۹ برای سوگیری زمانی تا ۰/۸۲۰ برای سوگیری انتخاب متغیر بود؛ پایین‌بودن توافق در سوگیری زمانی، بازتاب ناقص‌بودن گزارش بازه‌ی گردآوری در مستندات اغلب مجموعه‌داده‌هاست.

طبقه‌بندی کلی سوگیری

برای تجمیع امتیازهای مقوله‌ای به یک طبقه‌بندی کلی، یک امتیاز پیوسته بر پایه‌ی سه اصل تعریف شد: ساختار چنددامنه‌ای ROBINS-I [۱۱۲]، منطق کاهش تجمعی GRADE [۱۱۳]، و این اصل از QUADAS-2 [۱۱۴] که دامنه‌ی مستندنشده را نمی‌توان کم‌ریسک فرض کرد. مقوله‌های «در دسترس نیست» برای محاسبه، ریسک متوسط در نظر گرفته شدند:

$$\text{امتیاز سوگیری} = \sum(\text{ریسک بالا}) \times ۱/۰ \; + \; \sum(\text{ریسک متوسط} + \text{در دسترس نیست}) \times \tfrac{۱}{۴} \qquad (۳\text{-}۱)$$

آستانه‌ها متناسب با چارچوب هفت‌مقوله‌ای تعیین شدند: امتیاز ۳/۰ و بالاتر «سوگیری بحرانی»، ۲/۰ تا زیر ۳/۰ «سوگیری بالا»، ۱/۰ تا زیر ۲/۰ «سوگیری متوسط»، و زیر ۱/۰ «سوگیری پایین».

۳-۳ داده و پیش‌پردازش

مجموعه‌داده

آزمایش‌های این پایان‌نامه بر مجموعه‌داده‌ی عمومی VinDr-Multiphase [۷] انجام می‌شود. این مجموعه، بررسی‌های سی‌تی شکمی چندفازی را همراه با برچسب فاز در سطح سری فراهم می‌کند و از این رو هم برای آموزش و ارزیابی مدل تشخیص فاز و هم—پس از ثبت تصویر—برای ساخت جفت‌های آموزشی سنتز مناسب است.

انتخاب یک مجموعه‌داده‌ی عمومی به‌جای داده‌ی خام گردآوری‌شده، تصمیمی آگاهانه است: هر ادعای این پایان‌نامه درباره‌ی سنتز باید روی داده‌ای قابل بازتولید توسط دیگران آزمون شود، و مرور مجموعه‌داده‌ها [۶] نشان داد که همین قابلیت بازاستفاده، کمبود اصلی ادبیات این حوزه است.

پس از اعمال پایپ‌لاین ثبت تصویر (بخش ۳-۵) و کنارگذاری جفت‌هایی که معیار کیفیت هم‌ترازی را برآورده نمی‌کنند، 137 جفت هم‌ترازشده‌ی بدون‌کنتراست/وریدی و 136 جفت بدون‌کنتراست/شریانی باقی می‌ماند. این جفت‌ها در سطح *بیمار*—و نه در سطح برش یا سری—به سه بخش تقسیم می‌شوند: 97 مورد آموزش، 20 مورد اعتبارسنجی و 20 مورد آزمون. تقسیم با بذر تصادفی ثابت انجام و در یک فایل منجمد ذخیره می‌شود، و همه‌ی مدل‌های این پایان‌نامه—اعم از مدل‌های پیشنهادی و مدل‌های مبنای بازپیاده‌سازی‌شده از ادبیات—بدون استثنا روی همین تقسیم آموزش و ارزیابی می‌شوند. تقسیم در سطح

بیمار، نشت اطلاعات میان برش‌های مجاور یک بیمار را که در ادبیات سنتز تصویر پزشکی خطای رایجی است حذف می‌کند.

استانداردسازی هندسی و شدت روشنایی

همه‌ی حجم‌ها به فاصله‌ی وکسل همسان‌گرد[۱۰] 1.5 میلی‌متر بازنمونه‌برداری می‌شوند. یکنواختی این مقدار در سراسر مجموعه به‌صورت تجربی تأیید شده است و نه فرض‌شده؛ اهمیت این تأیید در فصل ۴ روشن می‌شود، آن‌جا که ناهمگنی فاصله‌ی وکسل به‌عنوان یکی از توضیح‌های ممکن برای کف خطای سنتز کنار گذاشته می‌شود.

شدت روشنایی با یک پنجره‌ی HU ثابت در بازه‌ی $[-۲۰۰, ۴۰۰]$ به بازه‌ی $[۰, ۱]$ نگاشت می‌شود. این پنجره بافت نرم شکمی و محدوده‌ی کنتراست عروقی را پوشش می‌دهد. انتخاب یک پنجره‌ی *واحد* برای همه‌ی مدل‌ها یک الزام روش‌شناختی است، نه یک جزئیات پیاده‌سازی: تغییر پنجره، مقدار عددی هر معیار سطح‌پیکسل را تغییر می‌دهد، و مقایسه‌ی دو مدل که با دو پنجره‌ی متفاوت سنجیده شده‌اند بی‌معناست.

نقاب‌های اندام

نقاب‌های اندام با TotalSegmentator [۱۰] تولید می‌شوند. خروجی پرشمار این ابزار سپس به یک حجم برچسب فشرده با قرارداد ثابت ادغام می‌شود که در آن هر اندام یک شناسه‌ی عددی یکتا دارد. دو نقاب از این ادغام حاصل می‌شود و تمایز میان آن‌ها در ادامه‌ی فصل نقش محوری دارد:

- **نقاب کامل**: همه‌ی اندام‌های بخش‌بندی‌شده. این نقاب دامنه‌ی *ارزیابی* است.
- **نقاب ثبت**: تنها استخوان‌ها و اندام‌های نرمِ پایدار در برابر فاز کنتراست. روده، ساختارهای پرکنتراست عروقی و ساختارهای دارای حرکت دودی[۱۱] به‌صراحت از آن حذف شده‌اند. این نقاب دامنه‌ی *محاسبه‌ی معیار تراز* است.

نقاب‌ها از فاز کنتراست‌دار استخراج می‌شوند، چرا که مرزهای اندام در آن فاز به‌مراتب واضح‌تر است. پیامد این انتخاب آن است که این نقاب‌ها را نمی‌توان به‌عنوان ورودی به مولد سنتز داد——چنین کاری اطلاعات هدف را به ورودی نشت می‌دهد——و کاربردشان به وزن‌دهی تابع زیان و تعریف معیارها محدود می‌ماند. این محدودیت در بخش ۳-۷ دوباره مطرح می‌شود.

[۱۰] Isotropic
[۱۱] Peristalsis

۳-۴ تشخیص فاز کنتراست

انگیزه‌ی طراحی

چنان‌که در بخش ۲-۴ مرور شد، بیشتر روش‌های موجود تشخیص فاز یا به شبکه‌های عصبی سه‌بعدی با نیاز داده‌ی آموزشی زیاد متکی‌اند یا مستقیماً روی حجم خام کار می‌کنند و در نتیجه به دستگاه، پروتکل و هسته‌ی بازسازی حساس‌اند. طراحی این پایان‌نامه از فرض متفاوتی آغاز می‌شود:

> فاز کنتراست، در تعریف بالینی خود، چیزی جز *الگوی شدت روشنایی در اندام‌های مشخص* نیست. رادیولوژیست فاز را از روی روشنایی آئورت نسبت به ورید باب و پارانشیم کبد تشخیص می‌دهد، نه از بافت کلی تصویر.

اگر این فرض درست باشد، آن‌گاه بازنمایی درست مسئله نه حجم خام، بلکه بردار کوچکی از آماره‌های سطح‌اندام است. چنین بازنمایی‌ای سه مزیت دارد: ابعاد ورودی از چند میلیون وکسل به چند ده عدد کاهش می‌یابد و مسئله با داده‌ی آموزشی اندک قابل‌حل می‌شود؛ ویژگی‌ها واحد فیزیکی (HU) دارند و در نتیجه میان دستگاه‌ها قابل‌انتقال‌ترند؛ و مدل حاصل *تفسیرپذیر* است، زیرا سهم هر اندام در تصمیم قابل استخراج است.

استخراج ویژگی

برای هر حجم، نقاب اندام با TotalSegmentator [۱۰] محاسبه و سپس برای هر اندام یک ویژگی—*میانه‌ی* HU درون آن اندام—استخراج می‌شود. انتخاب میانه به‌جای میانگین عمدی است: میانه در برابر داده‌ی پرت مقاوم است، و ضایعات کانونی، کلسیفیکاسیون و خطاهای موضعی بخش‌بندی دقیقاً همان داده‌ی پرتی هستند که میانگین را جابه‌جا می‌کنند.

نگاشت نام اندام به شناسه‌ی برچسب در زمان اجرا از نسخه‌ی نصب‌شده‌ی TotalSegmentator خوانده می‌شود و در کد ثابت نشده است؛ در غیر این صورت، ارتقای نسخه‌ی این ابزار می‌توانست بی‌سروصدا ویژگی‌ها را جابه‌جا کند و مدل را بی‌آن‌که خطایی رخ دهد بی‌اعتبار سازد.

طبقه‌بند

بردار ویژگی به یک طبقه‌بند تقویت گرادیان درختی[۱۲] از نوع XGBoost [۱۱۵] داده می‌شود. انتخاب این خانواده‌ی مدل، با توجه به ابعاد داده، طبیعی است: تعداد نمونه‌ها اندک و تعداد ویژگی‌ها کم است، ویژگی‌ها ناهمگن و دارای مقیاس فیزیکی‌اند، و رابطه‌ی میان روشنایی اندام و فاز آستانه‌ای و غیرخطی است—دقیقاً وضعیتی که درخت‌های تصمیم در آن بر شبکه‌های عصبی برتری دارند.

مدل با اعتبارسنجی متقاطع لایه‌ای[۱۳] ارزیابی می‌شود تا توزیع کلاس‌ها در هر تا حفظ شود. دو نسخه از مدل آموزش داده می‌شود: یکی روی مجموعه‌داده‌ی WAW-TACE و دیگری روی VinDr-Multiphase، تا انتقال‌پذیری میان مجموعه‌داده‌ها نیز سنجیده شود. نتایج در فصل ۴ گزارش می‌شود.

۵-۳ ثبت تصویر بین‌فازی چندگذره

ایده‌ی مرکزی: محدودسازی دامنه، نه وزن‌دهی

معیارهای کلاسیک ثبت تصویر چندوجهی، به‌ویژه اطلاعات متقابل[۱۴] [۴۴، ۴۶]، بر این فرض بنا شده‌اند که میان شدت روشنایی دو تصویر یک رابطه‌ی آماری *یکنواخت در سراسر تصویر* برقرار است. تزریق ماده‌ی حاجب این فرض را نقض می‌کند و نقض آن یکنواخت نیست: آئورت ممکن است بیش از صد واحد HU روشن‌تر شود، کبد چند ده واحد، و استخوان اصلاً تغییر نکند. هیستوگرام مشترک میان دو فاز در نتیجه چندمُدی[۱۵] می‌شود و معیاری که روی کل تصویر تعریف شده است، روی این ناهمگنی حاشیه‌گیری[۱۶] می‌کند و اطلاعات را از دست می‌دهد.

روش‌های آگاه از آناتومی موجود در ادبیات (بخش ۲-۵) به این مشکل با *وزن‌دهی* پاسخ می‌دهند: معیار همچنان روی کل تصویر محاسبه می‌شود، اما سهم نواحی مختلف در آن متفاوت است. پیشنهاد این پایان‌نامه از این نقطه جدا می‌شود:

معیار تراز نباید در نواحی ناپایدار وزن کمتری بگیرد؛ نباید در آن نواحی *محاسبه* شود.

به بیان صوری، اگر $\mathcal{M}$ نقاب اندام‌های پایدار در برابر فاز باشد، معیار S نه به‌صورت $\sum_x w(x)\, s(x)$ با w کوچک بیرون از $\mathcal{M}$، بلکه به‌صورت $\sum_{x\in\mathcal{M}} s(x)$ تعریف می‌شود. تفاوت این دو، در حالتی که w به

[۱۲] Gradient-boosted trees
[۱۳] Stratified k-fold cross-validation
[۱۴] Mutual information
[۱۵] Multi-modal
[۱۶] Marginalise

صفر میل کند، از نظر ریاضی از میان می‌رود؛ اما در عمل تفاوت اساسی است، زیرا در فرمول‌بندی وزنی، هیستوگرام مشترک—که اطلاعات متقابل از آن ساخته می‌شود—همچنان از وکسل‌های ناپایدار انباشته می‌شود و چندمُدی می‌ماند. محدودسازی دامنه، هیستوگرام را نیز محدود می‌کند.

ساخت نقاب چهارلایه

نقاب $\mathcal{M}$ از حجم برچسب ادغام‌شده‌ی بخش ۳-۳ ساخته می‌شود، با تقسیم اندام‌ها به لایه‌های زیر:

- **لایه‌ی ۱ — استخوان.** مهره‌ها، دنده‌ها، لگن، جناغ و طناب نخاعی. این ساختارها صلب‌اند و شدت روشنایی‌شان به‌کلی مستقل از فاز کنتراست است؛ بنابراین بالاترین اعتماد را دارند و مرجع صحت‌سنجی گذر صلب‌اند.
- **لایه‌ی ۲ — بافت نرم پایدار.** کبد، طحال، کلیه‌ها، پانکراس، کیسه‌ی صفرا و عضلات محوری. این‌ها با کنتراست تغییر می‌کنند اما شکل و موقعیتشان پایدار است.
- **لایه‌ی ۳ — سایر بافت نرم.** معده، مثانه، غدد فوق‌کلیه، لوب‌های ریه. تنها در نقاب *ارزیابی* حضور دارند.
- **حذف‌شده.** روده‌ی بزرگ و کوچک، دوازدهه و رکتوم. این ساختارها میان دو اسکن به‌دلیل حرکت دودی و گاز، جابه‌جایی غیرقابل‌مدل‌سازی دارند و حضورشان در معیار تراز، خطا وارد می‌کند نه اطلاعات.

نقاب ثبت از لایه‌های ۱ و ۲ ساخته می‌شود. پوشش نقاب (درصد وکسل‌های حجم) در هر مورد ثبت و پایش می‌شود؛ پوشش بسیار کم نشانه‌ی شکست بخش‌بندی است و باید پیش از تفسیر نتیجه‌ی ثبت تصویر شناسایی شود.

استانداردسازی پیش از ثبت

پیش از هر محاسبه‌ی هندسی، هر سری از جهت‌های راهنمای DICOM به قرارداد LPS بازآرایی و به فاصله‌ی وکسل همسان‌گرد 1.5 میلی‌متر بازنمونه‌برداری می‌شود. دو جزئیات این گام، که در نگاه نخست پیاده‌سازی به نظر می‌رسند، در عمل تعیین‌کننده‌اند.

نخست، *مقدار پرکننده‌ی مرز* در بازنمونه‌برداری به‌صورت ثابت -1024 واحد HU (هوا) تعیین می‌شود و نه کمینه‌ی خود تصویر. اسکنرهای سی‌تی وکسل‌های بیرون از میدان دید را با یک مقدار نشانه[۱۷] ذخیره می‌کنند که پس از اعمال شیب و عرض‌ازمبدأ به -4048 واحد HU می‌رسد؛ استفاده از این مقدار به‌عنوان پرکننده، هر وکسل مرزی حاصل از بازنمونه‌برداری را با عددی پر می‌کند که هیچ بافتی تولید نمی‌کند و هیستوگرام مشترک را که معیارهای مبتنی‌بر اطلاعات از آن ساخته می‌شوند آلوده می‌کند.

دوم، بازه‌ی HU به $[-1024, +3000]$ برش داده می‌شود. کران پایین همان مقدار نشانه را حذف می‌کند. کران بالا عمداً بالاتر از $+1024$ انتخاب شده است: برش در $+1024$ استخوان متراکم قشری را می‌بُرد و کیفیت بخش‌بندی ساختارهای اسکلتی را—که در گذرهای بعدی نقش لنگر هندسی دارند—به‌طور محسوس کاهش می‌داد.

هم‌ترازسازی مرکز جرم با دروازه‌ی اطمینان

دو سری از یک بررسی اغلب محدوده‌ی آناتومیک متفاوتی را پوشش می‌دهند. پیش از هر بهینه‌سازی مبتنی‌بر شدت روشنایی، جابه‌جایی درشت میان دو حجم از مرکز جرم سه‌بعدی چهار اندام *لنگر*—کبد، طحال و دو کلیه—در فضای فیزیکی برآورد می‌شود. این چهار اندام بزرگ‌اند و موقعیتشان میان فازها پایدار است.

این گام سه‌گانه *دروازه‌دار* است. یک نمره‌ی اطمینان γ، که سهم وزنی اندام‌های واقعاً یافت‌شده از کل وزن ممکن است، تعیین می‌کند که آیا برآورد قابل‌اتکاست؛ اگر γ از 0.40 کمتر باشد، یا اندازه‌ی جابه‌جایی از 80 میلی‌متر بیشتر، یا پراکندگی برآوردهای تک‌اندام از 12 میلی‌متر فراتر رود، هیچ جابه‌جایی‌ای اعمال نمی‌شود. منطق این محافظه‌کاری آن است که یک هم‌ترازسازی درشتِ نادرست بدتر از نبود آن است: بهینه‌سازی بعدی را به کمینه‌ی محلی اشتباه هدایت می‌کند.

افزون بر آن، دو ناحیه‌ی مرده[۱۸] اعمال می‌شود: جابه‌جایی محور z کمتر از 7.5 میلی‌متر و جابه‌جایی درون‌صفحه‌ای کمتر از 5 میلی‌متر نویز هم‌جلسه‌ای تلقی و نادیده گرفته می‌شوند، چرا که اعمال یک بازنمونه‌برداری اضافی برای تصحیحی در این مقیاس، بیش از آن‌که هم‌ترازی را بهبود دهد، وفاداری درون‌یابی را هزینه می‌کند.

شاخه‌ی شاهد. در کنار این مسیر، شاخه‌ی دومی اجرا می‌شود که *همان* پنجره‌ی برش فیزیکی را می‌سازد اما هیچ هم‌ترازی‌ای اعمال نمی‌کند. چون تنها متغیر میان دو شاخه اعمالِ جابه‌جایی است، مقایسه‌ی آن‌ها سهم این گام را به‌صورت کنترل‌شده جدا می‌کند. شکل ۳-۱ این انشعاب و جایگاه آن در کل زنجیره را

[۱۷] Sentinel value
[۱۸] Deadband

نشان می‌دهد.

ثبت صلب سه‌گذره

گذر صفر — مقداردهی اولیه‌ی بسته. به‌جای آغاز بهینه‌سازی از تبدیل همانی، یک تبدیل صلب اولیه به‌صورت بسته و بدون بهینه‌سازی تکراری محاسبه می‌شود. مرکز جرم هر اندام *نقاب ثبت*—یعنی هم استخوان‌های لایه‌ی ۱ و هم بافت نرم پایدار لایه‌ی ۲—در دو حجم به‌عنوان یک زوج نقطه‌ی متناظر در نظر گرفته می‌شود و چرخش و انتقال بهینه میان دو مجموعه نقطه با تجزیه‌ی مقادیر منفرد[۱۹] به روش کابش [۱۱۶] به دست می‌آید. یک نگهبان روی دترمینان ماتریس چرخش تضمین می‌کند که راه‌حل یک چرخش سره باشد و نه یک بازتاب؛ بدون این قید، دو حجم با جهت‌گیری آینه‌ای را می‌توان با نگاشت هر اندام به قرینه‌ی آناتومیک آن «هم‌تراز» کرد.

استفاده از هر دو لایه—و نه فقط استخوان—تصمیمی تجربی است: نسخه‌ی نخست این گذر تنها بر لنگرهای استخوانی تکیه می‌کرد و افزودن اندام‌های نرم پایدار به‌طور یکنواخت نتیجه‌ی بهتری داد، چرا که تعداد نقاط متناظر را افزایش و شرطی‌شدگی[۲۰] مسئله‌ی SVD را بهبود می‌دهد. حاصل، یک نقطه‌ی شروع هندسی درست است که گذر بعدی را از دامنه‌ی جذب کمینه‌های محلی دور نگه می‌دارد.

گذر یک — پالایش با زیان آناتومیک. گذر دوم، تبدیل صلب را با کمینه‌سازی یک زیان *آناتومیک* و نه یک زیان مبتنی‌بر شدت روشنایی پالایش می‌کند:

$$\mathcal{L}(T) \;=\; \lambda\, d_c(T) \;+\; \big(1 - \mathrm{Dice}_\epsilon(T)\big), \qquad \lambda = 10, \tag{۲-۳}$$

که در آن d_c میانگین وزن‌دار جابه‌جایی مرکز جرم و Dice_ϵ ضریب دایس *فرسوده* است. هر دو جمله تنها روی یک زیرمجموعه‌ی گزیده از ۱۱ اندام محاسبه می‌شوند؛ ساختارهایی که موقعیتشان میان دو فاز ناپایدار است—معده و مری به‌دلیل حرکت دودی و پرشدگی، و عروق ایلیاک به‌دلیل تغییر شدید HU با کنتراست—به‌صراحت از این دامنه بیرون گذاشته شده‌اند.

شعاع فرسایش به‌ازای هر اندام و متناسب با اندازه‌ی آن تعیین می‌شود (از 6 میلی‌متر برای کبد تا 1.5 میلی‌متر برای مهره‌ها)، تا ساختارهای کوچکِ دارای مرز نویزی نتوانند بر زیان مسلط شوند.

بهینه‌سازی با روش سیمپلکس نلدر–مید [۱۱۷] انجام می‌گیرد. انتخاب یک بهینه‌ساز بدون مشتق در اینجا یک راه‌حل جایگزین نیست بلکه یک ضرورت است: ضریب دایس روی نقاب‌های دودویی گسسته

[۱۹] Singular value decomposition, SVD
[۲۰] Conditioning

محاسبه می‌شود و نسبت به پارامترهای تبدیل مشتق‌پذیر نیست، بنابراین هیچ بهینه‌ساز گرادیانی روی این زیان تعریف نمی‌شود.

گذر دو — پالایش ساختاری روی بزرگی گرادیان. گذر پایانی، معیار را از شدت روشنایی خام به بزرگی گرادیان[۲۱] تغییر می‌دهد و آن را با همبستگی متقاطع نرمال‌شده‌ی محلی بیشینه می‌کند. منطق این تغییر آن است که تزریق ماده‌ی حاجب *سطح* روشنایی را جابه‌جا می‌کند اما *لبه*‌ها را در جای خود نگه می‌دارد؛ بنابراین معیاری که روی لبه تعریف شود، ذاتاً نسبت به فاز ناوردا[۲۲]تر است. بزرگی گرادیان به 200 واحد HU بر میلی‌متر مقیدسازی[۲۳] می‌شود تا مرزهای استخوان–هوا، که گرادیانی چند برابر بزرگ‌تر تولید می‌کنند، معیار را از مرزهای بافت نرم منحرف نکنند.

دروازه‌های پذیرش. گذرهای یک و دو هر یک با یک *دروازه‌ی پذیرش* همراه‌اند: پس از اجرای گذر، خطای مرکز جرم دوباره اندازه‌گیری می‌شود و اگر نسبت به گذر پیشین بدتر شده باشد، تبدیل گذر پیشین حفظ و نتیجه‌ی گذر جدید دور ریخته می‌شود. این ساز و کار یک جزئیات مهندسی نیست بلکه یک تصمیم روش‌شناختی است: زنجیره‌ای از گذرهای پالایشی، بدون دروازه، هر شکست یک گذر را به همه‌ی گام‌های پایین‌دستی منتقل می‌کند و آن را در انبوه داده پنهان می‌سازد. با دروازه، بدترین حالتِ یک گذرِ ناموفق «بی‌اثر» است و نه «مخرب». چنان‌که در فصل ۴ نشان داده می‌شود، این تمایز در عمل تعیین‌کننده شد.

ثبت غیرصلب

پالایش نهایی با یک تبدیل B–اسپلاین آزادشکل [۵۶] روی شبکه‌ی کنترلی با فاصله‌ی 25 میلی‌متر و بهینه‌ساز L-BFGS-B انجام می‌شود. معیار، همانند گذرهای پیشین، به $\mathcal{M}$ محدود است. نقاب متحرک از نقاب ثابت به فضای تصویر متحرک بازنمونه‌برداری و با حاشیه‌ی اضافی گشاد[۲۴] می‌شود تا خطای صلب باقی‌مانده را جذب کند. تبدیل روی *تصاویر معیار* (نقشه‌ی لبه یا فاصله) برازش می‌شود اما بر تصویر سی‌تی اصلی اعمال می‌گردد.

میزان تاخوردگی[۲۵] میدان تغییرشکل، یعنی درصد وکسل‌هایی که دترمینان ژاکوبین در آن‌ها نامثبت است، در هر مورد *گزارش* می‌شود اما به‌عنوان دروازه به کار نمی‌رود؛ گذاشتن دروازه بر آن، ثبت غیرصلب را بی‌سروصدا به ثبت صلب بازمی‌گرداند و همین کمیت است که بعداً امکان مقایسه‌ی منصفانه‌ی دقت و

[۲۱] Gradient magnitude
[۲۲] Invariant
[۲۳] Clamp
[۲۴] Dilate
[۲۵] Folding

منظم‌بودن[۲۶] میان روش‌ها را فراهم می‌کند.

پیاده‌سازی همه‌ی گذرها بر پایه‌ی SimpleITK [۵۴] است. شکل ۳-۱ کل زنجیره را همراه با نقابی که در هر گام دامنه‌ی معیار را تعیین می‌کند خلاصه می‌کند.

مجموعه‌ی معیارهای قابل‌انتخاب

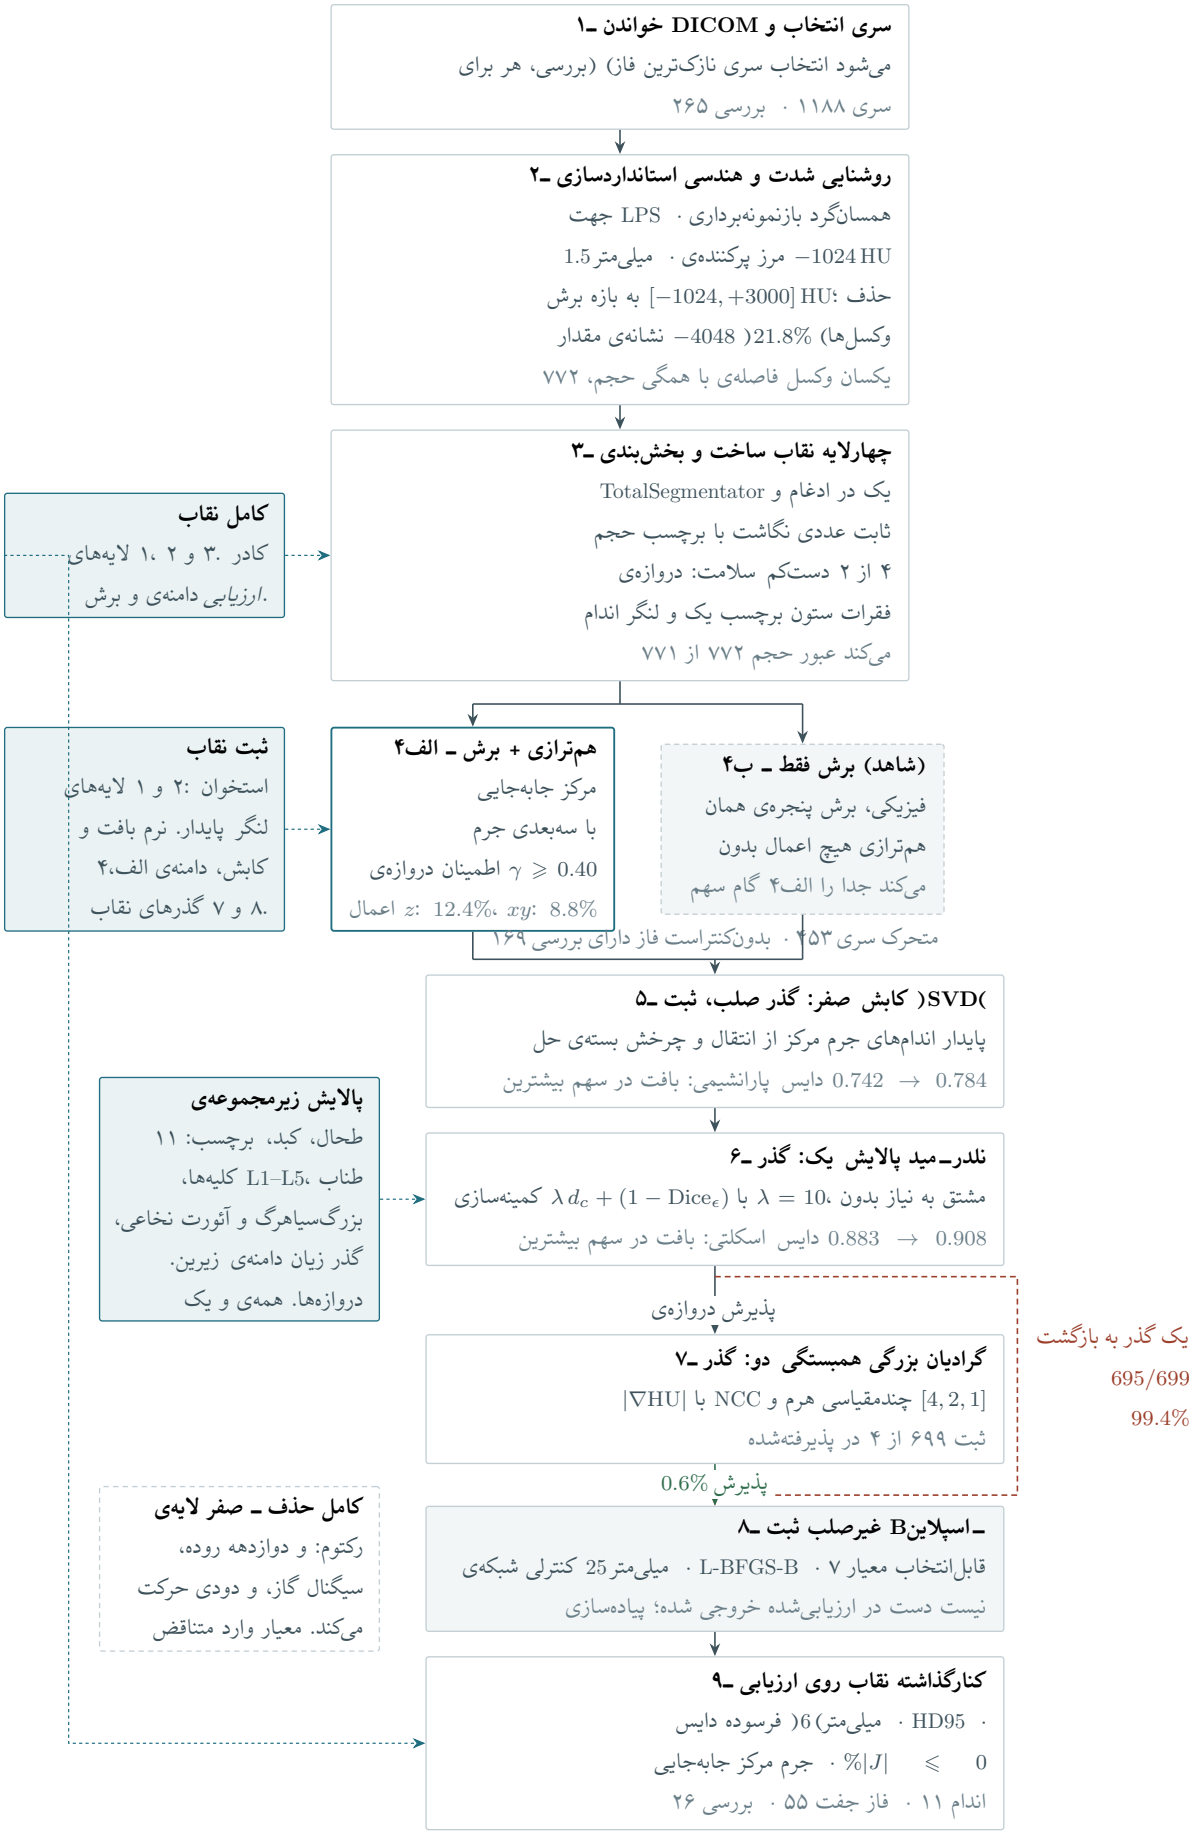
برای آن‌که بتوان سهم *محدودسازی دامنه* را از سهم *انتخاب معیار* جدا کرد، گذر غیرصلب با هفت معیار متفاوت قابل اجراست: اطلاعات متقابل ماتس روی HU خام، همبستگی متقاطع نرمال‌شده روی بزرگی گرادیان مرکزی، همان معیار روی گرادیان هموارشده‌ی سوبل، نقشه‌ی لبه‌ی دودویی‌شده با آستانه‌ی اتسو، فاصله‌ی علامت‌دار نقاب اندام، توصیفگر ساختاری MIND [۴۸]، و ترکیب ضربی MIND با لبه‌ی دودویی. علاوه بر این، هر یک از این معیارها را می‌توان با دامنه‌ی محدودشده به $\mathcal{M}$ یا روی کل تصویر اجرا کرد. حاصل، یک طرح عاملی[۲۷] دوبعدی (معیار × دامنه) است که آزمون مستقیم ادعای مرکزی این بخش را ممکن می‌سازد؛ نتایج آن در فصل ۴ می‌آید.

معیارهای ارزیابی ثبت تصویر

کیفیت هم‌ترازی با چهار کمیت سنجیده می‌شود که همگی روی نقاب *ارزیابی* و نه نقاب ثبت محاسبه می‌شوند——در غیر این صورت معیار ارزیابی همان چیزی می‌بود که بهینه شده است:

- **ضریب دایس فرسوده**[۲۸]: ضریب دایس پس از فرسایش هر دو نقاب به‌اندازه‌ی 6 میلی‌متر در فضای فیزیکی. فرسایش، حساسیت معیار به نویز مرزی بخش‌بندی را کاهش می‌دهد و آن را به تراز مرکز اندام حساس‌تر می‌کند.
- **فاصله‌ی هاسدورف صدک ۹۵**: کران بالای فاصله‌ی سطحی، مقاوم نسبت به تعداد اندکی وکسل پرت.
- **جابه‌جایی مرکز جرم**: بر حسب میلی‌متر، روی نقاب‌های فرسوده‌نشده.
- **همبستگی گرادیان درون اندام**: میزان انطباق ساختار لبه‌ای، مستقل از سطح روشنایی.
- **همبستگی توصیفگر MIND**: انطباق ساختار خودمشابه، معیاری مستقل از هر دو مورد بالا.

[۲۶] Regularity
[۲۷] Factorial design
[۲۸] Eroded Dice



شکل ۳–۱: پایپ‌لاین پیش‌پردازش و ثبت تصویر بین‌فازی. پیکان‌های پیوسته مسیر داده‌اند و پیکان‌های نقطه‌چین آبی نشان می‌دهند دامنه‌ی محاسبه‌ی معیار در هر گام کدام نقاب است. شاخه‌ی ۴ب شاهدی کنترل‌شده است که همان پنجره‌ی برش را بدون هم‌ترازی می‌سازد. مسیری که ۹۹/۴ درصد ثبت‌ها در عمل طی می‌کنند پیکان قرمز

- **درصد تاخوردگی**: تنها برای روش‌های غیرصلب؛ سهم وکسل‌هایی با دترمینان ژاکوبین نامثبت. این کمیت *دقت* را نمی‌سنجد بلکه *اعتبار فیزیکی* تغییرشکل را می‌سنجد و بدون آن، مقایسه‌ی یک روش غیرصلب با یک روش صلب بی‌معناست.

همبستگی متقاطع روی HU خام عمداً از این فهرست کنار گذاشته شده است: این معیار وجود رابطه‌ی خطی میان شدت روشنایی متناظر دو تصویر را فرض می‌کند و تزریق ماده‌ی حاجب دقیقاً همین فرض را نقض می‌کند، بنابراین مقدار آن میان دو فاز نویز است و نه سیگنال.

اندام‌ها برای گزارش به سه گروه پارانشیمی، عروقی و اسکلتی دسته‌بندی می‌شوند. گروه اسکلتی نقش *شاهد منفی* دارد: چون استخوان با کنتراست تغییر نمی‌کند، خطای باقی‌مانده در آن نشانه‌ی شکست ثبت تصویر است و نه دشواری آناتومیک.

۳-۶ سنتز فاز کنتراست‌دار از فاز بدون‌کنتراست

صورت‌بندی مسئله

جفت‌های هم‌ترازشده‌ی حاصل از بخش ۳-۵ یک مسئله‌ی ترجمه‌ی تصویر ــ به ــ تصویر نظارت‌شده تعریف می‌کنند: با داشتن حجم بدون‌کنتراست x، حجم کنتراست‌دار y همان بیمار در همان هندسه بازسازی شود. صورت‌بندی متعارف، کمینه‌سازی یک زیان بازسازی $\mathcal{L}(G(x), y)$ است.

این پایان‌نامه سه خانواده‌ی مدل را روی همین صورت‌بندی و همین تقسیم داده مقایسه می‌کند: مدل قطعی مبتنی‌بر شبکه‌ی مولد ــ متخاصم، مدل انتشار[۲۹]، و رگرسیون ناهم‌واریانس[۳۰]. منطق این انتخاب سه‌گانه در بخش ۳-۶ روشن می‌شود.

مولد قطعی

معماری پایه یک شبکه‌ی U-Net [۱۱۸] دوبعدی است که روی وصله‌های[۳۱] ۱۲۸ × ۱۲۸ از برش‌های محوری آموزش می‌بیند. آموزش وصله‌ای ــــ به‌جای برش کامل ــــ حافظه را آزاد و تعداد نمونه‌های مؤثر را زیاد می‌کند.

[۲۹] Diffusion model
[۳۰] Heteroscedastic regression
[۳۱] Patch

نرمال‌سازی. لایه‌های نرمال‌سازی گروهی [۱۱۹] به‌جای نرمال‌سازی نمونه‌ای [۱۲۰] به کار می‌روند. دلیل این انتخاب در فصل ۴ به‌صورت کمّی ارائه می‌شود و به مسئله‌ی درز[۳۲] میان وصله‌ها در استنتاج کاشی‌کاری‌شده مربوط است.

متمایزکننده. یک متمایزکننده‌ی وصله‌ای[۳۳] [۱۲۱] به‌صورت *شرطی* به کار می‌رود: ورودی آن الحاق تصویر مبدأ و تصویر مقصد است، نه تصویر مقصد به‌تنهایی. متمایزکننده‌ی غیرشرطی نمی‌تواند تشخیص دهد که تصویر تولیدشده به *این* ورودی مربوط است یا نه، و صرفاً واقع‌نمایی کلی را پاداش می‌دهد.

تابع زیان. زیان کل ترکیبی است از زیان L_1 سراسری، یک زیان L_1 وزن‌دار در سطح اندام، و جمله‌ی متخاصم. وزن‌های سطح‌اندام لایه‌بندی‌شده‌اند و بر اساس اهمیت هر اندام در تعیین فاز کنتراست تعیین می‌شوند. روده وزن *صفر* می‌گیرد: محتوای گاز و مدفوع آن میان دو اسکن تغییر می‌کند و از روی فاز بدون‌کنتراست قابل استنتاج نیست، پس آموزش مدل برای بازسازی آن، ظرفیت را صرف نویز می‌کند. روده همچنان *ارزیابی* می‌شود، صرفاً *آموزش* داده نمی‌شود—تمایزی که در فصل ۴ به‌صراحت دفاع می‌شود.

بهینه‌سازی. نرخ یادگیری از زمان‌بندی کسینوسی با راه‌اندازی مجدد گرم [۱۲۲] پیروی می‌کند. وزن جمله‌ی L_1 در طول آموزش کاهش می‌یابد تا در مراحل اولیه ساختار کلی و در مراحل بعدی جزئیات بافتی شکل بگیرد.

زمینه‌ی محور z: مدل ۵/۲ بعدی

مدل پایه هر برش را مستقل پردازش می‌کند و از این رو به پیوستگی میان‌برشی بی‌اعتناست. برای افزودن زمینه‌ی محور z بدون هزینه‌ی یک شبکه‌ی سه‌بعدی کامل، یک پیکربندی ۵/۲ بعدی به کار می‌رود: $2k+1$ برش مجاور به‌عنوان کانال‌های ورودی داده می‌شوند و تنها برش میانی پیش‌بینی می‌شود. شبکه دوبعدی باقی می‌ماند و تعداد پارامترها تقریباً تغییر نمی‌کند. پنجره‌ی z در مرزهای حجم بریده[۳۴] می‌شود تا رفتار آموزش و استنتاج در ابتدا و انتهای حجم یکسان بماند و هیچ برشی از دست نرود.

[۳۲] Seam
[۳۳] PatchGAN
[۳۴] Edge-clamped

شرطی‌سازی

دو نوع شرطی‌سازی با سازوکار مدولاسیون ویژگی خطی[۳۵] [۱۲۳] پیاده شده است:

- **شرطی‌سازی فاز**: یک بردار که فاز هدف (شریانی یا وریدی) را مشخص می‌کند و به یک مدل واحد اجازه می‌دهد هر دو فاز را تولید کند.
- **شرطی‌سازی سطح**: یک یا چند مقدار عددی که سطح روشنایی هدف در اندام‌های شاخص را مشخص می‌کند.

شرطی‌سازی سطح نقش ویژه‌ای دارد و باید به‌دقت تفسیر شود. این مقادیر از تصویر کنتراست‌دار *واقعی* خوانده می‌شوند و بنابراین در زمان استقرار بالینی در دسترس نیستند. هدف از این پیکربندی، ارائه‌ی یک روش کاربردی نیست؛ هدف، اندازه‌گیری یک *سقف* است: اگر مدل هنگام دریافت سطح واقعی بتواند آن را بازتولید کند، آن‌گاه ناتوانی‌اش در حالت عادی ناشی از کمبود *اطلاعات ورودی* است و نه کمبود ظرفیت. این تمایز، محور استدلال فصل ۴ است.

استنتاج در سطح حجم

استنتاج به‌صورت کاشی‌کاری با هم‌پوشانی و آمیختن[۳۶] وزنی انجام می‌شود تا مرز وصله‌ها در خروجی دیده نشود. خروجی به HU بازگردانده و روی شبکه‌ی اصلی هر مورد آزمون به‌صورت NIfTI نوشته می‌شود. این قرارداد خروجی برای همه‌ی مدل‌ها—از جمله مدل‌های بازپیاده‌سازی‌شده از ادبیات—یکسان است، و همین یکسانی است که امکان امتیازدهی همه‌ی آن‌ها با یک ابزار واحد را فراهم می‌کند.

مدل‌سازی عدم‌قطعیت: انتشار و رگرسیون ناهم‌واریانس

یک رگرسیون‌گر آموزش‌دیده با زیان L_1، در بهترین حالت *میانه‌ی شرطی* $\mathbb{E}[y \mid x]$ را پیش‌بینی می‌کند. اگر رابطه‌ی $x \mapsto y$ قطعی نباشد—یعنی اگر y به متغیرهایی وابسته باشد که در x مشاهده‌پذیر نیستند—آن‌گاه خطای باقی‌مانده تقلیل‌ناپذیر است و هیچ تغییری در معماری یا تابع زیان آن را کاهش نمی‌دهد.

در مسئله‌ی حاضر، نامزد چنین متغیرهای مشاهده‌نشده‌ای روشن است: دوز تزریق، زمان‌بندی بولوس و برون‌ده قلبی، که هیچ‌یک در اسکن بدون‌کنتراست قابل‌مشاهده نیستند. به بیان صوری،

$$y = f(x, Z), \qquad Z = \text{(مشاهده‌نشده (دوز، زمان‌بندی، فیزیولوژی}.$$

[۳۵] Feature-wise Linear Modulation, FiLM

[۳۶] Blending

اگر این صورت‌بندی درست باشد، مدل قطعی نه تنها خطا دارد، بلکه *باید* داشته باشد؛ و آن‌چه باید سنجیده شود نه کاهش خطا، بلکه *کالیبراسیون* توزیع پیش‌بینی‌شده است.

دو خانواده‌ی مدل برای آزمودن این ایده به کار می‌روند:

رگرسیون ناهم‌واریانس. سر خروجی مولد به دو کانال گسترش می‌یابد که میانگین μ و لگاریتم واریانس $\log \sigma^2$ را در هر وکسل پیش‌بینی می‌کنند، و آموزش با درست‌نمایی منفی گاوسی انجام می‌شود [۱۲۴]. این مدل با هزینه‌ی محاسباتی ناچیز، یک تخمین عدم‌قطعیت کالیبره‌شدنی می‌دهد و بنابراین *مبنایی* است که مدل انتشار باید از آن بهتر عمل کند تا هزینه‌اش توجیه شود.

مدل انتشار. مدل انتشار [۱۲۵] به‌جای $\mathbb{E}[y \mid x]$، خودِ توزیع $p(y \mid x)$ را مدل می‌کند و از این نظر ابزار نظری درست برای یک باقی‌مانده‌ی تصادفی است. پیاده‌سازی این پایان‌نامه از پارامترسازی v [۱۲۶]، نمونه‌بردار DDIM [۱۲۷]، هدایت بدون‌طبقه‌بند [۱۲۸]، وزن‌دهی زیان بر پایه‌ی نسبت سیگنال به نویز کمینه [۱۲۹] و میانگین متحرک نمایی وزن‌ها بهره می‌گیرد.

نکته‌ی حیاتی—که پیش از اجرای آزمایش‌ها ثبت شده است—آن است که یک نمونه‌ی صادق از توزیع شرطی، بر حسب یک معیار نقطه‌ای، *بدتر* از میانگین شرطی امتیاز می‌گیرد. برای یک توزیع گاوسی با انحراف معیار s، پیش‌بین میانگین خطای مطلق s ۰/۷۹۸ و یک نمونه‌ی منفرد خطای s ۱/۱۲۸ دارد؛ یعنی نسبتی حدود $\sqrt{۲}$. این افت، نقص مدل انتشار نیست بلکه بهای صادقانه‌ی مدل‌کردن عدم‌قطعیت است، آن‌گاه که با معیاری نقطه‌ای سنجیده شود. ثبت این انتظار *پیش از* آزمایش، شرط لازم برای آن است که نتیجه قابل ابطال باشد.

مدل‌های مبنا از ادبیات

برای آن‌که ادعاهای این پایان‌نامه در برابر وضعیت موجود سنجیده شوند، مجموعه‌ای از مدل‌های منتشرشده روی *همان* تقسیم داده، *همان* موارد آزمون و با *همان* ابزار امتیازدهی بازآموزی و ارزیابی می‌شوند:

- pix2pix و pix2pixHD [۱۲۱، ۱۳۰] — مبنای ترجمه‌ی جفت‌شده.
- CycleGAN [۱۳۱] — شاهد *جفت‌نشده*. داده‌ی ما جفت‌شده است، اما این مدل عمداً در حالت جفت‌نشده آموزش می‌بیند تا هزینه‌ی چشم‌پوشی از جفت‌شدگی اندازه‌گیری شود.
- ResViT [۱۳۲] و CyTran [۷۸] — مبناهای مبتنی‌بر ترانسفورمر.

- SwinUNETR [۱۳۳] و TransUNet [۱۳۴] —— این دو *معماری*‌اند و نه پایپ‌لاین سنتز؛ هر دو در اصل برای بخش‌بندی عرضه شده‌اند. شبکه‌ی آن‌ها بدون تغییر نگه داشته و حلقه‌ی آموزش با هدف یکسان با ResViT فراهم می‌شود تا مقایسه، *معماری* را جدا کند و نه بهینه‌سازی را.
- Ea-GAN [۱۳۵] —— شبکه‌ی مولد ـ متخاصم آگاه از لبه.
- SynDiff [۱۳۶] —— مدل انتشار خصمانه. این مدل به‌دلیل هزینه‌ی محاسباتی از اجرای نهایی کنار گذاشته شد؛ دلیل و شواهد زمان‌سنجی در فصل ۴ گزارش می‌شود.

باید تصریح شود که بازآموزی این مدل‌ها روی داده و مقیاس این پایان‌نامه، اعداد مقاله‌های اصلی آن‌ها را بازتولید *نمی‌کند*؛ آن‌چه گزارش می‌شود یک مقایسه‌ی کنترل‌شده بر داده‌ی یکسان است، نه یک بازتولید.

۳-۷ پروتکل ارزیابی

چرا معیارهای متعارف کافی نیستند

معیارهای رایج در ادبیات سنتز تصویر پزشکی—PSNR، SSIM و خطای مطلق میانگین—در این مسئله گمراه‌کننده‌اند، و این نکته یکی از یافته‌های روش‌شناختی این پایان‌نامه است.

دلیل نخست ساختاری است: پنجره‌ی HU انتخاب‌شده، هوا، ریه و چربی را به صفر و استخوان را به یک اشباع می‌کند، و این نواحی بخش بزرگی از حجم را تشکیل می‌دهند. هر معیاری که روی کل تصویر میانگین بگیرد، عمدتاً روی جرمی میانگین می‌گیرد که همه‌ی مدل‌ها در آن بی‌خطا هستند؛ حتی یک کپی همانی از تصویر بدون‌کنتراست بخش عمده‌ی امتیاز بهترین مدل را کسب می‌کند.

دلیل دوم عمیق‌تر است: این معیارها با میانگین شرطی کمینه می‌شوند. بنابراین یک خروجی *تار* را بالاتر از یک نمونه‌ی دارای بافت صحیح امتیاز می‌دهند. مرتب‌سازی مدل‌ها بر اساس این معیارها، آن‌ها را بر اساس میزان بافتی که تلاش می‌کنند تولید کنند مرتب می‌کند—در جهت اشتباه.

بنابراین این معیارها گزارش می‌شوند اما *ثانویه* تلقی می‌شوند، و ادعاها بر معیارهای زیر بنا می‌شود.

معیار اصلی: وفاداری HU در سطح اندام

معیار سرصفحه‌ی این پایان‌نامه، میانگین قدرمطلق خطای میانه‌ی HU در سطح اندام است که روی مجموعه‌ای از اندام‌های شکمی محاسبه می‌شود. نکته‌ی مهم آن است که این معیار با همان استخراج

ویژگی سطح‌اندامِ مدل تشخیص فاز (بخش ۳-۴) محاسبه می‌شود. به این ترتیب مؤلفه‌ی نخست روش، ابزار سنجش مؤلفه‌ی سوم می‌شود، و معیار به کمیتی متصل می‌ماند که معنای بالینی دارد: میزان روشنایی هر اندام، همان چیزی که فاز کنتراست را تعریف می‌کند.

در کنار آن، خطای مطلق و PSNR و SSIM *محدودشده به ناحیه‌ی اندام* گزارش می‌شود که مشکل نخستِ بالا را برطرف می‌کند.

معیار بازیابی سطح: تشخیص مولد از میانگین‌گیر

دو کمیت برای تشخیص یک مولد واقعی از یک میانگین‌گیر تعریف می‌شود. میانه‌ی HU هر اندام در تصویر تولیدشده، بر همان کمیت در تصویر واقعی، در سراسر موارد آزمون رگرس می‌شود:

- β، شیب این رگرسیون. مقدار $\beta = ۱$ یعنی مدل سطح واقعی هر مورد را دنبال می‌کند؛ مقدار $\beta = ۰$ یعنی مدل صرف‌نظر از ورودی، میانگین جمعیت را تولید می‌کند.
- نسبت واریانس $\mathrm{var}(\text{واقعی})/\mathrm{var}(\text{تولیدشده})$، با هدف ۱. مقدار نزدیک صفر یعنی خروجی کم‌پراکنده[۳۷] است.

این دو کمیت دقیقاً همان چیزی را می‌سنجند که معیارهای نقطه‌ای پنهان می‌کنند: یک مدل می‌تواند خطای HU قابل‌قبولی داشته باشد و در عین حال نسبت واریانسش نزدیک صفر باشد، یعنی هرگز سطح کنتراست هیچ بیماری را واقعاً پیش‌بینی نکرده باشد.

معیارهای بافت و پیوستگی

چهار کمیت نسبتی برای سنجش بافت و پیوستگی به کار می‌رود: نسبت انرژی طیفی بسامد بالا، فاصله‌ی واسرشتاین میان توزیع بزرگی گرادیان تولیدشده و واقعی، انرژی درز در مرز کاشی‌ها، و سوسوزنی[۳۸] میان‌برشی.

نکته‌ی تفسیری مهم آن است که این‌ها نسبت‌اند و هدفشان مقدار ۱ است، نه بیشینه. مقدار کمتر از یک به معنای تاری و مقدار بیشتر از یک به معنای نویز یا بافت توهمی[۳۹] است؛ هر دو شکست‌اند و باید بر حسب فاصله از یک رتبه‌بندی شوند.

---

[۳۷] Under-dispersed
[۳۸] Flicker
[۳۹] Hallucinated

معیارهای ادراکی LPIPS [۱۳۷] و FID [۱۳۸] نیز صرفاً برای *قابلیت مقایسه با ادبیات* گزارش می‌شوند و مبنای هیچ ادعایی نیستند: هر دو شبکه‌های از پیش آموزش‌دیده روی تصاویر طبیعی را بر تصویر سی‌تی خاکستری اجرا می‌کنند و اعتبار ترتیبشان در این دامنه تأیید نشده است.

معیارهای کالیبراسیون

برای مدل‌های احتمالاتی بخش ۳-۶، دو کمیت افزوده می‌شود: امتیاز احتمال رتبه‌ای پیوسته[۴۰] [۱۳۹] و پوشش بازه‌ی پیش‌بینی ۹۰ درصد، که مقدار هدفش ۰٫۹۰ است. انحراف از این مقدار، مستقیماً بدکالیبراسیون را اندازه می‌گیرد.

ارزیابی پایین‌دستی: شکاف بخش‌بندی

هیچ‌یک از معیارهای بالا، پرسش اصلی این پایان‌نامه را پاسخ نمی‌دهد. آن پرسش یک ارزیابی جداگانه می‌طلبد که به‌صورت زیر تعریف می‌شود.

مرجع، خروجی بخش‌بندی خودکار روی تصویر کنتراست‌دار *واقعی* است. سه بازو در برابر این مرجع سنجیده می‌شوند:

- بخش‌بندی روی تصویر بدون‌کنتراست واقعی — این خودِ *شکاف* است.
- بخش‌بندی روی تصویر کنتراست‌دار *تولیدشده* توسط هر مدل.
- بخش‌بندی روی تصویر تولیدشده توسط مدلِ شرطی‌شده با سطح واقعی — که *سقف* قابل‌دستیابی را می‌دهد.

معیارها همان ضریب دایس فرسوده و فاصله‌ی هاسدورف صدک ۹۵ بخش ۳-۵ هستند، تا فصل ثبت تصویر و فصل سنتز یک تعریف واحد از دایس داشته باشند. اندام‌ها به همان چهار گروه دسته‌بندی می‌شوند و گروه *اسکلتی* بار دیگر نقش شاهد منفی را دارد: استخوان با کنتراست تغییر نمی‌کند، پس اگر بازوی بدون‌کنتراست روی استخوان نیز افت دایس نشان دهد، آن‌چه اندازه گرفته شده تفاوت کیفیت کلی تصویر است و نه اثر کنتراست، و بقیه‌ی جدول را نمی‌توان به کنتراست نسبت داد.

محدودیت این طرح باید صریح بماند: مرجع، حاشیه‌نویسی انسانی نیست بلکه خروجی خودکار روی تصویر واقعی است. بنابراین یک تصویر تولیدشده می‌تواند با شبیه‌شدن به یک تصویر کنتراست‌دار *از دید*

[۴۰] Continuous ranked probability score, CRPS

همان *ابزار بخش‌بندی* امتیاز بگیرد. این محدودیت هرجا که این اعداد ظاهر شوند تکرار خواهد شد؛ شاهد منفی اسکلتی و کف بازوی بدون‌کنتراست، آن چیزی است که سیگنال باقی‌مانده را قابل‌تفسیر نگه می‌دارد.

انضباط آماری

سه قاعده در سراسر فصل ۴ اعمال می‌شود و ذکرشان در این‌جا ضروری است، چون بدون آن‌ها بخشی از نتایج گزارش‌شده متفاوت می‌بود.

- **کف نویز بذر.** هر پیکربندی کلیدی با سه بذر تصادفی اجرا و انحراف معیار میان بذرها محاسبه می‌شود. تفاوتی که از دروازه‌ی 2σ کوچک‌تر باشد نتیجه به شمار نمی‌آید. این قاعده در جریان همین پژوهش یک ادعای سرصفحه را باطل کرد—ادعایی که در یک بذر معنادار به نظر می‌رسید و در سه بذر نه‌تنها ناپدید شد بلکه علامتش برگشت.
- **آزمون‌های زوجی در سطح مورد.** پراکندگی میان بیماران بر تفاوت میان مدل‌ها غلبه دارد. بنابراین مقایسه‌ها از طریق آزمون زوجی روی موارد مشترک انجام می‌شود و نه از طریق مقایسه‌ی میانگین‌ها و انحراف معیارها.
- **تفاضل پیکربندی.** هر اجرا باید با اجرای پیشین خود تنها در کلیدهایی تفاوت داشته باشد که عمداً تغییر داده شده‌اند. این ساده‌ترین محافظ در برابر مخدوش‌کننده‌هاست.

۳-۸ جمع‌بندی

این فصل سه مؤلفه‌ی روش پیشنهادی را ارائه کرد. مدل تشخیص فاز، مسئله را از حجم خام به بردار کوچکی از میانه‌های HU در سطح اندام تقلیل می‌دهد و در ادامه، علاوه بر نقش دروازه‌بانی داده، ابزار اندازه‌گیری ارزیابی سنتز نیز می‌شود. پایپ‌لاین ثبت تصویر چندگذره، به‌جای وزن‌دهی به نواحی پایدار، *دامنه‌ی* محاسبه‌ی معیار تراز را به آن‌ها محدود می‌کند و با مقداردهی اولیه‌ی بسته بر پایه‌ی نشانه‌های استخوانی از کمینه‌های محلی پرهیز می‌کند. مدل‌های سنتز، از مولد قطعی تا مدل انتشار و رگرسیون ناهم‌واریانس، همگی روی جفت‌های حاصل از این ثبت تصویر و روی یک تقسیم منجمد آموزش می‌بینند.

پروتکل ارزیابی، خود بخشی از سهم این پایان‌نامه است: نشان داده شد که چرا معیارهای متعارف سطح‌پیکسل در این مسئله قادر به رتبه‌بندی مدل‌ها نیستند، و مجموعه‌ای از معیارهای سطح‌اندام، بازیابی

سطح، بافت و کالیبراسیون به‌جای آن‌ها تعریف شد. سرانجام، ارزیابی پایین‌دستی بخش‌بندی تعریف شد که تنها سنجه‌ای است که به پرسش عنوان این پایان‌نامه پاسخ می‌دهد.

فصل بعد نتایج تجربی هر یک از این مؤلفه‌ها را گزارش می‌کند.

فصل ۴

آزمایش‌ها

۴-۱ یافته‌های مرور نظام‌مند مجموعه‌داده‌ها

این بخش، یافته‌های کمّی حاصل از اجرای پروتکل بخش ۳-۲ را گزارش می‌کند. نتایج در سه سطح ارائه می‌شوند: ترکیب و افزونگی مجموعه‌داده‌ها، توزیع جغرافیایی، و ارزیابی ریسک سوگیری. بخش پایانی، پیامد مستقیم این یافته‌ها را برای سه مؤلفه‌ی روش این پایان‌نامه استخراج می‌کند.

ترکیب و افزونگی

از میان ۴۵ مجموعه‌داده‌ی واردشده، مجموعاً ۴۷,۰۴۹ بررسی سی‌تی فهرست شده است. اما تنها ۲۳,۷۴۶ مورد از این‌ها *اصیل* بودند؛ یعنی حدود ۵۱ درصد از حجم ظاهری این اکوسیستم، بازاستفاده‌ی موارد پیشین است.

ردیابی منشأ نشان داد این بازاستفاده تصادفی نیست بلکه ساختاری شبکه‌ای دارد: شمار اندکی از مجموعه‌داده‌های پایه—به‌ویژه LiTS [۱۷]، KiTS [۱۸]، Pancreas-CT و BTCV—نقش گره‌های مرکزی را ایفا می‌کنند و موارد آن‌ها به مجموعه‌های ترکیبی متأخرتری مانند AbdomenCT-1K [۱۱]، FLARE [۱۲] و AbdomenAtlas 1.1 [۱۳] سرریز می‌شود.

پیامد روش‌شناختی این ساختار برای هر پژوهشی که از این منابع استفاده می‌کند، خطر نشت داده است: پژوهشگری که مدلی را روی یک مجموعه‌ی ترکیبی آموزش می‌دهد و روی یکی از مجموعه‌داده‌های پایه ارزیابی می‌کند، ممکن است بدون آگاهی، همان بیماران را در هر دو سو داشته باشد. همین ملاحظه است که تصمیم فصل ۳ را برای تقسیم داده در سطح *بیمار* و تثبیت آن در یک فایل منجمد توجیه می‌کند.

توزیع جغرافیایی

با وجود مشارکت ۱۸ کشور، توزیع جغرافیایی به‌شدت نامتوازن است: حدود ۷۵ درصد مجموعه‌داده‌ها از ایالات متحده، کانادا و کشورهای اروپایی می‌آیند. ایالات متحده به‌تنهایی ۲۱ درصد و پس از آن چین و فرانسه هر یک ۹ درصد سهم دارند.

مهم‌تر از این تمرکز، آن چیزی است که کاملاً *غایب* است: آفریقای زیرصحرا، جنوب آسیا و بخش عمده‌ی خاورمیانه هیچ نمایندگی‌ای در چشم‌انداز داده‌ی عمومی موجود ندارند. این غیاب، پیامد بالینی مشخصی دارد. کارسینوم سلول کبدی [۱۴۰]، که تشخیصش به‌شدت به الگوی افزایش کنتراست در فاز شریانی و شست‌وشوی آن در فاز وریدی وابسته است، در آفریقای زیرصحرا اغلب در کبد غیرسیروتیک و در سنین پایین‌تر با الگوی تصویری متفاوتی بروز می‌کند [۱۴۱]. مدلی که تنها الگوی غربی این بیماری را دیده باشد، هیچ تضمینی برای عملکرد در آن بافت بالینی ندارد.

ارزیابی ریسک سوگیری

ارزیابی روی ۲۲ مجموعه‌داده‌ی دارای صد نمونه یا بیشتر انجام شد. جدول ۴-۱ شمار مجموعه‌داده‌های پرریسک را به‌تفکیک هفت مقوله گزارش می‌کند.

جدول ۴-۱: شمار مجموعه‌داده‌های دارای ریسک بالا در هر مقوله، از مجموع ۲۲ مجموعه‌داده‌ی ارزیابی‌شده.

مقوله	ریسک بالا	تفسیر
سوگیری نژادی	۱۶ از ۲۲	پرتکرارترین مقوله؛ اغلب مجموعه‌داده‌ها تک‌مرکزی‌اند یا ترکیب نژادی را اصلاً گزارش نمی‌کنند
سوگیری انتخاب	۱۵ از ۲۲	پوشش ناکافی تشخیص‌های افتراقی؛ اغلب تنها موارد سالم به‌عنوان گروه شاهد
سوگیری طیف	۱۲ از ۲۲	تمرکز بر یک آسیب‌شناسی و شدت خاص
سوگیری فنی	۱۱ از ۲۲	اسکنر واحد یا پروتکل تصویربرداری یکنواخت
سوگیری برچسب‌گذاری	۵ از ۲۲	کم‌تکرارترین مقوله؛ کیفیت حاشیه‌نویسی نگرانی نسبتاً کمتری است
سوگیری جمعیت‌شناختی	۰ از ۲۲	هیچ مجموعه‌داده‌ای در سطح ریسک بالا قرار نگرفت
سوگیری زمانی	۰ از ۲۲	هیچ مجموعه‌داده‌ای در سطح ریسک بالا قرار نگرفت

الگوی این جدول گویاست. دو مقوله‌ی نخست—نژادی و انتخاب—بیش از دو سوم مجموعه‌داده‌ها

را در سطح ریسک بالا قرار می‌دهند، در حالی که سوگیری برچسب‌گذاری تنها در پنج مورد پرریسک است. به بیان دیگر، ضعف اصلی این اکوسیستم در *کیفیت حاشیه‌نویسی* نیست—که موضوع تمرکز بیشتر پژوهش‌های کیفیت داده است—بلکه در ترکیب آن است: چه کسانی و چه بیماری‌هایی در داده حاضرند.

در سطح طبقه‌بندی کلی، ۴۷ درصد مجموعه‌داده‌ها سه شاخص ریسک بالا یا بیشتر داشتند، در حالی که تنها ۱۰ درصد سه شاخص ریسک پایین یا بیشتر داشتند.

[نیازمند بازبینی] چکیده‌ی مقاله‌ی منتشرشده این ارقام را ۱۷ و ۱۶ گزارش می‌کند، در حالی که جدول اصلی مقاله و شرح شکل ۵ آن، ۱۶ و ۱۵ را نشان می‌دهند. ارقام جدول بالا با شمارش مستقیم از جدول اصلی مقاله به دست آمده‌اند. این ناسازگاری باید در مقاله اصلاح و سپس عدد نهایی اینجا تثبیت شود.

وضعیت فاز کنتراست

[نیازمند تکمیل] محور «وضعیت فاز کنتراست» جزو شش محور استخراج این مرور بود، اما مقاله‌ی منتشرشده هیچ رقم تجمیعی برای آن گزارش نمی‌کند. رقمی که در نسخه‌ی پیشین این پایان‌نامه آمده بود—۱۱ مجموعه‌داده از ۴۵ (حدود ۲۴ درصد) دارای هر دو فاز—در متن مقاله یافت نشد و باید مستقیماً از شیت استخراج محاسبه و اینجا درج شود. این رقم برای استدلال بخش‌های ۳-۵ و ۳-۶ نقش محوری دارد و بدون آن، ادعای «کمیابی داده‌ی جفت‌شده» پشتوانه‌ی عددی ندارد.

پیامد برای این پایان‌نامه

سه یافته‌ی بالا، سه قید عملی بر کار این پایان‌نامه می‌گذارند.

نخست، بازاستفاده‌ی ۵۱ درصدی، ارزیابی روی مجموعه‌های ترکیبی را بی‌اعتبار می‌کند مگر آن‌که منشأ هر مورد ردیابی شود. به همین دلیل، آزمایش‌های این پایان‌نامه روی یک مجموعه‌داده‌ی *اصیل* و منفرد انجام می‌شوند، نه روی یک محک ترکیبی.

دوم، کمیابی داده‌ی جفت‌شده‌ی چندفازی، ثبت تصویر و سنتز را از دو گزینه‌ی رقیب به دو ضرورت مکمل تبدیل می‌کند: جفت‌های آموزشی باید *ساخته* شوند، و ساختنشان به هم‌ترازسازی هندسی نیاز دارد.

سوم، سوگیری جغرافیایی و جمعیت‌شناختی مستندشده، دامنه‌ی اعتبار هر نتیجه‌ای را که در ادامه‌ی این فصل به دست می‌آید محدود می‌کند. این محدودیت در تفسیر نتایج باید صریح بماند و در فصل ۵ به آن بازمی‌گردیم.

۲-۴ نتایج ثبت تصویر بین‌فازی

این بخش نتایج پایپ‌لاین بخش ۳-۵ را گزارش می‌کند. همه‌ی ارقام روی *مجموعه‌ی متناظر* محاسبه شده‌اند: ۲۶ بررسی که خروجی همه‌ی شرایط مقایسه برای آن‌ها موجود است، معادل ۵۵ جفت فاز و ۱۱ اندام. گزارش با میانه و چارک‌ها انجام می‌شود و نه با میانگین و انحراف معیار؛ توزیع خطا در این مسئله دُم‌دار است و میانگین در چند شرط بیش از دو برابر میانه است.

معناداری تفاوت‌ها با آزمون علامت[۱] زوجی روی سه‌تایی‌های (بررسی، فاز، اندام) سنجیده شده است. آزمون زوجی در اینجا ضروری است: تفاوت میان دو شرط اغلب از تفاوت میان بیماران کوچک‌تر است و مقایسه‌ی دو توزیع مستقل، این اثر را پنهان می‌کند.

قیف داده

از ۲۶۵ بررسی مجموعه‌داده، تنها ۱۶۹ بررسی (۶۳٫۸ درصد) دارای سری بدون‌کنتراست‌اند. چون فاز بدون‌کنتراست در سراسر این پایپ‌لاین مرجع ثابت است، ۹۶ بررسی باقی‌مانده پیش از هر ثبت تصویری کنار گذاشته می‌شوند. این عدد، و نه کیفیت هم‌ترازی، است که سقف تعداد جفت‌های آموزشی سنتز را تعیین می‌کند.

گام تبدیل DICOM به NIfTI روی هر ۷۷۲ حجم بدون شکست اجرا شد و دروازه‌ی سلامت بخش‌بندی ۷۷۱ حجم را پذیرفت؛ تنها حجم مردود، هر سه شرط دروازه را هم‌زمان نقض می‌کرد—صفر اندام لنگر، نبود برچسب ستون فقرات، و پوشش نقاب صفر—یعنی دقیقاً الگویی که دروازه برای شناسایی آن طراحی شده بود.

بزرگی ناهم‌ترازی اولیه

پیش از تفسیر نتایج، اندازه‌ی مسئله باید روشن شود. میانه‌ی اندازه‌ی جابه‌جایی مرکز جرم میان فاز بدون‌کنتراست و فازهای متحرک ۲٫۷۹ میلی‌متر است (صدک ۹۰: ۱۰٫۵ میلی‌متر؛ بیشینه: ۲۹٫۸ میلی‌متر). نمره‌ی اطمینان در میانه برابر ۱٫۰۰ است و تنها در ۱٫۳ درصد سری‌ها زیر آستانه می‌افتد. در نتیجه جابه‌جایی محور z تنها در ۱۲٫۴ درصد و جابه‌جایی درون‌صفحه‌ای تنها در ۸٫۸ درصد سری‌ها از ناحیه‌ی مرده عبور می‌کند.

به بیان دیگر، فازهای این مجموعه‌داده در حدود ۸۷ درصد موارد از پیش هم‌موقعیت‌اند. این یافته—

[۱] Sign test

که در ادامه به‌طور مستقیم تأیید می‌شود—برخلاف فرض رایج در ادبیات است و تفسیر نتایج ابلیشن را تغییر می‌دهد.

ابلیشن گام‌به‌گام

جدول ۴-۲ نتیجه‌ی افزودن تدریجی گام‌ها را گزارش می‌کند.

جدول ۴-۲: ابلیشن گام‌به‌گام پایپ‌لاین. دایس فرسوده به‌صورت میانه]چارک اول–چارک سوم[؛ فاصله‌ها بر حسب میلی‌متر و به‌صورت میانه. $n = 26$ **بررسی،** 55 **جفت فاز.**

شرط	دایس فرسوده ↑	مرکز جرم ↓	HD95 ↓
A1 ـ فقط برش	0.797 [0.62–0.89]	2.63	3.35
A2 ـ + هم‌ترازی مرکز جرم	0.773 [0.57–0.88]	2.92	3.67
A3 ـ + گذر صفر (کابش)	0.792 [0.62–0.89]	2.29	3.35
A4 ـ + گذر یک (نلدر–مید)	**0.816 [0.63–0.90]**	2.12	3.35
A5 ـ + گذر دو (گرادیان)	0.816 [0.63–0.90]	2.12	3.35
شاخه‌ی شاهد ـ همان زنجیره بدون هم‌ترازی گام ۴			
A3b ـ گذر صفر، بدون هم‌ترازی	0.797 [0.63–0.89]	2.28	3.35
A4b ـ گذر صفر+یک، بدون هم‌ترازی	**0.821 [0.65–0.90]**	2.10	3.35

سه یافته از این جدول بیرون می‌آید.

یکم ـ هم‌ترازی مرکز جرم سهمی در دقت نهایی ندارد. مقایسه‌ی زوجی A4 با A4b تفاوت معناداری نشان نمی‌دهد ($p = 0.14$؛ 182 برد در برابر 212 باخت)، و میانه‌ی شاخه‌ی بدون هم‌ترازی حتی اندکی بالاتر است. بدتر از آن، گام هم‌ترازی به‌تنهایی (A1 در برابر A2) نتیجه را *بدتر* می‌کند ($p = 1.8 \times 10^{-3}$). توضیح این رفتار در بخش پیشین آمد: وقتی میانه‌ی ناهم‌ترازی ۲٫۷۹ میلی‌متر است و تصحیح تنها در ۱۲ درصد موارد فعال می‌شود، هزینه‌ی وفاداریِ یک بازنمونه‌برداری اضافی بیش از سود آن است. سهم واقعی این گام، تضمین همپوشانی فیزیکی پنجره‌ی برش است و نه بهبود دقت؛ ادعای این پایان‌نامه باید در همین حد محدود بماند.

دوم ـ دو گذر صلب نخست، اثرهای مکمل و بر گروه‌های اندام متفاوت دارند. این مهم‌ترین یافته‌ی ساختاری این بخش است. تفکیک آزمون زوجی به گروه‌های اندام نشان می‌دهد که گذر صفر تقریباً تمام اثر خود را روی *بافت پارانشیمی* می‌گذارد (دایس $0.742 \rightarrow 0.784$؛ 217/76؛ $p = 7 \times 10^{-17}$) و بر ساختار اسکلتی اثر معناداری ندارد؛ در مقابل، گذر یک تقریباً تمام اثر خود را روی *ساختار اسکلتی* می‌گذارد (دایس $0.883 \rightarrow 0.908$؛ 90/24؛ $p = 3.6 \times 10^{-10}$) و بر بافت پارانشیمی اثر معناداری ندارد.

تفسیر این الگو مستقیم است: حل بسته‌ی کابش موقعیت درشت اندام‌های نرم بزرگ را تصحیح می‌کند، و پالایش مبتنی‌بر دایس، انطباق دقیق ساختارهای صلب و پرجزئیات را سفت می‌کند. هیچ‌یک جایگزین دیگری نیست.

سوم ــ گذر دو و گام غیرصلب در نتایج فعلی هیچ اثری ندارند. شرایط A4، A5 و A6 در هر شش معیار و در هر 581 ردیف جزئیات بیت‌به‌بیت یکسان‌اند. دلیل در مورد گذر دو روشن و مستند است: دروازه‌ی پذیرش این گذر را در ۶۹۵ از ۶۹۹ ثبت (۹۹/۴ درصد) رد کرده است، چون میانه‌ی خطای مرکز جرم آن ۱۳/۹۹ میلی‌متر در برابر ۲/۰۹ میلی‌متر گذر یک است.

این یک نتیجه‌ی منفی است و باید به همین صورت گزارش شود. ارزش روش‌شناختی آن در جای دیگری است: بدون دروازه، این گذر خطای هر ثبت را به‌طور میانه شش برابر می‌کرد و این خرابی در انبوه داده دیده نمی‌شد. دروازه، یک گذرِ مضر را به یک گذرِ بی‌اثر تبدیل کرد.

[نیازمند اجرای مجدد] یکسانی A6 با A5 توضیح متفاوتی دارد: هیچ‌یک از ردیف‌های A6 مقدار تاخوردگی ندارد، در حالی که این مقدار برای همه‌ی روش‌های غیرصلب دیگر ثبت شده است. یعنی خروجی ارزیابی‌شده‌ی A6 در واقع خروجی صلب است و گام B ــ اسپلاین باید پیش از هرگونه ادعا درباره‌ی آن دوباره اجرا و ارزیابی شود. تا آن زمان، ردیف A6 و ابلیشن هفت معیار غیرصلب از جدول‌ها کنار گذاشته شده‌اند.

ابلیشن تابع هدف: آزمون ادعای محدودسازی دامنه

جدول ۴-۳ ادعای مرکزی بخش ۳-۵ را مستقیماً می‌آزماید. هر چهار ردیف یک مدل تبدیل (اویلر سه‌بعدی)، یک مقداردهی اولیه‌ی یکسان و یک خط‌کش ارزیابی یکسان دارند؛ تنها متغیر، تابع هدف است.

جدول ۴-۳: ابلیشن تابع هدف با مدل تبدیل و مقداردهی اولیه‌ی یکسان. تنها ردیف دوم دامنه‌ی معیار را به نقاب محدود نمی‌کند.

تابع هدف	دایس ↑	مرکز جرم ↓	دایس ۰/۵ > ↓
مرکز جرم + دایس فرسوده	0.793	1.95	13.7%
سوبلNCC- ــ *بدون نقاب*	0.761	2.93	18.2%
MIND-NCC با نقاب	0.798	2.41	14.9%
مرکز جرم + دایس + سوبل (پیشنهادی)	**0.805**	1.99	**13.5%**

تفاوت میان ردیف دوم و ردیف چهارم——۰/۰۴۴ واحد دایس، ۴۷ درصد خطای مرکز جرم بیشتر، و ۳۵ درصد نرخ شکست بیشتر——تنها به *دامنه‌ی محاسبه‌ی معیار* قابل نسبت‌دادن است، چون بقیه‌ی اجزا ثابت نگه داشته شده‌اند. آزمون زوجی این تفاوت را با 398 برد در برابر 142 باخت و $p = 4.4 \times 10^{-29}$

تأیید می‌کند.

اما شاهد قاطع‌تر در *تفکیک این تفاوت به گروه‌های اندام* است:

- بافت پارانشیمی: $0.755 \to 0.821$، $p = 8.8 \times 10^{-34}$
- ساختار عروقی: $0.637 \to 0.686$، $p = 5.3 \times 10^{-6}$
- ساختار اسکلتی: $0.888 \to 0.891$، *بدون معناداری*

این دقیقاً الگویی است که فرضیه‌ی بخش ۳-۵ پیش‌بینی می‌کند. استخوان با تزریق ماده‌ی حاجب تغییر نمی‌کند، پس فرض رابطه‌ی یکنواخت شدت روشنایی در آن نقض نمی‌شود و محدودسازی دامنه چیزی به دست نمی‌آورد. بافت نرم و عروق دقیقاً همان‌جایی هستند که این فرض می‌شکند، و دقیقاً همان‌جا محدودسازی دامنه سود می‌دهد. گروه اسکلتی، که در بخش ۳-۵ به‌عنوان *شاهد منفی* معرفی شد، در نقش شاهد منفی رفتار می‌کند.

مقایسه با روش‌های موجود

جدول ۴-۴: مقایسه با روش‌های موجود روی همان ورودی و همان خط‌کش ارزیابی. ستون تاخوردگی تنها برای روش‌های غیرصلب معنا دارد.

روش	دایس ↑	مرکز جرم ↓	HD95 ↓	تاخوردگی ↓
صلب				
پیشنهادی (A4)	0.816	2.12	3.35	—
پیشنهادی (R)	0.805	1.99	3.35	—
غیرصلب				
ANTs-SyN [۴۷]	0.809	1.58	3.00	0.00%
uniGradICON	0.794	1.35	3.00	0.00%
uniGradICON + IO	0.832	1.15	2.60	0.00%
DEEDS [۴۹]	**0.886**	**1.01**	**2.12**	2.92%

خواندن صادقانه‌ی این جدول چنین است: DEEDS در هر سه معیار دقت از روش پیشنهادی بهتر عمل می‌کند و این تفاوت معنادار است ($525/49$؛ $p < 10^{-100}$). اما DEEDS یک روش *غیرصلب* است و در میانه ۲/۹ درصد از وکسل‌های درون نقاب—و در بدترین مورد ۱۳/۹ درصد—دترمینان ژاکوبین نامثبت دارد، یعنی تغییرشکل در آن نواحی از نظر فیزیکی نامعتبر است. روش پیشنهادی صلب است و بنا به ساختار، اصلاً نمی‌تواند تاخوردگی تولید کند.

مقایسه‌ی هم‌تراز، مقایسه‌ی صلب با صلب است؛ و در آن‌جا روش پیشنهادی با 0.816 از تنها مبنای صلب موجود در این آزمایش‌ها، یعنی نسخه‌ی بدون نقاب با 0.761، فاصله‌ی معناداری دارد. برای کاربرد پایین‌دستی این پایان‌نامه——ساخت جفت‌های آموزشی سنتز——نبودِ تاخوردگی یک الزام است و نه یک ترجیح: یک تغییرشکل تاخورده، بافت را در حجم هدف جعل می‌کند و مدل سنتز را روی آناتومی نادرست آموزش می‌دهد.

نکته‌ی جانبی اما قابل‌توجه، رفتار روش‌های یادگیرنده روی ساختارهای عروقی است: uniGradICON با وجود بهترین خطای مرکز جرم کلی (1.15 میلی‌متر)، در گروه عروقی خطای 5.8 میلی‌متری دارد، در حالی که روش پیشنهادی در همان گروه 3.4 میلی‌متر می‌دهد. آئورت و بزرگ‌سیاهرگ زیرین دقیقاً ساختارهایی هستند که شدت روشنایی‌شان بیشترین وابستگی را به فاز کنتراست دارد.

جمع‌بندی و محدودیت‌ها

سه ادعای این بخش که شواهد از آن‌ها پشتیبانی می‌کند: محدودسازی دامنه‌ی معیار به نقاب اندام، در همان گروه‌های اندامی که فرضیه پیش‌بینی می‌کرد و نه در گروه شاهد، بهبود معنادار می‌دهد؛ دو گذر صلب نخست اثرهای مکمل و بر گروه‌های متفاوت دارند؛ و دروازه‌های پذیرش، یک گذرِ ناموفق را از یک عامل خرابی به یک عامل بی‌اثر تبدیل می‌کنند.

دو ادعا که شواهد از آن‌ها پشتیبانی نمی‌کند و در متن پیشین این پایان‌نامه مطرح شده بود: هم‌ترازی مرکز جرم دقت نهایی را بهبود نمی‌دهد، و گذر دو در پیکربندی فعلی سودی ندارد.

محدودیت اصلی، اندازه‌ی مجموعه‌ی ارزیابی است. ۱۵۶ بررسی ثبت شدند اما تنها ۲۶ بررسی در همه‌ی شرایط مقایسه خروجی دارند و ارقام بالا بر همین زیرمجموعه استوارند. گسترش ارزیابی به کل مجموعه‌ی ثبت‌شده، پیش از تحویل نهایی، اولویت نخست است.

[نیازمند تکمیل] زمان اجرا و بیشینه‌ی حافظه‌ی هر گام، با وجود وجود ابزار اندازه‌گیری در پایپ‌لاین، ثبت نشده است و ستون هزینه‌ی محاسباتی جدول ۴-۴ خالی است.

[بخش‌های نانوشته] نتایج تجربی تشخیص فاز و سنتز، و ارزیابی پایین‌دستی بخش‌بندی، هنوز نوشته نشده‌اند.

فصل ۵

نتیجه‌گیری

Bibliography

[1] L. European Association for the Study of the. Easl clinical practice guidelines: Management of hepatocellular carcinoma. J. Hepatol., 69(1):182–236, 2018. 10.1016/j.jhep.2018.03.019.

[2] A. Forner, M. Reig, and J. Bruix. Hepatocellular carcinoma. Lancet, 391(10127):1301–1314, 2018. 10.1016/S0140-6736(18)30010-2.

[3] S. Jeon, I. Joo, J. Park, J.-M. Kim, S. Park, and S. Yoon. Fully-automated multi-organ segmentation tool applicable to both non-contrast and post-contrast abdominal CT: deep learning algorithm developed using dual-energy CT images. *Scientific Reports*, 14:4378, 2024.

[4] L. Abel, J. Wasserthal, M. Meyer, J. Vosshenrich, S. Yang, R. Donners, et al. Intra-individual reproducibility of automated abdominal organ segmentation—performance of TotalSegmentator compared to human readers and an independent nnU-Net model. *Journal of Imaging Informatics in Medicine*, 2025.

[5] Z. et al. Ncct-to-cect synthesis with contrast-enhanced knowledge and anatomical perception for multi-organ segmentation in non-contrast ct images, 2024. https://doi.org/10.1016/j.media.2024.103397.

[6] S. Danaei, Z. Dehghanian, E. Meftah, N. Naderi, S. Safavi-Naini, F. Khorasanizade, and H. Rabiee. State of abdominal ct datasets: A critical review of bias, clinical relevance, and real-world applicability. *PLOS Digital Health*, 2026. In press.

[7] B. Dao, T. Nguyen, H. Pham, and H. Nguyen. Phase recognition in contrast-enhanced ct scans based on deep learning and random sampling (vindr-multiphase dataset). Medical Physics, 49(5):3102–3116, 2022. 10.1002/mp.15551.

[8] F. Isensee, P. Jaeger, S. Kohl, J. Petersen, and K. Maier-Hein. nnu-net: a self-configuring method for deep learning-based biomedical image segmentation. *Nature Methods*, 18(2):203–211, 2021.

[9] M. Antonelli, A. Reinke, S. Bakas, et al. The medical segmentation decathlon. *Nature Communications*, 13, 2022.

[10] J. Wasserthal, H.-C. Breit, and M. Meyer. Totalsegmentator: Robust segmentation of 104 anatomic structures in ct images. Radiology: Artif. Intell., 5(5):e230024, 2023. 10.1148/ryai.230024.

[11] J. Ma, Y. Zhang, S. Gu, C. Zhu, C. Ge, Y. Zhang, et al. Abdomenct-1k: Is abdominal organ segmentation a solved problem? *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 44(10):6695–6714, 2021.

[12] J. Ma, Y. Zhang, S. Gu, C. Ge, E. Wang, Q. Zhou, et al. Automatic organ, pancancer segmentation in abdomen CT: the FLARE 2023 challenge, 2024. arXiv preprint arXiv:2408.12534.

[13] W. Li, C. Qu, X. Chen, P. Bassi, Y. Shi, Y. Lai, et al. Abdomenatlas: A large-scale, detailed-annotated, & multi-center dataset for efficient transfer learning, open algorithmic benchmarking. *Medical Image Analysis*, 97:103285, 2024.

[14] J. Liu, Y. Zhang, J. Chen, J. Xiao, Y. Lu, B. Landman, et al. CLIP-driven universal model for organ segmentation and tumor detection. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2023.

[15] C. Yu, C. Anakwenze, Y. Zhao, R. Martin, E. Ludmir, J. Niedzielski, et al. Multi-organ segmentation of abdominal structures from non-contrast and contrast enhanced CT images. *Scientific Reports*, 12, 2022.

[16] J. Park, I. Joo, S. K. Jeon, J.-M. Kim, S. J. Park, and S. H. Yoon. Automated abdominal organ segmentation algorithms for non-enhanced CT for volumetry and 3D radiomics analysis. *Abdominal Radiology*, 50(3):1448–1456, 2025.

[17] P. Christ et al. LiTS – liver tumor segmentation challenge (LiTS17). CodaLab competition 17094, 2017. 10.48550/arXiv.1901.04056.

[18] N. Heller, N. Sathianathen, A. Kalapara, E. Walczak, K. Moore, H. Kaluzniak, et al. Data from C4KC-KiTS. In *The Cancer Imaging Archive*, 2019.

[19] Y. Ji, H. Bai, C. Ge, J. Yang, Y. Zhu, R. Zhang, et al. AMOS: A large-scale abdominal multi-organ benchmark for versatile medical image segmentation. *Advances in Neural Information Processing Systems*, 35:36722–36732, 2022.

[20] X. Luo, W. Liao, J. Xiao, J. Chen, T. Song, X. Zhang, et al. WORD: A large scale dataset, benchmark, clinical applicable study for abdominal organ segmentation from CT image. *Medical Image Analysis*, 82:102642, 2022.

[21] B. Koch, E. Denton, A. Hanna, and J. Foster. Reduced, reused and recycled: The life of a dataset in machine learning research, 2021. arXiv preprint arXiv:2112.01716.

[22] G. Varoquaux and V. Cheplygina. Machine learning for medical imaging: methodological failures and recommendations for the future. *NPJ Digital Medicine*, 5(1):48, 2022.

[23] Z. Obermeyer, B. Powers, C. Vogeli, and S. Mullainathan. Dissecting racial bias in an algorithm used to manage the health of populations. *Science*, 366(6464):447–453, 2019.

[24] A. Larrazabal, N. Nieto, V. Peterson, D. Milone, and E. Ferrante. Gender imbalance in medical imaging datasets produces biased classifiers for computer-aided diagnosis. *Proceedings of the National Academy of Sciences*, 117(23):12592–12594, 2020.

[25] A. Kaushal, R. Altman, and C. Langlotz. Geographic distribution of US cohorts used to train deep learning algorithms. *JAMA*, 324(12):1212–1213, 2020.

[26] L. Seyyed-Kalantari, H. Zhang, M. McDermott, I. Chen, and M. Ghassemi. Underdiagnosis bias of artificial intelligence algorithms applied to chest radiographs in under-served patient populations. *Nature Medicine*, 27(12):2176–2182, 2021.

[27] R. Daneshjou, K. Vodrahalli, R. Novoa, M. Jenkins, W. Liang, V. Rotemberg, et al. Disparities in dermatology AI performance on a diverse, curated clinical image set. *Science Advances*, 8(32):eabq6147, 2022.

[28] C. Jones, D. Castro, F. De Sousa Ribeiro, O. Oktay, M. McCradden, and B. Glocker. A causal perspective on dataset bias in machine learning for medical imaging. *Nature Machine Intelligence*, 6(2):138–146, 2024.

[29] B. Koçak, A. Ponsiglione, A. Stanzione, C. Bluethgen, J. Santinha, L. Ugga, et al. Bias in artificial intelligence for medical imaging: Fundamentals, detection,

avoidance, mitigation, challenges, ethics, prospects. *Diagnostic and Interventional Radiology*, 2024.

[30] Z. Xu et al. Addressing fairness issues in deep learning-based medical image analysis: A systematic review. *npj Digital Medicine*, 7:265, 2024.

[31] K. Moons, J. Damen, T. Kaul, L. Hooft, C. Andaur Navarro, P. Dhiman, et al. PROBAST+AI: an updated quality, risk of bias, and applicability assessment tool for prediction models using regression or artificial intelligence methods. *BMJ*, 388, 2025.

[32] G. Collins, K. Moons, P. Dhiman, R. Riley, A. Beam, B. Van Calster, et al. TRIPOD+AI statement: updated guidance for reporting clinical prediction models that use regression or machine learning methods. *BMJ*, 385:e078378, 2024.

[33] R. Muhamedrahimov, A. Bar, J. Laserson, A. Akselrod-Ballin, and E. Elnekave. Using machine learning to identify intravenous contrast phases on computed tomography. *Computer Methods and Programs in Biomedicine*, 215:106603, 2022.

[34] B. Hou, T. S. Mathai, P. Mukherjee, X. Wang, R. M. Summers, and Z. Lu. Segment-and-classify: ROI-guided generalizable contrast phase classification in CT using XGBoost. *arXiv preprint arXiv:2501.14066*, 2025.

[35] E. P. Reis, L. Blankemeier, J. M. Zambrano Chaves, et al. Automated abdominal CT contrast phase detection using an interpretable and open-source artificial intelligence algorithm. *European Radiology*, 34(10):6680–6687, 2024.

[36] G. Baldini, R. Hosch, C. S. Schmidt, K. Borys, L. Kroll, S. Koitka, P. Haubold, O. Pelka, F. Nensa, and J. Haubold. Addressing the contrast media recognition challenge: A fully automated machine learning approach for predicting contrast phases in CT imaging. *Investigative Radiology*, 59(9):635–645, 2024.

[37] Z. Ye, J. M. Qian, A. Hosny, et al. Deep learning-based detection of intravenous contrast enhancement on CT scans. *Radiology: Artificial Intelligence*, 4:e210285, 2022.

[38] B. T. Dao, T. V. Nguyen, H. H. Pham, and H. Q. Nguyen. Phase recognition in contrast-enhanced CT scans based on deep learning and random sampling. *Medical Physics*, 49(5):3102–3116, 2022. VinDr-Multiphase dataset paper; random-slice-sampling majority-vote phase classifier.

[39] B. A. Rocha, L. C. Ferreira, L. G. R. Vianna, et al. Contrast phase recognition in liver computer tomography using deep learning. *Scientific Reports*, 12:20315, 2022.

[40] Q. Liu, J. Jiang, K. Wu, Y. Zhang, N. Sun, J. Luo, T. Ba, A. Lv, C. Liu, Y. Yin, Z. Yang, and H. Xu. A two-step automatic identification of contrast phases for abdominal CT images based on residual networks. *Insights into Imaging*, 2025.

[41] A. Anand, J. Liu, T. C. Shen, W. M. Linehan, P. A. Pinto, and R. M. Summers. Automated classification of intravenous contrast enhancement phase of CT scans using residual networks. In *Proc. SPIE 12465, Medical Imaging 2023: Computer-Aided Diagnosis*, page 124650O, 2023.

[42] . WAW-TACE: A hepatocellular carcinoma multiphase CT dataset with segmentations, radiomics features, and clinical data. *Radiology: Artificial Intelligence*, 2024. Zenodo DOI: 10.5281/zenodo.11063784.

[43] N. Heller, N. Sathianathen, A. Kalapara, et al. Data from C4KC-KiTS. The Cancer Imaging Archive, 2019.

[44] I. Wells WM, P. Viola, H. Atsumi, S. Nakajima, and R. Kikinis. Multi-modal volume registration by maximization of mutual information. Med. Image Anal., 1(1):35–51, 1996. 10.1016/S1361-8415(01)80004-9.

[45] C. Studholme, D. Hill, and D. Hawkes. An overlap invariant entropy measure of 3d medical image alignment. Pattern Recognition, 32(1):71–86, 1999. 10.1016/S0031-3203(98)00091-0.

[46] D. Mattes, D. Haynor, H. Vesselle, T. Lewellen, and W. Eubank. Nonrigid multimodality image registration. Proc. SPIE Med. Imaging, 4322:1609–1620, 2001. 10.1117/12.431046.

[47] B. Avants, C. Epstein, M. Grossman, and J. Gee. Symmetric diffeomorphic image registration with cross-correlation: Evaluating automated labeling of elderly and neurodegenerative brain. Med. Image Anal., 12(1):26–41, 2008. 10.1016/j.media.2007.06.004.

[48] M. Heinrich, M. Jenkinson, M. Bhushan, T. Matin, F. Gleeson, S. Brady, and J. Schnabel. Mind: Modality independent neighbourhood descriptor for multimodal deformable registration. Med. Image Anal., 16(7):1423–1435, 2012. 10.1016/j.media.2012.05.008.

[49] M. Heinrich, M. Jenkinson, M. Brady, and J. Schnabel. Deeds: Mrf-based nonlinear image registration using efficient discrete optimization. Int. J. Comput. Vis., 103(3):384–400, 2013. 10.1007/s11263-013-0606-z.

[50] K. Murphy, B. van Ginneken, and S. Klein. Semi-automatic construction of reference standards for evaluation of image registration. Med. Image Anal., 15(1):71–84, 2011. 10.1016/j.media.2010.07.005.

[51] G. Balakrishnan, A. Zhao, M. Sabuncu, J. Guttag, and A. Dalca. Voxelmorph: A learning framework for deformable medical image registration. IEEE Trans. Med. Imaging, 38(8):1788–1800, 2019. http://doi..org/10.1109/TMI.2019.2897538.

[52] J. Chen, E. Frey, Y. He, W. Segars, Y. Li, and Y. Du. Transmorph: Transformer for unsupervised medical image registration. Med. Image Anal., 82:102615, 2022. 10.1016/j.media.2022.102615.

[53] S. Klein, M. Staring, K. Murphy, M. Viergever, and J. Pluim. Elastix: A toolbox for intensity-based medical image registration. IEEE Trans. Med. Imaging, 29(1):196–205, 2010. 10.1109/TMI.2009.2035616.

[54] B. Lowekamp, D. Chen, L. Ibanez, and D. Blezek. The design of simpleitk. Front. Neuroinform., 7:45, 2013. 10.3389/fninf.2013.00045.

[55] J.-P. Thirion. Image matching as a diffusion process: An analogy with maxwell's demons. Med. Image Anal., 2(3):243–260, 1998. 10.1006/mian.1998.0107.

[56] D. Rueckert, L. Sonoda, C. Hayes, D. Hill, M. Leach, and D. Hawkes. Nonrigid registration using free-form deformations: Application to breast mr images. IEEE Trans. Med. Imaging, 18(8):712–721, 1999. 10.1109/42.796284.

[57] J. Pluim, J. Maintz, and M. Viergever. Mutual-information based registration of medical images: A survey. IEEE Trans. Med. Imaging, 22(8):986–1004, 2003. 10.1109/TMI.2003.815867.

[58] C. Metz, S. Klein, M. Schaap, T. van Walsum, and W. Niessen. Nonrigid registration of dynamic medical imaging data using nd+t b-splines and a groupwise optimization approach. Med. Image Anal., 15(2):238–249, 2011. 10.1016/j.media.2010.10.003.

[59] B. Papiez, M. Heinrich, L. Risser, and J. Schnabel. An implicit sliding-motion preserving regularisation via bilateral filtering for deformable image registration. Med. Image Anal., 18(8):1323–1335, 2014. 10.1016/j.media.2014.06.006.

[60] B. De Vos, F. Berendsen, M. Viergever, H. Sokooti, M. Staring, and I. Isgum. A deep learning framework for unsupervised affine and deformable image registration. Med. Image Anal., 52:128–143, 2019. 10.1016/j.media.2019.02.003.

[61] Y. Hu, M. Modat, and E. Gibson. Weakly-supervised convolutional neural networks for multimodal image registration. Med. Image Anal., 49:1–13, 2018. 10.1016/j.media.2018.07.002.

[62] O. Oktay, E. Ferrante, and K. Kamnitsas. Anatomically constrained neural networks (acnn): Application to cardiac image enhancement and segmentation. IEEE Trans. Med. Imaging, 37(2):384–395, 2018. 10.1109/TMI.2017.2743464.

[63] T. Mok and A. Chung. Large deformation diffeomorphic image registration with laplacian pyramid networks. Proc. MICCAI 2020, pp. 211–221, 2020. 10.1007/978-3-030-59716-0_21.

[64] Z. Zhao, V. Lau, and Z. Li. Recursive cascaded networks for unsupervised medical image registration. Proc. ICCV 2019, pp. 10600–10610, 2019. 10.1109/ICCV.2019.01069.

[65] A. Hoopes, M. Hoffmann, B. Fischl, J. Guttag, and A. Dalca. Hypermorph: Amortised hyperparameter learning for image registration. Proc. IPMI 2021, pp. 3–17, 2021. 10.1007/978-3-030-78191-0_1.

[66] Z. Xu and M. Niethammer. Deepatlas: Joint semi-supervised learning of image registration and segmentation. Proc. MICCAI 2019, pp. 420–429, 2019. 10.1007/978-3-030-32245-8_47.

[67] H. Tian. Unigradicon: A foundation model for medical image registration. arXiv:2403.05780, 2024. https://arxiv.org/abs/2403.05780.

[68] S. Park, E. K. Fishman, and A. L. Yuille. Multi-phase deformable registration for time-dependent abdominal organ variations. arXiv:2103.05525, 2021. https://arxiv.org/abs/2103.05525.

[69] Y. et al. Synthesizing contrast-enhanced computed tomography images with an improved conditional generative adversarial network, 2022. https://doi.org/10.1109/EMBC48229.2022.9871672.

[70] Y. et al. Spatial attention-guided generative adversarial network for synthesizing contrast-enhanced computed tomography images, 2023. https://doi.org/10.1109/EMBC40787.2023.10340586.

[71] Y. et al. Segmentation guided crossing dual decoding generative adversarial network for synthesizing contrast-enhanced computed tomography images, 2024. https://doi.org/10.1109/JBHI.2024.3403199.

[72] Y. et al. Oa-gan: organ-aware generative adversarial network for synthesizing contrast-enhanced medical images, 2024. https://doi.org/10.1088/2057-1976/ad31fa.

[73] Z. et al. Man-gan: a mask-adaptive normalization based generative adversarial networks for liver multi-phase ct image generation, 2025. https://doi.org/10.1038/s41598-025-10754-z.

[74] C. et al. Mask-aware transformer with structure invariant loss for ct translation, 2024. https://doi.org/10.1016/j.media.2024.103205.

[75] Z. et al. Contrast-aware network with aggregated-interacted transformer and multi-granularity aligned contrastive learning for synthesizing contrast-enhanced abdomen ct imaging, 2025. https://doi.org/10.1109/TCI.2025.3540711.

[76] C. et al. Generating synthetic contrast enhancement from non-contrast chest computed tomography using a generative adversarial network, 2021. https://doi.org/10.1038/s41598-021-00058-3.

[77] X. et al. Generation of contrast-enhanced ct with residual cycle-consistent generative adversarial network (res-cyclegan), 2021. https://doi.org/10.1117/12.2581056.

[78] R. et al. Cytran: A cycle-consistent transformer with multi-level consistency for non-contrast to contrast ct translation, 2021. https://arxiv.org/abs/2110.06400.

[79] S. et al. Unpaired medical image translation between portal-venous phase and non-contrast ct volumes for multi-organ segmentation, 2021. https://doi.org/10.1117/12.2590639.

[80] Z. et al. Contrast flow pattern and cross-phase specificity-aware diffusion model for ncct-to-multiphase cect synthesis, 2025. https://doi.org/10.1007/978-3-032-04965-0_9.

[81] Z. et al. Cross-domain distribution adversarial diffusion model for synthesizing contrast-enhanced abdomen ct imaging, 2025. https://www.sciencedirect.com/science/article/abs/pii/S0031320325003553.

[82] W. et al. Synthesis of abdominal contrast-enhanced ct using diffusion-based spatial transform control, 2025. https://doi.org/10.1007/978-3-032-09513-8_14.

[83] Z. et al. Causality-driven spatio-temporal generator for multi-phase contrast-enhanced ct synthesis, 2025. https://doi.org/10.1007/978-3-032-04947-6_11.

[84] L. et al. A text-guided brownian bridge diffusion model for unified multiphase contrast-enhanced ct synthesis, 2026.

[85] Z. et al. United multi-task learning for abdominal contrast-enhanced ct synthesis through joint deformable registration, 2023. https://doi.org/10.1016/j.cmpb.2023.107391.

[86] L. et al. Boosting medical image synthesis via registration-guided consistency and disentanglement learning, 2024. https://arxiv.org/abs/2407.07660.

[87] U. et al. A unified multi-phase ct synthesis and classification framework for kidney cancer diagnosis with incomplete data, 2022. https://doi.org/10.1109/JBHI.2022.3219123.

[88] H. et al. Clinical feasibility of deep learning based synthetic contrast enhanced abdominal ct in patients undergoing non enhanced ct scans, 2024. https://doi.org/10.1038/s41598-024-68705-z.

[89] K. et al. The feasibility of deep learning-based synthetic contrast-enhanced ct from nonenhanced ct in emergency department patients with acute abdominal pain, 2021. https://doi.org/10.1038/s41598-021-99896-4.

[90] H. et al. Contrast agent dose reduction in computed tomography with deep learning using a conditional generative adversarial network, 2021. https://doi.org/10.1007/s00330-021-07714-2.

[91] H. et al. Contrast media reduction in computed tomography with deep learning using a generative adversarial network in an experimental animal study, 2022. https://pubmed.ncbi.nlm.nih.gov/35438659/.

[92] A. et al. Applications of deep learning to reduce the need for iodinated contrast media for ct imaging: a systematic review, 2023. https://doi.org/10.1007/s11548-023-02862-w.

[93] J. et al. Deep learning for synthetic contrast-enhanced ct and mri: a scoping review, 2026. https://doi.org/10.1007/s00330-026-12548-x.

[94] X. Zhou, J. Wu, H. Zhao, L. Chen, S. Zhang, and G. Wang. GLFC: Unified global-local feature and contrast learning with mamba-enhanced UNet for synthetic CT generation from CBCT, 2025. arXiv:2501.02992; https://github.com/HiLab-git/GLFC.

[95] M. Fukuda, S. Kotaki, M. Nozawa, C. Kuwada, Y. Kise, E. Ariji, and Y. Ariji. A cycle generative adversarial network for generating synthetic contrast-enhanced computed tomographic images from non-contrast images in the internal jugular lymph node-bearing area, 2024.

[96] A. Rofena, V. Guarrasi, M. Sarli, C. L. Piccolo, M. Sammarra, B. B. Zobel, and P. Soda. A deep learning approach for virtual contrast enhancement in contrast enhanced spectral mammography. *Computerized Medical Imaging and Graphics*, 116:102398, 2024. https://github.com/cosbidev/VCE_CESM.

[97] P. et al. Multi-phase synthetic contrast enhancement in interventional computed tomography for guiding renal cryotherapy, 2023. https://doi.org/10.1007/s11548-023-02843-z.

[98] W. Li et al. Virtual contrast-enhanced magnetic resonance images synthesis for patients with nasopharyngeal carcinoma using multimodality-guided synergistic neural network. *International Journal of Radiation Oncology*Biology*Physics*, 112(4):1033–1044, 2022. https://github.com/WenLi-PolyU/MMgSN-Net-for-vce-MRI-synthesis.

[99] J. Li, Z. Qu, Y. Yang, F. Zhang, M. Li, and S. Hu. TCGAN: a transformer-enhanced GAN for PET synthetic CT. *Biomedical Optics Express*, 13(11):6003–6018, 2022. https://github.com/jinxiqinghuan/TCGAN.

[100] S. Kida, S. Kaji, et al. Visual enhancement of cone-beam CT by use of CycleGAN. *Medical Physics*, 47(3):998–1010, 2020. arXiv:1901.05773; https://github.com/shizuo-kaji/UnpairedImageTranslation.

[101] L. et al. Virtual contrast enhancement for ct scans of abdomen and pelvis, 2022. https://doi.org/10.1016/j.compmedimag.2022.102094.

[102] S. et al. Neural contrast enhancement of ct image, 2021. https://openaccess.thecvf.com/content/WACV2021/html/Seo_Neural_Contrast_Enhancement_of_CT_Image_WACV_2021_paper.html.

[103] P. et al. Time conditioning for arbitrary contrast phase generation in interventional computed tomography, 2024. https://doi.org/10.1088/1361-6560/ad46dd.

[104] S. et al. Synthetic contrast enhancement in cardiac ct with deep learning, 2018. https://arxiv.org/abs/1807.01779.

[105] D. et al. Development and evaluation of a novel organ-specific biomechanics-guided contrast-enhanced ct volume synthesis model, 2025.

[106] L. et al. Dyefreenet: Deep virtual contrast ct synthesis, 2020. https://doi.org/10.1007/978-3-030-59520-3_9.

[107] S. et al. Generating synthetic contrast-enhanced chest ct images from non-contrast scans using slice-consistent brownian bridge diffusion network, 2025. https://arxiv.org/abs/2508.16897.

[108] P. et al. Ncct-cect image synthesizers and their application to pulmonary vessel segmentation, 2023. https://doi.org/10.1016/j.cmpb.2023.107389.

[109] L. et al. Generative adversarial network-based noncontrast ct angiography for aorta and carotid arteries, 2023. https://doi.org/10.1148/radiol.230681.

[110] H. et al. Aorta-aware gan for non-contrast to artery contrasted ct translation and its application to abdominal aortic aneurysm detection, 2021. https://doi.org/10.1007/s11548-021-02492-0.

[111] L. et al. Translate contrast-enhanced ct from non-contrast ct via subtraction image prediction, 2025. https://www.sciencedirect.com/science/article/pii/S0360301625037952.

[112] J. A. C. Sterne, M. A. Hernán, B. C. Reeves, J. Savović, N. D. Berkman, M. Viswanathan, et al. ROBINS-I: a tool for assessing risk of bias in non-randomised studies of interventions. *BMJ*, 355:i4919, 2016.

[113] H. J. Schünemann, C. Cuello, E. A. Akl, R. A. Mustafa, J. J. Meerpohl, K. Thayer, et al. GRADE guidelines: 18. how ROBINS-I and other tools to assess risk of bias in nonrandomized studies should be used to rate the certainty of a body of evidence. *Journal of Clinical Epidemiology*, 111:105–114, 2019.

[114] P. F. Whiting, A. W. S. Rutjes, M. E. Westwood, S. Mallett, J. J. Deeks, J. B. Reitsma, et al. QUADAS-2: A revised tool for the quality assessment of diagnostic accuracy studies. *Annals of Internal Medicine*, 155(8):529–536, 2011.

[115] T. Chen and C. Guestrin. XGBoost: A scalable tree boosting system. In *ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794, 2016.

[116] W. Kabsch. A solution for the best rotation to relate two sets of vectors. Acta Crystallogr. A, 32(5):922–923, 1976. 10.1107/S0567739476001873.

[117] J. Nelder and R. Mead. A simplex method for function minimization. Comput. J., 7(4):308–313, 1965. 10.1093/comjnl/7.4.308.

[118] O. Ronneberger, P. Fischer, and T. Brox. U-net: Convolutional networks for biomedical image segmentation. pages 234–241, 2015.

[119] Y. Wu and K. He. Group normalization. In *European Conference on Computer Vision (ECCV)*, pages 3–19, 2018.

[120] D. Ulyanov, A. Vedaldi, and V. Lempitsky. Instance normalization: The missing ingredient for fast stylization. *arXiv preprint arXiv:1607.08022*, 2016.

[121] P. Isola, J.-Y. Zhu, T. Zhou, and A. A. Efros. Image-to-image translation with conditional adversarial networks. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 5967–5976, 2017.

[122] I. Loshchilov and F. Hutter. SGDR: Stochastic gradient descent with warm restarts. *International Conference on Learning Representations (ICLR)*, 2017.

[123] E. Perez, F. Strub, H. de Vries, V. Dumoulin, and A. Courville. FiLM: Visual reasoning with a general conditioning layer. In *AAAI Conference on Artificial Intelligence*, pages 3942–3951, 2018.

[124] A. Kendall and Y. Gal. What uncertainties do we need in bayesian deep learning for computer vision? In *Advances in Neural Information Processing Systems (NeurIPS)*, pages 5574–5584, 2017.

[125] J. Ho, A. Jain, and P. Abbeel. Denoising diffusion probabilistic models. *Advances in Neural Information Processing Systems*, 33:6840–6851, 2020.

[126] T. Salimans and J. Ho. Progressive distillation for fast sampling of diffusion models. In *International Conference on Learning Representations (ICLR)*, 2022.

[127] J. Song, C. Meng, and S. Ermon. Denoising diffusion implicit models. In *International Conference on Learning Representations (ICLR)*, 2021.

[128] J. Ho and T. Salimans. Classifier-free diffusion guidance. *arXiv preprint arXiv:2207.12598*, 2022.

[129] T. Hang, S. Gu, C. Li, J. Bao, D. Chen, H. Hu, X. Geng, and B. Guo. Efficient diffusion training via min-SNR weighting strategy. In *IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 7441–7451, 2023.

[130] T.-C. Wang, M.-Y. Liu, J.-Y. Zhu, A. Tao, J. Kautz, and B. Catanzaro. High-resolution image synthesis and semantic manipulation with conditional gans. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 8798–8807, 2018.

[131] J.-Y. Zhu, T. Park, P. Isola, and A. A. Efros. Unpaired image-to-image translation using cycle-consistent adversarial networks. In *IEEE International Conference on Computer Vision (ICCV)*, pages 2242–2251, 2017.

[132] O. Dalmaz, M. Yurt, and T. Çukur. ResViT: Residual vision transformers for multimodal medical image synthesis. *IEEE Transactions on Medical Imaging*, 41(10):2598–2614, 2022.

[133] A. Hatamizadeh, V. Nath, Y. Tang, D. Yang, H. R. Roth, and D. Xu. Swin unetr: Swin transformers for semantic segmentation of brain tumors in MRI images. In *International MICCAI Brainlesion Workshop*, pages 272–284, 2021.

[134] J. Chen, Y. Lu, Q. Yu, X. Luo, E. Adeli, Y. Wang, L. Lu, A. L. Yuille, and Y. Zhou. TransUNet: Transformers make strong encoders for medical image segmentation. *arXiv preprint arXiv:2102.04306*, 2021.

[135] B. Yu, L. Zhou, L. Wang, Y. Shi, J. Fripp, and P. Bourgeat. Ea-GANs: Edge-aware generative adversarial networks for cross-modality MR image synthesis. *IEEE Transactions on Medical Imaging*, 38(7):1750–1762, 2019.

[136] M. Özbey, O. Dalmaz, S. U. H. Dar, H. A. Bedel, Ş. Ünal, and T. Çukur. Unsupervised medical image translation with adversarial diffusion models. *IEEE Transactions on Medical Imaging*, 42(12):3524–3539, 2023.

[137] R. Zhang, P. Isola, A. A. Efros, E. Shechtman, and O. Wang. The unreasonable effectiveness of deep features as a perceptual metric. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 586–595, 2018.

[138] M. Heusel, H. Ramsauer, T. Unterthiner, B. Nessler, and S. Hochreiter. GANs trained by a two time-scale update rule converge to a local nash equilibrium. In

Advances in Neural Information Processing Systems (NeurIPS), pages 6626–6637, 2017.

[139] T. Gneiting and A. E. Raftery. Strictly proper scoring rules, prediction, and estimation. *Journal of the American Statistical Association*, 102(477):359–378, 2007.

[140] J. Llovet, R. Kelley, A. Villanueva, A. Singal, E. Pikarsky, S. Roayaie, et al. Hepatocellular carcinoma. *Nature Reviews Disease Primers*, 7(1):6, 2021.

[141] V. Kedar Mukthinuthalapati, V. Sewram, N. Ndlovu, S. Kimani, A. Abdelaziz, E. Chiao, et al. Hepatocellular carcinoma in sub-saharan africa. *JCO Global Oncology*, 7:756–766, 2021.

واژه‌نامه

الف

انحراف حجمی ..... Volumetric deviation

انتقال حوزه ..... Domain adaptation

اطلاعات متقابل ..... Mutual Information (MI)

اطلاعات متقابل بهنجارشده .. Normalised Mutual Information (NMI)

اشتراکی (پارامتر مشترک) ..... Shared-weight

ب

بخش‌بندی چندعضوی . Multi-organ segmentation

بازخوانی ..... Recall

بی‌اسپلاین ..... B-spline

بهنجارسازی سازگار با نقاب ..... Mask-adaptive normalisation

بدون‌جفت ..... Unpaired

باقیمانده ..... Residual

بهنجارسازی متقارن ... Symmetric Normalisation

برچسب‌های ضعیف ..... Weak labels

پ

پرسش‌محور ..... Prompt-driven

پرخون ..... Hypervascular

پنجره‌ی پارزن ..... Parzen window

پیشین‌های شکل تشریحی Anatomical shape priors

پایداری معکوس گرادیان ..... Gradient inverse consistency

پیمانه‌ای ..... Modular

پل براونی ..... Brownian bridge diffusion

ت

تکرارپذیری ..... Reproducibility

تمرکز محک ..... Benchmark concentration

تصویر متحرک ..... Moving image

تصویر ثابت ..... Fixed image

تغییر شکل آزاد .. Free-Form Deformation (FFD)

تکراری ..... Iterative

تبدیل‌گر فضایی ..... Spatial transformer

توصیف‌گر همسایگی مستقل از وجهیت Modality Independent Neighbourhood Descriptor (MIND)

ترجمه‌ی تصویر ..... Image-to-image translation

توجه چندسر ..... Multi-head attention

تقطیر دانش ..... Knowledge distillation

توجه بین‌فازی ..... Inter-phase attention

توجه فضایی ..... Spatial attention

تصویر بازترکیب‌شده ..... Recombined image

تضعیف اشعه‌ی ایکس ..... X-ray attenuation

ث

ثبت تصویر ..... Image registration
ثبت گروهی ..... Groupwise

ج

جابه‌جایی حوزه‌ای ..... Domain shift
جنگل درختان تقویت‌شده‌ی گرادیانی .... Gradient-boosted decision trees
جفت‌شده ..... Paired
جفت‌شده (خانواده‌ی GAN) ..... Paired GAN

چ

چندگذره ..... Multi-pass

ح

حرکت لغزشی ..... Sliding motion

خ

خودپیکربندی ..... Self-configuring
خطای ثبت هدف ..... Target Registration Error (TRE)
خشن‌به‌ریز ..... Coarse-to-fine
خودشباهت ..... Self-similarity

د

دقت ..... Accuracy
دقت‌مثبت ..... Precision
دیمانز ..... Demons
دایکام ..... DICOM
Dice فرسایش‌یافته ..... Eroded Dice

ز

زیان تغییرناپذیری ساختار .Structure invariant loss
زیان کانونی ..... Focal loss
زیان تباین چندگانه ..... Multiple Contrast Loss

س

سوگیری ..... Bias
سوگیری طیف ..... Spectrum bias
سوگیری انتخاب ..... Selection bias
سوگیری نژادی ..... Racial bias
سوگیری جمعیت‌شناختی ..... Demographic bias
سوگیری فنی ..... Technical bias
سوگیری برچسب‌گذاری ..... Labelling bias
سوگیری زمانی ..... Temporal bias
سی‌تی بدون‌کنتراست .. Non-contrast CT (NCCT)
سی‌تی کنتراست‌دار ..... Contrast-enhanced CT (CECT)
سی‌تی دوانرژی ..... Dual-energy CT
سی‌تی چندفازی ..... Multi-phase CT
سی‌تی شکمی ..... Abdominal CT
سنتز کنتراست مجازی ..... Virtual contrast enhancement
سازگاری چرخه‌ای ..... Cycle-consistency
سی‌تی شکمی چندفازی Multi-phase abdominal CT

ش

شبکه‌های آبشاری بازگشتی ... Recursive Cascaded Networks
شاخص شباهت ساختاری ... Structural Similarity Index (SSIM)
شباهت پرسپچوال یادگرفته‌شده Learned Perceptual

Image Patch Similarity (LPIPS)

شرط‌دهی متنی ..... Text-guided

شست‌وشو ..... Washout

ص

صدک نودوپنجم فاصله‌ی هاسدورف 95th percentile Hausdorff Distance (HD95)

صلب ..... Rigid

صفر/چندنمونه ..... Zero/few-shot

ض

ضریب هم‌پوشانی سورنسن–دایس .. Sørensen–Dice coefficient

ضریب همبستگی پیرسون .... Pearson Correlation Coefficient (PCC)

غ

غربالگری فرصت‌طلبانه .. Opportunistic screening

ف

فاز بدون‌کنتراست ..... Non-contrast (NC) phase

فاز کنتراست ..... Contrast phase

فاز کنتراست‌دار . Contrast-enhanced (CE) phase

فاصله‌ی مرکز جرم ..... Centroid distance

فاصله‌ی آغازشی فرشه Fréchet Inception Distance (FID)

فضازمانی علّی Causality-driven spatio-temporal

فاز شریانی ..... Arterial phase

فاز وریدی باب ..... Portal venous phase

فاز تأخیری ..... Delayed phase

ک

کارسینوم سلول کبدی . Hepatocellular carcinoma (HCC)

م

منحنی مشخصه‌ی عملکرد سیستم ..... Receiver Operating Characteristic curve (ROC)

مقیاس‌پذیری ترکیبی ..... Compound scaling

منظم‌ساز ..... Regulariser

مدل بنیادین ..... Foundation model

مستقل از وجهیت ..... Modality-independent

میدان تصادفی مارکوف ... Markov Random Field (MRF)

میانگین قدرمطلق خطا ..... Mean Absolute Error (MAE)

میانگین مربعات خطا Mean Squared Error (MSE)

مدل‌های انتشار ..... Diffusion models

ماده‌ی حاجب ..... Contrast media

ماده‌ی حاجب یددار . Iodinated contrast medium

ماموگرافی طیفی کنتراست‌دار .. Contrast Enhanced Spectral Mammography (CESM)

ن

نسبت کنتراست‌به‌نویز .... Contrast-to-noise ratio (CNR)

نقاب ..... Mask

نشت داده ..... Data leakage

نشانه‌های آناتومیک ..... Anatomical landmarks

نظارت ضعیف ..... Weak supervision

نقاب تصویر ثابت ..... Fixed-image mask

نسبت سیگنال به نویز اوج ... Peak Signal-to-Noise

Ratio (PSNR)

نمایندگی ..... Representativeness

و

وضعیت فاز کنتراست .... Contrast enhancement status

هـ

هم‌پوشانی برچسب ..... Label overlap (Dice)

همبستگی متقابل نرمال‌شده ..... Normalised Cross-Correlation (NCC)

ی

یادگیری فدرال ..... Federated learning

یادگیری متضاد چندگرانی ..... Multi-granularity contrastive learning

یک‌درمقابل‌بقیه ..... One-vs-rest

پیوست آ

مطالب تکمیلی

Abstract

We present a standard template for typesetting theses in Persian. The template is based on the XePersian package for the LaTeX typesetting system. This write-up shows a sample usage of this template.

Keywords: Thesis, Typesetting, Template, XePersian



Sharif University of Technology

Department of Computer Engineering

M.Sc. Thesis

Bioinformatics Thesis

Automatic multi-organ Segmentation in Abdominal CT with enhancing performance in non-contrast CT studies

By:

Saeide Danaei

Supervisor:

Hamid R. Rabiee

September 2026